

华北电力大学

学术硕士学位论文

基于特征频率分组融合的轻量级图像

超分辨率算法研究

Research on Lightweight Super-Resolution Algorithm
Based on Grouping Fusion of Feature Frequencies

高丹丹

2023 年 5 月

国内图书分类号：TP39
国际图书分类号：004.9

学校代码：10079
密级：公开

学术硕士学位论文

基于特征频率分组融合的轻量级图像
超分辨率算法研究

硕士研究生：高丹丹

导师：周登文教授

申请学位：工学硕士

学科：计算机科学与技术

专业：计算机科学与技术

所在学院：控制与计算机工程学院

答辩日期：2023年5月18日

授予学位单位：华北电力大学

Classified Index: TP39

U.D.C: 004.9

Dissertation for the Academic Master's Degree

**Research on Lightweight Super-Resolution Algorithm
Based on Grouping Fusion of Feature Frequencies**

Candidate:	Gao Dandan
Supervisor:	Prof.Zhou Dengwen
Academic Degree Applied for:	Master of Engineering
Subject:	Computer Science and Technology
Speciality:	Computer Science and Technology
School:	School of Control and Computer Engineering
Date of Defence:	May 18, 2023
Degree-Conferring-Institution:	North China Electric Power University

摘 要

单图像超分辨率算法是视觉领域中的重要任务之一,它的目的是从低分辨率图像中获取高分辨率图像。目前,深度卷积神经网络显著提升了单图像超分辨率的性能,已经成为主流的方法。通常,网络规模越大,性能越好,但是所需要的计算成本和存储资源也越高,这限制了其在资源受限设备上的应用。因此,研究轻量级的超分辨率网络模型设计是非常有必要的。本文通过构建新的网络结构,设计了平衡模型复杂度和性能的轻量级图像超分辨率算法。本文的主要工作和成果概括如下:

(1) 提出了基于特征频率分组融合的图像超分辨率算法。首先,构造了残差拼接块,该模块同时使用残差学习和通道拼接,促进局部特征信息的传递和融合;然后,通过多路混合注意力块,从不同的尺度收集不同的特征信息线索,以提高网络的细节保真度,为网络重建提供丰富的图像信息和高频细节;最后,使用特征频率分组融合块,融合全局特征信息。其中,特征频率分组融合块利用了特征高、低频信息的差异性,首先对特征进行分组,然后从特征差异性最大的分组开始,逐步地融合各分组特征。实验结果表明,本文设计的算法可以更好地利用网络中各个层次的信息,使高频和低频特征信息更好地融合,提高了超分辨率图像的重建质量。

(2) 提出了基于轻量卷积的图像超分辨率算法。首先,构造了一种新型的分组卷积,称为渐进交互组卷积,它比传统的分组卷积更加有效。它首先对输入特征进行特征分离,并逐步处理分离后的特征,接着将已处理的分组与未处理的分组之间的信息进行渐进性地交互,增强了不同通道上特征间的相互作用;然后,设计了一种专门用于图像超分辨率的轻量级卷积块,该卷积块由渐进交互组卷积、通道搅拌和深度可分离卷积三部分组成,有效地减少了网络的参数量;最后,设计轻量级残差拼接块,作为网络模型的基础构建块,它使网络更具轻量化和竞争性。为了更好地融合多层次的特征信息,提取更丰富的细节,本方法引入了前文的特征频率分组融合块和多路混合注意力块。实验结果表明,该方法在复杂度和性能之间取得了良好的平衡,是一种实用的方法,能够提高超分辨率图像的重建质量。

综上所述,本文提出的算法旨在平衡模型的复杂性和性能,构建轻量级的超分辨率网络,并提高重建图像的质量。在数据集相同的条件下,本文与选取的参

数量相近的轻量级算法重建结果进行对比实验，结果表明，所提算法的超分辨率重建结果在主观视觉效果和客观评价指标方面都取得了较好的表现。本文的算法提供了有效地方法来设计轻量级的超分辨率算法，为资源受限设备上的超分辨率图像处理提供了一种新的选择。

关键词：图像超分辨率；特征融合；频率分组；注意力机制；分组卷积

Abstract

Single image super-resolution algorithm is one of the important tasks in the field of computer vision. Its goal is to restore high-resolution images from images which are low-resolution. At present, deep convolutional neural networks have significantly improved the performance of single image super-resolution, and have become the mainstream algorithms. Ordinarily, the larger the network size, the better the performance, but the higher the computing cost and storage resources are required, which limits their applications on resource-constrained devices. Therefore, it is very necessary to study the design of lightweight super-resolution network models. In this paper, some lightweight super-resolution networks that balance model complexity and performance are proposed by improving the network structure. The main research work and results of this thesis are summarized below:

(1) We proposed an image super-resolution algorithm via grouping fusion of feature frequencies. Firstly, the residual concatenation block is constructed, which uses both residual learning and channel concatenation to promote the transfer and fusion of local feature information; Then, the proposed multi-way hybrid attention block is used to collect different feature information clues from different scales to improve the detail fidelity of the network, providing rich image information and more high-frequency details for network reconstruction; Finally, the feature frequency grouping fusion block is used to fuse global feature information. The feature frequency grouping fusion block utilizes the differences between the high and low frequency information of features, firstly groups the features, and then gradually fuses the features of each group starting from the group with the largest feature difference. Experimental results demonstrate that the method in this paper can make better use of the hierarchical information in the network make better fusion of high-frequency and low-frequency feature information, and improve the reconstruction quality of super-resolution images.

(2) We proposed a super-resolution algorithm based on lightweight convolution. First, a novel group convolution is designed, called progressive interactive group convolution, which is more efficient than traditional group convolution. It first separates the input features, and progressively processes the separated features, and then progressively interacts the information between the processed group and the unprocessed group, thereby enhancing the interaction between features on different channels; Then, a lightweight convolutional block dedicated to image super-resolution is constructed, which consists of three parts: progressive interactive group convolution, channel shuffle, and depthwise separable convolution, which effectively reduces the network parameters; Finally, a lightweight residual concatenation block is designed as

the basic building block of the network, which makes the network more lightweight and competitive. In order to better fuse multi-level feature information and extract richer details, this method introduces the feature frequency grouping fusion block and multi-way hybrid attention block proposed above. Experimental results demonstrate that the algorithm we proposed balances the complexity and performance well, and is a very practical method, which can improve the quality of the reconstructed image.

In summary, the algorithms proposed in this thesis aim to balance the complexity and performance of the model, build lightweight super-resolution networks, and improve the quality of reconstructed images. Under the same dataset conditions, this paper conducted comparative experiments with the reconstruction results of lightweight algorithms with similar parameter quantities. The results showed that the proposed algorithms achieved good performance in both subjective visual quality and objective quantitative metrics for super-resolution reconstruction. The algorithms in this thesis provide effective methods to design lightweight super-resolution algorithms, providing a new option for super-resolution image processing on resource constrained devices.

Keywords: super-resolution, feature fusion, frequency grouping, attention mechanism, group convolution

目 录

第 1 章 绪论.....	1
1.1 课题背景及研究意义.....	1
1.2 国内外研究现状.....	2
1.2.1 基于插值的超分辨率重建技术.....	2
1.2.2 基于重建的超分辨率重建技术.....	3
1.2.3 基于学习的超分辨率重建技术.....	4
1.3 主要研究内容.....	5
1.4 文章结构安排.....	6
第 2 章 卷积神经网络和单图像超分辨率相关知识	7
2.1 卷积神经网络相关知识.....	7
2.1.1 卷积运算和卷积类型.....	8
2.1.2 激活函数.....	10
2.1.3 损失函数.....	11
2.1.4 优化算法.....	12
2.2 图像退化模型.....	13
2.3 单图像超分辨率算法相关方法	14
2.3.1 轻量级单图像超分辨率算法.....	14
2.3.2 特征融合	17
2.3.3 注意力机制.....	19
2.4 图像质量评价.....	21
2.4.1 峰值信噪比(PSNR).....	22
2.4.2 结构相似性(SSIM).....	22
2.4.3 学习感知图像块相似性(LPIPS)	23
2.5 本章小结.....	23
第 3 章 基于特征频率分组融合的图像超分辨率算法	24
3.1 引言.....	24
3.2 算法总体框架.....	25
3.2.1 网络结构.....	25
3.2.2 深层特征提取块(DFEB).....	26
3.2.3 残差拼接块(RCB)	26
3.2.4 多路混合注意力块(HAB)	27
3.2.5 频率分组融合块(FGFB).....	27
3.3 实验结果与分析.....	29
3.3.1 数据集.....	29

3.3.2 实验参数设置.....	29
3.3.3 评估度量.....	29
3.3.4 结果与分析.....	29
3.4 本章小结.....	37
第4章 基于轻量卷积的图像超分辨率算法	38
4.1 引言.....	38
4.2 算法总体框架.....	39
4.2.1 网络结构.....	39
4.2.2 轻量级残差拼接块(LRCB)	40
4.2.3 轻量级卷积块(LConv).....	40
4.2.4 渐进交互组卷积(PIGC).....	41
4.3 实验结果与分析.....	42
4.3.1 数据集.....	42
4.3.2 实验参数设置.....	42
4.3.3 评估度量.....	42
4.3.4 结果与分析.....	43
4.4 本章小结.....	51
第5章 结论与展望	52
5.1 论文工作总结.....	52
5.2 未来工作展望.....	53
参考文献.....	54

第 1 章 绪 论

1.1 课题背景及研究意义

图像中包含着大量信息，具有直观和真实的特点，是构建多媒体的重要组成部分。数字图像是像素点组成的集合，每个单位面积中含有的像素点数量，称为图像的分辨率。如果分辨率不断提高，则图像中的细节信息也会变得更加丰富，包含大量的高频信息，这使得高分辨率图像的可信度更高和显示效果更好，也可以提高后续图像处理的准确性。因此，在数字图像应用领域需求不断增加的情况下，提高图像分辨率，便成为了一个热门的研究。通过改善成像设备分辨率可以使图像的分辨率得到提升。成像设备分辨率的提高，除了通过减小设备感光单元的尺寸来实现，还可以通过增加传感器的尺寸来实现。但是，这两种方法均需要在硬件方面进行改进，在使用过程中，受到成像设备制造工艺的限制和制作成本的制约，这些方法的使用存在一定的困难。

考虑到改造硬件的局限性，为了实现在不改变硬件设备的情况下，可以使图像的超分辨率得以提高，设计软件的方法成为了新的研究方向，这种方法就是图像超分辨率（Super Resolution, SR）重建^[1]。它的基本思想是：在硬件设备不做任何改变的条件下，通过使用计算机技术，实现从给定的低分辨率（Low Resolution, LR）图像中得到与之相对应的高分辨率（High Resolution, HR）图像。这种方式的成本较低，因此，其在多个领域得到了广泛的使用。

（1）遥感成像^[2]领域。在军事、航空航天、农业等领域到处都可以看到遥感成像的影子，但是受到自然环境、成像设备自身条件等多种因素的影响，卫星所采集到的图像普遍存在图像分辨率较低的情况，限制了其在后续的图像处理中的应用，也会影响对情况的判断。因此，需要采用图像 SR 重建技术为其提供帮助，通过对图像重建来提高图像的分辨率，以满足实际的工作需要。

（2）安防监控^[3]领域。随着社会的发展，社会安全已经是国家安全的重要内容，而视频监控的出现很大程度上保障了社会安全。视频监控在交通、商场、学校等场所发挥着重要的作用，但在实际应用过程中，受到天气、光线等不确定因素的影响，所捕获到的图像质量也会受到影响。因此，提高图像分辨率势在必行，这就需要图像 SR 重建技术为其提供帮助。

（3）医学诊断^[4]领域。通过医学设备可以扫描得到很多方面重要的信息，供医学诊断参考，但由于医学设备扫描得到的图像分辨率不高，在需要高分辨率图像的情况下，其使用价值会受到限制，有时由于细节信息的缺失，甚至会

影响医生的诊断。因此需要使用图像 SR 重建技术，来提高扫描图像的分辨率，使医学影像可以呈现更多的细节信息，从而帮助医生可以更加准确的分析病情。

可见，图像 SR 重建技术对国家和社会的发展起着重要的作用，由于其广泛的应用市场以及其自身的优势，其已成为图像领域中重要课题之一。这项技术的涌现推进了基于深度学习的图像 SR 重建技术的研究。当前，基于深度学习的图像 SR 重建已经占据了主导地位，该方法使重建后的图像包含更加丰富的细节，提高了重建质量。因此，这是一个非常有价值的研究课题。

1.2 国内外研究现状

单图像超分辨率（Single Image Super-Resolution, SISR）重建技术，旨在从给定的 LR 图像中恢复出与之相对应的 HR 图像。由于 SISR 重建技术应用场景较为丰富，因此受到众多学者的关注与研究，该项技术得到不断地突破与发展。目前，SISR 重建技术主要包括：（1）基于插值的 SR 重建技术^[5-9]；（2）基于重建的 SR 重建技术^[10-16]；（3）基于学习的 SR 重建技术^[17-28]。图 1-1 展示了 SISR 重建技术的分类。




图 1-1 单图像超分辨率重建技术的分类

1.2.1 基于插值的超分辨率重建技术

基于插值的 SR 重建技术，借助周围邻域内的像素点的已知值，根据设定好的插值方式，估算中心像素点的值。按照插值方式的不同，可以将基于插值

的重建方法分为线性插值法^[5-7]和非线性插值法^[8,9]。

比较经典的线性插值法包括：最近邻插值法^[5]、双线性插值法^[6]和双三次插值法^[7]。第一种方法，复制最相近位置上点的像素值，使插值后的像素值等于与它最相近的输入点的像素值。它是插值法最简单的一种方法，运算速度较快，但由于这种方法忽略了图像中其他像素点间的相互关系，所以其插值效果较差。第二种方法通过使用最相近的 4 个像素点的加权值，来计算得到插值点的值。由于该方法考虑了四周 4 个像素点之间的关系，且在水平和竖直两个方向上均进行了插值，所以其计算速度较最近邻插值法慢，但是插值效果却相对有所提升。虽然插值效果有所提升，但是由于其仅仅考虑了周围 4 个像素点对插值的影响，所以插值效果依然存在模糊的现象。第三种方法通过使用四周最相近的 16 个像素点的值，通过计算公式计算出插值点的值。由于双三次插值考虑的周围像素数有所增加，且插值次数也增加到了 3 次，所以相较于前面两种插值方法，其运算速度最慢，但插值效果最好。线性插值法的计算复杂度较低，重建速度较快，但是由于此类插值方法不能很好的恢复图像中的高频信息，重建图像中可能会出现失真现象，所以重建效果不是很理想，需进一步改进。

为了解决上述方法存在的问题，非线性插值法逐渐成为主流。非线性插值法主要包括基于边缘位置相关信息的插值法^[8]和基于小波计算公式的插值法^[9]两大类。前者对边缘像素点，主要是进行有方向的插值，而非边缘像素点，则进行无方向插值，以此来保证插值效果。基于小波系数的插值法主要是采用小波变换将 LR 图像中的高频信息和低频信息，分离成 1 个低频和 3 个高频信号，然后再进行处理，将处理后的信息进行逆变换，得到重构的 HR 图像。

基于插值法的 SR 重建方法实现相对容易，并且运行速度相对较快。但是，也存在缺点，由于其不能很好的恢复出下采样时所丢失的高频信息，精度较低，所以其重建图像的质量，还有待继续提升。

1.2.2 基于重建的超分辨率重建技术

通过对 HR 图像进行图像降质，可以得到 LR 图像。基于重建的 SR 重建技术通过使用引入的先验信息约束重建模型，对 LR 图像进行图像降质的逆操作，使模型可以重建出降质时丢失的高频信息。根据采用的重建算法不同，可以将基于重建的超分辨率重建技术分为频域法^[10-13]和空域法^[14-16]两大类。

频域法借助傅里叶变换位移的物理特性，采取使用特定的方法在频域消除毫米波段的混叠。频域法最初由 Huang^[10]提出，但是其没有考虑噪声等因素的影响，重建效果有待提高。Kim 等^[11]通过递归最小二乘法实现了 SR 重建，对 Huang 的方法进行改进。Rhee 等^[12]提出了基于广义去卷积的重建方法，离散傅

里叶变换被替换为离散余弦变换，削减了频域重建算法的计算量。Woods 等^[13]提出了利用迭代的贝叶斯公式和最大后验公式，很好地利用图像中已有的信息序列重建出 SR 图像。频域法非常简单、容易实现，拥有较小的计算复杂度。但是，考虑到平行运动引起的运动没有极限，传递函数是常数，计算机的先验知识没有得到充分利用，应用范围相对受到限制。

空域法主要包括三种方法，分别是：迭代反投影^[14]、凸集投影^[15]和最大后验概率法^[16]。第一种方法，通过使用反投影算子，不断的更新估计值以重建 SR 图像，该方法直观易懂，但是很难选择反投影算子，而且没有唯一解，重建出的 HR 图像多伴有锯齿效应。第二种方法的解空间，会受到多个约束条件的限制，如正定性、有界性等。每个约束条件都是一个凸集合，其交集就构成重建图像的解空间。该方法的算法简单，可以很好的利用先验知识信息，能够重建图像的细节和边缘信息。但是，该方法具有较高的计算复杂度，而且该方法的解不唯一。第三种方法，也称为贝叶斯算法，该方法是一种使用概率论的方法。最大后验法的解是唯一的，在求解的过程中使用了先验知识信息，所以重建图像中有较好的细节信息。但是该方法具有较大的计算量，收敛速度慢，因此，难以在实时场合中很好的开展工作。

基于重建的 SR 重建技术，通过使用 LR 图像中的冗余特征，重建 SR 图像。但是，应用的过程中在放大倍数较大的情况下，若先验知识信息不够充足，往往重建效果不太理想。

1.2.3 基于学习的超分辨率重建技术

基于学习的 SR 重建技术，首先，创建 HR/LR 配对的图像样本库，然后，通过机器学习模型学习配对样本间的映射关系，最后，LR 图像在这种关系的指导下，重建目标图像。主要包括基于邻域嵌入的算法^[17]、基于稀疏编码的算法^[18]和基于深度学习的算法^[19,21-27]。

基于邻域嵌入的算法：假设 LR 图像块的局部结构与 HR 图像块相似，将输入的 LR 图像块与训练集中最相近的几个块间的关系，映射到与之对应的 HR 图像块上，然后使用重建图像块，合成最后的 HR 图像。该方法速度较快，但数据集较多时速度会下降，并且由于提取的 LR 图像块中的特征未体现出所有的 HR 图像块中的信息，而且维持庞大的样本库需要占用很大的存储空间。

基于稀疏编码的算法：由 Yang 等^[18]第一次提出。该算法采取使用相同的稀疏表示和计算公式，借助联合强化训练，得到 LR 图像块和 HR 图像块的超完备字典。在重建时，首先得到输入的 LR 图像块关于 LR 过完备字典的表达式计算公式；然后，通过计算出的表示系数和 HR 过完备字典，生成相应的 HR 图像块；最后，

使用传递函数合并HR图像块，生成HR的显示图像。随即各种具体的方法涌现出来，不断的改良现有的算法，让原本不太好的修复效果得以提升。

基于深度学习的算法：使用多层的非线性变换，来提取图像特征，比其他具体方法具备更好的拟合潜力。Dong 等^[19]提出的 SRCNN，首次应用卷积神经网络（Convolutional Neural Networks, CNN），以端到端的形式，学习 LR 图像和 HR 图像相互间的关系，借助这种关系，恢复出 HR 图像。随后，基于深度学习的算法成为了研究热门。ResNet^[20]提出了对重建工作影响深远的残差网络。VDSR^[21]是在 ResNet 的基础上提出网络层数更多的 SR 网络模型，使重建效果进一步提升。Kim 等^[22]提出的 DRCN，是第一个将递归神经网络应用在 SR 重建领域中的模型，递归单元之间的参数共享，实现了增加网络深度却不增加参数量，提高模型性能。Lim 等^[23]提出的 EDSR 去掉了批归一化处理，减少了所需的内存资源，由于其对网络深度进行加深，扩大了感受野，使网络性能得到了提升。Tong 等^[24]提出了 SRDenseNet 网络模型，首次将稠密连接应用到图像 SR 重建中，增强特征传播，同时也提高了特征的复用，获得了不错的重建性能。Zhang 等^[25]考虑到通道间的相互依赖性，将注意力机制引入到了图像 SR 重建任务中，增强了网络的表征能力。Hui 等^[26]提出的 IMDN 网络，采用信息蒸馏方式，使网络更加的轻量化，且性能更加有效。文献[27]结合通道注意力机制和递归学习，来提高重建效果。

由上述分析可以发现，基于邻域嵌入的算法训练样本需求较少，且拥有较低的噪声敏感度，但是，其邻域大小如何选择是一个难点。基于稀疏编码的算法在使用过完备字典，重建特定图像时，拥有不错的效果，但是对于其他图像的重建，达不到较好的效果。基于深度学习的算法学习能力较强，重建速度较快，极大地提高了重建图像的质量，可以更好地恢复出图像中的细节，但该方法训练时的计算量比较大，对硬件设备的要求也相对较高。

1.3 主要研究内容

随着SISR算法研究的不断发展，诸多学者通过加深或加宽网络来增加CNN的规模，以提高网络的重建质量。这类方法从一定程度上提高了SR图像的质量，但也带来一些问题，比如网络模型参数量和计算量的增加，使其在诸如手机等资源受限的移动设备上难以应用。本文采用改进网络结构的方法，设计了轻量级的SR算法，以平衡模型复杂性和性能。本文提出了两个SR重建算法，分别是基于特征频率分组融合的图像超分辨率算法和基于轻量卷积的图像超分辨率算法。本文的主要工作包括：

（1）为了更好地融合高频和低频特征，改进SR图像的恢复质量。本文中，

构建了一个基于特征频率分组融合的SR网络模型。该模型中的频率分组融合块,按照网络中高、低频信息的差异性对特征进行分组,高、低频率差异最大的特征分为第1组,差异次之的特征分为第2组,依此类推。然后,从频率差异最小的特征组开始逐步融合,直至频率差异最大的特征组,更好地融合了网络中的层次信息,从而提高SR图像中高频信息的恢复质量。另外通过残差拼接块融合局部特征,增强局部特征的利用和传播。通过多路混合注意力块,从不同的尺度收集特征信息线索,为图像重建提供了更多的高频细节,提高了网络的细节保真度。通过多种模块的结合使用,提高了网络模型的重建效果。

(2) 为了构建更加轻量、有效的模型,本文提出了一个基于轻量卷积的SR算法。我们通过使用构造的轻量级卷积块,降低了网络模型的参数量。在轻量级卷积块中,使用渐进交互组卷积,相比传统的分组卷积操作,渐进交互组卷积更加有效,因为它既保留了传统分组卷积的优点,又增强了通道间特征的相互作用,可以较好的为SR重建提供更多信息。该模块中也使用了通道搅拌操作和深度可分离卷积。该网络模型中结合使用了前文提出的特征频率分组融合块和多路混合注意力块,以使网络中的特征信息得以更好地融合。实验证明我们的方法是有效和高效的,并且产生了具有竞争力的结果,在SISR重建模型的复杂性和性能之间取得了更好的平衡。

1.4 文章结构安排

本文主要研究基于特征频率分组融合的轻量级图像超分辨率算法,一共包含5个章节,具体内容如下:

第一章,绪论。首先,详细介绍了SISR重建技术的课题背景及研究意义;然后,介绍了国内外的研究现状;另外,介绍了本文主要研究的内容;最后,对文章结构进行梳理。

第二章,卷积神经网络和单图像超分辨率相关知识。主要介绍了CNN相关知识、图像的退化模型、SISR算法相关知识和评价指标。

第三章,基于特征频率分组融合的图像超分辨率算法。首先,详细介绍了本章算法整体网络结构和各个模块内容;然后,设计大量实验,验证、分析所提算法的有效性。

第四章,基于轻量卷积的图像超分辨率算法。详细介绍了本章算法整体网络结构和各个模块内容,并设计大量实验,验证、分析所提算法的有效性。

第五章,结论与展望。本章节主要对本文主要研究的两个SR算法,进行较全面的总结,也对下一步的研究方向进行了展望。

第 2 章 卷积神经网络和单图像超分辨率相关知识

2.1 卷积神经网络相关知识

CNN是由卷积层构成的前馈神经网络，网络中有多个神经元，每个神经元都有权值和偏差，通过网络训练和优化算法可以对网络中神经元的参数进行不断调整，直到达到较好的结果。其本质是多层感知机，由于具有局部连接和权值共享的优点，既可以缩减权值的个数让网络优化更加容易，也可以使模型的复杂度得到降低，同时产生过拟合的概率也得到较低。这些特点的存在，使CNN具有平移、扭曲不变性。目前，深度神经网络模型已经颠覆性地革新了SISR的质量和性能，并且主导了当前的单图像超分辨率技术的研究。

一般来说，CNN模型由五部分组成，分别为输入层、卷积层、池化层、全连接层和输出层，结构图如图 2-1 所示。对部分层重新排列组合便可得到不同类型的CNN。CNN中不同的层发挥着不同的作用。




图 2-1 卷积神经网络

输入层：CNN通过输入层将图像信息转化成了像素矩阵，然后输送到神经网络中。输入图像一般由不同的像素点组成，采用不同的像素值表示，即像素值反应了图像的亮度，比如 0 和 255 分别代表着黑色和白色。一副输入图像在计算机中被转化为由数字构成的多维矩阵，矩阵中的参数分别代表着图像的宽度、高度和深度。

卷积层：由多个滤波器组成，这些滤波器的参数通过不断地优化，使损失函数最小化。卷积层的主要功能是提取图像特征。卷积层中使用的数学运算称为卷积运算。第一个卷积层可以提取到一些较低级的特征信息，若网络模型深度增加，卷积层可以提取到较为复杂的特征。

池化层：又可以称作降采样层，是提取特征的一个过程，主要对数据进行压缩，减小了神经网络中后面一层的输入大小。它缩减参数量和计算量的同时，避

免了模型发生过拟合现象。常用的池化层包括：最大池化、平均池化、全局平均池化(Global Average Pooling, GAP)和全局最大池化(Global Max Pooling, GMP)。最大池化后的值，是池化前区域内几个数值的最大值；平均池化后的值，是池化之前区域内几个数值的平均值。

全连接层：一般用在网络的最后，同一层内是互不连接的神经元，相邻的两个层的神经元间为全连接。它可以把卷积层或者池化层提取出来的特征，转化成一维的向量，以达到对提取的特征进行整合的目的，然后进行图像分类等操作。

输出层：由于计算机视觉任务的不同，CNN的输出也不同。在分类任务中，通过Softmax函数得到一组概率分布，用来表示各个分类对应的概率。在回归问题中，输出层输出的结果是由CNN计算得到的数值。

2.1.1 卷积运算和卷积类型

2.1.1.1 卷积运算

卷积是数学上的一种运算形式，在CNN中，利用卷积核的权值与在图像中覆盖区域相对应位置的像素值点对点相乘，然后将所有相乘的结果相加，就可以计算出卷积中心位置上的像素值。接着，使卷积核滑动一定的步长，并使用上述的计算过程，直到卷积核滑过所有区域。

如图 2-2 所示，输入一个宽和高都是 3 的二维数组，则这个二维数组的大小为 3×3 ；卷积核大小为 2×2 。卷积核按照从左至右、从上至下的顺序滑动，步长为 1。图 2-2 中的阴影部分表示的是相应的输入部分与卷积核进行卷积操作，并得到相应的输出，即 $1 \times 0 + 2 \times 1 + 4 \times 2 + 5 \times 3 = 25$ 。以此类推，剩余的三个输出分别为 31、43 和 49。




图 2-2 卷积运算

假设输入数组的尺寸为 $W \times W$ ，卷积核大小为 $K \times K$ ，步长 (Stride) 为 S (默认为 1)，填充 (Padding) 为 P (默认为 0)，输出数组尺寸为 $N \times N$ ，计算公式如式 (2-1) 所示：

$$N = \left\lfloor \frac{W + 2P - K}{S} \right\rfloor + 1 \quad (2-1)$$

2.1.1.2 卷积类型

常见的卷积类型包括以下五种：

(1) 标准卷积：输入图像的矩阵，与卷积核进行卷积运算，便可以求出目标图矩阵。

(2) 反卷积：是一种特殊的卷积操作。其首先会先对输入图像进行填充，将尺寸扩大到期望的尺寸大小。然后，对卷积核进行旋转，即矩阵转置。随后将其与第一步填充后的图像进行卷积运算。反卷积操作可以恢复出图像降采样前的尺寸大小，所以通过反卷积操作可以实现图像的上采样，但是其不能恢复出降采样前所有元素的值。

(3) 空洞卷积 (Dilated Convolution)：也称作膨胀卷积。其与标准卷积的主要区别在于，它在卷积核中注入了空洞，引入了一个称为空洞率的参数。假设空洞率用 d 表示，当 $d=1$ 时，就是标准卷积。与传统卷积相比，在计算量相同时，空洞卷积可以增加感受野，有利于提高网络精度。但是由于其注入了空洞，会出现网格效应，从而导致信息丢失。

(4) 深度可分离卷积 (Depthwise Separable Convolution)：是将卷积运算分解为 2 个具体操作的方法，依次是逐通道卷积 (Depthwise Convolution) 和逐点卷积 (Pointwise Convolution)，其操作如图 2-3 所示。前者中一个卷积核仅与一个通道进行运算，并输出与输入通道数量相同的通道数。由于其对每一个输入通道进行单独处理，没有利用不同特征图相同位置上的特征信息，因此，需要后者进一步将卷积后的特征图进行整合。其实，后者是一种常规的卷积操作，只不过卷积核的大小为 1×1 ，用来改变输出通道维数。深度可分离卷积使参数量得到减少，在很多轻量级的网络模型中会使用到此方法。




图 2-3 深度可分离卷积

(5) 分组卷积 (Group Convolution)：首先将网络中的通道进行分组，然后分别处理分组后的特征，最后将处理后的特征进行通道拼接。通常情况下，假设分组数为 G ，则参数量会减少到 $1/G$ 。通过这种操作，不仅可以降低网络的参数量，节约网络模型的训练时间，也可以增加网络模型深度，使网络提取出更多的特征信息。

2.1.2 激活函数

在CNN中,卷积运算实际上是一种线性运算,但在实际应用中有很多函数关系是非纯线性的。在网络模型中使用激活函数,其非线性映射的能力得以增强,表达能力也得以提升,因此,CNN中也需要使用激活函数。经常使用的激活函数包括以下几种:

(1) Sigmoid函数:是一种常用的激活函数。如图 2-4 a) 所示,它可以将输入信息映射到[0,1]的区间内。其表达式如式 (2-2) 所示:

$$\text{sigmoid}(x) = \frac{1}{1 + e^{-x}} \quad (2-2)$$

Sigmoid函数求导操作较简单,由于其映射区间的特殊性,可以很好的对图像中的物体进行分类,但是该函数的计算量较大,会增加训练模型的时间。网络模型进行反向传播时,该函数的导数始终小于 1,而且一直在 0 附近变化,在深层网络模型中会出现梯度消失的现象,导致网络没法继续进行训练。另外,由于 Sigmoid函数的取值一直都是正数,会改变特征图的数据分布,而且该函数不以 0 为中心,所以会使网络模型的收敛速度变慢。

(2) tanh函数:也称为双曲正切函数。如图 2-4 b) 所示,tanh函数将输入信息映射到[-1,1]的区间,且函数图像过(0,0)点。该函数表达式如式 (2-3) 所示:

$$\text{tanh}(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2-3)$$

tanh函数的收敛速度较快,但是当 x 绝对值很大时,梯度会接近于 0,梯度消失问题无法解决。

(3) 修正线性单元 (Linear rectification function, ReLU) 激活函数:函数分布如图 2-4 c) 所示。当输入是正数,不会产生梯度消失,而且由于其分段映射,所以在训练网络模型时的前向传播和反向传播中的计算复杂度较低。但当输入负值时,梯度就会为 0,这将致使神经元死亡。该函数表达式如式 (2-4) 所示:

$$\text{Relu}(x) = \max(0, x) \quad (2-4)$$

(4) Leaky ReLU激活函数:改进了ReLU激活函数,其函数分布如图 2-4 d) 所示,该函数表达式如式 (2-5) 所示:

$$\text{LeakyReLU}(x) = \max(ax, x) \quad (2-5)$$

在Leaky ReLU激活函数中,引入了一个斜率 a ,它是一个固定不变的正常数,当输入负值时,反向传播时的梯度不为 0,避免了梯度消失。

(5) PReLU激活函数:也改进了ReLU激活函数,其函数分布如图 2-4 d) 所示,该函数表达式如式 (2-6) 所示:

$$\text{PReLU}(x) = \max(bx, x) \quad (2-6)$$

在PReLU激活函数中， b 是一个可学习的参数，随着网络模型的训练不断的更新，该参数会在一定程度上影响网络模型的训练。在实际应用中，该激活函数的表现不太稳定。




图 2-4 常用激活函数图像

2.1.3 损失函数

损失函数能够用来比较CNN的预测结果与真实数据之间存在的差异，正常情况下，值越小，代表性能越好。CNN根据损失函数的数值反复的迭代模型，使模型得以优化。在SISR任务中，通过计算预测图像跟真实图像对应位置的像素点差值，可以得到其损失值。常用的损失函数包括 L_1 损失函数和 L_2 损失函数。

(1) L_1 损失函数：又叫作平均绝对误差（Mean Absolute Error, MAE）。表示网络模型的预测值（ $y^{(i)}$ ）与实际真实值（ $\hat{y}^{(i)}$ ）之间差值的绝对值的和。其表达式如式（2-7）所示：

$$L_1(\hat{y}, y) = \sum_{i=0}^m |y^{(i)} - \hat{y}^{(i)}| \quad (2-7)$$

(2) L_2 损失函数：又称为均方误差（Mean Square Error, MSE）。反映了网络的预测值（ $y^{(i)}$ ）与实际真实值（ $\hat{y}^{(i)}$ ）之差的平方和。表达式如式（2-8）所示：

$$L_2(\hat{y}, y) = \sum_{i=0}^m (y^{(i)} - \hat{y}^{(i)})^2 \quad (2-8)$$

L_1 损失函数的收敛速度快, 且稳健性强。当误差较大时, 其增加的仅仅只是一个误差, 但 L_2 损失函数却增加的是误差的平方。这就使得 L_1 损失函数在面对误差较大情况下不易受到影响, 而 L_2 损失函数则需要更大程度的调整网络模型以适应相应的规则。虽然 L_2 损失函数的收敛速度较慢且稳定性较差, 但是 L_2 损失函数是处处可导的。因此, L_2 损失函数可以得到一个解析解。 L_1 损失函数和 L_2 损失函数有各自的优缺点, 在构建网络模型时, 可根据实际情况进行选择。

2.1.4 优化算法

在训练 CNN 模型时, 通过优化算法来不断迭代网络模型的参数, 使损失函数的值得到降低, 网络模型训练终止时, 模型参数就是通过迭代训练学到的参数。优化算法对于网络训练是十分重要的。一方面, 网络模型的训练可能需要几个小时、几天, 甚至几周, 网络模型训练的效率会受到优化算法的影响; 另一方面, 对优化算法及其超参数有所了解将有助于我们调参, 使网络模型可以取得更好的性能。常见的优化算法包括以下几种:

(1) 梯度下降法 (Gradient Descent, GD): 是基础的一种优化算法。该方法中, 负梯度方向函数值下降的最快, 该方法的目标就是求目标函数的负梯度。网络模型训练时, 梯度更新的速度受到学习率的控制, 如果设置的学习率太大, 参数更新的步幅就会变大, 会产生局部最优或者震荡的情况; 如果设置的学习率太小, 则参数迭代更新的次数就会增加, 使网络模型训练速度变慢、优化时间会变长, 难以收敛。因此, 需要配置合理的学习率。该方法在更新参数时需要对完整的训练集进行遍历, 以找到全局最优解。由于需要计算每个参数的偏导数, 所以, 这种方法在处理大型数据集时, 会导致训练时间较长。

(2) 批量梯度下降法 (Batch Gradient Descent, BGD): 是为了解决 (1) 法带来的训练耗时问题而提出的。该方法中, 将训练集划分成几个部分 (每个部分大小相近), 每次仅用一个部分进行网络模型训练, 且以该次训练得到的损失值为参考, 对网络模型中的参数进行迭代更新。然后使用下一个批量进行运算, 直到所有的批量都运算结束。批量划分较好的情况下, 可以很大程度上降低训练复杂度。但是, 该方法会导致优化参数的结果为局部最优解。

(3) 随机梯度下降法 (Stochastic Gradient Descent, SGD): 从训练集中随机的抽取一个数据进行网络模型的训练, 所以训练速度得到很大的提高, 但是由于每次都是随机选取数据, 所以会导致优化参数的结果是局部最优解。由于每次迭代的梯度很容易受到随机样本的选取, 会使梯度含有较大噪声, 使参数在优化的

过程中出现抖动,无法反映真实梯度。

(4) 小批量随机梯度下降法:该方法融合了上述(2)和(3)的优点,使网络模型可以更好的平衡参数更新的速度和参数更新的次数。相对于(2)的方法,该方法提高了训练速度。相对于(3)的方法,该方法使参数更新的方差得到降低,增加了参数更新的稳定性。在训练网络模型时,随机选择多个样本进行学习,使其适合参数的更新速度和更新次数。

(5) 动量法(Momentum):该方法使优化参数之前的梯度参与到当前的梯度运算中。该方法可以加速网络模型训练的收敛,一定程度上抑制震荡,且该方法有可能会逃离局部极小值点。该方法在梯度方向发生变化时,该方法可使参数迭代的速度减缓,减少震荡;方向一致时,可增加参数迭代更新的速度,提高收敛速度。但是,由于该方法引入了一阶动量,表示之前梯度的累加值,如果累积值太大,可能会使优化参数错过极小值点。

(6) Nesterov加速梯度法:在动量更新梯度的时候加入了对当前梯度的矫正,以使其可以跳出局部最优解。该方法使收敛速度加快,并且更新幅度较大的时候,该方法可以使震荡得到抑制。

(7) AdaGrad算法:该算法引入了二阶动量,可以在训练时动态调整学习率。如果参数梯度改变一直较大,学习率下降较快,可以使用较小的学习率;反之则使用较大的学习率。但是,该方法需要人为的设置一个合适的全局学习率。并且,由于动量具有累加性,梯度会出现趋于0的情况,网络训练会提前结束。

(8) RMSProp算法:是为了解决AdaGrad存在的问题。该方法增加了一个衰减因子,通过指数衰减,使用过去给定的窗口大小的梯度来指导当前梯度的更新,可以看作AdaGrad算法的一个特例。由于限定了窗口大小,仅使用部分梯度的值,所以避免了梯度累加太大而导致的过早结束训练的问题。但是,新的超参数的引入,增加了模型的复杂度。

(9) Adam算法:该方法融合了上述(5)和(8)两种方法,通过使用梯度的一阶、二阶矩估计,使网络模型中所有参数的学习率都可以进行动态的调整。该方法中,每一次参数的迭代更新会有一个确定的范围,参数会较为平稳的进行更新。目前,该方法被广泛应用在SISR网络重建中。

2.2 图像退化模型

在SISR算法中,通常假设输入的LR图像是由HR图像经过图像退化操作得到的,因此,SISR重建算法可以视为HR图像退化的逆过程。SISR重建算法通过使用配对的LR/HR进行训练,重建SR图像。SISR算法的降质模型,如图2-5所示。在降质模型中,对原始HR图像进行下采样、模糊、几何变换和噪声中的任意一

种或几种操作就可以得到对应的LR图像。下采样操作一般采用双三次下采样。模糊通常分为运动模糊和光学模糊。前者指由成像设备（如无人机、相机）和图像的相对运动造成的模糊，后者通常指的是高斯模糊。几何变形一般为图像平移和旋转。噪声按照时间分布，可以分为伽马噪声、高斯噪声和指数噪声等。




图 2-5 图像退化模型

上述降质操作的公式，如式（2-9）所示：

$$y = H(x) + n = (x \otimes k) \downarrow_s + n \quad (2-9)$$

其中， $H(\cdot)$ 表示退化函数， n 表示噪声。退化函数 $H(\cdot)$ 通过使用高分辨率图像 x 和模糊核 k 进行卷积运算，进行下采样得到。 $\downarrow_s$ 表示下采样的系数为 s 。

2.3 单图像超分辨率算法相关方法

2.3.1 轻量级单图像超分辨率算法

Dong等^[19]提出了第一个基于CNN的SISR网络模型，称为SRCNN。SRCNN采用端到端地学习方式，利用仅包含 3 个卷积层的CNN，实现了LR和HR图像对间的非线性映射，性能便超越了传统SISR的性能。其网络模型结构图如图 2-6 所示。




图 2-6 SRCNN 网络结构图

自SRCNN出现后，深度CNN技术便成为了当前SISR技术的研究^[19-31]的主流方向。但是，基于CNN的SISR网络模型特别容易受到模型中的参数量、深度和宽度等的影响。通常情况下，模型越大，性能越好，要改进SISR的性能，往往需要设计网络规模更大的模型。例如，尖端的EDSR^[23]有 65 个卷积层，网络模型的参数量达到 43M；RCAN^[25]拥有超过了 800 个的卷积层，网络模型的参数量也达到

16M。这两个模型拥有较好的性能，但在资源受限的设备上很难得到广泛的应用。因此，设计有较低计算能力和存储需求的轻量级SISR网络模型，成为了当前SISR研究的一个热门方向。

Kim等^[22]提出的DRCN，首先将递归结构应用于SISR任务，递归单元内的卷积层之间共享参数。通过使用递归操作可以构造深度较深的网络模型，不增加网络模型的参数量，但是却不能减少网络模型的计算量。Ahn等^[28]提出的CARN，运用分组卷积和递归学习，减少了模型的参数量和计算量。Hui等^[26]提出的IMDN，通过信息蒸馏（分裂和聚集运算），提取分层特征，以减少参数量和计算量。Liu等^[29]提出的RFDN，构造了一个更加轻量有效的网络模型，其主要是改进了IMDN中基础构建块IMDB的通道分裂形式和特征蒸馏方法。Li等^[30]提出的MHFN，通过构造融合多层次特征的轻量级模型，改善了网络性能。文献[31]通过构造多尺度特征映射网络，并联合使用多种损失训练模型，重建出高质量的图像。

2.3.1.1 递归学习

通常情况下，随着CNN深度的增加，SISR算法的性能也会提高。但是，这也会导致网络的参数量增加，因此需要更多的训练数据来避免过拟合的风险。由于训练数据数量有限，这是一种挑战。然而，使用递归学习技术，不仅可以增加网络深度，还可以使参数量保持不变。DRCN^[22]提出通过增加卷积层的数量来扩大感受野，其结构图如图 2-7 所示。为了不给网络带来更大的参数量，该方法首次在SISR算法中使用了递归学习，通过递归使网络模型深度加深，证明了该方法可以提升网络性能。DRCN的网络模型主要包括嵌入网络、推理网络和重构网络。




图 2-7 DRCN网络结构图

嵌入网络用来进行特征提取，将输入的LR图像（单通道或三通道）表征为指定通道数的特征图。

推理网络是整个网络结构的重要组成部分，用来完成超分辨率任务。该部分使用递归操作，每次递归所使用的卷积核和ReLU激活函数都相同，即它们共享参数。网络模型的深度随着递归次数的增加而加深，感受野也随之扩大。通过递归操作可以使网络模型在网络深度加深的情况下，保持较少的网络模型参数量。

重建网络用来重建，将多通道的特征图转换为与输入图像相同的通道数（单通道或三通道），然后生成HR图像。

2.3.1.2 分组卷积

分组卷积首先把网络中的特征通道平均分成多个组，然后再分别处理每组特征。分组卷积可以使网络的参数量大大降低，因此是设计轻量级SISR网络模型的一个不错的选择。

CARN^[28]是一个级联残差的轻量级网络，该方法提出了Residual-E块，来提高网络效率，该模块的结构图，如图 2-8 所示。该模块主要是受到MobileNet^[32]的启发，与MobileNet不同的是，该模块没有使用深度卷积，而是使用了分组卷积。为了进一步减少网络的参数量，CARN网络模型使用递归操作共享网络参数，使参数量减少到原来的 1/3。




图 2-8 Residual-E块结构图

2.3.1.3 特征蒸馏网络

设计轻量级的SISR算法中，特征蒸馏网络是一个不错的方法。Hui等^[26]提出的IMDN，其主要组成是信息多重蒸馏块(IMDB)。IMDN在网络中级联使用IMDB使得网络具有较少的参数量，从而达到轻量化的效果，IMDB的结构图如图 2-9 a) 所示。其由逐级分离模块、对比感知通道注意力(Contrast-Aware Channel Attention, CCA)和 1×1 的卷积层所构成。逐级分离模块，采用 3×3 的卷积层提取特征，并将特征图表示为64通道，接着使用通道分离操作将通道分离为48通道和16通道两部分。随后，48通道的特征图进入下一个卷积层继续卷积操作，16通道的特征图则在后面Concat部分进行通道拼接。然后，使用CCA筛选重要特征，最后通过 1×1 的卷积层调整特征通道数。

RFDN^[29]通过若干个特征蒸馏连接，获得更多有差别的特征表示，网络中级联使用残差特征蒸馏块(RFDB)。RFDB是网络的基础构件，其结构图如图 2-9 b) 所示，该模块对IMDB的特征蒸馏连接方式进行改进，使其比IMDB更加轻量、有效。作者认为使用 1×1 的卷积层进行通道压缩更加有效，因此将IMDB中的 3×3 卷积层替换 1×1 的卷积层。另外，作者考虑到IMDB中仅使用一个残差连接，进

行中层残差特征连接，在连接上过于粗糙，因此作者提出了浅残差块（Shallow Residual Block, SRB），SRB由一个 3×3 的卷积层、一个残差连接和ReLU激活函数组成。网络可以从残差学习中获益最多，在不增加额外参数数量的情况下，学习更细粒度的残差特征。




图 2-9 IMDB 和 RFDB 结构图

2.3.2 特征融合

在 SISR 网络模型中，由于特征信息存在相关性和特征冗余，如何融合特征信息对特征的传播能力和表达能力是非常重要的。目前，在 SISR 网络的架构中，最广泛的特征融合方式有残差连接^[21,23,25]、稠密连接^[33,34]和特征通道拼接^[24,29,35]。Anwar 等^[34]提出的稠密残差拉普拉斯网络模型 DRLN，其基本构建块为稠密残差拉普拉斯模块 DRLM，DRLM 中组合使用了残差连接、稠密连接和特征通道拼接。Li 等^[35]提出的多尺度残差网络模型 MSRN，稠密连接各个多尺度残差块 MSRB，然后用 1×1 的卷积层，使特征融合在一起。Luo 等^[36]提出的 LatticeNet，采用反向特征融合的方式，使高频特征逐步反向融合低频特征，改进了 SR 图像的恢复质量。下面介绍上述提到的相关论文。

2.3.2.1 DRLN

Anwar 等^[34]提出了一个紧凑精确的 SISR 算法 DRLN，网络的主体架构在残差结构上的基础上使用级联残差，每一个残差级联块都有一个跳跃连接，使低频信息流可以学习中级、高级特征。DRLM 是构建 DRLN 的基础构件，DRLM 由密集连接残差单元、压缩单元和拉普拉斯金字塔注意力单元三部分组成，其结构图如图 2-10 所示。




图 2-10 DRLM 结构图

在DRLM中采用级联残差结构进行特征提取，同时使用密集连接的操作，将前面的特征与当前的残差特征进行通道拼接，使更多的特征得以复用。由于前面的通道拼接操作后未进行通道压缩，通道数会不断地增加，因此，导致了参数量和计算量增加，所以融合多层次的特征后，采用压缩单元对特征进行压缩，以减少网络通道数。通道压缩后，特征信息进入到注意力单元，该注意力单元通过使用不同空洞率的空洞卷积从多个尺度筛选特征，以促进和利用不同特征间的关系。丰富的连接类型和残差结构上的级联残差，使学习的特征可以更加准确的表示。

2.3.2.2 MSRN

Li等^[35]在提出的MSRN中提到，一味地增加网络深度，对于改善网络的性能并不都是有效的，反而可能会随着网络深度的加深，在网络训练时出现更多的问题，因此，他们提出了MSRN。MSRN通过使用多尺度残差块，可以比较充分利用图像的特征信息。MSRN的网络结构图如图 2-11 所示。




图 2-11 MSRN 结构图

MSRN由多个级联的多尺度残差块MSRB组成，MSRB是第一个基于残差结构的多尺度模块，每个MSRB的输出特征为 M_i 。MSRB采用了尺寸大小不同的卷积核，使其提取的图像特征可以来自不同的尺度，然后将不同尺度的特征进行通道拼接，拼接之后采用 1×1 的卷积层，使特征信息得到融合，局部特征信息可以重用，MSRB提取的特征被认为是局部多尺度特征。然后，将所有MSRB的输出局部特征 M_i 进行组合，组合后采用 1×1 的卷积层进行通道降维，使来自全局的特征信息可以进行融合。多种特征融合结合的方式，使LR图像中的特征得到了最大限度的使用，解决了特征消失的问题。

2.3.2.3 LatticeNet

在LatticeNet^[36]中，作者认为分层信息对SR来说是非常重要的，因此提出了

反向特征融合（Backward Fusion Module，BFM），以融合来自多个层次的特征，获得更多的上下文信息，其结构图如图 2-12 所示。在该方法中，首先采用 1×1 的卷积层对每个基础构建块LB提取的特征 F_i 进行通道压缩，使通道数减半。然后从最后一个压缩后的特征开始，与前一个压缩后的特征进行通道拼接，拼接后的特征，通过 1×1 的卷积层使通道数减半，随后继续向前拼接，直至拼接到第一个压缩后的特征。通过这种从后向前拼接的方式，BFM可以融合所有基础构建块的特征。实验结果表明，所提出的BFM融合方式，比使用 1×1 的卷积层直接融合所有基础构建块的方式更加有效。




图 2-12 BFM 结构图

2.3.3 注意力机制

注意力机制^[37]通常是指人类的视觉系统，可以自动地关注于显著的感兴趣的区域，忽略那些对自己无用的信息，这种机制提高了大脑对信息处理的效率和精确度。CNN 网络结构中的注意力机制与人类系统的注意力机制类似，指能够聚焦于输入图像的特定部分，可以提高图像特征的利用率和表达能力。常见的注意力机制大致可以分为通道注意力机制^[25,38,39]、空间注意力机制^[41,42]和混合注意力机制^[43,44]。

2.3.3.1 通道注意力机制

Hu等^[39]提出了一个网络模型SENet，该网络首次将注意力机制引入到CNN中，并且获得了ImageNet 2017^[40]比赛的第一名。SENet算法的基础构件是SE（Squeeze-and-Excitation）。SE模块利用全局平均池化把输入的所有通道都转化成通道描述符（常数），接着将描述符再馈送到 2 个稠密链接层中，以生成缩放因子（权重），用于捕捉不同通道之间的相关性。

Zhang等^[25]提出的RCAN，认为不同通道上的特征对图像SR重建的实现有不同的程度，因此希望网络模型可以自己获取重要的图像特征，或者抑制一些对无用的特征，因此将Hu等^[39]提出的SENet机制引入到SISR重建任务中，在训练网络的过程中给不同的通道赋予不同的权重，在通道维度上提取较为重要的特征，来增强网络特征的表征能力。RCAN中的通道注意力（Channel Attention，CA）结构图，如图 2-13 所示。




图 2-13 CA^[25]结构图

在CA中，首先使用GAP对特征图下采样。然后，利用卷积操作压缩和扩张通道数，压缩和扩张的倍数为 16，然后使用Sigmoid进行激活，使每个通道产生一个 0 到 1 范围内的权重系数。最后，用输入的特征图乘以权重系数，以获得经过重新分配权重的新特征。

2.3.3.2 空间注意力机制

Spatial Transformer Networks(STN)^[41]是具有代表性的空间注意力机制模型，它可以在空间对各种形变数据进行转换，并且可以自动的去捕获重要区域的特征，使网络可以完成分类任务。空间注意力机制注重从空间位置的角度衡量特征的重要性，在所有通道相对应的位置进行权重赋值。Woo 等^[42]提出的 CBAM，通过使用最大池化和平均池化实现空间注意力机制，其结构图如图 2-14 所示。




图 2-14 CBAM^[42]中的空间注意力机制

在 CBAM 中，将输入尺寸大小为 $H \times W \times C$ 的特征图，依次经过最大池化和平均池化得到两个 $H \times W \times 1$ 的特征图，特征图所有数值都代表空间位置的重要性。然后，使两个特征图的通道拼接在一起。接着，通过使用卷积操作和 Sigmoid 激活函数，便可得到相应的权重系数。最后让权重系数乘以输入的特征图，便可得到缩放后的新特征。

2.3.3.3 混合注意力机制

通道注意力机制对网络中每个通道赋予不同的权重，筛选有利于目标任务的重要特征，空间注意力机制则更加关注空间位置上的信息对目标任务的重要程度。由于两者的关注点不同，所以，同时使用两种注意力机制，就可以同时关注到通道和空间位置两个维度的重要信息。

Fu 等^[43]提出了一个双路注意力网络模型 (DANet)，其结构图如图 2-15 所示。在 DANet 中，同时使用位置注意力机制和通道注意力机制。位置注意力机制使用自注意力机制探测不同位置间的相互依赖关系，若两个特征图的特征相似，在空间维度上无论有多远的距离，都可以相互改善。与此类此，通道注意力机制也使用了自注意力机制，通过整合所有通道的相关特征，有选择性地加强了相互依赖的通道表示。最终，两个注意力机制模块的输出相加，以增强特征表示。




图 2-15 DANet^[43]网络结构图

2.4 图像质量评价

对 SR 算法重建出的 SR 图像进行图像质量评价是衡量 SISR 算法性能的重要途径。在 SISR 算法中，常用的图像质量评估通常包含主观评价和客观量评价标两大类。

主观评价是通过人眼观察图像，进行质量评估的一种方法。这种方法可以直观地反映出重建图像的质量，更符合人类视觉系统的感知。然而，主观评价方法无法通过数学模型来量化和描述，因为其结果会受到观察者自身的视觉特征和所处的观察条件等多种因素的影响。特别是在重建图像差异较小的情况下，很难通过肉眼来判断图像的好坏。

客观评价法通过客观量化的指标，对重建图像的质量进行定量的描述。该方法可以弥补主观评价法的不足，但却可能出现不符合人类视觉系统的情况。因此，通常同时使用上述两种方法。

现有的 SISR 重建算法中，对于 SR 图像的质量评价，最普遍使用的评价指标包括峰值信噪比^[45](Peak Signal to Noise Ratio, PSNR)、结构相似性^[46](Structure

Similarity Index Measurement, SSIM) 和学习感知图像块相似性^[47] (Learned Perceptual Image Patch Similarity, LPIPS)。

2.4.1 峰值信噪比 (PSNR)

PSNR^[45]是评价图像质量最常使用的一种评价方法,一般指的是信号最大可能值与影响其表示质量的噪声值之间的比值。在图像超分辨率重建算法中,通常情况下,图像压缩以后,重建的 SR 图像在某种特定程度上和原始的 HR 图像会有一定程度的不同。为了可以准确的评估出重建 SR 图像的质量,往往会通过参考 PSNR 指标的值来评估对某一个重建算法的效果是否满意。它是原始图像和重建图像间的均方误差 (MSE) 相对于 $(2^n-1)^2$ 的一个对数值,其单位为 dB。PSNR 的值越大,效果越好。均方误差 MSE 的计算公式如式 (2-10) 所示:

$$MSE = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W (X(i, j) - Y(i, j))^2 \quad (2-10)$$

其中, $X(i, j)$ 表示重建 SR 图像在位置 (i, j) 的像素值, $Y(i, j)$ 表示原始 HR 图像在位置 (i, j) 的像素值, H 代表图像的高度, W 代表图像的宽度。

峰值信噪比 PSNR 的计算公式如式 (2-11) 所示:

$$PSNR = 10 \log_{10} \frac{(2^n - 1)^2}{MSE} \quad (2-11)$$

其中, n 是像素比特数, 2^n-1 表示图像像素的最大值。

2.4.2 结构相似性 (SSIM)

SSIM^[46]是用于衡量两幅图像之间的结构相似性的一种指标,可以用来评估图像的质量。它通过比较原始 HR 图像和重建 SR 图像之间的亮度 (luminance)、对比度 (contrast) 和结构信息 (structure) 来确定它们之间的相似程度。其中,亮度值表示图像中的平均亮度,对比度值表示图像中的颜色差异程度,结构值表示图像中的纹理和边缘信息。这些因素的权重可根据具体情况进行调整,以便更好地适应不同类型的图像。SSIM 值越大,表示两张图像越相似。SSIM 的计算公式如式 (2-12) 所示:

$$SSIM = \frac{(2\mu_X\mu_Y + C_1)(2\sigma_{XY} + C_2)}{(\mu_X^2 + \mu_Y^2 + C_1)(\sigma_X^2 + \sigma_Y^2 + C_2)} \quad (2-12)$$

其中, X 表示重建的 SR 图像, Y 表示原始的 HR 图像, μ_X 、 μ_Y 分别表示图像 X 和 Y 的均值, σ_X 、 σ_Y 分别表示图像 X 和 Y 的标准差, σ_{XY} 表示图 X 和 Y 的协方差, C_1 、 C_2 是常数。

2.4.3 学习感知图像块相似性 (LPIPS)

LPIPS^[47]也被称为“感知损失”，用来比较重建 SR 图像和原始 HR 图像间的差别。该评价指标更加符合人类的视觉感知情况，LPIPS 的值越低，表示两张图像的相似度越高，重建的结果越好。设 x 和 x_0 分别为原始 HR 图像和重建的 SR 图像，两张图片的差异性为 d ，计算公式如式 (2-13) 所示：

$$d(x, x_0) = \sum_l \frac{1}{H_l W_l} \sum_{h,w} \|w_l \odot (\hat{y}_{hw}^l - \hat{y}_{0hw}^l)\|_2^2 \quad (2-13)$$

2.5 本章小结

本章节详细介绍了CNN和SISR重建算法的相关知识。首先，我们介绍了卷积运算、卷积类型、激活函数、损失函数和优化算法等。接下来，讲述了图像的退化模型，对图像退化的原理进行了详细介绍。在此基础上，我们从递归学习、分组卷积和蒸馏网络三方面介绍了设计轻量级SR网络的方法。同时，也介绍了网络模型中特征融合的几种方式，包括残差学习、稠密连接等。另外，本章节还介绍了几种注意力机制。最后，介绍了SISR算法中几种常用的图像质量评价指标，包括PSNR、SSIM和LPIPS，这些指标可以帮助我们评估超分辨率重建的效果。

第3章 基于特征频率分组融合图像超分辨率算法

3.1 引言

深度CNN技术^[19]已经改变了SISR重建的方法，革新了SISR的性能，并且成为了当前SISR技术研究^[19-31]的主流。然而，基于CNN的SISR网络模型的性能严重依赖于网络规模，网络深度越深或宽度越宽，网络的性能往往越好。如先进的EDSR^[23]网络具有65个卷积层，参数量高达43M；而RCAN^[25]网络具有超过800层的卷积层，参数量也达到了16M。尽管它们的网络模型拥有出色的性能，但它们在资源受限的设备上应用非常困难，因为他们需要较大的计算能力和存储资源。因此，设计轻量级的SISR网络模型成为当前SISR研究的热点。

当前设计轻量级SISR网络模型面临着挑战：难以恢复LR图像丢失的HR图像中的高频信息，因此重建出来的SR图像往往不够清晰，通常会出现图像失真、图像模糊或纹理细节丢失等现象。当前的SISR网络采用以残差连接^[21,23,25]、稠密连接^[33,34]和通道注意力机制^[24,29,35]为主的网络架构，大多设计去掉了CNN分类网络中常使用的批归范层和池化层^[48]，以降低特征信息的损失，提高了特征信息的利用率和表达能力。Qiu等^[49]在其工作中表明，SISR网络的浅层特征包含更多低频信息，深层特征包含更多高频信息。要重建出SR图像中的高频信息，需要融合低频特征信息。最近，Luo等^[36]提出反向特征融合方案：首先采用 1×1 的卷积层对所有特征提取块的输出通道进行压缩，使通道数减少一半，然后从后向前逐步融合所有降维后的特征，提高了重建SR图像的质量。

为了提高SR图像的恢复质量，本章提出了一种名为特征频率分组融合轻量级超分辨率网络（Super-Resolution via Grouping Fusion of Feature Frequencies, FFGFNet）模型，其采用特征频率分组融合的方法来融合高频和低频特征信息。受到Luo等^[36]的工作的启发，本章方法将高频和低频特征信息分组，其中低、高频差异最大的特征组成第1个组，差异次之的特征组成第2个组，依此类推。然后，从频率差异最小的特征组开始，逐步融合，直至频率差异最大的特征组。实验结果表明，本章的特征频率分组融合方法是有效的。与其他同类网络模型相比，本方法在客观度量和主观度量上均表现优异，并具有更好的复杂度和性能平衡。FFGFNet模型有以下特点：（1）该模型是一种轻量级超分辨率网络模型，仅有0.9M参数，性能优于当前类似网络模型，具有更好的模型复杂度和性能平衡；（2）模型采用频率特征分组融合块（Frequency Grouping Fusion Block, FGFB）来更好地融合高频和低频特征信息，提高超分辨率图像中边缘和纹理等高频信息的恢复

质量；(3) 模型还采用多路混合注意力块 (Hybird Attention Block, HAB)，可以收集多路不同的特征信息线索；(4) 模型中还有残差拼接块 (Residual Concatenation Block, RCB)，用于传递和融合局部特征信息。

3.2 算法总体框架

本章提出的FFGFNet模型架构，如图 3-1 所示，包括：由 2 个 3×3 的卷积层组成的浅层特征提取块 (Shallow Feature Extraction Block, SFEB)、2 个深层特征提取块 (Deep Feature Extraction Block, DFEB)、1 个 FGFB 和 1 个上采样块 (Upsampler)。SFEB 用来提取浅层特征信息。2 个级联的 DFEB 参数共享，以减少参数量。Upsampler 使用亚像素的卷积^[50]。本章 FF GFNet 模型架构的重要组成部分是 DFEB 和 FGFB，下面详细介绍 FF GFNet 模型架构的各个部分。

3.2.1 网络结构




图 3-1 FF GFNet 模型整体网络架构

假设输入的图像为 I_{LR} ，其首先通过 SFEB，提取浅层特征，表示为式 (3-1)：

$$F_0 = f_{SFEB}(I_{LR}) \quad (3-1)$$

其中， $f_{SFEB}(\cdot)$ 表示的是浅层特征提取函数， F_0 是其输出的特征信息。 F_0 再输入到 DFEB，进行深层特征提取。每个 DFEB 包含 M (本章实验中， $M=4$) 个残差注意力块 (Residual Attention Block, RAB)，RAB 之间参数不共享。2 个 DFEB 共 $2M$ 个 RAB，依次编号 $1, 2, \dots, 2M$ 。第 m 个 RAB 的输出 F_m ，表示为式 (3-2)：

$$F_m = f_{RAB}^m(F_{m-1}), m = 1, 2, \dots, 2M \quad (3-2)$$

其中， $f_{RAB}^m(\cdot)$ 是第 m 个 RAB 函数。FGFB 接收 2 个 DFEB 中的所有 RAB 的输出，进行分组融合，输出 F_{fusion} ，表示为式 (3-3)：

$$F_{fusion} = f_{FGFB}(F_1, F_2, \dots, F_{2M}) \quad (3-3)$$

其中， $f_{FGFB}(\cdot)$ 是频率分组融合函数 (具体融合方法参见 3.2.5 节)。 F_0 及 F_{fusion} 一起输入到 Upsampler，重建目标残差图像 $I_{SR'}$ ，表示为式 (3-4)：

$$I_{SR'} = f_{UP}(F_0 + F_{fusion}) \quad (3-4)$$

其中, $f_{UP}(\cdot)$ 是 Upsampler 函数。最终输出的目标 SR 图像为 I_{SR} , 可以表示为式 (3-5):

$$I_{SR} = f_{Bic}(I_{LR}) + I_{SR'} \quad (3-5)$$

其中, $f_{Bic}(\cdot)$ 是双三次插值函数。

3.2.2 深层特征提取块 (DFEB)

受 DRCN^[22] 的启发, FFGFNet 中的 DFEB 采用递归学习的方法, 两个 DFEB 共享参数, 增加网络深度的情况下, 保持较少的网络参数量。每个 DFEB 包含 M (在本章实验中, $M=4$) 个 RAB, 如图 3-2 a) 所示。每个 RAB 包括 3 个 RCB 和 1 个 HAB, 如图 3-2 b) 所示。




图 3-2 DFEB 和 RAB 结构图

3.2.3 残差拼接块 (RCB)

Anwar 等^[34]提出的 DRLN, 在其基本构件块 DRLM 中, 同时使用残差学习和通道拼接进行特征融合, 但其使用稠密连接将前层所有特征进行通道拼接, 极大的增加了网络的参数量与运行复杂度。因此, 我们在其基础上进行优化, 提出了 RCB, 如图 3-3 所示。




图 3-3 RCB 结构图

RCB 包含 2 个卷积和 ReLU 非线性激活函数^[51]学习特征残差信息, 并将原输入特征与残差特征进行通道拼接, 以增强特征信息的利用和传播。但是, 也会增加大量的冗余, 因此, 使用 1 个 1×1 的卷积层, 来压缩和融合拼接后的特征信息。第 $m(m=1, 2, \dots, 2M)$ 个 RAB 中第 $k(k=1, 2, 3)$ 个 RCB 的输出特征, 表示为式 (3-6) (忽略了 ReLU 非线性激活):

$$\begin{cases} F_{m,0}^C = F_{m-1} \\ F_{m,k}^C = \text{Conv}_{1 \times 1}([F_{m,k-1}^C, (F_{m,k-1}^C + \text{Conv}_{3 \times 3}(\text{Conv}_{3 \times 3}(F_{m,k-1}^C)))])) \end{cases} \quad (3-6)$$

其中, $\text{Conv}_{n \times n}(\cdot)$ 表示 $n \times n$ 的卷积函数, $F_{m,k-1}^C$ 是第 m 个 RAB 中, 前一个 RCB

的输出，也是当前 RCB 的输入。 F_{m-1} 是第 $m-1$ 个 RAB 的输出， $[\cdot]$ 是特征通道拼接操作。

3.2.4 多路混合注意力块（HAB）

常见的注意力机制通常采用全局平均池化提取信息，其仅考虑全局角度而忽视了其他角度的影响。因此，我们提出了如图 3-4 所示的 HAB，该模块混合使用 GAP、GMP 和局部信息三个种方式，并将其分为上、中、下 3 个分支。3 条支路以不同的形式，计算通道的重要性（权重），然后求和，可以更好地发掘特征信息的线索，提高我们网络的细节保真度，使我们的网络拥有不错的性能。




图 3-4 HAB 结构图

为了简便，我们假定输入 $X = [x_1, x_2, \dots, x_c, \dots, x_C] \in \mathbb{R}^{H \times W \times C}$ (H , W 和 C 分别为高、宽和通道数)，3 条支路的权重如式 (3-7) 所示（忽略 ReLU 非线性激活）：

$$\begin{cases} W_1 = \sigma(\text{Conv}_{1 \times 1}(\text{Conv}_{1 \times 1}(f_{\text{GAP}}(X)))) \\ W_2 = \sigma(\text{Conv}_{1 \times 1}(\text{Conv}_{1 \times 1}(f_{\text{GMP}}(X)))) \\ W_3 = \sigma(\text{Conv}_{1 \times 1}(\text{Conv}_{1 \times 1}(X))) \end{cases} \quad (3-7)$$

其中， $\sigma(\cdot)$ 是 Sigmoid 函数， $\text{Conv}_{1 \times 1}(\cdot)$ 是 1×1 的卷积函数， $f_{\text{GAP}}(\cdot)$ 是 GAP 函数， $f_{\text{GMP}}(\cdot)$ 是 GMP 函数。HAB 的输出 F_{hab} ，如式 (3-8) 所示：

$$F_{\text{hab}} = (W_1 + W_2 + W_3) \odot X \quad (3-8)$$

其中， $\odot$ 表示特征元素逐点相乘， W_1 、 W_2 和 W_3 的尺寸分别为 $1 \times 1 \times C$ 、 $1 \times 1 \times C$ 和 $W \times H \times C$ ，逐元素运算时，需要 Python 广播（Broadcasting）机制实现。 W_1 和 W_2 求和后在空间维度进行复制，然后与 W_3 求和。

3.2.5 频率分组融合块（FGFB）

有效地利用层次信息对于提高 SR 图像的质量是至关重要的。本章提出了 FGFB，将低、高频率差异最大的特征分为第 1 个组，差异次之的特征分为第 2 个

组，依此类推。然后，从频率差异最小的特征组开始，逐步融合，直至频率差异最大的特征组。另外，考虑到可能并不是所有的特征对图像的恢复都能起到良好的作用，因此，我们在融合尾部引入了HAB，根据特征的重要程度对其进行加权处理，以提取出网络中更重要的信息。FGFB的结构图，如图 3-5 所示。




图 3-5 FGFB 结构图

第 4 组融合的输出为 F_1^G ，可表示为式 (3-9)：

$$F_1^G = \text{Conv}_{1 \times 1}([\text{Conv}_{1 \times 1}(F_4), \text{Conv}_{1 \times 1}(F_5)]) \quad (3-9)$$

其中， $\text{Conv}_{1 \times 1}(\cdot)$ 表示 1×1 的卷积函数， F_m 是第 m 个 RAB 的输出， $[\cdot]$ 是通道拼接。第 3 组融合的输出为 F_2^G ，可表示为式 (3-10)：

$$F_2^G = \text{Conv}_{1 \times 1}([F_1^G, \text{Conv}_{1 \times 1}(F_3), \text{Conv}_{1 \times 1}(F_6)]) \quad (3-10)$$

其中， $\text{Conv}_{1 \times 1}(\cdot)$ 表示 1×1 的卷积函数， F_m 是第 m 个 RAB 的输出， $[\cdot]$ 是通道拼接。第 2 组和第 1 组的融合输出 F_3^G 和 F_4^G 的计算是类似的。FGFB 的最终输出 F_{fusion} ，可表示为式 (3-11)：

$$F_{\text{fusion}} = f_{\text{HAB}}(F_4^G) \quad (3-11)$$

其中， $f_{\text{HAB}}(\cdot)$ 是多路混合注意力函数（具体函数参见 3.2.4）

3.3 实验结果与分析

3.3.1 数据集

3.3.1.1 训练集

本章采用流行的DIV2K^[52]数据集来训练和验证网络模型。该数据集包括 800 幅训练图像（编号 1-800）和 100 幅验证图像（编号 801-900）。我们使用 10 幅图像（编号 841-850），标记为DIV2K-10，用于验证。我们使用原始HR图像通过一定的操作，获得相应的LR图像，这个操作就是双三次下采样。此外，类似其他网络模型，我们也采用了一些数据增强技术，例如通过 90°、180°、270°和水平翻转，以增强训练数据的多样性。

3.3.1.2 测试集

为了保证对比的客观性，我们使用和其他方法一样的 5 个标准的测试数据集，即：Set5^[53]、Set14^[54]、B100^[55]、Urban100^[56]和Manga109^[57]。

3.3.2 实验参数设置

训练批大小设置为 16，输出块的尺寸设置为 192×192。使用ADAM^[58]优化器，设置 $\beta_1 = 0.9$ ， $\beta_2 = 0.999$ ， $\varepsilon = 10^{-8}$ ，初始学习率为 2×10^{-4} ，共训练 1000 个迭代周期，每 200 个迭代周期（epoch）衰减一半。使用L₁损失函数。每个DFEB中RAB个数为 4，HAB中每个支路的 2 个 1×1 卷积，对特征通道分别压缩和扩张 16 倍。利用Pytorch^[59]框架，一个NVIDIA 2080Ti GPU设备，实现模型的构建、训练和测试。

3.3.3 评估度量

为了公正、可靠的比较，本章沿用了与之前方法一样的度量方式，在YCbCr空间^[25]的亮度（Y）通道上，计算PSNR、SSIM。此外，本章还使用了LPIPS度量进行评估（PSNR、SSIM和LPIPS的具体计算方式参见 2.4 节）。

3.3.4 结果与分析

3.3.4.1 残差注意力块（RAB）实验

在DFEB中，RAB个数分别为 2、3、4、5 和 6 时，放大 4 倍时的PSNR和模型参数量，在DIV2K-10 验证集上的值，如表 3-1 所示。可以看出：增加RAB个

数, PSNR增加, 但是, 参数量也随之增加。当RAB个数为 5 和 6 时, PSNR增加减缓, RAB个数设置为 4, 似乎是一个合理的折中。

表 3-1 在 DIV2K-10 验证集上的 4 倍 SR 时不同 RAB 个数的性能比较

DFEB 中 RAB 个数	PSNR (dB)	参数量 (K)
2	29.85	507
3	29.95	707
4	30.06	907
5	30.08	1107
6	30.13	1307

(1) RCB个数实验

在RAB中, RCB个数为 2、3 和 4 时, DIV2K-10 验证集上 4 倍SR时不同RCB个数的性能比较, 如表 3-2 所示。可以看出: 增加RCB个数, PSNR增加, 但是, 参数量也随之增加。当RCB个数为 4 时, PSNR增加很小, RCB个数设置为 3, 似乎是一个合理的折中。

表 3-2 在 DIV2K-10 验证集上的 4 倍 SR 时不同 RCB 个数的性能比较

RAB 中 RCB 个数	PSNR (dB)	参数量 (K)
2	29.86	653
3	30.06	907
4	30.07	1162

(2) RCB结构实验

为了验证RCB结构对模型性能的影响, 我们进行了 4 组对比实验。第 1 组实验, RCB不包含残差、通道拼接和 1×1 卷积 (通道压缩), 这个模型称为RCB_0; 第 2 组实验, RCB包含残差, 但不包含通道拼接和 1×1 卷积 (通道压缩), 这个模型称为RCB_1; 第 3 组实验, RCB不包含残差, 但包含通道拼接和 1×1 卷积 (通道压缩), 这个模型称为RCB_2; 第 4 组实验是使用完整的残差块, 这个模型称为RCB (即FFGFNet)。在DIV2K-10 验证集上, 4 倍SR的PSNR和模型参数量, 如表 3-3 所示。可以看出: 残差和通道拼接都能改进模型性能, 残差和通道拼接联合使用时, 性能改进更大。

表 3-3 在 DIV2K-10 验证集上的 4 倍 SR 时不同 RCB 结构的 PSNR 结果

模型	PSNR (dB)
RCB_0	29.91
RCB_1	29.97
RCB_2	30.03
RCB	30.06

3.3.4.2 频率分组融合块 (FGFB) 实验

为了验证FGFB的效果,我们设计了4组实验。第1组实验,FFGFNet模型不包含FGFB,这个模型称为FGFB_0;第2组实验,把FGFB,替换为8个RAB输出特征的稠密连接和通道拼接,这个模型称为FGFB_1;第3组实验,把FGFB,替换为LatticeNet^[36]中的反向特征融合,这个模型称为FGFB_2;第4组实验,是FFGFNet模型包含FGFB,这个模型称为FGFB(即FFGFNet)。在DIV2K-10验证集上,不同模型4倍SR的PSNR结果,如表3-4所示。可以看出:FGFB是有效的。

表 3-4 DIV2K-10 验证集上 4 倍 SR 时不同 FGFB 模型的 PSNR 结果

模型	PSNR (dB)
FGFB_0	30.01
FGFB_1	30.00
FGFB_2	29.95
FGFB	30.06

3.3.4.3 多路混合注意力块 (HAB) 实验

为了验证HAB的效果,我们设计了3组实验。第1组实验中,是在FFGFNet模型的RAB和FGFB中均不包含HAB,这个模型称为HAB_0;第2组实验中,是把RAB和FGFB中的HAB均替换为RCAN^[25]中的通道注意力,这个模型称为HAB_1;第3组实验中,是使用我们提出的HAB,这个模型称为HAB(即FFGFNet)。在DIV2K-10验证集上,不同模型4倍SR的PSNR结果,如表3-5所示。可以看出:HAB是有效的。

表 3-5 DIV2K-10 验证集上 4 倍 SR 时不同 HAB 模型的 PSNR 结果

模型	PSNR (dB)
HAB_0	30.00
HAB_1	30.01
HAB	30.06

我们提出的HAB如图3-3所示,计算注意力权重分为3条支路,收集特征的不同线索。从上到下,分别是支路1,使用了GAP的通道注意力^[25];支路2,使用了GMP通道注意力^[43];以及支路3,类似于通道注意力和空间注意力。为了验证HAB各个支路的效果,我们设计了4组实验,验证了HAB只使用支路1、同时使用支路1和支路2、同时使用支路1和支路3,以及同时使用3条支路这4种情形,对模型性能的影响。在DIV2K-10验证集上,4种情形4倍SR的PSNR结果,如表3-6所示。可以看出:仅使用第1条支路时,性能最差;同时使用第1条、第2条和同时使用第1条、第3条时,性能均有所增加;同时使用3条支路

时性能最好。由此可见，每条支路都有效果，3条支路同时使用效果最好。

表 3-6 DIV2K-10 验证集上 4 倍SR时RAB各支路组合的PSNR结果

支路 1	支路 2	支路 3	PSNR (dB)
√	×	×	30.01
√	√	×	30.02
√	×	√	30.03
√	√	√	30.06

3.3.4.4 图像恢复效果实验

为了验证本章RCB、HAB和FGFB的图像恢复效果，进行了 3 组消融实验。第 1 组实验，FFGFNet模型仅使用RCB，这个模型称之为Only_RCB；第 2 组实验，同时使用RCB和HAB，这个模型称之为RCB_HAB；第 3 组实验，同时使用提出的 3 个模块，这个模型称之为Ours。在Urban100 数据集上 4 倍SR结果，如图 3-6 所示。可以看出：仅使用RCB时，恢复效果较差；在此基础上增加HAB后，效果得到改善；同时使用 3 者时，效果最佳。因此推测：本章各模块间的相互协作，可以更充分地利用图像特征，特别是低频和高频特征的融合，达到了更好的图像细节恢复效果。




图 3-6 Urban100 数据集上不同模型 4 倍SR结果

3.3.4.5 与先进网络模型的比较

为了验证本章FFGFNet模型的有效性，本小节对它和其他 13 个先进网络模型进行了定量客观比较和主观视觉效果比较。代表性的模型主要有：SRCNN^[19]、

FSRCNN^[60]、VDSR^[21]、DRCN^[22]、LapSRN^[61]、MemNet^[62]、CARN^[28]、AWSRN-M^[63]、LAPAR-A^[64]、A²F-M^[65]、RFDN-L^[29]、LatticeNet^[36]和ACAN^[66]。在 5 个标准测试数据集上, 2、3、4 倍SR的PSNR、SSIM结果, 分别如表 3-7 和 3-8 所示(粗体和下划线分别表示最优结果和次优结果)。视觉效果如图 3-7 所示。除 LatticeNet外, 其他网络模型的PSNR、SSIM结果均来自于作者在原论文中的实验。而LatticeNet的结果, 源自运行作者提供的训练模型¹。原因是LatticeNet原文测试采用了自集成(self_ensemble)策略, 为了公正比较, 本章所有测试结果均未采用自集成策略。

在 5 个标准测试数据集上, 9 个代表性的网络模型: AWSRN^[63]、AWSRN-SD^[63]、CARN^[28]、CARN-M^[28]、SRFBN-S^[67]、IMDN^[26]、A²F-SD^[65]、A²F-L^[65]和 A²F-M^[65], 4 倍SR的LPIPS结果如表 3-9 所示。A²F-M的结果, 通过运行作者的网络模型得到, 其他网络模型的结果引用自A²F^[65]。

(1) 定量客观比较

从表 3-7 和 3-8 可以看出, 我们的PSNR、SSIM结果显著优于其他网络模型。例如, AWSRN-M^[63]和A²F-M^[65], 比我们的FFGFNet略大, 但是本章的结果在所有的数据集和所有的尺度上, 一致优于这 2 个网络模型。2、3 和 4 倍SR的PSNR, 在各个数据集上, 超出AWSRN-M最大值均为 0.24dB; 超出A²F-M最大值分别为 0.19dB、0.22dB和 0.23dB。我们的网络模型比LatticeNet^[36]略大, 但是一致优于其 2、3 和 4 倍SR的PSNR, 在各个数据集上, 超出LatticeNet的最大值分别为 0.21dB、0.25dB和 0.26dB。ACAN^[66]网络模型 4 倍时的参数量, 超过我们网络模型的 1.7 倍, 计算量超过我们网络模型的 6 倍, 但是在Manga109 数据集上的PSNR结果, 比FFGFNet的结果低 0.27dB。综合参数量和计算量考虑, 我们的SSIM值也十分具有优势。

对于LPIPS度量, 从表 3-9 可以看出, 除了在B100 数据集上, AWSRN^[63]结果略好外, 在其他所有数据集上, FFGFNet的结果均优于其他网络模型。

(2) 主观效果比较

图 3-7 展示了本章提出的FFGFNet与其他先进方法, 在进行 4 倍SR时的结果比较。从图中可以看出, FFGFNet的重建效果优于其他方法, 这是明显可见的。在Urban100 数据集中, 例如对于image092, 其他方法产生的结果可能存在过度模糊和失真, 或者重建的条纹方向错误, 但是FFGFNet的结果接近于原始HR图像。在其他图像中, FFGFNet也取得了与image092 类似的优秀表现, 例如在image015 和image024 图像中, 也取得了不错的重建效果。

¹ <https://github.com/ymff0592/super-resolution>

表 3-7 本章算法 FFGFNet 与其他 SISR 方法在 5 个标准测试集上的平均 PSNR

放大 倍数	模型	参数量 (K)	计算量 (G)	Set5	Set14	B100	Urban100	Manga109
2	SRCNN	57	52.7	36.66	32.42	31.36	29.50	35.74
	FSRCNN	12	6.0	37.00	32.63	31.53	29.88	36.67
	VDSR	665	612.6	37.53	33.03	31.90	30.76	37.22
	DRCN	1774	17974.0	37.63	33.04	31.85	30.75	37.63
	LapSRN	813	29.9	37.52	33.08	31.80	30.41	37.27
	MemNet	677	2662.4	37.78	33.28	32.08	31.31	37.72
	CARN	1592	222.8	37.76	33.52	32.09	31.92	38.36
	AWSRN-M	1063	244.1	38.04	33.66	32.21	32.23	38.66
	LAPAR-A	548	171.0	38.01	33.62	32.19	32.10	38.67
	A ² F-M	999	224.2	38.04	33.67	32.18	32.27	38.87
	RFDN-L	626	145.5	38.08	33.67	32.18	32.24	38.95
	LatticeNet	756	169.5	38.06	<u>33.70</u>	32.20	32.25	<u>38.94</u>
	ACAN	800	2108.0	<u>38.10</u>	33.60	<u>32.21</u>	<u>32.29</u>	38.81
	FFGFNet	885	387.0	38.12	33.79	32.24	32.46	38.90
3	SRCNN	57	52.7	32.75	29.28	28.41	26.24	30.59
	FSRCNN	12	4.6	33.16	29.43	28.53	26.43	30.98
	VDSR	665	612.6	33.66	29.77	28.82	27.14	32.01
	DRCN	1774	17974.0	33.82	29.76	28.80	27.15	32.31
	MemNet	677	2662.4	34.09	30.00	28.96	27.56	32.51
	CARN	1592	118.8	34.29	30.29	29.06	27.38	33.50
	AWSRN-M	1143	116.6	34.42	30.32	29.13	28.26	33.64
	LAPAR-A	594	114.0	34.36	30.34	29.11	28.15	33.51
	A ² F-M	1003	100.0	<u>34.50</u>	30.39	29.11	28.28	33.66
	RFDN-L	633	65.5	34.47	30.35	29.11	<u>28.32</u>	<u>33.78</u>
	LatticeNet	765	76.3	34.40	30.32	29.10	28.19	33.63
	ACAN	1115	1051.7	34.46	<u>30.39</u>	<u>29.11</u>	28.28	33.61
	FFGFNet	893	170.0	34.55	30.45	29.16	28.43	33.88
4	SRCNN	57	52.7	30.48	27.49	26.90	24.52	27.66
	FSRCNN	12	4.6	30.71	27.59	26.98	24.62	27.90
	VDSR	665	612.6	31.35	28.01	27.29	25.18	28.83
	DRCN	1774	17974.0	31.53	28.02	27.23	25.14	28.98
	LapSRN	813	149.4	31.54	28.19	27.32	25.21	29.09
	MemNet	677	2662.4	31.74	28.26	27.40	25.50	29.42
	CARN	1592	90.9	32.13	28.60	27.58	26.07	30.47
	AWSRN-M	1254	72.0	32.21	<u>28.65</u>	27.60	26.15	30.56
	LAPAR-A	659	94.0	32.15	28.61	<u>27.61</u>	26.14	30.42
	A ² F-M	1010	56.7	32.28	28.62	27.58	26.17	30.57
	RFDN-L	643	37.4	<u>32.28</u>	28.61	27.58	<u>26.2</u>	<u>30.61</u>
	LatticeNet	777	43.6	32.18	28.61	27.57	26.14	30.54
	ACAN	1556	616.5	32.24	28.62	27.59	26.17	30.53
	FFGFNet	907	96.8	32.33	28.70	27.64	26.35	30.80

表 3-8 本章算法 FFGFNet 与其他 SISR 方法在 5 个标准测试集上的平均 SSIM

放大 倍数	模型	参数量 (K)	计算量 (G)	Set5	Set14	B100	Urban100	Manga109
2	SRCNN	57	52.7	0.9524	0.9063	0.8879	0.8946	0.9661
	FSRCNN	12	6.0	0.9558	0.9088	0.8920	0.9020	0.9694
	VDSR	665	612.6	0.9587	0.9124	0.8960	0.9140	0.9729
	DRCN	1774	17974.0	0.9588	0.9118	0.8942	0.9133	0.9723
	LapSRN	813	29.9	0.9590	0.913	0.8950	0.9100	0.9740
	MemNet	677	2662.4	0.9597	0.9142	0.8978	0.9195	0.9740
	CARN	1592	222.8	0.9590	0.9166	0.8978	0.9256	0.9765
	AWSRN-M	1063	244.1	0.9605	0.9181	0.9000	0.9294	0.9772
	LAPAR-A	548	171.0	0.9605	0.9183	0.8999	0.9283	0.9772
	A ² F-M	999	224.2	0.9607	0.9184	0.8996	0.9294	0.9774
	RFDN-L	626	145.5	0.9606	0.9190	0.8996	0.9290	0.9773
	LatticeNet	756	169.5	0.9607	<u>0.9187</u>	0.8999	0.9288	<u>0.9774</u>
	ACAN	800	2108.0	<u>0.9608</u>	0.9177	<u>0.9001</u>	<u>0.9297</u>	0.9773
	FFGFNet	885	387.0	0.9610	0.9196	0.9005	0.9311	0.9775
3	SRCNN	57	52.7	0.9090	0.8209	0.7863	0.7989	0.9107
	FSRCNN	12	4.6	0.9104	0.8242	0.7910	0.8080	0.9212
	VDSR	665	612.6	0.9213	0.8314	0.7976	0.8279	0.9310
	DRCN	1774	17974.0	0.9226	0.8311	0.7963	0.8276	0.9328
	MemNet	677	2662.4	0.9248	0.8350	0.8001	0.8376	0.9369
	CARN	1592	118.8	0.9255	0.8407	0.8034	0.8404	0.9440
	AWSRN-M	1143	116.6	0.9275	0.8419	0.8059	0.8545	0.9450
	LAPAR-A	594	114.0	0.9267	0.8421	0.8054	0.8523	0.9441
	A ² F-M	1003	100.0	0.9278	0.8427	0.8054	0.8546	0.9453
	RFDN-L	633	65.5	<u>0.9280</u>	0.8421	0.8053	0.8547	<u>0.9458</u>
	LatticeNet	765	76.3	0.9272	0.8416	0.8049	0.8513	0.9442
	ACAN	1115	1051.7	0.9277	<u>0.8435</u>	<u>0.8055</u>	<u>0.8550</u>	0.9447
	FFGFNet	893	170.0	0.9285	0.8436	0.8066	0.8580	0.9463
4	SRCNN	57	52.7	0.8628	0.7503	0.7101	0.7221	0.8505
	FSRCNN	12	4.6	0.8657	0.7535	0.7150	0.7280	0.8517
	VDSR	665	612.6	0.8838	0.7674	0.7251	0.7524	0.8809
	DRCN	1774	17974.0	0.8854	0.7670	0.7233	0.7510	0.8816
	LapSRN	813	149.4	0.8850	0.7720	0.7280	0.7560	0.8845
	MemNet	677	2662.4	0.8893	0.7723	0.7281	0.7630	0.8942
	CARN	1592	90.9	0.8937	0.7806	0.7349	0.7837	0.9084
	AWSRN-M	1254	72.0	0.8954	<u>0.7832</u>	0.7368	0.7884	0.9093
	LAPAR-A	659	94.0	0.8944	0.7818	<u>0.7366</u>	0.7871	0.9074
	A ² F-M	1010	56.7	0.8955	0.7828	0.7364	0.7892	<u>0.9100</u>
	RFDN-L	643	37.4	<u>0.8957</u>	0.7818	0.7363	<u>0.7883</u>	0.9096
	LatticeNet	777	43.6	0.8943	0.7812	0.7355	0.7844	0.9075
	ACAN	1556	616.5	0.8955	0.7824	0.7366	0.7891	0.9086
	FFGFNet	907	96.8	0.8961	0.7842	0.7378	0.7936	0.9115

表 3-9 本章算法 FFGFNet 与其他 SISR 方法在 5 个标准测试集上 4 倍 SR 的 LPIPS 值

模型	参数量 (K)	Set5	Set14	B100	Urban100	Mangal09
AWSRN	1587	0.1747	0.2853	0.3692	0.2198	0.1058
AWSRN-SD	444	0.1779	0.2917	0.3838	0.2468	0.1168
CARN	1592	0.1761	0.2893	0.3799	0.2363	-
CARN-M	412	0.1777	0.2938	0.385	0.2524	-
SRFBN-S	483	0.1776	0.2938	0.3861	0.2554	0.1396
IMDN	715	0.1743	0.2901	0.374	0.235	0.133
A ² F-SD	320	0.1731	0.287	0.3761	0.2375	0.1112
A ² F-L	1374	0.1733	0.2846	0.3698	0.2194	0.1056
A ² F-M	1010	0.1719	0.2837	0.3695	0.2213	0.1068
FFGFNet	907	0.1718	0.2836	0.3695	0.2171	0.1039




图 3-7 标准测试集上 4 倍视觉效果比较

3.4 本章小结

本章提出了 FFGFNet 模型，其主要特点是通过对低频和高频特征信息的分组融合，能够更好地恢复 SR 图像中的高频信息，如边缘和纹理。此外，还构造了一个 RCB 来更好地利用和传播局部特征信息，同时提出了一个 HAB 来多路收集特征信息的不同线索。RCB 和 HAB 的组合形成了 FFGFNet 模型的基本构件 RAB。实验结果表明，本章提出的网络模型在客观度量和主观效果方面都优于其他类似的先进网络模型。此外，本章的网络模型提供了一个更好的 SISR 模型复杂度和性能平衡，可为 SISR 任务提供更加有效和可靠的解决方案。

第 4 章 基于轻量卷积的图像超分辨率算法

4.1 引言

当前,轻量级的 SISR 网络在现实中具有非常重要的意义。由于移动设备的存储能力和计算量都比较有限,所以,运行较大的网络模型非常困难。相比之下,轻量级的网络具有很少的参数量和计算量,非常适合在存储量和计算量较小的移动设备上使用。因此,设计轻量级 SISR 网络模型,是当前 SISR 研究的热点。

为了设计轻量级的网络,研究者采用了多种方法,其中一种常见的做法是采用递归学习^[28,68-70]。通过递归学习,可以在增加网络深度的情况下,不增加网络的参数量,从而达到轻量的目的。如 CARN^[28]在其基础级联块间,使用递归学习,每个级联块参数共享,大大降低了网络的参数量。NRSR^[68]、RRSR^[69]和 GRRN^[70]通过构造递归网络,使网络达到了不错的性能。虽然递归学习可以提高网络性能,但是训练深度递归网络比较困难。

除了使用递归学习,使用分组卷积也是设计轻量级网络模型的另一个可行方案。采用分组卷积可以显著削减模型参数量,提高训练效率。AlexNet^[71]是最早提出使用分组卷积的网络模型,其提出分组卷积,主要是由于其硬件资源设备不足,因此将特征分组,使用多个 GPU 训练。CARN^[28]将分组卷积运用到了 SR 重建中,使网络达到了不错的性能。IMDN^[26]在其基础构建块 IMDB 中采用特征蒸馏和通道分离,设计了轻量级的网络,改进了网络性能。RFDN^[29]进一步改进了 IMDN 中的 IMDB 模块,在通道分离后,分别提取每条支路的特征,通过改进,提升了网络性能。

为了设计一个既轻量化又能够提供高性能、改善 SR 图像质量的网络,本章中提出了一个基于轻量卷积的超分辨率算法(Very Lightweight and Efficient Image Super-Resolution Network, VLESR)。该算法是一个非常轻量且高效的图像超分辨率网络,使网络在参数量和性能间取得了良好的平衡。本章工作的贡献可以总结如下:(1)提出了一个基于轻量卷积的超分辨率算法,它的复杂度和性能优于本文选取的与其参数量相近的轻量级算法;(2)提出了一种渐进交互组卷积(Progressive Interactive Group Convolution, PIGC),不仅具备普通组卷积的优点,而且增强了特征通道间的信息交互,因此它比传统的组卷积效果更加有效。(3)提出了一种用于图像超分辨率的轻量级卷积块(Lightweight Convolutional Block, LConv),大大减少了网络模型的参数量;(4)提出了一种轻量级残差拼接块(Lightweight Residual Concatenation Block, LRCB),结合了残差连接和通道连

接的优点的同时，也非常轻量化；

4.2 算法总体框架

本章所提出的 VLESR 网络架构如图 4-1 所示，主要包括 1 个 3×3 的卷积层、1 个 DFEB、1 个 FGFB 和 1 个 Upsampler 模块^[50]。DFEB 中包含多个 RAB，Upsampler 使用亚像素卷积^[50]。本章 VLESR 模型架构的重要组成部分是 DFEB，下面详细介绍 VLESR 模型架构的各个部分。

4.2.1 网络结构




图 4-1 VLESR 网络结构图

假设输入的 LR 图像为 I_{LR} ，输出图像是 I_{SR} 。 I_{LR} 首先通过一个 3×3 的卷积层，提取浅层特征，可表示为式 (4-1)：

$$F_0 = f_{3 \times 3}(I_{LR}) \quad (4-1)$$

其中， $f_{3 \times 3}(\cdot)$ 表示的是 3×3 的卷积层， F_0 是其输出的特征信息。 F_0 再输入到 DFEB，进行深层特征提取。每个 DFEB 包含 I （实验中， $I=4$ ）个 RAB。第 i 个 RAB 的输出 F_i ，可表示为式 (4-2)：

$$F_i = f_{RAB}^i(F_{i-1}), i=1, 2, \dots, I \quad (4-2)$$

其中， $f_{RAB}^i(\cdot)$ 是第 i 个 RAB 函数。FGFB 接收 DFEB 中的所有 RAB 的输出 $(F_1, F_2, \dots, F_I)$ ，进行特征分组融合，输出 F_{fusion} ，可表示为式 (4-3)：

$$F_{fusion} = f_{FGFB}(F_1, F_2, \dots, F_I) \quad (4-3)$$

其中， $f_{FGFB}(\cdot)$ 是频率分组融合函数（具体融合方法参见 3.2.5 节）。 F_0 及 F_{fusion} 一起输入到 Upsampler，重建目标残差图像 $I_{SR'}$ ，可表示为式 (4-4)：

$$I_{SR'} = f_{UP}(F_0 + F_{fusion}) \quad (4-4)$$

其中， $f_{UP}(\cdot)$ 是 Upsampler 函数。 I_{SR} 是最终的输出图像，可表示为式 (4-5)：

$$I_{SR} = f_{Bic}(I_{LR}) + I_{SR'} \quad (4-5)$$

其中， $f_{Bic}(\cdot)$ 是双三次插值函数。

4.2.2 轻量级残差拼接块 (LRCB)

每个 RAB 中包括 3 个 LRCB、1 个 HAB (具体方法见 3.2.4 节) 和 1 个跳跃连接。RAB 的结构图, 如图 4-2 a) 所示。LRCB 中包括两部分, 第一部分包括 2 个轻量级卷积层 LConv, 每个卷积层后面跟着 1 个 ReLU 非线性激活函数, 然后, 使用跳跃连接学习局部残差特征, 将这些与输入特征进行通道拼接, 加强特征信息的传播和使用。在第二部分, 使用 1 个 1×1 卷积层压缩通道拼接后的特征。LRCB 的结构图, 如图 4-2 b) 所示。




图 4-2 RAB结构图和LRCB结构图

第 $i(i=1,2,\dots,I)$ 个 RAB 中第 $k(k=1,2,3)$ 个 LRCB 的输出特征, 可以表示为式 (4-6) (忽略了 ReLU 非线性激活):

$$\begin{cases} F_{i,0} = F_{i-1} \\ F_{i,k} = f_{1 \times 1}([F_{i,k-1}, (F_{i,k-1} + f_{LC}(f_{LC}(F_{i,k-1})))])) \end{cases} \quad (4-6)$$

其中, $f_{1 \times 1}(\cdot)$ 表示 1×1 的卷积函数, $f_{LC}(\cdot)$ 是 LConv 函数, $[\cdot]$ 是特征通道拼接操作, $F_{i,k-1}(\cdot)$ 是第 i 个 RAB 中, 前一个 LRCB 的输出, 也是当前 LRCB 的输入。 F_{i-1} 是第 $i-1$ 个 RAB 的输出。

4.2.3 轻量级卷积块 (LConv)

Zhang 等^[72]提出的 ShuffleNet, 构建了一个非常轻量的适用于高级视觉任务的基础块, 称之为 ShuffleNet 单元, 该网络可以有效地应用于移动设备。受到 Zhang 等^[72]的启发, 本章基于 ShuffleNet 单元, 设计了一个非常轻量的、适用于 SISR 任务的基础构建块, 我们称之为轻量卷积块 LConv。本章节主要从两个方面改进了 ShuffleNet 单元: (1) 从 ShuffleNet 单元中删除了批处理规范化层, 因为批处理规范化的操作会降低 SISR 网络的准确性^[23]; (2) 在 ShuffleNet 单元, 将第 1 个和第 2 个 1×1 的分组卷积层分别替换为本章节提出的渐进交互组卷积 PIGC 和 1×1 逐点卷积, 替换后不仅可以保持分组卷积的优点, 还可以加强特征

通道间的信息融合和协作。LConv 的结构图，如图 4-3 所示。




图 4-3 LConv 结构图

假设 LConv 的输入为 F_{in} ，输出为 F_{out} ，则其输出可以表示为式 (4-7)：

$$F_{out} = f_{1 \times 1 PC}(f_{3 \times 3 DC}(f_{CS}(f_{PIGC}(F_{in})))) \quad (4-7)$$

其中， $f_{PIGC}(\cdot)$ 表示渐进交互组卷积（具体方法参见 4.2.4 节）， $f_{CS}(\cdot)$ 表示通道搅拌函数， $f_{3 \times 3 DC}(\cdot)$ 表示 3×3 的逐通道卷积， $f_{1 \times 1 PC}(\cdot)$ 表示 1×1 的逐点卷积。

4.2.4 渐进交互组卷积（PIGC）

由于分组卷积操作，每个分组间没有特征信息交互，这导致了网络性能的退化。为了充分利用组间的信息，我们提出了一种改进的组卷积操作——PIGC。PIGC 不仅具备普通组卷积的优点，而且增强了特征通道间的信息交互。具体而言，PIGC 通过逐步渐进交互的操作，使得每个分组内的特征可以与其他分组内的特征进行交互，以增强它们的表达能力。PIGC 的结构图如图 4-4 所示。




图 4-4 PIGC 结构图

假设 PIGC 的输入为 F_{in} ，并且输入特征被平均分为了 N 组（在本章实验中， $N=4$ ）， $F_n^P (n=1, 2, \dots, N)$ 表示第 n 个分组的特征，则有 $F_m = [F_1^P, F_2^P, \dots, F_N^P]$ 。PIGC 包括 N 条分支，每条分支处理一组特征，各分支的输出特征，可表示为式 (4-8)：

$$\begin{cases} H_1^P = f_{1 \times 1}(F_1^P) \\ H_n^P = f_{1 \times 1}(F_1^P + H_{n-1}^P), n = 2, \dots, N \end{cases} \quad (4-8)$$

其中, $f_{1\times 1}(\cdot)$ 表示 1×1 的卷积操作, H_n^p 是 PIGC 中第 n 个分支的输出。然后, 将 PIGC 中所有分支的输出进行通道拼接, 得到输出特征 F^{cat} , 表示为式 (4-9):

$$F^{cat} = [H_1^p, H_2^p, \dots, H_N^p] \quad (4-9)$$

4.3 实验结果与分析

4.3.1 数据集

4.3.1.1 训练集

本章采用流行的DIV2K^[52]数据集来训练和验证网络模型。该数据集包括 800 个训练图像 (编号 1-800) 和 100 个验证图像 (编号 801-900)。我们使用 10 个图像 (编号 801-810), 标记为DIV2K-10, 用于验证。我们使用原始HR图像通过一定的操作, 获得相应的LR图像, 这个操作就是双三次下采样。此外, 类似其他网络模型, 我们也采用了一些数据增强技术, 例如通过 90° 、 180° 、 270° 和水平翻转, 以增强训练数据的多样性。

4.3.1.2 测试集

为了保证对比的客观性, 我们使用和其他方法一样的 5 个标准的测试数据集, 即: Set5^[53]、Set14^[54]、B100^[55]、Urban100^[56]和Manga109^[57]。

4.3.2 实验参数设置

训练批大小设置为 16, 输出块的尺寸设置为 192×192 。使用ADAM^[58]优化器, 设置 $\beta_1 = 0.9$, $\beta_2 = 0.999$, $\varepsilon = 10^{-8}$, 初始学习率为 3×10^{-3} , 总共训练 1000 个迭代周期, 每 200 个迭代周期 (epoch) 衰减一半。使用 L_1 损失函数。每个LRCB的输入特征为 64 通道。DFEB中RAB个数为 4, HAB块中每个支路的 2 个 1×1 卷积, 对特征通道分别压缩和扩张 16 倍。通过Pytorch^[59]框架, 一个NVIDIA 2080Ti GPU设备, 实现模型的构建、训练和测试。

4.3.3 评估度量

为了公正、可靠的比较, 本章沿用了与之前方法一样的度量方式, 在YCbCr空间^[25]的亮度 (Y) 通道上, 计算PSNR、SSIM。此外, 本章还使用了LPIPS度量进行评估 (PSNR、SSIM和LPIPS的具体计算方式参见 2.4 节)。

4.3.4 结果与分析

4.3.4.1 消融实验

为了评估LRCB、HAB和FGFB的效果，本章设计了 8 组比较实验。为了方便比较，本章首先将LRCB进行两方面的简化：（1）不包含残差连接、通道拼接和 1×1 卷积；（2）LConv中的PIGC和 1×1 点卷积用ShuffleNet^[72]单元中的分组卷积代替。这个简化之后的模块，我们称之为LRCB_S。本章提出的模型VLESR中，移除了FGFB、RAB中的HAB，并用LRCB_S替换掉LRCB，我们将这个模型看做本实验的基础模型。在基础模型上进行不同的操作，可实现不同的模型变体。如用LRCB替换掉LRCB_S、添加FGFB或添加HAB或同时添加FGFB和HAB。在DIV2K-10 验证集上，放大 4 倍时，SR的PSNR和模型性能，如表 4-1 所示。

表 4-1 在 DIV2K-10 验证集上的 4 倍 SR 时不同模型的性能比较

LRCB_S	√	×	√	√	×	√	×	×
LRCB	×	√	×	×	√	×	√	√
HAB	×	×	√	×	√	√	×	√
FGFB	×	×	×	√	×	√	√	√
PSNR (dB)	29.258	29.351	29.297	29.312	29.395	29.343	29.388	29.440

表 4-1 的第 2 列是本实验的基础模型，最后一列是本章所提出的VLESR。从表格中可以看出，基础模型的PSNR最低，为 29.258dB。表格的第 3 到 5 列表示，在基础模型中分别加入LRCB、HAB和FGFB，加入后网络的性能有所提升。表格的第 6 到 8 列表示分别加入LRCB、HAB和FGFB的任意两个模块，性能会继续提升。当同时使用三者时，性能最好，PSNR为 29.440dB，比基础模型的PSNR提高了 0.182dB。

4.3.4.2 残差注意力块（RAB）个数实验

在DFEB中，RAB个数的不同，会影响网络的性能。图 4-5 a) 表示在DFEB中，RAB个数分别为 3、4 和 5 时，在DIV2K-10 验证集上，2 倍SR的PSNR的变化趋势。可以看出：增加RAB个数，PSNR增加，当RAB的个数是 4 和 5 时，他们PSNR的变化曲线特别接近，RAB个数设置为 4，似乎是一个合理的折中。

4.3.4.3 轻量级残差拼接块（LRCB）个数实验

在RAB中，LRCB个数分别为 2、3 和 4 时，DIV2K-10 验证集上 2 倍SR的PSNR的变化趋势如图图 4-5 b) 所示。可以看出：随着增加LRCB个数的增加，PSNR也在增加。但是，从表 4-2 可以看出，LRCB个数从 2 增加到 3，和从 3 增加到 4，网络参数量增长相同（80K），但是PSNR的增加值却从 0.117dB，变到了

0.086dB，呈下降趋势。因此，LRCB个数设置为 3，似乎是一个合理的折中。




图 4-5 在DIV2K-10 验证集上的 2 倍SR时RAB个数和LRCB个数实验对比

表 4-2 在 DIV2K-10 验证集上的 2 倍 SR 时不同 LRCB 个数的性能比较

RAB 中 LRCB 个数	PSNR (dB)	参数量 (K)	计算量 (G)
2	35.460	231	52.7
3	35.577	311	71.2
4	35.663	391	89.6

4.3.4.4 渐进交互组卷积（PIGC）中分组数实验

在PIGC中，分组数分别为 2、4 和 8 时，在DIV2K-10 验证集上，2 倍SR的 PSNR的变化趋势，如图 4-6 所示。为了表示方便，我们所取的数以 2 的整数次幂表示分组数。从图中可以看出，分组数为 4 时，PSNR明显优于分组数为 2 和 8 的情况。因此，我们选择PIGC的分组数为 4。




图 4-6 在DIV2K-10 验证集上的 2 倍SR时PIGC分组数对比

4.3.4.5 轻量级残差拼接块（LRCB）结构实验

为了验证LRCB结构设计的有效性,本节进行了4组对比实验。第1组实验,LRCB不包含残差、通道拼接和 1×1 卷积(通道压缩),这个模型称为LRCB_0;第2组实验,LRCB包含残差,但不包含通道拼接和 1×1 卷积(通道压缩),这个模型称为LRCB_1;第3组实验,LRCB不包含残差,但包含通道拼接和 1×1 卷积(通道压缩),这个模型称为LRCB_2;第4组实验是使用完整的残差块,这个模型称为LRCB(即VLESR)。在DIV2K-10验证集上,4倍SR时不同模型的PSNR结果,如表4-3所示。可以看出:残差和通道拼接联合使用时,性能效果最佳。这一事实似乎也表明,残差学习和通道拼接都可以增强特征传播和学习能力,残差学习与通道拼接相结合可以进一步帮助探索新特征并学习更好的特征表示^[48]。

表 4-3 在DIV2K-10 验证集上的 4 倍SR时不同模型的PSNR

模型	PSNR (dB)
LRCB_0	29.286
LRCB_1	29.348
LRCB_2	29.393
LRCB	29.440

4.3.4.6 轻量卷积块（LConv）实验

为了验证LConv的在本网络模型中的效果,本节进行了3组对比实验。在第1组实验中,用ShuffleNet单元中 1×1 分组卷积,分别替换掉图4-3中的PIGC和 1×1 的点卷积,该模型称为LConv_0;在第2组实验中,仅用ShuffleNet单元中的 1×1 的分组卷积,替换掉PIGC,该模型称为LConv_1;在第3组实验中,使用完整的LConv模块,这个模型称为LConv(即VLESR)。在DIV2K-10验证集上,放大4倍时,SR的PSNR结果,如表4-4所示。从表中可以看出,使用LConv时效果最好,表明LConv可以有效的增强各通道间的信息融合和协作。

表 4-4 在 DIV2K-10 验证集上的 4 倍 SR 时不同模型的 PSNR

模型	PSNR (dB)
LConv_0	29.361
LConv_1	29.399
LConv	29.440

4.3.4.7 频率分组融合块（FGFB）实验

为了验证FGFB在本网络模型中的效果,我们设计了4组实验。第1组实验,VLESR模型不包含FGFB,这个模型称为FGFB_0;第2组实验,把FGFB,替换为RAB输出特征的稠密连接和通道拼接,这个模型称为FGFB_1;第3组实验,把FGFB,替换为LatticeNet^[36]中的反向特征融合,这个模型称为FGFB_2;第4组

实验，是VLESR模型包含FGFB，这个模型称为FGFB（即VLESR）。在DIV2K-10验证集上，我们对不同模型进行了4倍超分辨率的PSNR验证，结果如表4-5所示。可以看出，通过分组融合高频和低频信息的FGFB模型，比稠密链接的融合特征和反向融合特征的模型都有更好的表现。

表 4-5 DIV2K-10 验证集上 4 倍 SR 时不同 FGFB 模型的 PSNR 结果

模型	PSNR (dB)
FGFB_0	29.395
FGFB_1	29.409
FGFB_2	29.417
FGFB	29.440

4.3.4.8 与先进网络模型的比较

(1) 参数量比较和计算量比较

本章提出的VLESR，使性能和复杂性具有更好的平衡，与其他最先进的方法比较的结果，如图4-7所示。从图中可以看出，与SRMDNF相比，本章的VLESR的PSNR值高约0.2dB，但是VLESR的参数却只有SRMDNF的1/5。与LapSRN相比，VLESR比其PSNR高约0.7dB，但是计算量不到其1/7。




图 4-7 在Set5 上的 4 倍SR时各种先进方法的SISR结果

(2) 定量客观比较和主观效果比较

为了验证VLESR模型的有效性，本小节对它和其他13个先进网络模型进行了定量客观比较和主观视觉效果比较，这些网络模型有：SRCNN^[19]、FSRCNN^[60]、VDSR^[21]、DRCN^[22]、DRRN^[73]、MemNet^[62]、SRMDNF^[74]、IDN^[75]、AWSRN-S^[63]、SRFBN-S^[67]、LAPAR-B^[64]、A²F-SD^[65]和PAN^[76]。在5个标准测试数据集上，2、3、4倍SR的PSNR、SSIM结果，分别如表4-6和4-7所示（粗体和下划线分别表示最优结果和次优结果）。视觉效果如图4-8和4-9所示。除PAN^[76]外，其他网络模型的PSNR、SSIM结果均来自于作者在原论文中的实验。由于PAN同时使用

DIV2K和Flickr2K作为训练集，为了公平比较，本章通过作者提供的源代码，使用DIV2K训练集重新训练，因此，测试结果与原论文有所不同。

在5个标准测试数据集上，9个代表性的网络模型：SRCNN^[19]、CARN^[28]、CARN-M^[28]、AWSRN-S^[63]、AWSRN-SD^[63]、SRFBN-S^[67]、LAPAR-B^[64]、A²F-SD^[65]和PAN^[76]，4倍SR的LPIPS结果如表4-8所示。SRCNN、AWSRN-S、AWSRN-SD和LAPAR-B的结果运行作者的模型，PAN的结果通过我们训练的模型计算得出，其他模型的结果援引自A²F。

定量客观比较：从表4-6和4-7可以看出，我们提出的VLESR模型在PSNR、SSIM指标上表现显著优于其他网络模型。尽管VLESR的模型规模略大于PAN模型，但是其计算量比PAN模型小。在几乎所有的数据集和尺度上，VLESR的PSNR结果均优于其他模型。与效果次之的模型相比，在4倍SR时，最大的PSNR差值为0.15dB；3倍SR时，最大差值为0.27dB；2倍SR时，最大差值为0.38dB。虽然LAPAR-B模型的参数量比VLESR略小，但是其计算量却是VLESR的两倍多，而VLESR的性能始终比LAPAR-B好。LAPAR-B与VLESR相比，在4倍SR时，最大PSNR差值为0.45dB；3倍SR时，最大差值为0.46dB；2倍SR时，最大差值为0.52dB。综合参数量和计算量考虑，我们的SSIM值也十分具有优势。

在LPIPS度量方面，从表4-8可以看出，在除了Set14数据集外的其他所有数据集上，VLESR的结果均优于其他对比的网络模型。尽管在Set14数据集上，A²F-SD的结果略优于VLESR，但是在整体效果上，VLESR仍然是最优秀的模型。

主观效果比较：图4-8展示了本章提出的VLESR方法与其他最先进方法2倍SR时的重建图像效果比较。从图中可以看出，VLESR的结果明显优于其他方法。以Urban100数据集中的image092图像为例，VLESR重建的图像与HR图像更为接近，而其他方法重建的图像要么过度模糊和扭曲，要么重建出错误的条纹方向。类似的情况，也出现在Set14数据集中的Barbara图像中。图4-9展示了VLESR与其他最先进方法4倍SR时的重建图像效果比较。从图4-9中也可以得出相同的结论，VLESR在图像重建任务中具有更高的准确性和清晰度。

表 4-6 本章算法 VLESR 与其他 SISR 方法在 5 个标准测试集上的平均 PSNR

放大 倍数	模型	参数量 (K)	计算量 (G)	Set5	Set14	B100	Urban100	Manga109
2	SRCNN	57	52.7	36.66	32.42	31.36	29.50	35.74
	FSRCNN	12	6.0	37.00	32.63	31.53	29.88	36.67
	VDSR	665	612.6	37.53	33.03	31.90	30.76	37.22
	DRCN	1774	17974.0	37.63	33.04	31.85	30.75	37.63
	DRRN	297	6797.0	37.74	33.23	32.05	31.23	37.92
	MemNet	677	2662.4	37.78	33.28	32.08	31.31	37.72
	SRMDNF	1513	347.7	37.79	33.32	32.05	31.33	38.07
	IDN	553	127.7	37.83	33.30	32.08	31.27	38.01
	AWSRN-S	397	91.2	37.75	33.31	32.00	31.39	37.90
	SRFBN-S	282	-	37.78	33.35	32.00	31.41	38.06
	LAPAR-B	250	85.0	37.87	33.39	32.10	31.62	38.27
	A ² F-SD	313	71.2	37.91	33.45	32.08	31.79	<u>38.52</u>
	PAN	261	70.5	<u>37.99</u>	<u>33.53</u>	<u>32.14</u>	<u>31.93</u>	38.37
	VLESR	311	71.2	38.01	33.58	32.16	32.14	38.75
3	SRCNN	57	52.7	32.75	29.28	28.41	26.24	30.59
	FSRCNN	12	4.6	33.16	29.43	28.53	26.43	30.98
	VDSR	665	612.6	33.66	29.77	28.82	27.14	32.01
	DRCN	1774	17974.0	33.82	29.76	28.80	27.15	32.31
	DRRN	297	6797.0	34.03	29.96	28.95	27.53	32.74
	MemNet	677	2662.4	34.09	30.00	28.96	27.56	32.51
	SRMDNF	1530	156.3	34.12	30.04	28.97	27.57	33.00
	IDN	553	57.0	34.11	29.99	28.95	27.42	32.71
	AWSRN-S	477	48.6	34.02	30.09	28.92	27.57	32.82
	SRFBN-S	376	-	34.20	30.10	28.96	27.66	33.02
	LAPAR-B	276	61.0	34.20	30.17	29.03	27.85	33.15
	A ² F-SD	316	31.9	34.23	30.22	29.01	27.91	33.29
	PAN	261	39.0	<u>34.30</u>	<u>30.30</u>	<u>29.06</u>	<u>28.02</u>	<u>33.34</u>
	VLESR	319	32.9	34.40	30.34	29.08	28.16	33.61
4	SRCNN	57	52.7	30.48	27.49	26.90	24.52	27.66
	FSRCNN	12	4.6	30.71	27.59	26.98	24.62	27.90
	VDSR	665	612.6	31.35	28.01	27.29	25.18	28.83
	DRCN	1774	17974.0	31.53	28.02	27.23	25.14	28.98
	DRRN	297	6797.0	31.68	28.21	27.38	25.44	29.46
	MemNet	677	2662.4	31.74	28.26	27.40	25.50	29.42
	SRMDNF	1555	89.3	31.96	28.35	27.49	25.68	30.09
	IDN	553	32.3	31.82	28.25	27.41	25.41	29.41
	AWSRN-S	588	33.7	31.77	28.35	27.41	25.56	29.74
	SRFBN-S	483	-	31.98	28.45	27.44	25.71	29.91
	LAPAR-B	313	53.0	31.94	28.46	27.52	25.85	30.03
	A ² F-SD	320	18.2	32.06	28.47	27.48	25.80	30.16
	PAN	272	28.2	<u>32.06</u>	28.56	27.55	<u>26.01</u>	<u>30.33</u>
	VLESR	331	19.5	32.17	<u>28.55</u>	27.55	26.03	30.48

表 4-7 本章算法 VLESR 与其他 SISR 方法在 5 个标准测试集上的平均 SSIM

放大 倍数	模型	参数量 (K)	计算量 (G)	Set5	Set14	B100	Urban100	Manga109
2	SRCNN	57	52.7	0.9524	0.9063	0.8879	0.8946	0.9661
	FSRCNN	12	6.0	0.9558	0.9088	0.8920	0.9020	0.9694
	VDSR	665	612.6	0.9587	0.9124	0.8960	0.9140	0.9729
	DRCN	1774	17974	0.9588	0.9118	0.8942	0.9133	0.9723
	DRRN	297	6797.0	0.9591	0.9136	0.8973	0.9188	0.9760
	MemNet	677	2662.4	0.9597	0.9142	0.8978	0.9195	0.9740
	SRMDNF	1513	347.7	0.9600	0.9150	0.8980	0.9200	0.9761
	IDN	553	127.7	0.9600	0.9148	0.8985	0.9196	0.9749
	AWSRN-S	397	91.2	0.9596	0.9151	0.8974	0.9207	0.9755
	SRFBN-S	282	-	0.9597	0.9156	0.8970	0.9207	0.9757
	LAPAR-B	250	85.0	0.9600	0.9162	0.8987	0.9235	0.9764
	A ² F-SD	313	71.2	0.9602	0.9164	0.8986	0.9246	<u>0.9767</u>
	PAN	261	70.5	<u>0.9603</u>	<u>0.9174</u>	<u>0.8992</u>	<u>0.9263</u>	0.9766
	VLESR	311	71.2	0.9605	0.9177	0.8993	0.9280	0.9770
3	SRCNN	57	52.7	0.9090	0.8209	0.7863	0.7989	0.9107
	FSRCNN	12	4.6	0.9104	0.8242	0.7910	0.8080	0.9212
	VDSR	665	612.6	0.9213	0.8314	0.7976	0.8279	0.9310
	DRCN	1774	17974	0.9226	0.8311	0.7963	0.8276	0.9328
	DRRN	297	6797.0	0.9244	0.8349	0.8004	0.8378	0.9390
	MemNet	677	2662.4	0.9248	0.8350	0.8001	0.8376	0.9369
	SRMDNF	1530	156.3	0.9250	0.8370	0.8030	0.8400	0.9403
	IDN	553	57.0	0.9253	0.8354	0.8013	0.8359	0.9381
	AWSRN-S	477	48.6	0.9240	0.8376	0.8009	0.8391	0.9393
	SRFBN-S	376	-	0.9255	0.8372	0.8010	0.8415	0.9404
	LAPAR-B	276	61.0	0.9256	0.8387	0.8032	0.8459	0.9417
	A ² F-SD	316	31.9	0.9259	0.8395	0.8028	0.8465	0.9424
	PAN	261	39.0	<u>0.9266</u>	0.8416	<u>0.8042</u>	<u>0.8493</u>	<u>0.9435</u>
	VLESR	319	32.9	0.9272	<u>0.8415</u>	0.8043	0.8519	0.9445
4	SRCNN	57	52.7	0.8628	0.7503	0.7101	0.7221	0.8505
	FSRCNN	12	4.6	0.8657	0.7535	0.7150	0.7280	0.8517
	VDSR	665	612.6	0.8838	0.7674	0.7251	0.7524	0.8809
	DRCN	1774	17974	0.8854	0.7670	0.7233	0.7510	0.8816
	DRRN	297	6797.0	0.8888	0.7720	0.7284	0.7638	0.8960
	MemNet	677	2662.4	0.8893	0.7723	0.7281	0.763	0.8942
	SRMDNF	1555	89.3	0.8930	0.7770	0.7340	0.7730	0.9024
	IDN	553	32.3	0.8903	0.7730	0.7297	0.7632	0.8942
	AWSRN-S	588	33.7	0.8893	0.7761	0.7304	0.7678	0.8982
	SRFBN-S	483	-	0.8923	0.7779	0.7313	0.7719	0.9008
	LAPAR-B	313	53.0	0.8917	0.7784	0.7335	0.7772	0.9025
	A ² F-SD	320	18.2	0.8928	0.7790	0.7373	0.7767	0.9038
	PAN	272	28.2	<u>0.8939</u>	0.7813	0.7352	<u>0.7830</u>	<u>0.9069</u>
	VLESR	331	19.5	0.8945	<u>0.7802</u>	<u>0.7345</u>	0.7830	0.9073

表 4-8 本章算法 VLESR 与其他 SISR 方法在 5 个标准测试集上 4 倍 SR 的 LPIPS 值

模型	参数量 (K)	Set5	Set14	B100	Urban100	Manga109
SRCNN	57	0.2075	0.3199	0.3891	0.3101	0.1849
CARN	1592	0.1761	0.2893	0.3799	0.2363	—
CARN-M	412	0.1777	0.2938	0.3850	0.2524	—
AWSRN-S	588	0.1803	0.2929	0.3853	0.2567	0.121
AWSRN-SD	444	0.1779	0.2917	0.3838	0.2468	0.1168
SRFBN-S	483	0.1776	0.2938	0.3861	0.2554	0.1396
LAPAR-B	313	0.1814	0.2905	0.3813	0.2457	0.1159
A ² F-SD	320	0.1731	0.2870	0.3761	0.2375	0.1112
PAN	272	0.1741	0.2861	0.3748	0.2348	0.1107
VLESR	331	0.1721	0.2886	0.3748	0.2313	0.1078




图 4-8 标准测试集上 2 倍视觉效果




图 4-9 标准测试集上 4 倍视觉效果比较

4.4 本章小结

本章提出了一种非常轻量 and 高效的图像超分辨率网络，称为 VLESR。在 VLESR 中，LRCB 是网络模型的基础构建块，可以更好地传播和融合局部特征，提高网络的表达能力。FGFB 模块可以更好地融合高、低频特征信息，提高 SR 的恢复质量。此外，为了降低网络的参数量，本章提出了 LConv，该模块比普通卷积更加轻量。为了进一步增强分组卷积中组间信息的交互，我们提出了 PIGC，PIGC 是对普通分组卷积的一种改进，能够更好地增强特征通道间的信息交互，使特征的表达能力得到提高。大量实验表明，VLESR 具有竞争性的结果，是一种有效和高效的方法。无论是主观视觉效果比较还是客观指标度量，该方法都明显优于其他先进的方法。VLESR 在复杂度和性能之间取得了良好的平衡，是一种非常实用的方法。

第 5 章 结论与展望

5.1 论文工作总结

本文的研究成果包括设计了轻量级的图像超分辨率重建模型,所设计的模型可以在保持高性能的同时降低模型的复杂性。具体而言,本文通过研究不同的网络结构及组件,提出了基于特征频率分组融合的图像超分辨率算法和基于轻量卷积的图像超分辨率算法。这些算法在超分辨率重建任务上具有较高的重建质量,并且可以在轻量级设备上实现。本文的研究成果对于轻量级超分辨率重建技术的发展具有重要意义,并且可以为相关领域的应用提供有效的技术支持。

(1)提出了一种基于特征频率分组融合的图像超分辨率算法,称为FFGFNet。该方法使用特征频率分组融合方法对所有基础构建块的特征进行了融合,以充分利用分层信息。该方法结合残差拼接块和多路混合注意力机制,提高了图像超分辨率的重建质量。实验结果表明,该方法中所提出的各个模块都非常有效。在主观效果比较中,可以明显地看到该方法的重建质量优于本文选取的与其参数量相近的轻量级算法。此外,在客观指标度量中,该方法与其他 13 个先进方法进行了比较,在被放大 2、3、4 倍时,都表现出了较好的性能。

(2)提出了一种基于轻量卷积的图像超分辨率算法,称为 VLESR。该算法采用了一系列轻量化的卷积操作来构建更加轻量化的超分辨率网络。其中,设计了新型的渐进交互组卷积,该卷积能够增强通道间特征的相互作用,从而提高网络的性能。此外,通过通道搅拌和深度可分离卷积等技术手段,构建了轻量级卷积块。另外,设计了轻量级残差拼接块,作为网络的基础构件,使得整个网络更加轻量化。结合前文提出的特征频率分组融合块和多路混合注意力块,更好地融合多层次的特征信息,提取更丰富的细节。大量实验结果表明,该算法具有很强的竞争力,并且在主观视觉效果比较和客观指标度量方面都取得了较好表现。特别是在复杂度和性能之间取得了良好的平衡,是一种非常实用的超分辨率算法。

综上所述,本文致力于深入研究轻量级图像超分辨率算法的设计,通过详细阐述网络模型的设计结构及其组件设计,探讨如何在保持轻量高效率的同时提高超分辨率图像重建的质量。为了验证算法的有效性,本文开展了充分的实验研究,证明了提出的方法在复杂度和性能之间取得了平衡,且在主观视觉效果比较和客观指标度量方面都取得了较好表现。

5.2 未来工作展望

轻量级单图像超分辨率重建技术的重要性在不断增强,它在各种领域都有着广泛的应用,如安防监控、医学诊断、遥感成像等。本文针对图像超分辨率重建的轻量级算法进行了详细的探究,并提出了多种创新的设计策略,并且取得了不错的成果。然而,随着科技的不断进步,图像超分辨率重建技术也将面临更多的挑战和问题。因此,下一步的研究工作,可以从以下几个方面入手:

(1) 现有的图像超分辨率重建方法,重点关注的是 2 倍、3 倍和 4 倍的放大倍数,对于更高倍数的超分辨率重建算法研究的相对较少。但是,在实际应用中,更高的分辨率对于一些领域非常重要。因此,未来的研究方向之一是研究更大倍数的超分辨率重建算法,以满足实际应用的需求。

(2) 本文研究的超分辨率重建技术主要是基于单幅图像开展的研究,但随着技术的不断进步和实际应用需求的增加,对于多幅图像的超分辨率重建也越来越受到关注。下一步的工作中,需要探索并研究基于多幅图像的超分辨率重建技术,以提高重建的准确性和效率。

(3) 本文所提出的算法是有监督的方法,训练数据要求有目标图像,在选择数据集时要有对应的高分辨率图像,因此实验对于数据集的选择有一定局限性。在某些领域中(如医疗健康领域),获取大量的训练数据是比较困难的,因此,在下一步的工作中,需要对图像超分辨率算法进一步探索,以适应现实需求。

综上所述,虽然轻量级单图像超分辨率技术已经取得了一定的研究成果,但是在实际应用中还存在差距,需要进行不断的探索和创新。相信更多的学者,未来一定能够积极探索如何将图像超分辨率技术应用于实际生产和工程实践中,并开拓更多的应用场景和领域,推动图像超分辨率重建技术的快速发展和广泛应用。

参考文献

- [1] Freeman W T, Pasztor E C, Carmichael O T. Learning low-level vision[J]. International Journal of Computer Vision, 2000, 40(1): 25-47
- [2] Thornton M W, Atkinson P M, Holland D A. Sub-pixel mapping of rural land cover objects from fine spatial resolution satellite sensor imagery using super-resolution pixel-swapping[J]. International Journal of Remote Sensing, 2006, 27(3): 473-491
- [3] Zou W W W, Yuen P C. Very low resolution face recognition problem[J]. IEEE Transactions on Image Processing, 2012, 21(1): 327-340
- [4] Shi W, Caballero J, Ledig C, et al. Cardiac image super-resolution with global correspondence using multi-atlas patchmatch[C]. Proceedings of the International Conference on Medical Image Computing and Computer-Assisted Intervention. Heidelberg: Springer, 2013: 9-16
- [5] Prashanth H S, Shashidhara H L, Murthy K N B. Image scaling comparison using universal imagequality index[C]. 2009 International Conference on Advances in Computing, Control, and Telecommunication Technologies. IEEE, 2009: 859-863
- [6] Gribbon K T, Bailey D G. A novel approach to real-time bilinear interpolation[C]. Electronic Design, Test and Applications, 2004: 126-131
- [7] Keys R. Cubic convolution interpolation for digital image processing[J]. IEEE Transactions on Acoustics, Speech, and Signal Processing, 1981, 29(6): 1153-1160
- [8] Li X, Orchard M T. New edge-directed interpolation[J]. IEEE Transactions on Image Processing, 2001, 10(10): 1521-1527
- [9] Chang S G, Cvetkovic Z, Vetterli M. Locally adaptive wavelet-based image interpolation[J]. IEEE Transactions on Image Processing, 2006, 15(6): 1471-1485
- [10] Huang T S. Multi-frame image restoration and registration[J]. Advances in Computer Vision and Image Processing, 1984, 1: 317-339
- [11] Kim S P, Bose N K, Valenzuela H M. Recursive reconstruction of high resolution image from noisy undersampled multiframes[J]. IEEE Transactions on Acoustics, Speech, and Signal Processing, 1990, 38(6): 1013-1027
- [12] Rhee S, Kang M G. Discrete cosine transform based regularized high-resolution image reconstruction algorithm[J]. Optical Engineering, 1999, 38(8): 1348-1356
- [13] Woods N A, Galatsanos N P, Katsaggelos A K. Stochastic methods for joint registration, restoration, and interpolation of multiple undersampled images[J]. IEEE Transactions on Image Processing, 2006, 15(1): 201-213

- [14] Irani M, Peleg S. Motion analysis for image enhancement: resolution, occlusion, and transparency[J]. *Journal of Visual Communication and Image Representation*, 1993, 4(4): 324-335
- [15] Stark H, Oskoui P. High-resolution image recovery from image-plane arrays, using convex projections[J]. *JOSA A*, 1989, 6(11): 1715-1726
- [16] Marquina A, Osher S J. Image super-resolution by TV-regularization and Bregman iteration[J]. *Journal of Scientific Computing*, 2008, 37(3): 367-382
- [17] Chang H, Yeung D Y, Xiong Y. Super-resolution through neighbor embedding[C]. *Proceedings of the 2004 IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, 2004, 1: I-I
- [18] Yang J, Wright J, Huang T S, et al. Image super-resolution via sparse representation[J]. *IEEE Transactions on Image Processing*, 2010, 19(11): 2861-2873
- [19] Dong C, Loy C C, He K, et al. Learning a deep convolutional network for image super-resolution[J]. *Springer International Publishing*, 2014: 184-199
- [20] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]. *Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition*, 2016: 770-778
- [21] Kim J, Lee J K, Lee K M. Accurate image super-resolution using very deep convolutional networks[C]. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. Los Alamitos: IEEE Computer Society Press, 2016: 1646-1654
- [22] Kim J, Lee J K, Lee K M. Deeply-recursive convolutional network for image super-resolution[C]. *Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition*, 2016: 1637-1645
- [23] Lim B, Son S, Kim H, et al. Enhanced deep residual networks for single image super-resolution[C]. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops*. Los Alamitos: IEEE Computer Society Press, 2017: 1132-1140
- [24] Tong T, Li G, Liu X, et al. Image super-resolution using dense skip connections[C]. *Proceedings of the 2017 IEEE International Conference on Computer Vision*, 2017: 4809-4817
- [25] Zhang Y, Li K, Li K, et al. Image super-resolution using very deep residual channel attention networks[C]. *Proceedings of the European Conference on Computer Vision*. Heidelberg: Springer, 2018: 294-310
- [26] Hui Z, Gao X, Yang Y, et al. Lightweight image super-resolution with information multi-distillation network[C]. *Proceedings of the 27th ACM International Conference on Multimedia*, 2019: 2024-2032

- [27] 郭琳, 李晨, 陈晨, 等. 基于通道注意递归残差网络的图像超分辨率重建[J]. 计算机科学, 2021, 48(8): 6
- [28] Ahn N, Kang B, Sohn K A. Fast, accurate, and lightweight super-resolution with cascading residual network[C]. Proceedings of the 2018 European Conference on Computer Vision, 2018: 252-268
- [29] Liu J, Tang J, Wu G. Residual feature distillation network for lightweight image super-resolution[C]. Proceedings of the 2020 European Conference on Computer Vision, 2020: 41-55
- [30] 李金新, 黄志勇, 李文斌, 等. 基于多层次特征融合的图像超分辨率重建[J]. 自动化学报, 2021, x(x): 1-11
- [31] 段然, 周登文, 赵丽娟, 等. 基于多尺度特征映射网络的图像超分辨率重建[J]. 浙江大学学报(工学版), 2019, 53(7): 1331-1339
- [32] Howard A G, Zhu M, Chen B, et al. Mobilenets: Efficient convolutional neural networks formobile vision applications. arXiv preprint arXiv:1704.04861 (2017)
- [33] 张芸菲. 基于残差结构和密集连接的超分辨率重建算法[D]. 西安电子科技大学, 2020. DOI: 10.27389 /d.cnki.gxadu. 2020.000223
- [34] Anwar S, Barnes N. Densely residual laplacian super-resolution[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020, 44(3): 1192-1204
- [35] Li J, Fang F, Mei K, et al. Multi-scale residual network for image super-resolution[C]. Proceedings of the 2018 European Conference on Computer Vision, 2018: 517-532
- [36] Luo X, Xie Y, Zhang Y, et al. Latticenet: towards lightweight image super-resolution with lattice block[C]. Proceedings of the 2020 European Conference on Computer Vision, 2020: 272-289
- [37] Itti L, Koch C, Niebur E. A model of saliency-based visual attention for rapid scene analysis[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1998, 20(11): 1254-1259
- [38] 刘志强. 基于残差通道注意力的图像超分辨网络轻量化的研究[D]. 西安电子科技大学, 2021. DOI: 10.27389/d.cnki.gxadu. 2021.001608
- [39] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]. Proceedings of the 2018 IEEE Conference on Computer Vision and Pattern Recognition, 2018: 7132-7141
- [40] Timofte R, Agustsson E, Van Gool L, et al. Ntire 2017 challenge on single image super-resolution: methods and results[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops, 2017: 114-125
- [41] Jaderberg M, Simonyan K, Zisserman A. Spatial transformer networks[J].

- Advances in Neural Information Processing Systems, 2015: 28
- [42] Woo S, Park J, Lee J Y, et al. Cbam: Convolutional block attention module[C]. Proceedings of the 2018 European Conference on Computer Vision, 2018: 3-19
- [43] Fu J, Liu J, Tian H, et al. Dual attention network for scene segmentation[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2019: 3141-3149
- [44] 周登文, 王婉君, 马钰, 等. 基于区域互补注意力和多维注意力的轻量级图像超分辨率网络[J]. 模式识别与人工智能, 2022, 35(07): 625-636
- [45] Huynh-Thu Q, Ghanbari M. Scope of validity of psnr in image/video quality assessment[J]. Electronics Letters, 2008, 44(13): 800-801
- [46] Wang Z, Bovik A C, Sheikh H R, et al. Image quality assessment: from error visibility to structural similarity[J]. IEEE Transactions on Image Processing, 2004, 13(4): 600-612
- [47] Zhang R, Isola P, Efros A A, et al. The unreasonable effectiveness of deep features as a perceptual metric[C]. Proceedings of the 2018 IEEE Conference on Computer Vision and Pattern Recognition, 2018: 586-595
- [48] Huang Z, Li W, Li J, et al. Dual-path attention network for single image super-resolution[J]. Expert Systems with Applications, 2021, 169: 114450
- [49] Qiu Y, Wang R, Tao D, et al. Embedded block residual network: a recursive restoration model for single-image super-resolution[C]. Proceedings of the 2019 IEEE/CVF International Conference on Computer Vision, 2019: 4179-4188
- [50] Shi W, Caballero J, Huszár F, et al. Real-time single image and video super-resolution using an efficient sub-pixel convolutional neural network[C]. Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition, 2016: 1874-1883
- [51] Agarap A F. Deep learning using rectified linear units(relu)[OL]. [2018-03-22]. <https://arxiv.org/abs/1803.08375>
- [52] Agustsson E, Timofte R. Ntire 2017 challenge on single image super-resolution: dataset and study[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops. Los Alamitos: IEEE Computer Society Press, 2017: 126-135
- [53] Bevilacqua M, Roumy A, Guillemot C, et al. Low-complexity single-image super-resolution based on nonnegative neighbor embedding[C]. Proceedings of the British Machine Vision Conference 2012: 135.1-135.10
- [54] Zeyde R, Elad M, Protter M. On single image scale-up using sparse-representations[C]. Proceedings of the International Conference on Curves and Surfaces. Heidelberg: Springer, 2010: 711-730
- [55] Martin D, Fowlkes C, Tal D, et al. A database of human segmented natural images

- and its application to evaluating segmentation algorithms and measuring ecological statistics[C]. Proceedings Eighth IEEE International Conference on Computer Vision. Los Alamitos: IEEE Computer Society Press, 2001, 2: 416-423
- [56] Huang J B, Singh A, Ahuja N. Single image super-resolution from transformed self-exemplars[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2015: 5197-5206
- [57] Matsui Y, Ito K, Aramaki Y, et al. Sketch-based manga retrieval using manga109 dataset[J]. Multimedia Tools and Applications, 2017, 76(20): 21811-21838
- [58] Kingma D P, Ba J. Adam: a method for stochastic optimization[OL]. [2014-12-22]. <https://arxiv.org/abs/1412.6980>
- [59] Paszke A, Gross S, Chintala S, et al. Automatic differentiation in pytorch[OL]. [2017-10-29]. <https://openreview.net/forum?id=BJJsrnfCZ>
- [60] Dong C, Loy C C, Tang X. Accelerating the super-resolution convolutional neural network[C]. Proceedings of the European Conference on Computer Vision. Heidelberg: Springer, 2016: 391-407
- [61] Lai W S, Huang J B, Ahuja N, et al. Deep laplacian pyramid networks for fast and accurate super-resolution[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2017: 5835-5843
- [62] Tai Y, Yang J, Liu X, et al. Memnet: a persistent memory network for image restoration[C]. Proceedings of the IEEE International Conference on Computer Vision. Los Alamitos: IEEE Computer Society Press, 2017: 4549-4557
- [63] Wang C, Li Z, Shi J. Lightweight image super-resolution with adaptive weighted learning network[OL]. [2019-04-04]. <https://arxiv.org/abs/1904.02358>
- [64] Li W, Zhou K, Qi L, et al. Lapar: Linearly-assembled pixel-adaptive regression network for single image super-resolution and beyond[J]. Advances in Neural Information Processing Systems, 2020, 33: 20343-20355
- [65] Wang X, Wang Q, Zhao Y, et al. Lightweight single-image super-resolution network with attentive auxiliary feature learning[C]. Proceedings of the Asian Conference on Computer Vision. Heidelberg: Springer, 2020: 268-285
- [66] 陈一鸣, 周登文. 基于自适应级联的注意力网络的超分辨率重建[J]. 自动化学报, 2020, 46(x): 1-11
- [67] Li Z, Yang J, Liu Z, et al. Feedback network for image super-resolution[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2019: 3867-3876
- [68] 周登文, 李文斌, 李金新, 等. 一种轻量级的多尺度通道注意图像超分辨率重建网络[J]. 电子学报, 2022, 50(10): 2336-2346

- [69] 周登文, 赵丽娟, 段然, 等. 基于递归残差网络的图像超分辨率重建[J]. 自动化学报, 2019, 45(06): 1157-1165. DOI: 10.16383/j.aas.c180334
- [70] 张雷, 胡博文, 张宁, 等. 图像超分辨率全局残差递归网络[J]. 计算机科学, 2019, 46(B06): 4
- [71] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Communications of the ACM, 2017, 60(6): 84-90
- [72] Zhang X, Zhou X, Lin M, et al. Shufflenet: an extremely efficient convolutional neural network for mobile devices[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 6848-6856
- [73] Tai Y, Yang J, Liu X. Image super-resolution via deep recursive residual network[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 3147-3155
- [74] Zhang K, Zuo W, Zhang L. Learning a single convolutional super-resolution network for multiple degradations[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2018: 3262-3271
- [75] Zhao H, Kong X, He J, et al. Efficient image super-resolution using pixel attention[C]. Springer International Publishing, 2020: 56-72
- [76] Hui Z, Wang X, Gao X. Fast and accurate single image super-resolution via information distillation network[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 723-731