

华北电力大学

专业硕士学位论文

基于通道协作的单图像超分辨率算法

Single image super-resolution algorithm based on
channel cooperation

李艺攀

2022 年 5 月

国内图书分类号：TP39
国际图书分类号：004.9

学校代码：10079
密级：公开

专业硕士学位论文

基于通道协作的单图像超分辨率算法

硕士研究生：李艺攀

导师：周登文教授

企业导师：陈光

申请学位：工程硕士

专业领域：计算机技术

培养方式：全日制

所在学院：控制与计算机工程学院

答辩日期：2022年5月

授予学位单位：华北电力大学

Classified Index: TP39

U.D.C: 004.9

Dissertation for the Professional Master's Degree

Single image super-resolution algorithm based on channel cooperation

Candidate:	Li Yipan
Supervisor:	Prof.Zhou Dengwen
Enterprise mentor:	Chen Guang
Academic Degree Applied for:	Master of Engineering
Speciality:	Computer Technology
Cultivation ways:	Full-time
School:	School of Control and Computer Engineering
Date of Defence:	May, 2022
Degree-Conferring-Institution:	North China Electric Power University

摘 要

深度学习技术已显著改进了单图像超分辨率方法(SISR: Single Image Super-Resolution) 的性能,并主导了 SISR 方法的研究。但是,大多数方法并未充分利用特征通道之间的相关性。为了解决这个问题,本文提出了一个基于特征通道协作的 SISR 方法,以改进现有的 SISR 方法。我们构造了两个通用的特征通道协作模块:特征通道协作注意力模块和特征通道协作上采样模块,两个模块是独立的,可以集成到其它现存的 SISR 模型中。在当前两个代表性的 SISR 方法上的实验结果表明:我们的特征通道协作模块能够显著改进其它 SISR 方法的性能。具体来说,本文有以下创新点:

(1) 本文提出了特征通道协作注意力模块,融合各个通道特征,以变换出更有表达力的特征。该过程先将特征编码到特定的特征空间,随后通过任意两个通道向量间的余弦相似度来衡量其相关性,然后依据通道相关系数对每个通道互补增强,进而实现不同通道间信息的交互和互补,最后将特征再解码回原始特征空间。这一过程充分利用了同一深度不同通道间的相关性,使得不同通道捕获的特征能够进行协作传播。

(2) 本文提出了特征通道协作上采样模块,是一种能同时融合不同尺度间高频信息的多尺度上采样模块。该模块包含 16 个宽激活模块,可以融合不同尺度的信息。为了进一步提升不同模块间的协作能力,将特征通道协作注意力模块应用在该上采样模块中,以充分利用这 16 个模块所提取特征的相关性,使得上采样模块中不同深度不同尺度的特征能够进行交互和互补,改进多尺度上采样效果。

(3) 本文提出的特征通道协作模块是独立的,可以集成到其它主流的 SISR 模型,并显著提升其性能。

关键词: 图像超分辨率; 卷积神经网络; 通道协作; 注意力机制; 多尺度上采样

Abstract

Deep learning technology has significantly improved the performance of Single Image Super-Resolution methods and has dominated the research of SISR methods. However, most methods do not make full use of the correlation between feature channels. In order to solve this problem, this paper proposes a SISR method based on feature channel cooperation (CC) to improve the existing SISR methods. We construct two general feature channel cooperation modules: feature channel cooperation attention module (CCAM) and feature channel cooperation upsampling module (CCUM). The two modules are independent and can be integrated into other existing SISR models. The experimental results on two representative SISR methods show that our CC modules can significantly improve the performance of other SISR methods. Specifically, the innovations of this paper are as follows:

(1) This paper proposes a feature channel cooperation attention module (CCAM), which integrates the features of each channel to transform more expressive features. First, the feature is encoded into a specific feature space, its correlation is measured by the cosine similarity between any two channel vectors. Then the complementary activation of each channel is calculated by using the channel correlation coefficient, so as to realize the interaction and complementarity of information between different channels. Finally, the feature is decoded back to the original feature space. This process makes full use of the correlation between different channels at the same depth, so that the features captured by different channels can be propagated cooperatively.

(2) This paper proposes a feature channel cooperation upsampling module (CCUM), which is a multi-scale upsampling module that can fuse high-frequency information between different scales at the same time. The module contains 16 wide activation modules, which can fuse information of different scales. In order to further improve the cooperation ability between different modules, the CCAM is then applied to take advantage of the correlation of the features of these 16 modules, so that the features of different depths and scales in the upsampling module can interact and complement each other, so as to improve the effect of multi-scale upsampling.

(3) The feature channel cooperation module proposed in this paper is independent, which can be integrated into other mainstream SISR models and significantly improve its performance.

Keywords: Image Super-Resolution , convolutional neural network , Channel Collaboration, Attention mechanism, Multi-scale upsampling

目 录

摘要	I
Abstract	II
第 1 章 绪论	1
1.1 课题背景及研究意义	1
1.2 国内外研究现状	2
1.2.1 基于插值的方法	2
1.2.2 基于重建的方法	3
1.2.3 基于学习的方法	4
1.3 主要研究内容	7
1.4 本文章节安排	8
第 2 章 图像超分辨率算法概述	9
2.1 图像的退化模型	9
2.2 卷积神经网络基本组成	10
2.3 损失函数	14
2.4 注意力机制	14
2.4.1 通道注意力	15
2.4.2 空间注意力	15
2.4.3 非局部注意力	16
2.5 卷积神经网络模型	17
2.5.1 单尺度模型	17
2.5.2 多尺度模型	19
2.6 本章小结	21
第 3 章 基于通道协作的单图像超分辨率算法	23
3.1 引言	23
3.2 算法总体框架	24
3.2.1 网络结构	25
3.2.2 特征通道协作注意力模块 (CCAM)	25
3.2.3 特征通道协作上采样模块 (CCUM)	28
3.2.4 宽激活块 (WAB)	29

3.2.5 自适应尺度块 (ASB)	29
3.3 本章小结	29
第 4 章 实验与分析	31
4.1 引言	31
4.2 数据集	31
4.3 实验参数设置	31
4.4 图像质量评价	32
4.4.1 峰值信噪比	32
4.4.2 结构相似性	32
4.4.3 平均意见得分	33
4.5 实验细节	34
4.5.1 消融实验	34
4.5.2 特征通道协作注意力模块分析	35
4.5.3 特征通道协作上采样模块分析	36
4.6 实验结果	37
4.6.1 客观结果	37
4.6.2 主观结果	37
4.7 本章小结	40
第 5 章 结论与展望	42
5.1 论文工作总结	42
5.2 未来工作展望	42
参考文献	44
致 谢	50

第1章 绪论

1.1 课题背景及研究意义

近年来,数据成为当今科技发展的核心资源,带动了互联网产业井喷式发展,随之而来的人工智能更是将数据处理推到了高峰,同时也推动人类进入全新的信息化时代。在信息化时代获取信息变得更加方便快捷,同时对信息的质量也有了更高的要求,这就促进了信息处理技术不断地发展和完善。图像作为储存信息的载体,在各个领域都发挥着极其重要的作用。日常生活中,许多设备都需要图像作为载体进行传播,如智能电视、移动手机、电脑、数码相机、视频监控等设备,图像的质量就显得尤为重要,这就带动了图像处理技术慢慢走向成熟。

图像超分辨率技术是根据给定的低分辨率图像恢复出相对应的高分辨率图像^[1],越来越多的研究者开始关注此方向。生活中往往因为拍摄角度、拍摄距离、摄像设备、光线、照片的传送过程等导致照片质量不理想。为了解决这一问题,一方面可以改进硬件设施,提高硬件的配置,但这会导致成本过高,硬件的发展也到了一定的瓶颈期,并且有些应用场景改进硬件非常困难,比如一些医疗器械,所以一般不选择从硬件角度解决图像分辨率低这一问题;另一方面就是从软件考虑,利用已有的低分辨率图像,对图像丢失的信息进行补充,丰富其纹理、细节特征,重建出高分辨率图像。为此,人们提出了超分辨率重构的概念,超分辨率重构的目的在于从算法的角度思考如何恢复图像丢失的信息,经过人们不断摸索,超分辨率重建技术发展越来越成熟,在遥感图像^[2]、视频监控^[3]和医学成像^[4]等许多领域被广泛应用。

(1) 遥感图像。航空遥感和卫星遥感图像在很多领域都有着非常重要的作用,通过对这些图像的分析 and 理解,能应用在地质勘察、军事部署等方面。不过,有时因为距离太远,加之受到下雨、雾霾等恶劣天气影响而造成光线不好,使得拍摄的图像分辨率较低,并且拍摄完成的照片还需要向地面进行远距离的传送,在传送的过程中也会进一步降低图像的分辨率。分辨率低的图像严重影响军事判断,若能准确提高此类图像的分辨率将会有非常高的应用价值。

(2) 视频监控。当前,视频监控成为安全防范的有效技术,广泛应用在交通、家庭、办公、商城、电力等各种场合。拥有视频监控后,不需要大量的管理人员亲临现场,仅仅需要少部分的人员在监控室监管即可实现安全防范的作用,提高了管理效率。而智能监控进一步引入目标检测等技术,可以对监控画面中的人、车辆、物体的行为进行识别,进而促进了智能驾驶的发展。在现实中,会遇

到各种不确定的因素，如天气等原因造成摄像机采集的画面模糊，甚至扭曲，影响观察和判断，所以迫切需要分辨率更高的图像。

(3) 医学成像。医学成像是通过现代的一些医疗设备（如超声等仪器），利用计算机来形成一种真实图像，可以对人体的形态、组织器官等方面进行全面细致地观察，对于疾病的诊断和治疗有着非常重要的作用。当然，由于医院有些设备性能低，很多关键的细节信息无法获取，影响医生对疾病的判断，所以利用超分辨率重建技术将影像细节恢复出来，使图像变得更加清晰，对于疾病的诊断是很有帮助的。

(4) 多媒体视频图像。人们生活在一个信息化的时代，对于数字、影音的使用需求也不断增多，所以视频图像的质量是很重要的。对于画面的细腻程度、清晰程度等，都是人们追求的最直接的感官标准。一些经典的影视作品，由于拍摄的时间比较久远，受当时拍摄设备的限制，画质模糊，给用户带来不好的观感。而超分辨率技术可以将这种类型的视频恢复成高分辨率画面，经过超分辨率处理后的影视作品可以再次走入人们的视线，重温经典。在数字电视转成高清电视的关键时期，超分辨率重建技术发挥着非常重要的作用，由于储存视频需要大量的内存空间，特别是高清视频，这时可以只存储低分辨率视频图像，节省内存，当需要观看较为高清的视频时，对其进行超分辨率重建即可。

上述得出，图像可以储存大量对人类有帮助的信息，提升图像的信息量以及准确性在各个行业都有研究意义，其中最直接的技术就是图像超分辨率重建，它的实现有很多种方法，目前最受欢迎的就是基于深度学习^[5]的方法，在各个方面都明显优于传统方法，占据了统领地位。对于以往的图像处理方法而言，基于深度学习的方法重建出的图像质量显著提升，且实现过程简单，人为干预较少。因此，基于深度学习的单图像超分辨率算法是一个值得深入研究和探讨的话题。

1.2 国内外研究现状

图像超分辨率的最终结果是得到对应的高分辨率图像，这是为了满足现实的需要，高分辨率包含的信息量是低分辨率中不具备的。为了提高图像质量，很多领域都需要用到超分辨率技术。现阶段我们将图像超分辨率方法划分为：基于插值的超分辨率方法、基于重建的超分辨率方法和基于学习的超分辨率方法。在这三种方法中，我们重点探讨基于学习的超分辨率方法。

1.2.1 基于插值的方法

基于插值的方法其计算过程就是补充像素，在什么位置补充、怎么补充是需

要考虑的问题。补充空缺像素值的方式有很多，但都是考虑未知点附近或多或少的像素点，因不同的位置对此点的影响效果不一样，所以有些插值方法会考虑分配不同的权重。根据他们在计算过程中用到的像素点和数学公式的不同，将插值方法分为：最近邻插值、双线性插值和双三次插值等。最近邻插值实现过程比较简单，即基于最接近于该点位置的像素值来决定待求解的像素值，该插值算法的运算速度最快，但效果比较差；双线性插值法将未知像素点的邻接区域由 2 个点扩大到 4 个点，由 4 个像素的加权平均值求出，所谓的双线性插值是因为在横向和纵向都进行插值，通过此插值法得到的重构结果比最近邻插值更加光滑、自然；双三次插值法效果更佳，采样点和插值次数都增多了，采样点由 4 个增加到附近的 16 个，次数也变成了 3 次，并且会根据数值变化率进行加权，同时根据与待求像素点的距离来赋予每个点权重值。双三次插值在计算未知像素点的值时由于参考了更多附近的像素值，所以双三次插值的重建图像相较于前两种插值效果更好，而且可以很好地缓解重建图像有锯齿状的问题。Keys^[6]提出的双三次插值最为经典，应用在各种超分辨率场景中。

由于传统的插值方法没有考虑图像的边缘特性，因此，在插值过程中，图像边缘区域的效果并不理想，会丢掉很多关键信息，导致最后产生的图像质量不能令人满意。随后 Li 等^[7]人提出的基于边缘指导的插值方法，虽然考虑了边缘特性，但计算量太大，也不能放大任意倍数；Battiato 等^[8]人根据低分辨率图像在一个区域内的边缘方向信息来确定插值公式。这些方法虽然关注了图像的边缘信息，但是最终还是不能将图像的细节信息恢复出来，图像仍然会出现锯齿状。

总体来说，基于插值方法最大的优点是操作简单、便于实现、速度快，所以在一些工业场合会选择该方法重建图像。同时，在一些情况下，还可以使用双三次插值对原图像进行降采样处理。但是在插值的过程中仅仅依赖局部信息计算，并没有从全局的角度考虑，所以导致插值放大后的图像质量过于平滑，看起来既模糊又不真实。

1.2.2 基于重建的方法

超分辨率中基于重建的方法提出时间是较早的，发表于 2013 年的文献^[9]罗列了多种重建方法，并做了针对性介绍。较为经典的方法有：迭代反投影、贝叶斯分析法等。Tsai 等^[10]人以傅里叶变换为中间媒介，把一幅图像划分成不同的时序，一般情况下，会将低分辨率图像转换为频率域，随后进行重建和恢复。Irani^[11]提出了迭代反投影，其基本思想是，在重构图像时，首先采用插值算法来进行放大，从而获得原始图像，随后将经过放大的图像投影到低分辨率图像上，最后计算反投影后的图像与真实图像之间的差，将这个差值作为损失函数约束此

过程进行循环迭代。Schultz 等^[12]人根据图像是否有噪声，提出了对这两种图像的最大后验概率估计方法，此方法是一种非线性图像扩展法，该方法可以优化凸函数，进一步提升图像重建效果，经过实验发现，该方法生成的图像有较高的清晰度。

基于重建的方法采用不同的先验信息进行约束，在一定程度上可以抑制失真，不过其令人诟病的点在于需要大量约束条件，所以对约束条件的合理性要求较高，并且超分的倍数不能过高，倍数高的话会使恢复效果差强人意，只能进行小倍数的放大。同时，由于在重建过程中一般需要不断迭代来达到最优效果，所以需要的时间较长，大多数情况下，此方法较为耗费资源，需要多幅图像来完成重建，而在实际应用时，不容易获取同一场景下的多幅图像。这些都是基于重建的超分辨率方法存在的弊端。

1.2.3 基于学习的方法

出现最晚的技术往往更符合人们的意愿，基于学习的方法也不例外，现实中人们最关心和追求的是速度和质量，此方法在一定程度上满足了人类的需求。理论上图像超分辨是通过一种输入得到相应的输出，在这里输入代表低分辨率图像，输出代表高分辨率图像，该过程类似数学中的函数，与简单数学函数不同的是输入和输出之间的联系并不是确定的，可能存在多对一的关系，例如，经过不同高分辨率图像下采样后，会生成类似的低分辨率图像，这正是我们研究的重点。常见的基于学习的图像重建方法有：基于字典的方法^[13]、基于 k-近邻的方法^[14]和基于深度学习的方法^[5]。

近年来，研究者们越来越重视深度学习网络的研究，当前的研究工作中，基于深度学习的单图像超分辨率方法越来越受关注。其中，卷积神经网络技术在图像重建中显示出良好的性能，是目前的主流方法。基于深度学习的方法在训练时依赖所需要的数据集，同时一些超参数的设置、评价指标的选取也会直接影响到模型性能。Dong 等^[15]人提出了 SRCNN，引领了卷积神经网络在 SISR 这个领域的发展，该方法首先将上采样后的图像作为网络的输入，其次仅使用三个卷积层搭建网络，该方法是具有重要意义的，为后续工作的展开做了铺垫。与 SRCNN 不同的是，FSRCNN^[16]的开创性思维在于图像输入网络前不再使用插值进行放大，而将放大的步骤放在网络尾部进行，此时非线性映射在图像尺寸较小的情况下完成，降低了计算量，加快了训练速度。ESPCN^[17]通过对网络输出附近的特征进行上采样来降低大量的计算和运行时间开销，该论文实现上采样的方式是采用亚像素卷积，该方式提高了重建效率，后续很多工作都采用亚像素卷积实现上采样。

随着网路深度的加深,人们发现如果仅使用单一的线性网路很容易导致梯度消失,而残差学习可以很好地缓解这一问题。He 等^[18]人将残差学习用到网络,提出了 ResNet,实现非常简单,将前后两个不同位置的特征通道进行逐像素相加即可,引入残差后缓解了网络深度加深性能反而降低这一现象。根据使用残差位置的不同,可以分为全局残差和局部残差。输入低分辨率图像和高分辨率图像存在着很强的相关性,将二者用残差的方式连接起来,称为全局残差,全局残差可以帮助恢复网络丢失的高频信息,广泛应用在超分辨率工作中^{[19][20][21]}。例如 Kim 等^[19]人在 2016 年提出的 VDSR,强调网络的深度,该方法引入了全局残差,为网络深度的加深提供了有力支持,该网络的深度进一步提升至 20 层,从而大大改善了图像重构的效果。局部残差是指在某个特征提取块内使用的残差,例如超分辨率论文^{[22][23][24]}均使用到了局部残差。当然实际应用中许多网络将局部残差与全局残差一同利用。

递归学习即在网络训练过程中,将同一个模块多次使用。DRCN^[25] 引入了递归神经网络来进行超分辨率重建工作,将一个卷积层作为迭代单元,在不增加太多参数量的情况下改善模型的性能。Tai 等^[26]人提出了长期记忆网络 MemNet,所谓长期记忆,是因为网络的每个特征提取块都参与了最后的输出,值得注意的是这些块在最后进行逐像素相加时,网络尾部的门控单元会自适应调整每个块所占的权重。级联残差网络 CARN^[27] 将几个残差块作为一个迭代单元,并且对残差块进行了局部和全局的特征融合,取得了非常不错的超分效果,更进一步,迭代模块可以应用到网络的不同部分。Han 等^[28]人提出了 DSRN,它是一种在低分辨率和高分辨率模式下交换所抽取信息的双重状态递归网络,在每次递归中,每个分支并不是固定不变的,而是会不断更新和交换,这样有利于分析 LR 和 HR 之间的关系。Lim 等^[29]人提出了 EDSR 网络,该算法做出的修改主要在残差网络上,删除了残差网络上一些多余的模块(归一化层),使其更适用于超分辨率任务,实验结果证明该做法是有效的。一般来说,递归学习的确可以获得更多的特征信息,而无需引入太多的参数,从而提高了模型的表达能力。不足之处是计算成本变大,同时也可能在网络梯度回传时产生问题,如梯度爆炸,所以在递归网络中同样可以引入残差学习来缓解这些问题。

密集连接每层的输出特征图都是后边所有层的输入,将不同层次的特征信息融合,为重建图像提供更丰富的细节信息。密集连接能在一定程度上缓解梯度消失,有助于特征信息更好的传递,同时以更少的参数量实现了更高的性能。自从 Huang 等^[30]人提出 DenseNet 以来,密集连接的使用变得越来越广泛。密集连接不仅可以在一个块中的不同卷积层之间使用,也可以应用在不同的特征提取块之间。如 Tong^[31] 等人构建了网络较深的 SRDenseNet,不仅设计了密集连接块,

还将密集连接块中的每一层特征都输入给之后的每一层，与残差网路不同的是，在网路的最后将所有层级联在一起，而不是使用逐像素相加，该网络降低了参数量，缓解了梯度消失的问题。MemNet^[32]、CARN^[27]、RDN^[33] 和 ESRGAN^[34] 同样采用了层级和块级密集连接。

多路径学习是指通过不同的分支进行不同的操作，并将其融合在一起，提取不同层次的特征，增加模型的表达能力。首先 GoogleNet^[35] 提出了 Inception 结构，将不同尺寸的卷积核并列来提取特征，极大地提高了图像分类准确率。LapSRN^[36] 包括一条预测子带残差的特征提取路径和一条重建高分辨率图像的路径，该方法采用逐步上采样的方式进行重建，可以实现一次训练同时生成多个放大因子图像。MSRN^[37] 设计了多尺度残差块，由两条分支组成，一条分支包含两个 3×3 卷积，另一条分支由两个 5×5 卷积组成，这两条分支同时提取特征信息，最后将两个分支融合。Lim^[29] 提出了特定尺度的多路径学习，以实现网络一次训练生成多个倍数的图像，网络是通过共享主要的网络模块，如共享中间的特征提取，并分别在网络的头部和尾部加上用于特定比例的预处理模块和上采样，该方式与单尺度模型相比，节省了训练时间。

GAN 网络自从提出以来就面临着训练困难的问题，生成器和判别器的损失不能很好地约束训练过程，例如有时判别器非常强大，导致损失函数一直都是 0，不能引导生成器更新，从而导致训练结果不好。随后很多论文尝试解决这些问题，例如 DCGAN^[38] 利用卷积神经网络搭建生成器和判别器，而非原有 GAN 网络中的多层次感知机，为了能够获得一组相对较好的网络结构设置，采用的方法是对生成器和判别器同时进行枚举实验，但是这种方式并没有从真正意义上解决问题。WGAN^[39] 在网络结构设置时做出了改进：判别器通过去除最后一层的 sigmoid 激活函数、损失函数不取对数、判别器的参数每次更新截断到一定的范围和不使用动量优化算法等改动，很好地解决了以上问题。Ledig 等^[40]人提出了 SRGAN，是基于生成对抗网路的超分辨率重建方法，改进了损失函数，提出了由内容损失和对抗损失组成的感知损失函数，可以帮助网络捕获图像的纹理细节信息，使得生成的图像更真实。生成对抗网络功能很强大，不仅可以重建图像，还可以实现风格迁移。CycleGAN^[41] 采用两个判别器和生成器，可以在一种风格下的模式图中进行学习，从而生成另一种风格的模式图，这个过程两个场景下的物体是相同的，只是风格发生变化。值得注意的是，风格迁移的同时，也可以让物体发生变化。

在研究者的不断努力下，新方法新技术不断地被提出，同时在不同领域之间也存在着交互，图像超分辨率在深度学习领域的研究逐渐深入，每一种新方法的提出都是一种启发，研究者不断冲击更好的重建效果。深度学习已成为研究主流，

也是本文的主要研究内容。

1.3 主要研究内容

在深度学习的大势下,学者为了追求性能,不断增加网络的深度,但是往往伴随着参数量的剧增,在实际应用中显然不可取,并且网络在增加到一定深度后性能波动范围不大,由此转而去关注如何在特征提取的过程中有效提取更多的特征信息,从而提升网络性能。考虑到不同通道特征之间的联系,引入了残差网络、注意力机制等,建立通道间的联系,然而并不能充分利用通道之间的相关性。为了解决这个问题,本文提出了一个基于特征通道协作 (CC: Channel Collaboration) 的单图像超分辨率方法,根据特征通道之间的相似性,特征通道的每个像素位置都融合了各个特征通道对应的像素。实验结果表明,我们的方法可以更充分地利用特征通道之间的相关性,帮助网络更好的学习特征信息。具体来说,本文的创新点有 3 个:

(1) 本文提出了特征通道协作注意力模块 (CCAM: Channel Collaboration Attention Module), 使得不同通道捕获的特征能够进行协作学习。该过程包含 3 个阶段,分别是特征嵌入、特征交融和特征嵌出,特征嵌入阶段捕获全局特征信息,同时将特征编码到特定的特征空间中,方便后续阶段的计算;在特征交融阶段,我们通过任意两个通道间的余弦距离来衡量其相似性,充分实现不同通道间信息的交互和互补;在最后的特征嵌出阶段恢复原来的尺寸并将计算得到的特征再解码回原始特征空间。这一过程使得不同通道捕获的特征能够进行协作传播。

(2) 本文提出了特征通道协作上采样模块 (CCUM: Channel Collaboration Upsampling Module)。该模块是一个多尺度上采样模块,相较于其它多尺度上采样模块^{[42][43]}, CCUM 不增加参数量,但能显著改进多尺度上采样性能。主要过程是:首先经过 16 个宽激活块 (WAB: Wide Activation Block)^[44] 捕获更丰富的特征信息,然后应用特征协作注意力模块 (CCAM) 进行特征通道交互,再通过自适应尺度块 (ASB: Adaptive Scale Block), 根据上采样的倍数选择进入一个相应的分支,获得不同上采样因子的 SR 图像。使得上采样模块中不同深度不同尺度的特征能够进行交互以及互补,进而提升超分辨率性能。

(3) 实验表明,本文方法能有效提升目前主流的多尺度超分辨率方法的性能 (客观和主观性能)。此外实验还表明,我们的通道协作注意力模块能提升单尺度超分辨率性能。

1.4 本文章节安排

本文主要研究基于通道协作的单图像超分辨率算法，一共包含 5 个章节内容，其组织结构如下：

第一章，绪论。首先介绍了选择图像超分辨率这一课题的背景以及应用场景。其次分析了国内外对图像超分辨率的研究现状，主要分为 3 类：基于插值的方法、基于重建的方法和基于学习的方法，在众多基于学习的方法中，基于深度学习^[5]的单图像超分辨率算法是当前的研究热点，我们重点关注基于卷积神经网络的方法。接着从深度学习网络的架构角度出发，探索基于深度学习的超分辨率网络的发展历程，介绍了残差学习、递归学习、多路径、密集连接和生成对抗网络。最后，对论文的主要内容和章节进行了总结。

第二章，图像超分辨率算法概述。本章节主要介绍与图像超分辨算法相关的知识。首先介绍了基于深度学习卷积神经网络的一些基本层结构：卷积层、池化层、全连接层、激活层；其次介绍了图像质量的评价标准和网络常用到的损失函数；最后介绍了与本文工作相关的基础知识：注意力机制和卷积神经网络的模型，其中注意力机制包括通道注意力、空间注意力和非局部注意力，卷积神经网络分别列举了几篇经典的单尺度模型和多尺度模型，本文工作是关于多尺度模型，即一次训练可以同时输出多个放大倍数的模型。

第三章，基于通道协作的单图像超分辨率算法。本章节首先在引言部分介绍了当前方法存在的问题，针对这些问题找到了解决方法，提出了基于通道协作的单图像超分辨率算法；接着介绍了各个模块的实现过程。

第四章，实验与分析。本章主要介绍了实验所用到数据集以及一些超参数的设置，为了证明模块设计的有效性以及超参数设计的合理性，设计了一些消融实验和对比实验。最后与其他先进论文做比较，从客观指标(PSNR 和 SSIM 指标)和主观视觉效果图说明了本文方法的有效性。

第五章，总结与展望。在最后一章节对全文进行了总结，还对一些可能进一步完善的地方做了阐述。

第 2 章 图像超分辨率算法概述

2.1 图像的退化模型

图像分辨率是指在一张图像中所储存的信息量，图像分辨率越高，图像的信息更丰富，图像的质量往往就会越好。在计算机视觉领域中，我们所说的分辨率是用像素的个数来表示的。日常生活中，由于摄影器材和存储条件的限制，图像质量有所降低。在本文中，主要讨论利用深度学习的方法进行图像超分辨率重建，提高图像的质量，该方法利用学习的方式得到高分辨率和低分辨率图像的非线性关系，从而引导低分辨率图像向高分辨率图像重构。

图像超分辨率的前提是有低分辨率图像的产生，对于监督学习，还需有对应的标签，即高分辨率图像，这就需要将高分辨率图像做退化操作。与超分辨率重建不同，图像退化的目的是得到分辨率低的图像，来与其分辨率高的图像做对应，组成图像对儿用来训练。实际的退化过程可能受到多种因素的影响，例如在摄影期间摄像机的抖动、拍摄物体的运动等导致图像的信息不完整，从而造成图像模糊，或由于在图像传送期间受到外部干扰，引入噪音等。总的来说，影响退化过程的因素可能有：几何形变、压缩模糊、下采样、噪音等，退化过程如图 2-1 所示，该过程表示分辨率高的图像 (HR) 经过退化系统、噪声的一系列操作后，图像的质量受到损害，从而退化成分辨率低的图像 (LR)。




图 2-1 图像的退化模型

我们可以将上述退化操作用如下公式表示：

$$y = \phi(x, \theta_{\eta}) \tag{2-1}$$

其中 $\phi(\cdot)$ 代表退化函数， θ_{η} 代表退化系数。现实中图像的退化是不为人知的，事实上并不存在一张高分辨率图像与之对应，所以无法确定退化的干扰因素。为了方便表示，退化操作可为：

$$y = H(x) + n = (x \otimes k) \downarrow_s + n \tag{2-2}$$

将该退化过程分解成了两个部分,一个是 $H(\cdot)$ 表示退化函数,而 n 表示噪声。其中退化函数用高分辨率图像 x 与模糊核 k 进行卷积操作即可实现, $\downarrow_s$ 表示下采样的系数表示为 s 。对于噪声,可以选择高斯白噪声。

图像的退化过程并不唯一,一般选择上述公式进行退化,考虑到公式与实际退化过程的相似程度,双三次下采样是较为符合期望的选择,用这个操作模拟退化,得到退化后的图像。有了退化图像和退化理论基础,就可以学习重建的过程,重建操作简单理解是学习输入与输出之间的映射关系,如同数学公式中的函数,不过这里的参数是随着学习而变化的,至于数据就是我们之前提到的高、低分辨率图像,模型随着训练过程不断优化,最终得到具有较好超分性能模型来对低分辨率图像超分。

2.2 卷积神经网络基本组成

卷积神经网络的基本原理就是卷积操作,运算单元就是我们常说的神经元,由权重和偏差组成,可以根据我们输入的数据不断更新,得到更利于模型性能的数据,后面常跟着激活函数,有些计算机视觉任务最后一层是全连接层。不同层的功能是不同的,下面分析各个处理层。

(1) 卷积层。卷积层是神经网络可以实现某一功能最主要的结构,也是核心操作,其参数由滤波器构成,可以通过学习不断更新,而卷积操作是数学上的一种运算。卷积神经网络中的滤波器相对于输入特征来说相对较小,由 3 个维度组成,即宽度、高度以及深度,输入特征也由这 3 个维度构成。例如滤波器的大小可以是 $7 \times 7 \times 3$,第一个 7 表示宽度,第二个 7 代表高度,深度为 3,深度与输入数据的深度相同。正向传播过程中,由于深度相同,故而滤波器相当于在两个维度滑动,也就是输入图像的宽和高。进行卷积运算时,滑动的过程中可以选择不同的步长以及输入特征四周不同大小的填充。每个滤波器在卷积结束后会产生一个二维的特征图,不同的滤波器提取到不同的图像特征。直观来看,网络会让滤波器提取到一些特征信息的时候就被激活,这些特征信息可能是一张图像的边界部分,或者一个物体的形状等。卷积的独特之处是权重共享,较少的参数量就可以达到非常好的效果,降低了计算量与参数成本,可以有效抑制过拟合,更加符合现实需要。

卷积操作是神经网络的基本操作,为了降低计算量或者使网络发挥不同的功能,人们试图改进卷积操作,于是出现了关于卷积的改进,常见的有空洞卷积、分组卷积和深度可分离卷积。

a) 空洞卷积,空洞卷积可以理解为在标准卷积的过程中加入了空洞,二者实

现过程基本相同,标准卷积可以看成空洞卷积的一种情况。Zhang 等^[45]人在网络模型中用空洞卷积替代普通的卷积,扩大感受野是空洞卷积最基本的特点,并且不会引入附加参数,不仅如此,空洞卷积另一个优势在于它捕获信息的能力,可以获得多尺度的上下文信息,得到长距离的信息依赖关系。当然空洞卷积存在一些潜在的问题:其一是网格效应,当多次叠加使用时,会发现并不是所有的像素都用来计算了,所以会损失信息的连续性,在某些超分辨率任务中,该问题会导致一些信息丢失,影响是致命的;其二是空洞卷积在一些特征图较小的情况下,它的作用就有弊无利了,所以空洞率的设计非常重要,在网络中设计一个良好的空洞卷积就可以有效避免上述两个问题。

b) 分组卷积,分组卷积是把输入特性图中的通道数划分为若干组,对每一组进行卷积运算,然后把各组的输出级联起来,形成本层的特征图,这样的方式可以减少参数量。Hui 等^[21]人提出了信息蒸馏网络 IDN,将分组卷积合理应用到网络中,降低模型复杂性和内存消耗。虽然分组卷积可以减少参数量,但是有时会伴随一定的性能损伤。

c) 深度可分离卷积,深度可分离卷积与分组卷积有密切联系,只不过它的分组个数是特征通道数,即将每个特征通道分为一组,对每组分别做组内卷积,这种卷积形式非常高效。自从 Howard 等^[46]人提出深度可分离卷积以来,在很多方向的工作得到应用。主要包括两个过程:逐通道卷积和逐点卷积,逐通道卷积是对每个通道分别进行卷积,所以该步骤产生的通道数与输入的通道数一致;接着进行逐点卷积,考虑到不同通道上同一位置的相关性,使用 1×1 的卷积核在深度方向进行标准的卷积操作。这种卷积方法在计算过程中的参数量和计算量相对较少。最近, Nie 等^[47]人在智能手机端部署模型以实现超分辨率,所以对于内存占用、速度方面的要求较高,而利用深度可分离卷积可以满足这一要求。

(2) 池化层。池化层穿插在卷积层中间使用,经过池化使特征图的尺寸逐步降低。这样一方面可以降低网络参数量,丢掉一些不重要的信息,将有用的信息保留下来,同时也可以起到防止模型过拟合的效果。池化可以看成是卷积的一种变体,也是采用和卷积同样的窗口滑动方式。池化的方式有很多种,均值池化和最大值池化是应用最广泛的。最大值池化,假设特征通道数为 1,池化层使用 3×3 的卷积核大小,步长设为 3,与输入数据对应位置做运算,该操作会从 9 个数字中取最大值,而数据的深度维度则维持不变(均值池化与最大值池化类似,只不过是将对对应位置的权重进行取均值的操作)。

当然,在使用最大值池化时,由于函数不是连续的,所以不可导,其反向传播可以被简单地理解为沿着最大数的梯度回送,因此在传递到池化层的同时,要记录最大值元素的索引。池化层在网络中并不是必须使用的,目前一些卷积神经

网络只是偶尔使用池化层。

(3) 激活层。在神经网络中，假设不使用激活函数，只堆叠卷积层，这样的网络是没有办法处理非线性问题的，所以激活函数是必不可少的存在。总之，激活函数将非线性特征引入到神经网络中，从而使得神经网络能够学习和处理更加复杂的非线性问题。激活函数的种类有很多：如 Sigmoid、tanh、ReLU、PReLU 等。各个激活函数介绍如下：

a) Sigmoid, Sigmoid 函数图像如图 2-2 (a) 所示，其公式如下：

$$\text{sigmoid}(x) = \frac{1}{1 + e^{-x}} \quad (2-3)$$

由于计算包含幂运算和除法运算，所以该激活函数的计算量较大，增加训练时间；Sigmoid 函数其导数的取值范围是 (0, 0.25)，当网络较深时，那么梯度在经过很多网络层后将变得越来越小，接近于 0，即在反向传播的过程中容易出现梯度消失的现象；同时 Sigmoid 函数值均是正数，这就使得经过激活函数后将特征图中的非正数均变成正数，改变数据分布；值得注意的是，该函数不是以 0 为中心，可能导致模型收敛速度较慢。

b) Tanh, Tanh 函数如图 2-2 (b) 所示，类似 Sigmoid 函数图像的平移，又叫双曲正切函数，可以很清晰地看到，该函数的取值范围变成了 (-1, 1)，并且是 0 均值的函数，其公式为：

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2-4)$$

幂运算在 Tanh 函数中也会存在，当 x 绝对值很大时，梯度又会很小，权重更新很慢，梯度消失还是不可避免。不过，其导数的范围变成了 (0, 1) 之间，对于缓解梯度消失有一定帮助。

c) ReLU, 由函数图像 2-2 (c) 可以看出，它的导数并不连续，因为它是分段的，ReLU 称为修正线性单元函数，因其在数学上的重要作用，又简单易分析，被广泛应用在各个场合，是应用较普遍的激活函数之一，公式为：

$$\text{relu}(x) = \max(0, x) \quad (2-5)$$

从图 2-2 (c) 中可以看出：当 ReLU 函数在 $x > 0$ 区间范围下，导数为 1；当 $x < 0$ 时，导数为 0。在这种情况下，神经网络一方面起到屏蔽不重要信息、增加模型鲁棒性的作用，另一方面有效解决了梯度消失的问题。ReLU 函数只需要做比较运算，不再有复杂的幂运算，计算简单，在速度上取得了进步。当然存在一些值得注意的问题，ReLU 的输出并不是以 0 为均值；同时由于函数的负半轴为 0，也会带来负面影响，例如某些神经元不能被激活，从而造成对应的参数

无法更新，所以在参数初始化以及在设置学习率的时候需要特别注意。

d) PReLU，该函数对 ReLU 函数进行改进，在 $x < 0$ 区间范围下，增加了一个可学习的参数 α ，一般情况下它是一个很小的正数，通过这种方法解决了 ReLU 函数梯度为 0 的问题，函数图像如图 2-2 (d) 所示，数学公式如下：

$$prelu(x) = \begin{cases} x & x \geq 0 \\ \alpha x & x < 0 \end{cases} \quad (2-6)$$

PReLU 函数在实际应用时，参数 α 是可以根据不同的需要进行调整的，参数的选择在一定程度上会影响模型的训练，实际应用中该激活函数的表现并不是很稳定。




图 2-2 常用激活函数的图像

(4) 全连接层。全连接层一般出现在网络的最后，在全连接层中将原本是 3 维结构的特征图展开为向量形式，随后通过激活函数，提高了模型的非线性表达能力。卷积的实现过程可以理解为局部连接，不能有效利用图像的全局信息，但是全连接层可以做到，这是因为全连接层的计算模式不同，每个神经元都连接到上一层的全部神经元，并将网络中获取的特征信息进行整合。经过全连接层得到的特征向量，每个特征点都是由输入特征图中的所有特征点加权求和计算得到的。也正是由于全连接层整合所有特征信息，所以会引入大量的参数，还需要更多的内存。而全连接层忽视了空间结构特性，所以在一些任务上并不适应。对于

本文所研究的图像超分辨率问题，没有用到全连接层，一般情况下，在分类、目标识别等任务中会在网络的尾部使用全连接层。

2.3 损失函数

在图像超分辨率任务中，理想的结果是重建的图像与原始高分辨率图像接近，这就需要一定的方法来得到这个差值，损失函数的作用就在于此，大多数损失函数都是让两幅图像间的差异数值化。根据损失函数的值来迭代模型，约束模型不断优化。图像的基本单位是像素，损失计算的是图像之间对应像素点的差值。损失函数的种类有很多，有的模型不只使用一种类型的损失函数，常见的损失函数如 L1 损失和 L2 损失。

L1 损失也称为最小绝对偏差损失，计算的是重建图像和原始分辨率图像逐像素差值的绝对值的总和，像 EDSR^[29]、RDN^[33]、CARN^[27]、MSRN^[37] 等论文均使用该损失函数，计算公式如下：

$$L_1(\hat{y}, y) = \sum_{i=0}^m |y^{(i)} - \hat{y}^{(i)}| \quad (2-12)$$

L2 损失也叫均方误差损失，计算的是重建图像与原始高分辨率图像逐像素差值的平方和。像 SRCNN^[15]、FSRCNN^[16] 等工作均使用了 L2 损失函数。

$$L_2(\hat{y}, y) = \sum_{i=0}^m (y^{(i)} - \hat{y}^{(i)})^2 \quad (2-13)$$

由于 L1 损失是绝对值函数，其不足之处在于无论所预测的数值与实际值是否相近，其梯度均为定值，且导数具有为非连续性，造成在反向传播时求导困难，优点是收敛速度较快；L2 损失函数在收敛速度上有些劣势，但是训练更容易，不会错过极值点。总之，两个损失函数各有利弊，根据网络实际需要选择适合的损失函数。

2.4 注意力机制

近年来，注意力机制因其独特的作用深受学者们的喜欢，在人工智能的各个方向都有涉及，例如自然语言处理和图像处理等。注意力模仿的是人类脑细胞对信号的处理习惯，人类在观察一整张图像时，关注点不可能是全域，因全域范围过大，不可能关注方方面面，这是普通人类脑细胞的局限性，习惯性关注细节信息比较明显的地方，而无用的地方关注度较低，这大大提高了人类视觉信息处理的效率。而深度学习中的注意力机制正是受到了人类脑细胞这一特性的启发，基本思想就是忽视无关信息关注重要信息。目前常用的注意力机制大致可以分为通

道注意力、空间注意力和非局部注意力等^{[48][49][50]}。

2.4.1 通道注意力

在卷积神经网络中，每层都有多个卷积核，而在不同权值下，可以从多个方面学习图像的特征信息，生成不同的特征通道，以便于重建出图像更丰富的信息。通道注意力就是给这些通道分配不同的权重，在通道维度上对特征加以区分来提




图 2-3 RCAN^[51] 网络中的通道注意力模块

取较为重要的信息，Zhang 等^[51]提出了 RCAN，将通道注意力与残差结构相结合，使模型性能有了很好地提升。该注意力与 SE 模块^[52]类似，每个通道用一个权值代表。其计算过程如图 2-3 所示：

该过程是这样的：首先对 $H \times W \times C$ 特征图经过全局的平均池化，产出一组 C 个一维的特征向量，值得注意的是，这里每个通道对应生成一个独立的权重；接着依次经过一维卷积实现通道的压缩和扩张，增加非线性拟合能力；通过激活函数，生成激活后的权重；最后，将该权重乘以原始的特征图，获得了重新分配权重后的新特征。在此过程中，实现了对通道权值再分配。

2.4.2 空间注意力

对一个图像进行特征提取的过程中，每个区域特征信息的重要程度是不一样的，空间注意力就是从空间位置的角度区分特征的重要程度。与通道注意力不同的是，通道注意力是对每个通道赋一个权值，而空间注意力是在所有通道对应位置赋值。CBAM^[53] 论文中将空间注意力和通道注意力混合使用，其中通道注意力的实现过程如图 2-4 所示：




图 2-4 CBAM 网络^[53] 中的空间注意力模块

与通道注意力相似，对给定的一组特征图 $H \times W \times C$ ，模型在通道维度上对其进行池化操作，区别在于，这种方法中的池化过程包括最大值池化和平均值池化，由此可获得两个 $H \times W \times 1$ 的特征图，减少由池化引起的信息损耗。在特征图中，每一个数值都表示了这个空间位置的重要性。在此基础上，通过卷积层和激活函数，求出加权系数，再乘以输入的特征图，从而获得新的特征分布。空间注意力和通道注意力的思想是类似的，但它们的关注点不同，如果二者同时使用，那么就可以同时注意到通道和空间位置信息。

2.4.3 非局部注意力

基于图像滤波领域的非局部均值滤波操作思想提出的一种非局部信息统计的注意机制。非局部均值滤波在计算每个像素位置输出时，考虑到了图中全部位置，经计算得到相关权重矩阵，该矩阵表示其他位置和当前待计算位置的相似度。即在特征提取的过程中考虑了全局信息又关注重点信息。




图 2-5 Non-local 网络^[54]中的非局部模块

Wang 等^[54]人提出非局部神经网络，如图 2-5 所示，该模块首先将输入特征图做线性映射，降低其通道数，变换到三个空间维度，然后将 θ 和 ϕ 进行矩阵相乘，计算各像素对其他像素间的相关性，并将得到的相关权重矩阵经过 softmax 函数做进一步处理，此时权重矩阵中的值在 0 到 1 之间，并将该权重矩阵乘回特征矩阵 g ，最后与原特征图做残差运算，得到非局部块的输出。该注意力由于生成的权重矩阵大小为 $THW \times THW$ ，相应的计算量和显存占用均较大。

由于以往方法中没有考虑图像中信息的不均匀分布，在特征提取的过程中受到局部卷积运算以及同等处理通道特征信息的影响。为了解决这个问题，Zhang

等^[55] 人设计了一种基于局部和非局部的注意力模块，用于提取特征，并捕获像素间的远距离依赖。在每个局部注意块设计了主干分支和局部掩码分支，相应的，非局部注意块设计了主干分支和非局部掩码分支。局部和非局部分支的目的是对混合注意的特征信息赋予不同的权重，这种注意力机制帮助网络学习局部和非局部信息。

2.5 卷积神经网络模型

2.5.1 单尺度模型

基于深度学习的单图像超分辨率算法相较于最近邻插值、双线性插值等方法重建图像的效果大大提升。SRCNN^[15] 开创了先河，在超分辨率领域使用深度学习算法。FSRCNN^[16] 在 SRCNN 的基础上进一步改进，在网络最后使用反卷积放大尺寸，而不是一开始放大，通过减小卷积核尺寸和增加映射层数，FSRCNN 不仅效果有所提升，训练速度也变得更快。ESPCN^[17] 改变上采样的方式，核心概念是亚像素卷积层，根据放大倍数的不同，将通道数进行不同的变换，并重新排列像素就能获得高分辨率图像，在之后的工作中得到广泛应用。上述提到的模型均为浅层网络（少于 5 层），当网络加深会使训练变得困难，Kim 等^[42]人利用残差网络缓解训练难题，增加 20 个卷积层。这些在图像超分辨率的发展中都有着非常重要的意义。下面介绍上述提到的各个经典论文。

2.5.1.1 SRCNN

SRCNN^[15] 引领了卷积神经网络在 SISR 这个领域的发展，仅使用了三个卷积层搭建网络结构。SRCNN 网络预先处理输入的图像，根据放大倍数的不同，利用双三次插值法将低分辨率图像做相应的处理，此时虽然图像变大了，但仍然是低分辨率图像。随后进入三层卷积，分别对应三个过程，即图像的特征提取、非线性映射、图像重建。SRCNN 的实现过程如图 2-6：




图 2-6 SRCNN 的网络结构图

(a) 提取图像特征，从插值后的图像中提取图像块，通过 64 个卷积核大小为 9×9 的卷积操作提取特征信息，并将特征变换到高维空间，第一层卷积层后跟着 ReLU 激活层。

(b) 非线性映射，通过卷积核大小为 1×1 的卷积操作将 64 维的特征矩阵变成 32 维的特征矩阵，卷积后仍然跟着 ReLU 激活函数。这里可以使用更多的卷积层，但是出于对网络开销的考虑，只使用了 1 层卷积。

(c) 图像重建，该过程仍然是卷积操作，但是不再使用激活函数。
SRCNN 是端到端的超分算法，操作简单。与传统超分辨率不同，在实际应用时不需要任何人工的干预，并且重建出的图像质量比以往传统方式重建的图像边缘更清晰，伪影更少。但仍然有很多可以改进的地方，后续的许多工作在这篇论文的基础进行改进。

2.5.1.2 FSRCNN

FSRCNN^[16] 是在基于 SRCNN^[15] 上的改进，经典的 SRCNN 存在一些局限，一是 SRCNN 在输入网络前先进行插值，将图像放大之后再输入网络，放大后的图像输入网络会使得网络的计算量大大增加；二是 SRCNN 网络在进行非线性映射时在高维空间下完成，即特征通道数较多，虽然高维空间下可以帮助更好的提取特征，但增大了参数量，计算速度受限。针对以上问题，FSRCNN 做出改进，其网络结构如图 2-7 所示，包含特征提取、收缩、非线性映射、扩张和重建 5 个部分：




图 2-7 FSRCNN 的网络结构图

FSRCNN 的改进有：(a) 首先在图像输入网络前不再进行预处理操作，而是直接输入，在网络的后端使用反卷积将图像放大再输出，此时的计算复杂度与图像的尺寸大小成正比；(b) 其次在模型的中间使用先降维后升维操作，这样的做法可以使模型的参数量减少。SRCNN 在非线形映射时仅使用 1 个卷积层，而 FSRCNN 减小了卷积核尺寸并增加了卷积层数，同时作者认为特征图过深时，特征图的很多信息是冗余的，所以减少了输入特征图深度，最终实现参数量减少

的情况下保持了模型效果；(c)最后 FSRCNN 选择在网络的尾部使用反卷积的形式实现图像的放大，反卷积顾名思义就是卷积的逆运算，该方法不同于传统的插值运算，传统的插值根据特定的公式计算得到，而反卷积的参数在训练过程中不断改变，需要根据学习得到。在不同上采样倍数下，网络中只有在最后的上采样部分含有放大倍数的信息，反卷积的优势更为明显。

2.5.1.3 ESPCN

ESPCN^[17] 改进了上采样方法，提出了重见效果更好的亚像素卷积，本文指出在超分辨率重建前将低分辨率图像利用诸如插值的方式放大并输入网络，并不是最好的选择；而一般的反卷积操作本身具有局限性，对于空缺的像素值会进行补 0，可能会给重建图像带来负面影响，为此引入了有效的亚像素卷积。




图 2-8 亚像素卷积层^[17]

亚像素卷积分两个环节，一是前期的准备，用普通的卷积进行特征通道的放大，需要在上采样前根据放大倍数确定特征图通道的个数，通道数为放大倍数的平方，这样可以确保特征图所有像素的个数等于高分辨率图像像素的个数；二是重新排列像素，即可实现图像重建，像素重排的过程如图 2-8 所示。亚像素卷积并不是真正意义上的卷积操作，而是通过通道混淆实现图像放大。

亚像素卷积的使用方式非常灵活，超分效果也不错，速度上有非常大的优势。同时由于上采样是在网络的尾部进行的，属于后置上采样的方式，所以大量的计算量放在了低维空间进行，大大降低了网络的参数量，广泛应用在很多工作中。

2.5.2 多尺度模型

多尺度超分辨率一次训练即可实现多个上采样因子的输出，这种方式往往没有单尺度超分辨率模型效果好，如何让多倍数输出模型达到更好的超分辨率效果，是极具挑战性的问题。目前已经有不少网络实现了多尺度上采样，如 Lai 等^[36]人结合了拉普拉斯金字塔算法和神经网络进而提出 LapSRN 网络，通过将较大的上采样因子分解为多个小的上采样因子，逐步重建出不同尺度的高分辨率图

像，但是只能重建出 2 的幂次方的上采样尺度（如 $\times 2$ ， $\times 4$ ， $\times 8$ ），无法处理奇数倍数的超分辨率场景。MDSR^[29] 利用残差网络构建了多尺度超分辨率网络，提出了针对不同尺度的处理模块，包括预处理以及动态上采样模块。MDCN^[43] 由多尺度密集交叉模块、分层特征蒸馏块和动态上采样模块组成。具体地，多尺度密集交叉模块通过稠密连接以利用不同尺度卷积核所学到的特征；分层特征蒸馏模块学习不同深度的层次特征；动态上采样模块的结构与 MDSR^[29] 一样。

2.5.2.1 LapSRN

LapSRN^[36] 论文指出一些方法采用事前确定的上采样方式进行放大，则会产生一些问题，例如一些网络先使用双三次插值将图片放大，然后输入网络，这个过程会导致额外的计算量；另外该论文指出也有利用亚像素卷积和反卷积技术在网络末端进行放大的方法，这种方式虽然加快了网络的速度，降低了计算量，但是该方式适合小型网络，对于较为复杂的大网络来说，不能很好的学习映射关系。同时，大多数方法一次上采样只能重建一个倍数的图像，对于尺度因子较大的情况（如 $\times 8$ ），训练难度比较大。为了解决以上问题，LapSRN 网络做出了以下改进，如图 2-9 所示：




图 2-9 LapSRN^[36] 网络图

在上图中，红色箭头代表特征提取，蓝色箭头代表反卷积层，绿色箭头代表将两张图像进行逐像素相加。LapSRN 网络上层部分对图像进行特征提取，下层支路进行图像重建。在上层分支中，每一级都包含多个卷积层和一个反卷积层（进行 2 倍放大），每个反卷积层的输出连向两个不同的分支。将特征提取分支的图像与上采样后的图像相加，获得高分辨率图像，再将图像输入至下一阶段，重

复该过程。采用这样逐层递进的方式重建出的超分辨率图像更清晰，在这个过程中，同时得到了不同倍数的高分辨率图像，并且速度较快。但论文实验结果表明，对于 $\times 8$ 模型中间产生的 $\times 2$ 和 $\times 4$ 结果没有单独训练 $\times 2$ 和 $\times 4$ 的效果好。

2.5.2.2 MDSR

EDSR^[29] 论文的特征提取块设计时是在 SRResNet 的基础上去掉了批规范化处理，该论文指出，原来的残差块是针对图像分类、目标检测等高层的计算机视觉问题而设计的，而图像超分辨率是计算机视觉中的低层问题，所以直接将原来的残差块拿来使用并不合适。并且批规范化层也占有一定的计算量，所以去掉该层之后，相同层数的网络参数量就会减少，减少的参数量可以用来增加网络深度，提升网络的性能。在 EDSR 模型的基础上，本文还提出了另一个多尺度模型 MDSR^[29]，该模型可以同时实现不同的上采样倍数，MDSR 的网络架构如图 2-10 所示：




图 2-10 MDSR 的网络结构图

MDSR^[29] 的中间特征提取块采用和 EDSR^[29] 一样的结构，不同之处是，MDSR 在前端加入预处理模块，预处理模块是由 2 个残差块构成的，按不同放大倍数进入不同的分支，从而减少了不同放大率下的输入图像之间的差别。在网络的尾部，不同的放大倍数进入不同的分支，以得到不同倍数的输出结果。在工作^[43]中指出 MDSR 模型在网络头部添加的特定尺度处理模块并不利于特征信息的传递和不同尺度之间的交互，所以网络在实现多倍数输出时去掉了特定尺度处理模块。

2.6 本章小结

本章主要介绍了单图像超分辨率算法的相关知识。首先，对卷积神经网络包含的基本处理层进行了分析，包括卷积层、池化层、激活层和全连接层。同时还分析了基于卷积操作的一些改进，如空洞卷积、分组卷积和深度可分离卷积；其

次，对几个图像质量评估指标进行了介绍，分别从主客观两个方面进行了分析，从峰值信噪比、结构相似性、平均意见得分等方面进行了介绍，同时分析了不同评价方式的优缺点，在本文实验中选择了 PSNR 和 SSIM 两种方式；接着分析了在超分论文中常用的损失函数：L1 损失和 L2 损失函数，L2 损失一般不常用；最后介绍了两个与本文工作相关的内容：一个是注意力机制，注意力就是忽略那些不重要的特征，而把重点放在有用的特征上，将具有不同重要性的特征进行加权处理，对三个不同角度进行的注意力分别做了介绍：通道注意力、空间注意力和非局部注意力。另一个与本文工作相关是多尺度模型，分别介绍了单尺度模型和多尺度模型。单尺度模型以 SRCNN^[15]、FSRCNN^[16]、ESPCN^[17] 网络为例，介绍了这一类模型的网络架构及变化。所谓多尺度模型就是一次训练可以有多个倍数的图像输出，本文以 LapSRN^[36]、MDSR^[29] 网络为例，重点讲述了如何实现多尺度输出。

第3章 基于通道协作的单图像超分辨率算法

3.1 引言

单图像超分辨率 (SISR: Single Image Super Resolution)^[1]技术是指从给定的低分辨率图像恢复对应的高分辨率图像。SISR 是计算机视觉领域中的经典问题,在诸如遥感成像^[2]、视频监控^[3]和医学成像^[4]中应用广泛。当前,基于深度学习^[5]的方法,主导了 SISR 技术的研究。这些方法试图从大量的外部数据,学习 LR 和 HR 图像之间的非线性映射。Dong 等^[15]第一次提出了基于卷积神经网络 (CNN: Convolutional Neural Networks) 的 SISR 方法 SRCNN,仅有 3 个卷积层,就胜出了传统的 SISR 方法。此后,出现了大量的基于 CNN 的 SISR 方法。一个主要的改进是:引入了残差连接^[18],可以缓解网络训练中的梯度爆炸和消失问题,以增加网络的深度。例如, Kim 等利用残差连接,提出了 VDSR^[19],网络深度已增至 20 层。Kim 等也利用递归的残差连接,提出了 DRCN^[25],将网络增加到 16 层。残差连接的一个变种是稠密连接^[30],进一步增强了特征传播。例如, SRDenseNet^[31]在一个稠密块中,向后面的所有层输入前面的特征信息。RDN^[33]设计了具有局部、全局跳跃连接的残差稠密块。这些方法考虑了不同层特征之间的联系,并没有考虑同一层特征内部之间的关系。

一些基于 CNN 的方法引入了注意力机制,对所学习的特征信息做出区分。例如空间注意力^[53]通过对通道中同一位置的像素信息计算权重,网络学到了所有通道的整体分布。Wang 等^[54]提出了非局部网络 (NLN: Non-local Network) 来捕获长距离空间位置的信息。随后 SAN^[56]采用 Non-local,计算得到任意像素间的相关性系数,利用了空间位置的相关性。上述提到的注意力方法均考虑了空间位置的依赖,但没有考虑通道上的关系。

鉴于各种通道特征间的相关性和交互作用, Hu 等^[52]提出一种 (SE: Squeeze-and Excitation)块,利用全局平均池化,将各输入通道压缩为通道描述符(也就是一个常量),并将其送入两个稠密层中,产生相应的输入通道的比例系数(权重),以建模通道之间的相互依赖性。Zhang 等^[51]提出的 RCAN,将通道注意力 (CA: Channel Attention) 机制用到图像超分辨率 (SR: Super-Resolution),显著提高了 SISR 的性能。Dai 等^[56]提出的 SAN,进一步提出了二阶通道注意力 (SOCA) 模块, SOCA 通过使用二阶统计,而非 GAP,自适应地重新伸缩各个通道的特征,可以更好地学习通道特征之间的相关性。一些论文也说明了利用通道间相关性的重要性^{[57][58]},例如目标检测领域的 CGACD^[57]提出了基于通道相关引导的

通道注意力,对通道使用相关操作得到一组特征图,随后经过 SE 注意力生成一组通道权重,而该注意力仅在一开始考虑了通道间的相关性,用经过 SE 的结果分别调整每个通道的权重,特征通道信息不能被其他特征通道信息显式的调整,没有充分发挥通道相关性的作用。这些方法大都没有显式考虑特征通道之间的联系。

当前的 SISR 方法引入的通道注意力机制,仅利用数量权重,伸缩各个通道特征,并不能充分利用特征通道之间的相关性。为了解决这个问题,本文提出了一个基于特征通道协作 (CC: Channel Collaboration) 的 SISR 方法,可以根据特征通道之间的相似性,在特征通道的每个像素位置,融合各个特征通道对应像素,使得各特征通道信息自适应地被(其他通道信息)强调和互补。我们的方法可以更充分地利用特征通道之间的相关性,提高特征的表示能力。我们构造了两个特征通道协作模块:特征通道协作注意力模块 (CCAM: Channel Collaboration Attention Module) 和特征通道协作上采样模块 (CCUM: Channel Collaboration Upsampling Module)。前者融合各个通道特征,以变换出更有表达力的特征;而后者运用 CC,改进多尺度上采样效果。我们的方法可以显著改进当前的 SISR 方法的性能。我们的主要贡献包括:(1) 提出了一个基于特征通道协作的注意力模块,可以显著提升特征的表达能力;(2) 提出了一个基于特征通道协作的多尺度上采样模块,可以显著改进多尺度上采样效果;(3) 实验结果显示:我们提出的特征通道协作模块可以集成到其它主流的 SISR 模型,并显著提升其性能。

3.2 算法总体框架

本文提出了一个基于特征通道协作 (CC: Channel Collaboration) 的单图像超分辨率方法,我们构造了两个特征通道协作模块,特征通道协作注意力模块 (CCAM: Channel Collaboration Attention Module) 和特征通道协作上采样模块 (CCUM: Channel Collaboration Upsampling Module)。CCAM 和 CCUM 作为独立模块可以应用在其他网络以提升模型性能,可能的使用方式如图 3-1 所示。通过特征通道协作注意力,我们利用同一深度的不同通道之间的相关性,使得被不同通道捕获的特征能够进行协作传播,提升低频和高频特征信息提取能力,CCAM 具体实现如图 3-2 所示;而特征通道协作上采样模块能同时融合不同尺度间的高频信息的多尺度上采样模块,其中 CCUM 模块包含宽激活块 (WAB: Wide Activation Block) 和自适应尺度块 (ASB: Adaptive Scale Block),同时为进一步提升跨尺度协作,还将 CCAM 应用到上采样模块中,充分利用不同尺度信息的相关性,进而提升超分辨率性能。CCUM 如图 3-3 (a) 所示,WAB 和 ASB 模块分别如图 3-3 (b) 和 3-3 (c) 所示。

3.2.1 网络结构




图 3-1 特征通道协作在 SISR 网络中的应用

本文提出的特征通道协作注意力模块 (CCAM: Channel Collaboration Attention Module) 和特征通道协作上采样模块 (CCUM: Channel Collaboration Upsampling Module)是独立的模块,可以集成于任何超分辨率模型,图 3-1 为我们的 CC 在普通超分辨率网路的框架上的应用,一个可能的应用实例。如图 3-1 所示,CCAM 可以放在构件 Block 的尾部 (类似 SE 模块),而 CCUM 可以取代原来的上采样方式,我们选择在 MDCN^[29] 和 MDSR^[59] 的基础上进行实验。我们在 MDCN 网络的特征提取块 MDCB (MDCB: Multi-scale Dense Cross Block) 残差之前加入 CCAM,同时将 MDCN 网络的动态重建模块 (DRB: Dynamic Reconstruction Block) 替换为我们的 CCUM 模块,其他网络架构和超参数设置保持不变,用我们的的模块替换之后的模型,网络参数量基本不变,甚至略少,实验结果如表 4-6 所示。同时在 MDSR 架构上,将 ResBlock 的残差之前加入 CCAM,将 MDSR 的上采样模块替换为我们的 CCUM 模块,同样的其他网络结构和超参数设置不变,MDSR 的参数量为 8M,加上我们的改进后参数量为 8.13M,实验结果如表 4-6 所示。

3.2.2 特征通道协作注意力模块 (CCAM)




图 3-2 特征通道协作注意力模块

为了提升网络对低频和低频特征信息提取能力,特征通道协作注意力模块 (CCAM: Channel Collaboration Attention Module) 中,我们引入了新颖的注意力

机制, 该机制可以获得任意两通道间的相关性, 使得被不同通道捕获的特征能够进行协作传播。我们提出的特征通道协作注意力模块 (CCAM) 如图 3-2 所示, SCP 的实现包含 3 个部分, 分别是特征嵌入、特征交融和特征嵌入, 下面介绍各个部分。

(1) 特征嵌入

在该阶段, 捕获全局特征信息并将特征嵌入到另一空间中, 以实现通道间信息更好的交流。通过两个 1×1 的卷积, 对输入的特征图进行扩张和压缩变换。假定某个训练批次, 输入的特征图为: $X \in R^{N \times C \times H \times W}$, 其中, N 、 C 、 H 和 W 分别表示该训练批次输入特征图的样本个数、通道数、高度和宽度。第 i 个样本特征图 X^i 的变换公式如下:

$$F^i = w_{ei} \left(\sigma \left(W_{si} (X^i) \right) \right) \quad (3-1)$$

其中, W_{si} 和 W_{ei} 是两个 1×1 的压缩和扩张卷积运算, σ 为修正线性单元 (ReLU) 激活层, 特征通道扩张和压缩比为 r (实验中, 取 $r=16$)。特征通道扩张, 可以获取更多的特征信息; 特征通道压缩, 可以选择性的保留特征信息, 以提高特征的代表能力。

(2) 特征融合

在特征交融阶段, 我们获取任意通道间的相关性, 使得通道间相互作用, 并更新特征的响应值, 实现被不同通道间捕获的特征可以互补以进行协作传播。特征融合阶段, 又分为两步: (a) 计算各个特征通道的相关系数; (b) 根据相关系数, 融合各个特征通道, 生成更有表达力的特征。

(a) 计算相关系数。首先, 3 维特征图 $F^i \in R^{C \times H \times W}$ 展平为 2 维矩阵, 即 $F^i \in R^{C \times (HW)}$ 。值得注意的是, 我们采用该 2 维向量表征一个通道, 从而为后续计算通道相关系数做准备。然后, 对于任意两个通道特征 F_a^i 和 F_b^i 的相关性, 我们采用余弦相似度来度量通道之间的相似性:

$$S(F_a^i, F_b^i) = \left\langle \frac{F_a^i}{\|F_a^i\|}, \frac{F_b^i}{\|F_b^i\|} \right\rangle \quad a, b = 1, \dots, C \quad (3-2)$$

其中 $F_a^i \in R^{C \times (HW)}$, $F_b^i \in R^{C \times (HW)}$, $\langle \cdot \rangle$ 为向量内积, $\|\cdot\|$ 是 L_2 范数。由此, 可以获得任意两个通道之间的相似度矩阵 $S \in R^{C \times C}$ 。然后, 为了获得任意两个通道相关系数的概率分布, 我们接着使用一个 softmax 层以行的维度来归一化矩阵 S , 获得相关系数矩阵:

$$\rho_{mk} = \frac{\exp\{S(F_m^i, F_k^i)\}}{\sum_{k=1}^C \exp\{S(F_m^i, F_k^i)\}} \quad m, k = 1, \dots, C \quad (3-3)$$

ρ_{mk} 是相关系数矩阵中第 m 行, 第 k 列元素, 也就是 C 个特征通道中, 第 m 和第 k 个通道之间的相关系数。相关性概率矩阵 ρ_{mk} 的第 m 行表示第 m 个通道和所有通道间的相关系数的归一化概率。通过该操作, 可以将相似的通道进行分组, 使得这些通道拥有多样性和互补性。

(b) 特征融合。为充分利用通道多样性以及互补性, 我们采用加权和的形式获得每一个通道的互补激活。通过特征融合可以创建更有表示力的特征。融合后的每个特征通道是 C 个特征通道的线性组合 (或加权平均), 以求第 m 个通道互补激活为例:

$$Z_m^i = \sum_{k=1}^C \rho_{mk} F_k^i \quad (3-4)$$

(3) 特征嵌出

经过特征交融后的输出结果已经包含各个通道间的相关性以及互补性信息, 特征嵌出阶段与特征嵌入阶段类似, 我们使用和公式 (3-1) 一样的操作将特征交融后的信息被嵌出到初始空间, 操作如下:

$$F_{out}^i = W_{eo} \left(\sigma \left(W_{so} (Z^i) \right) \right) \quad (3-5)$$

其中, W_{so} 和 W_{eo} 是两个 1×1 的压缩和扩张卷积运算, σ 为修正线性单元 (ReLU) 激活层, 特征通道扩张和压缩比为 r (实验中, 取 $r=16$)。由于残差连接, 特征通道协作注意力模块 (CCAM) 传递 (输出) 到下一层的特征 X_{out}^i 为:

$$X_{out}^i = X^i + F_{out}^i \quad (3-6)$$

经过上述操作后, CCAM 能够让信息流在传递给下一层之前, 就利用同尺度不通通道特征相关性, 使这些特征充分交流和互补。总的来说, 特征嵌入捕获全局特征信息, 并将其编码到特定的特征空间; 特征交融阶段实现不同通道间的交互和互补; 特征嵌出阶段收集互补信息以及将信息传递给下一层。对于 SE 模块^[52], 其经过类似公式 (3-1) 的嵌入操作, 然后经过 sigmoid 层直接独立地生成各通道的权重, 没有显式地考虑到通道间特征的相关性。SCP 与 SE 的对比实验结果在章节 4.4.2.2 展示。

3.2.3 特征通道协作上采样模块 (CCUM)




图 3-3 特征通道协作上采样模块结构图

大多数多尺度方法在上采样阶段中都采用动态上采样模块：对于不同的上采样尺度特征，直接独立地进入不同的分支，而每个分支仅通过一个 3×3 卷积层变换通道，随后进入 Pixelshuffle 达到上采样的目的。显然同一样本的不同尺度的上采样信息是有相关性的，而动态上采样模块并没有充分地利用该相关性。为解决这一问题，我们设计了特征通道协作上采样模块 (CCUM: Channel Collaboration Upsampling Module)。我们应用特征通道协作 (CC) 技术，构造了一个 CC 多尺度上采样模块 (CCUM)。相较于其它多尺度上采样模块^{[42][43]}，CCUM 不增加参数量，但能显著改进多尺度上采样性能。

CCUM 如图 3-3(a) 所示，主要过程是：首先经过 16 个宽激活块 (WAB: Wide Activation Block)^[44]捕获更丰富的特征信息，然后，应用特征协作注意力模块 (CCAM)，进行特征通道交互，再通过自适应尺度块 (ASB: Adaptive Scale Block)，根据上采样的倍数选择进入一个相应的分支，获得不同上采样因子的 SR 图像。下面介绍特征通道协作上采样模块 (CCUM: Channel Collaboration Upsampling Module) 的具体实现过程及各部分实现细节。

输入特征 F_0 依次通过 16 个 WAB 块，可表示为：

$$F_k = H_k(F_{k-1}), \quad k = 1, \dots, 16 \tag{3-7}$$

H_k 是第 k 个 WAB 块函数， F_k 是第 k 个 WAB 块的输出，类似地， F_{k-1} 是第 $k-1$ 个 WAB 块的输出，也即是第 k 个 WAB 块的输入。然后，所有 WAB 块生成的输出级联，并经过 1×1 卷积压缩，进入 CCAM：

$$S = W_u \left(W_{CCAM} \left(W_d [F_1, F_2, \dots, F_{16}] \right) \right) \quad (3-8)$$

$[\cdot]$ 是级联操作 (Concat.), W_d 和 W_u 是 1×1 卷积, 分别进行通道的缩减和还原, W_{CCAM} 是 CCAM 模块, S 是输出的特征, 再输入到 ASB 块:

$$I = W_{ASB}(S) \quad (3-9)$$

W_{ASB} 代表 ASB 块, I 是输出的 SR 图像。

3.2.4 宽激活块 (WAB)

WDSR^[60] 已经证实: 非线性 ReLU 阻碍浅层信息向深层流动, ReLU 层之前扩展特征通道, 有助于传播浅层特征到最终层。受 WDSR 启发, 我们构造了 WAB 块, 如图 3-3(b) 所示。WAB 块可表示为:

$$F_k = W_r \left(W_s \left(\sigma \left(W_b (F_{k-1}) \right) \right) \right) \quad (3-10)$$

F_{k-1} 是第 k 个 WAB 块的输入 (即第 $k-1$ 个 WAB 块的输出), W_b 和 W_s 分别是扩大和压缩通道的 1×1 卷积层, σ 是 ReLU 激活函数, W_r 是 3×3 的卷积层, 恢复出原特征通道数。

3.2.5 自适应尺度块 (ASB)

自适应尺度块 (ASB) 使用的上采样方法是亚像素卷积^[61], 如图 3-3(c) 所示。ASB 包含 3 个分支, 分别处理 $\times 2$ 、 $\times 3$ 和 $\times 4$ 上采样。模型训练时, 随机选择某个分支, 即每次训练一个尺度因子。

为了更好的利用不同放大倍数之间的相关信息, 同时更高效的训练数据, 我们把不同倍数的图像混合在一起进行训练。在训练时, 模型会随机的选择不同倍数的图像, 上采样时自适应的选择对应的分支, 即三个分支在一次训练中只会被选中一个。这样的多倍数训练方式, 不仅可以学习尺度之间的信息, 还可以节省时间。

3.3 本章小结

本章节提出了基于特征通道协作 (CC) 的方法, 改进当前单图像超分辨率 (SISR) 的方法, 重建高质量的超分辨率图像。在本章节中, 首先介绍了本文要解决的问题, 引出本文方法的动机, 为了解决这一问题提出了基于特征通道协作传播 (CC) 的方法, CC 通过两个模块实现: 特征通道协作注意力模块 (CCAM) 和

特征通道协作上采样模块 (CCUM)。随后介绍了 CCAM 和 CCUM 如何在超分辨率网络架构中使用。接着介绍了 CCAM 的具体实现方法，包含三个过程：特征嵌入、特征融合、特征嵌出，通过特征通道协作注意力模块，利用同一深度的不同通道间的相关性，使其协作传播，可以帮助网络更好的提取特征信息。再次详细介绍 CCUM 的实现方法，其中 CCUM 首先经过 16 个宽激活块 (WAB) 捕获更丰富的特征信息，然后在 CCUM 中应用特征协作注意力模块 (CCAM)，进行特征通道交互，再通过自适应尺度块 (ASB)，根据上采样的倍数选择进入一个相应的分支，获得不同上采样因子的 SR 图像。CCUM 是一个能同时融合不同尺度的高频信息的多尺度上采样模块，充分利用不同尺度信息的相关性，改进上采样效果。

第 4 章 实验与分析

4.1 引言

本章节主要介绍训练网络所需要的数据集、对数据的处理、实验过程中的一些参数设置和实验细节。实验细节从两类实验分析，一是消融实验，验证各个模块在网络中发挥的作用，二是各个模块结构设计及模块优势的分析。最后除了对比不同放大倍数下的客观指标 PSNR 和 SSIM 外，还对比了主观图，做了较为详尽的实验分析。

4.2 数据集

对于训练集，我们选择 NTIRE 2017 挑战赛的官方数据集 DIV2K^[62]，该数据集用于图像超分辨率重建任务的高质量 2K 分辨率图像数据集，总共 1000 张高分辨率图像，包含 800 张训练图像 (1-800)，100 张验证图像 (801-900)，100 张测试集 (901-1000)。我们使用 800 个 DIV2K 训练图像训练模型，训练中使用 5 个 DIV2K 验证图像 (801-805)，标记为 DIV2K_val5。LR 图像通过双三次下采样原 HR 图像获得。

对于测试集，我们选择在 5 个标准的测试集：Set5^[63]、Set14^[64]、B100^[65]、Urban100^[66] 和 Manga109^[67] 上执行测试。Set5^[61] 是由 5 张图像组成，是图像超分辨率领域的经典测试数据集；Set14^[62] 数据集中图像的平均分辨率进一步提高，对于细节信息恢复能力的评估更为准确；B100^[63] 包含大量的生活场景图像，如动物、风景等；Urban100^[64] 增加了室内、城市、建筑等方面的真实图像，使得图像更为全面；Manga109^[65] 是由漫画图像组成的，来自 109 本不同类型的漫画书。值得注意的是，在本文实验中所有 SR 图都转换到 YCbCr 空间^{[68][66]}上，在 Y 通道计算峰值信噪比 (PSNR)^[71] 和结构相似性 (SSIM)^[71] 评估度量。

4.3 实验参数设置

训练中的批大小 (Batch Size) 设置为 16，LR 图像片尺寸设置为 48×48。类似于 MDCN^[59] 和 MDSR^[29]，我们也使用随机的水平翻转和 90 度旋转，增强训练数据集。我们也使用 ADAM 优化器，设置 $\beta_1 = 0.9$ ， $\beta_2 = 0.999$ ，以及 $\varepsilon = 10^{-8}$ 。学习率初始化为 10^{-4} ，每 200 个迭代周期 (epoch) 减半。损失函数选择 L1 损失。模型实现使用 PyTorch 1.6^[70] 框架，模型训练使用单个 NVIDIA

2080Ti GPU, 每次随机选取一个尺度 ($\times 2$ 、 $\times 3$ 或 $\times 4$)。

4.4 图像质量评价

利用神经网络恢复的图像肉眼感觉都比较好,这就需要有一定的评价标准来做统一的界定。评价图像质量的好坏最主要的是通过客观评价,如峰值信噪比 (PSNR)、结构相似性 (SSIM)^[71] 等。当然也有主观评价,即以人眼观测作为评价主体,来判断重建图像的细节是否恢复,这种方法带有一定的主观性;主观评价更符合我们的需要,但这种方式比较耗时,所以常常使用客观评价。这些不同的客观评价方法与人类的视觉感知在某种程度上并不相符,甚至各个方法之间的结论也不一致^[72],为了增加说服力,可以同时使用多种评价方式。这里介绍三种评价方式,由于平均意见得分这种方式在实际使用时有一定的局限性,本文利用峰值信噪比 (PSNR) 和结构相似性 (SSIM) 两种方式。

4.4.1 峰值信噪比

峰值信噪比是最容易理解的一种方法,同时也是使用最普遍的测量图像重建质量的方法,通过计算对应像素点的差值,比较两幅图像的差异。两个图像的 PSNR 值越大,代表越相似。其计算公式如下:

$$MSE = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W (X(i, j) - Y(i, j))^2 \quad (2-7)$$

$$PSNR = 10 \log_{10} \left(\frac{(2^n - 1)^2}{MSE} \right) \quad (2-8)$$

首先计算均方差 (MSE: Mean Square Error), 其中 X 代表原始低分辨率图像, Y 代表重建后的高分辨率图像, H 为图像的高度, W 为图像的宽度。接下来计算均方误差相较于 $(2^n - 1)^2$ 的对数值, 其单位为 dB。通过公式可以看到, PSNR 单单考虑两幅图在逐点数值上的差异, 并没有考虑点与点之间的联系, 这就限制了图像的直观感受, 所以常伴随着 PSNR 的评价结果与主管评价不一致的情况, 所以仅使用 PSNR 值来衡量图像质量的好坏不太合适, 往往需要结合其他评价指标。

4.4.2 结构相似性

结构相似性 (SSIM) 同样是比较两幅图像相似性的方法。由于仅仅根据对应位置的像素值计算是否相似不符合人类视觉的评价结果, 所以对评价方式重新考

虑。SSIM 的理论基础是在两个自然图片高度相近的情况下，相邻的像素之间存在着强烈的相关性，这是 SSIM 被提出的出发点。相关性是衡量图像质量的一个关键指标，这在大多数的评价指标中是不曾体现的，它的范围在 0 到 1 之间，SSIM 值越接近 0，说明两图像间差异越大，反之差异越小。SSIM 分别从亮度、对比度、结构三方面测量图像相似性，分别由 $l(X,Y)$ 、 $c(X,Y)$ 、 $s(X,Y)$ 表示，SSIM 的求解过程如下：

$$SSIM(X,Y) = (l(X,Y))^\alpha \cdot (c(X,Y))^\beta \cdot (s(X,Y))^\gamma \quad (2-9)$$

$$\begin{cases} l(X,Y) = \frac{2\mu_X\mu_Y + c_1}{\mu_X^2 + \mu_Y^2 + c_1} \\ c(X,Y) = \frac{2\sigma_X\sigma_Y + c_2}{\sigma_X^2 + \sigma_Y^2 + c_2} \\ s(X,Y) = \frac{\sigma_{XY} + c_3}{\sigma_X\sigma_Y + c_3} \end{cases} \quad (2-10)$$

其中 μ_X 、 μ_Y 分别表示图像 X 和 Y 的均值， σ_X 、 σ_Y 分别表示图像 X 和 Y 的方差， σ_{XY} 表示对比图像 X 和参考图像 Y 的协方差， c_1 、 c_2 、 c_3 为常数，在实际运用中，我们一般设定 $\alpha = \beta = \gamma = 1$ ，以及 $c_3 = c_2 / 2$ ，则 SSIM 的计算公式可以化简为：

$$SSIM(X,Y) = \frac{(2\sigma_X\sigma_Y + c_1)(\sigma_{XY} + c_2)}{(\mu_X^2 + \mu_Y^2 + c_1)(\sigma_X^2 + \sigma_Y^2 + c_2)} \quad (2-11)$$

4.4.3 平均意见得分

平均意见得分 (MOS: Mean opinion score) 是一种常用的关于图像质量的主观测评方法，在这种方法中，会邀请很多评分员为测试图像打分，通常是将分数划分在 1 到 5 之间（分数越高图像质量越好），最后的 MOS 是将所有分数求平均。在实际生活中，图像是为人类服务的，所以一味追求数值上的标准而忽略人的直观感受是不贴合实际的，比如一些图像在感知质量很好，但在评价指标上并不理想。在此情形中，MOS 方法能够更可靠地测量感知质量^[73]。虽然 MOS 看起来是一种不错的评估方式，但仍然有一定的缺点，如评级标准不同。在评价图像质量时，往往结合多种评价方式。

4.5 实验细节

4.5.1 消融实验

为了验证我们的特征通道协作注意力模块 (CCAM) 和特征通道协作上采样模块 (CCUM), 在 MDCN 上进行了实验。每个 MDCB 之后插入 CCAM, 并用 CCUM 替换原上采样模块, 在 DIV2K_val5 上的实验结果如表 4-1 所示 (其中 “x”表示包含该模块, “√”表示不包含)。假定 MDCN 中包含 CCAM 的模型, 记为_CCAM1, 否则记为 _CCAM0; MDCN 中上采样模块替换为 CCUM 的模型, 记为 _CCUM1, 否则记为_CCAM0。例如, MDCN_CCAM1_CCUM1 模型可意为在 MDCN 网络中包含 CCAM, 其上采样块也已替换为我们的 CCUM, 其它模型可类推。MDCN 的 PSNR 为 38.43dB, MDCN_CCAM1_CCUM0 和 MDCN_CCAM0_CCUM1 的 PSNR 比 MDCN 分别提升了 0.11dB 和 0.09dB。MDCN_CCAM1_CCUM1 模型结果最好, PSNR 达到 38.57dB, 比 MDCN 高出了 0.14dB。从实验结果可以发现, 在原模型 MDCN 网络的基础上使用任意通道协作模块, 模型效果均有不同程度的提升, 并且当同时使用两个模块时, 效果最好。

表 4-1 MDCN^[59] 中分别使用 CCAM 和 CCUM 在 DIV2K_val5 上 ×2 的 PSNR

CCAM	×	√	×	√
CCUM	×	×	√	√
PSNR	38.43	38.54	38.52	38.57

为了观察 CCAM 特征提取效果, 我们选取了 Set5 数据集中的图像 butterfly, 可视化了 MDCN 和 MDCN_CCAM1 输入到上采样模块前的特征信息, 由于空间关系, 我们选取前 8 个通道。我们将没有加入 CCAM 模块学到的通道特征和引入 CCAM 学到的通道特征可视化, 结果如图 4-1 所示, 图 4-1(a) 为 MDCN 网络中选取最后一个特征提取块的输出特征通道可视化结果, 可以发现此时的特征图几乎看不到所学的特征; 图 4-1(b) 为 MDCN 网络的特征提取块尾部加上 CCAM 的效果, 可以看出图像可视化结果较为清晰, 边缘和纹理细节恢复得更好。此外, 在其他通道可视化中也有类似的发现。MDCN 网络之所以会出现上述情况, 说明特征提取块几乎没有学到特征, 原因很可能是在网络后面的梯度基本消失, 而在特征提取块中主要依赖残差分支在传递信息, 为了学习更多的特征信息, 我们在特征提取块的残差前加入 CCAM, 通过建立通道间的协作关系帮助网络学习更丰富的信息, 很好的缓解了该问题。




图 4-1 特征可视化结果

4.5.2 特征通道协作注意力模块分析

4.5.2.1 CCAM 结构设计分析

我们首先进行特征通道协作注意力模块结构设计上的探索。为了证明通道协作的有效性，我们去掉特征嵌入和特征嵌出（记为 embedding）做消融实验，我们在 MDCN 网络的基础上，分别将不带 embedding 的 SCC 和带有 embedding 的 CCAM 放在特征提取块的尾部，其他网络架构保持不变。本组实验的结果见表 4-2，在 $\times 2$ 模型下不带 embedding 的 CCAM 的 PSNR 值为 38.48dB，而带有 embedding 的 CCAM 的 PSNR 值为 38.54dB，对比表 4-1 中 MDCN_CCAM0_CCUM0 模型的值为 38.43bB，均比该模型的 PSNR 值高，这说明我们的模块的性能提升主要归功于通道协作传播，而不是仅由于特征嵌入和特征嵌出带来的额外参数量。同时带有 embedding 的 CCAM 比不带 embedding 的 CCAM 性能略好，PSNR 可提高 0.05~0.06dB，所以我们在 CCAM 结构设计上保留 embedding。

表 4-2 带有和不带有特征嵌入、特征嵌出的 CCAM 在 DIV2K_val5 上 $\times 2$ 、 $\times 3$ 和 $\times 4$ 的 PSNR

embedding	$\times 2$	$\times 3$	$\times 4$
$\times$	38.48	34.68	32.46
$\surd$	38.54	34.73	32.51

4.5.2.2 CCAM 的优势

为了与 SE 模块^[52]进行比较，我们把 CCAM 和 SE 模块分别插入多尺度模型 MDCN 和 单尺度模型 MSRN^[37]特征提取块的尾部。在 DIV2K_val5 上的 $\times 2$ 实验结果，如表 4-3 所示，Baseline 表示两个网络的原模型，Baseline_SE 表

明是在原模型的特征提取块的尾部添加 SE 注意力，同理 Baseline_CCAM 表示在原模型的特征提取块的尾部添加本文的注意力 CCAM，由表中的数据可以看出，CCAM 的 PSNR 性能略优于 SE 模块。

表 4-3 MDCN^[59]中分别使用 SE 模块^[52]和 CCAM 在 DIV2K_val5 上 ×2 的 PSNR

模型	MDCN	MSRN
Baseline	38.43	38.33
Baseline_SE	38.47	38.35
Baseline_CCAM	38.54	38.38

4.5.3 特征通道协作上采样模块分析

4.5.3.1 CCUM 设计分析

为了验证不同数目的 WAB 块对性能的影响，我们在 DIV2K_val5 上，执行 ×2、×3 和 ×4 试验，WAB 块的数目分别设置为 8、16 和 32。为了尽可能排除其它因素影响，CCUM 中未包含 CCAM，实验结果如表 4-4 所示。WAB 块更多，PSNR 性能稍微更好。考虑到模型参数和计算量的约束，WAB 块个数为 16，可能是一个合适的平衡点。

表 4-4 CCUM 中不同 WAB 个数在 DIV2K_val5 上的 ×2、×3 和 ×4 的 PSNR

数目	×2	×3	×4
8	38.41	34.50	32.47
16	38.52	34.62	32.47
32	38.55	34.75	32.52

4.5.3.2 CCAM 在 CCUM 中的效果分析

为了发现 CCAM 在 CCUM 中的效果，CCUM 中包含和不包含 CCAM 的实验结果如表 4-5 所示。在 ×3 和 ×4 时，PSNR 分别提升了 0.09dB 和 0.06dB，这也说明 CCAM 似乎是有效的。

表 4-5 CCUM 包含和不包含 CCAM 时 DIV2K_val5 上的 ×2、×3 和 ×4 的 PSNR

CCAM	×2	×3	×4
×	38.52	34.62	32.47
√	38.52	34.71	32.53

4.6 实验结果

4.6.1 客观结果

我们把 CCAM 和 CCUM 插入到 MDSR^[29] 和 MDCN^[59]，与原 MDSR 和 MDCN 进行对比。同时，我们也与其它类似的、具有代表性的模型 SRCNN^[15]、VDSR^[19]、DRCN^[25]、LapSRN^[36]、EDSR^[29]、CARN^[27]、MSRN^[37]、D-DBPN^[74]、SRFBN^[75]、SeaNet^[76]进行了比较。在：Set5^[63]、Set14^[64]、B100^[65]、Urban100^[66]和 Manga109^[67] 五个标准测试集上 $\times 2$ 、 $\times 3$ 和 $\times 4$ 实验结果，PSNR 和 SSIM 值分别如表 4-6、表 4-7 所示，最好的结果用加粗表示，次好结果用下划线表示。MDSR 在 Manga109 上的实验结果，由于作者未在该数据集上进行测试，本文通过运用作者公开可用的模型测试得到 (用 * 标记)，其它实验结果源于各自论文。我们的特征通道协作 (CCAM 和 CCUM)，均提升了 MDSR^[29] 和 MDCN^[59] 的性能。例如，在表 4-6 中，对 MDCN^[59] 的 $\times 4$ 情形，PSNR 分别提升了 0.16dB、0.086dB、0.05dB、0.24dB 和 0.25dB，在大的测试集上，提升更显著一些。同样的，在表 4-7 中观察另一个评价指标 SSIM，在 MDCN 和 MDSR 上，当使用我们的方法时 SSIM 在不同数据集上有了不同程度的提高。

4.6.2 主观结果

图 4-2、4-3、4-4 分别展示本文方法同其他先进方法在 $\times 2$ 、 $\times 3$ 、 $\times 4$ 放大倍数下重建的 SR 图对比结果，很明显的看出本文方法生成的超分辨率图像具有更丰富的细节信息和清晰的纹理，更接近真实图像，在不同倍数下均展现了这一优势。例如图 4-2 是 Set14 数据集中 barbara $\times 2$ 放倍数下的图像，Bicubic、EDSR、SeaNet 等方法均无法准确而清楚的恢复出国巾的线条，线条方向恢复出现错误，与真实图像不符，MDSR 和 MDCN 也存在这一问题，但在这两个方法的基础上加上本文方法后，明显改善了线条的恢复，使其更接近真实图像。再看 $\times 3$ 放大倍数下的 Urban100 中的 img078 图像，如图 4-3 所示，Bicubic 插值图像很不清楚，LAPSRN 的重构结果有些失真，MSRN 模型、EDSR 模型、SeaNet 模型、MDSR 模型、MDCN 模型均出现线条恢复部分失真，在 MDSR、MDCN 对比之下，MDSR-ours、MDCN-ours 的结果显著更好。再以 $\times 4$ 放大倍数下的 Manga109 中的 YumeiroCooking 图像为例，如图 4-4 所示，除了 EDSR 模型和本文的模型外，其余模型均有不同程度的失真或模糊。由此可见，本文提出的方法帮助通道协作，能充分利用提取到的特征，重建后的图像就会显示出更明显的轮廓和边界，并且视觉效果良好，我们的结果也最接近于原 HR 图像。

表 4-6 不同 SISR 方法在 5 个标准测试数据集上 $\times 2$ 、 $\times 3$ 和 $\times 4$ 的平均 PSNR
(最好结果与次好结果分别用加粗和下划线显示)

倍数	模型	Set5 PSNR	Set14 PSNR	B100 PSNR	Urban100 PSNR	Manga109 PSNR
$\times 2$	SRCNN	36.66	32.42	31.36	29.50	35.74
	VDSR	37.53	33.03	31.90	30.76	37.22
	DRCN	37.63	33.04	31.85	30.75	37.63
	LapSRN	37.52	33.08	31.80	30.41	37.27
	EDSR	38.11	33.92	32.32	32.93	39.10
	CARN	37.76	33.52	32.09	31.92	38.36
	MSRN	38.08	33.70	32.23	32.29	38.69
	D-DBPN	38.09	33.85	32.27	32.55	38.89
	SRFBN	38.11	33.82	32.29	32.62	39.08
	SeaNet	38.08	33.75	32.27	32.50	38.76
	MDSR	38.11	33.85	32.29	32.84	39.08*
	MDSR-ours	<u>38.21</u>	<u>34.05</u>	32.31	32.886	<u>39.23</u>
	MDCN	38.19	33.86	<u>32.32</u>	<u>32.92</u>	39.09
	MDCN-ours	38.24	34.11	32.37	33.20	39.36
$\times 3$	SRCNN	32.75	29.28	28.41	26.24	30.59
	VDSR	33.66	29.77	28.82	27.14	32.01
	DRCN	33.82	29.76	28.80	27.15	32.31
	EDSR	34.65	30.52	29.25	28.80	34.17
	CARN	34.29	30.29	29.06	27.38	33.50
	MSRN	34.46	30.41	29.15	28.33	33.67
	SRFBN	34.70	30.51	29.24	28.73	34.18
	SeaNet	34.55	30.42	29.17	28.50	33.73
	MDSR	34.66	30.44	29.25	28.79	34.12*
	MDSR-ours	<u>34.69</u>	<u>30.55</u>	29.25	28.81	<u>34.35</u>
	MDCN	34.69	30.54	<u>29.26</u>	<u>28.83</u>	34.17
	MDCN-ours	34.73	30.62	29.32	29.07	34.47
	SRCNN	30.48	27.49	26.90	24.52	27.66
	VDSR	31.35	28.01	27.29	25.18	28.83
$\times 4$	DRCN	31.53	28.02	27.23	25.14	28.98
	LapSRN	31.54	28.19	27.32	25.21	29.09
	EDSR	32.46	28.80	27.71	26.64	31.02
	CARN	32.13	28.60	27.58	26.07	30.47
	MSRN	32.26	28.63	27.61	26.22	30.57
	D-DBPN	32.47	28.82	27.72	26.38	30.91
	SRFBN	32.47	28.81	27.72	26.60	31.15
	SeaNet	32.33	28.72	27.65	26.32	30.74
	MDSR	32.50	28.72	27.72	26.67	31.05*
	MDSR-ours	<u>32.54</u>	<u>28.84</u>	27.73	26.68	<u>31.21</u>
	MDCN	32.48	28.83	<u>27.74</u>	<u>26.69</u>	31.10
	MDCN-ours	32.64	28.91	27.79	26.93	31.35

表 4-7 不同 SISR 方法在 5 个标准测试数据集上 $\times 2$ 、 $\times 3$ 和 $\times 4$ 的平均 SSIM

(最好结果与次好结果分别用加粗和下划线显示)

倍数	模型	Set5 SSIM	Set14 SSIM	B100 SSIM	Urban100 SSIM	Manga109 SSIM
$\times 2$	SRCNN	0.9524	0.9063	0.8879	0.8946	0.9661
	VDSR	0.9587	0.9124	0.8960	0.9140	0.9729
	DRCN	0.9588	0.9118	0.8942	0.9133	0.9723
	LapSRN	0.9590	0.9130	0.8950	0.9100	0.9740
	EDSR	0.9602	0.9195	0.9013	0.9351	0.9773
	CARN	0.9590	0.9166	0.8978	0.9256	0.9765
	MSRN	0.9607	0.9186	0.9002	0.9303	0.9772
	D-DBPN	0.9600	0.9190	0.9000	0.9324	0.9775
	SRFBN	0.9609	0.9196	0.9010	0.9328	0.9779
	SeaNet	0.9609	0.9190	0.9008	0.9318	0.9774
	MDSR	0.9602	0.9198	0.9007	0.9347	0.9778*
	MDSR-ours	<u>0.9612</u>	<u>0.9213</u>	0.9012	0.9346	0.9779
	MDCN	0.9612	0.9202	<u>0.9014</u>	<u>0.9355</u>	<u>0.9780</u>
	MDCN-ours	0.9614	0.9214	0.9019	0.9374	0.9781
$\times 3$	SRCNN	0.9090	0.8209	0.7863	0.7989	0.9107
	VDSR	0.9213	0.8314	0.7976	0.8279	0.9310
	DRCN	0.9226	0.8311	0.7963	0.8276	0.9328
	EDSR	0.9280	0.8462	0.8093	0.8653	0.9476
	CARN	0.9255	0.8407	0.8034	0.8404	0.9440
	MSRN	0.9278	0.8437	0.8064	0.8561	0.9456
	SRFBN	0.9292	0.8461	0.8084	0.8641	0.9481
	SeaNet	0.9282	0.8444	0.8071	0.8594	0.9463
	MDSR	0.9280	0.8452	0.8091	0.8655	0.9478*
	MDSR-ours	0.9293	0.8460	0.8090	0.8650	<u>0.9488</u>
	MDCN	<u>0.9294</u>	<u>0.8470</u>	<u>0.8095</u>	<u>0.8662</u>	0.9485
	MDCN-ours	0.9297	0.8478	0.8106	0.8698	0.9498
$\times 4$	SRCNN	0.8628	0.7503	0.7101	0.7221	0.8505
	VDSR	0.8838	0.7674	0.7251	0.7524	0.8809
	DRCN	0.8854	0.7670	0.7233	0.7510	0.8816
	LapSRN	0.8850	0.7720	0.7280	0.7560	0.8845
	EDSR	0.8968	0.7876	0.7420	0.8033	0.9148
	CARN	0.8937	0.7806	0.7349	0.7837	0.9084
	MSRN	0.8960	0.7836	0.7380	0.7911	0.9103
	D-DBPN	0.8980	0.7860	0.7400	0.7946	0.9137
	SRFBN	0.8983	0.7868	0.7409	0.8015	0.9160
	SeaNet	0.8970	0.7855	0.7388	0.7942	0.9129
	MDSR	0.8973	0.7857	0.7418	0.8041	0.9144*
	MDSR-ours	<u>0.8987</u>	0.7872	0.7412	0.8031	<u>0.9166</u>
	MDCN	0.8985	<u>0.7879</u>	<u>0.7423</u>	<u>0.8049</u>	0.9163
	MDCN-ours	0.8998	0.7891	0.7437	0.8100	0.9187




图 4-2 ×2 视觉效果比较




图 4-3 ×3 视觉效果比较




图 4-4 ×4 视觉效果比较

4.7 本章小结

本章节详细介绍了训练网络所需要的数据集、实验参数的设置、大量的消融

实验、对比实验的细节以及最后的实验结果。首先介绍了网络用到的数据集，包括训练集和测试集。接着介绍了实验参数的一些设置，包含学习率、损失函数、迭代周期等，实验过程中参数设置分别与 MDCN、MDSR 保持一致。其次，对模块进行了实验，来验证本文提出模块的有效性及合理性，四组消融实验证明了本文提出的模块是有效性的，并且只有在同时使用两个模块时效果是最好的，只使用其中任何一个模块的效果也会比基模型效果好。对于特征通道协作上采样模块 (CCAM) 来说，通过两组对比实验分别验证结果设计的合理性和 CCAM 的有效性；对于特征通道协作上采样模块 (CCUM)，通过两组对比实验验证了超参数设计的合理性和 CCUM 的有效性。最后从客观和主观两个角度分析了在不同放大倍数下、多个数据集上的实验结果，客观角度采用 PSNR 和 SSIM 两个角度对恢复图像的好坏进行评价，主观方面列举了大量的超分辨率图像，本文方法恢复出的图像具有较为清晰的轮廓，细节恢复较好。

第 5 章 结论与展望

5.1 论文工作总结

受限于各种环境因素以及硬件成本,图像的分辨率在很多场景下已经不能满足现实的需求,高效、高性能的超分辨率技术得到广泛研究,其中基于深度学习的超分辨率重建技术显著改进了单图像超分辨率方法的性能。本文通过研究图像超分辨率模型中特征通道之间的相关性,提出了基于特征通道协作的单图像超分辨率算法,该方法考虑不同通道间的相关性,使得各特征通道的信息自适应地被强调和互补,提升网络模型利用特征信息的能力。本文构造了两个通用且独立的特征通道协作模块,可以集成到其他现存的单图像超分辨率模型中,完成的主要工作如下:

本文提出了特征通道协作注意力模块,融合各个通道特征,以变换出更有表达力的特征。与一般通道注意力独立计算每个通道权重不同的是,我们的注意力模块可以根据通道间的相关性实现通道间的协作。该方法将特征编码到特定的特征空间,通过任意两个通道向量间的余弦相似度来衡量其相关性,然后利用通道相关系数对每个通道进行互补激活,进而实现不同通道间信息的交互和互补,最后将特征再解码回原始特征空间。这一过程使得不同通道捕获的特征能够进行协作传播。

本文提出了特征通道协作上采样模块,是一种能同时融合不同尺度间高频信息的多尺度上采样模块,可以同时训练 $\times 2$ 、 $\times 3$ 和 $\times 4$ 模型。特征通道协作上采样模块中的宽激活块可以捕获更丰富的特征信息,自适应尺度块可以根据上采样的倍数进入相应的分支,获得不同上采样因子的超分辨率图像。同时为了进一步提升模块间的协作能力,还可以将特征通道协作注意力模块应用到上采样模块中,这一过程使得上采样模块中不同深度不同模块的特征能够进行交互以及互补,改进多尺度上采样效果。

本文方法应用在当前两个代表性方法上的实验结果表明,标准测试集下,使用该方法不仅在客观指标 PSNR/SSIM 上得到提升,而且重建图像在主观效果上细节更丰富,轮廓更清晰,改善了图像的重建质量。此外,我们的特征通道协作注意力模块能提升单尺度超分辨率模型的性能。

5.2 未来工作展望

本文对基于深度学习的单图像超分辨率方法进行了学习和研究,并提出了基

于通道协作的单图像超分辨率算法，在主观和客观指标方面取得了良好的效果，提升了图像的重建质量。但本文方法仍然有一些不足之处，还需要进一步改善，主要有以下问题：

（1）本文所提出的方法特征通道协作注意力模块通过计算任意两个通道间的余弦距离来衡量通道间的相关性，不可避免的带来了一些计算量。在建立通道间相关性，保证模型性能的前提下，寻找一种合理的计算方式，降低计算量，在计算量和性能之间取得较好的平衡。

（2）在实验中，对某些参数的选择主要依靠人工经验，虽然做了不同参数选择下的对比实验，但终究不能列举所有的参数值。未来可以在网络中利用强化学习等方式，降低人为干预带来的误差。

参考文献

- [1] William T Freeman, Egon C Pasztor, and Owen T Carmichael. Learning low-level vision. *International journal of computer vision*, 40(1): 25–47, 2000.
- [2] Matt W Thornton, Peter M Atkinson, and DA Holland. Sub-pixel mapping of rural land cover objects from fine spatial resolution satellite sensor imagery using superresolution pixel-swapping. *International Journal of Remote Sensing*, 27(3): 473–491, 2006.
- [3] Wilman WW Zou and Pong C Yuen. Very low resolution face recognition problem. *IEEE Transactions on image processing*, 21(1): 327–340, 2011.
- [4] Wenzhe Shi, Jose Caballero, Christian Ledig, Xiahai Zhuang, Wenjia Bai, Kanwal Bhatia, Antonio M Simoes Monteiro de Marvao, Tim Dawes, Declan O’ Regan, and Daniel Rueckert. Cardiac image superresolution with global correspondence using multi-atlas patchmatch. In *International conference on medical image computing and computer-assisted intervention*, pages 9–16. Springer, 2013.
- [5] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. Deep learning. *nature*, 521(7553): 436–444, 2015.
- [6] Keys R. Cubic convolution interpolation for digital image processing[J]. *IEEE transactions on acoustics, speech, and signal processing*, 1981, 29(6): 1153-1160.
- [7] Li X, Orchard M T. New edge-directed interpolation[J]. *IEEE Trans Image Process*, 2001, 10(10): 1521-1527
- [8] Battiato S, Gallo G, Stanco F. A locally adaptive zooming algorithm for digital images[J]. *Image and vision computing*, 2002, 20(11): 805-812.
- [9] 苏衡, 周杰, 张志浩. 超分辨率图像重建方法综述[J]. *自动化学报*, 2013, 39(8): 1202-1213.
- [10] Tsai R. Multiframe image restoration and registration[J]. *Advance Computer Visual and Image Processing*, 1984, 1: 317-339.
- [11] Irani M, Peleg S. Improving resolution by image registration[J]. *CVGIP: Graphical models and image processing*, 1991, 53(3): 231-239.
- [12] Schultz R R, Stevenson R L. A Bayesian approach to image expansion for improved definition[J]. *IEEE Transactions on Image Processing*, 1994, 3(3): 233-242.
- [13] Yang C Y, Yang M H. Fast direct super-resolution by simple functions[C]//*Proceedings of the IEEE international conference on computer vision*. 2013: 561-568.
- [14] Freeman W T, Pasztor E C, Carmichael O T. Learning low-level vision[J]. *International journal of computer vision*, 2000, 40(1): 25-47.

- [15]Chao Dong, Chen Change Loy, Kaiming He, and Xiaoou Tang. Image super-resolution using deep convolutional networks. *IEEE transactions on pattern analysis and machine intelligence*, 38(2): 295–307, 2015.
- [16] Dong C, Loy C C, Tang X. Accelerating the super-resolution convolutional neural network[C]//*European conference on computer vision*. Springer, Cham, 2016: 391-407.
- [17]Shi W, Caballero J, Huszár F, et al. Real-time single image and video super-resolution using an efficient sub-pixel convolutional neural network[C]//*Proceedings of the IEEE conference on computer vision and pattern recognition*. 2016: 1874-1883.
- [18]He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//*Proceedings of the IEEE conference on computer vision and pattern recognition*. 2016: 770-778.
- [19]Kim J, Lee J K, Lee K M. Accurate image super-resolution using very deep convolutional networks[C]//*Proceedings of the IEEE conference on computer vision and pattern recognition*. 2016: 1646-1654.
- [20]Tai Y, Yang J, Liu X. Image super-resolution via deep recursive residual network[C]//*Proceedings of the IEEE conference on computer vision and pattern recognition*. 2017: 3147-3155.
- [21]Hui Z, Wang X, Gao X. Fast and accurate single image super-resolution via information distillation network[C]//*Proceedings of the IEEE conference on computer vision and pattern recognition*. 2018: 723-731.
- [22]Zhang Y, Li K, Li K, et al. Image super-resolution using very deep residual channel attention networks[C]//*Proceedings of the European conference on computer vision (ECCV)*. 2018: 286-301.
- [23]Mao X, Shen C, Yang Y B. Image restoration using very deep convolutional encoder-decoder networks with symmetric skip connections[J]. *Advances in neural information processing systems*, 2016, 29.
- [24]Han W, Chang S, Liu D, et al. Image super-resolution via dual-state recurrent networks[C]//*Proceedings of the IEEE conference on computer vision and pattern recognition*. 2018: 1654-1663.
- [25]Kim J, Lee J K, Lee K M. Deeply-recursive convolutional network for image super-resolution[C]//*Proceedings of the IEEE conference on computer vision and pattern recognition*. 2016: 1637-1645.
- [26]Tai Y, Yang J, Liu X, et al. Memnet: A persistent memory network for image restoration[C]//*Proceedings of the IEEE international conference on computer vision*. 2017: 4539-4547.
- [27]Ahn N, Kang B, Sohn K A. Fast, accurate, and lightweight super-resolution with

- cascading residual network[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 252-268.
- [28]Han W, Chang S, Liu D, et al. Image super-resolution via dual-state recurrent networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 1654-1663.
- [29]Lim B, Son S, Kim H, et al. Enhanced deep residual networks for single image super-resolution[C]//Proceedings of the IEEE conference on computer vision and pattern recognition workshops. 2017: 136-144.
- [30]Huang G, Liu Z, Van Der Maaten L, et al. Densely connected convolutional networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 4700-4708.
- [31]Tong T, Li G, Liu X, et al. Image super-resolution using dense skip connections[C]//Proceedings of the IEEE international conference on computer vision. 2017: 4799-4807.
- [32]Tai Y, Yang J, Liu X, et al. Memnet: A persistent memory network for image restoration[C]//Proceedings of the IEEE international conference on computer vision. 2017: 4539-4547.
- [33]Zhang Y, Tian Y, Kong Y, et al. Residual dense network for image super-resolution[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 2472-2481.
- [34]Wang X, Yu K, Wu S, et al. Esrgan: Enhanced super-resolution generative adversarial networks[C]//Proceedings of the European conference on computer vision (ECCV) workshops. 2018: 0-0.
- [35]Sam S M, Kamardin K, Sjarif N N A, et al. Offline signature verification using deep learning convolutional neural network (CNN) architectures GoogLeNet inception-v1 and inception-v3[J]. Procedia Computer Science, 2019, 161: 475-483.
- [36]Lai W S, Huang J B, Ahuja N, et al. Deep laplacian pyramid networks for fast and accurate super-resolution[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 624-632.
- [37]Li J, Fang F, Mei K, et al. Multi-scale residual network for image super-resolution[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 517-532.
- [38]Radford A, Metz L, Chintala S. Unsupervised representation learning with deep convolutional generative adversarial networks[J]. arXiv preprint arXiv:1511.06434, 2015.
- [39]Arjovsky M, Chintala S, Bottou L. Wasserstein generative adversarial networks[C]//International conference on machine learning. PMLR, 2017: 214-223.
- [40]Ledig C, Theis L, Huszár F, et al. Photo-realistic single image super-resolution

- using a generative adversarial network[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 4681-4690.
- [41]Zhu J Y, Park T, Isola P, et al. Unpaired image-to-image translation using cycle-consistent adversarial networks[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2223-2232.
- [42]Lim B, Son S, Kim H, et al. Enhanced deep residual networks for single image super-resolution[C]//Proceedings of the IEEE conference on computer vision and pattern recognition workshops. 2017: 136-144.
- [43]Li J, Fang F, Li J, et al. MDCN: Multi-scale dense cross network for image super-resolution[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2020, 31(7): 2547-2561.
- [44]Yu J, Fan Y, Yang J, et al. Wide activation for efficient and accurate image super-resolution[J]. arXiv preprint arXiv:1808.08718, 2018.
- [45]Zhang K, Zuo W, Gu S, et al. Learning deep CNN denoiser prior for image restoration[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 3929-3938.
- [46]Howard A G, Zhu M, Chen B, et al. Mobilenets: Efficient convolutional neural networks for mobile vision applications[J]. arXiv preprint arXiv: 1704.04861, 2017.
- [47]Ignatov A, Timofte R, Van Vu T, et al. Pirm challenge on perceptual image enhancement on smartphones: Report[C]//Proceedings of the European Conference on Computer Vision (ECCV) Workshops. 2018: 0-0.
- [48]Qi Y, Gu J, Li W, et al. Pulmonary nodule image super-resolution using multi-scale deep residual channel attention network with joint optimization[J]. The Journal of Supercomputing, 2020, 76(2): 1005-1019.
- [49]Zhang S, Yuan Q, Li J, et al. Scene-adaptive remote sensing image super-resolution using a multiscale attention network[J]. IEEE Transactions on Geoscience and Remote Sensing, 2020, 58(7): 4764-4779.
- [50]Mei Y, Fan Y, Zhou Y. Image super-resolution with non-local sparse attention[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 3517-3526.
- [51]Zhang Y, Li K, Li K, et al. Image super-resolution using very deep residual channel attention networks[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 286-301.
- [52]Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7132-7141.
- [53]Woo S, Park J, Lee J Y, et al. Cbam: Convolutional block attention module[C]//Proceedings of the European conference on computer vision (ECCV).

- 2018: 3-19.
- [54]Wang X, Girshick R, Gupta A, et al. Non-local neural networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7794-7803.
- [55]Zhang Y, Li K, Li K, et al. Residual non-local attention networks for image restoration[J]. arXiv preprint arXiv: 1903.10082, 2019.
- [56]Tao Dai, Jianrui Cai, Yongbing Zhang, Shu-Tao Xia, and Lei Zhang. Second-order attention network for single image super-resolution. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 11065–11074, 2019.
- [57]Fei Du, Peng Liu, Wei Zhao, and Xianglong Tang. Correlation-guided attention for corner detection based visual tracking. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 6836–6845, 2020.
- [58]Jun Fu, Jing Liu, Haijie Tian, Yong Li, Yongjun Bao, Zhiwei Fang, and Hanqing Lu. Dual attention network for scene segmentation. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 3146–3154, 2019.
- [59]Juncheng Li, Faming Fang, Jiaqian Li, Kangfu Mei, and Guixu Zhang. Mdcn: Multi-scale dense cross network for image super-resolution. IEEE Transactions on Circuits and Systems for Video Technology, 31: 2547–2561, 2021.
- [60]Jiahui Yu, Yuchen Fan, Jianchao Yang, Ning Xu, Zhaowen Wang, Xinchao Wang, and Thomas Huang. Wide activation for efficient and accurate image superresolution. arXiv preprint arXiv: 1808.08718, 2018.
- [61]Wenzhe Shi, Jose Caballero, Ferenc Huszár, Johannes Totz, Andrew P Aitken, Rob Bishop, Daniel Rueckert, and Zehan Wang. Real-time single image and video super-resolution using an efficient sub-pixel convolutional neural network. In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 1874–1883, 2016.
- [62]Radu Timofte, Eirikur Agustsson, Luc Van Gool, MingHsuan Yang, and Lei Zhang. Ntire 2017 challenge on single image super-resolution: Methods and results. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops, pages 114–125, 2017.
- [63]Marco Bevilacqua, Aline Roumy, Christine Guillemot, and Marie-Line Alberi-Morel. Low-complexity singleimage super-resolution based on nonnegative neighbor embedding. In Richard Bowden, John P. Collomosse, and Krystian Mikolajczyk, editors, British Machine Vision Conference, BMVC 2012, Surrey, UK, September 3-7, 2012, pages 1–10. BMVA Press, 2012.
- [64]Roman Zeyde, Michael Elad, and Matan Protter. On single image scale-up using

- sparse-representations. In International conference on curves and surfaces, pages 711–730. Springer, 2010.
- [65]David Martin, Charless Fowlkes, Doron Tal, and Jitendra Malik. A database of human segmented natural images and its application to evaluating segmentation algorithms and measuring ecological statistics. In Proceedings Eighth IEEE International Conference on Computer Vision. ICCV 2001, volume 2, pages 416–423. IEEE, 2001.
- [66]Jia-Bin Huang, Abhishek Singh, and Narendra Ahuja. Single image super-resolution from transformed self-exemplars. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pages 5197–5206, 2015.
- [67]Yusuke Matsui, Kota Ito, Yuji Aramaki, Azuma Fujimoto, Toru Ogawa, Toshihiko Yamasaki, and Kiyoharu Aizawa. Sketch-based manga retrieval using manga109 dataset. Multimedia Tools and Applications, 76(20): 21811–21838, 2017.
- [68]Yulun Zhang, Yapeng Tian, Yu Kong, Bineng Zhong, and Yun Fu. Residual dense network for image super-resolution. In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 2472–2481, 2018.
- [69]Chao Dong, Chen Change Loy, Kaiming He, and Xiaoou Tang. Learning a deep convolutional network for image super-resolution. In European conference on computer vision, pages 184–199. Springer, 2014.
- [70]Pytorch. <http://pytorch.org>.
- [71]Wang Z, Bovik A C, Sheikh H R, et al. Image quality assessment: from error visibility to structural similarity[J]. IEEE transactions on image processing, 2004, 13(4): 600-612.
- [72]Ledig C, Theis L, Huszár F, et al. Photo-realistic single image super-resolution using a generative adversarial network[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 4681-4690.
- [73]Sajjadi M S M, Scholkopf B, Hirsch M. Enhancenet: Single image super-resolution through automated texture synthesis[C]//Proceedings of the IEEE international conference on computer vision. 2017: 4491-4500.
- [74]Muhammad Haris, Gregory Shakhnarovich, and Norimichi Ukita. Deep back-projection networks for super-resolution. In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 1664–1673, 2018.
- [75]Zhen Li, Jinglei Yang, Zheng Liu, Xiaomin Yang, Gwanggil Jeon, and Wei Wu. Feedback network for image super-resolution. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 3867–3876, 2019.
- [76]Faming Fang, Juncheng Li, and Tieyong Zeng. Softedge assisted network for single image super-resolution. IEEE Transactions on Image Processing, 29: 4656–4668, 2020.

致 谢

时间过得很快,令我难以忘怀的研究生生活也快结束了,这三年的宝贵经历,带来的不仅仅是学术上的收获,还学会了许多为人处世的道理。我想对这段时间对我鼓励和支持的老师、同学、家人、朋友,表达由衷的感谢。

首先,我要感谢我的导师周登文教授,在整个研究生期间给予了莫大的帮助。在周老师的身上,我看到了作为一名科研人员应该有的拼劲和一丝不苟的态度,学无涯且思无尽,无论未来我是否从事这个领域,都会保持这种终身学习的习惯。周老师每周都会留出时间开组会,大家一起学习优秀的论文,周老师还会耐心的听我们汇报工作的进展、遇到的问题,当存在问题时,及时指正,避免走很多弯路,同时也锻炼了我汇报工作时的语言组织能力。在此,谨向周老师表达衷心的感谢。

其次,感谢实验室的小伙伴们,王天生、李珊珊、夏颖、孙涵、李昊闻等同学帮助我解决了许多问题;感谢黄志勇师兄、李文斌师兄、李金新师兄、田金月师姐、马路遥师兄在我的学习过程中提供了很多建议和指导;感谢王婉君师妹、高丹丹师妹、马钰师弟、王凯皓师弟、乌恩师妹、邱连明师妹、刘子涵师弟、刘玉铠师弟的陪伴。感谢大家带着我一起努力向前冲,研究生生活因你们而丰富多彩。

然后,我还要感谢我的父母,我的家人,是他们的鼓励与支持,让我继续前行,他们的无私付出才让我一路坚持到现在。

最后,我要向参与论文评审和答辩的所有专家、老师表示衷心的感谢,感谢你们在百忙之中抽出时间审阅论文,感谢你们提出宝贵的修改意见使我的工作更加完善,老师们辛苦了。

最后的最后,感谢学校为我们提供了一个学习和生活的好环境,由于疫情,部分论文写作工作在国际交流中心隔离期间完成,感谢工作人员和医护人员对我们的照顾,希望新冠疫情能早日结束,也对参与这场无声战役中的所有人员致敬。