

华北电力大学

硕士学位论文

基于多路特征并联的图像超分辨算法研究

Multi-Feature Parallel for Image Super-Resolution

李金新

2021 年 6 月

国内图书分类号：TP39
国际图书分类号：004.9

学校代码：10079
密级：公开

学术硕士学位论文

基于多路特征并联的图像超分辨率算法研究

硕 士 研 究 生：李金新
导 师：周登文教授
申 请 学 位：工学硕士
学 科：计算机科学与技术
专 业：计算机科学与技术
所 在 学 院：控制与计算机工程学院
答 辩 日 期：2021 年 5 月 30 日
授予学位单位：华北电力大学

Classified Index: TP39
U.D.C: 004.9

Thesis for the Master Degree

Multi-Feature Parallel for Image Super-Resolution

Candidate:	Li Jinxin
Supervisor:	Prof. Zhou Dengwen
Academic Degree Applied for:	Master of Engineering
Subject:	Computer Science and Technology
Speciality:	Computer Science and Technology
School:	School of Control and Computer Engineering
Date of Defence:	May 30, 2021
Degree-Conferring-Institution:	North China Electric Power University

摘 要

深度卷积神经网络被广泛应用于单图像超分辨率重建领域,显著提升了重建方法的性能。加深网络深度往往可以获取更高的性能。但是,当前超分辨率重建方法常采用增加卷积层层数或者卷积层个数的方式提高重建图像的性能,当卷积层层数或者个数增加时,模型的参数量,运行时间以及计算量也随之增加。现实世界中,由于硬件设备资源有限,此类方法实际应用中表现大打折扣。本文通过调研分析当前性能优越的单图像超分辨率重建方法,提出一种潜在的解决方法,以提高在资源受限情况下超分辨率图像重建性能。首先,本文提出一个多路特征并联的图像超分辨率重建方法。该方法可以获取低分辨率图像的层次特征信息,通过重建图像的不同方面,显著提高重建性能。其次,本文改进多路特征并联的图像超分辨率重建方法,提出了多路特征并联融合的轻量级图像超分辨率重建方法,在重建性能,模型参数量与计算复杂度方面获得良好的平衡。本文主要贡献如下:

(1) 提出一个特征并联残差块。特征并联残差块采用先扩张后压缩的策略,结构中的第一个卷积层和第二个卷积层被用于扩张图像特征信息的通道,提取丰富的特征信息,第三个卷积层与第四个卷积层用于压缩特征信息的通道,筛选有利于图像重建的图像特征信息。本文将第二个卷积层与第三个卷积层的卷积核尺寸均设置为 1×1 , 相比于其它尺寸的卷积层,随着通道数目的增加,不会显著增加参数量。

(2) 提出一个相关权重模块。相关权重模块根据特征信息,计算每一个特征信息通道的权重,随后分别对各个特征信息通道进行加权处理,使有利于图像重建的特征信息被传递。

(3) 提出一个浅层特征映射单元。浅层特征映射单元,通过不同支路上,不同的尺度卷积层提取丰富的浅层特征信息,丰富的浅层特征信息有助于重建模块重建高质量的图像。

(4) 提出一个多路重建单元。多路重建单元包含三个分支支路,分别将特征信息重建图像的不同方面,将所有重建结果相加,生成最终的重建图像。

关键字: 超分辨率; 层次特征信息; 卷积神经网络; 残差学习;

Abstract

Deep convolutional neural networks are widely used in the field of single-image super-resolution, which significantly improves the performance of the reconstruction method. A lot of methods has made notable achievements by growing the network depth. However, most methods use increasing the number of convolutional layers or the number of convolutional layers to improve the performance of reconstructed images. When the number or number of convolutional layers increases, the parameter amount of the model and the memory capacity occupied also increase. In the real world, due to the limitations of hardware devices, the practical application performance of these methods is greatly reduced. This paper investigates and analyzes the current single-image super-resolution method with superior performance, and proposes a potential solution to improve the performance of super-resolution image reconstruction under resource-constrained conditions. First, this paper proposes a Mutil-Feature Parallel Network. The method can obtain the rich hierarchical feature information of the input image, and significantly improve the reconstruction performance by rebuilding different aspects of the super-resolution image. Secondly, this paper improves the Mutil-Feature Parallel Network, and proposes a lightweight Mutil-Feature Parallel Fusion Network for single image super-resolution, which achieves a good balance in reconstruction performance, number of parameters and computation complexity. The main contributions of this article are as follows:

(1) Propose a parallel residual block. The feature parallel residual block adopts the strategy of first expansion and then compression. The first and second convolutional layers first expand the channel of image feature information to extract rich image feature information. The third and fourth convolutional layers compress features. Information channel, screening image feature information that is conducive to image reconstruction. The second convolutional layer and the third convolutional layer use 1×1 convolutional layers. Compared with convolutional layers of other sizes, as the number of channels increases, the amount of parameters will not be significantly increased.

(2) Propose a correlation weight module. The correlation weight module can calculate the weight of each feature information channel according to the image feature information, and weight each feature information channel separately, so that the feature information that is conducive to image reconstruction can be transmitted. In addition, the adaptive weight module has no parameters.

(3) Propose a shallow feature mapping module. The shallow feature mapping module extracts rich shallow feature information through different branches and different scale convolution layers. The rich shallow feature information helps the reconstruction module to reconstruct high-quality images.

(4) Propose a multiple reconstruction module. The three-way reconstruction module can reconstruct different aspects of the image with the shallow feature information and the deep feature information, and finally add all the reconstruction results to generate the final reconstructed image.

Keywords: super-resolution, hierarchical features, convolutional neural network, residual learning

目录

摘要.....	I
Abstract.....	II
第 1 章 绪论.....	1
1.1 课题背景与意义.....	1
1.2 国内外研究现状.....	2
1.3 主要研究内容与文章结构安排.....	5
1.3.1 主要研究内容.....	5
1.3.2 文章结构安排.....	5
第 2 章 相关技术与基础理论.....	7
2.1 图像超分辨率技术.....	7
2.1.1 图像超分辨率技术概念.....	7
2.1.2 SRCNN 方法.....	8
2.1.3 EDSR 方法.....	8
2.1.4 RDN 方法.....	9
2.1.5 CARN 方法.....	11
2.2 评价指标.....	12
2.2.1 PSNR 指标.....	12
2.2.2 SSIM 指标.....	12
2.3 本章小结.....	13
第 3 章 基于多路特征并联的图像超分辨率算法.....	14
3.1 引言.....	14
3.2 多路特征并联的图像超分辨率算法.....	15
3.2.1 网络结构.....	15
3.2.2 特征并联残差块 (PRB).....	16
3.2.3 相关权重模块 (CW).....	17
3.2.4 多路重建单元 (MRU).....	18
3.3 多路特征并联融合的轻量级图像超分辨率算法.....	19
3.3.1 网络结构.....	19
3.3.2 浅层特征映射单元 (SFMU).....	20
3.4 本章小结.....	21

第 4 章 实验与分析.....22

4.1 引言22

4.2 实验细节22

4.2.1 数据集22

4.2.2 实验参数设置22

4.2.3 对比实验22

4.3 实验结果与分析27

4.3.1 MFPN 实验结果与分析27

4.3.2 MFPPN 实验结果与分析32

4.4 本章小节37

第 5 章 结论与展望.....38

5.1 工作总结38

5.2 工作展望39

参考文献.....40

攻读硕士学位期间发表的论文及其它成果.....44

致谢.....45

第 1 章 绪论

1.1 课题背景与意义

当今科技发展日新月异,科技深深影响着千家万户。人类可以通过互联网获取图像,文字,视频和音频等相关数据信息,大量的数据信息有助于人类在生产生活中平稳发展。相关研究表明,人类主要通过视觉器官得到有效信息,其中人类接收到的视觉有效信息主要来自图形图像^[1]。如果图像质量较低,会阻碍人类从图像中获取有价值的信息,所以提高图像质量已成为热点研究领域。

当前对于图像质量的评估有各种各样的评价指标,其中被人类常用于评价图像的一项重要指标是图像分辨率。图像分辨率是指单位英寸内包含像素个数。图像的分辨率数值越高,图像呈现的视觉效果越显著,纹理与颜色等信息越丰富,反之则出现纹理信息丢失,图像严重模糊等问题。然而,图像采集以及传输过程中容易受到噪音与传感器硬件设备限制等因素影响,出现因图像分辨率降低影响图像质量的问题,使得人类无法获取有效信息。因此,如何提高图像分辨率,最大程度上恢复图像的纹理和颜色等信息是当前最紧要任务。

提高图像分辨率的方法有两种:第一种是提高硬件设备的能力,可以通过使用高精度度的采集设备,传输能力更强的传输设备,从而保证图像在采集和传输中尽量减少硬件因素影响;第二种是通过图像超分辨率(Super-resolution, SR)方法,可以将质量较差的低分辨率(Low-resolution, LR)图像重建为高质量的,语义信息与低分辨率图像相同的高分辨率(High-resolution, HR)图像。考虑到第一种方法容易受到硬件设备的成本与技术因素的限制,往往选择第二种方法。因此,如何设计性能更优越的图像超分辨率技术成为当前图像处理研究的热点之一。

由于图像超分辨率方法对于硬件设备要求较低,在人类的日常生活生产中得到广泛的使用。图像超分辨率方法被应用到人类社会的众多领域,如医学^[2]、监控^[3],卫星遥感^[4]等。

医学方向:越来越多的医生需要通过各种医学成像设备,获取病人的身体状况的详细信息。而许多医学设备如核磁共振、超声波、彩超以及电子计算机断层扫描等,获取的图像往往是低分辨率的,干扰医生对于病灶情况的判断,进而影响患者治疗。而图像超分辨率方法可以将低分辨率的医学图像转变为更加清晰的,准确的高分辨率图像,对于医生诊断和治疗患者提供极大地帮助。

监控方向:为了遏制和防控恶劣事件,如盗窃、抢劫、车祸和天灾,在公共场合中会安装有大量的监控设备。当发生恶劣事件时,有关部门可以通过监控视频获取相关人员情况,通过其中的部分图像获取相关信息,采取和制定相应行动方案。但是,公共场所中的监控设备往往受到周围环境和本身设备的限制,无法

拍摄出清晰的高质量的图像,从而影响工作人员开展工作。使用图像超分辨率方法可以有效提高从监控视频中获取的图像的质量,可实现对重点图像中的重点区域重建,有效的提高了工作人员的效率。

卫星遥感方向:受限于成像设备和大气层自然环境等因素,遥感图像往往无法满足军事、地质监控和农业生产等领域对于图像的需求。由于卫星在高空中采集拍摄遥感图像,图像中相关物体往往较小,甚至只有几个像素点,无法有效获取较小目标信息。图像超分辨率方法可以重建遥感图像为高分辨率图像,为从遥感图像中识别和检测物体提供更加有效的帮助。

1.2 国内外研究现状

图像超分辨率重建理论于 1964 年由 Harris 等人^[5]提出,随后得到众多科学家的关注,并被广泛应用到各个领域^[2-4]。图像超分辨率重建方法分为单图像超分辨率重建(Single image super-resolution, SISR)和多图像超分辨率重建(Multi-frame super resolution)。其中,单图像超分辨率重建指将一幅低分辨率图像重建为高质量的高分辨率图像;多图像超分辨率重建是将多幅低分辨率图像恢复为高分辨率图像。本文主要研究内容为单图像超分辨率重建。

当前,图像超分辨率方法分为基于插值的超分辨率方法^[6-8]、基于重建的超分辨率方法^[9-12]和基于学习的超分辨率方法^[13-25]。

基于插值的图像超分辨率方法是根据图像相关区域内的已知像素信息,通过相关公式计算未知像素值,包括最近邻插值、双线性插值和双三次插值(Bicubic)^[7]。上述的三种图像插值方法是基于多项式计算方式,具有执行速度快,简单易实现和计算复杂度低的优点。然而,仅通过相邻的像素估计未知的像素,只能利用少量信息,忽略了图像的整体结构,导致重建后图像的边缘区域出现模糊、分块和振铃等问题。

众多科研工作者为了缓解由于图像插值方法造成的图像边缘模糊的问题提出基于边缘指导的插值方法。2001 年, Li 等人^[6]提出了 NEDI 方法,使用根据图像对偶性计算的协方差进行插值,提高边缘区域的清晰度和准确性。2012 年,周等人^[8]提出了用于彩色图像的双三次卷积彩色图像插值方法,该方法与其它插值方法相比,显著提高了对于彩色图像的重建性能。基于插值的超分辨率方法对于图像中的先验知识的利用不合理,重建后图像边缘区域容易出现振铃现象,主观视觉效果较差。

基于重建的图像超分辨率方法是首先通过模拟图像降质的逆过程构建图像的退化模型,根据高分辨率图像与低分辨率图像之间的一致性关系生成对应的高分辨率图像。利用傅里叶变换重建图像的频域法是由 Tsai 等人^[9]最先提出。Tekalp 等人^[10]进一步开发了频域法,主要是从图像噪声和传感器模糊入手。频域法存在

对图像中先验知识利用不足的问题,因此众多科技工作者开始研究空域法。代表性方法是 1989 年 Stark 等人^[11]提出基于集合的凸集投影法。1991 年 Irani 等人^[12]提出了迭代反投影法,每次迭代过程是计算从重建后的高分辨率图像中获取的低分辨率图像与需要修复的输入低分辨率图像之间的差值,并将其投影到方法重建后的高分辨率图像中进行修复,反复迭代重建出最终图像。迭代反投影方法具有重建速度快的优点,但是由于无法精准确定反向投影算子,导致方法最终重建的图像结果不唯一。

基于学习的图像超分辨率方法,通过学习图像之间的映射联系,将得到大量的先验知识用于重建图像。基于高分辨率图像特征信息与对应的低分辨率图像特征信息之间的结构具有相似性,Chang 等人^[13]提出了基于邻域嵌入的方法。基于多几何字典学习和集群稀疏编码,2012 年 Yang 等人^[14]提出的图像超分辨率算法显著改善了重建后图像的质量。

近年,基于深度学习的方法被应用于各个领域,用于解决各种问题,并取得显著成效。其中,卷积神经网络可以从图像中提取大量的图像特征信息,并且可以构建复杂的非线性映射关系,被广泛应用到计算机视觉领域。

2014 年,第一个将深度学习与图像超分辨率技术相结合的是 Dong 等人提出的基于卷积神经网络的图像超分辨率网络方法(Super-Resolution Convolutional Neural Network, SRCNN)^[15],随后越来越多的科研工作者开始使用卷积神经网络解决图像超分辨率重建问题。SRCNN 方法中三个卷积层的功能分别为从低分辨率图像中提取图像特征信息并映射至高维、高维特征向量与高维特征向量之间的映射与图像重建。与其它非基于卷积神经网络的超分辨率方法对比, SRCNN 方法重建后的超分辨率图像质量较高。SRCNN 方法具有模型结构简单,卷积层数少(仅包含三层),参数量低的优点。

Dong 等人为了进一步提升 SRCNN 方法计算速度,基于 SRCNN 方法提出了快速图像超分辨率网络(Fast Super-Resolution Convolutional Neural Networks, FSRCNN)^[16]。FSRCNN 方法与 SRCNN 方法对于网络末端的设计不同,FSRCNN 方法使用反卷积层,并且在网络的映射层前使用 1×1 卷积层进行特征通道的压缩操作,在映射层之后使用 1×1 卷积层进行特征通道的扩张操作,上述操作可以降低模型的参数量与运行时间,提升了图像重建效果。

首尔国立大学 Kim 等人^[17]基于残差学习,提出深层的卷积神经网络超分辨率方法(Very Deep Convolutional Networks For Super-Resolution, VDSR)。VDSR 方法为了提取图像的深层特征信息,使用了 20 个卷积层,并且为了使网络在训练中避免梯度消失与梯度爆炸问题, Kim 等人使用了梯度裁剪方法,有关 VDSR 方法的实验结果表明,重建图像的质量优于 SRCNN 方法。Kim 等人为了能够增加网络深度,又限制网络参数的增加,采用可以共享参数的递归结构,提出了 DRCN (Deeply-Recursive Convolutional Network)^[18]方法。

Tai 等人^[19]提出了 DRRN (Deep Recursive Residual Network)方法,同时利用三种结构,分别是局部残差结构、全局残差结构和递归结构。采用共享残差单元的方式,加深网络结构的同时仅增加少量参数,改进 VDSR 方法与 DRCN 方法的性能。

Lai 等人^[20]提出了拉普拉斯金字塔超分辨率网络(Laplacian Pyramid Super-Resolution Network, LapSRN)。LapSRN 方法可以将低分辨率图像逐级重建至 2 倍、4 倍和 8 倍的高分辨率图像。该方法重建放大因子为 8 倍的图像时,可以同时获得放大因子为 2 倍和 4 倍的图像。此外,该方法使用转置卷积进行上采样操作,可以重建图像更精细。在网络的训练过程中,通过使用 Charbonnier 损失函数^[20],监督每一级的图像上采样结果,实现同时训练多种尺寸图像。LapSRN 方法实验结果表明,在重建结果和运行时间方面该方法均有较大优势。

Li 等人^[21]提出的 MSRN (Multi-Scale Residual Network)方法,残差块内首先同时使用 3×3 与 5×5 卷积层从输入信息中提取特征,然后将第一次提取的特征信息进行合并,再次使用 3×3 与 5×5 卷积层分别提取特征信息,并将提取的特征信息进行合并,通过 1×1 卷积操作降低特征维度,实现了提取不同尺度的特征信息,提升了网络性能。

Ahn 等人^[22]提出了结合级联结构与残差学习的级联残差网络(Cascading Residual Network, CARN),具有较小参数量与计算量。CARN 方法的实验结果表明,该方法在模型参数量和性能之间取得了良好平衡。

自 He 等人^[23]提出残差神经网络之后,许多基于卷积神经网络的超分辨率方法开始使用残差学习,搭建深层网络架构。2017 年,Lim 等人^[24]去除了残差块中的规范化模块,优化残差块的结构。通过叠加残差块,设计了一个参数量为 43MB,超过 65 个卷积层的 EDSR(Enhanced Deep Super-Resolution Network)方法,并获得了 2017 年超分辨率比赛冠军^[25]。通过在网络结构最开始处添加不同放大因子的预先训练好的模型,MDSR 方法可以同时获得不同放大因子的重建图像。EDSR 方法通过增加网络深度显著提升了重建图像的质量,表明了增加网络深度可以有效提高网络模型的重建性能。由于 EDSR 方法的网络规模巨大(超出 65 个卷积层),因此需要应用设备具有较高的存储空间,以及强大的计算性能。

Zhang 等人^[26]提出了 RDN (Residual Dense Network)方法,结合残差结构和稠密结构,充分利用从低分辨率图像提取的层次特征信息,进而重建出高质量的高分辨率图像。

1.3 主要研究内容与文章结构安排

1.3.1 主要研究内容

自 2014 年以来, 基于卷积神经网络的 SRCNN 方法表明了基于深度学习的单图像超分辨率技术可以有效重建高质量的超分辨率图像。随后, 越来越多的单图像超分辨率技术被提出, 多数单图像超分辨率方法通过增加卷积层的数目或者通过提高卷积层通道数目方式, 提升方法重建性能。然而, 随着网络中卷积层层数以及卷积层通道数目的增加, 单图像超分辨率方法的模型参数量和运行时间也随之增加。轻量级的单图像超分辨率方法可以极大满足对于应用设备存储容量等硬件方面的要求, 适用于资源有限的移动设备或者对于资源使用有限制需求的其它设备。但是, 轻量级的单图像超分辨率方法的模型容量有限, 导致重建性能较差。如何降低模型规模, 提高重建质量, 并尽可能满足资源受限设备的应用需求成为关键问题。针对上述问题, 本文的主要研究内容如下:

(1) 网络结构的设计是影响图像超分辨率方法性能的重要因素, 本文首先设计了一个重量级的基于多路特征的图像超分辨率方法。该方法由特征并联残差块, 相关权重模块和多路重建单元组成。基于残差学习, 设计了特征并联残差块。残差块内先两次扩张, 然后两次压缩特征通道。扩张通道数目可以保证大量特征信息的提取, 压缩通道数目实现筛选有效特征信息。为了确保特征信息的有效传递, 提出了相关权重模块, 该结构可以通过计算特征信息为残差块设置权重。然后, 构造了多路重建单元, 该单元从每个残差组中接收信息以重构图像的特征信息, 并将所有分支信息相加以生成最终的高分辨率图像。

(2) 通过降低重量级模型卷积层数目和通道数目设置, 可以实现设计轻量级的模型。基于此思路, 本文通过优化基于多路特征的图像超分辨率方法参数设置, 设计了轻量级的多路特征并联融合的图像超分辨率方法。其中, 相关权重模块并不具备参数量, 由于减少特征并联残差块的数目和卷积层通道数目, 减少了相关权重模块计算量。多路重建单元由多个 1×1 卷积层和亚像素的卷积层组成, 参数量较小。为了进一步提取丰富的浅层特征信息, 设计了浅层特征映射单元, 通过每条支路上的不同尺度感受野的卷积层, 提取不同层次的浅层特征信息。

1.3.2 文章结构安排

本文共五章内容, 结构如下:

第 1 章, 绪论。本文在该章节叙述了课题的研究背景与意义, 重点介绍了图像超分辨率技术; 其次, 对国内外有关图像超分辨率技术的研究现状及进展进行介绍与分析, 详细介绍了具有代表性的基于深度学习的超分辨率方法, 如 SRCNN 方法, LapSRN 方法和 MSRN 方法等; 最后, 介绍了本文研究内容与结构安排。

第 2 章, 相关技术与基础理论。该章节首先描述的是图像超分辨率技术概念, 重点分析了与本文相关的 SRCNN、CARN、EDSR 和 RDN 等方法, 并详细介绍各种方法的关键内容和优缺点; 最后, 介绍了用于评价图像超分辨率技术性能的评价指标。

第 3 章, 基于多路特征并联的图像超分辨率算法。该章节首先对多路特征并联的图像超分辨率算法网络结构的设计进行详细介绍。并对本文提出的特征并联残差块结构, 相关权重模块结构以及多路重建单元结构进行介绍与分析; 最后, 介绍和分析本文提出的多路特征并联融合的轻量级图像超分辨率算法网络结构, 阐述了设计网络的原因, 并介绍了本文提出的浅层特征映射单元。

第 4 章, 实验与分析。首先叙述了本文提出的方法在实验中使用的训练数据集, 测试数据集以及网络结构中相关超参数的设置。随后本文进行对比实验, 分析了网络中各个结构中相关参数设计原因; 最后, 从主观视觉与客观指标上, 通过与其它流行方法对比, 详细分析本文提出的算法性能。

第 5 章, 结论与展望。该章节总结了本文内容与工作, 并指出后续工作目标。

第 2 章 相关技术与基础理论

高分辨率的图像可以使人类直观的获取大量有效信息。但是,由于采集设备,传输设备和人为因素,在实际的生产生活中常常无法获得高分辨率的图像。因而,有关图像重建的超分辨率技术得到了广泛的关注。近几年,基于深度学习的超分辨率技术快速发展,与传统方法相比,在图像重建性能上取得优异的表现。本章将对几种经典图像超分辨率技术与评价指标进行相关介绍。

2.1 图像超分辨率技术

2.1.1 图像超分辨率技术概念

通常,低分辨图像是模糊的、包含噪音的甚至存在了几何形变问题^[27]。因此图像的退化过程往往无法确定,大大增加了高分辨率图像恢复的难度。超分辨率重建是一个病态的问题,这是因为许多张不同的高分辨率图像很大程度上会对应着同一幅低分辨率图像,这就造成恢复细节逼真、丰富的高分辨率图像非常困难,如图 2-1 所示。




图 2-1 一张低分辨率图像对应的多张高分辨率图像

超分辨率图像重建过程如公式 2-1 所示:

$$I_{SR} = H(I_{LR}) \tag{2-1}$$

其中, I_{SR} 代表超分辨率图像, $H(\cdot)$ 代表超分辨率重建过程, I_{LR} 代表低分辨率图像, $H(\cdot)$ 将低分辨率图像重建为超分辨率图像。实际上,基于深度学习的图像超分辨率技术的主要工作是设计合理并有效的重建过程。

2.1.2 SRCNN 方法

2014 年 Dong 等人^[15]受基于稀疏表示的超分辨率算法^[28](ScSR)的启发提出了 SRCNN 方法，该方法是最先基于卷积神经网络的超分辨率方法。SRCNN 方法使用卷积神经网络直接学习输入的低分辨率图像与重建目标高分辨率图像之间端到端的映射关系。如图 2-2 所示 SRCNN 方法的网络结构。




图 2-2 SRCNN 方法网络结构图

SRCNN 方法使用的卷积层的卷积核尺寸分别为 9×9 、 1×1 与 5×5 ，具有网络层次浅，参数量较小(57KB)的优点。第一个卷积层的功能是获取低分辨率图像的图像块，再将图像块中的特征信息从低维特征空间映射到高维特征空间。第二个卷积层的功能是将第一个卷积层获取的每个高维特征空间的特征向量非线性映射到另一个特征空间下的高维特征向量。第三个卷积层的功能是整合第二个卷积层获取的所有图像特征，重建图像。

SRCNN 方法的相关实验结果表明，与传统的超分辨率方法相比，该方法有效的提高了重建图像的质量。但是，SRCNN 方法存在巨大的改进空间。SRCNN 方法需要预处理输入的图像，利用双三次插值方法将原始的低分辨率图像上采样至与高分辨率图像尺寸相同。预处理将会导致图像特征信息的丢失，不利于提取原始图像特征信息。并且会出现处理速度慢，运行时间长的问题。SRCNN 方法需要使用数值较小的学习率缓解梯度消失与爆炸问题，使得网络的训练时间增加，收敛速度下降。通常，网络结构越深，模型的感受野越大，提取的特征信息越丰富，可用于图像重建的信息越多。但是，SRCNN 方法仅由 3 个卷积层组成，存在难以从低分辨率图像中获取丰富的高频信息与纹理信息的问题，因此重建图像中高频细节的能力有限，并且浅层网络也无法完全学习海量图像中复杂的映射关系。

2.1.3 EDSR 方法

Lim 等人^[24]提出了重量级的 EDSR 方法，结构如图 2-3 所示，赢得了 2017 年 NTIRE 超分辨率比赛的冠军。EDSR 方法优化了 SRResNet^[29]方法的残差块结

构，去掉了规范化模块，残差块结构如图 2-4 所示。由于同一残差块内，位置相邻的卷积层和规范化模块占用的内存容量相同，因此，去除规范化模块，可以在运行中节省大量内存。实现了在相同的计算资源下，使用 EDSR 方法的残差块可以建立一个更大的模型。在训练过程中，基于预先训练的低尺度模型，训练更高尺度模型，使得模型在训练中更好的利用图像中与尺寸大小无关的信息。




图 2-3 EDSR 方法网络结构图




图 2-4 (a) SRResNet 方法的残差块结构 (b) EDSR 方法的残差块结构

EDSR 方法相关实验表明，在卷积神经网络中，可以通过堆叠卷积层或者增加卷积层的通道数目方式，提高模型的重建能力^[24]。这对后续超分辨率重建工作提供了方向。但简单堆叠卷积层或者增加卷积层的通道数目会导致模型参数量急剧增长。EDSR 方法使用了 65 个卷积层，参数量高达 43MB，在实际应用中存在问题。如何降低模型参数量，并且提高模型的重建性能成为了关键问题。

2.1.4 RDN 方法

通常，随着网络深度的增加，模型中的每个卷积层感受野也随着增加，卷积层将会提取不同层次的特征信息。这些不同层次的特征信息对应着图像中不同的尺度、视角和纵横比的物体，所以来自深层网络的层次特征将为重建图像提供更

多线索。

基于上述思路, Zhang 等人^[26]提出了 RDN 方法, 充分利用网络中所有卷积层的层次特征。如图 2-5 所示 RDN 方法由浅层特征网络、残差稠密块(residual dense Block, RDB)、稠密特征连接和上采样网络组成。残差稠密块结构如图 2-6 所示, 由局部特征融合, 局部残差连接(Local residual learning)以及连续内存组成。残差稠密块使用稠密连接^[30]方式, 实现将前一个 RDB 模块的输出结果以及每个卷积层(当前 RDB 模块)提取特征信息, 直接连接至随后的每一个卷积层, 可以有效提取局部特征信息。另外, RDB 模块也使用了残差连接, 促进特征信息的流动。RDN 方法为了进一步提高对每一个 RDB 模块提取的特征信息的利用率, 合并模型中所有 RDB 模块提取的特征信息, 随后使用 1×1 卷积层融合特征信息, 再利用 3×3 卷积层提取全局的残差信息, 配合使用全局残差连接, 最终实现提取并利用不同层次的特征信息的目的。




图 2-5 RDN 方法网络结构图^[26]




图 2-6 RDB 模块结构图^[26]

RDN 方法实验结果表明, 在退化过程为双三次下采样的不同放大倍数下, RDN 方法效果优于 EDSR 方法, 并且 EDSR 方法参数量为 RDN 方法参数量 2 倍。在 BD(使用标准偏差为 1.6 的尺寸为 7×7 的高斯核对图像进行模糊处理, 随后对模糊处理后的图像下采样 3 倍)^[24]与 DN(先下采样 3 倍, 再增加噪声水平为 30 的高斯噪声)^[24]退化过程下, RDN 方法重建效果显著优于 SRCNN 方法与 FSRCNN 方法。虽然 RDN 方法降低了参数量, 仅为 22.3MB, 但是对于资源受限的设备, 该方法仍难以实际应用。

2.1.5 CARN 方法

尽管基于深度学习的超分辨率方法具有出色的重建性能,但此类方法存在计算量大,参数量多和运行时间长的问题(如 EDSR 方法, RDN 方法),导致资源受限的设备往往无法使用重量级的超分辨率方法。

Ahn 等人^[22]提出一个轻量级的 CARN 方法,用于解决上述问题。基于残差神经结构, Ahn 等人设计了高效残差块模块(Residual-E), 结构如图 2-3(a)所示。高效残差块模块由两个 3×3 的组卷积层和一个 1×1 的卷积层组成。与普通卷积层相比,组卷积层可以通过设置合适的分组大小,进一步降低参数,实现在模型性能与参数量之间达到平衡。如图 2-3(b)所示,级联块是由局部的级联连接方式组合高效残差块模块构成,通过使用局部级联方式可以获取来自多个残差块的特征信息。如图 2-4 所示, CARN 方法总共有 3 个级联块。每一个级联内又由 3 个残差块组成,每一个级联块均利用 1×1 的卷积层,对前面的级联块的输出特征信息进行融合压缩。CARN 方法通过使用全局级联连接和局部级联连接,一方面实现获取各个层级的特征信息,另一方面可以让低层的特征传递到高层,有助于图像的重建。

CARN 方法的相关实验结果表明,通过控制模型参数量,降低了模型计算复杂度,可以为资源受限的设备使用超分辨率方法提供可能。但是, CARN 方法的重建图像的能力, 仍然存在提升的空间。




图 2-3 (a) 高效残差块结构 (b)级联块




图 2-4 CARN 方法网络结构图^[22]

2.2 评价指标

对于超分辨率方法重建后图像质量的评价可分为主观和客观评价，主观评价指标是根据视觉感官感受评价重建后图像质量。主观评价指标容易受到评价个体的影响，不同的个体评价的标准无法统一，存在一定差异。客观评价指标是通过特定的评价函数公式评估图像重建后的质量从而量化评价结果，避免了个体之间的差异。本文采用的客观评价为峰值信噪比(Peak-Signal to Noise Ratio, PSNR)^[31]和结构相似性(Structure Similarity Index Measurement, SSIM)^[32]。

2.2.1 PSNR 指标

PSNR 指标是当前客观评价超分辨率重建方法性能的重要指标之一，通过计算重建后的图像与实际图像在像素级别上的差异，评估重建后的图像质量。PSNR 指标的计算方法如公式 2-1 所示。

$$PSNR = 10 \log_{10} \left(\frac{(2^n - 1)^2}{MSE} \right) \tag{2-1}$$

其中， n 为图像中每一个像素的比特数(实际使用中通常取值为 8)。MSE 计算如公式 2-2 所示。

$$MSE = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W (X(i, j) - Y(i, j))^2 \tag{2-2}$$

其中 X , Y 分别表示重建后的图像与实际图像，图像的高度和宽度分别为 H 和 W 。PSNR 指标的数值越大，表示重建后的图像与实际图像间的差异越小，即重建后的图像的质量越高。PSNR 指标的单位为 dB。

2.2.2 SSIM 指标

SSIM 采用比较重建后的图像与实际图像的亮度，对比度与结构的方式，衡量图像间的相似性。SSIM 指标计算方法如公式 2-3 所示。

$$SSIM(X, Y) = l(X, Y) \cdot c(X, Y) \cdot s(X, Y) \tag{2-3}$$

其中 X 和 Y 分别表示重建后的图像与实际图像, $l(X, Y)$ 是亮度方面的对比, $c(X, Y)$ 是对比度方面的对比, $s(X, Y)$ 是结构方面的对比。计算公式如公式 2-4 所示。

$$\begin{cases} l(X, Y) = \frac{2\mu_X\mu_Y + C_1}{\mu_X^2 + \mu_Y^2 + C_1} \\ c(X, Y) = \frac{2\sigma_X\sigma_Y + C_2}{\sigma_X^2 + \sigma_Y^2 + C_2} \\ s(X, Y) = \frac{2\sigma_{XY} + C_3}{\sigma_X\sigma_Y + C_3} \end{cases} \quad (2-4)$$

其中 μ_X 与 σ_X 分别代表重建后的图像 X 的均值与方差, 通过公式 2-5 可得。

$$\begin{cases} \mu_X = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W X(i, j) \\ \sigma_X = \frac{1}{H \times W - 1} \sum_{i=1}^H \sum_{j=1}^W (X(i, j) - \mu_X)^2 \end{cases} \quad (2-5)$$

其中 μ_Y 和 σ_Y 分别表示为实际图像 Y 的均值与方差, 通过公式 2-6 可得。

$$\begin{cases} \mu_Y = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W Y(i, j) \\ \sigma_Y = \frac{1}{H \times W - 1} \sum_{i=1}^H \sum_{j=1}^W (Y(i, j) - \mu_Y)^2 \end{cases} \quad (2-6)$$

其中 σ_{XY} 表示为重建后的图像 X 与实际图像 Y 的协方差, 通过公式 2-7 可得。

$$\sigma_{XY} = \frac{1}{H \times W - 1} \sum_{i=1}^H \sum_{j=1}^W (X(i, j) - \mu_X)(Y(i, j) - \mu_Y) \quad (2-7)$$

为了避免分母为 0 而导致的系统误差而设置常数 C_1 , C_2 与 C_3 。SSIM 指标越高表示图像间结构相似度越高, 重建方法的性能越强。

2.3 本章小结

本章主要介绍了四种与本文工作相关的图像超分辨率技术以及评价指标。本章首先介绍了图像超分辨率技术的概念, 分析了超分辨率技术的难点。随后, 对 SRCNN 方法, EDSR 方法, RDN 方法与 CARN 方法, 进行了详细介绍。SRCNN 方法是一个浅层网络, 学习能力有限, 重建后的图像质量提升空间很大。EDSR 方法与 RDN 方法是重量级方法, 参数量大, 性能优越。但是, 无法满足资源受限设备的要求。CARN 方法是轻量级方法, 但是, 大量的级联操作导致特征信息冗余, 影响图像重建过程。并且, CARN 方法重建性能仍有提升的空间。最后, 本章介绍了客观评价指标 PSNR 和 SSIM, 是当前评价超分辨率方法性能的最广泛使用评价指标之一。

第3章 基于多路特征并联的图像超分辨率算法

3.1 引言

基于卷积神经网络的超分辨率重建方法模型结构的设计是影响重建方法性能的重要因素之一。SRCNN 方法仅使用三层卷积层解决单图像超分辨率重建问题,并且性能显著优于传统的超分辨率重建方法。然而, SRCNN 方法存在网络层次浅,难以训练等问题。Kim 等人提出了基于残差学习的,网络更深的 VDSR 方法,提高了重建性能。Kim 等人为了在增加网络深度的同时,限制模型参数数量的增加,使用了参数共享的递归结构,提出了 DRCN 方法。Tai 等人提出了利用局部残差结构、全局残差结构和递归结构的 DRRN 方法,通过共享残差单元,仅增加少量参数,使得 DRRN 方法性能超越了 DRCN 方法与 VDSR 方法。Ahn 等人提出了基于级联残差结构的 CARN 方法,使用级联连接与残差连接,使得参数数量和性能取得很好的平衡。

He 等人提出了深层的 ResNet 模型,用于图像分类工作, ResNet 模型的每一个残差单元可以通过获取上一个单元的输出结果学习残差函数,而非原始的函数,使得深层网络的训练变得简单。ResNet 模型表明可以通过加深网络层数的方式提升网络的性能。SRResNet 方法改进了 ResNet 模型中的残差单元,构建更深的网络,获得了更高的重建性能。随后,EDSR 方法通过去除了规范化模块,进一步改善 SRResNet 方法中的残差块结构,并且堆叠了 65 个卷积层,EDSR 方法性能显著提升。Huang 等人^[30]提出的密集连接的卷积神经网络(Dense Connected Convolutional Networks, DenseNet)允许密集块内不同卷积层之间直接连接,即每个卷积层都会接受其前面所有卷积层的输出结果作为其额外的输入信息。DenseNet 模型实现了特征信息复用,促进了特征信息的传递。Tong 等人^[33]基于 DenseNet 模型的密集块结构提出 SRDenseNet 方法,在不同密集块之间使用了密集连接,进一步实现特征信息的复用,提高了重建性能。为了获取输入的低分辨率图像中的所有层次特征信息, RDN 方法引入了残差连接和密集连接,性能显著优于 EDSR 方法。

虽然 EDSR 方法与 RDN 方法性能优越,但是参数量较大, EDSR 方法参数量高达 43MB, RDN 方法参数量高达 22.3MB。EDSR 方法通过提高残差块中卷积层通道数目,获取了高性能,但该方式会引入大量参数。无法满足资源受限设备的要求。DRCN 方法与 DRRN 方法使用递归结构,降低了参数量,但是递归结构会增加大量的计算成本。导致即使 DRCN 方法与 DRRN 方法参数量小,可以用于资源受限的设备,但因为它们的计算量过大,实际应用中仍然存在问题。RDN 方法使用残差连接与密集连接,将网络中提取的所有层次特征信息用于重

建图像，会存在大量的冗余特征信息，而这些信息往往对于重建高分辨率图像没有帮助。

为了解决上述问题，本文首先提出了多路特征并联的图像超分辨率算法(Multi-Feature Parallel Network ,MFPN)。本文设计了使用两次扩张压缩结构的特征并联残差块(Parallel Residual Block, PRB)，与 EDSR 方法残差块不同，本文并没有提高残差块输入与输出特征信息的通道数目，而是使用扩张与压缩的方式，在残差块结构的内部先扩张通道，然后采用压缩方式，保证每两个相邻的残差块结构之间传递的特征信息通道数目一致。PRB 结构扩张通道两次，逐步提取特征信息，然后压缩通道，筛选特征信息，实现了有效提取特征信息的同时降低模块参数量。为了有效利用层次特征信息，本文设计了多路重建单元(multiple reconstruction unit, MRU)。将多个 PRB 结构组合为残差组，多路重建单元将每一个残差组提取的特征信息直接重建为与高分辨率图像相同尺寸的图像，避免因获取所有层次特征信息而导致的信息冗余问题。MRU 结构最终将所有重建后的图像相加，生成图像。为了尽可能满足资源受限设备的应用需求，基于本文提出的 MFPN 方法，本文提出了多路特征并联融合的轻量级图像超分辨率算法(Multi-Feature Parallel Fusion Network ,MFPFN)。

3.2 多路特征并联的图像超分辨率算法




图 3-1 MFPN 方法网络结构图

3.2.1 网络结构

随着网络深度的增加，模型性能提高但是参数量也随着增加。RDN 方法利用了网络中提取的所有层次特征信息，易引入冗余的特征信息，并且方法本身参数量很大。为了在性能与参数规模上取得平衡，本文提出了 MFPN 方法，网络结

构如图 3-1 所示。MFPN 方法主要由特征并联残差块，相关权重模块(Correlation Weight, CW)与多路重建单元组成。

假定模型输入的低分辨率图像为 I_{LR} ，重建后的图像为 I_{SR} ，MFPN 方法首先使用一个 3×3 的卷积层，从 I_{LR} 中提取浅层特征信息，过程如公式 3-1：

$$F_0 = H_{conv}(I_{LR}) \tag{3-1}$$

其中 H_{conv} 表示卷积层操作， F_0 为提取的浅层特征信息。在模型中使用简单堆叠残差块的方式，会影响特征信息的传递。为此，本文将多个 PRB 结构组合为残差组(Residual Group, RG)，并在 RG 结构内增加局部跳跃连接，可以有效的传递特征信息。为了配合 MRU 结构的使用，本文设计了 3 个 RG 结构，每一个 RG 结构提取不同层次的特征信息，计算过程如公式 3-2：

$$F_i = H_{RG_i}(F_{i-1}) \tag{3-2}$$

其中 H_{RG_i} 表示残差组操作， F_i 为提取的特征信息， i 的取值范围为[1,2,3]。MRU 结构将每一 RG 结构提取的特征信息用于重建图像，过程如公式 3-3：

$$I_{SR} = H_{MRU}(F_1, F_2, F_3) \tag{3-3}$$

其中 H_{MRU} 表示多路重建单元操作，它利用所有特征信息重建 SR 图像 I_{SR} 。

3.2.2 特征并联残差块 (PRB)




图 3-2 PRB 结构图

在 EDSR 方法的残差块结构中，每一个卷积层均具有相同的通道数目。该残差块可以用增加特征通道数目的方式，提高模型的性能，但会导致参数数量快速增加。本文提出了如图 3-2 所示的 PRB 结构，它包含两个 3×3 卷积层，两个 1×1 卷积层，ReLU 激活函数和 CW 结构。PRB 结构使用先扩张后压缩的策略，首先使用卷积层扩张特征通道数目，然后使用另一个卷积层压缩特征通道数目，可以有效的获取特征信息，并且仅增加内部通道数目，而不是增加残差块结构的输入与输入通道数目，显著降低了模型参数量。PRB 结构的第一个卷积层的卷积核为 3×3 ，目的是扩张特征通道数目，以获得更丰富的特征信息。第二个卷积层将进一步扩张特征通道数目，设置卷积核为 1×1 用于减缓参数增加。第三个与第四个卷积层的作用是压缩特征通道数目以过滤特征信息，促进对图像重建有意义的特征信息被传递，卷积核被分别设置为 1×1 与 3×3 。并且本文在 PRB 结构中使用

两次跳跃连接，增强了特征信息的流动。PRB 结构使用 1×1 卷积层可以保证在第二次扩张通道数量时，不会导致 PRB 结构参数数量的急剧增加。

假设第 i 个 PRB 结构的输入特征信息与输出特征信息分别为 F_{i-1} 与 F_i 。PRB 结构的计算过程如公式 3-4，3-5 与 3-6：

$$F_m = W_{conv_1}(F_i) \quad (3-4)$$

$$F_n = H_{CW}(W_{conv_3} \sigma(W_{conv_2} F_m)) + F_m \quad (3-5)$$

$$F_{i-1} = H_{CW}(W_{conv_4} \sigma(F_n)) + F_i \quad (3-6)$$

其中 W_{conv_1} ， W_{conv_2} ， W_{conv_3} 与 W_{conv_4} 分别是第一至第四个卷积层的权重(忽略了偏置项)， H_{CW} 表示 CW 结构操作， F_m 与 F_n 表示为 PRB 结构的中间计算量， $\sigma(\cdot)$ 表示 ReLU 激活函数。

3.2.3 相关权重模块 (CW)

深度的基于残差结构的超分辨率重建方法，存在梯度爆炸或者梯度消失问题，出现网络训练的不稳定问题。为了保证网络训练稳定，通常使用残差尺度参数(residual scale)^[34]缓解此问题，残差尺度参数是固定的数值，往往经验设置，不易优化。随着网络深度的增加，每个卷积层中提取特征信息不同，使用固定的残差尺度参数会阻碍有效特征信息的传递。本文提出了 CW 结构，可学习的最优的残差尺度参数。

如图 3-3 所示，CW 结构由不具备参数量的全局平均池化层和 Sigmoid 激活函数两部分组成。在模型中使用 CW 结构时，仅会增加模型的计算量，而不会增加模型的参数量。所有输入特征信息将被全局平均池化层编码为初始权重值。之后，Sigmoid 激活函数将初始权重值调整至 $[0, 1]$ 。由于特征信息之间的差异，CW 结构会为每一个特征通道的信息生成不同的权重值，加强了对重建图像有效的特征信息的传递，改善了网络中梯度的传播。

假设 $X=[x_1, x_2, \dots, x_c]$ 是尺寸为 $H \times W \times C$ 的特征信息，初始权重值为 $Z=[z_1, z_2, \dots, z_c]$ 。全局平均池化层 H_{GAP} 通过计算输入的特征信息 X ，得出初始权重值。输入特征信息的第 c 个通道的初始权重值计算如公式 3-7 所示：

$$z_c = H_{GAP}(x_c) = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W x_c(i, j) \quad (3-7)$$

Sigmoid 激活函数 $f(\cdot)$ 将初始权重值转化为权重向量 V ，如公式 3-8：

$$V = f(Z) \quad (3-8)$$

CW 结构最终的输出结果可由公式 3-9 计算：

$$\hat{X} = X \odot V \quad (3-9)$$

其中 $\hat{X}$ 表示加权后的特征信息， $\odot$ 表示将输入特征 X 的每个通道乘以权重向量 V 的相应元素。




图 3-3 CW 结构图

3.2.4 多路重建单元 (MRU)

当前基于深度学习的超分辨率重建方法通过使用转置卷积或亚像素的卷积^[35]执行上采样操作。对比图像重建的质量，亚像素的卷积比转置卷积性能更优^[36]。然而，当前方法使用亚像素的卷积时，往往配合使用多个 3×3 卷积层，实现上采样操作^[24,26]，导致随着放大因子增加，会显著增加模型的参数量。本文设计了 MRU 结构，可以在不损失图像重建质量的同时，降低参数量。如图 3-1 的 MRU 部分所示，MRU 结构包含三条重建支路，每条重建支路包含 1 个 1×1 卷积层和 1 个亚像素卷积层。MRU 结构在亚像素的卷积操作之前使用 1×1 卷积层，随后使用亚像素卷积层将特征信息直接重建，使得输出结果与 HR 图像尺寸相同。三条重建支路结果相加，重建最终的 SR 图像。这与 EDSR 方法和 RDN 方法上采样操作不同，并没有在亚像素卷积层之后再次利用 3×3 卷积层重建 3 通道的 HR 图像。相较于多次使用 3×3 卷积层而言，MRU 结构仅使用三个 1×1 卷积层，可以极大降低参数，并且随着放大因子的增加，也不会显著增加参数量。同时，MRU 结构通过获取各个支路的特征信息，进行图像重建，可以缓解特征信息的冗余问题，进一步提高重建图像的质量。

假设 $F=[F_1,F_2,F_3]$ 为来自于残差组的层次特征信息，第 i 条重建支路的输出结果 I_i 计算过程如公式 3-10：

$$I_i = H_{up}\left(H_{conv_i}\left(F_i\right)\right) \tag{3-10}$$

其中 H_{up} 表示亚像素卷积层操作， H_{conv_i} 表示第 i 条支路的 1×1 卷积层， $i=[1,2,3]$ 。MRU 生成的 SR 图像可由公式 3-11 计算：

$$I_{SR} = I_1 + I_2 + I_3 \tag{3-11}$$

3.3 多路特征并联融合的轻量级图像超分辨率算法

3.3.1 网络结构

性能优越的 EDSR 方法与 RDN 方法参数量与计算量均较大，难以应用于资源受限的设备。轻量级的 DRRN 方法与 DRCN 方法采用递归结构，通过共享参数方式，降低模型参数量，但计算量较大。设计合理的残差块结构，网络使用非递归结构，是设计轻量级的图像超分辨率方法的一种途径。轻量级的 CARN 方法采用级联方式，使用 1×1 卷积层将特征信息融合，再将其传递给下一个卷积操作。本文认为使用级联方法传递特征，会出现特征信息的冗余问题。并且，浅层特征信息与深层特征信息包含了图像中的不同频率信息，只有合理的使用浅层特征信息与深层特征信息，才能重建高质量的图像。为此，本文提出了基于多路特征并联的轻量级的图像超分辨率算法 MFPPN 方法，网络结构如图 3-4 所示。MFPPN 方法主要由浅层特征映射单元(Shallow Feature Extraction Unit, SFMU)，特征并联残差块，相关权重模块与多路重建单元组成。




图 3-4 (a) MFPPN 方法网络结构图 (b)残差组结构图 (c)符号说明

假定模型输入的低分辨率图像为 I_{LR} ，重建后图像为 I_{SR} ，MFPPN 方法首先使用一个 3×3 的卷积层从 I_{LR} 中提取浅层特征信息 F_0 ，过程如公式 3-12：

$$F_0 = H_{conv}(I_{LR}) \tag{3-12}$$

其中 H_{conv} 表示卷积层操作。与 MFPPN 方法相同，在模型中将多个 PRB 结构组合为残差组，并在 RG 结构内添加局部跳跃连接。计算过程如公式 3-13、3-14 与 3-15：

$$F_{D_1} = H_{RG_1}(F_0) \quad (3-13)$$

$$F_{D_2} = H_{RG_2}(F_{D_1}) \quad (3-14)$$

$$F_{D_3} = H_{RG_3}(F_{D_2}) \quad (3-15)$$

深层特征信息 F_{D_1} , F_{D_2} 与 F_{D_3} 分别由 H_{RG_1} , H_{RG_2} 与 H_{RG_3} 残差组提取。SFMU 结构从 F_0 中进一步提取多尺度, 多层次的浅层特征信息, 计算过程如公式 3-16:

$$(F_{S_1}, F_{S_2}, F_{S_3}) = H_{SFMU}(F_0) \quad (3-16)$$

其中 H_{SFMU} 表示 SFMU 结构的操作, F_{S_1} , F_{S_2} 与 F_{S_3} 是由 SFMU 结构提取的浅层特征信息。本文使用可学习的参数 β_i 和 γ_i , 对 F_{D_i} 与 F_{S_i} 执行合并操作, 得到融合后的特征信息 F_i , 计算过程如公式 3-17:

$$F_i = [\gamma_i F_{S_i}, \beta_i F_{D_i}] \quad (3-17)$$

其中 $[\cdot]$ 表示合并操作, 此处的 i 取值范围为 $[1,2,3]$ 。MRU 结构将所有融合后的特征信息重建为最终的 SR 图像, 如公式 3-18 所示:

$$I_{SR} = H_{MRU}(F_1, F_2, F_3) \quad (3-18)$$

3.3.2 浅层特征映射单元 (SFMU)

通常, 浅层特征信息含有丰富的低频信息。但是, 当前超分辨率重建方法仅使用一个或两个卷积层, 提取低分辨率图像中的浅层特征信息, 对于图像的低频信息获取不充分, 导致模型对于浅层特征信息的利用不足。为了获取大量的低频信息, 本文设计了一个浅层特征映射单元(SFMU), 如图 3-4 的 SFMU 部分所示。SFMU 结构通过使用感受野不同的卷积层, 提取具有更多信息的多尺度、多层次浅层特征信息, 而丰富的浅层特征信息将有助于 MRU 结构重建高质量的 SR 图像。不同于其它超分辨率重建方法使用全局跳跃连接方式合并网络提取的浅层特征信息与深层特征信息, 本文将 SFMU 结构的一个分支支路提取的浅层特征信息与一个 RG 提取的深层特征信息进行合并。并且, 通过可学习的标量权重对合并操作前的特征信息进行加权, 可以实现特征信息的流动, 提高特征信息的利用率, 并且在模型训练中, 可学习标量权重会自动调节, 寻找合适的权重信息。

为了降低 SFMU 结构的计算量与参数量, SFMU 结构先使用 1×1 卷积层缩减输入特征信息的维度。三个不同感受野的卷积层被设置为三条分支支路, 将每个分支支路提取的特征信息, 通过可学习的标量参数权重进行加权操作, 传递至下一个分支支路。实现了特征信息的逐步叠加以及大尺度浅层特征信息的获取, 从而提取了丰富的浅层特征信息。

假设 SFMU 结构提取的浅层特征信息为 F_{S_1} , F_{S_2} 与 F_{S_3} , 可由公式 3-19, 3-20, 3-21 与 3-22 计算得出。

$$F_{S_0} = H_T(F_0) \quad (3-19)$$

$$F_{S_1} = H_{C_1}(F_{S_0}) \quad (3-20)$$

$$F_{S_2} = H_{C_2}(F_{S_0} + \alpha_1 F_{S_1}) \quad (3-21)$$

$$F_{S_3} = H_{C_3}(F_{S_0} + \alpha_2 F_{S_2}) \quad (3-22)$$

其中 H_T 是用于降低通道数目的 1×1 卷积操作, H_{C_1} , H_{C_2} 与 H_{C_3} 代表每个分支支路的卷积层, α_1 与 α_2 是可学习的标量权重参数。

3.4 本章小结

本章首先提出了在性能与参数规模上取得平衡的多路特征并联的图像超分辨率重建方法(MFPN)。MFPN 方法主要由特征并联残差块, 相关权重模块和多路重建单元组成。与 EDSR 方法残差块相比, 采用扩张压缩结构的 PRB 结构可以显著降低模型参数量, 有效传递特征信息。CW 结构通过计算输入特征信息, 生成相应的权重信息, 并对输入特征信息进行加权处理, 与固定的残差尺度参数相比, 进一步促进了 PRB 结构内的特征信息的流动。MRU 结构将每一个残差组提取的特征信息直接重建为与 HR 图像相同尺寸的图像, 重建 HR 图像的不同方面, 过滤了大量冗余特征信息, 增强了重建图像能力。随后, 基于 MFPN 方法, 本文提出了多路特征并联融合的轻量级图像超分辨率算法(MFPFN)。MFPFN 方法主要包含浅层特征映射单元, 特征并联残差块, 相关权重模块与多路重建单元。MFPFN 方法优化了 MFPN 方法的结构, 降低了 MFPN 方法的参数设置。MFPFN 方法分别将 SFMU 结构的每个分支支路提取的特征信息与每个残差组提取的特征信息通过可学习的标量权重加权合并, 由 MRU 结构重建最终图像。SFMU 结构通过使用多条支路上的不同卷积层可以提取多尺度与多层次的浅层特征信息, 提高了方法对浅层特征信息的利用率, 为重建高质量图像提供帮助。

第4章 实验与分析

4.1 引言

本章主要对本文提出的 MFPN 方法与 MFPFN 方法的性能,以及提出的各个模块的有效性进行实验验证与分析。首先,详尽介绍了方法训练中使用的参数设置、超参数设置、数据集、训练方法和各种模块的对比实验。随后,在不同放大因子情况下,将本文提出的方法与其它超分辨率重建方法进行主观视觉和客观指标对比,并详细分析实验结果。

4.2 实验细节

4.2.1 数据集

本文模型使用的训练数据集为 DIV2K 数据集^[25]中的 800 张训练集,该训练集中图像是分辨率 2K 以上的 RGB 图像。本文对训练数据集进行数据增强,将训练集中图像进行 90°旋转和随机水平翻转。实验中使用 Set5^[37]标准测试数据集作为验证集,选用 Set14^[38], B100^[39], Urban100^[40]和 Manga109^[41]共 4 个标准测试数据集作为实验的测试集。

4.2.2 实验参数设置

本文模型训练中,每批次使用 16 个 48×48 尺寸的图像块,并使用参数设置为 $\beta_1=0.9$, $\beta_2=0.999$, $\epsilon=10^{-8}$ 的 ADAM 优化器^[42],并且使用权值归一化处理^[43],初始学习率为 10^{-3} 。本文模型训练了 1000 个迭代周期,每 200 个迭代周期将衰减学习率为原先的一半,使用 L1 损失函数。使用平均峰值信噪比(PSNR)与结构相似性(SSIM)评价模型性能,并使用 PyTorch 实现并在 NVIDIA GeForce RTX 2080Ti GPU 上进行训练。

4.2.3 对比实验

4.2.3.1 MFPN 方法残差组实验

本文中 MFPN 方法使用了三个 RG,每个 RG 又拥有相同数量的 PRB 结构。本文在 Set5 标准测试集上验证 RG 内不同数量的 PRB 结构对 MFPN 方法性能的影响,实验中验证数据集的图像放大因子设置为 2 倍,共设计五组模型。五组模型的每个 RG 内 PRB 结构数量分别被设置为 12, 13, 14, 15 与 16,共训练 300 个迭代周期,其它设置均相同:均使用三个 RG。如表 4-1 所示,当 PRB 的数量为 14 时,模型在性能与模型参数上取得最佳平衡。并且从表 4-1 中可知,PRB

结构数目的增加，导致模型参数量也随着增加，模型的性能并不是一直提升。当 PRB 结构数量从 12 个增加至 14 个时，模型性能随着提升，当 PRB 结构数量从 14 个增加至 16 个时，模型的性能开始下降。这主要是因为随着 RG 中 PRB 结构数量过多增加，梯度信息传递不流畅，部分有效特征信息出现丢失问题，导致 MRU 结构无法获取足够的特征信息，重建相应的高质量 SR 图像。为了获得更好的性能和适当的计算负担，本文将 MFPN 方法的每个 RG 中 PRB 结构数目设置为 14 个。

表 4-1 在 2 倍因子与 300 迭代周期下，MFPN 方法的 RG 内不同数目 PRB 结构的模型在 Set5 数据集上的平均 PSNR 及模型参数量

PRB 数量	模型参数量(MB)	PSNR (dB)
12	7.71	38.18
13	8.35	38.19
14	8.99	38.21
15	9.64	38.19
16	10.28	38.20

4.2.3.2 MFPPN 方法残差组实验

表 4-2 在 4 倍因子与 200 迭代周期下，MFPPN 方法的 RG 内不同数目 PRB 结构的模型在 Set5 数据集上的平均 PSNR 及参数量

PRB 数量	模型参数量(MB)	PSNR (dB)
5	1.23	32.23
6	1.47	32.26
7	1.71	32.25

本文中 MFPPN 方法使用了三个 RG，在每个 RG 中设置 PRB 结构的数量均相同。本文在 Set5 标准测试集上为了验证 RG 内不同 PRB 结构数量对 MFPPN 方法性能的影响，共设置三组模型，RG 内 PRB 结构数量分别被设置为 5，6 与 7，其它设置均相同：实验中设置验证数据的图像放大因子为 4 倍，训练 200 个迭代周期，均使用三个 RG。如表 4-2 所示，当 RG 内 PRB 结构的数量为 6 时，模型在性能与参数量上效果最佳，PSNR 指标为 32.26dB。对比 RG 内设置 PRB 结构数量为 5 的模型时，RG 内 PRB 结构的数量为 6 的模型性能提升了 0.03dB，并且模型参数量仅增加了 0.24MB。与 RG 内 PRB 结构的数量为 6 的模型进行对比，本文发现模型 RG 内 PRB 结构数量被设置为 7 时，模型的参数量增加了

0.24MB，但是性能却降低了 0.01dB。因此，为了使模型性能与参数量取得最佳平衡，本文将 MFPPN 方法的每个 RG 中 PRB 结构数量设置为 6 个。

4.2.3.3 PRB 结构对比实验

本文为了验证 PRB 结构对比 EDSR 方法中的残差块结构在性能与参数量上的优势，在 Set5 标准测试数据集上，进行了迭代周期为 200 的图像的放大因子为 4 倍的超分辨率对比试验。实验中，本文共设计 4 个测试模型，为了方便说明特作标识，分别标记为:模型 I、模型 II、模型 III 与模型 IV。模型 II 使用的网路结构为 EDSR 架构,将残差块中卷积层的输入与输出通道数目由 256 更改为 64，残差块的数目由 32 更改为 18。模型 IV 仅将模型 II 的输入与输出通道数目更改为 72，其它结构的设置均相同。模型 I 是把模型 II 中的 EDSR 方法残差块结构替换为本文提出的 PRB 结构，并且在 PRB 结构的扩张阶段，第一个卷积层输入与输出特征通道数分别设置为 32 与 64，第二个卷积层的输入与输出特征通道数分别设置为 64 与 128；在 PRB 结构的压缩阶段，第三个卷积层输入与输出特征通道数分别设置为 128 与 64，第四个卷积输入与输出特征通道数分别设置为 64 与 32。模型 III 中残差块结构与模型 I 中残差块结构相同，仅 PRB 结构的参数设置不同。模型 III 在 PRB 结构扩张阶段，第一个卷积层输入与输出特征通道数分别设置为 32 与 96，第二个卷积层输入与输出特征通道数分别设置为 96 与 128；在 PRB 结构的压缩阶段，第三个卷积层输入与输出特征通道数分别设置为 128 与 96，第四个卷积输入与输出特征通道数分别设置为 96 与 32。实验中，模型 I、模型 II、模型 III 和模型 IV 的其它参数设置均相同：残差尺度参数设置为 0.1。

结果如表 4-3 所示，可以发现使用 PRB 结构的模型 III 性能最佳，与卷积通道数目为 72 的使用 EDSR 残差块的模型 IV 相比，PSNR 值相同，但是 PRB 结构参数量降低了 13.2KB。与卷积通道数目为 64 的使用 EDSR 残差块的模型 II 对比，参数量仅增加 6.4KB，性能可以提高 0.06dB。通过比较模型 III 与模型 II，模型 IV 可以发现，本文提出的 PRB 结构可以有效降低参数量而不损失性能。对比模型 III 与模型 I，性能提高 0.05dB，表明通过增加第一个卷积层的输出通道数目，可以有效提高 PRB 结构提取特征信息能力，进一步提升 PRB 的性能。

表 4-3 在 4 倍因子与 200 迭代周期下，残差块结构不同的模型在 Set5 数据集上的平均 PSNR 及参数量

通道数目设置 单个模块参数量(KB) PSNR (dB)			
I	32-64-128	53.5	32.12
II	64-64	73.8	32.11
III	32-96-128	80.2	32.17
IV	72-72	93.4	32.17

4.2.3.4 CW 结构对比试验

本文为了验证 CW 结构对 PRB 结构的性能提升是有效的，考虑 4.2.3.3 中模型 I 使用和不使用 CW 结构两种情况。实验中参数设置等均相同：数据集图像的放大因子被设置为 4 倍，共训练 200 个迭代周期。对比实验结果如表 4-4 所示，在 PRB 结构中使用 CW 结构后，模型在 Set5 标准测试数据集上 PSNR 值为 32.20dB，而未使 CW 结构的模型在 Set5 标准测试数据集上 PSNR 值为 32.12dB。实验发现使用 CW 结构后 PSNR 值提升 0.08dB。实验结果表明，CW 结构可以根据特征信息，自动学习到最优的残差尺度参数，有效的帮助 PRB 结构传递特征信息，并且不会增加额外的参数。

表 4-4 CW 结构对模型性能的影响，在 4 倍因子与 200 迭代周期下的 Set5 数据集上的平均 PSNR

CW	PSNR (dB)
使用	32.20
不使用	32.12

4.2.3.5 MRU 结构对比试验

表 4-5 在 4 倍因子与 200 迭代周期下，重建单元不同的模型在 Set5 数据集上的平均 PSNR 及参数量

重建单元	参数量(KB)	PSNR (dB)
EDSR 重建单元	297.16	32.11
MRU	9.36	32.13

本文为了验证 MRU 结构的重建性能，将 4.2.3.3 中模型 II 作为基准模型，将模型 II 中的 EDSR 重建单元更改为 MRU 结构后，与模型 II 进行对比。如表 4-5 所示，两个模型的实验结果分别对应“EDSR 重建单元”行与“MRU”行。可以发现当输入的特征通道数目相同时(通道数目为 64)，MRU 结构的参数量仅有 9.36KB，大约为 EDSR 重建单元参数量(297.16KB)的 1/32。在 Set5 标准测试数据集上，重建结构为 MRU 结构的模型 PSNR 值为 32.13dB，而使用 EDSR 重建单元的模型 PSNR 值为 32.11dB，本文提出的 MRU 结构使模型的 PSNR 值提高了 0.02dB。实验结果表明，本文提出的 MRU 结构使用三条支路，依据不同层次的特征信息，分别重建 HR 图像的不同方面，实现了恢复高质量图像，并且

MRU 结构参数量极低,在通道数目为 64,放大因子为 4 倍时,参数量仅为 9.36KB,有助于构建轻量级模型。

4.2.3.6 SFMU 结构对比试验

本文为了验证 SFMU 结构上不同支路上卷积核大小和不使用 SFMU 结构等多种情况对模型性能的影响,进行放大因子为 4 倍的超分辨率对比实验,训练 200 个迭代周期,使用 Set5 标准测试数据集进行验证。本文在实验中设计了 5 组模型,第一组模型不使用 SFMU 结构;第二组模型使用 SFMU 结构,将 SFMU 结构的三个分支支路上的卷积层卷积核大小均设置为 1×1 ;第三组模型使用 SFMU 结构,将 SFMU 结构的三个分支支路上卷积层卷积核大小均设置为 3×3 ;第四组模型使用 SFMU 结构,将 SFMU 结构的三个分支支路上卷积层的卷积核大小被设置为 5×5 ;第五组模型使用 SFMU 结构,设置 SFMU 结构的三个分支支路上卷积层的卷积核大小依次为 1×1 , 3×3 与 5×5 。第二组模型,第三组模型,第四组模型与第五组模型的结构与 MFPM 方法结构相同,由于第一组模型未使用 SFMU 结构,故模型结构与 MFPM 方法相同。实验中其他参数设置均相同:均使用三个 RG,每个 RG 内共有 6 个 PRB 结构,并且 PRB 结构的通道数目设置均相同,重建结构均为 MRU 结构。

实验结果如表 4-6 所示。本文发现第五组模型,设置 SFMU 结构三条分支支路的卷积核大小依次为 1×1 , 3×3 与 5×5 时效果最好,第五组模型 PSNR 值较第一组模型,第二组模型,第三组模型与第四组模型分别超出 0.04dB, 0.08dB, 0.02dB, 0.01dB。本文认为 SFMU 结构的每一条分支支路被设置不同大小的卷积核,可以获取了不同层次的,不同尺度的浅层特征信息,并且与深层层次特征信息通过可学习参数进行组合使用,使得模型重建性能更加优越。由于未使用 SFMU 结构,第一组模型无法获取足够丰富的浅层特征信息,导致模型重建效果较差。本文发现当所有分支支路使用相同大小的卷积核,且不断增加卷积核大小时,模型参数量会增加,但是模型的重建效果会随着提升,这表明通过获取图像的浅层特征信息有助于重建高质量的 HR 图像。然而,当分支支路的卷积核尺寸均被设置为 1×1 时,与未使用 SFMU 结构的第一组模型相比,PSNR 值降低 0.04dB。本文分析是由于各个分支支路均使用 1×1 卷积层,感受野较小,无法获取多尺度的特征信息,从而获取的浅层特征信息较少,并且容易存在冗余信息,导致效果较差。但是,将 SFMU 结构的各个分支支路均使用 3×3 卷积层的第三组模型 PSNR 值高出第一组模型 PSNR 值 0.02dB,将 SFMU 结构的各个分支支路均使用 5×5 卷积层的第四组模型 PSNR 值高出第一组模型 PSNR 值 0.03dB。本文认为合理设置各个分支支路卷积层的卷积核,通过可学习参数加权上一条支路特征信息,并与输入的特征信息相加计算,可以获取丰富的浅层特征信息。因此,本文将 MFPM 方法中的 SFMU 结构的各个分支支路的卷积核大小分别设置为 1×1 , 3×3 与 5×5 。

表 4-6 在 4 倍因子与 200 迭代周期下，SFMU 结构支路设置不同卷积核的模型在 Set5 数据集上的平均 PSNR

第一个支路卷积层卷积核	第二个支路卷积层卷积核	第三个支路卷积层卷积核	PSNR (dB)
--	--	--	32.22
1×1	1×1	1×1	32.18
3×3	3×3	3×3	32.24
5×5	5×5	5×5	32.25
1×1	3×3	5×5	32.26

4.3 实验结果与分析

本节将分别从主观视觉与客观指标对本文提出的 MFPN 方法与 MFPPN 方法的实验结果进行展示与分析。

4.3.1 MFPN 方法实验结果与分析

4.3.3.1 双三次下采样退化过程的图像重建效果对比

为了评估本文提出的 MFPN 方法在图像退化过程为双三次下采样时的性能，对比了 8 个具有代表性的超分辨率方法：SRCNN^[15]方法，FSRCNN^[16]方法，VDSR^[17]方法，LapSRN^[20]方法，MSRN^[21]方法，EDSR^[24]方法，D-DBPN^[44]方法和 RDN^[26]方法。MFPN 方法与其它对比方法重建图像的放大因子分别为 2 倍，3 倍和 4 倍，本节将从主观视觉，客观指标以及模型参数量等三个方面评价模型的性能。

如表 4-7 所示，本文提出的 MFPN 方法参数量为 9MB，EDSR 方法的参数量是 MFPN 方法的 4.7 倍，RDN 方法参数量是 MFPN 方法的 2.4 倍，D-DBPN 方法参数量(10MB)比 MFPN 方法高出 1MB。虽然与参数量为 6MB 的 MSRN 方法相比，MFPN 方法参数量较高，但是 MFPN 方法性能更优越。如表 4-8，4-9，与 4-10 所示在各个测试数据集上，MFPN 方法重建性能全部高于 D-DBPN 方法与 MSRN 方法。在 Urban100 标准测试数据集的 2 倍与 4 倍放大因子下，MFPN 方法的 PSNR 值平均高于 D-DBPN 方法 0.2dB。在 Urban100 标准测试数据集的 2 倍,3 倍与 4 倍放大因子下,MFPN 方法的 PSNR 值平均高于 MSRN 方法 0.5dB。与 RDN 方法对比，在部分测试数据集上，RDN 方法性能略优，但是 MFPN 方法在客观指标与模型参数量上取得更好的平衡，并且在 Manga109 标准测试数据集的 2 倍，3 倍与 4 倍放大因子下，MFPN 方法的 PSNR 值平均高出 RDN 方法 0.1dB。与 EDSR 方法对比，在 Set14 与 Manga109 标准测试数据集上 EDSR 方法重建性能低于 MFPN 方法，如在 Set14 标准测试数据集上放大因子为 2 倍，3

倍与 4 倍时，MFPN 方法 PSNR 值平均高于 EDSR 方法 0.08dB，其它数据集上性能相当。实验结果表明，与其它超分辨率方法对比，本文提出的 MFPN 方法在客观指标与模型参数量上取得了平衡。

表 4-7 在 4 倍因子下，各个模型的参数量

模型	MSRN	EDSR	D-DBPN	RDN	MFPN
参数量(MB)	6	43	10	22.3	9

表 4-8 在 2 倍放大因子下，各个模型的平均 PSNR 值与 SSIM 值

放大因子	模型	Set14	B100	Urban100	Manga109
×2	Bicubic	30.24/0.8688	29.56/0.8431	26.88/0.8403	30.80/0.9339
	SRCNN	32.42/0.9063	31.36/0.8879	29.50/0.8946	35.74/0.9661
	FSRCNN	32.63/0.9088	31.53/0.8920	29.88/0.9020	36.67/0.9694
	VDSR	33.03/0.9124	31.90/0.8960	30.76/0.9140	37.22/0.9729
	LapSRN	33.08/0.9130	31.80/0.8950	30.41/0.9100	37.27/0.9740
	MSRN	33.70/0.9186	32.23/0.9002	32.29/0.9303	38.69/0.9772
	EDSR	33.92/0.9195	32.32/0.9013	32.93/0.9351	39.10/0.9773
	D-DBPN	33.85/0.9190	32.27/0.9000	32.55/0.9324	38.89/0.9775
	RDN	34.01/0.9212	32.34/0.9017	32.89/0.9353	39.18/0.9780
	MFPN	34.06/0.9210	32.32/0.9013	32.93/0.9351	39.33/0.9781

表 4-9 在 3 倍放大因子下，各个模型的平均 PSNR 值与 SSIM 值

放大因子	模型	Set14	B100	Urban100	Manga109
×3	Bicubic	27.55/0.7742	27.21/0.7385	24.46/0.7349	26.95/0.8556
	SRCNN	29.28/0.8209	28.41/0.7863	26.24/0.7989	30.59/0.9107
	FSRCNN	29.43/0.8242	28.53/0.7910	26.43/0.8080	30.98/0.9212
	VDSR	29.77/0.8314	28.82/0.7976	27.14/0.8279	32.01/0.9310
	LapSRN	29.87/0.8320	28.82/0.7980	27.07/0.8280	32.21/0.9350
	MSRN	30.41/0.8437	29.15/0.8064	28.33/0.8561	33.67/0.9456
	EDSR	30.52/0.8462	29.25/0.8093	28.80/0.8653	34.17/0.9476
	RDN	30.57/0.8468	29.26/0.8093	28.80/0.8653	34.13/0.9484
	MFPN	30.59/0.8469	27.21/0.7385	28.85/0.8655	34.23/0.9486

表 4-10 在 4 倍放大因子下，各个模型的平均 PSNR 值与 SSIM 值

放大因子	模型	Set14	B100	Urban100	Manga109
×4	Bicubic	26.00/0.7027	25.96/0.6675	23.14/0.6577	24.89/0.7866
	SRCNN	27.49/0.7503	26.90/0.7101	24.52/0.7221	27.58/0.8505
	FSRCNN	27.59/0.7535	26.98/0.7150	24.62/0.7280	27.90/0.8517
	VDSR	28.01/0.7674	27.29/0.7251	25.18/0.7524	28.83/0.8809
	LapSRN	28.19/0.7720	27.32/0.7280	25.21/0.7560	29.09/0.8845
	MSRN	28.63/0.7836	27.61/0.7380	26.22/0.7911	30.57/0.9103
	EDSR	28.80/0.7876	27.71/0.7420	26.64/0.8033	31.02/0.9148
	D-DBPN	28.82/0.7860	27.72/0.7400	26.38/0.7946	30.91/0.9137
	RDN	28.81/0.7871	27.72/0.7419	26.61/0.8028	31.00/0.9151
	MFPN	28.83/0.7870	27.72/0.7406	26.61/0.8017	31.07/0.9162




图 4-1 各个超分辨率方法 4 倍放大因子的视觉效果对比

图 4-1 为各种超分辨率方法在 4 倍放大因子下的视觉效果图，可以明显观察出，本文提出的 MFPN 方法对于条纹的恢复效果显著。对比 Urban100 数据集的图像“img024”可以发现，其它对比方法重建的条纹出现模糊，甚至无法恢复条纹，SRCNN 方法，FSRCNN 方法，VDSR 方法，EDSR 方法与 D-DBPN 方法重建后图像的条纹完全模糊，无法辨别条纹数目。虽然 MSRN 方法与 RDN 方法可以重建出条纹，但是在重建后的图像中出现条纹之间重叠问题，仍然无法辨别清楚条纹数量。本文提出的 MFPN 方法可以恢复更清晰的条纹，更加贴近于 HR 图像。对于 Urban100 数据集的图像“img092”， SRCNN 方法，FSRCNN 方法，

VDSR 方法, MSRN 方法与 EDSR 方法无法重建清晰条纹, 并且条纹的方向与原图不一致。RDN 方法重建图像模糊, 并且重建后条纹存在重合, D-DBPN 方法重建的条纹, 与 HR 图条纹方向一致, 但是图像整体模糊, 无法重建图像的上下边缘。本文提出的 MFPN 方法可以清晰恢复图像中的条纹信息, 图像的边缘更加清晰, 并且与 HR 图像条纹的方向, 数量相同。实验结果表明, MFPN 方法可以通过提取层次特征信息, 使用 MRU 结构将不同的层次特征信息重建为 HR 图像的不同方面, 显著增强了重建能力, 提高了图像重建质量。

4.3.3.2 其它退化过程的图像重建效果对比

本文为了验证 MFPN 方法的有效性, 参考文献[24], 分别在 BD 退化方式与 DN 退化方式下测试模型重建性能。BD 退化过程是指使用标准差为 1.6 的, 尺寸为 7x7 高斯核对原高分辨率图像进行滤波, 再对处理后的图像进行 3 倍下采样操作。DN 退化过程是先将高分辨率图像进行双三次下采样 3 倍, 在对下采样后的图像增加 30%的高斯噪音。相较于直接双三次下采样退化过程, 对于经过 BD 退化过程与 DN 退化过程的图像重建更加困难。

在 BD 退化过程与 DN 退化过程下, 本文将 MFPN 方法与其它 5 种先进的超分辨率方法进行了比较: SRCNN 方法, FSRCNN 方法, SRMD^[45]方法, RDN 方法和 SRFBN^[46]方法。每个模型的测试数据为分别经过 BD 与 DN 退化过程处理后的 Set14, B100, Urban100 和 Manga109 标准测试数据集, 实验结果如表 4-11 与 4-12 所示。可以观察到, 在 BD 和 DN 方式退化后的所有数据集上, 本文提出的 MFPN 方法表现最佳。在 BD 退化方式下, MFPN 方法在各个测试数据集上 PSNR 值平均超出 RDN 方法 0.22dB, 平均超出 SRFBN 方法 0.21dB。在 DN 退化方式下, MFPN 方法在各个测试数据集上 PSNR 值平均超出 RDN 方法 0.17dB, 平均超出 SRFBN 方法 0.14dB。表明本文提出的 MFPN 方法重建图像的综合性能更优。

表 4-11 在 BD 退化过程下, 各个模型的平均 PSNR 值与 SSIM 值

模型	Set14	B100	Urban100	Manga109
Bicubic	26.12/0.7106	26.02/0.6733	23.20/0.6661	25.03/0.7987
SRCNN	28.52/0.7924	27.76/0.7526	25.31/0.7612	28.79/0.8851
FSRCNN	24.44/0.7106	24.86/0.6832	22.04/0.6745	23.04/0.7927
SRMD	30.11/0.8364	28.98/0.8009	27.50/0.8370	32.97/0.9391
RDN	30.53/0.8447	29.23/0.8079	28.46/0.8581	33.97/0.9465
SRFBN	30.48/0.8439	29.21/0.8069	28.48/0.8581	34.07/0.9466
MFPN	30.63/0.8459	29.28/0.8088	28.74/0.8624	34.44/0.9485

表 4-12 在 DN 退化过程下，各个模型的平均 PSNR 值与 SSIM 值

模型	Set14	B100	Urban100	Manga109
Bicubic	23.14/0.4828	22.94/0.4461	21.63/0.4701	23.08/0.5448
SRCNN	25.49/0.6580	25.11/0.6151	23.32/0.6500	25.78/0.7889
FSRCNN	23.02/0.5856	23.41/0.5556	21.15/0.5682	22.39/0.7111
SRMD	26.13/0.6974	25.64/0.6495	24.28/0.7092	26.72/0.8424
RDN	26.60/0.7101	25.93/0.6573	24.92/0.7362	28.00/0.8590
SRFBN	26.60/0.7144	25.95/0.6625	24.99/0.7424	28.02/0.8618
MFPN	26.70/0.7158	25.99/0.6630	25.22/0.7488	28.22/0.8653

在图 4-2 中，本文展示了 Urban100 和 Manga109 标准测试数据集下的 BD 和 DN 退化过程的两组重建图像。Urban100 数据集下的“img074”经过了 BD 退化处理，Manga109 数据集下的“ByebyeC-BoY”(B-BoY)经过了 DN 退化处理。与其他方法相比，MFPN 方法可以重建更准确细节的 SR 图像。其它方法存在模糊，条纹错误，以及无法重建错误等问题，而 MFPN 方法重建效果更接近原图。




图 4-2 各个超分辨率方法在 BD 与 DN 退化方式下的视觉效果对比

4.3.2 MFPFN 方法实验结果与分析

为了评估本文提出的轻量级 MFPFN 方法的性能，在 Set14, B100, Urban100 和 Manga109 标准测试集上测试放大因子分别为 2 倍，3 倍，4 倍以及 8 倍图像重建的性能。与轻量级的 SRCNN^[15]方法，FSRCNN^[16]方法，VDSR^[17]方法，DRCN^[18]方法，DRRN^[19]方法，LapSRN^[20]方法，SRMDNF^[45]方法，CARN^[22]方法，SRFBN-S^[46]方法，IMDN^[47]方法，CBPN^[48]方法，MemNet^[49]方法和 MSRN^[21]方法在客观指标与主观视觉上进行对比。

如表 4-13, 4-14, 4-15 与 4-16 所示，在 Set14 标准测试数据集上放大因子为 2 倍，3 倍以及 4 倍情况下，本文提出的 MFPFN 方法比 CARN 方法的 PSNR 值分别高出 0.27dB, 0.11dB 和 0.06dB，并且 MFPFN 方法的参数量比 CARN 方法参数量降低 120KB。所有测试数据集图像放大因子为 4 倍时，MFPFN 方法比 CBPN 方法和 IMDN 方法的 PSNR 值分别平均提高 0.06dB 与 0.16dB。在部分测试数据集上，MSRN 方法的重建效果略好，但是，MFPFN 方法的综合性能更强，MSRN 方法的 4 倍模型参数量(为 6078KB)是本文提出的 MFPFN 方法的 4 倍，在放大因子为 2 倍，3 倍以及 4 倍的 Urban100 与 Manga109 数据集上，MFPFN 方法比 MSRN 方法的 PSNR 值分别平均高出 0.06 dB 与 0.18 dB。在放大因子为 8 倍的所有测试数据集上，MFPFN 方法性能明显优于其它方法，比性能次优的 MSRN 方法，在各个标准测试数据集上的 PSNR 值平均提高 0.16dB。

表 4-13 在 2 倍放大因子下，各个轻量级模型的平均 PSNR 值与 SSIM 值

放大因子	模型	参数量 (KB)	Set14	B100	Urban100	Manga109
×2	SRCNN	57	32.42/0.9063	31.36/0.8879	29.50/0.8946	35.74/0.9661
	FSRCNN	12	32.63/0.9088	31.53/0.8920	29.88/0.9020	36.67/0.9694
	VDSR	665	33.03/0.9124	31.90/0.8960	30.76/0.9140	37.22/0.9729
	DRCN	1774	33.04/0.9118	31.85/0.8942	30.75/0.9133	37.63/0.9723
	LapSRN	813	33.08/0.9130	31.80/0.8950	30.41/0.9100	37.27/0.9740
	DRRN	297	33.23/0.9136	32.05/0.8973	31.23/0.9188	37.92/0.9760
	MemNet	677	33.28/0.9142	32.08/0.8978	31.31/0.9195	37.72/0.9740
	SRMDNF	1513	33.32/0.9150	32.05/0.8980	31.33/0.9200	38.07/0.9761
	CARN	1592	33.52/0.9166	32.09/0.8978	31.92/0.9256	38.36/0.9765
	MSRN	5930	33.70/0.9186	32.23/0.9002	32.29/0.9303	38.69/0.9772
	SRFBN-S	282	33.35/0.9156	32.00/0.8970	31.41/0.9207	38.06/0.9757
	CBPN	1536	33.60/0.9171	32.17/0.8989	32.14/0.9279	-/-
	IMDN	694	33.63/0.9177	32.19/0.8996	32.17/0.9283	38.88/0.9774
	MFPFN	1463	33.79/0.9196	32.20/0.8998	32.40/0.9301	38.88/0.9774

表 4-14 在 3 倍放大因子下, 各个轻量级模型的平均 PSNR 值与 SSIM 值

放大因子	模型	参数量 (KB)	Set14	B100	Urban100	Manga109
×3	SRCNN	57	29.28/0.8209	28.41/0.7863	26.24/0.7989	30.59/0.9107
	FSRCNN	12	29.43/0.8242	28.53/0.7910	26.43/0.8080	30.98/0.9212
	VDSR	665	29.77/0.8314	28.82/0.7976	27.14/0.8279	32.01/0.9310
	DRCN	1774	29.76/0.8311	28.80/0.7963	27.15/0.8276	32.31/0.9328
	LapSRN	813	29.87/0.8320	28.82/0.7980	27.07/0.8280	32.21/0.9350
	DRRN	297	29.96/0.8349	28.95/0.8004	27.53/0.8378	32.74/0.9390
	MemNet	677	30.00/0.8350	28.96/0.8001	27.56/0.8376	32.51/0.9369
	SRMDNF	1530	30.04/0.8370	28.97/0.8030	27.57/0.8400	33.00/0.9403
	CARN	1592	30.29/0.8407	29.06/0.8034	27.38/0.8404	33.50/0.9440
	MSRN	6114	30.41/0.8437	29.15/0.8064	28.33/0.8561	33.67/0.9456
	SRFBN-S	376	30.10/0.8372	28.96/0.8010	27.66/0.8415	33.02/0.9404
	IMDN	703	30.32/0.8417	29.09/0.8046	28.17/0.8519	33.61/0.9445
	MFPFN	1465	30.40/0.8428	29.13/0.8056	28.35/0.8557	33.85/0.9460

表 4-15 在 4 倍放大因子下, 各个轻量级模型的平均 PSNR 值与 SSIM 值

放大因子	模型	参数量 (KB)	Set14	B100	Urban100	Manga109
×4	SRCNN	57	27.49/0.7503	26.90/0.7101	24.52/0.7221	27.66/0.8505
	FSRCNN	12	27.59/0.7535	26.98/0.7150	24.62/0.7280	27.90/0.8517
	VDSR	665	28.01/0.7674	27.29/0.7251	25.18/0.7524	28.83/0.8809
	DRCN	1774	28.02/0.7670	27.23/0.7233	25.14/0.7510	28.98/0.8816
	LapSRN	813	28.19/0.7720	27.32/0.7280	25.21/0.7560	29.09/0.8845
	DRRN	297	28.21/0.7720	27.38/0.7284	25.44/0.7638	29.46/0.8960
	MemNet	677	28.26/0.7723	27.40/0.7281	25.50/0.7630	29.42/0.8942
	SRMDNF	1555	28.35/0.7770	25.68/0.7730	25.68/0.7730	30.09/0.9024
	CARN	1592	28.60/0.7806	27.58/0.7349	26.07/0.7837	30.47/0.9084
	MSRN	6078	28.63/0.7836	27.61/0.7380	26.22/0.7911	30.57/0.9103
	SRFBN-S	483	28.45/0.7779	27.44/0.7313	25.71/0.7719	29.91/0.9008
	CBPN	1197	28.63/0.7813	27.58/0.7356	26.14/0.7869	-/-
	IMDN	715	28.58/0.7811	27.56/0.7353	26.04/0.7838	30.45/0.9075
	MFPFN	1468	28.66/0.7830	27.61/0.7371	26.27/0.7909	30.74/0.9114

表 4-16 在 8 倍放大因子下，各个轻量级模型的平均 PSNR 值与 SSIM 值

放大因子	模型	参数量 (KB)	Set14	B100	Urban100	Manga109
×8	SRCNN	57	23.86/0.5443	24.14/0.5043	21.29/0.5133	22.46/0.6606
	FSRCNN	12	23.94/0.5482	24.21/0.5112	21.32/0.5090	22.39/0.6357
	VDSR	665	23.20/0.5110	24.34/0.5169	21.48/0.5289	22.73/0.6688
	DRCN	1774	24.25/0.5510	24.49/0.5168	21.71/0.5289	23.20/0.6686
	LapSRN	813	24.45/0.5792	24.54/0.5293	21.81/0.5555	23.39/0.7068
	MSRN	6226	24.88/0.5961	24.70/0.5410	22.37/0.5977	24.28/0.7517
	MFPFN	1490	25.02/0.6426	24.80/0.5968	22.46/0.6170	24.60/0.7811




图 4-3 各个轻量级超分辨率方法在放大因子为 4 倍的视觉效果对比

如图 4-3 所示，本文展示了各种对比方法与 MFPFN 方法对于 Urban100 标准测试数据集中的“img012”，“img024”和“img046”图像以及 Manga109 标准测试数据集中的“HighschoolKimengumi_vol20”(HK_vol20)图像的重建效果。观察图像“img012”可以发现，SRCNN 方法，VDSR 方法，LapSRN 方法，IMDN 方法以及 MSRN 方法的重建图像与原 HR 图像的条纹方向相反，Bicubic 插值方法重建图像模糊，在 SRFBN-S 方法与 CARN 方法的重建图像中，仅有右下角条纹方向与原 HR 图相同，图像中其它部分条纹方向与原 HR 图像相反。本文提出的 MFPFN 方法可以准确重建条纹的方向，并且条纹数量相同。本文认为是由于浅层特征映射单元提取了丰富的多层次和多尺度的浅层特征信息，每一个残差组获取了深层次的特征信息，多路重建单元将丰富的深层特征信息与浅层特征信息恢复更精准的条纹信息。在“img046”图像中，Bicubic 插值方法、SRCNN 方法和 VDSR 方法重建的图像非常模糊，LapSRN 方法、CARN 方法、SRFBN-S 方法、IMDN 方法与 MSRN 方法重建的图像严重失真，MFPFN 方法重建的图像更加接近 HR 图。观察“img024”图像，MFPFN 方法与其它方法都存在重建的条纹数目与 HR 图像不一致的问题。但是，其它方法均存在严重模糊和图像失真问题，而 MFPFN 方法重建的图像显著更好，更加的清晰。对于“HK_vol20”图像，其它方法重建的图像眼睛部位出现模糊与走样，MFPFN 方法重建图像的眼睛部分是清晰可视的，显著优于其它方法。

如图 4-4 所示，当图像放大因子为 8 倍时，MFPFN 方法重建图像效果显著优于其它方法。在 Urban100 数据集的“img092”图像中，发现 LapSRN 方法与 MSRN 方法重建图像的条纹方向与原图像相反，并且 LapSRN 方法重建图像模糊，MFPFN 方法的重建图像很接近于 HR 图像。在 Set14 数据集的“ppt3”图像中，本文发现 MFPFN 方法的重建图像比其它方法在图像边缘显著更清晰。




图 4-4 各个轻量级超分辨率方法在放大因子为 8 倍的视觉效果对比

如表 4-17 所示，与其它轻量级模型相比，本文提出的 MFPFN 方法在 Set14 数据集上放大因子为 4 倍的运行时间与性能之间实现了更好的平衡。MFPFN 方法的平均运行时间是 0.021s，比 CARN 方法和 IMDN 方法的平均运行时间分别高出 0.003s 和 0.005s，但在 Set14 数据集上的平均 PSNR 值分别比 CARN 方法与 IMDN 方法高出 0.06dB 和 0.08dB。与 MSRN 方法相比，MFPFN 方法的运行时间降低了 0.01s，并且 MFPFN 方法的 PSNR 值高出 MSRN 方法 0.03dB。

表 4-18 显示了 Set14 数据集上放大因子为 4 倍的计算复杂度和平均 PSNR 值。实验中，使用 1280×720 图像计算 GFLOP^[50]。与 DRCN 方法，DRRN 方法，MemNet 方法和 MSRN 方法相比，MFPFN 方法具有更高的 PSNR 值和更低的 GFLOP。MFPFN 方法的 GFLOP 分别是 DRCN 方法，DRRN 方法，MemNet 方法和 MSRN 方法的 GFLOP 的 1/84、1/58、1/23 和 1/3。MFPFN 方法的 PSNR 值分别比 DRCN 方法，DRRN 方法，MemNet 方法和 MSRN 方法高出 0.64dB，0.45dB，0.4dB 和 0.03dB。与 CARN 方法相比，MFPFN 方法在计算复杂度和性能之间实现了更好的平衡。MFPFN 方法的 GFLOP 比 CARN 方法高出 25.4G。但是，MFPFN 方法的 PSNR 值比 CARN 方法高出 0.06dB。

表 4-17 4 倍放大因子在 Set14 数据集上，各个方法平均运行时间与 PSNR 值

方法	运行时间(s)	PSNR (dB)
CARN	0.018	28.60
MSRN	0.031	28.63
IMDN	0.016	28.58
MFPFN	0.021	28.66

表 4-18 4 倍放大因子在 Set14 数据集上，各个方法的 Flops 值与 PSNR 值

方法	Flops(G)	PSNR (dB)
DRCN	9788.7	28.02
DRRN	6796.9	28.21
MemNet	2662.4	28.26
CARN	90.9	28.60
MSRN	349.9	28.63
MFPFN	116.3	28.66

4.4 本章小节

本章主要对本文提出的 MFPN 方法与 MFPPN 方法进行实验验证,并对各个模块进行对比实验与分析。首先对实验中使用的数据集进行介绍,随后分别对本文提出的 PRB 结构, CW 结构和 MRU 结构进行对比实验分析,随后从主观视觉与客观指标上分析 MFPN 方法与 MFPPN 方法的重建性能。实验结果表明,与 RDN 方法和 EDSR 方法相比,本文提出的 MFPN 方法在模型参数量与重建性能方面取得更好的平衡。与其它轻量级的方法对比, MFPPN 方法在模型参数量,计算复杂度,运行时间与重建性能方面具有极大优势。

第 5 章 结论与展望

5.1 工作总结

图像超分辨率技术可以将图像质量较低的低分辨率图像重建为高质量的,清晰的高分辨率图像,有效的缓解了人类日常生活与工作中获取图像不清晰,模糊和噪音问题。本文通过分析当前先进的超分辨率方法,结合其中的优点,改进不足,从残差块结构和重建结构开展相关研究,提出了多路特征并联的图像超分辨率方法。当前性能优越的超分辨率方法,参数量均在 10MB 以上。为降低模型规模与计算量,提高超分辨率图像的重建质量,尽可能满足资源受限设备的应用需求,本文提出了多路特征并联融合的轻量级图像超分辨率方法。本文主要研究工作总结如下:

本文设计了一个重量级的多路特征并联的图像超分辨率方法。该方法包含模块为:特征并联残差块,相关权重模块和多路重建单元。本文改进了 EDSR 方法的残差块结构,提出了使用先扩张后压缩的策略的特征并联残差块。特征并联残差块内先将特征通道进行两次扩张操作,提取丰富的图像特征信息,然后两次压缩通道数目,进行特征信息的筛选。与 EDSR 方法残差块结构比较,特征并联残差块不需要提高输入信息中的特征通道数目,因此不会提高模型的整体参数量与计算量。为了使特征并联残差块更有效得传递特征信息,本文提出了相关权重模块。该结构不具备参数量,仅通过计算输入的特征信息得出对应权重值,再对输入的特征信息进行加权处理。本文设计了多路重建单元,该单元的每个分支将分别对应的残差组提取的特征信息进行重建,重建结果与高分辨率图像尺寸相同。最终将所有分支重建结果相加,生成最终的超分辨率图像。实验结果表明,与先进的 EDSR 方法和 RDN 方法相比,本文提出的多路特征并联的图像超分辨率方法性能更优越,参数量更少。EDSR 方法参数量是多路特征并联的图像超分辨率方法参数量的 4.7 倍,RDN 方法参数量是多路特征并联的图像超分辨率方法参数量的 2.4 倍。

为了满足资源受限设备的实际需求,本文通过优化多路特征并联的图像超分辨率方法网络结构,设计了多路特征并联融合的轻量级图像超分辨率方法。该方法包含模块为:特征并联残差块,相关权重模块,多路重建单元和浅层特征映射单元。为了获取丰富的浅层特征信息,提高重建质量,本文设计了浅层特征映射单元,使用不同感受野大小的卷积层,分别提取不同层次的浅层特征信息。相关权重模块仅有计算操作,不具备参数,随着特征并联残差块的数目和内部卷积层通道数目的减少,可以降低模型整体参数量和计算量。多路重建单元仅包含三个 1×1 卷积层和三个亚像素卷积层,随着通道数目的降低,参数量与计算量减少。

大量的实验证明了多路特征并联融合的图像超分辨率方法的卓越性能。与其他代表性的轻量级方法相比，多路特征并联融合的图像超分辨率方法可以在性能，参数量与计算量之间实现更好的平衡。

5.2 工作展望

本文提出了重量级的多路特征并联的图像超分辨率方法和多路特征并联融合的轻量级图像超分辨率方法。实验结果表明本文提出的方法均有优越的性能，可以重建高质量图像。然而，本文提出的方法仍有改进的空间，主要为以下几点：

(1) 本文提出的多路特征并联的图像超分辨率方法与多路特征并联融合的轻量级图像超分辨率方法对于图像中规则形状和结构的重建，效果显著，如何进一步提高重建不规则形状和结构的性能，是未来的研究工作重点。

(2) 本文提出的方法与 EDSR 方法，RDN 方法，和 CARN 方法等相同，只能重建放大因子为指定大小的图像，后续将实现重建任意尺度的超分辨率图像。

参考文献

- [1] Gonzalez R C, Woods R E. Digital Image Processing[M]. 电子工业出版社, 2007
- [2] Oktay O, Bai W, Lee M, et al. Multi-input Cardiac Image Super-Resolution Using Convolutional Neural Networks[C]. International Conference on Medical Image Computing and Computer-Assisted Intervention. Springer, Cham, 2016:246-254
- [3] Rasti P, Uiboupin T, Escalera S, et al. Convolutional Neural Network Super Resolution for Face Recognition in Surveillance Monitoring[M]. Articulated Motion and Deformable Objects. Springer International Publishing, 2016:175 -184
- [4] Luo Y, Zhou L, Wang S, et al. Video Satellite Imagery Super Resolution via Convolutional Neural Networks[J]. IEEE Geoscience & Remote Sensing Letters, 2017, 14(12):2398-2402
- [5] Harris J L. Diffraction and Resolving Power[J]. Journal of the Optical Society of America, 1964, 54(7):931-93
- [6] Li X, Orchard M T. New edge-directed interpolation[J]. IEEE Trans Image Process, 2001, 10(10):1521-1527
- [7] 钟宝江, 陆志芳, 季家欢. 图像插值技术综述[J]. 数据采集与处理, 2016, 31(6):1083-1096
- [8] 周登文, 申晓留. 边导向的双三次彩色图像插值[J]. 自动化学报, 2012, 38(4):525-530
- [9] Freeman W T, Jones T R, Pasztor E C. Example-Based Super- Resolution[J]. Computer Graphics and Applications, 2002, 22(2): 56 -65
- [10] Tekalp A M, Ozkan M K, Sezan M I. High-resolution image reconstruction from lower-resolution image sequences and space varying image restoration[C]. IEEE International Conference Acoustics, Speech and Signal Processing, 1992, 3:169-172
- [11] Stark H, Oskoui P. High-resolution image recovery from image-plane arrays, using convex projections[J]. Journal of the Optical Society of America, 1989, 6:1715-1726
- [12] Irani M, Peleg S. Improving resolution by image registration[J]. CVGIP: Graphical Models and Image Processing, 1991, 53(23):231 -239
- [13] Chang H, Yeung D Y, Xiong Y. Super-resolution through neighbor embedding[C]. IEEE Conference on Computer Vision and Pattern Recognition, Washington, DC, USA, 2004: 275-282.
- [14] Yang S, Wang M, Chen Y, et al. Single-Image Super-Resolution Reconstruction via Learned Geometric Dictionaries and Clustered Sparse Coding[J]. IEEE Transactions on Image Processing, 2012, 21(9):4016-4028.
- [15] Dong C, Loy C C, He K, et al. Learning a Deep Convolutional Network for Image

- Super-Resolution[J]. 2014:184-199
- [16] Dong C, Chen C L, Tang X. Accelerating the Super-Resolution Convolutional Neural Network[J]. 2016:391-407
- [17] Kim J, Lee J K, Lee K M. Accurate Image Super-Resolution Using Very Deep Convolutional Networks[J]. 2015:1646-1654
- [18] Kim J, Lee J K, Lee K M. Deeply-Recursive Convolutional Network for Image Super-Resolution[C]. 2016 IEEE Conference on Computer Vision and Pattern Recognition, Las Vegas, Nevada, USA, IEEE, 2016: 1063-6919
- [19] Tai Y, Yang J, Liu X. Image Super-Resolution via Deep Recursive Residual Network[C]. IEEE Conference on Computer Vision and Pattern Recognition, Hawaii, USA, IEEE, 2017: 2790-2798.
- [20] Lai W, Huang J, Ahuja N, et al. Deep Laplacian Pyramid Networks for Fast and Accurate Super-Resolution[C]. IEEE Conference on Computer Vision and Pattern Recognition, Hawaii, USA, IEEE, 2017: 5835-5843.
- [21] Li J, Fang F, Mei K, Zhang G. Multi-scale residual network for image super-resolution[C]. European Conference on Computer Vision. Zurich, Switzerland, Springer, Cham, 2018:517-532
- [22] Ahn N, Kang B, Sohn K A. Fast, accurate, and lightweight super-resolution with cascading residual network[C]. European Conference on Computer Vision. Zurich, Switzerland: Springer, Cham, 2018: 252-268
- [23] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[C]. Computer Vision and Pattern Recognition. IEEE, 2016:770-778
- [24] Lim B, Son S, Kim H, et al. Enhanced Deep Residual Networks for Single Image Super-Resolution[C]. 2017 IEEE Conference on Computer Vision and Pattern Recognition Workshops. Honolulu, HI, USA, IEEE, 2017:1132-1140
- [25] Timofte R, Agustsson E, Gool L V, et al. Ntire 2017 Challenge on Single Image Super-Resolution: Methods and Results[C]. 2017 IEEE Conference on Computer Vision and Pattern Recognition Workshops. Honolulu, USA, IEEE, 2017:1110-1121
- [26] Zhang Y, Tian Y, Kong Y, Zhong B, Fu Y. Residual Dense Network for Image Super-Resolution[C]. 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition, Salt Lake City, USA, IEEE, 2018:2472-2481
- [27] 崔顺. 基于深度学习的图像超分辨率重建技术研究[D]. 西安: 西安电子科技大学, 2017
- [28] Yang J, Wright J, Huang T S, et al. Image super-resolution via sparse representation[J]. IEEE Transactions on Image Processing, 2010,19(11):2861-2873
- [29] Ledig C, Theis L, Huszár F, et al. Photo-Realistic Single Image Super-Resolution Using a Generative Adversarial Network[C]. 2017 IEEE Conference on Computer Vision and Pattern Recognition, Honolulu, HI, USA, 2017:105-114
- [30] Huang G, Liu Z, Van Der Maaten L, et al. Densely Connected Convolutional

- Networks[C]. 2017 IEEE Conference on Computer Vision and Pattern Recognition, Honolulu, HI, USA, 2017:2261-2269
- [31] Huynh-Thu Q, Ghanbari M. Scope of validity of PSNR in image/video quality assessment[J]. Electronics Letters, 2008, 44(13):800-801
- [32] Wang Z, Bovik A C, Sheikh H R, et al. Image quality assessment: from error visibility to structural similarity[J]. IEEE Transactions on Image Processing, 2004, 13(4):600-612
- [33] Tong T, Li G, Liu X, et al. Image Super-Resolution Using Dense Skip Connections[C]. 2017 IEEE International Conference on Computer Vision, Venice, Italy, 2017:4809-4817
- [34] Szegedy C, Ioffe S, Vanhoucke V, et al. Inception-v4, inception-resNet and the impact of residual connections on learning[C]. Thirty-First AAAI Conference on Artificial Intelligence. San Francisco, USA, AAAI Press, 2017: 4278-4284
- [35] Shi W, Caballero J, Huszár F, et al. Real-time Single Image and Video Super-Resolution Using an Efficient Sub-Pixel Convolutional Neural Network[C]. 2016 IEEE Conference on Computer Vision and Pattern Recognition, Las Vegas, NV, USA, IEEE, 2016:1874-1883
- [36] Wang Z, Chen J, Hoi S C H. Deep learning for image super-resolution: A survey[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020,1-1
- [37] Bevilacqua M, Roumy A, Guillemot C, et al. Low-Complexity Single-Image Super-Resolution based on Nonnegative Neighbor Embedding[C]. 23rd British Machine Vision Conference. Guildford, UK, BMVA Press, 2012:1-10
- [38] Zeyde R, Elad M, Protter M. On Single Image Scale-Up Using Sparse-Representations[C]. International Conference on Curves & Surfaces. Berlin, Heidelberg, Springer, 2010:711 -730
- [39] Martin D, Fowlkes C, Tal D, et al. A database of human segmented natural images and its application to evaluating segmentation algorithms and measuring ecological statistics[C]. IEEE International Conference on Computer Vision. Vancouver, BC, Canada, IEEE, 2001:416-423
- [40] Huang J B, Singh A, Ahuja N. Single Image Super-Resolution from Transformed Self-Exemplars[C]. 2015 IEEE Conference on Computer Vision and Pattern Recognition, Boston, MA, USA, 2015:5197 – 5206
- [41] Matsui Y, Ito K, Aramaki Y, et al. Sketch-Based Manga Retrieval Using Manga109 Dataset[J]. Multimedia Tools and Applications, 2017,76(20):21811–21838
- [42] Kingma D P, Ba J. Adam: A method for stochastic optimization. arXiv preprint arXiv:1412.6980. 2014
- [43] Samlins T, Kingma D P. Weight Normalization: A Simple Reparameterization to Accelerate Training of Deep Neural Networks[C]. NIPS'16 Proceedings of the 30th International Conference on Neural Information Processing Systems. Barcelona, Spain. IEEE, 2016:901-909

- [44] Haris M, Shakhnarovich G, Ukita N. Deep Back-Projection Networks for Super-Resolution[C]. 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition, Salt Lake City, UT, USA, 2018:1664–1673
- [45] Zhang K, Zuo W, Zhang L. Learning a Single Convolutional Super-Resolution Network for Multiple Degradations[C]. 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition, Recognition, Salt Lake City, UT, USA, 2018:3262–3271
- [46] Li Z, Yang J, Liu Z, et al. Feedback Network for Image Super-Resolution[C]. 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition, Long Beach, CA, USA, 2019:3862–3871
- [47] Hui Z, Gao X, Yang Y, et al. Lightweight Image Super-Resolution with Information Multi-distillation Network[C]. 27th ACM International Conference on Multimedia. New York, USA: Association for Computing Machinery, 2019:2024-2032
- [48] Zhu F, Zhao Q. Efficient Single Image Super-Resolution via Hybrid Residual Feature Learning with Compact Back-Projection Network[C]. 2019 IEEE/CVF International Conference on Computer Vision Workshop. Seoul, Korea, IEEE, 2019:2453-2460
- [49] Tai Y, Yang J, Liu X, et al. Memnet: A persistent memory network for image restoration[C]. 2017 International Conference on Computer Vision. Venice, Italy, IEEE, 2017:4539-4547
- [50] Zhang X, Zhou X, Lin M, et al. Shufflenet: An extremely efficient convolutional neural network for mobile devices[C]. 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition, Salt Lake City, UT, USA, IEEE, 2018:6848–6856

攻读硕士学位期间发表的论文及其它成果

发表的学术论文

- [1] 第一作者. 基于多层次特征融合的图像超分辨率重建[J]. 自动化学报, 2020. (EI 刊源)
- [2] 第三作者. 一种轻量级的多尺度通道注意图像超分辨率重建网络[J]. 电子学报, 2020. (EI 刊源)
- [3] 第三作者. Dual-path Attention Network for Single Image Super-Resolution[J]. Expert Systems with Applications. (SCI 刊源)

致谢

硕士研究生就读期间，得到了导师，朋友和家人的帮助与关心，在此向他们表示衷心的感谢。

衷心感谢我的导师周登文教授对我的辛苦栽培。周老师认真严谨地教学与科研精神，深深的影响了我。周老师在课堂上对于知识点的讲解深入浅出，积极与学生交流，认真批改学生作业。在研究课题阶段，周老师放弃自己的假期休息时间，与我们讨论实验中遇到的难题，为我们解答疑惑，使我的科研得以顺利开展。周老师以身作则，严谨认真，一丝不苟的精神，深深的打动了我，是我学习的榜样。

衷心感谢实验室的伙伴们，黄志勇，李文斌同学。课题研究中，两位同学帮我解决了许多难题，不断的支持和鼓励我。感谢段然师姐、赵丽娟师姐、周鹏师兄、柴晓亮师兄，以及田金月师姐、孙秀秀师姐、马路遥师兄的帮助。感谢王天生师弟、李珊珊师妹、李艺攀师妹、梁木师弟、马钰师弟、王凯峰师弟、王婉君师妹、高丹丹师妹、陈一鸣等同学的陪伴与支持，从他们身上学习到了很多有意义的东西。

最后，感谢我的家人对我的鼓励与支持，家人的信任是我最大的助力。衷心感谢！