

华北电力大学

学术硕士学位论文

基于嵌套残差图像超分辨率算法研究

Nested Residual Network for Image Super-Resolution

李文斌

2021 年 5 月

国内图书分类号: TP39
国际图书分类号: 004.9

学校代码: 10079
密级: 公开

学术硕士学位论文

基于嵌套残差图像超分辨率算法研究

硕 士 研 究 生: 李文斌

导 师: 周登文教授

申 请 学 位: 工学硕士

学 科: 计算机科学与技术

专 业: 计算机科学与技术

所 在 学 院: 控制与计算机工程学院

答 辩 日 期: 2021 年 5 月

授予学位单位: 华北电力大学

Classified Index: TP39
U.D.C: 004.9

Thesis for the Master Degree
Nested Residual Network for Image Super-Resolution

Candidate:	Li Wenbin
Supervisor:	Prof.Zhou Dengwen
Academic Degree Applied for:	Master of Engineering
Subject:	Computer Science and Technology
Speciality:	Computer Science and Technology
School:	School of Control and Computer Engineering
Date of Defence:	May,2021
Degree-Conferring-Institution:	North China Electric Power University

摘 要

单图像超分辨率重建是计算机视觉领域经典问题,旨在从一个给定的低分辨率图像中恢复出高分辨率图像。近年来,基于深度卷积神经网络的图像超分辨率技术取得了突出进展,许多有效方法相继被提出。但是,当前大多数方法通过简单堆叠残差块方式增加网络深度,虽然提升了网络性能,但是不可避免引入大量参数,限制了在移动或嵌入式等资源受限设备中的使用。本文提出了一种轻量级嵌套残差超分辨率网络,旨在构建一种参数量少、视觉效果良好,客观性能与计算复杂度之间取得较好平衡的网络模型。具体来说,本文创新点如下:

(1) 本文提出了多尺度特征融合块提取多样化特征。当前许多方法使用单一尺度卷积核提取特征,忽略了许多特征信息。在多尺度特征融合块中,我们并列不同感受野的卷积核提取特征,使用级联操作融合提取到的多尺度特征。一方面确保提取的特征信息更加多样化,为重建高质量图像提供丰富的细节信息;另一方面有利于特征信息的融合。此外,我们使用递归方式组织多尺度特征融合块,在增加网络深度的同时不增加网络参数量。

(2) 本文提出了通道搅乱注意模块,便于特征通道之间信息流动,增强特征选择能力。近年来,许多基于卷积神经网络的方法都忽略了特征通道之间的相互依赖性,阻碍了网络的表示能力。我们结合通道搅乱和注意机制的优势,提出了通道搅乱注意模块。其中,通道搅乱运算能够促进通道之间信息的流动,注意机制能够增强网络对特征的选择能力,进而提高了网络的表示能力。

(3) 本文提出了全局特征融合连接便于提高浅层特征的利用率,减少图像信息的丢失。一般来说,浅层特征包含大量低频信息。为充分利用这些低频信息,全局特征融合连接将浅层特征融合到网络的每一个阶段,有利于深层特征与浅层特征的融合。此外,不同于一般的全局特征融合(如逐点相加或级联操作)方式,我们使用逐点卷积对浅层特征实现跨特征通道的信息交互与融合,有利于特征信息的流动,减少图像信息的丢失,提高浅层特征的利用率。

关键字: 注意机制; 多尺度特征; 卷积神经网络; 深度学习; 超分辨率

Abstract

Single-image super-resolution reconstruction is a classic problem in the field of computer vision, which aims to recover a high-resolution image from a given low-resolution image. In recent years, image super-resolution based on deep convolutional neural networks has made outstanding progress and many effective methods have been proposed gradually. However, most of the current methods increase the network depth by simply stacking residual blocks. Although the network performance is improved, a large number of parameters are inevitably introduced, which limits the use in resource-constrained devices such as mobile or embedded devices. In this paper, we propose a lightweight nested residual super-resolution network, which aims to construct a network that has a small amount of parameters, better visual results, and a good balance between objective performance and computational complexity. Specifically, the innovations of this methods are as follows:

(1) We proposed a multi-scale feature fusion block (MSFFB) to extract diverse features. Many current methods use a single-scale convolution kernel to extract features, ignoring a lot of feature information. In the multi-scale feature fusion block, we juxtapose the convolution kernels of different receptive fields to extract the features, and use the concatenate operation to fuse the extracted multi-scale features. On the one hand, it ensures that the extracted feature information is more diversified and provides rich detail information for reconstructing high-quality images; on the other hand, it is conducive to fuse the feature information. In addition, we use recursive manner to organize multi-scale feature fusion blocks which can increase the depth of the network without increasing the amount of parameters.

(2) We proposed channel shuffle attention mechanism (CSAM) module, which can encourage the flow of the information across channels and enhance the networks' abilities to select features. Recently, most CNN-based SISR methods have ignored the interdependence between feature channels and hinders the networks' representational abilities. We propose the CSAM by combining the advantages of attention mechanism and channel shuffle. The channel shuffle operation can encourage the flow of the information across channels and enhance the networks' abilities to select features, and thus their representation abilities.

(3) We proposed global feature fusion operation (GFFC), which can improve the utilization of shallow features and reduce the loss of image information. Generally speaking, the shallow features contain abundant low frequency information. In order to

make full use of these low-frequency information, the GFFC is introduced in our method to fuse the low-frequency information into each stage of the network and to maximize the use of the one. In addition, unlike general global feature fusion operations (such as element-wise or concatenate operations), we use point-wise convolution to realize cross-channel interaction and information fusion for shallow features, which is conducive to the flow of feature information and reduces image information. The loss of this improves the utilization of shallow features.

Keywords: Attention mechanism, multi-scale features, convolutional neural network, deep learning, super-resolution

目录

摘要	I
Abstract	II
第 1 章 绪论	1
1.1 课题背景及研究意义	1
1.2 国内外研究现状	2
1.2.1 基于插值的超分辨率技术	2
1.2.2 基于重建的超分辨率技术	3
1.2.3 基于学习的超分辨率技术	3
1.3 主要研究内容	4
1.4 本文章节安排	5
第 2 章 相关方法综述	7
2.1 卷积神经网络	7
2.2 SRCNN	10
2.3 多尺度特征提取模块	11
2.3.1 Inception 模块	11
2.3.2 多尺度残差块	12
2.4 注意机制	12
2.5 图像质量评价	14
2.5.1 PSNR	14
2.5.2 SSIM	15
2.6 本章小结	16
第 3 章 基于嵌套残差网络图像超分辨率	17
3.1 引言	17
3.2 算法总体框架	18
3.2.1 网络结构	18
3.2.2 特征级联组	19
3.2.3 全局特征融合连接(GFFC)	19
3.2.4 嵌套块(NU)	19
3.2.5 层次特征融合块(HFFB)	20
3.2.6 基本嵌套单元(BNC)	21
3.2.7 多尺度特征融合块(MSFFB)	21
3.2.8 通道搅乱注意力模块(CSAM)	22
3.3 本章小结	23
第 4 章 实验与分析	24
4.1 引言	24
4.2 数据集	24
4.2.1 训练集	24
4.2.2 测试集	24
4.3 实验细节	25
4.3.1 实验参数设置	25
4.3.2 超参数 R、G、H 和 M 的设置	25
4.3.3 消融试验	26

4.4 结果与分析 28

4.5 本章小结..... 34

第5章 结论与展望 36

5.1 论文工作总结..... 36

5.2 未来工作展望..... 37

参考文献..... 38

攻读硕士学位期间发表的论文及其它成果 43

致谢 44

第 1 章 绪论

1.1 课题背景及研究意义

随着人工智能时代的到来,图像承载着互联网上许多的信息,网络上的图像迅猛的增长。移动互联、社交物联、移动支付等都拓宽了互联网的应用范围,互联网中各种图像、音频、视频等数以亿计的增长。有关研究表明,眼睛是人类观察物理世界的最重要和最快速的方式,而互联网中 75%的内容都与视觉有关^[1]。因此,对视频和图像处理技术的研究是一件非常有意义的科研任务。

自 1960 年代以来,计算机视觉(Computer Vision)的算法已经以各种形式出现,但是机器学习的最新进展以及数据存储、主要计算力以及市场上便宜的显示器质量的提高,推动了软件水平的重大提高。例如,降低图像的噪声、显著的对比度提升或图像的上下左右旋转操作都可以在图像的像素上执行,并且不需要对图像有复杂的了解,从而可以对其中发生的事情有所了解。计算机视觉的每个方向都有很大的应用场景,尤其在这个智能时代,自动驾驶、智能机器人、工业产品故障的检测以及重要场所的人脸识别系统等,都有着重要的商业使用,方便了人们的生活,改善了人类的社会方式。

日新月异的科学技术发生着天翻地覆的改变,以前的图像质量太差,人们对图像的要求变高了。而且硬件技术的发展到了一定瓶颈时期,在硬件方面,当前水平太低,不能提升图像的主观效果。因此,必须从软件方面考虑进一步提高图像质量,应运而生的技术随之大力发展。基于深度学习的单图像超分辨率重建技术成为了图像界研究的重要任务之一。一方面,相较于传统方法,基于深度学习的方法显著提升了图像的质量,优于一切传统方法;另一方面,该技术相对比较简单,能节省需要人力成本,简化了操作流程,方便实现。当前,图像超分辨率(Super-Resolution, SR)重建技术主要在视频监控^[2]、遥感图像^[3]、医疗诊断^[4]等有着广泛应用。

(1) 公共安全领域。一般情况下,受大风大雾大雨等恶劣天气的干扰,监控摄像头拍摄到的视频质量很差,许多图像都不清晰,存在严重模糊,大大影响了安保领域的前景。因此,大力提高监控图像的质量非常迫切,超分辨率图像重建技术正好能解决这一难题,得到了安保行业的一致认可。其基本思想是获取低分辨率输入并将其放大到高分辨率的任务。

(2) 卫星遥感领域。卫星遥感成像在航空航天和军工领域有着极其重要的应用,但是恶劣的天气依旧严重影响卫星的拍摄,往往拍摄到的图像辨识度很低,严重影响科学家的判断,这对于严格的军事来说,是一种致命的缺点,因此,如何便捷高效的恢复高质量的遥感图像是军工领域一件极具挑战性的任务。

(3) 医疗成像领域。当前医学界主流使用的医学成像技术主要有射线成像、

核磁共振成像、核医学成像和超声波成像四类。通过扫描仪器获取的图像往往质量较低,影响医生对疾病的分析。所以,通过超分辨率重建技术得到清晰的医疗图像,可以帮助医生正确分析疾病,节省医生工作体力。

由此可知,图像超分辨率重建技术在社会中有着大量的使用,广阔的市场决定着这一技术商用范围很广。近年来,图像超分辨率重建再次成为学者的研究热点之一,而且相较于传统方法,基于卷积神经网络的超分辨率重建技术获得的图像具有清晰的纹理和丰富的细节信息,导致图像超分辨率技术大踏步的前进。

1.2 国内外研究现状

单图像超分辨率重建(Single Image Super-Resolution, SISR)是计算机视觉领域的一个经典问题,旨在从给定的低分辨率图像(Low-Resolution, LR)中恢复出对应的高分辨率图像(High-Resolution, HR)。众所周知,单图像超分辨率重建技术是计算机视觉领域一个病态的逆问题,一个输入低分辨率图像一般对应很多个超分辨率图像,常见的重建超分辨率图像自身具有很多比较严重的问题,比如大量特征细节的丢失、边缘有振铃效应和模糊不清等。当前单图像超分辨率重建主要有三类:(1) 基于插值的超分辨率技术^[5-8]; (2) 基于重建的超分辨率技术^[9-12]; (3) 基于学习的超分辨率技术^[13-26]。

1.2.1 基于插值的超分辨率技术

基于插值的超分辨率是最简单的图像重建技术,图像插值技术由来已久,作为图像处理的关键任务,一般用于缩小或放大图像,或者提升图像的分辨率。在这方面已经做了很多工作。已经开发了各种技术。一些数码相机使用插值法生成比捕获的传感器更大的图像,或者创建数字变焦。几乎所有的图像编辑软件都支持一种或多种插值方法。插值方法有很多:选择邻近像素值插值、镜像插值、简单复制、求取两个像素平均值作为需要插入的值、Bicubic等。插值方法的工作原理基本相似。各种方法之间的差异在于所选择的插值模型。在每种情况下,为了确定插值像素的值,定位输入图像中输出像素所对应的点。然后,通过计算该点附近某组像素的加权平均值,为输出像素分配一个值。权重基于每个像素到该点的距离。这些方法在所考虑的像素集方面也有所不同。

为了解决传统插值类方法的缺陷。Li^[5]等人首先提出了根据边缘像素值大小指导的插值算法,具体来讲就是先计算输入的模糊图像的局部协方差系数,然后再计算输出的高清图像的协方差系数,然后根据二者之间的几何对偶性,使用协方差估计值自适应插值。与传统的线性插值算法相比,该算法显著提高了插值图像的主观效果。

Sun等^[6]人利用了局部结构的图像梯度化方法,根据先验正则化过程实现插

值,从模糊图像估计高清图像时,可以约束图像梯度,生成的高分辨率图像具有罕见的振铃或锯齿状伪像。Zhang和Wu^[7]于 2008 年提出一种软决策自适应的插值算法(SAI),该方法使用二维分段自回归模型学习低分辨率图像的映射,还可以根据场景结构的变化做出自适应调整。Giachetti^[8]等人提出了基于曲率的迭代插值方法,该方法对需要插值的像素不断迭代校正,该插值像素根据图像强度的二阶梯度最小化目标函数而获得。

1.2.2 基于重建的超分辨率技术

Xu^[9]和Shan^[10]等人提出一种自动增强图像/视频分辨率的上采样方法,能有效保留必要的图像结构信息,该方法不仅简单而且有效。Kim^[11]提出了单图像超分辨率的基本框架,主要原理是根据输入和输出图像对,学习从低分辨率图像到超分辨率图像的相互关系,提出了一种稀疏的解决方案,该方案主要整合了随机梯度下降的想法。Xiong^[12]提出了一种将自适应正则化和基于学习的超分辨率相结合的实用解决方案。首先,该方法分析迭代正则化过程中的图像能量变化特征,即原始(例如边缘、脊和角)和非原始场之间的能量变化比。基于所揭示的能量变化率的收敛特性,可以确定适当的正则化强度以很好地平衡压缩伪影的去除和原始分量的保留。

1.2.3 基于学习的超分辨率技术

基于学习的方法则是利用大量的训练数据集,从中学习输入图像和目标图像之间某种对应关系,然后根据学习到的映射关系来计算低/高分辨率之间对应的图像,从而实现超分辨率图像的重建。

Dong^[13]等人第一次将CNN用于SISR中,通过端到端的方式学习低分辨率图像和高分辨率图像之间的非线性映射关系。SRCNN网络结构简单,只有三个卷积层,但是性能显著优于传统方法。之后,Dong等人又提出了FSRCNN^[14],主要目的在于加速SRCNN模型,性能得到了进一步的提升。VDSR^[15]首次采用残差学习的方式加深了网络层数,使得越深的网络层提取更多的复杂特征。一般来讲,残差图像的特征图像素值比较少,大部分像素值都为 0 或者更小,所以计算起来所用算力少,收敛很快。VDSR还使用了一种全新的技术:自适应梯度裁剪(Adjustable Gradient Clipping)技术,不仅加速梯度下降过程,同样缓解了反向传播中梯度爆炸/消失问题。DRCN^[16]使用更多的卷积层扩大网络感受野,有效避免引入过多网络参数量,将递归方式引入到网络结构中,有效提升了网络性能。SRDenseNet^[17]在稠密块(Dense Block)中将提取到的每层输出传递给网络深层,级联(Concatenate)所有层的特征,而不是像残差网络那样将输出特征通过加法运算合并^[18]。SRGAN^[19]将生成对抗网络(Generative Adversarial Network,GAN)引入到

了超分辨率重建任务中。SRGAN选择均方误差(Mean Square Error, MSE)训练网络,其效果很好,能获得很高的客观指标,但是恢复出来的超分辨率图像往往会丢失许多高频细节,主观视觉效果较差。SRGAN利用感知损失和对抗损失来提升图像主观效果。

EDSR^[20]认为批规范化处理(Batch Normalization, BN)操作无效且占用大量内存,因此直接删掉了这一操作。残差网络最开始用于图像分类任务,后来直接把残差网络的思想用到了超分辨率重建这样的基础任务中。相比于一般的残差块,批规范化层消耗了占据同样大小的内存资源,然而直接删掉批规范化层后,在占据同样的内存资源下,EDSR可以通过堆叠更多的残差块加深网络,进而提取更多复杂特征,大大提升网络性能。MSRN^[21]提出了一种多尺度残差块(MSRB)作为MSRN的特征提取模块。首先,使用MSRB提取种类和大小不同的图像特征,可以将其视为局部多尺度特征。其次,将每个MSRB的输出级联在一起,相当于执行一个全局特征融合。最后,融合局部和全局特征,尽可能提高低分辨率图像特征的利用率,有效避免了浅层特征在网络传输中的消失问题。最后,引入了一个以 1×1 卷积核作为瓶颈层的卷积层来获得全局特征融合。此外,MSRN还使用了一个设计良好的重构结构,该结构简单但高效,并且可以很容易地迁移到任何较大的缩放因子。

RCAN^[26]首次将注意机制(Attention Mechanism)引入超分辨率重建中,通道注意力(Channel Attention, CA)机制模块根据特征通道之间的相互关系,自适应调整每个通道的特征,加强重要特征的传递,抑制次要特征的传输。

各种基于深度学习的超分辨率重建网络层出不穷,性能不断提升。但是,网络也随之越深,训练网络需要的计算成本大幅增加,不利于各种移动等嵌入式设备,限制了超分辨率的实用价值,因此如何设计一种轻量级图像超分辨率网络,使其更适合于资源受限的设备,是当前亟需解决的一大难题。

1.3 主要研究内容

近年来,随着深度学习技术的快速发展,许多先进方法通过加深网络层数提高性能。虽然能重建出高质量的超分辨率图像,但是训练网络需要占据大量的内存空间,参数数量和计算量也大幅增加,这显然不利于资源受限的移动和嵌入式设备中,影响了超分辨率的实用价值。本文提出了一种轻量级嵌套残差超分辨率网络,旨在构建一种在参数量和性能之间取得较好平衡的网络模型,提升图像超分辨率重建的质量,更好的适合于资源受限的移动等设备上。具体来讲,本文主要研究内容有如下三点:

(1) 本文提出了多尺度特征融合块(MSFFB),使用多种尺寸不同的卷积核(5×5 、 3×3 和 1×1)提取特征,充分提取图像包含的特征信息,从而使得提取的

特征更加多样化,为重建高质量图像提供丰富的细节信息。MSRN首次提出了多尺度残差块(MSRB),但是,MSRB结构中四个卷积核之间参数不共享,参数量较大,占据大量内存空间,不利于网络训练。两个多尺度层结果级联在一起,产生许多特征信息冗余,导致训练时间较长。为解决该问题,基于MSRB结构,我们提出了MSFFB提取图像特征。具体来讲,我们分别去掉了MSRB两个支路中的一层 5×5 和 3×3 卷积核,并采用了递归结构,便于加深网络。我们的递归结构较深,显著减少了参数量。此外,我们也简化了级联运算操作,两个支路提取的特征只级联一次,减少了特征信息的冗余。

(2) 本文提出了通道搅乱注意模块(CSAM),方便提取到的特征信息在通道之间流动,并且有利于增强网络对特征的选择能力。虽然通道搅乱在shuffleNet中提出,有效提高了图像分类准确率并减少了计算量。但是,我们首次引入到图像超分辨率重建中,实验也证明了这种用法是有效的。对MSRN网络的分析得出,MSRB模块中的局部残差连接将浅层信息直接传递到深层,忽略了特征之间的相关性,影响了网络性能。为解决该问题,我们提出了通道搅乱注意力模块。结合通道搅乱操作和注意力机制的优势,完美融合它们对特征的处理能力,有效提高了网络对图像特征的使用。其中通道搅乱运算主要促进了通道信息的流动,而注意力机制增强了网络对特征的选择能力。

(3) 本文提出了全局特征融合连接(GFFC),便于充分利用大量低频信息。一般来讲,浅层特征包含大量低频信息。为充分利用这些低频信息,我们提出的全局特征融合连接使用逐点卷积将浅层特征融合到网络的每一个阶段,进而提高浅层特征的利用率,减少图像信息的丢失,恢复更多重建图像细节。具体讲,我们使用逐点卷积先局部的融合浅层特征,然后与嵌套块的输出级联在一起,融合到网络的每一阶段。

1.4 本文章节安排

本文一共分五个章节,具体安排如下:

第一章,绪论。本章最开头部分详细介绍了单图像超分辨率重建技术的基础知识;其次总结了国内外对超分辨率重建技术的最新进展,重点总结了近年来的研究热点——基于深度学习的单图像超分辨率重建方法;

第二章,相关方法综述。本章节主要介绍了CNN的发展现状,包括卷积神经网络的基础知识、网络架构及优点。其次,介绍了基于CNN的SISR开山之作SRCNN,以及单图像超分辨率重建网络架构(主要有特征提取、非线性映射和重建模块三部分)。最后,介绍了本文方法相关的基础知识:(1) 多尺度特征提取结构。首先由GoogleNet^[28]提出了Inception结构,通过并列不同大小的滤波器提取特征,极大的提高了图像分类准确率。其次, Li等人提出的MSRN方法,首次将多

尺度残差块引入图像超分辨率重建技术中，得到了高清图像。(2) 注意机制。本节着重介绍了注意机制的发展历史、核心思想和多种注意机制模块的结构。此外，还介绍了单图像超分辨率重建的常用客观评价指标，包括主观视觉效果和客观指标。

第三章，基于嵌套残差的图像超分辨率研究。本章节主要提出了本文方法，一种轻量级的嵌套残差的图像超分辨率研究算法(NRSR)。针对当前主流方法所存在的问题，即大参数量网络需要更多计算成本，不利于资源受限的移动等嵌入式设备上的使用。为解决该问题，本文设计了一种新的递归网络结构，不同于一般的堆叠残差块方式组织网络架构，而是采用一种模块嵌套模块的方式，结合递归方式的优点，在减少网络参数数量的同时增加网络深度。此外，详细介绍了NRSR网络的整体结构及主要模块。

第四章，实验与分析。本章主要介绍了训练所使用的主流标准数据集、训练策略、参数设置等。通过大量实验验证了本文提出模块的有效性以及各种超参数的设置。并对本文方法的有效性做了详细分析。最后，分别与当前主流方法做了对比，大量实验表明了本文方法的有效。

第五章，结论与展望。本章对全文做了最终的总结，并为后续工作的研究指出了具体方向。

第2章 相关方法综述

2.1 卷积神经网络

人工神经网络的原理主要受到大脑神经系统的运行方式的启示。人工神经网络主要由众多的神经元节点相互连接而组成一个整体,其中的神经元节点分布式的套在一起,一起学习输入以得到最优的输出。在人工神经网络中,通常将多维矢量的图像传到输入层,然后,隐藏层将图像做出处理,并根据前一层的结果做出相应决定,通过权衡自身内部的随机变化,如何贬低或增加最终输出,这就是所谓的学习过程。彼此之间通过叠加多个隐藏层的过程通常称为深度学习。

卷积神经网络(CNN)由纽约大学的Yann LeCun于1998年提出,与传统的ANN类似,一般由可以自我优化的神经元组成。每个神经元可以接收输入端的输入,并执行相关运算,这是无数ANN的知识基础。从输入的原始图像矢量到类评分的最终输出,整个网络仍将表达单个感知评分函数(权重)。最后一层将包含与类相关的损失函数,并且为传统ANN开发的所有常规技巧仍将适用。

卷积神经网络之所以广为流行,原因就是局部连接和共享权重两大特点,一方面减少了权值的数量,并且使得网络易于优化,另一方面减少了神经网络过拟合的风险。卷积神经网络生物神经网络有异曲同工之妙,它的两大特点不仅可以降低了网络模型的复杂度,还能有效减少网络的参数数量。当网络的输入是多维度的低分辨率图像时,其性能往往特别好,因此图像可以直接放到网络中,规避了传统识别算法中复杂特征的提取和数据重建过程。卷积捕获平移不变性(即卷积核与位置无关)功能更高效,大大减少了参数数量,因此使网络更易于优化并且对数据大小的依赖性降低。与常规神经网络相比,卷积神经网络的隐藏层具有几个维度并且排列在一起:通道、宽度、高度和最简单的二维情况下的滤波器数量一样。卷积神经网络就像多层感知机一样由一系列层组成,每个层都通过另一个可微函数转换前一层的激活或输出。一般在处理平面图像时有很多优点,根据不同图像提取不同图像特征,主要包括一些最明细的颜色、简单纹理形状、整体图像轮廓等;在处理二维图像的位置移动识别、原图像的缩小放大等实际应用上具有很好的鲁棒性和运算效率。

卷积神经网络是一种有监督的机器学习模型,具有很强自适应能力,擅长于提取图像局部特征和全局特征,它的权值共享这一优势更像生物神经网络,在模式识别和视觉领域取得了很大的进步。卷积神经网络有以下两大特点:稀疏连接和权重共享。




图 2-1 卷积神经网络结构图

卷积神经网络的基本原理是给定一组输入和输出，然后通过学习的方式确定二者之间关系，这种关系类似于一种相似性映射关系，不是确定的数学关系。只根据目前已知的计算机视觉模式来训练超分辨率网络，就可以得到这一基本映射。卷积神经网络的训练集是一种类似于：(输入图像，标签图像)的向量组对构成，所有这些向量对都是来源于真实世界的的数据。在开始训练网络之前，都需要对网络中的滤波器进行相应初始化，所有的权重向量都被初始化为一些不一样的随机数，否则卷积核后的结果都是同一个特征。随机数“不同”是保证网络中的卷积核提取不同特征，避免提取到的特征具有同一性。实际上，假如使用一样的参数去做权重向量的初始化，那么超分辨率网络就没有任何的学习的能力了。

卷积神经网络结构的组成部分包括：输入层、卷积层、池化层、全连接层、输出层，如图 2-1 所示。每一层包含许多特征图，也就是常说的图像特征。下面主要介绍每一层的基础知识。

卷积层：由若干滤波器组成，每个滤波器的权重参数都是通过最小化损失函数不断优化得到的。对图像做卷积运算主要在于提取不同的图像特征，第一个卷积层主要提取一些低频的图像信息，如图像的边、轮廓、纹理等，较深卷积层主要是从低级特征中不断循环获得更多繁杂的特征。

池化层：旨在逐渐减小表示的维数，从而进一步减少参数的数量和模型的计算复杂性。池化层主要是对经过激活之后的特征图进行操作，并使用“Max”函数减小图像尺寸。在网络中，一般以最大池化函数的形式出现，大小为 2×2 的内核沿着输入图像的尺寸，步长为 2。这样可以将输入图像尺寸缩小到原来的是四分之一，同时将深度保持不变。

全连接层：一般在网络最后面，卷积神经网络将输出展平并视为单个向量。在使用卷积神经网络时，有必要意识到，对于具有 n 个通道的特征图，可以应用内核大小为 1 和 m 个输出通道的卷积滤波器，这等效于将相同的具有 m 个输出的完全连接层应用于特征图中的每个点。

激活层：通常在卷积和全连接层之后使用非线性函数来激活隐藏层节点。激活函数主要是激活网络中一部分节点，将激活后的信息传入后面的网络中。激活函数的主要作用就是在神经网络中引入非线性因素，是一种对卷积神经网络模型

的补充，将必要的特征信息保留并传给深层网络。常见激活函数如下：




图 2-2 常用激活函数图像

(1) Sigmoid是常用的非线性激活函数，如图 2-2 (a)所示，值域为 $[0,1]$ ，它的数学形式如下：

$$f(x) = \text{sigmoid}(x) = \frac{1}{1 + e^{-x}} \quad (2-1)$$

缺点：(1) Sigmoid函数饱和使梯度消失。(2) Sigmoid函数的输出不是零中心的。

(2) tanh函数，值域为 $[-1,1]$ ，如图 2-2 (b)所示，它的数学形式如下：

$$f(x) = \tanh\left(\frac{e^x - e^{-x}}{e^x + e^{-x}}\right) \quad (2-2)$$

缺点：仍具有梯度消失问题。

(3) ReLU函数，值域为 $[0, +\infty]$ ，如图 2-2 (c)所示，它的数学形式如下：

$$f(x) = \max(0, x) \quad (2-3)$$

优点：(1) ReLU函数能加速反向传播时随机梯度的下降。(2) sigmoid和tanh激活函数都包含指数形式函数，一般来讲需要很大的计算力，而ReLU函数只是一

个简单判断运算，不需要太多内存资源。

缺点：在训练的时候，ReLU函数比较脆弱，并且因网络太深而导致梯度传递不下去容易“死掉”。

(4) PReLU函数，值域为 $[0,+\infty]$ ，如图 2-2 (d)所示，它的数学形式如下：

$$f(x) = \max(\alpha x, x) \tag{2-4}$$

其中， α 可以通过反向传播学习得到。

PReLU函数针对ReLU函数的缺点提出改进方案。在PReLU中，小于零部分的斜率是根据数据自适应变化的。

2.2 SRCNN

近些年来，深度学习技术的发展日新月异，基于卷积神经网络的图像超分辨率技术取得了卓越的成果。Dong等是第一个提出SRCNN网络的优秀架构，作为深度学习在超分辨率重建领域的开山大作，重建效果比以往任何的传统方法都要好。SRCNN网络结构如下图 2-3 所示：

SRCNN主要包含三个模块，主要为图像的浅层特征提取模块、特征非线性映射模块和最终的重建模块。三个卷积层使用的滤波器尺寸分别是 5×5 、 9×9 和 1×1 ，前两个的卷积核的输出通道数分别为 32 和 64。SRCNN使用Timofte数据集^[30]和ImageNet^[31]数据集作为训练集，使用均方误差作为损失函数，有利于获得较高的客观指标值。




图 2-3 SRCNN网络结构^[13]

(1) 提取浅层特征：浅层的卷积核主要是从输入图像中提取多个特征图 (Feature Map)，每个特征图是一个多维向量，不仅包含图像尺寸大小，还有通道数。

(2) 非线性映射：将一定维度的特征矩阵，通过卷积运算实现非线性映射，变成另一特定维度的特征矩阵。

(3)重建图像:旨在从卷积核提取的特征图反卷积为超分辨率图像的过程,一般将特定维度的特征图上采样为超分辨图像,训练网络得到的参数就是一个卷积层所对应的卷积核权重(w)和偏置项(b),参数 $P=\{W_1,W_2,W_3,b_1,b_2,b_3\}$ 。训练的目标就是最小化目标函数 $F(Y;P)$ 与损失函数的均方误差。

2.3 多尺度特征提取模块

2.3.1 Inception 模块

在Inception出现之前,大部分网络都是不断堆叠卷积层个数,使网络越来越深,以此来提升网络性能。为了使网络既能学习全局性特征,又能学习局部性特征,GoogleNet就首次提出了一种新的卷积核组合方式(即Bottleneck Layer),如下图所示。

Inception设计思路:

Inception通过多尺度卷积核在增加特征表达能力的同时尽可能减少计算。

(b) 模型更精巧复杂了,增加批归一化和梯度裁剪(Gradient Clipping)去稳定训练。

(c) 使用最大池化降低特征图大小。一般池化层的作用是降低特征图大小,保持图像语义信息不变,为了有效的保存提取到的图像信息,应该在池化层之前增加卷积核个数。




图 2-4 Inception结构^[24]

和卷积层、池化层顺序连接的结构(如VGG网络)相比,这样的结构主要有以下改进:

(1) 每一层模块就包含 5×5 、 3×3 、 1×1 卷积核和 3×3 池化。这样,网络中每一个卷积层都能学习到“稀疏”(3×3 、 5×5)或“不稀疏”(1×1)的特征,既增加了网络宽度,也增加了网络对多尺度的适应性。

(2) 通过级联操作在每个模块后合并特征，获得非线性属性。

2.3.2 多尺度残差块

Li等人在MSRN方法中提出了多尺度特征提取模块，这又是第一次在图像超分辨率重建中使用多尺度特征提取模块，其结构如下图 2-5 所示：




图 2-5 多尺度残差块^[21]

在普通残差块的基础上，组合不同尺寸的卷积核，有选择性的获得不同形状的图像特征，称之为多尺度残差块(MSRB)。同时，通过级联操作合并这些特征，可以得到重要的图像特征信息。

$$\begin{aligned} S_1 &= \sigma(w_{3,3}^1 * M_{n-1} + b^1) \\ P_1 &= \sigma(w_{5,5}^1 * M_{n-1} + b^1) \\ S_2 &= \sigma(w_{3,3}^2 * [S_1, P_1] + b^2) \\ P_2 &= \sigma(w_{5,5}^2 * [P_1, S_1] + b^2) \\ S' &= w_{1,1}^3 * [S_2, P_2] + b^3 \end{aligned} \tag{2-5}$$

设N表示送到MSRB的特征图的数量(即通道数)，因此：

- (a) 第一个卷积层的输入和输出有N个通道，将 3×3 和 5×5 的卷积层的输出通道经过级联融合在一起。
- (b) 则第二个卷积层的输入或输出就有 2N个通道；
- (c) 然后再经过级联操作融合后，得到 4N个通道，传递给一个 1×1 卷积层，将这些特征融合的通道的数量压缩到N。
- (d) 最后，将MSRB块的输入通过跳跃连接和其输出相加在一起，能大大降低计算复杂度，有效提高网络训练效率。

2.4 注意机制

人类视觉系统本质上就是一种注意机制，大脑将有限的注意力集中在重点信

息上，有利于节省身体能量，快速获得最关键的信息。对于一张任意图像，人类视觉首先会完整的扫描整张图像，重点关注一些最显眼的区域，也就是常说的注意力焦点，然后对这一重点区域重点关注，获取更多需要的重点信息，抑制无效信息。这是我们人类在历史进化的长河中形成的一种生存方式，人类视觉注意力机制能帮助我们人类及时有效的处理生存中的事务。

SENet^[28]首次将注意力机制引入卷积神经网络，注意力机制模块结构图如下图所示 2-6 所示，其目的是直接建立各特征通道之间的相互依赖关系。具体来说，就是主动学习重要的特征并保留，将重要特征通过加权方式增强传递给深层网络，抑制次要特征，相应的其权重相对较小，在网络学习过程中会渐渐消失，从而抑制无效信息。

首先是压缩操作，对于一个 $H \times W \times C$ 的特征通道，通过一个全局平均每池化操作变成 $1 \times 1 \times C$ 的特征通道，每个特征图被压缩成一个实数，代表整个特征图的全局信息，在这里使用不同的压缩率可以获得不同的通道数。然后再经过一个激活函数，增加一些非线性因素，过滤一些特征信息，便于学到多样的特征。在整个压缩阶段，整体的通道数是不变的。




图 2-6 注意机制模块^[28]

其次是扩张操作，通过 1×1 卷积层扩展通道数，参数 w 是生成的每个特征通道的相应权重，其中，参数 w 通过训练网络得到，用于建立特征通道之间的相关性关系。

最后是一步操作就是重新标权，也就是经过压缩之后得到的权重，一般叫作通道描述子，逐个与输入的特征图相乘。在某种意义上，对不同特征图自适应加权，有助于增强重要特征，抑制次要特征，便于网络更好学习，保留图像重要信息。

SKNet^[33]提出了一种新的注意机制思想，每个神经元对输入信息自动调整感受野的大小，主要使用不同尺度卷积核控制感受野大小。

每一个SK单元使用不同尺寸的卷积核提取特征信息，然后分割一部分特征融合之后，使用softmax进行融合，最后在重新标权到之前的特征通道上。SK单元包括三个方面：分割(Split)、融合(Fuse)和选择(Select)。




图 2-7 SKNet 注意机制模块^[29]

分割阶段使用不同尺寸大小滤波器对输入图像进行特征提取。
融合阶段合并来自多个支路的特征信息，以获得重标定的权重，代表特征信息的全局表示。
选择阶段根据重标定权重融合不同尺寸的卷积核的特征映射。

RCAN首次将注意机制引入图像超分辨率重建，取得了良好的效果。该网络通过考虑通道之间的相互依赖关系来自动地重新改变特征重要性，选择重要特征，抑制不重要特征，有利于网络学习图像主要特征，过滤冗余信息。

Lu等^[34]提出了一种多特征通道网络(CAMFFN)，在递归模块中加入注意机制，目的在于优先选择重要特征，然后再递归提取这些重要特征中的图像信息，实验证明，该方法取得了良好的效果。Liu等^[35]提出了一种并行网络，整体架构分两支，其中一支是注意网络用于选择重要特征，另一支是稠密网络用于提取复杂特征，然后再融合二者的结果，便提取到了重要而又复杂的特征，实验表明该方法也取得了较好视觉效果。

2.5 图像质量评价

当前图像超分辨率重建中，主流的客观评价指标主要是峰值信噪比^[36] (Peak-Signal to Noise Ratio, PSNR)和结构相似性^[37](Structure Similarity Index Measurement, SSIM)。主观评价差异性较大，只能作为一种补充。

2.5.1 PSNR

PSNR是当前主要的评价指标，用于计算两个图像之间的差距，两个图像之

间的比率以分贝形式计算。该动态范围在最大和最小值之间变化，这些值可以通过其质量来更改。PSNR的一般通过均方误差定义。MSE的计算公式如下，PSNR的计算公式如下所示：

$$MSE = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W (X(i, j) - Y(i, j))^2 \quad (2-6)$$

$$PSNR = 10 \log_{10} \left(\frac{(2^n - 1)^2}{MSE} \right) \quad (2-7)$$

其中，MSE表示当前图像X和参考图像Y的均方误差，H、W分别表示图像的高度和宽度； $n=8$ 表示为每个像素所占的比特数，即像素的灰度最大取值范围 256。PSNR的单位是分贝(dB)，PSNR值越大表示图像越接近原图。

2.5.2 SSIM

SSIM用于计算两个图像之间的结构相似性。它也是图像重建领域常用的客观指标。它告诉我们图像与原始参考图像相距多远，更符合人类的感知系统。

$$\begin{cases} s(X, Y) = \frac{\sigma_{XY} + C_2}{\sigma_X \sigma_Y + C_2} \\ c(X, Y) = \frac{2\sigma_X \sigma_Y + C_2}{\sigma_X^2 + \sigma_Y^2 + C_2} \\ l(X, Y) = \frac{2\mu_X \mu_Y + C_1}{\mu_X^2 + \mu_Y^2 + C_1} \end{cases} \quad (2-8)$$

其中 μ_X 、 μ_Y 分别表示图像X和Y的均值，即：

$$\begin{cases} \mu_X = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W X(i, j) \\ \mu_Y = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W Y(i, j) \end{cases} \quad (2-9)$$

σ_X 、 σ_Y 别表示图像X和Y的方差， σ_X^2 、 σ_Y^2 计算如下：

$$\begin{cases} \sigma_Y^2 = \frac{1}{H \times W - 1} \sum_{i=1}^H \sum_{j=1}^W (X(i, j) - \mu_Y)^2 \\ \sigma_X^2 = \frac{1}{H \times W - 1} \sum_{i=1}^H \sum_{j=1}^W (X(i, j) - \mu_X)^2 \end{cases} \quad (2-10)$$

σ_{XY} 表示对比图像X和参考图像Y的协方差， C_1 、 C_2 、 C_3 为常数，可由如下公式所得：

$$\sigma_X \sigma_Y = \frac{1}{H \times W - 1} \sum_{i=1}^H \sum_{j=1}^W (X(i, j) - \mu_X)(Y(i, j) - \mu_Y) \quad (2-11)$$

SSIM的计算公式如下，SSIM取值范围为 0 到 1，SSIM值越大，表示图像越接近原图。

$$SSIM(X, Y) = l(X, Y) \cdot c(X, Y) \cdot s(X, Y) \quad (2-12)$$

2.6 本章小结

本章重点介绍了卷积神经网络的历史脉络、SRCNN方法、以及与本文方法相关的多尺度特征提取模块和注意机制的历史。卷积神经网络是人类对大脑神经系统的研究中，不断改进提出了卷积神经网络，很好的解决了许多计算机视觉任务。卷积神经网络包含多个层，主要有卷积层、激励层、池化层、全连接层等。基于深度学习的图像超分辨率重建领域，SRCNN作为的开山之作，提出了基本的网络架构。SRCNN网络结构简单，但是重建的结果比以往的传统方法都要好。以往许多方法都用一种卷积核提取特征，GoogleNet在图像分类领域提出了Inception结构，利用不同尺寸卷积核提取多尺度特征，提升了网络性能。基于Inception结构，Li等人首次将多尺度特征提取方法引入图像超分辨率重建中，提出了MSRN网络，有效的提升了重建的效果。随着深度学习的发展，注意机制渐渐引入到了超分辨重建中。SENet首次在图像分类任务中使用了注意机制，其主要思想就是通过学习的方式来自适应判断每个特征图的重要程度，增强重要特征，抑制次要特征。RCAN将注意机制引入到图像超分辨率领域，通过自适应地调整特征通道的重要性选择相对重要的特征。此外，本文介绍了两种最常用的客观评价指标PSNR和SSIM，保证了图像重建性能评价的公平性。

第3章 基于嵌套残差网络图像超分辨率

3.1 引言

单图像超分辨率技术是从给定的低分辨率图像中恢复出对应的高分辨率图像,是计算机视觉领域的经典问题,被广泛用于遥感成像、视频监控和医学图像处理等领域。

单图像超分辨率是一个病态逆问题:一个低分辨率图像可对应多个高分辨率图像^[38],重建的高分辨率图像往往会出现细节丢失、边缘走样和模糊等缺陷。深度学习技术极大地推动了迅速发展的计算机视觉领域^[39,40],当前,绝大多数的单图像超分辨率算法取得了很大的进步,然而在实际应用中依然存在问题:更好的结果,往往依赖于更深的网络,更多的参数,也需要更多的训练数据。这需要更长的训练和推理时间,更强的计算能力和存储能力。由于这个原因,其实用性受到了很大的限制,尤其是资源受限的移动设备。例如,EDSR通过堆叠残差块的方式构建了一个既宽且深的网络,赢得了2017年NTIRE^[41]超分辨率比赛冠军,其参数量有43MB之多。RDN^[42]将稠密连接嵌入到残差块中,构建了一个更深的网络,其性能超过了EDSR,参数量有所降低,也约有22MB之多。当前也有一些使用轻量级网络的单图像超分辨率方法。Dong等人是第一个将卷积神经网络引入单图像超分辨率重建技术中,他们的方法称之为SRCNN。SRCNN只有三个卷积层,但是,取得了较好的结果。Kim等提出的VDSR,使用了残差网和梯度裁剪技术,扩展到20个卷积层,进一步提升了性能。DRRN^[39]结合递归学习、局部残差学习和全局残差学习,连续递归残差块,进一步加深了网络,效果优于VDSR。MemNet^[44]提出了以记忆模块和门控单元为基本单元的持续记忆网络,同时使用递归的技术,单图像超分辨率性能优于DRRN。CARN^[45]构建了一个级联的残差网,单图像超分辨率性能优于MemNet。CBPN^[46]通过级联上/下采样层,在低分辨率图像和高分辨率图像空间中提取特征信息,单图像超分辨率性能优于CARN。Hui等^[47]提出的IMDN方法在残差块内逐步提取特征,通过通道注意力机制对特征进行选择,性能超过了CBPN。Li等人^[44]提出的MSRN方法,运用了全局融合层特征,单图像超分辨率性能再次超越IMDN。与EDSR和RDN等方法相比,基于轻量级网络的单图像超分辨率方法的性能仍有差距。在这些使用轻量级网络的单图像超分辨率方法中,MSRN性能最好,参数量也最大(6MB),SRCNN参数量最小(57KB),性能也是最低的。

本文中,我们提出了一个新的轻量级单图像超分辨率网络。我们方法的参数量只有1.5MB,只相当于当前先进的单图像超分辨率方法MSRN的1/4。但是,主观和客观性能度量均著优于MSRN。我们的主要贡献包括:1)提出了一个多尺

度特征融合模块(MSFFB)使用不同尺寸的卷积核(5×5 、 3×3 和 1×1), 提取和融合多种尺度的特征; 2) 提出了通道搅乱注意块(CSAM), 促进通道之间信息流动, 增强特征选择能力; 3) 提出了全局特征融合连接(GFFC)模块, 提高浅层特征的利用率, 增强图像细节信息。

3.2 算法总体框架

通常, 更深的网络, 能获得更好的单图像超分辨率性能。残差网络缓解了深度网络的梯度消失/爆炸问题, 但是, 简单地堆叠残差块, 会使参数量急剧增加, 这是一个两难的选择。增加网络深度, 但不会增加参数的一种可行的方式是: 采用递归的结构, 在残差块之间参数共享。但是, 由于严重的梯度消失/爆炸问题, 的训练有一定困难。本文中, 提出了一个新的递归网络(NRSR): NRSR把递归的残差块嵌套在一起, 形成一个嵌套块构件, 再递归这个嵌套块。NRSR包括三个部分: 浅层特征提取(SFEB)、特征级联组(FCG)和重建(RB)模块, 如图 3.1 (a)所示。FCG包含三个嵌套块(NU), 每个NU包含三个递归的层次特征融合块(HFFB), HFFB的结构参见图 3.1 (b)。HFFB主要由三个基本嵌套单元(BNC)组成, BNC的结构参见图 3.1(c)。BNC主要由多尺度特征融合块(MSFFB) (如图 3.1 (c)所示)和通道搅乱注意力(CSAM)模块(如图 3.1 (d)所示)。

3.2.1 网络结构




图 3.1 NRSR 结构图

假定 I_L 和 I_H 分别是输入的 LR 图像和输出的 HR 图像。 I_L 首先输入到 SFEB 模块, 取浅层特征 F_0 。SFEB 只是一个简单的卷积层:

$$F_0 = G_{ext}(I_{LR}) \quad (3-1)$$

其中, $G_{ext}(\cdot)$ 表示 3×3 卷积。 F_0 输入到FCG模块, 进行深层特征的提取和全局特征的融合:

$$F_{DF} = G_{fcg}(F_0) \quad (3-2)$$

其中, $G_{fcg}(\cdot)$ 是FCG模块函数, F_{DF} 是其输出的特征。 F_{DF} 再输入到RB模块, 重建输出的高分辨率图像 I_{SR} :

$$I_{SR} = G_{up}(F_{DF}) + G_{bic}(I_{LR}) \quad (3-3)$$

其中, $G_{bic}(\cdot)$ 是双三次插值函数, $G_{up}(\cdot)$ 是重建模块的函数。把原输入的低分辨率图像 I_{LR} 进行双三次上采样, 叠加到 $G_{bic}(\cdot)$ 的输出, 获得重建的高分辨率图像 I_{SR} 。在基于卷积神经网络的单图像超分辨率方法中, 重建模块大都采用文献^[20,21]的方法(Conv-PixelShuffle-Conv)。为了减少参数量, 我们去掉了上述方法中的最后一个 3×3 卷积层。

3.2.2 特征级联组

参见图 3.1 (a), FCG主要包括三个嵌套块(NU)和三个全局特征融合连接(GFFC)。一个嵌套块包含三个层次特征融合块(HFFB); 一个HFFB主要包含三个基本嵌套单元(BNC) [参见图 3.1 (b)]; 一个BNC主要包含三个多尺度特征融合块(MSFFB)和一个通道搅乱注意力(CSAM)模块[参见图 3.1 (c)]; 同一BNC内的三个MSFFB之间参数共享。

3.2.3 全局特征融合连接(GFFC)

浅层特征包含大量低频信息。为充分利用这些低频信息, 全局特征融合连接将浅层特征融合到网络的每一个阶段。不同于一般的全局特征融合(如逐点相加或级联操作), 我们使用逐点卷积对浅层特征实现跨通道交互和信息融合, 以实现特征信息的流动, 减少图像信息的丢失, 提高浅层特征的利用率。全局特征融合连接(GFFC)对 F_0 执行逐点卷积(即 1×1 的卷积), 输出特征级联到FCG模块内 3 个嵌套单元模块的输出特征之中。

$$F_{gc} = f_{1 \times 1}(F_0, W_1) \quad (3-4)$$

其中, F_0 表示浅层特征, $f_{1 \times 1}(\cdot)$ 和 W_1 分别表示逐点卷积和相应权重。 F_{gc} 最后融合到网络的每一阶段。

3.2.4 嵌套块(NU)

如图 3-1(a)所示, 三个层次特征融合块以递归的方式组成一个嵌套块(NU)。

我们的嵌套块类似于残差中残差结构(RIR)^[27],差别在于:没有采用跳跃连接方式,而是模块嵌套模块的方式,不仅有多层次特征融合模块,也有多尺度特征提取模块。这种方式不仅能增加网络深度,还有利于提取更丰富的深层特征。可用如下公式表示:

$$\begin{aligned} H_i^0 &= F_0 \\ H_i^3 &= G_{nu}(H_i^0) = R_i^j(\cdots(R_i^0(H_i^{j-1}))) \\ H_i^j &= R_i^j(H_i^{j-1}) \end{aligned} \quad (3-5)$$

其中, H_i^0 和 H_i^3 ($i=1;2;3$) 分别表示第 i 个嵌套块的输入和输出, $G_{nu}(\cdot)$ 和 $R_i^j(\cdot)$ 分别表示嵌套块和层次特征融合块。在公式(3-5)中, R_i^j ($j=1;2;3$) 表示第 i 嵌套块中的第 j 个层次特征融合块, H_i^j 和 H_i^{j-1} 表示相应的输入和输出。此外,我们将第一个嵌套块的输入 H_i^0 初始化为 F_0 。然后,通过级联操作将嵌套块和全局特征融合连接的输出融合在一起形成一个新的输入,传递给下一个嵌套块:

$$H_i^0 = F_{1 \times 1}([H_{i-1}^3, F_{gc}], W_2) \quad (3-6)$$

其中, $[H_{i-1}^3; F_{gc}]$ 表示将嵌套块和全局特征融合连接的输出级联在一起。 $F_{1 \times 1}(\cdot)$ 和 W_2 分别表示 1×1 的卷积和相应的权重。它的作用是将级联操作后的特征通道数目压缩到和嵌套块的输入通道数一样。最终的深层特征 F_{DF} 可以表示为:

$$F_{DF} = F_{1 \times 1}([H_3^3, F_{gc}], W_2) \quad (3-7)$$

3.2.5 层次特征融合块(HFFB)

一个层次特征融合块(HFFB)包括三个不同的基本嵌套单元和压缩单元。层次特征融合块内部融合不同层次的多样化特征,是一种局部与全局特征的融合,能有效提高特征使用率,减少图像信息的丢失。首先,将第一个基本嵌套单元的输出与输入合并在一起,之后通过压缩单元将特征通道数压缩到与基本嵌套单元的输入一样。接着将压缩的结果输入第二个基本嵌套单元中,它的输出与之前合并后的结果再次合并在一起,经过压缩单元后的输出作为第三个基本嵌套单元的输入。最后将第三个基本嵌套单元的输出与之前第二个合并后的结果再次合并在一起。这一过程可表示为:

$$\begin{aligned} C_0^{ij} &= B_0^{ij} = H_i^{j-1} \\ B_k^j &= G_y^k(C_{k-1}^j) \\ C_k^j &= F_{1 \times 1}([B_0^j, \cdots B_k^j], W_3) \\ H_i^j &= C_3^j \end{aligned} \quad (3-8)$$

其中, $G_y^k(\cdot)$ ($k=1;2;3$) 表示第 i 个嵌套块中的第 j 个层次特征融合块中的第 k 个

基本嵌套单元(BNC)。具体来说, C_0^{ij} 和 B_0^{ij} 表示第一个基本嵌套单元的输入, B_k^{ij} 表示第 k 个基本嵌套单元的输出。 C_k^{ij} 表示多层特征融合的结果, $[B_0^{ij}, \dots, B_k^{ij}]$ 表示局部与全局特征的合并。压缩单元 $F_{1 \times 1}(\cdot)$ 和 W_3 分别表示一个 1×1 卷积和相应的权重。此外, 层次特征融合块的最终输出就可表示为 C_3^{ij} 。

3.2.6 基本嵌套单元 (BNC)

基本嵌套单元(BNC)主要包括局部融合单元、多尺度特征融合块和通道搅乱注意力模块三部分。对提取的多尺度特征和经过通道搅乱注意力模块选择后的特征以及局部残差连接的输出三部分特征, 通过逐点相加操作实现多样化特征融合, 有助于增强特征表达能力, 提供丰富的细节信息。此外, 对输入到多尺度特征融合块和通道搅乱注意力模块的特征, 局部融合单元首先使用一个 1×1 卷积使特征通道之间进行交互, 便于特征信息的整合。如公式(3-14)所示:

$$\begin{aligned} H_{ifu} &= F_{1 \times 1}(B_{k-1}^{ij}, W_4) \\ B_k^{ij} &= G_{bnc}^k(C_{k-1}^{ij}) \\ &= G_{csam}(H_{ifu}) + G_{msffb}(H_{ifu}) + B_{k-1}^{ij} \end{aligned} \quad (3-9)$$

其中, $G_{bnc}(\cdot)$ 、 $G_{csam}(\cdot)$ 和 $G_{msffb}(\cdot)$ 分别表示基本嵌套单元、多尺度特征融合块和通道搅乱注意力模块。 W_4 表示局部融合单元的权重, B_{k-1}^{ij} 和 C_{k-1}^{ij} 如公式(3-8)所示。

3.2.7 多尺度特征融合块 (MSFFB)

许多轻量级超分辨率方法对特征的利用能力有限, 仅使用普通 3×3 卷积提取特征, 本文提出的多尺度特征融合块(MSFFB)使用不同感受野的卷积核(5×5 和 3×3)提取多种尺度的特征, 确保提取的特征更加多样化, 为重建高质量图像提供丰富的细节信息。多尺度特征融合块主要包括三个尺寸不同的卷积核, 5×5 和 3×3 的卷积核用于提取特征, 1×1 的卷积核用于融合这两种不同尺度的特征。这里 1×1 的卷积不仅能实现特征之间的融合, 也能压缩输出, 保证输出与输入之间具有相同的通道数, 便于三个共享多尺度特征融合块实现递归。这一过程可用以下公式表示:

$$\begin{aligned} S_3 &= \sigma(F_{3 \times 3}(M_{n-1}, W_5)) \\ S_5 &= \sigma(F_{5 \times 5}(M_{n-1}, W_6)) \\ M_n &= F_{1 \times 1}([S_3, S_5], W_7) \end{aligned} \quad (3-10)$$

其中, σ 表示 Relu 激活函数。 $F_{5 \times 5}(\cdot)$ 、 $F_{3 \times 3}(\cdot)$ 和 $F_{1 \times 1}(\cdot)$ 分别表示三个不同感受野大小的卷积核, W_5 、 W_6 和 W_7 表示相应的权重, S_3 和 S_5 表示提取到的不同

尺度的特征。此外, M_{n-1} 和 $M_n(n=1;2;3)$ 表示第 n 个共享多尺度特征融合块的输入和输出。三个共享多尺度特征融合块的最终输出 M_3 可表示为:

$$\begin{aligned} M_0 &= H_{ifu} \\ M_3 &= G_{msffb}(G_{msffb}(G_{msffb}(M_0))) \end{aligned} \quad (3-11)$$

其中, M_0 表示第一个多尺度特征融合块的输入, 我们将其初始化为 H_{ifu} 。

3.2.8 通道搅乱注意力模块(CSAM)

近年来, 许多基于卷积神经网络的超分辨率方法都忽略了通道之间的相互依赖性, 阻碍了网络的表征能力, 受文献^[22,27,32]等方法的启发, 本文提出的通道搅乱注意力模块(CSAM)使用通道搅乱(Channel Shuffle)操作能有效促进通道之间信息的流动, 增强网络对特征的选择能力, 进而提高网络表征能力。如图 3.2 所示, 通道搅乱注意力模块主要由三部分组成: 两个 1×1 之间的瓶颈块、全局平均池化和softmax函数。

首先, H_{ifu} 经过第一个 1×1 卷积层压缩通道减少参数量。然后经过一个组卷积对通道分组, 分完组的特征通道经过通道搅乱操作, 实现通道之间的信息流动。最后经过第二个 1×1 卷积层将输出通道数恢复到输入通道数。这个过程可用如下公式所示:

$$X = F_{r2c}(F_{cf}(F_{gc}(F_{c2r}(H_{ifu}, W_c), W_g)), W_r) \quad (3-12)$$

其中, $F_{cf}(\cdot)$ 表示通道搅乱操作。 $F_{r2c}(\cdot)$ 、 $F_{c2r}(\cdot)$ 和 $F_{gc}(\cdot)$ 分别表示 1×1 卷积和逐点组卷积, W_r 、 W_c 和 W_g 是其相应权重。然后, 假定 $X = [x_1; \dots; x_c; \dots; x_C] \in \mathbb{R}^{H \times W \times C}$, 通过全局平均池化操作, 得到维度为 C 的通道描述子(Channel Descriptor)^[22] $z \in \mathbb{R}^C$, z 中第 c 个通道描述子可表示为:

$$z_c = G_{gap}(x_c) = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W x_c(i, j) \quad (3-13)$$

其中, $G_{gap}(\cdot)$ 表示全局平均池化, 通道描述子 z 可以看作是对整个图像信息的一个集中表示^[22], 因为平均操作将图像中每个像素都考虑在内。最后, 使用softmax函数计算这些通道描述子之间的相关权重 w :

$$w = \tau(z) = \frac{e^{\bar{z}_i}}{\sum_{i=1}^C e^{\bar{z}_i}} \quad (3-14)$$

其中, τ 表示softmax函数, $w \in \mathbb{R}^C$ 表示维度为 C 的相关权重。将这些相关权重乘以相对应的通道, 就得到了通道搅乱注意力模块的最终输出:

$$\hat{x} = w_c \cdot x_c \quad (3-15)$$

其中， w_c 和 x_c 表示第 c 个通道的相关权重和相应特征通道。




图 3.2 通道搅乱注意机制模块结构

3.3 本章小结

本章提出了一种新的轻量级嵌套残差网络(NRSR)，介绍了NRSR网络的主要架构，主要包括全局特征融合连接、特征串联组、多尺度特征融合块、层次特征融合块、通道搅乱注意机制模块等。详细介绍了本文方法设计的初衷和动机，其中，全局特征融合连接作为本文创新点之一，在网络每一阶段融合浅层特征，有利于提高浅层特征利用率，减少图像信息丢失，为后续重建高质量的超分辨率图像提供大量的低频信息，使得超分辨率图像具有锐利的边缘和清晰的轮廓。多尺度特征融合块不同于一般的单尺度卷积核提取特征，该模块使用不同尺寸的卷积核提取丰富多样的特征，确保提取的特征更加多样化，为重建高质量图像提供丰富的细节信息。通道搅乱注意机制模块作为最主要的创新点，结合注意机制和通道搅乱操作的优势，不仅能有效促进通道之间信息的流动，而且还能增强网络对特征的选择能力，提高网络表征能力。本文方法首次在超分辨率重建领域使用通道搅乱操作，有效提高了网络性能，实验证明，本文方法是有效的，具有很高的使用价值。此外，本文方法整体结构是一种嵌套结构，模块与模块嵌套在一起，模块内部使用递归方式组织残差块，这样一种全新的方式在加深网络的同时不增加网络参数量，能有效提取深层次特征，在存储资源受限的移动等嵌入式设备上具有潜在实用价值。

第 4 章 实验与分析

4.1 引言

本章主要介绍训练网络所需要的数据集、训练策略、实验参数设置、超参数的设置以及各种对比实验。此外，在不同放大倍数下，对比了一些其他轻量级方法(如主观视觉和客观指标)，做了详尽实验分析。

4.2 数据集

4.2.1 训练集

本文训练和验证图像采用高质量DIV2K^[49]数据集。前 800 个图像用于训练，第 801-805 个图像用于验证。原高分辨率图像训练图像，进行双三次(Bicubic, B I)下采样,获得配对的低分辨率和高分辨率训练图像对。类似其它方法,通过 90°、180°、270°旋转，以及水平翻转，增强了训练图像。生成的超分辨率图像转换到 YCbCr 空间，在亮度(Y)通道上计算峰值信噪比和结构相似性。




图 4-1 DIV2K 图像示例

4.2.2 测试集

为保证比较的客观性，本文使用同其他方法一样的 5 个基准测试集，即: Set5^[50]、Set14^[51]、B100^[52]、Urban100^[53]和Manga109^[54]。其中，图 4-2 展示部分Urban100 图像。




图 4-2 Urban100 图像示例

4.3 实验细节

4.3.1 实验参数设置

本文采用与文献^[20]相同的参数设置，训练图像裁剪为 48×48 的图像片，每批次随机输入 16 个图像片。使用 Adam^[55] 优化器且设置 $\beta_1=0.9$ 、 $\beta_2=0.999$ 、 $\epsilon=10^{-8}$ 、 L_1 损失函数、通道数(滤波器个数) $C=64$ ，初始学习率设置为 $L_r=1e-4$ ，每 20 0 个迭代周期(epoch)学习率减半。模型使用 Pytorch^[56] 框架，在 NVIDIA 2080Ti GPU 上进行训练。

4.3.2 超参数 R 、 G 、 H 和 M 的设置

本节将分析一些超参数的设置。假定 R 和 G 分别表示通道搅乱注意力模块中的压缩率和分组数， H 表示层次特征融合块数目， M 表示多尺度特征融合块数目。超参数的设置对网络的影响，如下图 4-3 所示。

为验证通道搅乱注意力模块中第一个 1×1 卷积压缩率 R ，我们做了四组实验，分别设 $R=16$ 、32、48 和 64，如图 4-3 (a) 所示。可以看出： $R=48$ 时的曲线位于其它三条曲线之上，即 PSNR 更高。合适的压缩率 R 能减少参数量，过滤掉一些无效信息，为后续通道搅乱操作提供更为有效的信息。

对于通道搅乱注意力模块中分组卷积的组数 G ，我们做了三组实验。分别设 $G=2$ 、3 和 4，如图 4-3 (b) 所示，可以看出： $G=3$ 时网络性能表现最好。一般情况下，分组越多，参数量越少，但是会影响网络性能，分组数 $G=3$ 是参数量和性能之间较好的平衡点。

最后，网络中的递归结构在层次特征融合块和多尺度特征融合块之间共享参数，在不增加参数量的情况下，可增加网络的深度。为验证递归块个数 H 和 M ，我们做了三组对比实验，分别假定 H 和 M 同时增大，即 H 和 M 同时等于 1、2 或 3，如下图 4-3 (c) 所示。可以看出， $H=M=3$ 的时效果最好。考虑到计算量的约束，

我们没有试验更大的 H 和 M 。




图 4-3 超参数 R 、 G 、 H 和 M 的设置对网络的影响

4.3.3 消融实验

4.3.3.1 MSFFB、CSAM 和 GFFC 的影响

表 4-1 多尺度特征融合块、通道搅乱注意力模块和全局特征融合连接在验证集上结果								
GFFC	×	√	×	×	√	√	×	√
CSAM	×	×	√	×	√	×	√	√
MSFFB	×	×	×	√	×	√	√	√
PSNR	32.14	32.17	32.15	32.20	32.22	32.26	32.27	32.32

为了验证多尺度特征融合块、通道搅乱注意力模块和全局特征融合连接的有效性，本文设计了八组对比实验，每个实验使用相同的压缩率^[27]($R=48$)、分组数($G=3$)、多尺度特征融合块($M=3$)和层次特征融合块($H=3$)数目。如表 4-1 所示，不包含这三个模块的网络称为基准网络，记为NRSR_G0_C0_M0，在DIV2K验证

集上PSNR值只有 32.14dB。

在基准网络上分别增加 3 个模块之一，记为NRSR_G1_C0_M0、NRSR_G0_C1_M0和NRSR_G0_C0_M1。如表 4-1 中第 3 列至第 5 列所示，PSNR值均比基准网络高。只包含多尺度特征融合块的网络比基准网络PSNR值高 0.06dB，说明多尺度特征融合块是有效的。

接下来，在基准网络上增加其中两个模块，分别记为NRSR_G1_C1_M0、NRSR_G1_C0_M1和NRSR_G0_C1_M1，如表 4-1 中第 6 列至第 8 列所示，PSNR值逐渐增高，且包含任意两个模块的网络都比仅包含一个模块的网络效果更好。其中NRSR_G0_C0_M1 网络和NRSR_G0_C1_M1 网络相比，即在多增加一个通道搅乱注意力模块的情况下，PSNR值高出 0.06dB。通道搅乱注意力模块能充分利用特征通道之间的相关性，促进特征之间信息的流动，进而增强网络对特征的选择能力，提升了网络的性能。

最后，包含全部三个模块的网络记为NRSR_G1_C1_M1，如表 4-1 最后一列所示，PSNR值进一步提高，达到了 32.32dB。在包含通道搅乱注意力模块和多尺度特征融合块网络的基础上，再增加全局特征融合连接，PSNR值增加了 0.06dB (对比表 4-1 中最后两列)，全局特征融合连接在网络中能提高浅层特征的利用率，减少图像低频信息的丢失，改进了模型的性能。

4.3.3.2 GFFC 中 1×1 卷积影响

表 4-2 全局特征融合连接中 1×1 卷积在验证集 $\times 4$ 上结果

1×1 Conv	DIV2K-5
$\times$	32.30
$\surd$	32.32

为了验证全局特征融合连接（GFFC）中 1×1 卷积的效果，我们在DIV2K-5验证数据集上设计了两个对比实验。如表 4-2 所示，具有 1×1 卷积的GFFC的平均PSNR比没有 1×1 卷积的GFFC的平均PSNR高 0.02dB。GFFC中的 1×1 卷积实现了有效的信息交互以及通道之间浅层特征的融合，从而提高了性能。

4.3.3.3 CSAM 中通道搅乱的影响

为验证通道搅乱操作在通道搅乱注意机制模块（CSAM）中， $\times 4$ 放大倍数下，我们在DIV2K-5 验证数据集上训练了 200 个迭代周期。如表 4-3 所示，具有通道搅乱操作的CSAM的性能要优于没有通道搅乱操作的CSAM，因为CSAM中的通道混洗可以促进信息在通道之间的流动。

表 4-3 通道搅乱注意机制模块中通道搅乱操作在验证集上结果

Channel Shuffle	DIV2K-5
×	32.29
√	32.32

4.4 结果与分析

为了验证本文NRSR网络的有效性，我们同其他先进方法进行了定量客观比较和主观视觉效果比较。其它代表性的方法包括：SRCNN、VDSR、DRRN、MemNet、CARN、CBPN、IMDN、MSRN、DRCN、FSRCNN、SRMDNF^[57]、LapSRN^[58]以及LFFN^[59]。放大倍数分别为×2、×3、×4 和×8，如表 4-4 和图 4、5 所示。




图 4-4 各种 SISR 方法的×4 模型在 Set5 数据集上的平均 PSNR 值及参数量

定量客观比较：参见表 4-4，本文NRSR方法比其它方法PSNR值和SSIM值显著更高。与本文方法参数量相当的CARN和SRMDNF相比，在Set5 数据集×2、×3、×4 放大倍数下，我们的PSNR值都超过了 0.2dB。图 4-4 是各个单图像超分辨率方法×4 模型，在Set5 数据集上的结果，本文NRSR方法具有更好的PSNR性能和参数量平衡。与MSRN相比，我们的PSNR值高约 0.2dB，而参数量只有它的 1/4。虽然一些方法比NRSR参数少，但是，有很显著的性能差距。使用自集合(self-ensemble)^[20]的方法，记为NRSR+，可以进一步提高性能，如表 4-4 所示。我们的PSNR值和SSIM值超过了其它所有比较的单图像超分辨率方法。

表 4-4 各种 SISR 方法×2 的客观指标，最好结果用加粗标出。

放大 倍数	模型	参数量	Set14	B100	Urban100	Manga109
			PSNR/SSIM	PSNR/SSIM	PSNR/SSIM	PSNR/SSIM
×2	SRCNN	57K	32.42/0.9063	31.36/0.8879	29.50/0.8946	35.74/0.9661
	FSRCNN	12K	32.63/0.9088	31.53/0.8920	29.88/0.9020	36.67/0.9694
	VDSR	665K	33.03/0.9124	31.90/0.8960	30.76/0.9140	37.22/0.9729
	DRCN	1774K	33.04/0.9118	31.85/0.8942	30.75/0.9133	37.63/0.9723
	LapSRN	813K	33.08/0.9130	31.80/0.8950	30.41/0.9100	37.27/0.9740
	DRRN	297K	33.23/0.9136	32.05/0.8973	31.23/0.9188	37.92/0.9760
	MemNet	677K	33.28/0.9142	32.08/0.8978	31.31/0.9195	37.72/0.9740
	SelNet	974K	33.61/0.9160	32.08/0.8984	-	-
	SRMDNF	1513K	33.32/0.9150	32.05/0.8980	31.33/0.9200	38.07/0.9761
	CARN	1592K	33.52/0.9166	32.09/0.8978	31.92/0.9256	38.36/0.9765
	CBPN	1036K	33.60/0.9171	32.17/0.8989	32.14/0.9279	-/-
	IMDN	694K	33.63/0.9177	32.19/0.8996	32.17/0.9283	38.88/0.9774
	LFFN	1522K	-/-	32.20/0.8994	32.39/0.9299	38.73/0.9765
	MSRN	5930K	33.70/0.9186	32.23/0.9002	32.29/0.9303	38.69/0.9772
	NRSR	1561K	33.76/0.9189	32.22/0.9001	32.41/0.9308	38.89/0.9775
	NRSR+	1561K	33.79/0.9195	32.26/0.9006	32.58/0.9321	39.07/0.9779

表 4-5 各种 SISR 方法×3 的客观指标，最好结果用加粗标出。

放大 倍数	模型	参数量	Set14	B100	Urban100	Manga109
			PSNR/SSIM	PSNR/SSIM	PSNR/SSIM	PSNR/SSIM
×3	SRCNN	57K	32.75/0.9090	29.28/0.8209	28.41/0.7863	26.24/0.7989
	FSRCNN	12K	33.16/0.9140	29.43/0.8242	28.53/0.7910	26.43/0.8080
	VDSR	665K	33.66/0.9213	29.77/0.8314	28.82/0.7976	27.14/0.8279
	DRCN	1774K	33.82/0.9226	29.76/0.8311	28.80/0.7963	27.15/0.8276
	DRRN	297K	34.03/0.9244	29.96/0.8349	28.95/0.8004	27.53/0.8378
	MemNet	677K	34.09/0.9248	30.00/0.8350	28.96/0.8001	27.56/0.8376
	SelNet	1159K	34.27/0.9257	30.30/0.8399	28.97/0.8025	-
	SRMDNF	1530K	34.12/0.9250	30.04/0.8370	28.97/0.8030	27.57/0.8400
	CARN	1592K	34.29/0.9255	30.29/0.8407	29.06/0.8034	27.38/0.8404
	IMDN	703K	34.36/0.9270	30.32/0.8417	29.09/0.8046	28.17/0.8519
	LFFN	1534K	34.43/0.9266	-/-	29.13/0.8059	28.34/0.8558
	MSRN	6114K	34.46/0.9278	30.41/0.8437	29.15/0.8064	28.33/0.8561
	NRSR	1569K	34.53/0.9283	30.43/0.8437	29.15/0.8062	28.45/0.8581
	NRSR+	1569K	34.59/0.9287	30.49/0.8448	29.20/0.8072	28.61/0.8604

表 4-6 各种 SISR 方法×4 的客观指标，最好结果用加粗标出。

放大 倍数	模型	参数量	Set14	B100	Urban100	Manga109
			PSNR/SSIM	PSNR/SSIM	PSNR/SSIM	PSNR/SSIM
×4	SRCNN	57K	27.49/0.7503	26.90/0.7101	24.52/0.7221	27.66/0.8505
	FSRCNN	12K	27.59/0.7535	26.98/0.7150	24.62/0.7280	27.90/0.8517
	VDSR	665K	28.01/0.7674	27.29/0.7251	25.18/0.7524	28.83/0.8809
	DRCN	1774K	28.02/0.7670	27.23/0.7233	25.14/0.7510	28.98/0.8816
	LapSRN	813K	28.19/0.7720	27.32/0.7280	25.21/0.7560	29.09/0.8845
	DRRN	297K	28.21/0.7720	27.38/0.7284	25.44/0.7638	29.46/0.8960
	MemNet	677K	28.26/0.7723	27.40/0.7281	25.50/0.7630	29.42/0.8942
	SelNet	1417K	28.49/0.7783	27.44/0.7325	-	-
	SRMDNF	1555K	28.35/0.7770	27.49/0.7340	25.68/0.7730	30.09/0.9024
	CARN	1592K	28.60/0.7806	27.58/0.7349	26.07/0.7837	30.47/0.9084
	CBPN	1197K	28.63/0.7813	27.58/0.7356	26.14/0.7869	-/-
	IMDN	715K	28.58/0.7811	27.56/0.7353	26.04/0.7838	30.45/0.9075
	LFFN	1531K	-/-	27.52/0.7377	26.24/0.7902	30.66/0.9099
	MSRN	6078K	28.63/0.7836	27.61/0.7380	26.22/0.7911	30.57/0.9103
	NRSR	1581K	28.73/0.7847	27.65/0.7388	26.35/0.7939	30.81/0.9125
	NRSR+	1581K	28.81/0.7861	27.70/0.7398	26.50/0.7967	31.06/0.9148

表 4-7 各种 SISR 方法×8 的客观指标，最好结果用加粗标出。

放大 倍数	模型	参数量	Set14	B100	Urban100	Manga109
			PSNR/SSIM	PSNR/SSIM	PSNR/SSIM	PSNR/SSIM
×8	SRCNN	57K	23.86/0.5443	24.14/0.5043	21.29/0.5133	22.46/0.6606
	FSRCNN	12K	23.94/0.5482	24.21/0.5112	21.32/0.5090	22.39/0.6357
	VDSR	655K	23.20/0.5110	24.34/0.5169	21.48/0.5289	22.73/0.6688
	DRCN	1774K	24.27/0.5510	24.49/0.5168	21.71/0.5289	23.20/0.6686
	LapSRN	813K	24.45/0.5792	24.54/0.5293	21.81/0.5555	23.39/0.7068
	MSRN	6226K	24.88/0.5961	24.70/0.5410	22.37/0.5977	24.28/0.7517
	NRSR	1664K	24.95/0.6406	24.79/0.5965	22.41/0.6148	24.52/0.7771
	NRSR+	1664K	25.05/0.6432	24.84/0.5982	22.55/0.6202	24.68/0.7823

表 4-8 Set5×4 放大倍数下网络性能与运行时间对比

模型	CARN	MSRN	IMDN	NRSR
时间(s)	0.040	0.045	0.046	0.067
PSNR (dB)	32.13	32.26	32.21	32.43

表 4-9 Set5×4 放大倍数下最先进方法性能与参数量对比

模型	SAN	EBPN	ERN	NRSR
参数量(M)	15.7	8.18	9.53	1.58
PSNR(dB)	32.64	32.79	32.39	32.43

在Set5×4 放大倍数下,本文NRSR方法与其它轻量级模型相比,在运行时间、参数量和性能上取得了更好的平衡。NRSR与比较的方法分别多用时 0.027 秒、0.022 秒和 0.021 秒,但是,平均PSNR性能分别提高了 0.30dB, 0.17dB和 0.22dB (表 4-8)。其次,与当前最先进的单图像超分辨率方法相比(表 4-9),在参数量和性能之间,本文方法似乎取得了更好的平衡。与SAN方法相比,我们方法的平均PSNR值略低,而参数量只有其 1/10(参见表中最后两列)。与ERN和EBPN方法相比,我们的参数量只相当其 1/6,但是,平均PSNR性能相当(EBPN略高 0.06dB, ERN略低 0.04dB)。

表 4-10 Set5×4 放大倍数下模型复杂度对比

模型	DRCN	DRRN	MemNet	CARN	MSRN	NRSR
Flops (G)	9788.7	6796.9	2662.4	90.9	349.9	728.4
PSNR (dB)	31.53	31.68	31.74	32.13	32.13	32.43

模型复杂度比较: 表 4-10 显示了在Set5 数据集上放大倍数×4 的复杂度和PSNR比较。GFLOPs^[60]的计算使用 1280×720 图像。与其他递归模型(DRCN, DRRN和MemNet)相比,我们的NRSR(也是递归)具有更高的PSNR和更低的GFLOPs。NRSR的GFLOPs分别是DRCN, DRRN和MemNet的GFLOPs的 1/13、1/9 和 1/4。我们的NRSR的PSNR分别比DRCN, DRRN和MemNet的PSNR高出 0.9dB, 0.75dB和 0.69dB。与MSRN(非递归)相比,我们的NRSR的GFLOPs约为MSRN的两倍。但是,我们的NRSR的PSNR比MSRN高 0.3dB。

主观效果比较: 图 4-5 是本文方法与其它先进方法在×4 放大倍数下重建的超分辨率图像,本文方法比其它方法重建结果显著更好。以图像 062 为例,Bicubic、SRCNN、CARN、MSRN等方法恢复出来的玻璃窗格子模糊不清,条纹产生畸变,图像失真严重,本文方法恢复的图像纹理清晰、细节丰富,更加的接近真实图像。图像 063 情况相似。再以B100 测试集中的图 148026 为例,其它方法恢复的图像木板条纹严重模糊,本文方法恢复的木板条纹接近真实图像。




图 4-5 基准测试集 Urban100、Set14 和 B100 中图像 img092、img024、barbara 和 148026 的×4 视觉效果比较

图 4-6 和 4-7 分别是在×2 和×3 放大倍数下重建的SR图像，我们的方法能重建出高质量的图像，是清晰可视的。以Set14 中“barbara”图像为例，在×2 放大倍数下，CARN、MSRN方法恢复出的围巾模糊不清，存在严重失真，我们的方法几乎完美恢复了图像(图 4-6)。×3 放大倍数下，本文方法恢复结果类似(图

4-7)。图 4-8 是与当前最先进的、更轻量级网络，在Set14 数据集 $\times 4$ 放大倍数的主观视觉效果比较，我们的方法更好地恢复出了“with”的轮廓。图 4-9 和 4-10 是真实图像“Hilbert”与“Airplane”，在 $\times 4$ 放大倍数下的重建结果(左下角红色方框是局部放大图)。很容易观察到：我们的重建结果显著优于其它两个尖端的方法。




图 4-6 Set14 测试集中图像barbara的 $\times 2$ 视觉效果比较




图 4-7 Manga109 测试集中图像 YumeiroCooking 的 $\times 3$ 视觉效果比较




图 4-8 Set14 测试集中图像 ppt3 的×4 视觉效果比较




图 4-9 真实 Hilbert 图像×4 放大倍数下视觉效果比较




图 4-10 真实 Airplane 图像×4 放大倍数下视觉效果比较

4.5 本章小结

本章节详细介绍了训练网络所需要的实验参数，并做了大量对比实验验证证明本文方法的创新点。首先，在章节开头说明了实验中涉及到的参数设置，包括学习率，滤波器个数以及迭代周期等。接下来通过实验证明本文方法超参数设置的合理性，每一个参数值都对网络性能有着显著影响。大量对比实验证明本文方

法超参数设置的合理性，即只有设置本文方法中的参数，网络性能取得最好。然后，八组对比实验分别证明了本文方法提出的模块的有效性，只有包含三个模块的网络性能最好，超过了任何缺少其中一个模块的网络，我们的网络超过了当前许多最流行的轻量级网络。最后，大量的图表展示了本文方法的最终结果，从客观指标来看，本文方法性能最好，PSNR和SSIM都超过任何一个网络；从主观效果来看，在 $\times 2$ 、 $\times 3$ 和 $\times 4$ 倍数下，本文方法恢复出的图像都具有清晰的轮廓和锐利的边缘，能完美恢复出原图像，具有很好的视觉效果。

此外，在模型复杂度方面，本文方法在参数量和网络性能之间取得了很好的平衡，参数量不仅少，而且PSNR值更高。本文方法GFlops较其他网络很少，说明我们的网络计算量较少，占用计算资源很少。在Set5 $\times 4$ 放大倍数下，本文NRSR方法与其它轻量级模型相比，在运行时间、参数量和性能上取得了更好的平衡。

第5章 结论与展望

5.1 论文工作总结

随着深度学习的快速发展,基于卷积神经网络的单图像超分辨率算法成为研究热点,许多高效的方法相继被提出,重建的超分辨率图像质量越来越高。由于当前智能手机、移动设备等的普及,超分辨率技术还未能更好的服务于用户,这限制了超分辨率技术的应用前景。但是,许多已有的方法网络参数量巨大,计算复杂度高,更不利于资源受限的移动等设备。因此,本文提出了一种轻量级嵌套残差网络,与当前最具代表性的方法相比,本文方法不仅参数量少,而且重建效果良好,有利于移动等终端设备上的潜在使用。从实验结果来看,无论是在标准测试集上,还是真实自然图像上,都能重建出轮廓清晰、边缘锐利的高质量超分辨率图像。具体来说,本文主要工作有:

(1) 本文提出了多尺度特征融合块便于提取多样化特征。该模块使用不同感受野的卷积核提取特征,确保提取的特征信息更加多样化,为重建高质量图像提供丰富的细节信息。不同于一般的单尺度特征提取模块,我们的多尺度特征融合块并列两个不同尺寸卷积核,使用级联操作融合多样化特征,传递到深层网络中,提取更多丰富图像特征。具体来讲,我们在MSRN方法的基础上,去掉了多余卷积层,并且使用递归方式来组织并列的卷积核,通过级联操作融合不同尺度特征,一方面减少了网络参数量,增加了网络深度,另一方面减少了冗余信息。

(2) 本文提出了通道搅乱注意模块便于特征通道之间信息流动,增强网络对重要特征的选择,抑制次要特征信息,减少图像信息冗余。虽然通道搅乱在shuffleNet中首次提出,有效提高了图像分类准确率并减少了计算量。但是,我们首次引入到图像超分辨率重建中,实验也证明了这种用法是有效的。当前许多方法残差块中直接使用局部跳跃连接将浅层信息传递到深层,忽略了特征之间的相关性,限制了特征在通道之间的交流。我们结合通道搅乱和注意力机制的优势提出了通道搅乱注意模块。其中,通道搅乱运算促进了通道信息的流动,注意力机制增强了网络对特征的选择能力。

(3) 本文提出了全局特征融合连接便于提高浅层特征利用率。一般来讲,浅层特征包含大量低频信息。为充分利用这些低频信息,我们提出的全局特征融合连接使用逐点卷积将浅层特征融合到网络的每一个阶段,便于浅层特征和深层特征之间的融合,提高低频信息的利用率,尽可能减少特征信息的丢失,有利于恢复更多图像细节。

大量实验证明:与当前最流行的轻量级网络相比,本文方法不仅具有良好的客观PSNR/SSIM值,而且重建的超分辨率图像,轮廓清晰、细节丰富,几乎与原

图像相差无几。此外，本文方法参数量较少，运行时间短，在资源受限的移动等设备上具有潜在应用价值。

5.2 未来工作展望

本文基于深度学习的方法提出了一种轻量级嵌套残差超分辨率网络，在主观视觉和客观指标方面取得了良好效果，在移动等设备上具有一定潜在实用价值。但是本文方法仍有一些不足之处，主要有以下问题：

（1）本文网络结构主要使用递归方法，旨在加深网络的同时减少网络参数量，不可避免的带来了较大的计算量。因此，在保证网络性能的同时，可利用当前许多剪枝方法减少网络计算量，更好的在计算量和性能之间取得较好的平衡。

（2）本文方法都是在单尺度上训练网络，不同放大倍数对应不同模型，这为以后的使用带来不便。因此，通过进一步改进网络重建模块，使之训练出一个模型对应不同放大倍数，更好的适用于现实世界，以便带来更多商用价值。

单图像超分辨率重建作为计算机视觉领域的重点研究任务，是一个基础性的课题，不仅具有广阔的应用价值，而且在未来有很大的研究价值。以上是本人在研究生期间的主要研究内容，后续还有很大的研究空间，希望我的研究成果可以为单图像超分辨率重建技术研究做出一点微薄的贡献。

参考文献

- [1] Gonzalez R C, Woods R E. Digital Image Processing[M]. 电子工业出版社, 2007.
- [2] Rasti P, Uiboupin T, Escalera S, et al. Convolutional Neural Network Super Resolution for Face Recognition in Surveillance Monitoring[M]// Articulated Motion and Deformable Objects. Springer International Publishing, 2016:175 -184
- [3] Luo Y, Zhou L, Wang S, et al. Video Satellite Imagery Super Resolution via Convolutional Neural Networks[J]. IEEE Geoscience & Remote Sensing Letters, 2017, 14(12):2398-2402
- [4] Oktay O, Bai W, Lee M, et al. Multi-input Cardiac Image Super-Resolution Using Convolutional Neural Networks[C]// International Conference on Medical Image Computing and Computer-Assisted Intervention. Springer, Cham, 2016:246-254
- [5] Li X, Orchard M T. New edge-directed interpolation[J]. IEEE Trans Image Process, 2001, 10(10):1521-1527
- [6] Sun J, Xu Z, Shum H Y. Image super-resolution using gradient profile prior[C]//Proceedings of the 2008 IEEE Conference on Computer Vision and Pattern Recognition, Alaska, Jun 24-26, 2008. Piscataway: IEEE, 2008: 1-8.
- [7] Zhang X, Wu X. Image Interpolation by Adaptive 2-D Autoregressive Modeling and Soft-Decision Estimation[J]. IEEE Transactions on Image Processing, 2008, 17(6):887-896
- [8] Giachetti A, Asuni N. Real-time artifact-free image upscaling[J]. IEEE Transactions on Image Proces, 2011, 20(10):2760 - 2768
- [9] Xu L, Jia J. Two-phase kernel estimation for robust motion deblurring[C]//Proceedings of the 11th European Conference on Computer Vision, Crete, Sep 5-11, 2010. Cham: Springer, 2010: 157-170.
- [10] Shan Q, Li Z, Jia J, et al. Fast image/video upsampling[J]. ACM Transactions on Graphics, 2008, 27(5): 1-7.
- [11] Kim K I, Kwon Y. Single- image super- resolution using sparse regression and natural image prior[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2010, 32 (6): 1127-1133.
- [12] Xiong Z, Sun X, Wu F. Robust web image/video superresolution[J]. IEEE Transactions on Image Processing, 2010, 19 (8): 2017-2028.
- [13] Dong C, Loy C C, He K, et al. Learning a Deep Convolutional Network for Image Super-Resolution[J]. 2014.184–199

- [14] Dong C, Chen C L, Tang X. Accelerating the Super-Resolution Convolutional Neural Network[J]. 2016:391-407
- [15] Kim J, Lee J K, Lee K M. Accurate Image Super-Resolution Using Very Deep Convolutional Networks[J]. 2015:1646-1654
- [16] Kim J, Lee J K, Lee K M. Deeply-Recursive Convolutional Network for Image Super-Resolution[C]// 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, Las Vegas, USA, 2016: 1637-1645.
- [17] Tong T, Li G, Liu X, et al. Image Super-Resolution Using Dense Skip Connections[C]//IEEE International Conference on Computer Vision (ICCV). 2017:4809-4817.
- [18] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[C]//IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas: IEEE Computer Society, 2016: 770-778.
- [19] Ledig C, Wang Z, Shi W, et al. Photo-realistic single image super-resolution using a generative adversarial network [C]// IEEE Conference on Computer Vision and Pattern Recognition, Hawaii, USA: IEEE, 2017: 105-114.
- [20] Lim B, Son S, Kim H, et al. Enhanced Deep Residual Networks for Single Image Super-Resolution[C]// IEEE Conference on Computer Vision and Pattern Recognition Workshops. IEEE Computer Society, 2017:1132-1140
- [21] Juncheng Li, Faming Fang, Kangfu Mei, and Guixu Zhang. Multi-scale residual network for image superresolution. In Proceedings of the European Conference on Computer Vision (ECCV),2018: 517–532 .
- [22] Zhang Y, Li K, Li K, et al. Image Super-Resolution Using Very Deep Residual Channel Attention Networks[J]. 2018:294–310.
- [23] 陈一鸣,周登文.基于自适应级联的注意力网络的超分辨重建[J/OL].自动化学报:1-11[2021-05-31].<https://doi.org/10.16383/j.aas.c200035>.
- [24] 周登文,马路遥,田金月,孙秀秀.基于特征融合注意网络的图像超分辨率重建[J/OL].自动化学报:1-9[2021-05-31].<https://doi.org/10.16383/j.aas.c190428>.
- [25] 段然,周登文,赵丽娟,柴晓亮.基于多尺度特征映射网络的图像超分辨率重建[J].浙江大学学报(工学版),2019,53(07):1331-1339.
- [26] 周登文,赵丽娟,段然,柴晓亮.基于递归残差网络的图像超分辨率重建[J].自动化学报,2019,45(06):1157-1165.
- [27] Xiangyu Zhang, Xinyu Zhou, Mengxiao Lin, and Jian Sun. Shufflenet: An extremely efficient convolutional neural network for mobile devices. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition,2018: 6848–6856.
- [28] Sam S M, Kamardin K, Sjarif N N A, et al. Offline signature verification using deep

- learning convolutional neural network (CNN) architectures GoogLeNet inception-v1 and inception-v3[J]. *Procedia Computer Science*, 2019, 161: 475-483.
- [29] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. *Proceedings of the IEEE*, 1998, 86(11):2278-2324
- [30] Timofte R, De V, Gool L V. Anchored Neighborhood Regression for Fast Example Based Super-Resolution[C]// 2013 IEEE International Conference on Computer Vision (ICCV). IEEE Computer Society, 2013:1920-1927
- [31] Lai W S, Huang J B, Ahuja N, et al. Deep laplacian pyramid networks for fast and accurate super resolution[C]//IEEE Conference on Computer Vision and Pattern Recognition. Honolulu: IEEE Computer Society, 2017: 5835-5843.
- [32] Krizhevsky A, Sutskever I, Hinton G. Imagenet classification with deep convolutional neural networks[C]// NIPS. Curran Associates Inc. 2012:1106-1114.
- [33] Jie Hu, Li Shen, and Gang Sun. Squeeze-and-excitation networks. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2018: 7132–7141.
- [34] Li X, Wang W, Hu X, et al. Selective kernel networks[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 510-519.
- [35] LU Y, ZHOU Y, JIANG Z, et al. Channel attention and multi-level features fusion for single image super-resolution [C]// VCIP 2018:2018 IEEE Visual Communications and Image Processing. Taiwan: IEEE,2018:1-4.
- [36] LIU Y, WANG Y, LI N, et al. An attention-based approach for single image super resolution [C]// ICPR 2018: Proceedings of the 2018 International Conference on Pattern Recognition. Beijing: IEEE, 2018: 2777-2784.
- [37] Huynh-Thu Q, Ghanbari M. Scope of validity of PSNR in image/video quality assessment[J]. *Electronics Letters*, 2008, 44(13):800-801
- [38] Wang Z, Bovik A C, Sheikh H R, et al. Image quality assessment: from error visibility to structural similarity[J]. *IEEE Transactions on Image Processing*, 2004,13(4):600-612
- [39] Christian Ledig, Lucas Theis, Ferenc Husz'ar, Jose Caballero, Andrew Cunningham, Alejandro Acosta, Andrew Aitken, Alykhan Tejani, Johannes Totz, Zehan Wang, et al. Photo-realistic single image superresolution using a generative adversarial network. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2017:4681–4690.
- [40] Fei Wang, Mengqing Jiang, Chen Qian, Shuo Yang, Cheng Li, Honggang Zhang, Xiaogang Wang, and Xiaoou Tang. Residual attention network for image classification. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2017: 3156–3164 .
- [41] Zhen Li, Jinglei Yang, Zheng Liu, Xiaomin Yang, Gwanggil Jeon, and Wei Wu.

- Feedback network for image super-resolution. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2019: 3867–3876.
- [42] R. Timofte, E. Agustsson, L. Van Gool, M.-H. Yang, L. Zhang, Ntire 2017 challenge on single image super-resolution: Methods and results, in: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops, 2017: 114–125. 1, 6
- [43] Yulun Zhang, Yapeng Tian, Yu Kong, Bineng Zhong, and Yun Fu. Residual dense network for image superresolution. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018:2472–2481.
- [44] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[C]// Computer Vision and Pattern Recognition. IEEE, 2016:770-778
- [45] Ying Tai, Jian Yang, Xiaoming Liu, and Chunyan Xu. Memnet: A persistent memory network for imagerestoration. In Proceedings of the IEEE international conference on computer vision, 2017: 4539–4547.
- [46] Namhyuk Ahn, Byungkong Kang, and Kyung-Ah Sohn. Fast, accurate, and lightweight super-resolution with cascading residual network. In Proceedings of the European Conference on Computer Vision (ECCV), 2018: 252–268.
- [47] Feiyang Zhu and Qijun Zhao. Efficient single image super-resolution via hybrid residual feature learning with compact back-projection network. In Proceedings of the IEEE International Conference on Computer Vision Workshops, 2019: 0–0.
- [48] Zheng Hui, Xinbo Gao, Yunchu Yang, and Xiumei Wang. Lightweight image super-resolution with information multi-distillation network. In Proceedings of the 27th ACM International Conference on Multimedia, 2019: 2024–2032.
- [49] Juncheng Li, Faming Fang, Kangfu Mei, and Guixu Zhang. Multi-scale residual network for image superresolution. In Proceedings of the European Conference on Computer Vision (ECCV), 2018: 517–532.
- [50] Radu Timofte, Eirikur Agustsson, Luc Van Gool, Ming Hsuan Yang, and Lei Zhang. Ntire 2017 challenge on single image super-resolution: Methods and results. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops, 2017: 114–125.
- [51] Marco Bevilacqua, Aline Roumy, Christine Guillemot, and Marie Line Alberi-Morel. Low-complexity singleimage super-resolution based on nonnegative neighbor embedding. 2012:135.1–135.10.
- [52] Roman Zeyde, Michael Elad, and Matan Protter. On single image scale-up using sparse-representations. In International conference on curves and surfaces, Springer, 2010: 711–730.
- [53] David Martin, Charless Fowlkes, Doron Tal, Jitendra Malik. et al. A database of human

- segmented natural images and its application to evaluating segmentation algorithms and measuring ecological statistics. *Iccv Vancouver, Canada*, 2001:416-423.
- [54] Jia-Bin Huang, Abhishek Singh, and Narendra Ahuja. Single image super-resolution from transformed self-exemplars. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2015: 5197–5206.
- [55] Yusuke Matsui, Kota Ito, Yuji Aramaki, Azuma Fujimoto, Toru Ogawa, Toshihiko Yamasaki, and Kiyoharu Aizawa. Sketch-based manga retrieval using manga109 dataset. *Multimedia Tools and Applications*, 2017:76(20):21811–21838.
- [56] Diederik P Kingma and Jimmy Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv*, 2014:1412.6980.
- [57] Adam Paszke, Sam Gross, Soumith Chintala, Gregory Chanan, Edward Yang, Zachary DeVito, Zeming Lin, Alban Desmaison, Luca Antiga, and Adam Lerer. Automatic differentiation in pytorch. 2017.
- [58] Kai Zhang, Wangmeng Zuo, and Lei Zhang. Learning a single convolutional super-resolution network for multiple degradations. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2018: 3262–3271.
- [59] Wei-Sheng Lai, Jia-Bin Huang, Narendra Ahuja, and Ming-Hsuan Yang. Deep laplacian pyramid networks for fast and accurate super-resolution. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2017: 624– 632 .
- [60] Wenming Yang, Wei Wang, Xuechen Zhang, Shuifa Sun, and Qingmin Liao. Lightweight feature fusion network for single image super-resolution. *IEEE Signal Processing Letters*, 2019:26(4):538–542 .

攻读硕士学位期间发表的论文及其它成果

- [1] 除导师外学生第一作者. 一种轻量级的多尺度通道注意图像超分辨率重建网络. 电子学报. (EI刊源, CCF A类)
- [2] 学生第三作者. 基于多层次特征融合的图像超分辨率重建. 自动化学报. (EI刊源, CCF A类)
- [3] 学生第二作者. Dual-path Attention Network for Single Image Super-Resolution. Expert Systems with Applications. JCR分区一区)

致谢

三年的硕士生涯即将结束，在这难忘的三年里，每天过的充实而又快乐。值此之际，谨向那些帮助过我的老师和同学们，表达由衷的感谢。

首先。我要感谢导师周登文教授的谆谆教诲。周老师治学严谨、为人正直。对待科研一丝不苟，在我整个研究生期间给予了莫大的帮助。在课堂上总是能深入浅出的讲解基础知识，还不断启发我们思考，在教会了我们知识的同时，也教会了我们如何思考。每周六的组会更是让我们受益匪浅，大家相互交流近期心得，锻炼了我们的口才，也学会了不少技能。周老师的言传身教、以身作则，不断鼓舞着我们不断努力向前，唯有脚踏实地才能有所成果。

其次，我要感谢 721 的小伙伴们，李金新、黄志勇同学，他们总是在我困难的时候及时给予帮助，在科研的道路上相互鼓励。也感谢他们创造了一个良好的学术氛围，让我不再那么浮躁、不再那么急功近利。每一次的思想碰撞，总是有新的灵感爆发，让我的实验顺利搞下去；同时也在我错误的时候，能够及时止损。我要感谢他们的陪伴，无数个日日夜夜的努力，没有他们，科研的道路注定索然无味。

感谢师兄师姐们的指导，他们是我科研的领路人，是 721 的灯塔，也是 721 的榜样。优秀的段然师姐、赵丽娟师姐、田金月师姐、孙秀秀师姐，周鹏师兄、柴晓亮师兄、马路遥师兄。无论在科研上还是生活中，对我悉心的指导，让我少走了许多弯路，传授了我们经验，感谢他们无私的帮助。

感谢师弟师妹们的陪伴，王天生师弟、梁木师弟、马钰师弟、王凯峰师弟、李珊珊师妹、李艺攀师妹、王婉君师妹、高丹丹师妹。作为 721 的后浪，他们学习努力、刻苦认真。在枯燥的科研道路上，总能带来一丝丝的乐趣，让我们有信心努力向前，力争上游。

感谢各位评阅专家的辛苦审阅，感谢你们提出宝贵的修改意见，使我的工作更加完善，你们的认同也是对我莫大的鼓励。

感恩一切，特此致谢！