

华北电力大学

专业硕士学位论文

基于像素级对比学习的图像超分辨率研究

Pixel-wise Contrastive Learning for Image Super-Resolution

马钰

2023 年 5 月

国内图书分类号: TP39
国际图书分类号: 004.9

学校代码: 10079
密级: 公开

专业硕士学位论文

基于像素级对比学习的图像超分辨率研究

硕士研究生: 马钰

导师: 周登文教授

企业导师: 钱永臣

申请学位: 电子信息硕士

专业领域: 计算机技术

培养方式: 全日制

所在学院: 控制与计算机工程学院

答辩日期: 2023 年 5 月

授予学位单位: 华北电力大学

Classified Index: TP39

U.D.C: 004.9

Dissertation for the Professional Master's Degree

**Pixel-wise Contrastive Learning for Image
Super-Resolution**

Candidate:	Ma Yu
Supervisor:	Prof.Zhou Dengwen
Enterprise mentor:	Qian Yongchen
Academic Degree Applied for:	Electronic and Information Engineering
Speciality:	Computer Technology
Cultivation ways:	Full-time
School:	School of Control and Computer Engineering
Date of Defence:	May, 2023
Degree-Conferring-Institution:	North China Electric Power University

摘 要

图像的超分辨率重建是指采用低分辨率的单图像或一组图像来获取对应图像的高分辨率图像，从而提升图像质量。深度卷积神经网络已主导了当前单图像超分辨率（Single Image Super Resolution, SISR）技术的研究，并取得了很大的进展。但是，SISR 仍是一个开放性的问题，重建的超分辨率（Super-Resolution, SR）图像往往会出现模糊、纹理细节丢失和失真等问题。为了解决上述问题，本文提出了一个新的逐像素对比损失，在一个局部区域中，使 SR 图像的像素尽可能靠近对应的原高分辨率（High-Resolution, HR）图像的像素，并远离局部区域中的其它像素，可显著改进 SR 图像的保真度和视觉质量。此外，本文还提出了一种组合对比损失的渐进残差特征融合的 SR 网络架构，主要贡献包括：

（1）提出了一个通用的基于对比学习的逐像素损失函数，能够改进 SR 图像的保真度和视觉质量。在图像空间，对比损失使 SR 图像的像素尽可能靠近对应的 HR 图像的像素，并远离局部区域中的其它像素。同时损失函数还可以与其他 SR 网络架构协作使用。

（2）提出了一个轻量的多尺度残差通道注意力块，可以更好地融合多尺度的特征。

（3）提出了一个空间注意力融合块，可以更好地融合空间特征。

（4）提出了一个渐进的残差特征融合 SR 网络架构，组合了多尺度残差通道注意力块、空间注意力融合块和逐像素对比损失。实验结果显示，本文方法取得了有竞争力的 SR 性能，比其它代表性的方法性能显著更好。

关键词：图像超分辨率；卷积神经网络；对比学习；特征融合

Abstract

Image super-resolution reconstruction refers to the use of low resolution single images or a group of images to obtain high-resolution images of corresponding images, thereby improving image quality. Deep convolutional neural networks have dominated the current research on single image super-resolution (SISR) technology and made significant progress. However, SISR is still an open issue, and reconstructed super-resolution (SR) images often encounter issues such as blurring, loss of texture details, and distortion. In this paper, a new pixel-wise contrastive loss has been proposed. In a local area, keeping the SR pixels as close as possible to the original HR pixels and away from other pixels in the local area, which can significantly improve the fidelity and visual quality of the SR image. We also proposes an progressive residual feature fusion SR network architecture that combines with the comparative loss. Our main contributions include:

(1) A general pixel-wise contrastive loss function based on contrastive learning is proposed, which can improve the fidelity and visual quality of SR images. In image space, contrastive loss brings the SR pixels as close as possible to the original HR pixels and away from other pixels in the local area. Also the loss function can be used in collaboration with other SR network architectures.

(2) A lightweight multi-scale residual channel attention block is proposed to better fuse multi-scale features.

(3) A spatial attention fusion block is proposed, which can better fuse spatial features.

(4) A progressive residual feature fusion SR network architecture is proposed, combining a multi-scale residual channel attention block, a spatial attention fusion block, and a pixel-by-pixel contrast loss. The experimental results show that competitive SR performance is achieved, which is significantly better than other representative methods.

Keywords: image super-resolution , convolutional neural network , contrastive learning , feature fusion

目 录

第 1 章 绪论.....	1
1.1 课题背景及研究意义.....	1
1.2 国内外研究现状.....	2
1.2.1 基于插值的方法.....	2
1.2.2 基于重建的方法.....	3
1.2.3 基于学习的方法.....	4
1.3 主要研究内容.....	7
1.4 本文章节安排.....	8
第 2 章 图像超分辨率算法概述	9
2.1 卷积神经网络.....	9
2.2 注意力机制.....	13
2.2.1 通道注意力.....	13
2.2.2 混合空间注意力与通道注意力.....	14
2.3 特征融合网络.....	15
2.3.1 残差连接网络.....	15
2.3.2 密集连接网络.....	15
2.3.3 残差特征聚合网络.....	16
2.4 对比学习.....	17
2.5 本章小结.....	17
第 3 章 基于像素级对比学习的图像超分辨率算法	18
3.1 引言.....	18
3.2 相关损失函数.....	20
3.2.1 L_1 损失	20
3.2.2 L_2 损失	20
3.2.3 感知损失.....	21
3.2.4 对比损失.....	22
3.2.5 对抗损失.....	23
3.3 算法总体框架.....	24
3.3.1 网络结构.....	24
3.3.2 渐进特征融合组(PFFG)	25
3.3.3 多尺度残差通道注意力块(MRCAB)	26
3.3.4 空间注意力融合模块(SAFB).....	27
3.4 像素级对比损失函数.....	28
3.5 本章小结.....	30

第 4 章 实验与分析	32
4.1 引言	32
4.2 数据集	32
4.3 图像质量评价	32
4.3.1 峰值信噪比	33
4.3.2 结构相似性	33
4.3.3 主观评价指标	34
4.4 实验参数设置	34
4.5 实验细节	35
4.5.1 消融实验	35
4.5.2 对比损失的设计与分析	36
4.5.3 渐进特征融合模块的设计与分析	38
4.6 实验结果	40
4.6.1 客观结果	40
4.6.2 主观结果	40
4.7 本章小结	43
第 5 章 结论与展望	45
5.1 论文工作总结	45
5.2 未来工作展望	45
参考文献	47

第1章 绪论

1.1 课题背景及研究意义

当前,数据已成为科技发展的核心资源,推动了互联网产业迅猛发展,同时推动了人工智能技术的高速发展,这一趋势推动了人类进入全新的信息化时代。信息化时代的到来,使得人们的信息需求不断增长,包括对信息质量的要求越来越高。这导致相应的信息处理技术也在不断地发展和完善。在这一背景下,作为储存信息的重要载体之一,图像在各个领域所发挥的作用越来越重要。随着图像采集设备和传输技术的发展,图像数据可以获得的途径多元化,如智能电视、移动手机、电脑、数码相机、视频监控等设备,但是许多有重要应用价值的图像数据的分辨率较低。因此,超分辨率技术的发展与研究已经成为图像处理和计算机视觉领域中的基本问题。

在图像处理和计算机视觉领域,单图像超分辨率(Single Image Super Resolution, SISR)技术是一个基础问题,旨在通过处理低分辨率(Low Resolution, LR)图像来重建对应的高分辨率(High Resolution, HR)图像,从而提高图像的清晰度和感官效果^[1]。SISR能增强图像的视觉细节和保真度,达到提高图像分析和解释的准确性和可靠性的目的。拍摄照片在日常生活中常常会面临多种问题,如拍摄天气、距离、摄像设备、灯光和照片传送过程等方面的限制,导致照片的分辨率低等问题存在。以往的解决方法是改进硬件设施来提高分辨率,然而这种方式成本过高,而且在某种应用场景下如医疗器械,改进硬件设施非常困难。当前流行的方法是从软件角度入手,通过对已有的低分辨率图像进行信息补全,丰富细节信息特征,从而重建出高分辨率图像。这种方法相比于硬件更加经济实惠和灵活,并且在各个领域都得到了广泛使用。为此,人们提出了超分辨率重建的方法,超分辨率重建技术发展越来越成熟,应用在遥感图像^[2]、视频监控^[3]和医学成像^[4]等许多领域中。

在遥感图像处理中,需要高分辨率图像来提高图像的精度和信息量,以更好地进行识别和分类。由于传感器的像元大小和成像分辨率以及天气影响等因素,造成拍摄的图像分辨率较低。利用图像内部的信息,超分辨率技术对低分辨率的遥感图像进行处理,以生成高清图像。融合航空遥感图像和卫星遥感图像,并对这些图像进行分析和理解,可以获得更全面和准确的地表覆盖信息。在监控领域中,由于监控设备的限制以及天气等原因造成采集的画面较为模糊,难以满足实际需求。超分辨率可以用于监控图像的细节增强、目标跟踪、行为分析等方面,

可以恢复监控视频中细节信息,提高监控效果和准确性,提高目标跟踪的精度和鲁棒性,更好地分析和识别目标的行为。医学成像是通过现代的一些医疗设备(如超声等仪器),利用计算机来形成一种真实图像,可以对人体的形态、组织器官等方面进行全面细致的观察,对于疾病的诊断和治疗有着非常重要的作用。医学成像图片的分辨率直接关系到医生对患者病情的判断和诊断。高分辨率的医学成像图片可以提供更多的细节和信息,使医生在检测病变、诊断疾病和制定治疗方案时更加准确。另外,医学成像技术已经成为了许多医疗科技产品的核心部分,例如计算机断层扫描和磁共振成像,这些技术需要高分辨率的成像图片来提供更准确和清晰的图像,从而帮助医生做出更好的诊断和治疗决策。在多媒体视频领域的应用主要是提高视频质量和增强观感效果。在现代设备上观看经典电影时,由于时间久远以及当时拍摄设备的限制,会出现图像模糊和失真的问题,使用超分辨率技术可以将经典电影或纪录片转换为高分辨率视频,从而提高视频的清晰度和细节展现效果。超分辨率技术也可以用于视频编辑和特效制作中,例如将低分辨率视频转换为高分辨率视频后再进行剪辑、特效添加等操作,可以在视觉上提高视频的质量和观感效果。

总体而言,图像超分辨率技术在提高图像、视频等数据的质量和清晰度,增强信息获取能力方面具有重要意义。此外,超分辨率技术还可以解决一些实际问题。由于具有广泛的应用前景,图像超分辨率算法的研究值得进一步深入研究和探索。

1.2 国内外研究现状

图像超分辨率方法是视觉领域的经典问题,也是一个不适定问题。许多高清图像都可能退化为相同的低分辨率图像,因此需要先验知识来约束解的超分辨率图像解空间。即使进行了超分辨率图像的重建,仍然存在模糊、失真和纹理细节丢失等问题。过去,超分辨率的方法主要基于插值,例如双线性插值和双三次插值。尽管这些方法计算代价较低,但无法恢复丢失的细节。基于重建的超分辨率方法改进了插值方法,但通常优化困难,推理复杂度高。当前,基于学习的方法超分辨率技术得到了不断突破与发展,并受到众多研究者的关注。

1.2.1 基于插值的方法

基于插值的方法是超分辨率算法中基础的一种方法,这种方法的基本思想是,根据低分辨率图像的已知信息,利用插值的方式生成高分辨率图像。插值的原理是基于已知数据点的信息来构建函数,然后在该函数上求解未知点的函数值或导

数值。常见的插值方法中，包括最近邻插值^[5]、双线性插值^[6]和双三次插值^[7]。其中最近邻插值较为简单，直接将最近邻的像素值赋值给目标像素，该算法的速度快，但效果差，容易出现锯齿状伪影；双线性插值法由 x 轴和 y 轴两个方向 4 个像素点的进行加权平均求出目标像素值，插值后的图像更加平滑，效果较上种方法较好，但是计算量稍大；双三次插值法是大多数研究者常采用的插值方法，增加了采样点的区域和插值次数，利用 4×4 邻域内的 16 个采样点，采样 3 次，对每个像素计算插值过程中的权重系数，进行加权平均。双三次插值采集了更多的像素信息，所以双三次生成的图像质量更好，细节更加清晰，但计算量较大，计算速度较慢。

传统的插值方法中，插值函数的形式是固定的，且未考虑图像中结构信息，生成的图像边缘往往出现锯齿状伪影。为了缓解这个问题，Li 等^[8]提出的基于边缘指导的插值方法，对图像进行边缘检测获得结构信息并且修复不连续的线段，根据边缘信息指导插值过程，对于边缘信息突出的图像，能够有效提高图像质量；Battiatto 等^[9]提出局部自适应的图像缩放算法，根据图像局部的特征和纹理信息调整图像的缩放方式，通过自适应权重调整插值的效果，从而提高图像的质量，但存在一定的计算复杂度和时间消耗。

总的来说，基于插值方法最大的优点是简单、操作易实现。但是在插值的过程中仅计算局部区域的像素信息，并没有从全局的角度考虑，会产生明显的伪影和失真。因此，在实际应用中，需要结合其他方法提高重建图像的质量。

1.2.2 基于重建的方法

相较于基于插值的方法，本节论述的方法通过学习大量的 LR 图像到 HR 图像的映射，它能更准确地恢复图像的细节信息，提高图像的清晰度和质量。Tsai 等^[10]将低分辨率图像划分为不同时序，并转到频率域。通过对频率域图像重建和恢复，达到了较好的效果。傅里叶变换在该方法中作为中间媒介，用于实现 LR 图像到频率域的转换，并提供高分辨率图像重建所需的频率信息。Irani 等^[11]提出了迭代反投影的方法，将输入图像进行分解，得到层级，从高层开始，对当前层进行插值上采样得到初步估计图像，然后将该图像投影到该层的低分辨率图像上，并计算误差，得到残差图像。接着利用反投影的方法将残差图像投影到当前层的高分辨率图像上，得到更精确的残差图像，这个过程反复迭代，直到残差图像的大小小于设定的阈值为止。由于降采样的过程是未知的，投影过程会产生较大误差，因此该算法对初始估计的要求较高，对噪声等干扰较为敏感。Schultz 等^[12]提出的最大后验概率估计方法是一种基于贝叶斯统计的非线性超分辨率方法。根据图像是否有噪声分为两种情况处理。无噪声情况下，将超分辨率问题转

化为最大后验概率问题，通过优化凸函数来求解高分辨率图像；有噪声情况下，引入正则项，将问题转化为二次规划问题，通过求解得到高分辨率图像。与其他方法相比，该方法能够较好地解决噪声问题，引入正则化避免过拟合。经过实验验证，该方法可以生成高质量、清晰度较高的图像，达到较好的超分辨率效果。

总的来说，基于重建的方法需要更多的计算和先验信息，但是可以获得更好的重建效果，对于一些纹理较为繁多的图像，基于重建的方法可以更好地重建出细节纹理信息。由于单张图像的先验知识有限，LR 图像本身就缺少纹理边缘细节，得到的 HR 图像仍然存在模糊的情况。在使用基于重建的方法时，需要充分考虑先验知识的限制，并对初始值的选择进行合理控制。现在的超分辨率技术更倾向于使用基于学习的方法，通过神经网络模型和大量数据的学习，实现对高分辨率图像的重建。

1.2.3 基于学习的方法

基于学习的超分辨率方法通常使用深度学习网络，如卷积神经网络、生成对抗网络或扩散模型等技术来实现图像超分辨率的一种方法。与上节介绍的方法相比，基于学习的方法主要对 LR 图像的高频纹理细节进行恢复，不需要先验知识和手动设计特征，而是通过训练大量数据，以及神经网络自动学习图像的高频信息。通常分为两个阶段：训练和测试。在训练阶段，首先使用一组 LR 图像和对应的 HR 图像，学习从 LR 图像到 HR 图像的映射。在测试阶段，将图像输入到训练好的网络中，模型输出其对应的 HR 图像，重建出高质量的超分辨率效果。

早期的基于学习的图像超分辨率方法有：基于稀疏表示的方法^[13]、基于邻近嵌入的方法^[14]和基于样例学习的方法^[15]。基于稀疏表示的方法将 LR 图像表示为一组向量的线性组合，这些向量是从高分辨率图像提取的，包含纹理和结构信息。通过对基础向量进行选择 and 权重的优化，可以得到一个更接近于高分辨率图像的重建图像。稀疏表示对于字典的构建要求较高，依赖大量的训练数据来学习字典，因此训练较为困难；基于邻近嵌入的方法考虑了更多样本，它会找出每个 LR 图像块的 K 个近邻图像块，并使用几何流形的概念来计算它们之间的相似性。假设高分辨率块和低分辨率块的几何流形结构相似，该方法计算 K 个近邻图像块与目标图像块的相似系数，并将其用作加权系数，最终对应的高分辨率图像块加权融合以获得目标的高分辨率图像块。这种方法类似于用不同的特征来表示一个特征，然后线性组合得到想要的特征，因此它可以减小数据集的规模，更加灵活；基于样例学习的方法利用高分辨率图像和相应的低分辨率图像对学习一个回归模型。具体来说，将低分辨率图像划分为若干个子块，从示例对中选择一个具有相似特征的锚点块，然后通过邻域回归的方法学习低分辨率子块到锚点块的映射

关系。该方法需要大量的数据集，容易过拟合，算法复杂度较高，因此很难在实际应用中使用。

随着深度学习的发展和硬件算力的提高，深度学习网络在多个领域大放异彩，在超分辨率这项任务中取得了显著的性能，接下来将关注基于深度学习的 SISR 算法。其可分为两类：基于图像重建和基于感知的方法。基于图像重建的方法使用均方误差和绝对值误差作为损失函数，学习从 LR 图像到 HR 图像的映射函数，生成像素值更加正确的 SR 图像。基于感知的方法目标是在视觉感官上生成类似于 HR 图像的 SR 图像，使用感知损失或对抗损失来优化生成的图像。2014 年，Dong 等^[16]首次将卷积神经网络引入到 SR 任务中，提出了 SRCNN，奠定了卷积神经网络在 SISR 这个领域的基础，该方法首先将经过插值上采样后的图像作为网络的输入，再输入到三个卷积层组成的网络生成高分辨率图像，在多个基准数据集上取得了显著的性能。由于 SRCNN 网络较浅，提取特征的能力较弱，随后提出了 FSRCNN^[17]网络，低分辨率图像输入网络前不再经过插值放大，图像尺寸较小的情况下进行训练，大大减少了计算量，缩小了训练时间，随后加深网络深度，在尾部使用反卷积的方法对特征图像进行放大，效果显著提升，以后的工作大多采用这种方式来重建高分辨率图像，但是反卷积在放大图像时往往会出现棋盘效应。为了改善这个问题，ESPCN^[18]提出亚像素卷积的方式进行上采样，将卷积操作的输出通道数扩展到原来的平方，提供更丰富的信息，改善超分辨率效果，但参数量较大。

传统的浅层网络结构中，只能对数据进行简单的线性或非线性变换，无法提取高层次特征。更深的层数和更丰富的结构，可以进一步提高模型的表达能力和精度。He 等^[19]在 2016 年提出了 ResNet，解决了深度网络中梯度消失的问题，其提出的残差学习的方法帮助较深网络更好地学习，基本思想是使用跳跃连接，将两个不同深度的特征逐像素相加，使梯度能够通过深度神经网络更有效地传播，有关研究学者也将这一思想引入到超分辨率领域。Kim 等^[20]提出的 VDSR，构建非常深的卷积神经网络，具有 20 个卷积层，提高了网络的非线性映射能力，并采用残差学习的方法进一步提高了网络的性能，优于之前的超分辨率方法。DRCN^[21]在残差学习的基础上引入了递归学习来进行超分辨率重建工作，将一个卷积层作为迭代单元，在不增加参数量的情况下，提高网络的感受野和表达能力，但计算量会成倍提升。Tai 等^[22]在 2018 年提出了 MemNet，在网络架构中使用记忆模块，每个存储块由卷积层、线性修正单元和短期存储模块组成，网络的每个特征提取块都参与了最后的输出，允许网络捕捉远距离特征图像素之间的相关性。CARN^[23]利用级联结构来提高超分辨率的准确性，利用多尺度特征提取方法有效捕捉图像的局部和全局特征。此外，利用残差学习加快了收敛速度并提高性能。

SRResNet^[24]利用跳跃连接和残差学习提高超分辨率的性能,使得训练时梯度更容易传播和网络更容易优化。此外,采用感知损失函数来生成更多的高频细节和更好的感官效果。Zhang 等^[25]提出的 RDN,使用残差稠密连接。稠密连接和残差稠密连接比残差连接可以更好地利用深度卷积层的分层特征。Lim 等^[26]提出了 EDSR 网络,去掉了 SRResNet 中的批归一化层,研究者发现图像被归一化以后,色彩的分布也会被归一化,对于超分辨率这个任务并不适用。Zhang 等^[27]在 2018 年提出了 RCAN 网络,由多个残差块组成,每个残差块包含通道注意力机制,并引入局部残差连接,取得了具有竞争力的结果。有趣的是,通过改进策略,RCAN 模型能够胜出或匹配几乎所有之后出版的基于卷积神经网络的模型^[28]。Tong 等^[29]提出的 SRDenseNet 使用了稠密连接。注意力机制在 SR 网络中也得到了广泛的关注。通道注意力机制^[27]考虑不同通道之间特征之间的依赖,显著提高了模型的表示能力和网络性能。Zhang 等^[30]提出了一种非局部注意块,以建模长距离像素之间的依赖,可以很好地捕捉空间注意力,进一步增强特征的表示能力。Niu 等^[31]提出的 HAN,进一步组合了层注意力、通道和空间注意力,以建模层、通道和空间位置之间的整体依赖。Li 等^[32]提出的 MSRN 方法,采用局部多路径学习,同时提取多个尺度特征,改进了特征的表示能力。视觉 Transformer^[33,34]能够建模全局像素之间的依赖,在图像分类、物体检测和分割等高级视觉任务中,取得了巨大的成功,在盲超分领域^[35,36]也大放异彩。Liang 等^[37]将 Swin Transformer^[38]引入到图像恢复,取得了最先进的性能。这些代表性的方法,虽有好的性能,但是,模型参数量较大,需要较大的内存和较强的计算能力,限制了它们在资源受限的设备上的应用,当前网络架构设计的一个趋势是:设计更轻量的网络模型,找到最优的网络模型复杂度和性能之间最优的平衡^[39]。

当前基于卷积神经网络的超分辨率研究,大多聚焦于网络架构设计,但是,合适的损失函数对超分辨率模型的性能至关重要。当前,最广泛使用的损失函数是逐像素的即平均绝对误差和均方误差。这些逐像素的误差度量,返回许多可能解的平均值^[40],会导致重建图像模糊、过度平滑和不自然的外观,尤其是在信息丰富的区域。为缓解这个问题,Johnson 等^[41]提出感知损失,结合了人类视觉系统的特性,更加关注图像的语义信息,使用预训练的 VGG 网络,在特征空间度量高级感知和语义差异。感知损失和 L_1 等像素损失不同,其目的并非仅仅鼓励生成的图像像素匹配目标图像的像素。相反,感知损失侧重于鼓励生成的图像和目标图像具有相似的特征,而不是像素级别的匹配。考虑到重建图像应与目标图像具有相同的纹理,Sajjadi 等^[42]提出了一种基于块的纹理损失。图像纹理视为不同特征通道之间的相关性,其定义基于预训练分类网络特征的 Gram 矩阵。纹理损失迫使重建图像应与目标图像之间局部纹理相似。Ledig 等^[24]提出 SRGAN,

鼓励图像逼近自然图像流行。这些损失函数改进了重建图像的视觉质量，但是保真度较低，更重要的是，仍然不能阻止图像的模糊。

1.3 主要研究内容

在深度学习快速发展的趋势下，许多算法为了追求高性能，不断加深网络的深度和加宽网络的宽度，但是随着参数量和计算量的剧增，在计算和存储资源受限设备上难以应用。SISR 是一个具有挑战性的不适定问题，存在许多的高分辨率图像可以退化成同一个低分辨率图像，目前许多方法利用平均绝对误差或均方误差来最小化生成的超分辨率图像和高分辨率图像对应像素之间的距离这可能会导致最终得到的超分辨率图像是解空间的均值，重建的图像往往过于平滑，不接近人类对自然图像的视觉感受。为了解决上述问题，本文提出了一个新的基于对比学习的逐像素损失函数和一个新的网络架构，称为渐进的残差特征融合网络。实验结果表明：该网络组合基于对比学习的逐像素损失函数，取得了有竞争力的性能。具体来说，本文的主要创新点有 3 个：

(1) 提出了一个新的基于对比学习的逐像素损失函数。它仅利用配对的 LR 图像与 HR 图像的内部像素信息，而不依赖于非配对的 LR 图像。在图像空间，训练 HR 图像与输出的 SR 图像对应的像素分别作为正样本和锚，HR 图像上与正样本像素值不同的像素作为负样本集合，与正样本像素值相同的像素构成正样本集合。该损失函数以对比学习的方式拉近正样本对之间的距离，推远负样本对之间的距离。通过对比学习的方式把锚点像素更好地接近 HR 图像上相同位置的像素，使最终得到的重建图像的像素与 HR 图像上相同位置的像素更加接近，改进超分辨率网络的性能。

(2) 提出了一个新的网络架构，称为渐进残差特征融合网络。本网络应用扩张卷积^[43]扩展 RCAN^[27]的基本构件-残差通道注意力块，以支持多尺度特征，称为多尺度残差通道注意力块。以多尺度残差通道注意力块作为基本构件，并运用空间注意力机制^[44]，渐进地融合多尺度残差通道注意力块的特征，从而使融合后的特征更加有利于网络的学习。实验证明，我们的方法优于当前类似方法的性能。

(3) 提出的渐进残差特征融合网络与基于对比学习的逐像素损失函数结合取得了具有竞争力的超分辨率方法的性能（客观和主观性能）。此外实验还表明，L_{PCL} 能提升其他超分辨率方法的性能。

1.4 本文章节安排

本文组织内容结构如下：

第一章，绪论。在第一小节中，主要探讨了研究超分辨率算法的背景、应用场景和研究意义。在第二小节中，分析了图像超分辨率算法在国内外研究领域的现状，特别关注了基于卷积神经网络的方法，这与本文工作相关。最后，对论文的内容和架构进行了总结和梳理。

第二章，相关超分辨率算法概述。首先介绍了卷积神经网络的基础知识内容。其次介绍了与本文工作相关的两个 SISR 算法相关知识：注意力机制和特征融合网络。

第三章，基于像素级对比学习的图像超分辨率研究。本章节介绍了当前其他损失函数以及模型存在的问题，针对这些问题所提出本文的方法，提出了基于对比学习的逐像素损失函数和渐进残差特征融合网络，之后详细介绍了各个损失和各个模块的实现过程。

第四章，实验与分析。本章主要介绍了算法进行训练和测试所用数据集以及训练时一些超参数的设置，为了证明损失函数和各个模块的有效性以及超参数设计的合理性，设计消融实验和对比实验。最后与其他先进方法做比较，无论从客观指标，还是主观视觉效果图，都说明了本文方法的有效性。

第五章，总结与展望。在最后一章节对所提出的算法进行了总结，还对一些可能需要进一步完善的地方做了阐述，为以后超分辨率工作的开展进行展望。

第 2 章 图像超分辨率算法概述

2.1 卷积神经网络

卷积神经网络 (Convolutional Neural Networks, CNN) 是一种人工神经网络, 通常用于处理结构数据, 如图像。其基本原理就是卷积操作提取输入数据的特征, 然后通过层与层之间的权重进行组合, 这些权重可以根据输入的数据不断更新, 得到更利于模型性能的权重。通常包括卷积层、池化层、激活层和全连接层。CNN 的结构如下图 2-1 所示。卷积层利用卷积核对数据进行卷积操作进行特征提取和变换。卷积层后是激活函数, 用于引入非线性, 增强网络拟合能力。池化层是深度学习中常用的方法, 其作用是减小神经网络模型中特征图的大小, 汇聚邻近像素提高特征的抽象层次, 保留重要特征。全连接层把特征进行汇总, 并组合成输出结果。下面详解分析各个层的内容。




图 2-1 卷积神经网络示意图

卷积层：是 CNN 的核心组成部分，主要功能在于采用卷积操作提取特征，以便用于分类、监测、分割等任务，其参数由可学习的滤波器构成，本质是一个加权和操作。卷积层的独到优势在于参数共享和局部连接，参数共享使得网络在参数量在很小的情况下达到很好的性能，也增强了平移不变性；局部连接使得网络对局部特征有很好的提取能力。卷积核在输入数据上进行滑动并执行加权和操作，每个元素与输入数据的元素相乘，然后将所有值相加得到单个输出值。

滤波器的形状通常为矩形或正方形，由三个维度组成：宽度、高度和深度，大小相对来说较小。深度与输入数据深度相同，正向传播时滤波器在宽度和高度两个维度上滑动，可以选择不同的步长和输入特征周围不同大小的 0 填充。每个卷积滤波器在卷积操作后得到一个独特的特征图，因为它们在提取图像中的不同特征时被激活，比如边缘或形状。这些滤波器的选择和激活帮助神经网络更好地理解输入图像。随着卷积层的增多，每个神经元在输入图像上的感受野会随之增大，能够获取更多的上下文信息，从而减少每一层计算利用信息不足的问题，取得了更好的性能表现。

为了降低计算量或者赋予网络不同的能力，研究人员试图改进卷积操作，于是出现了转置卷积、空洞卷积和深度可分离卷积等操作。这些方法在卷积操作中引入了新的思想和技术，使得网络可以更有效地处理不同的数据，提升特定任务的性能。

a) 转置卷积^[18]，主要用于对图像数据进行上采样操作。普通卷积在不引入填充的情况下，会把输入数据的空间缩小。转置卷积与之操作相反，将空间维度放大，得到较大分辨率的图像。由于转置卷积可以增加特征图的分辨率来生成更高分辨率的图像，在图像处理领域得到了广泛应用。但存在一些局限，进行上采样后的图像会出现棋盘状条纹。

b) 空洞卷积^[43]，与标准卷积类似，在卷积核内部扩大了参数与参数之间的距离，也称为“膨胀”，扩大了感受野，获取更多的上下文信息，提高网络的特征表示能力。与普通卷积相比，可以不引入额外的参数，从而避免参数量过大的情况。同时，空洞卷积可能会出现网格效应，导致信息的不连续性，在特征图较小的情况下，可能会损失信息。因此，空洞率大小的设置非常重要。总之，空洞卷积可以帮助提高模型的性能，但要注意超参数设置需要合理设计。

c) 深度可分离卷积^[44]，与普通的卷积操作相比，深度可分离卷积将标准卷积拆分为逐通道卷积和逐点卷积两个步骤，提高了模型的计算速度。具体来说，深度可分离卷积首先在每个通道上进行卷积操作，然后为了使各通道间具有相关性，进行逐点卷积，即对逐通道卷积输出的每个位置进行 1×1 的卷积。与标准卷积相比，深度可分离卷积的计算量和参数量减少了百分之九十以上。目前因为其高效的计算和低参数的特点，深度可分离卷积被广泛应用于移动设备等资源受限的场景。实际应用中，深度可分离卷积已被证明可以取得与标准卷积相当的性能表现，且比卷积的参数量和计算量少。

池化层：又称为降采样层，将特征图的空间维度降低，在减少特征图的空间维度的同时保留了重要信息，如图 2-2 所示。




图 2-2 均值池化与最大值池化示意图

池化层的主要功能是通过将一个窗口内的像素信息聚集到一个像素中来对特征图进行降采样。池化也是采用窗口滑动方式，在一个小的矩形框中执行，最常见的窗口大小为 2×2 或 3×3 。卷积神经网络中常用的池化的方式有很多种，包括均值池化和最大值池化等。最大值池化是最常用的池化方法，取每个窗口内的最大值作为输出值。经常用于提取特征、降低特征图空间维度以及防止过拟合。优点是不需要参数学习，可以有效降低网络的计算复杂度。缺点是容易丢失一些较重要的特征，没有考虑像素间的相关性。此外，最大值池化可能会导致图像平移、旋转等变化时特征丢失或位置偏移等问题。均值池化是对逐窗口内区域的像素值求平均值作为输出值。

与最大值池化不同的是，均值池化对于区域内的像素有相同的权重，可以平滑特征图上的空间细节。但是当图像中含有大量噪声时，均值池化会损失重要的局部细节信息，因为噪声会影响均值池化输出的平均值。

激活层：是 CNN 中不可或缺的一层，如果仅仅堆叠卷积层而不使用激活层，神经网络无法处理非线性问题。激活函数允许网络学习和处理更加复杂的问题，捕捉更加复杂的数据模式和特征，从而提升模型的性能和表达能力。同时，激活层还可以帮助反向传播过程中限制梯度大小并增加稳定性，消除梯度消失问题。因此，激活层不仅可以引入非线性特征，还可以帮助解决梯度消失问题，提高网络的性能和训练的稳定性。常见的激活函数的种类有：Sigmoid、Tanh、ReLU、PReLU 等。

a) Sigmoid，函数图像如图 2-3 a) 所示，其公式为：

$$\text{sigmoid}(x) = \frac{1}{1 + e^{-x}}. \quad (2-1)$$

Sigmoid 函数的输出值在 0 到 1 之间，具有平滑性和可导性，使得网络优化更加容易。Sigmoid 函数通常用于二分类问题中，作为输出层的激活函数，如分类任务。但是，Sigmoid 函数也存在一些问题，输入值非常大或者非常小时，梯度会变得非常小，无限接近于 0，在反向传播时出现梯度消失。当输入值为 0 时，函数的导数值最大，导致在梯度更新时，使得参数更新时幅度较小，收敛难度较大。

b) Tanh，又叫双曲正切函数，如图 2-3 b) 所示，其公式为：

$$\text{tanh}(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}. \quad (2-2)$$

Tanh 函数可以将任何实数映射到 -1 到 1 的区间内，与 Sigmoid 函数相似，但是可以更好的处理一些非线性问题，因为其输出区间较为广泛。Tanh 函数具有单调性和连续性，且具有中心化的特点，即输出的均值为 0，有利于降低偏差

误差。同时也会存在一些问题，当输入值绝对值很大的情况下，函数的梯度会很小，接近于 0，不可避免导致梯度消失的问题。因此，在具体应用中，需要根据具体任务选择合适的激活函数。

c) ReLU，称为修正线性单元函数，如图 2-3 c) 所示，公式为：

$$\text{relu}(x) = \max(0, x). \quad (2-3)$$

ReLU 函数是一个简单而有效的函数，当输入值大于 0 时，输出不变，导数为 1，如果输出为负数时，则返回 0，导数为 0。ReLU 函数与上述的函数相比有以下几个优点：由于大于 0 的输入具有导数值为 1 的导数，反向传播时梯度不会变小，可以不受梯度消失问题的困扰；计算效率高，只需要简单阈值操作，不要复杂的数值运算，使得其可以在很多网络中使用。然而，ReLU 存在一些缺点，




图 2-3 常用激活函数的图像

如果神经元的输出持续为负值时，神经元将永远不会更新，导致“死亡神经元”。可以通过使用 ReLU 函数的变种来解决这个问题，比如 PReLU 或 Leaky ReLU。

d) PReLU，又称为参数校正线性单元，是对 ReLU 函数的扩展，解决了输入值小于 0 时，梯度不更新的限制。在输入值 $x < 0$ 区间内，引入了一个可学习的参数 α ，即输入小于 0 的导数为 α ，函数如图 2-3 d) 所示，公式如下：

$$prelu(x) = \begin{cases} x & x \geq 0 \\ \alpha x & x < 0 \end{cases} \quad (2-4)$$

PReLU 函数优点包括防止过拟合，避免陷入局部最小值，已成功应用于计算机视觉任务中。缺点是增加了模型的复杂度，因为每个 PReLU 激活函数都含有一个学习参数 α ，导致训练的收敛速度变慢，训练性能不稳定。

全连接层：许多深度学习模型的关键部分，一般在网络的最后出现，将一层中的每个神经元连接到下一层的每个神经元，从而实现了全连接。在全连接层中每个神经元从上一层的所有神经元接收输入，其输入送到下一层的所有神经元。全连接层中的权重矩阵和偏差向量是在训练过程中优化的可学习参数。权重矩阵决定每个输入神经元和输出神经元之间的连接强度，而偏置向量通过添加一个恒定值来调整每个神经元的输出。全连接层可以与不同的激活函数结合，增强网络的表示能力和非线性拟合能力。然而，全连接层的计算复杂度较高，需要的内存较多，容易过拟合，特别是在大型网络中，因为全连接层整合所有特征信息。可以利用 dropout、权重衰减、批归一化或 L1/L2 正则化等方法来缓解这个问题。总之，全连接层在卷积神经网络中发挥着关键作用，可用于分类、回归等任务中。但也需要注意其存在过拟合等问题，需要采用合适的策略来调整。

2.2 注意力机制

注意力机制在分类、分割、目标检测和图像重建等领域等都有着广泛的应用。注意力机制可以关注感兴趣的区域，忽略无用的信息。例如，在 SR 领域，注意力机制聚焦于图像中的重要区域，引导网络聚焦于图像的细节和纹理信息；在图像分类任务中，通常情况下，模型会将所有输入的特征视为同等重要，但实际上某些特征如物体的轮廓，可能对分类性能的提高帮助更大，注意力机制使模型关注图像重要部分。接下来详细介绍与本文工作相关的通道注意力及其与空间注意力的混合。通道注意力关注通道维度，计算每个通道权重；空间注意力主要关注空间维度，计算每个空间位置的权重。

2.2.1 通道注意力

通道注意力旨在动态调整输入的通道权重，使网络关注有用的信息并抑制无用的信息，从而提高模型性能。SENet^[56]首先提出了通道注意力机制，解决 CNN 中通道之间信息交互不足的问题。主要包含两个操作：Squeeze 和 Excitation。Squeeze 通过全局平均池化将每个通道的特征图降维成一个值，以赋予每个通道的重要性。Excitation 通过学习通道权重来调整特征图上每个通道的重要性，加

强有用的通道权重，抑制无用的通道权重，其计算过程如图 2-4 所示。




图 2-4 通道注意力模块^[56]

Zhang 等^[27]提出了 RCAN，在网络中引入残差块和通道注意力机制，提高了网络的性能和超分辨率图像的质量和保真度。维度为 $H \times W \times C$ 的特征图经过池化，得到 $1 \times 1 \times C$ 的输出，然后进行放缩，提高非线性能力，再利用 Sigmoid 函数进行归一化，得到权重系数，最终与原始特征图相乘。

近年来出现了一些改进通道注意力的模型，如 MCSN^[59]、CBAM^[44]等。SKNet 提出基于自适应卷积的通道注意力机制，通过动态选择不同的卷积核的大小和形状来增强有用的特征。CBAM 在通道注意力的基础上提出空间注意力，动态调整每个空间位置的权重来进一步提升性能。通道注意力机制是一种简单而有效的方法，应用在广泛的任务中。

2.2.2 混合空间注意力与通道注意力

空间注意力用于增强对于空间信息的感知和处理能力。与通道注意力不同，通道注意力是关注通道的重要性，而空间注意力对每个空间位置的赋予不同的权重。由于二者的关注维度不同，若同时使用，那么就可以同时注意到通道和空间位置信息，其结构如图 2-5 所示。




图 2-5 混合注意力 BAM 模块^[58]

空间注意力与通道注意力在空间维度和通道维度可以相互作用，增强网络特征提取能力。BAM^[58]论文中将空间注意力和通道注意力混合使用。给定特征图 $H \times W \times C$ ，模型的一条支路上在通道维度上对其进行全局平均池化操作，再进行放缩，得到通道注意力权重，以突出重要的特征通道；另一条支路进行 3×3 卷积

和 1×1 卷积，得到空间注意力权重，以突出图像中的重要区域。BAM 将空间注意力特征图与通道注意力相结合，以获取更丰富的特征表示。混合注意力已被证明在不同的深度学习架构中都具有很好的效果，是一种广泛应用的注意力机制。

2.3 特征融合网络

2.3.1 残差连接网络

随着神经网络层数的加深，研究者们发现网络层数增加反而出现性能变差的情况。残差特征融合最早应用于 ResNet 中，核心思想是引入残差模块，使得网络学习到恒等映射。其操作较为简单，将不同层的特征通过逐元素相加融合起来，允许梯度跨层流动，避免了由于网络过深而导致的梯度消失问题。Lim 等^[26]在 2017 年提出 EDSR 方法，获得了 NTIRE 超分辨率赛道的冠军。其方法如图 2-6 所示。通过这种方式，网络可以实现更深的网络结构，而不会出现网络退化的问题。残差特征融合包含两种方式：局部残差连接和全局残差连接。残差连接帮助了 EDSR 实现了可以训练较深的网络，而不会出现梯度弥散的情况。除 EDSR 外，还有一些超分辨率模型借鉴残差连接的思想，如 SRResNet、RCAN 和 SAN^[59]等，实现了更深的网络的训练。这些模型都使用了残差模块和多级特征融合机制来提升模型性能。还有研究者将残差连接方法与生成对抗网络结合使用，如 SRGAN、ESRGAN^[60]等，有利于网络训练稳定，生成更加逼真的高分辨率图像。




图 2-6 残差连接结构示意图^[26]

2.3.2 密集连接网络

DenseNet^[61]是一种基于密集连接的分类网络，在分类任务上取得了有效的效果。密集连接网络也是超分辨率任务中一种常用的特征融合方法，如

SRDenseNet、RDN、CARN、和 ESRGAN 等。传统的网络结构中，每一层只能利用上一层的输出，底层特征随着网络的加深，信息会逐渐丢失，信息传递可能会出现瓶颈，其结构如图 2-7 所示。




图 2-7 密集连接结构示意图^[61]

密集连接中每一层的输入不仅仅包含上一层的输出，还包含了之前所有层的特征信息，使得底层特征可以直接传到高层，提高了特征重用性，信息可以更加充分流动，可以更好解决信息瓶颈等问题，提高模型的表达能力。超分辨率任务中，采用密集连接使得底层特征与高层特征更好的结合起来，提高重建图像的质量。密集连接也存在一些局限性，每层的输出都传输到下一层，导致计算量过大，内存占用量很高，需要更多的计算资源和训练时间。其次，可能会引入过多的冗余信息，导致模型泛化能力下降。

2.3.3 残差特征聚合网络

在基于卷积神经网络的超分辨率任务中，残差连接在提高网络性能方面扮演了很重要的角色。随着网络深度的增加，残差特征逐渐集中于输入图像的不同方面，为了更加充分利用残差分支的分层特征，Liu 等^[62]提出 RFANet，其核心创新点是残差特征聚合模块（RFA），能够整合有用的残差特征以产生更具代表性的特征，该模块结构如图 2-8 所示。

其过程是将四个残差块的输出特征进行通道拼接，再经过 1×1 卷积进行通道压缩，达到融合残差特征的目的。然而，该方法存在一定局限性，在对残差特征进行融合时，并没有考虑到不同方面的残差特征对网络的帮助是不同的，同等的对待不同层次的残差特征，未关注到关键特征，可以在融合过程中引入注意力机制来解决这个问题。




图 2-8 残差特征聚合模块示意图^[58]

2.4 对比学习

对比学习旨在学习一个嵌入的空间，使得相似的样本对彼此靠近，不同的样本对彼此远离。对比学习可用于监督的学习环境，也可用于无监督的学习环境，在图像分类和图像聚类等高级视觉任务中非常成功。但是，很少用于低级视觉任务。高级视觉任务的对比学习可能不适用于低级视觉任务，因为前者更需要全局视觉表示，而后者更需要丰富的纹理细节^[50]。对比学习需要考虑的两个重要因素是：度量相似性的隐空间，以及正/负样本的选取。在当前低级视觉任务中，使用的隐空间大都是预训练网络（如 VGG）的特征空间。采用最简单的方法选取正样本和负样本，例如：输入的低质量图像作为负样本，输入的高质量图像作为正样本。

2.5 本章小结

本章主要介绍了基于 CNN 的超分辨率算法的概念和知识。首先，概括分析了卷积层、池化层、激活层和全连接层。其次，介绍了两个与本文工作相关的算法：一个是注意力机制，主要围绕通道注意力、空间注意力及其两者的混合进行介绍，另一个是特征融合网络，分别介绍了残差连接、密集连接和残差特征聚合网络。

第 3 章 基于像素级对比学习的图像超分辨率算法

3.1 引言

单图像超分辨率 (Single Image Super Resolution, SISR) ^[1] 是为了从低分辨率图像中恢复出细节清晰的高分辨率图像。SISR 是计算机视觉中一个基础问题, 在诸如遥感成像^[2]、视频监控^[3]和医学成像^[4]中应用广泛。由于许多 HR 图像可退化为相同的 LR 图像, 因此 SISR 是一个典型的不适定问题, 每个输入的 LR 图像可能对应多个 HR 的解决方案, 需要提供图像的先验知识, 约束解超分辨率图像的解空间。SISR 仍然是计算机视觉中开放性的研究问题, 重建的 SR 图像往往会出现模糊、纹理细节丢失和失真等问题。

Dong 等^[16]提出第一个基于 CNN 技术的 SISR 方法 SRCNN, 直接端到端地学习 LR 和 HR 图像之间的映射函数之后, 深度卷积神经网络技术已主导了当前 SR 技术的研究。Kim 等^[20]提出的 VDSR 方法, 通过引入残差学习, 加深了网络, 改进了性能。Lim 等^[26]提出的 EDSR 方法, 通过堆积残差块, 进一步加深了网络 (有 65 个卷积层), 改进了性能。Zhang 等^[27]提出的 RCAN 方法, 在残差块中引入了通道注意力机制, 超过 400 个卷积层, 显著改进了 SISR 方法的性能。当前基于 CNN 的 SISR 方法主要研究新的 SR 网络架构, 损失函数广泛使用逐像素的损失函数, 如均方误差 (MSE) ^[27]和平均绝对误差 (MAE) ^[16], 但是, 这些传统的逐像素损失, 使得生成的 SR 图像是潜在 SR 输出图像的平均^[40], 导致输出的图像被过度平滑。为了解决这个问题, Johnson 等^[41]提出了感知损失。感知损失不是在图像空间度量逐像素的损失, 而是在预训练的 VGG 网络^[49]特征空间度量逐像素的损失。感知损失能改进 SR 图像的感知质量, 但是, 由于多了特征编码的过程, 不可避免地造成信息丢失, 降低了 SR 图像保真度。更重要的是, 感知损失也不能阻止 SR 图像的模糊。Wang 等^[52]提出了一个对比自蒸馏 SR 网络 (Contrastive Self-Distillation, CSD), 引入了一个基于对比学习的损失函数。CSD 损失与感知损失类似, 也选择了在预训练 VGG 网络的特征空间逐像素比较损失。以教师子网络输出的 SR 图像作为正样本, 学生子网络输出的 SR 图像作为锚, 从同一个小批中采样 K 张图像 (除锚外), 通过双三次插值上采样到与输出 SR 图像相同的分辨率, 作为负样本。CSD 损失使锚更靠近正样本, 并远离负样本, 进一步改进了学生子网络输出的 SR 图像的视觉质量。与感知损失相比, CSD 损失除限制了学生子网络输出的上界 (正样本) 外, 也限制了下界 (负样本), 以减小解空间。但是, CSD 损失也有与感知损失类似的问题, 保真度低。

另外，CSD 损失使用与锚点差距较大的低分辨率图像经过插值上采样后作为负样本，是一个较弱的下界。受 CSD 的启发，我们提出了一个新的基于对比学习的逐像素损失函数（Pixel-wise Contrastive Loss, L_{PCL} ）。 L_{PCL} 在图像空间，训练 HR 图像与输出的 SR 图像对应的像素分别作为正样本和锚，HR 图像上正样本邻近的且与正样本像素值不同的像素作为负样本，像素值相同的像素构成正样本。类似地， L_{PCL} 也让锚更靠近正样本，远离负样本。各类损失的视觉效果参见图 3-1。

同时也提出了一个新的网络架构，称为渐进的残差特征融合网络（Progressive Residual Feature Fusion Network, PRFFN）。PRFFN 应用扩张卷积^[43]扩展 RCAN^[27]的基本构件-残差通道注意力块（RCAB），以支持多尺度特征，称为多尺度残差通道注意力块（MRCAB）。PRFFN 以 MRCAB 作为基本构件，并运用空间注意力机制^[44]，渐进地融合 MRCAB 的特征。 L_{PCL} 与 PRFFN 网络架构组合，能够获得先进的 SR 性能。当然 L_{PCL} 是通用的，也可以与其它 SR 网络架构协作应用。




图 3-1 PRFFN 在不同的损失约束下的视觉效果比较

本文的主要贡献包括：（1）提出了一个通用的基于对比学习的逐像素损失 L_{PCL} ，能够显著改进 SR 图像的视觉质量；（2）提出了一个新的渐进的残差特征融合 SR 网络架构（PRFFN）；（3）实验结果显示：PRFFN 组合 L_{PCL} ，取得了有竞争力的 SR 性能。

3.2 相关损失函数

当前基于卷积神经网络的图像超分辨率技术研究中，大多聚焦于架构设计，但是合适的损失函数对超分辨率网络的性能也至关重要。损失函数衡量了模型的重建的 SR 图像与 HR 图像的之间的差距。模型训练过程中，根据损失值不断优化模型，以提高模型的性能。在超分辨率任务中，选择损失函数时，不仅要求损失函数是可导的，否则无法进行反向传播，还需要考虑到图像的细节和纹理细节。此外，损失函数应该能够提高超分辨率图像的视觉质量。当前最广泛使用的目标函数是逐像素的 L_1 损失（即平均绝对误差）和 L_2 损失（即均方误差）。还有一些比较好的目标函数，包括感知损失^[37]、纹理损失^[38]、对抗损失^[24]和对比损失^[43,44]等。

3.2.1 L_1 损失

L_1 损失也称为平均绝对误差损失（MAE），计算重建图像和原始高清图像的每个像素点之间的绝对误差，并将所有像素误差求和，其公式如下：

$$L_1(\hat{y}, y) = \sum_{i=0}^m |y^{(i)} - \hat{y}^{(i)}|. \quad (3-1)$$

因为超分辨率任务是一个回归问题， L_1 损失会为低分辨率输入图像生成高分辨率输出图像提供平滑的结果。与 L_2 损失相比，由于 L_1 损失不会过度惩罚异常值，对异常值的敏感度较低，对于离群值更加鲁棒。因此，大部分情况下， L_1 损失函数更被广泛的使用。

3.2.2 L_2 损失

L_2 损失也叫均方误差损失（MSE），计算的是 SR 图像与 HR 图像逐像素差值的平方和，计算公式如下：

$$L_2(\hat{y}, y) = \sum_{i=0}^m (y^{(i)} - \hat{y}^{(i)})^2. \quad (3-2)$$

与 L_1 损失的计算方式相近，但是需要对误差进行平方。因此， L_2 损失会将误差平方，对异常值非常敏感，在异常值较多时， L_1 损失更加有效。 L_2 损失作

为损失函数时，由于其函数的特性，自身就会对梯度进行缩放。对于具有多个最小值的问题， L_2 损失函数在收敛速度上有些劣势，但是训练更容易，更容易收敛到全局最小值。总之，需要结合具体使用场景来选择合适的损失函数。目前也有一些变体，即 L_1 损失和 L_2 损失的加权和，或者其他方法，比如满足一定条件下使用 L_1 损失，其他情况使用 L_2 损失。

3.2.3 感知损失

感知损失是通过计算重建 SR 图像与 HR 图像特征的差异来量化图像之间的差距，如图 3-2 所示。




图 3-2 感知损失示意图^[37]

主要特点是将神经网络中某一层的输出作为特征表示，用于衡量重建图像与原始图像的相似度。通常，这一层是在预训练的图像分类任务中得到的，因为这些网络在训练时学习到的特征对图像重建具有很好的泛化能力。因此，感知损失可以看作是通过在预训练网络中提取图像特征来评估超分辨率模型性能的一种方式。其公式如下：

$$\ell_{feat}^{\phi,j}(\hat{y}, y) = \frac{1}{C_j H_j W_j} \|\phi_j(\hat{y}) - \phi_j(y)\|_2^2, \quad (3-3)$$

其中， C_j 、 H_j 和 W_j 分别表示第 j 层特征图的通道数、高度和宽度。 $\phi_j(\cdot)$ 是第 j 层的激活函数。

感知损失的计算方式类似于 L_2 损失函数，只是将比较的对象从像素值改为特征向量，可以通过一些预训练好的网络，如 VGG 网络^[49]中的某一层来得到。在计算感知损失时，通常会对不同层的特征向量分别计算损失，然后将它们加权求和得到最终的损失值。与 L_1 损失和 L_2 损失不同，感知损失鼓励输出的 SR 图像与 HR 图像具有相似特征表示，而不是迫使其像素匹配。然而，感知损失也存在不足，由于使用了预训练模型，所以需要额外的计算成本和训练时间，其次预训练模型会图像特征进行压缩，不可避免的造成信息丢失，降低了重建图像的保

真度。

3.2.4 对比损失

对比学习旨在学习一个嵌入的空间，使得相似的样本对彼此靠近，不同的样本对彼此远离。对比学习可用于监督的学习环境，也可用于无监督的学习环境，在图像分类和图像聚类等高级视觉任务中非常成功。但是，很少用于低级视觉任务。高级视觉任务的对比学习可能不适用于低级视觉任务，因为前者更需要全局视觉表示，而后者更需要丰富的纹理细节^[50]。对比学习需要考虑的两个重要因素是：度量相似性的隐空间，以及正/负样本的选取。在当前低级视觉任务中，使用的隐空间大都是预训练网络（如 VGG）的特征空间。采用最简单的方法选取正样本和负样本，例如：输入的低质量图像作为负样本，输入的高质量图像作为正样本。Wu 等^[51]提出的图像去雾方法，使用了 VGG 特征空间，真实的图像作为正样本，退化的雾图像作为负样本，重建出的图像作为锚。在 VGG 特征空间中，让锚靠近正样本，远离负样本。Wang 等^[52]提出了一个对比自蒸馏超分辨率网络（CSD），也使用了 VGG 特征空间。其教师子网络输出的重建图像作为正样本，学生子网络输出的重建图像作为锚，从同一个小批中采样 K 个图像（除锚外），通过双三次插值上采样到与输出重建图像相同的分辨率，作为负样本。其结构如图 3-3 所示。




图 3-3 CSD 对比损失示意图^[52]

在盲超分辨率任务中，Wang 等^[53]使用一个编码器子网络，学习不同退化的抽象表示。假定相同图像中的块，退化相同，不同图像的块，退化不同，以分别选择正样本和负样本。Wu 等^[50]提出了一个基于对比学习的超分辨率框架，以判别器子网络的特征空间为隐空间。通过对真实图像施加一些轻微的模糊，生成多个难的负样本，即简单地锐化真实图像，生成多个信息丰富的正样本。Wu 等的隐空间对退化更加敏感，其负样本试图促使 SR 图像远离平滑的图像，而其正样

本试图迫使吸收更多的细节信息。本文工作主要受到 CSD 的启发，CSD 虽能改进视觉效果，但是，保真度较低，正/负样本限定的上下界距离大，即上下界较弱。L_{PCL} 直接使用图像空间，训练真实图像与输出的重建图像对应的像素为正样本和锚，真实图像上正样本邻近的像素作为负样本。

3.2.5 对抗损失

对抗损失是用于训练生成对抗网络（GAN）的损失函数。GAN 由两部分组成，分别为生成器（Generator，G）和判别器（Discriminator，D）。G 网络用于生成伪造数据，D 网络用于分辨出伪造数据和真实数据。训练 GAN 网络的目标是使 G 网络生成的伪造数据尽可能接近真实数据，使得 D 网络无法区分 G 网络生成的数据是真实的还是伪造的，同时 D 网络能准确地区分真实数据和伪造数据。其公式如下：

$$\min_G \max_D V(D, G) = \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_z(\mathbf{z})} [\log(1 - D(G(\mathbf{z})))] \quad (3-4)$$

其中， $G(\cdot)$ 是生成器， $D(\cdot)$ 是判别器， $p_{\text{data}}(\mathbf{x})$ 是 HR 图像的分布， $p_z(\mathbf{z})$ 是生成器输入的 LR 图像的分布。对抗损失函数包含两个部分：真实数据损失和生成数据损失。其中，真实数据的损失指的是将真实数据输入判别器后，判别器判定其为真实数据的概率的对数值；生成数据的损失指的是将生成的数据输入判别器后，判别器判定其为真实数据的概率的对数值的相反数。在对抗训练中，生成器和判别器的优化目标是相互对抗的。生成器的目标是最小化对抗损失函数，而判别器的目标则是最大化对抗损失函数。

对抗损失存在着一些问题，如训练困难，生成器和判别器的损失难以同时收敛，判别器非常强大时，损失函数的值为 0，导致生成器无法更新。研究者们提出了许多方法和训练技巧来改进以上问题。DCGAN^[50]利用卷积神经网络搭建对抗网络架构，同时利用批归一化、Leaky ReLU 激活函数、权重初始化等方法来稳定训练过程，具有生成高质量图像的能力。WGAN^[51]使用 Wasserstein 距离作为损失函数取代了原生 GAN 中使用的 KL 散度或 JS 散度。Wasserstein 距离可以更好地评估分布之间的距离，训练更加高效稳定。同时利用了权重剪切的正则化技术，限制判别器的参数范围，避免判别器梯度爆炸。Ledig 等^[24]将 GAN 网络引用到超分辨率任务中，提出 SRGAN 的方法。采用对抗损失和内容感知损失来训练生成器，以生成更加符合感知的高分辨率图像。这些方法的出现进一步推动了生成对抗网络技术的发展。

3.3 算法总体框架

本文提出了一个新的超分辨率网络架构 (PRFFN)，如图 3-4 a) 所示，主要包括：浅层特征提取块 (Shallow Feature Extraction Block, SFEB)、特征映射块 (Feature Mapping Module, FMM) 和上采样块。其中 SFEB 仅包含一个 3×3 的卷积层，提取浅层特征信息。FMM 包含 10 个渐进特征融合组 (Progressive Feature Fusion Group, PFFG)，PFFG 的结构如图 3-4 b) 所示。Upsampler 使用亚像素的卷积^[18]。损失函数使用了 L_1 损失和像素级对比损失组成。




图 3-4 PRFFN 网络架构

3.3.1 网络结构

首先，假定输入的 LR 图像为 I_{LR} ， I_{LR} 首先经过 SFEB 提取浅层特征：

$$F_0 = f_{SFEB}(I_{LR}), \quad (3-5)$$

其中， $f_{SFEB}(\cdot)$ 是浅层特征提取函数， F_0 是其输出。再通过 FMM 进行深层特征提取：

$$F_n = f_{PFFG}^n(F_{n-1}), n=1, 2, \dots, N, \quad (3-6)$$

其中， $f_{PFFG}^n(\cdot)$ 是 FMM 中第 n 个 PFFG 函数， F_n 是其输出， F_{n-1} 是其输入 (即第

$n-1$ 个 PFFG 的输出), N 是 FMM 中 PFFG 的个数。然后, 深层残差特征 F_N 组合浅层特征 F_0 , 通过 Upsampler 重建目标 SR 图像:

$$I_{SR} = f_{UP}(F_n + F_0), \tag{3-7}$$

其中, $f_{UP}(\cdot)$ 是 Upsampler 函数, I_{SR} 是最终输出的 SR 图像。

3.3.2 渐进特征融合组 (PFFG)

Liu 等^[58]的工作表明: 随着网络深度的增加, 中间层残差特征逐渐集中于输入图像的不同方面, 这对于重建空间细节非常有用。RFANet^[58]利用层次残差特征信息, 能够细化更多关键内容, 显示出强大的图像重建能力。上述方法对残差特征进行融合时, 通常是通过特征相加或拼接等简单操作实现的, 对融合的特征信息同等对待, 例如残差连接、密集连接与残差特征融合, 如图 3-5 所示。




图 3-5 不同的特征融合方法

Wang 等^[59]的工作认为: 融合的特征对于当前层的特征的学习可能并不都有用, 其提出的 A²F, 使用通道注意力对融合特征进行建模, 使模型自动将重要性分配给不同的通道。本文受^[59]工作的启发, 提出利用空间注意力对融合特征进行建模, 实验证明, 与其相比, 我们的方法参数量和计算量较小, 且性能较好。同时为了更有效地融合这些残差特征, 提出了渐进特征融合组 (PFFG), 利用渐进融合的方式, 首先相邻残差块的特征进行两两融合, 再逐层对融合后的特征进行二次融合, 对特征进行逐层筛选, 最终生成更具代表性的特征。

PFFG 的结构如图 3-2 b) 所示，相邻两个多尺度残差通道注意力块 (Multi-scale Residual Channel Attention Block, MRCAB) 的输出特征，输入到空间注意力融合块 (Spatial Attention-based Fusion Block, SAFB) 进行融合，再将两个 SAFB 的输出特征进行融合后，与输入特征 F_{n-1} 组合作为 PFFG 的输出。第 $n(n=1,2,\dots,N)$ 个 PFFG 块的输出特征可以表示为：

$$F_n = f_{SAFB} \left(f_{SAFB} \left(F_{n,1}^{MR}, F_{n,2}^{MR} \right), f_{SAFB} \left(F_{n,2}^{MR}, F_{n,3}^{MR} \right) \right) + F_{n-1}, \quad (3-8)$$

其中， $f_{SAFB}(\cdot)$ 表示空间注意力融合函数（具体函数参见 3-6）。 $F_{n,m}^{MR}$ 是第 $n(n=1,2,\dots,N)$ 个 PFFG 中第 $m(m=1,2,3)$ 个 MRCAB 的输出特征。

3.3.3 多尺度残差通道注意力块 (MRCAB)

MRCAB 是建立在 RCAN^[27] 的网络基础上。受 MSRN^[32] 的启发，他们开发了一个多尺度的残差块，称为 MSRB。MSRB 包含两个分支：一个分支使用 3×3 的卷积，另一个分支使用 5×5 的卷积。两个分支输出的不同尺度特征拼接在一起，再分别通过 3×3 和 5×5 的卷积。实验中发现：更多的尺度，可以更好地利用特征信息。所以，MRCAB 使用了三个分支，为了获得全局上下文信息，利用不同空洞率的卷积核来提取多尺度特征，其结构如图 3-6 所示。




图 3-6 多尺度残差通道注意力块

第 $n(n=1,2,\dots,N)$ 个 PFFG 中第 $m(m=1,2,3)$ 个 MRCAB 的输出特征，可以表示为：

$$\left\{ \begin{array}{l} F_{n,0}^{MR} = F_{n-1} \\ S_m^1 = \sigma \left(\text{Conv}_{3 \times 3}^1 \left(F_{n,m-1}^{MR} \right) \right) \\ S_m^2 = \sigma \left(\text{Conv}_{3 \times 3}^2 \left(F_{n,m-1}^{MR} \right) \right) \\ S_m^3 = \sigma \left(\text{Conv}_{3 \times 3}^4 \left(F_{n,m-1}^{MR} \right) \right) \\ F_{n,m}^{MR} = \text{CA} \left(\text{Conv}_{3 \times 3} \left(S_m^1 + S_m^2 + S_m^3 \right) \right) + F_{n,m-1}^{MR} \end{array} \right. , \quad (3-9)$$

其中, $\text{Conv}_{3 \times 3}^d(\cdot)$ 表示卷积核大小为 3, 空洞率为 $d, d=1,2,4$, 参数共享的卷积函数。 S_m^k 是第 m 个 MRCAB 块的第 $k(k=1,2,3)$ 个分支的输出特征。 $\sigma(\cdot)$ 是 ReLU 非线性激活函数, $\text{CA}(\cdot)$ 表示通道注意力函数^[27]。MRCAB 与 MSRN^[32] 中 MSRB 的区别在于: MSRB 所利用的卷积是不同的卷积核, 参数量较大。本文的 MRCAB 利用不同扩张率的参数共享的卷积核, 大大减少了参数量。

3.3.4 空间注意力融合模块 (SAFB)

特征融合在超分辨率网络中很流行, 但大多数关于特征融合的工作都专注于构建复杂的路径来融合不同块、组或层中的特征。特征如何进行融合的方法很少被提及, 通常是通过特征相加或拼接等简单操作实现的, 这仅仅是一种线性的聚合方法, 线性的特征拼接方法在融合时对中间层的特征信息同等对待, 没有重点关注图像边缘和纹理等细节。为了解决这一问题, 本文提出了一种轻量而高效的空间注意力融合模块 SAFB, 如图 3-7 所示。




图 3-7 空间注意力融合模块结构图

利用空间注意机制来对融合特征的重要性进行建模, 增加了网络的非线性,

产生更具有代表性的特征。相较于其它融合模块，SAFB 不仅不增加参数量，而且能显著改进网络性能。利用空间注意力来对融合特征的空间位置信息进行建模，生成空间注意力权重，捕获融合特征的空间位置依赖关系。假定 SAFB 的输入特征为 F_A 和 F_B ，经过通道拼接，然后进行 1×1 卷积，再进行通道分离得到两个二维的向量 ($1 \times H \times W$)，并使用 Sigmoid 函数进行归一化，获得空间注意力权重，分别与 F_A 和 F_B 进行相乘，再求和，作为 SAFB 的输出。这个过程可以表示为：

$$\begin{cases} W_A, W_B = f_{split}(Conv_{1 \times 1}([F_A, F_B])) \\ F_{fuse} = sigmoid(W_A) \cdot F_A + sigmoid(W_B) \cdot F_B \end{cases} \quad (3-10)$$

其中， F_A 与 F_B 表示输入到 SAFB 中的两组特征。 $[\cdot]$ 表示通道拼接操作。 $f_{split}(\cdot)$ 表示通道分离操作。

3.4 像素级对比损失函数

损失函数包含两个部分： L_1 损失和像素级对比损失。每一部分都有其使用的原因。没有使用 L_2 损失，是因为许多研究者表明超分辨率领域 L_1 损失比 L_2 损失的性能更好。如图 3-8 所示，目标是让 SR 与 HR 对应位置像素点的距离是最接近的。




图 3-8 像素级对比损失示意图

以 SR 图中像素 A (SR 图像白色区域的像素) 为例，与 A 对应位置 HR 的像素 A' (HR 图像白色区域的像素) 应该是最接近的。但由于 L_1 损失或 L_2 损失

的目的是使整个重构图像 SR 的整体像素更加正确,生成的是解空间的平均值,很可能会导致 A 与非对应像素点 B' (HR 图像纹理区域的像素) 更相似,产生纹理平滑的效果。

对比学习^[43,47,61-63]已经取得了瞩目的成就。对于给定的锚点,对比学习的目的是将锚点拉向正样本,将锚点推离负样本。由于超分辨率是一个不适定问题,使得恢复高质量的细节具有挑战性。仅利用 L_1 损失或 L_2 损失来优化 HR 和 SR 图像之间像素空间的平均差异且仅约束相同位置的重构误差(如图 3-9 a)所示),鼓励 SR 图像的细节区域平滑,使其平均(像素)更加正确,这会导致得到的 SR 图像的部分像素与 HR 图像对应的像素之间距离并不是最接近的,反而与周围像素点接近的情况,导致纹理失真和模糊。




图 3-9 L_1 和 L_2 与像素级对比损失(PCL)示意图

为了解决这个问题,我们提出了像素级对比学习来生成更加准确的 SR 图像。首先将 SR 与 HR 嵌入成二维的向量,以便计算出 SR 图像中的每一个像素点(即锚点: Anchor)到 HR 图像中相同位置以及周围共 K 个像素点的 L_1 距离。然后将其分为两个集合,正样本集合和负样本集合。目的是缩小正样本对的 L_1 距离,扩大负样本对的 L_1 距离,使正样本与锚点的 L_1 距离远远小于负样本与锚点的 L_1 距离(如图 3-7 b)所示)。其形式类似于对比学习中的 InfoNCE^[63]损失:

$$L_{PCL} = \frac{1}{M} \sum_{l=1}^M -\log \frac{\sum_{x_{HR}^i \in S_{1,P}} \exp(-\|x_{SR}^l - x_{HR}^i\|_1)}{\sum_{x_{HR}^j \in S_1} \exp(-\|x_{SR}^l - x_{HR}^j\|_1)}, \quad (3-11)$$

其中, x_{SR}^l 和 x_{HR}^l 是 SR 图像和 HR 图像上第 l 个位置的像素点。 x_{HR}^j 是 HR 图像

上第 j 个位置的像素点。其对应的正负样本在 x_{HR}^j 周围共 K 个像素点选取，由这 K 个像素点组成的集合记为 S_l 。在 K 个像素点中，我们把与 x_{HR}^j 相等的所有像素点作为正样本，其组成的集合记为 $S_{l,p}$ （包括 x_{HR}^j ），其与像素点作为负样本。

下面将取多个不同位置的像素点作为多个负样本与取多个不同位置的像素点的均值作为一个负样本这两种情况进行分析。推远锚点到不同位置的负样本的 L_1 距离，可以给每个负样本分配一个概率权重，在训练中梯度更加自适应的传递（因为有的困难的负样本需要推离的更远，有的容易的负样本是不需要的）。而使用均值作为负样本，困难和容易的负样本当作同等比例进行推离。

值得注意的是，所提出的像素级对比损失与 L_1 损失以及 Wang 等所提出的 CSD 损失并不是对立的，而是互补的关系。CSD 损失使得生成的 SR 图像在特征上更加接近 HR 图像， L_{PCL} 使 SR 图像在像素上更加接近 HR 图像。总的损失函数是由以下公式计算：

$$L_C = \lambda_c L_{PCL} + L_1, \quad (3-12)$$

其中， λ_c 为像素级对比损失的对应系数。

从后面的实验中可以看出，像素级对比学习的方法在超分辨率任务中表现良好。

3.5 本章小结

本文提出了一个基于像素级对比学习的图像超分辨率方法，以改进现有的方法。我们的方法包括基于对比学习的逐像素损失函数和一个新的网络架构（PRFFN），从损失函数和网络架构两方面改进了超分辨率网络的性能。在本章节中，首先介绍了 PRFFN 网络的架构，主要包括：渐进特征融合组、多尺度残差通道注意力模块和空间注意力融合模块，也介绍了本网络架构设计的动机和需要解决的问题，其中渐进融合中间层特征，使得残差特征得到更好的利用是设计本架构的目标。由于只使用了 30 个 MRCAB 模块，感受野与深度网络相比较小，为了扩大感受野，捕捉上下文信息，提出了参数共享的多尺度模块。为了对不同残差特征进行融合时进行重要性建模，重视更重要的特征，提出了空间注意力融合模块，与渐进融合模块搭配使用，这样既融合了特征，又可以重视那些重要的特征如纹理、边缘信息，忽略不重要的信息，帮助网络恢复出质量更高的重建图像。像素级对比损失作为本文方法核心的创新点，是在对比学习的基础上提出的，强调在重建图像与高清图像的像素之间进行对比学习，采用对比学习的方式来拉近相同位置的像素距离，推远不同位置的像素距离，使得生成的像素更加准确。最终达到了在深度卷积神经网络模型复杂度和性能之取得了很好的平衡。详细介

绍了本文所提出的网络架构，称为渐进的残差特征融合网络。PRFFN 应用扩张卷积扩展 RCAB，以支持多尺度特征。PRFFN 以 MRCAB 作为基本构件，并运用空间注意力机制，渐进地融合 MRCAB 的特征。 L_{PCL} 与 PRFFN 网络架构组合，能够获得先进的 SR 性能。当然 L_{PCL} 是通用的，也可以与其它 SR 网络架构协作应用。大量的实验结果表明本文方法相比于其他先进的方法更为有效。

第 4 章 实验与分析

4.1 引言

本章节主要包含以下内容：数据集的选择和预处理、实验参数设置和实验细节的描述。实验细节分为两类：消融实验和结构设计及优势的分析。通过消融实验，验证各个模块在网络中的作用；通过结构设计及优势的分析，探究各个模块的性能差异。最后，除了对比不同放大倍数下的客观指标，本文还进行了主观评价，提供了较为详细的实验分析。

4.2 数据集

本文中，采用了 NTIRE 2017 挑战赛的官方数据集 DIV2K^[68]作为训练集，该数据集包含了 1000 张高质量分辨率图像，其中 800 张用于训练（1-800），100 张用于验证（801-900），另外 100 张作为测试集（901-1000）。我们在训练过程中使用了 800 张 DIV2K 训练图像以及 5 张 DIV2K 验证图像（811-815，标记为 DIV2K_val5）。为了获得 LR 图像，我们通过双三次下采样原始 HR 图像获得。

在测试阶段，使用了五个标准测试集：Set5^[69]、Set14^[70]、B100^[71]、Urban100^[72]和 Manga109^[73]。其中，Set5 包含了 5 张经典的测试图像，Set14 进一步提高了图像的平均分辨率，B100 包含了大量的生活场景图像，Urban100 增加了室内、城市和建筑等真实图像，而 Manga109 则由 109 本不同类型的漫画书组成。需要注意的是，在本文的实验中，所有的 SR 图像都被转换到 YCbCr^[27,74]空间上，以 Y 通道计算 PSNR 和 SSIM 评估指标。此外，还进行了详细的主观图像比较和定量指标对比分析，以评估算法的视觉效果和性能优劣。这些实验设置和分析有助于更全面地评估算法的性能和探究其内在机制，从而为图像超分辨率领域的研究提供参考和启示。

4.3 图像质量评价

不同的模型达到的效果不同，需要有评价模型好坏的统一定量评价指标，并且这个指标需要被大众接受。当前，超分辨率算法的研究者们通常使用客观评价指标来评价图像质量的好坏，包括峰值信噪比（Peak Signal to Noise Ratio, PSNR）、结构相似性（Structure Similarity Index Measurement, SSIM）^[41]等。PSNR 是衡

量图像的重建误差；SSIM 是衡量图像结构和纹理的相似性。主观评价指标可以通过观察者直接观察，做出评价进行打分。目前也有一些工作采用网络的方式来判断哪个图像更加符合感官认知，比如学习感知图像块相似性 (Learned Perceptual Image Patch Similarity, LPIPS)，LPIPS 是基于感知距离的度量，可以更好地反映人眼对图像的感知差异，LPIPS 的值越低，表示两张图像的相似度越高，重建的结果越好。

4.3.1 峰值信噪比

PSNR 描述一个信号的最大可能功率与影响其表示保真度的干扰噪声的功率之比，通常用于量化各种图像重建任务的重建图像质量。计算方法是计算原始图像与重建图像之间的均方误差 (MSE)，并根据像素动态范围 (8 位的 0-255) 将 MSE 转换为分贝 (dB)。PSNR 值越大，图像重建的效果越好。其计算公式如下：

$$MSE = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W (X(i, j) - Y(i, j))^2, \quad (4-1)$$

$$PSNR = 10 \log_{10} \left(\frac{(2^n - 1)^2}{MSE} \right), \quad (4-2)$$

其中， X 代表真实图像， Y 代表重建后的图像， H 和 W 分别为图像的高度和宽度， n 是像素比特数， $2^n - 1$ 表示图像像素的最大值。虽然 PSNR 被广泛使用在许多应用中，但也存在一些局限性。PSNR 只计算了整个图像的平均误差，忽略了图像的对比度和结构信息。在研究中需要综合考虑 PSNR 和其他图像质量指标，更加全面地评估图像质量。

4.3.2 结构相似性

SSIM 是一种用于计算数字图像和视频质量的方法，通过比较两幅图像的亮度、对比度和结构相似程度来评估图像间的相似度。其中，亮度指数表示图像的平均亮度值，对比度指数表示相邻像素的差异程度，结构相似性指数衡量图像中的纹理和结构的相似程度。计算 SSIM 时将图像分成多个块，并计算每个块的亮度、对比度和结构相似度。与 PSNR 相比，SSIM 在许多方面更加符合人类是觉得感知，它的范围在 0 到 1 之间，数值越接近 1，表示相似度越高，反之差异越大。公式如下：

$$SSIM(X, Y) = (l(X, Y))^{\alpha} \cdot (c(X, Y))^{\beta} \cdot (s(X, Y))^{\gamma}, \quad (4-3)$$

$$\begin{cases} l(X, Y) = \frac{2\mu_X\mu_Y + c_1}{\mu_X^2 + \mu_Y^2 + c_1} \\ c(X, Y) = \frac{2\sigma_X\sigma_Y + c_2}{\sigma_X^2 + \sigma_Y^2 + c_2} \\ s(X, Y) = \frac{\sigma_{XY} + c_3}{\sigma_X\sigma_Y + c_3} \end{cases} \quad (4-4)$$

其中， μ_X 、 μ_Y 表示均值， σ_X 、 σ_Y 表示方差， σ_{XY} 表示协方差， c_1 、 c_2 、 c_3 为常数，可以化简 SSIM 的计算公式加快运算速度，公式为：

$$SSIM(X, Y) = \frac{(2\sigma_X\sigma_Y + c_1)(\sigma_{XY} + c_2)}{(\mu_X^2 + \mu_Y^2 + c_1)(\sigma_X^2 + \sigma_Y^2 + c_2)} \quad (4-5)$$

4.3.3 主观评价指标

主观评价指标核心是通过人类感知的主观反馈来评估图像的质量。主观评价需要邀请一些参与者，要求他们观看，然后根据他们的主观感受进行评分或提供反馈。通常是将分数划分在 1 到 5 之间，这些分数可以通过各种方式分析和计算，以获得综合评估。然而，这种方式需要人力和时间的投入，容易受到参与者不同个体差异的影响。在实际研究中，主观评价通常与客观评价指标结合使用，以获得更全面准确的质量评估。

4.4 实验参数设置

为了与其他算法公平比较，实验采用了与大多数论文相同的设置来进行训练。具体来说，设置了批大小为 16，将 LR 图像片尺寸设置为 48×48 以不占据大量计算资源和加快训练速度。通过在训练时使用随机的水平翻转和 90 度旋转来增强数据集，以提高模型的鲁棒性和泛化性能。使用了 ADAM 优化器来训练模型，并设置了 $\beta_1 = 0.9$ ， $\beta_2 = 0.999$ ，以及 $\varepsilon = 10^{-8}$ 以确保优化器能够帮助网络收敛。在学习率的设置上，将其初始化为 10^{-4} ，并在每 200 个迭代周期 (epoch) 后将其减半以逐步降低学习率，以达到更好的收敛效果。最后，采用了 PyTorch 1.6^[71] 框架来实现本文的模型，以便更方便地进行实验和结果分析，模型训练使用一块 NVIDIA 2080Ti GPU。通过这些实验参数设置和选择，能够在训练过程中使网络获得更好的效果和更高的准确度，以便在后续的研究和应用中获得更好的性能。

4.5 实验细节

4.5.1 消融实验

如方法描述，我们的网络包含了三个主要部分：MRCAB、SAFB 和像素级对比损失 (L_{PCL})。为了验证其有效性，本节进行了五组对比实验。如表 4-1 所示：

表 4-1 不同模块在 DIV2K_val5 上 $\times 3$ 的 PSNR

	方法	L_1	L_{PCL}	PSNR(dB)
1	base	√	×	32.259
2	base + RFA	√	×	32.307
3	base + SAFB	√	×	32.342
4	base + SAFB + MRCAB	√	×	32.364
5	base + SAFB + MRCAB	√	√	32.451

第一个实验，不包含像素级对比损失和特征融合，即只有 30 个残差通道注意力模块 (RCAB) [27]，仅在 L_1 损失约束下进行训练，这个实验称为 base。第二个实验，在 base 的基础上增加了 RFA，RFA 表示每三个 RCAB 如图 3-2(b) 所示的方法把 SAFB 模块替换为：先进行通道拼接，再通过 1×1 卷积进行通道压缩。第三个实验，在第二个实验的基础上将 RFA 替换为 SAFB。第四个实验，将 RCAB 的第一个卷积参数共享三次并将空洞率分别调整为 1、2、4，称为多尺度残差通道注意力模块 (MRCAB)。第五个实验，在第四个实验的基础上，增加了像素级对比损失 (L_{PCL})，即的完整模型。为了验证不同模块的有效性，将五个模型分别在 DIV2K_val5 这 5 张图片进行了 $\times 3$ 倍的超分辨率实验。具体性能如表 4-1 所示，可以看到：模型 base 虽然参数量最少，但 PSNR 仅 32.259dB；增加了 RFA 后的 PSNR 提高了 0.05dB；将 RFA 替换为 SAFB 后，比 base 模型高了近 0.1dB，比 RFA 高了 0.05dB；在不增加参数量的情况下，第四个模型仍然提高了 0.03dB，通过对比第三、四组实验，可以发现使用多种空洞率的卷积提取到的多尺度特征比单一尺度特征更有效；通过对比最后两组实验，可以发现在损失函数中使用本文所提出的 L_{PCL} 可以让生成的 SR 图像拥有更高的保真度。最终的模型在增加少量参数的情况下，相较于 base 模型提高了近 0.2dB，表明了 MRCAB、SAFB 和像素级对比损失，是有效的。

4.5.2 对比损失的设计与分析

4.5.2.1 对比损失的有效性分析

为了验证对比损失的有效性，不仅比较 L_1 、 L_{PCL} 、CSD 和感知损失在同一个模型下的 PSNR 值，还计算了学习的感知图像块相似性（Learned Perceptual Image Patch Similarity, LPIPS）度量。LPIPS 被认为更符合人类的感知，值越低表示结果越好。如表 4-2 所示， L_1 和 L_{PCL} 结合，PSNR 和 LPIPS 结果明显好于 L_1 的结果，PSNR 平均提高了 0.05dB，达到了最好的结果，LPIPS 也有所下降。 L_1 与感知损失结合（简称为 Lperc）后，所得到的 LPIPS 取得了改进，但 PSNR 值平均下降了 0.6dB 左右。在感知损失的基础上加上的 PCL 后，虽然，LPIPS 指标变化不大，但 PSNR 在测试集上平均提高了 0.1dB。把 CSD 方法与 L_{PCL} 结合后，PSNR 平均提升 0.05dB 的情况下，感知质量也达到了最好的效果。

表 4-2 不同损失函数在 4 个标准测试集上 $\times 2$ 的 PSNR 和 LPIPS 值

方法	Set5	Set14	B100	Urban100
	PSNR/LPIPS	PSNR/LPIPS	PSNR/LPIPS	PSNR/LPIPS
L_1	38.13/0.0551	34.68/0.0913	32.46/0.1392	32.64/0.0576
$L_1 + L_{PCL}$	38.18/0.0546	33.90/0.0895	32.50/0.1382	32.75/0.0558
Lperc	37.89/0.0445	33.48/0.0751	32.13/0.1201	32.48/0.0470
Lperc + L_{PCL}	38.01/0.0429	33.76/0.0739	32.20/0.1187	32.69/0.0454
CSD	38.09/ <u>0.0398</u>	33.79/ <u>0.0716</u>	32.25/ <u>0.1151</u>	32.69/ <u>0.0373</u>
CSD + L_{PCL}	<u>38.15/0.0382</u>	<u>33.86/0.0694</u>	<u>32.29/0.1136</u>	<u>32.73/0.0334</u>

4.5.2.2 对比损失中损失函数系数的影响

验证在同一个模型下，损失函数系数 λ_c 对网络性能的影响。如图 4-1 所示， λ_c 越大，代表对周围像素点的约束更加强烈，迫使周围像素更加远离当前像素，如果设置过大会破坏像素之间的关系，导致网络性能降低。如果设置过小又会导致该损失函数对模型的约束不够，极限情况下 $\lambda_c=0$ ，代表 L_{PCL} 不起任何作用。总的来说，损失函数系数 λ_c 为 10^{-1} 时，在约束当前点与周围点的关系时给出了一个折中的方案，使网络性能达到最佳的效果。




图 4-1 损失函数系数对模型性能的影响

4.5.2.3 对比损失中 K 的影响

进一步探讨研究选择不同数量的像素值（即 K ）进行对比学习对 L_{PCL} 的影响。在本文方法中，如果选择有 K 个像素点进行对比学习，而仅 HR 上对应位置的像素点是正样本，选择不同的 K 值对结果的影响如图 4-2 所示。




图 4-2 K 取值对模型性能的影响

经过对比样本数量的实验，发现在训练过程中选择更多的对比样本数量，会提升网络的表现性能。然而，这也会使得网络的训练时间变得更长，而且随着对比数量的增多，性能提升的效果也不再显著。因此，在性能和训练时间之间寻找平衡点变得非常重要。为了取得性能与训练时间的平衡，最终选择了 $K=64$ 作为最佳的对比样本数量。这种选择可以在保证性能的同时，不会显著增加训练时间，从而提高了训练效率。

4.5.2.4 对比损失的通用性分析

为了验证对比损失的通用性,把对比损失应用在不同的模型中,如 EDSR^[26]、SwinIR^[33]与 RCAN^[27]。如表 4-3 所示:

表 4-3 验证对比损失的通用性在 DIV2K_val5 上 $\times 3$ 的 PSNR

方法	PSNR(dB)	SSIM
EDSR	32.34(+0.06)	0.9067(+0.0010)
SwinIR	32.49(+0.05)	0.9350(+0.0007)
RCAN	33.63(+0.06)	0.9388(+0.0008)

对比损失可以进一步提升这些网络的性能。同时以 SwinIR 为例,模型在利用像素级对比损失后,所恢复出的图像细节更加准确,更加接近 HR 图像,如图 4-3 所示。




图 4-3 SwinIR 在 PCL 约束下的视觉效果

4.5.3 渐进特征融合模块的设计与分析

在主框架中,一共使用 10 个渐进特征融合模块(PFFG)。如图 3(b)所示,PFFG 包含了 3 个多尺度残差通道注意力模块(MRCAB)与 3 个空间注意力融合模块(SAFB)。分别研究了 MRCAB 和 SAFB 对网络的影响。

4.5.3.1 MRCAB 的设计与分析

MRCAB 块是建立在 RCAN 中的 RCAB 块的基础之上。为了在参数量不变的情况下,扩大感受野以及获得多尺度的信息,将 RCAB 的第一个卷积核进行多次参数复用,每次使用的空洞率是不同的。为了探究不同空洞率的卷积核对


性能的影响，对不同空洞率组合的 MRCAB 进行了对比实验。从表 4-4 中可以看出使用 1, 2, 4 的空洞率组合时，扩大了感受野的同时，也获取了多尺度信息，模型的性能达到了最高。但当使用 1, 2, 5 的组合时，PSNR 值却下降了 0.04dB 左右，这可能是较大的空洞卷积更加稀疏地提取图像特征，使得一些无用的像素参与了运算，导致了性能下降。

表 4-4 不同空洞率组合在 DIV2K_val5 上 $\times 3$ 的 PSNR


空洞率组合	PSNR(dB)
1	32.375
1, 2	32.370
1, 2, 3	32.392
1, 2, 4	32.451
1, 2, 5	32.412

4.5.3.2 SAFB 的设计与分析

为了验证 SAFB 比 RFA 融合方法更加有效，我们对 SAFB 与 RFA 线性融合方法在 DIV2K_val5 进行了验证和比较。SAFB 与 A²F 的结构如图 4-4 所示。在表 4-1 中第二和第三的结果显示出 SAFB 减少了参数量的同时，结果比 RFA 融



a) 基于空间注意力的特征融合



b) 基于通道注意力的特征融合

图 4-4 特征融合方法示意图

合方法更加有效。如图 4-4 a) 所示，SAFB 融合方法是一种利用空间注意力机制来融合残差特征的方法。

与 A²F 利用通道注意力如图 4-4 b) 的方法所示相比，在 MRCAB 块中已经使用了通道注意力，再利用其进行残差特征的融合，提升的效果不太明显。从表 4-5 中看出，利用空间注意力对残差特征进行融合，效果较好。

表 4-5 不同的注意力融合方法在 DIV2K_val5 上 $\times 2$ 的 PSNR

注意力融合方法	PSNR(dB)
通道注意力融合	35.88
像素注意力融合	35.90
空间注意力融合	35.94

4.6 实验结果

4.6.1 客观结果

本文同其 SRCNN^[16]、FSRCNN^[17]、DRCN^[21]、MSRN^[32]、ACAN^[39]、LatticeNet^[76]、LapSRN^[77]、AWSRN^[78]、SMSR^[79]、OISR-RK2^[80]、OISR-LF^[81]、SeaNet^[82]以及 TSAN^[83]方法在 5 个标准测试集上，在三个放大倍数 $\times 2$ 、 $\times 3$ 和 $\times 4$ 进行了 PSNR 和 SSIM 实验结果比较，如表 4-6 所示，最好的结果用加粗表示，次好结果用下划线表示。从表中可以看出，本文方法在所有数据集上不同的放大倍数上展示出了较好的结果。如图 4-5 所示，在 $\times 2$ 倍 Set14 数据集上，PRFFN 比 TSAN 模型的 PSNR 高出了 0.06dB；在 $\times 2$ 倍 Urban100 数据集上，PRFFN 比 SeaNet 模型的 PSNR 值高 0.15dB，并且 PRFFN 比 OISR-LF 模型参数量降低 2473k 的情况下，PSNR 值比其高出 0.09dB。在放大 $\times 3$ 倍的测试集上，PRFFN 比 MSRN 方法分别高出了 0.3dB、0.2dB、0.15dB、0.6dB 和 0.3dB。同样的，从评价指标 SSIM 可以看出，PRFFN 在不同倍数不同数据集上 SSIM 指标都有较好的结果。

4.6.2 主观结果

为了展示主观效果对比，将本文方法与其他先进且具有代表性的方法在 Urban100 和 Set14 这两个标准测试数据集上进行了主观视觉比较。如图 4-6、图 4-7 和图 4-8 分别展示本文方法与其他方法在三个不同放大倍数下重建不同效果的 SR 图，从结果可以很明显地看出，本文方法生成的超分辨率图像在细节信息和纹理清晰度上更加真实，更接近真实图像。这一优势在不同的放大倍数下都能

得到体现。例如在 Set14 数据集中,选取 barbara $\times 2$ 放大倍数下的图像,如图 4-6 所示, Bicubic、CARN、MSRN 等方法均未能恢复出准确且清晰的线条, SwinIR、TSAN 等方法恢复的线条方向出现错误,与真实图像不符。PRFFN 恢复出的线条明显更加清晰,更加准确,更接近真实图像。当放大倍数为 $\times 3$ 时,在 Urban100 数据集中的 img078 图像中,如图 4-7 所示,低分辨率图像经过 Bicubic 插值很不清晰,FSRCNN 重构出的图像比 Bicubic 稍好一些,但仍较为模糊,MSRN、CARN、SwinIR、TSAN、OISR-RK2 等模型所恢复出的线条恢复部分错误,观察本文方法的结果,显著更好。以放大倍数为 $\times 4$ 的 Urban100 中的 img076 图像为例,如图 4-8 所示, Bicubic、TSAN、FSRCNN、CARN 等模型恢复出的条纹之间出现了白色的断层,SeaNet、MSRN 和 OISR-RK2 模型出现部分条纹方向错误,而 SwinIR 模型和本文的模型,恢复出的条纹较为准确清晰。同样在 $\times 4$ 的 Urban100 数据集中的 img092 图像,横竖线条交错较为复杂,线条数量较多,更加考验模型的重建能力。观察恢复出的线条, Bicubic 恢复的图像已经非常模糊,其他方法均出现线条失真、歪斜等情况,而 PRFFN 更加贴合真实图像。根据实验结果可知,本文提出的渐进特征融合网络架构和像素级对比损失的方法能够有效地改善超分辨率重建结果。本文提出的渐进特征融合网络架构和像素级对比损失的方法,能充分利用提取到的特征,恢复出更加准确的像素值,们提出的方法在视觉效果方面优于其他先进的超分辨率方法,且在重建后的图像轮廓和边界方面表现出色,本文方法的结果也最接近于原始高分辨率图像。




图 4-5 各种 SISR 方法的 2x 放大倍数下 Set14 数据集上的平均 PSNR 值及参数量

表 4-6 不同 SISR 方法在 5 个标准测试数据集上 $\times 2$ 、 $\times 3$ 和 $\times 4$ 的平均 PSNR 与 SSIM
(最好结果与次好结果分别用加粗和下划线显示)

倍数	模型	Set5	Set14	B100	Urban100	Manga109
		PSNR/SSIM	PSNR/SSIM	PSNR/SSIM	PSNR/SSIM	PSNR/SSIM
$\times 2$	SRCNN	36.66/0.9524	32.42/0.9063	31.36/0.8879	29.50/0.8946	35.74/0.9661
	FSRCNN	37.01/0.9557	32.62/0.9078	31.53/0.8920	29.88/0.9020	36.68/0.9691
	DRCN	37.63/0.9568	33.04/0.9128	31.85/0.8943	30.74/0.9130	37.65/0.9733
	LapSRN	37.52/0.9590	33.08/0.9130	31.80/0.8950	30.41/0.9100	37.27/0.9740
	ACAN	38.10/0.9608	33.60/0.9177	32.21/0.9001	32.29/0.9297	38.81/0.9773
	CARN	37.76/0.9590	33.52/0.9166	32.09/0.8978	31.92/0.9256	38.36/0.9765
	LatticeNet	38.06/0.9607	33.70/0.9187	32.20/0.9000	32.25/0.9288	38.94/0.9774
	OISR-RK2	38.12/0.9609	33.80/0.9193	32.26/0.9007	32.48/0.9317	38.79/0.9773
	OISR-LF	38.12/0.9609	33.78/0.9186	32.26/0.9007	32.52/0.9320	38.80/0.9774
	MSRN	38.08/0.9607	33.70/0.9186	32.23/0.9002	32.29/0.9303	38.69/0.9772
	AWSRN	38.11/0.9608	33.78/0.9189	32.26/0.9006	32.88/0.9346	<u>38.87/0.9776</u>
	TSAN	<u>38.22/0.9619</u>	<u>33.84/0.9218</u>	<u>32.32/0.9015</u>	<u>32.77/0.9345</u>	-/-
	Ours	<u>38.18/0.9611</u>	<u>33.90/0.9207</u>	<u>32.30/0.9012</u>	<u>32.75/0.9337</u>	<u>39.02/0.9777</u>
$\times 3$	SRCNN	32.75/0.9090	29.28/0.8209	28.41/0.7863	26.24/0.7989	30.59/0.9107
	FSRCNN	33.15/0.9139	29.39/0.8239	28.49/0.7909	26.43/0.8080	30.98/0.9212
	DRCN	33.82/0.9226	29.89/0.8304	28.80/0.7954	27.15/0.8311	32.31/0.9328
	ACAN	34.46/0.9277	30.39/0.8435	29.11/0.8065	28.28/0.8550	33.61/0.9447
	CARN	34.30/0.9255	30.29/0.8407	29.06/0.8034	27.38/0.8493	33.50/0.9440
	LatticeNet	34.40/0.9272	30.32/0.8461	29.10/0.8049	28.19/0.8513	33.63/0.9442
	OISR-RK2	34.55/0.9282	30.46/0.8443	29.18/0.8075	28.50/0.8597	<u>33.80/0.9442</u>
	OISR-LF	34.56/0.9284	30.46/0.8450	29.20/0.8077	28.56/0.8606	33.78/0.9442
	MSRN	34.38/0.9262	30.34/0.8395	29.08/0.8041	28.08/0.8554	33.44/0.9427
	SeaNet	34.55/0.9280	30.42/0.8395	29.17/0.8071	28.50/0.8594	<u>33.73/0.9463</u>
	TSAN	<u>34.64/0.9282</u>	<u>30.52/0.8454</u>	<u>29.20/0.8080</u>	<u>28.55/0.8602</u>	-/-
	Ours	<u>34.67/0.9288</u>	<u>30.54/0.8460</u>	<u>29.23/0.8084</u>	<u>28.65/0.8621</u>	<u>34.03/0.9473</u>
$\times 4$	SRCNN	30.48/0.8628	27.49/0.7503	26.90/0.7101	24.52/0.7221	27.66/0.8505
	FSRCNN	30.71/0.8657	27.59/0.7535	26.98/0.7150	24.62/0.7280	27.90/0.8517
	DRCN	31.53/0.8854	28.02/0.7670	27.23/0.7233	25.14/0.7510	28.98/0.8816
	LapSRN	31.54/0.8850	28.19/0.7720	27.32/0.7280	25.21/0.7560	29.09/0.8845
	AWSRN	32.46/0.8968	28.69/0.7843	27.64/0.7385	26.29/0.7930	30.72/0.9109
	CARN	32.13/0.8937	28.60/0.7806	27.58/0.7349	26.07/0.7837	30.47/0.9084
	OISR-RK2	32.32/0.8965	28.72/0.7843	27.72/0.7400	26.37/0.7953	30.75/0.9082
	OISR-LF	32.33/0.8968	28.73/0.7845	27.66/0.7389	26.38/0.7953	<u>30.76/0.9080</u>
	SeaNet	32.33/ <u>0.8981</u>	28.72/ <u>0.7855</u>	27.65/0.7388	26.32/0.7942	<u>30.74/0.9129</u>
	MSRN	32.07/0.8903	28.60/0.7751	27.52/0.7273	26.04/0.7896	30.17/0.9034
	TSAN	<u>32.40/0.8975</u>	<u>28.73/0.7847</u>	<u>27.67/0.7398</u>	<u>26.39/0.7955</u>	-/-
	Ours	<u>32.43/0.8983</u>	<u>28.75/0.7857</u>	<u>27.70/0.7398</u>	<u>26.55/0.7974</u>	<u>30.93/0.9133</u>




图 4-6 ×2 视觉效果比较




图 4-7 ×3 视觉效果比较




图 4-8 ×4 视觉效果比较

4.7 本章小结

本章详细介绍了网络训练所需的数据集、实验参数和评价指标，并进行了充

分的消融实验和对比实验，以证明本文方法创新点的有效性。此外，还展示了最终实验结果。首先在章节开头介绍了网络训练用到的数据集 DIV2K 和用于测试的五个标准测试集。接下来介绍了训练网络所需要的参数的一些设置，包含批处理量、学习率、优化器、迭代周期和训练设备等。然后，为了验证各个模块的有效性以及一些超参数设置的合理性，对各个模块进行了消融实验以及不同的参数对网络的影响，证明了本文提出的架构和损失是合理且有效的，并且只有设置与本文相同的参数以及同时使用这两个方法时效果是最好的。对于像素级对比损失，通过三组对比实验分别验证了损失系数和选取正负样本数量的合理性以及对比损失的通用性；对于网络架构设计，通过两组实验证明了 MRCAB 的合理性和 SAFB 的有效性。最后通过大量的图表，在客观和主观两个角度对不同放大倍数下、多个数据集上的实验结果进行了详细的分析。客观角度采用了 PSNR 和 SSIM 两个指标对恢复图像的质量进行了评价。在不同倍数下，本文提出的方法在多个数据集上都取得了优于其他方法的表现。主观方面，本文列举了四张具有代表性的超分辨率图像。实验结果显示，本文方法恢复出的图像具有更加清晰的轮廓和纹理细节，可以更好地还原高清图像的细节特征。通过综合客观和主观两个角度的实验分析，可以得出本文提出的方法相对于其他方法具有更高的重建质量，可以为超分辨率领域的研究提供有价值的参考。

第 5 章 结论与展望

5.1 论文工作总结

在深度学习快速发展的趋势下,许多算法为了追求高性能,不断加深网络的深度和加宽网络的宽度,但是随着参数量和计算量的剧增,在计算和存储资源受限设备上难以应用。SISR 是一个具有挑战性的不适定问题,存在无限多的高分辨率图像可以退化成同一个低分辨率图像,大多数现有的方法利用平均绝对误差或均方误差来最小化生成的超分辨率图像和高分辨率图像对应像素之间的距离,这可能会导致最终得到的超分辨率图像是解空间的均值,重建的图像往往过于平滑,不接近人类对自然图像的视觉感受。为解决上述问题,本文提出了一个新的基于对比学习的逐像素损失函数和一个新的网络架构,称为渐进残差特征融合网络 (PRFFN)。具体来说,本文的主要创新点有 3 个:

(1) 提出了一个新的基于对比学习的逐像素损失函数 (L_{PCL})。它仅利用 LR 图像与 HR 图像的内部信息,并不依赖于非配对的 LR 图像。在图像空间,训练 HR 图像与输出的 SR 图像对应的像素分别作为正样本和锚,HR 图像上与正样本像素值不同的像素作为负样本集合,与正样本像素值相同的像素构成正样本集合。以对比学习的方式拉近正样本对之间的距离,推远负样本对之间的距离。 L_{PCL} 通过对比学习的方式把锚点像素更好地接近 HR 图像上相同位置的像素,可显著改进 SR 图像的保真度和视觉质量。

(2) 提出了一个新的网络架构,称为渐进残差特征融合网络。PRFFN 应用扩张卷积^[39]扩展 RCAN^[27]的基本构件-残差通道注意力块 (RCAB) 以支持多尺度特征,称为多尺度残差通道注意力块 (MRCAB)。PRFFN 以 MRCAB 作为基本构件,并运用空间注意力机制^[40],渐进地融合 MRCAB 的特征,从而使融合后的特征更加有利于网络的学习。实验证明,PRFFN 优于当前类似方法的性能。

(3) 提出的 PRFFN 与 L_{PCL} 结合取得了具有竞争力的超分辨率方法的性能 (客观和主观性能)。此外实验还表明,本文所提出的 L_{PCL} 能提升其他超分辨率方法的性能。

5.2 未来工作展望

本文对提出了一种基于像素级对比学习的图像超分辨率算法,并提出了基于特征融合的网络架构。该方法在主观和客观指标方面都取得较好的效果,提升了

图像的重建质量。然而，本文方法仍然存在一些局限性，需要进一步改进，其中包括：

（1）本文所提出的方法像素级对比损失，需要计算来获得重建图像的一个像素点到高分辨率图像每个像素点的 L1 距离，虽然不增加测试的计算量和时间，但会带来训练时长增加。因此，寻找一种合理的计算方式，降低训练时间，以便应用在更多的模型上。

（2）本文所提出的方法目前仅限于单图像超分辨率方法，并且没有扩展到其他相关任务，例如视频超分辨率或低光图像增强。如何构建一个在更多领域可以利用的损失函数将会是一个新的热点。

参考文献

- [1] Freeman W T, Pasztor E C, Carmichael O T. Learning low-level vision[J]. International Journal of Computer Vision, 2000, 40(1): 25-47
- [2] Thornton M W, Atkinson P M, Holland D A. Sub-pixel mapping of rural land cover objects from fine spatial resolution satellite sensor imagery using super-resolution pixel-swapping[J]. International Journal of Remote Sensing, 2006, 27(3): 473-491
- [3] Zou W W, Yuen P C. Very low resolution face recognition problem[J]. IEEE Transactions on image processing, 2011, 21(1): 327-340
- [4] Shi W, Caballero J, Ledig C, et al. Cardiac image super-resolution with global correspondence using multi-atlas patchmatch[C]. Medical Image Computing and Computer-Assisted Intervention–MICCAI 2013: 16th International Conference, Nagoya, Japan, September 22-26, 2013, Proceedings, Part III 16, 2013: 9-16
- [5] Rukundo O, Cao H. Applications. Nearest neighbor value interpolation[J]. International Journal of Advanced Computer Science, 2012, 3(4): 25-30
- [6] Gribbon K T, Bailey D G. A novel approach to real-time bilinear interpolation[C]. Proceedings. DELTA 2004. Second IEEE international workshop on electronic design, test and applications. IEEE, 2004: 126-131
- [7] Carlson R E, Fritsch F N. Monotone piecewise bicubic interpolation[J]. SIAM journal on numerical analysis, 1985, 22(2): 386-400
- [8] Li X, Orchard M T. New edge-directed interpolation[J]. IEEE transactions on image processing, 2001, 10(10): 1521-1527
- [9] Battiato S, Gallo G, Stanco F, et al. A locally adaptive zooming algorithm for digital images[J]. Image and vision computing, 2002, 20(11): 805-812
- [10] Tsai R Y, Huang T S. Registration. Multiframe image restoration and registration[J]. Multiframe image restoration, 1984, 1: 317-339
- [11] Irani M, Peleg S, Processing I. Improving resolution by image registration[J]. CVGIP: Graphical models, 1991, 53(3): 231-239
- [12] Schultz R R, Stevenson R L. A Bayesian approach to image expansion for improved definition[J]. IEEE transactions on Image Processing, 1994, 3(3): 233-242
- [13] Yang J, Wright J, Huang T S, et al. Image super-resolution via sparse representation[J]. IEEE transactions on image processing, 2010, 19(11): 2861-2873
- [14] Yang S, Wang Z, Zhang L, et al. Dual-geometric neighbor embedding for image

- super resolution with sparse tensor[J]. IEEE transactions on image processing, 2014, 23(7): 2793-2803
- [15]Tang Y, Yan P, Yuan Y, et al. Single-image super-resolution via local learning[J]. International Journal of Machine Learning, 2011, 2: 15-23
- [16]Dong C, Loy C C, He K, et al. Learning a deep convolutional network for image super-resolution[C]. Proceedings of the 2016 European Conference on Computer Vision, 2014: 184–199
- [17]Dong C, Chen C L, Tang X. Accelerating the super-resolution convolutional neural network[C]. Proceedings of the 2016 European Conference on Computer Vision, 2016: 391-407
- [18]Shi W, Caballero J, Huszár F, et al. Real-time single image and video super-resolution using an efficient sub-pixel convolutional neural network[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2016: 1874-1883
- [19]He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2016: 770-778
- [20]Kim J, Lee J K, Lee K M. Accurate image super-resolution using very deep convolutional networks[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2016: 1646-1654
- [21]Kim J, Lee J K, Lee K M. Deeply-recursive convolutional network for image super-resolution[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2016: 1637-1645
- [22]Tai Y, Yang J, Liu X, et al. Memnet: A persistent memory network for image restoration[C]. Proceedings of the IEEE international conference on computer vision, 2017: 4539-4547
- [23]Ahn N, Kang B, Sohn K-A. Fast, accurate, and lightweight super-resolution with cascading residual network[C]. Proceedings of the European conference on computer vision (ECCV), 2018: 252-268
- [24]Ledig C, Theis L, Huszár F, et al. Photo-realistic single image super-resolution using a generative adversarial network[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2017: 4681-4690
- [25]Zhang Y, Tian Y, Kong Y, et al. Residual dense network for image super-resolution[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2018: 2472-2481
- [26]Lim B, Son S, Kim H, et al. Enhanced deep residual networks for single image super-resolution[C]. Proceedings of the IEEE conference on computer vision and pattern recognition workshops, 2017: 136-144

- [27]Zhang Y, Li K, Li K, et al. Image super-resolution using very deep residual channel attention networks[C]. Proceedings of the European conference on computer vision (ECCV), 2018: 286-301
- [28]Lin Z, Garg P, Banerjee A, et al. Revisiting rcnn: Improved training for image super-resolution[J]. arXiv preprint arXiv:11279, 2022
- [29]Tong T, Li G, Liu X, et al. Image super-resolution using dense skip connections[C]. Proceedings of the IEEE international conference on computer vision, 2017: 4799-4807
- [30]Zhang Y, Li K, Zhong B, et al. Residual Non-local Attention Networks for Image Restoration[C]. International Conference on Learning Representations, 2019.
- [31]Niu B, Wen W, Ren W, et al. Single image super-resolution via a holistic attention network[C]. Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XII 16, 2020: 191-207
- [32]Li J, Fang F, Mei K, et al. Multi-scale residual network for image super-resolution[C]. Proceedings of the European conference on computer vision (ECCV), 2018: 517-532
- [33]Lu Z, Li J, Liu H, et al. Transformer for single image super-resolution[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 457-466
- [34]Conde M V, Choi U J, Burchi M, et al. Swin2SR: Swinv2 transformer for compressed image super-resolution and restoration[C]. Computer Vision–ECCV 2022 Workshops: Tel Aviv, Israel, October 23–27, 2022, Proceedings, Part II. Cham: Springer Nature Switzerland, 2023: 669-687
- [35]Luo Z, Huang Y, Li S, et al. Learning the degradation distribution for blind image super-resolution[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 6063-6072
- [36]Fu J, Wang H, Xie Q, et al. KXNet: A model-driven deep neural network for blind super-resolution[C]. Computer Vision–ECCV 2022: 17th European Conference, Tel Aviv, Israel, October 23–27, 2022, Proceedings, Part XIX. Cham: Springer Nature Switzerland, 2022: 235-253
- [37]Liang J, Cao J, Sun G, et al. Swinir: Image restoration using swin transformer[C]. Proceedings of the IEEE/CVF international conference on computer vision, 2021: 1833-1844
- [38]Liu Z, Lin Y, Cao Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]. Proceedings of the IEEE/CVF international conference on computer vision, 2021: 10012-10022
- [39]周登文, 王婉君, 马钰, 等. 基于区域互补注意力和多维注意力的轻量级图像超分辨率网络[J]. 模式识别与人工智能, 2022, 35(07): 625-636

- [40]Fan Y, Shi H, Yu J, et al. Balanced two-stage residual networks for image super-resolution[C]. Proceedings of the IEEE conference on computer vision and pattern recognition workshops, 2017: 161-168
- [41]Johnson J, Alahi A, Fei-Fei L. Perceptual losses for real-time style transfer and super-resolution[C]. Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11-14, 2016, Proceedings, Part II 14, 2016: 694-711
- [42]Sajjadi M S, Scholkopf B, Hirsch M. Enhancenet: Single image super-resolution through automated texture synthesis[C]. Proceedings of the IEEE international conference on computer vision, 2017: 4491-4500
- [43]Yu F, Koltun V. Multi-scale context aggregation by dilated convolutions[J]. arXiv preprint arXiv:1507.01222, 2015
- [44]Woo S, Park J, Lee J-Y, et al. Cbam: Convolutional block attention module[C]. Proceedings of the European conference on computer vision (ECCV), 2018: 3-19
- [45]Wang Z, Bovik A C, Sheikh H R, et al. Image quality assessment: from error visibility to structural similarity[J]. IEEE transactions on image processing, 2004, 13(4): 600-612
- [46]Zhang R, Isola P, Efros A A, et al. The unreasonable effectiveness of deep features as a perceptual metric[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2018: 586-595
- [47]He K, Fan H, Wu Y, et al. Momentum contrast for unsupervised visual representation learning[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2020: 9729-9738
- [48]Sermanet P, Lynch C, Chebotar Y, et al. Time-contrastive networks: Self-supervised learning from video[C]. 2018 IEEE international conference on robotics and automation (ICRA). IEEE, 2018: 1134-1141
- [49]Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. International Conference on Learning Representations (ICLR), 2015: 1-14
- [50]Wu G, Jiang J, Liu X, et al. A practical contrastive learning framework for single image super-resolution[J]. arXiv preprint arXiv:2103.13924, 2021
- [51]Wu H, Qu Y, Lin S, et al. Contrastive learning for compact single image dehazing[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021: 10551-10560
- [52]Wang Y, Lin S, Qu Y, et al. Towards Compact Single Image Super-Resolution via Contrastive Self-distillation[J]. arXiv preprint arXiv:2105.11683, 2021
- [53]Wang L, Dong X, Wang Y, et al. Exploring sparsity in image super-resolution for efficient inference[C]. Proceedings of the IEEE/CVF conference on computer

- p>vision and pattern recognition, 2021: 4917-4926
- [54]Radford A, Metz L, Chintala S. Unsupervised representation learning with deep convolutional generative adversarial networks[J]. arXiv preprint arXiv:1511.06434, 2015
- [55]Arjovsky M, Chintala S, Bottou L. Wasserstein generative adversarial networks[C]. International conference on machine learning, 2017: 214-223
- [56]Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2018: 7132-7141
- [57]周登文, 李文斌, 李金新, 等. 一种轻量级的多尺度通道注意图像超分辨率重建网络[J]. 电子学报, 2022, 50(10): 2336-2346
- [58]Park J, Woo S, Lee J-Y, et al. Bam: Bottleneck attention module[J]. arXiv preprint arXiv:1807.06514, 2018
- [59]Dai T, Cai J, Zhang Y, et al. Second-order attention network for single image super-resolution[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2019: 11065-11074
- [60]Wang X, Yu K, Wu S, et al. Esrgan: Enhanced super-resolution generative adversarial networks[C]. Proceedings of the European conference on computer vision (ECCV) workshops. 2018: 0-0
- [61]Huang G, Liu Z, Van Der Maaten L, et al. Densely connected convolutional networks[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2017: 4700-4708
- [62]Liu J, Zhang W, Tang Y, et al. Residual feature aggregation network for image super-resolution[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2020: 2359-2368
- [63]Wang X, Wang Q, Zhao Y, et al. Lightweight single-image super-resolution network with attentive auxiliary feature learning[C]. Proceedings of the Asian conference on computer vision, 2020
- [64]Hadsell R, Chopra S, LeCun Y. Dimensionality reduction by learning an invariant mapping[C]. 2006 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'06). IEEE, 2006, 2: 1735-1742
- [65]Chen T, Kornblith S, Norouzi M, et al. A simple framework for contrastive learning of visual representations[C]. International conference on machine learning, 2020: 1597-1607
- [66]Xie Z, Lin Y, Zhang Z, et al. Propagate yourself: Exploring pixel-level consistency for unsupervised visual representation learning[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021: 16684-16693
- [67]Oord A V D, Li Y, Vinyals O. Representation learning with contrastive predictive

- coding[J]. arXiv preprint arXiv:1807.03748, 2018
- [68]Agustsson E, Timofte R. Ntire 2017 challenge on single image super-resolution: Dataset and study[C]. Proceedings of the IEEE conference on computer vision and pattern recognition workshops, 2017: 126-135
- [69]Bevilacqua M, Roumy A, Guillemot C, et al. Low-Complexity Single-Image Super-Resolution based on Nonnegative Neighbor Embedding[C]. British Machine Vision Conference (BMVC), 2012
- [70]Zeyde R, Elad M, Protter M. On single image scale-up using sparse-representations[C]. Curves and Surfaces: 7th International Conference, Avignon, France, June 24-30, 2010, Revised Selected Papers 7. Springer Berlin Heidelberg, 2012: 711-730
- [71]Martin D, Fowlkes C, Tal D, et al. A database of human segmented natural images and its application to evaluating segmentation algorithms and measuring ecological statistics[C]. Proceedings Eighth IEEE International Conference on Computer Vision. ICCV 2001, 2001: 416-423
- [72]Huang J-B, Singh A, Ahuja N. Single image super-resolution from transformed self-exemplars[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2015: 5197-5206
- [73]Matsui Y, Ito K, Aramaki Y, et al. Sketch-based manga retrieval using manga109 dataset[J]. Multimedia Tools and Applications, 2017, 76: 21811-21838
- [74]Dong C, Loy C C, He K, et al. Learning a deep convolutional network for image super-resolution[C]. Computer Vision—ECCV 2014: 13th European Conference, Zurich, Switzerland, September 6-12, 2014, Proceedings, Part IV 13, 2014: 184-199
- [75]Paszke A, Gross S, Chintala S, et al. Automatic differentiation in pytorch[J], 2017
- [76]Luo X, Xie Y, Zhang Y, et al. Latticenet: Towards lightweight image super-resolution with lattice block[C]. Computer Vision—ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XXII 16, 2020: 272-289
- [77]Lai W-S, Huang J-B, Ahuja N, et al. Deep laplacian pyramid networks for fast and accurate super-resolution[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2017: 624-632
- [78]Li Z, Wang C, Wang J, et al. Lightweight adaptive weighted network for single image super-resolution[J]. Computer Vision and Image Understanding, 2021, 211: 103254
- [79]Wang L, Dong X, Wang Y, et al. Exploring sparsity in image super-resolution for efficient inference[C]. Proceedings of the IEEE/CVF conference on computer

- vision and pattern recognition. 2021: 4917-4926
- [80]He X, Mo Z, Wang P, et al. Ode-inspired network design for single image super-resolution[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019: 1732-1741
- [81]Fang F, Li J, Zeng T. Soft-edge assisted network for single image super-resolution[J]. IEEE Transactions on Image Processing, 2020, 29: 4656-4668
- [82]Zhang J, Long C, Wang Y, et al. A two-stage attentive network for single image super-resolution[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2021, 32(3): 1020-1033
- [83]Chollet F. Xception: Deep learning with depthwise separable convolutions[C]. Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1251-1258