

华北电力大学

学术硕士学位论文

基于多路跨尺度信息融合的轻量级超分辨率
算法研究

Lightweight Super-Resolution Algorithm Based on
Multi-Path Cross-Scale Information Fusion

李珊珊

2022 年 5 月

国内图书分类号：TP39

学校代码：10079

国际图书分类号：004.9

密级：公开

学术硕士学位论文

基于多路跨尺度信息融合的轻量级超分辨率 算法研究

硕 士 研 究 生：李珊珊

导 师：周登文教授

申 请 学 位：工学硕士

学 科：计算机科学与技术

专 业：计算机科学与技术

所 在 学 院：控制与计算机工程学院

答 辩 日 期：2022 年 5 月

授予学位单位：华北电力大学

Classified Index: TP39

U.D.C: 004.9

Dissertation for the Academic Master's Degree

**Lightweight Super-Resolution Algorithm Based on
Multi-Path Cross-Scale Information Fusion**

Candidate:	Li Shanshan
Supervisor:	Prof. Zhou Dengwen
Academic Degree Applied for:	Master of Engineering
Subject:	Computer Science and Technology
Speciality:	Computer Science and Technology
School:	School of Control and Computer Engineering
Date of Defence:	May, 2022
Degree-Conferring-Institution:	North China Electric Power University

摘 要

单图像超分辨率重建是计算机视觉领域经典问题，旨在从一张给定的低分辨率图像中恢复出高分辨率图像。但是，性能的改进，往往以参数量的急剧增加为代价。通常，规模更大的网络，表达能力更强，取得的性能更好，然而更大的网络往往会急剧增加参数量和计算量，这限制了超分辨率方法在资源受限的移动设备上的实际应用。本文提出了一个新的基于多路跨尺度的轻量级单图像超分辨率网络，目的在于构建一种参数量和计算量都较小的网络，同时在深度卷积神经网络模型复杂度和单图像超分辨率性能之间，建立更好的平衡。

(1) 本文提出了多路特征渐进融合块(FPF)，使用多种尺寸不同的卷积核来提取多路径上不同深度的特征信息，FPF 充分利用浅层特征信息和深层特征信息，为重建高质量图像提供丰富的细节信息。我们将浅层特征通过 1×1 的卷积和 Sigmoid 函数去多路渐进地引导深层特征的提取。

(2) 本文提出了多路特征注意力机制(FAM)，FAM 与 FPF 配对使用，加权拼接多路通道特征，可以增强特征表达能力。采用通道级联直接连接不同层次的特征，忽略了自适应学习对模型的贡献，加权层间连接虽然会阻碍有效的反向传播，但这种自适应学习的方法与人脑神经元的行为方式相似。基于该思想，我们设计了 FAM 模块，可以最优地对特征通道进行加权，并进行通道拼接。

(3) 本文提出了一个基于多路跨尺度信息融合的轻量级图像超分辨率模型，该模型无论是在主观视觉还是客观性能指标，均显著高于其它类似的轻量级超分辨率方法，在深度卷积神经网络模型复杂度和单图像超分辨率的性能之间，取得了一个更好的平衡。

关键字：注意机制；卷积神经网络；深度学习；超分辨率

Abstract

Single image super-resolution reconstruction is a classical problem in the field of computer vision, which aims to recover a high-resolution image from a given low-resolution image. However, the improvement of performance is often at the expense of the sharp increase of parameters. Generally, larger networks have stronger expression ability and better performance, however, larger networks tend to dramatically increase the amount of parameters and calculations which limits the practical application of super-resolution method in resource constrained mobile devices. In this paper, we propose a new lightweight single image super-resolution network based on multi-channel and cross scale. The purpose is to build a network with less parameters and computation, and establish a better balance between the model complexity of deep convolutional neural network and the performance of single image super-resolution.

(1) We proposed multi-channel feature progressive fusion block (FPF), which uses a variety of convolution cores with different sizes to extract the feature information of multi-path and different depths. FPF makes full use of shallow feature information and deep feature information to provide rich detail information for reconstructing high-quality images. We use 1×1 convolution and sigmoid function to gradually guide the learning of deep features and predicts the importance of features pixel by pixel.

(2) We proposed a multi-channel feature attention mechanism (FAM). FAM and FPF are paired and weighted to splice multi-channel features, which can enhance the ability of feature expression. The channel cascade is used to directly connect the characteristics of different levels, ignoring the contribution of adaptive learning to the model. Although the weighted interlayer connection will hinder the effective back propagation, this adaptive learning method is more in line with the behavior of human brain neurons. We adopt the attention mechanism, which can concatenate the multi-path weighted feature channels and enhance the expression ability of features.

(3) We proposed a multi-channel and cross-scale lightweight image super-resolution model. The model is superior to other similar lightweight super-resolution methods in terms of subjective vision, objective performance indexes, and achieves a better balance between the complexity of deep convolutional neural network model and the performance of single image super-resolution.

Keywords: attention mechanism, convolutional neural network, deep learning, super-resolution

目 录

摘 要 I

Abstract.....II

第 1 章 绪 论 1

 1.1 课题背景及研究意义 1

 1.2 国内外研究现状 2

 1.2.1 基于插值的超分辨率技术 2

 1.2.2 基于重建的超分辨率技术 3

 1.2.3 基于学习的超分辨率技术 3

 1.3 主要研究内容 6

 1.4 论文的内容结构安排 7

第 2 章 相关方法综述 9

 2.1 卷积神经网络 9

 2.2 经典的单图像超分辨率算法 14

 2.2.1 SRCNN 方法 14

 2.2.2 FSRCNN 方法 14

 2.2.3 VDSR 方法 15

 2.3 注意力机制 16

 2.3.1 通道注意力机制 16

 2.3.2 空间注意力机制 16

 2.3.3 混合注意力机制 17

 2.4 本章小结 17

第 3 章 基于多路跨尺度信息融合的轻量级超分辨率算法研究 18

 3.1 引言 18

 3.2 多路径特征提取块 19

 3.2.1 Inception 模块 19

 3.2.2 多路径信息融合块 20

 3.3 算法总体框架 23

 3.3.1 MPFN 网络结构 24

 3.3.2 多路特征提取块(MPFE) 25

 3.3.3 多路特征渐进融合块(FPF) 26

 3.3.4 多路特征注意力机制(FAM) 27

3.3.5 分层特征融合注意力块(HFFAB).....	28
3.3.6 上采样(Upsampler).....	31
3.4 本章小结	32
第 4 章 实验与分析	33
4.1 引言	33
4.2 数据集	33
4.2.1 训练集	33
4.2.2 测试集	33
4.3 图像质量评价	34
4.3.1 PSNR	34
4.3.2 SSIM	35
4.3.3 LPIPS	35
4.4 损失函数	36
4.5 实验细节	36
4.5.1 实验参数设置	36
4.5.2 各种对比实验	37
4.6 结果与分析	39
4.6.1 客观评价指标对比	39
4.6.2 主观效果对比	45
4.7 本章小结	46
第 5 章 结论与展望	48
5.1 论文工作总结	48
5.2 未来工作展望	49
参考文献	50
攻读硕士学位期间发表的论文及其它成果	56
致谢	57

第1章 绪论

1.1 课题背景及研究意义

由于计算机人工智能技术逐渐变为当今的技术主流。所以，成为计算机人工智能的主要组成部分之一的图像传感器急剧增加。而在人工智能涉及的几乎所有感知领域当中，视觉领域也是最具有核心的，视觉输入占据了人类全部感觉信息输入量的近百分之八十，而且它还是人类最为复杂困难的其中一个感知。计算机视觉与人工智能有密切联系，计算机视觉正是用各类图像信息系统替代视觉艺术器官当作信息输入敏感工具和手段，由计算机系统来替代人脑进行信息处理和解读。计算机图像视觉的最后研发工作目标在于使计算机能像人一样透过图像视觉观测和了解整个世界，具备主动应对周围环境的力量。在达到终点之前，人类奋斗的中期主要目标是创建一个视觉信息系统，这种信息系统能依靠人的视觉敏感性和反馈的某种程度的智慧共同完成特定的各项任务。

在计算机视觉系统中，计算机图像处理方式对图像视觉信息内容的处理过程是十分关键的。图像处理技术涉及图像描述、图像增强等内容^[1]。所以图像对计算机视觉的发展变得十分重要，以前的图像质量太差，清晰度已经不能满足人们的需求，所以基于深度学习的单图像超分辨率重建技术成为了图像处理技术研究的重要部分之一，该技术凭借着自身简单，方便实现的特点，在社会中有广泛的应用领域，例如：军事，医学，公共安全等。

(1) 军事领域。众所周知，在采集军事图像的时候，在大风或大雾等天气条件下，对图像分辨率的影响是极大的，很容易使得图像变得模糊，这对于非常严格的军事来说，是一种非常致命的弱点。图像超分辨重建技术的存在，给军事领域带来了极大的便捷。

(2) 医学领域。医学影像模态有很多种类型，涉及电子计算机断层扫描、X光线、磁共振造影、超声等。由于医疗成像系统的图像质量很容易受到病人配合度的直接影响，会严重影响到医生对病情的判断与分析。医学成像设备是比较昂贵的，图像超分辨重建技术的存在，可以在减少医学成像成本的情况下，有利于医生快速定位病因，极大地提高医生和患者的诊疗效率。

(3) 公共安全领域。在中国的许多城市，基本已经实现了监控摄像的全覆盖。这些监控摄像往往被用于违法犯罪追踪，但是在大风或大雾的天气下，图像质量就会受到影响，图像超分辨重建技术的存在，可以有助于办案人员快速恢复出清晰的视频图像，迅速对案情进行分析，可以维护我们的社会安全，从而减少违法

犯罪。

由此可见，图像超分辨率技术对我们的社会有着极大的意义。近年来，由于深度学习技术的迅速发展，研究人员提出了各种多样的超分辨率网络模型。相对于传统的方法，图像超分辨率技术之所以有如此的飞跃，主要得益于卷积神经网络的存在。

1.2 国内外研究现状

单图像超分辨率重建(Single Image Super-Resolution, SISR)目的在于从给定的低分辨率图像(Low-Resolution, LR)得到高分辨率图像(High-Resolution, HR)^[2]。但是在学习从LR到HR图像的映射的过程中，可以得到无限个HR图像^[3]。而且，在自然图像中，它们退化的方式多种多样，我们无法确定单一的形式。当前单图像超分辨率重建主要有三大类：(1) 基于插值的超分辨率技术^[4-6]；(2) 基于重建的超分辨率技术^[7-8]；(3) 基于学习的超分辨率技术^[9-28]。

1.2.1 基于插值的超分辨率技术

基于插值的方法，通俗上来讲，就是利用我们所知道的一些图像像素点的值，通过对这些图像像素值进行一些预先定义的数学公式运算，从而得到想要插值点的像素值。由于只是简单地进行了一些数学公式的运算，所以是十分便于人们理解的；但是也是存在着一定的缺点。比如：①图像的降质过程是千变万化的，而仅仅只是通过对这些图像像素值进行一些预先定义的数学公式运算，从而得到想要插值点的像素值，就会导致产生特别模糊的现象；②在图像的像素值中，它的变化是断续的。目前常采用的插值方法有：最近邻插值法、双线性插值法和双立方插值法。

(1) 最近邻插值法：该方法是三者中最简单的方法。从名字上进行分析，该方法是利用最相近的像素点进行插值，可以注意到是，在这个过程只是一个简单的线性运算，而且将最相近像素点的像素值复制给插值点。在一张图像的许多个像素点中，它们存在着十分紧密的联系，而最近邻插值忽视了这种联系，所以导致恢复出来的超分辨率图像效果很差，甚至会有马赛克。

(2) 双线性插值法：为了利用在一张图像的很多个像素点中的紧密联系，该方法采用了与其最相近的4个像素点进行一些数学公式的运算，从而得到像素值。虽然图像超分辨率重建的质量得到了进一步的提升，然而仍旧有以下两点缺陷：①由于需要采用4个像素点做水平和垂直方向的线性内插，所以计算量会增加，运算复杂，从而运行时间也会增加；②仅仅考虑了最相邻的4个像素点的影响，所考虑到的影响因素太少，导致图像也会产生一定的模糊现象。

(3) 双立方卷积插值法: 该方法采用了最相近的 16 个像素点进行一些数学公式的运算, 得到想要插值点的像素值。由此可见, 计算时间都会比上述两种方法要增加。同时这个过程进行 3 次插值的运算, 所以计算复杂度相对于以上两种方法也会增加。但是, 它重建的效果在这三种方法中是最好的。

为了解决上述三种传统的方法, Li 等^[4]提出了一种利用协方差系数来调整插值计算, 从而对图像进行插值的算法。此算法与上述三种传统的线性插值算法进行比较, 可以进一步提高插值后的图像的主观质量效果。

Battiato 等^[5]提出了一种局部自适应的数字图像缩放算法, 该算法试图在加倍输入图片的同时考虑有关不连续或亮度急剧变化的信息。这是通过对缩放图像进行多次扫描来实现的, 因此可以使用有限的计算资源来实现。该算法适用于单色图像, 但很容易适用于缩放 RGB 彩色图像和 CCD/CMOS 相机传感器获取的 Bayer 数据图像。该方法解决了从给定的数字图像(缩放)生成放大图像的问题, 在双三次插值的质量和效率上都具有竞争力。

Sun 等^[6]提出了另外一种新的图像超分辨率算法, 该算法使用了通用图像先验-梯度轮廓先验知识, 它是定义图像梯度形态特征和图像清晰度特征参数先验。该算法可以运用预先已经从大量自然图像模型中学习了解到的图像梯度轮廓, 能够在从低分辨率图像恢复高分辨率图像时给出图像梯度的约束。基于这个简单但非常有效的先验知识, 该方法进一步提升了图像重建的质量。

1.2.2 基于重建的超分辨率技术

该方法的主要分为两大类别: (1) 多图像超分辨率方法: 该方法指在图像重建的过程中, 输入了多张低分辨率图像, 从多张低分辨率图像中提取细节信息;

(2) 单图像超分辨率方法: 该方法输入一张低分辨率图像。

在自然图像中, 多张近似的图像也存在着一些十分紧密的联系。所以 Tsai 等^[7]在图像重建的过程中, 输入了多张低分辨率图像, 从多张低分辨率图像中提取丰富的特征细节信息, 进一步得到了质量更高的超分辨率重建图像。

Irani 等^[8]提出了一种图像配准的方法, 当知道图像序列中的相对位移, 并且对成像过程有一定的了解时, 可以提高图像分辨率。该方法类似于层析成像中使用的反投影, 给出了从图像序列计算未知图像位移时, 提高灰度图像和彩色图像分辨率的例子。

1.2.3 基于学习的超分辨率技术

该方法是指通过利用训练集图像来学习一个网络模型, 最后把 LR 图像输入到该模型, 得到超分辨率图像(Super-Resolution, SR), 从而实现 SR 图像的重建。

Dong 等^[9]所提出的 SRCNN, 成为了使用 CNN 技术进行重建超分辨率图像工作的先驱, 也在之后图像超分辨率重建这一方面的研究中产生了深远的影响。在模型将低分辨率图像通过双三次插值算法后, 再进行卷积操作, 仅使用了 3 个卷积层, 获得了不错的性能。随后, 受到 SRCNN 的启发, Dong 等^[10]提出了 FSRCNN 网络。

2015 年, ResNet^[11]打开了使用深度残差网络重建超分辨率图像工作的先河, 对之后图像超分辨率重建研究工作产生了深远的影响。模型的规模会影响到图像超分辨率的性能, 规模越大, 性能往往会越好。但是深度不能无限增加, 会带来梯度消失或爆炸的问题, 为了解决这一问题, 可以采用 ResNet 中的残差连接, 使特征信息更加完整, 减少丢失。

受到残差学习的影响, VDSR^[12]第一次采用残差学习的方式加深了神经网络的层数, 同 SRCNN 的做法一样, VDSR 也将输入的低分辨率图像首先通过双三次插值算法放大。VDSR 的主要贡献如下: (1) 采用残差学习, 加深了网络模型, 使得网络模型的参数量和计算量增加, 单图像超分辨率性能会得到了一定的提升; (2) VDSR 采用了不同于传统的卷积层-带 padding 的卷积层, 解决了图像在连续的卷积操作会变得越来越小的问题。

2016 年, Shi 等^[13]第一次提出了亚像素卷积操作, 同时提出了 ESPCN 模型, ESPCN 在 LR 空间进行特征的提取, 并引入了亚像素卷积层用于学习一组放大滤波器, 用这些针对特征图训练得到的更复杂的滤波器代替手工双三次滤波器。可以降低计算成本, 实现实时超分辨率重建, 有利于图像保持更多的细节信息, 同时可以使训练得更快并且得到质量更高的超分辨率重建图像。

同年, Kim 等^[14]提出了一种深度递归超分辨率网络模型 DRCN, 这是第一次将递归神经网络应用到超分辨重建技术中, 递归神经网络可以在保持参数量不变的情况下, 加深神经网络模型的深度, 进一步提升了重建图像的质量。随后, DRRN^[15]受到 DRCN 的启发, 进一步加深了神经网络的深度, 采用递归技术将网络深度达到了 54 层, 超越了 DRCN 的性能。

2017 年, Who 等^[16]提出了 LapSRN 网络模型, Who 等认为在图像超分辨率重建任务中, 由于多张图像进行降质退化过程后的结果可以得到相同的一张图像。所以仅仅使用 L_2 损失函数, 会导致约束性比较低, 得到的结果不好。同时利用线性插值方法将输入图片转为指定尺寸, 这一步骤增加了人为噪声。针对以上不足, LapSRN 主要有两点创新: (1) 采用了金字塔结构, 将网络分为两个分支: 一个分支提取特征信息, 另外一条分支用于图像的重构; (2) 提出了一种新的损失函数, 该网络的重构分支一共进行了 3 次上采样, 每次的上采样都有一个损失, 从而将这 3 个损失都减少到最小, 那么图像丢失的信息也就越少, 图像质量就越好。

由于上述的一些图像超分辨率重建方法中,大多数采用了 L_1 和 L_2 损失函数,产生的结果图像往往不符合我们人类的视觉系统,所以出现了基于 GAN 的方法,例如 SRGAN^[17]采用了感知损失,从而使得超分辨率重建图片更加真实,更接近人的视觉。

同年, Lim 等^[18]在 SRResNet^[17]的基础上,提出了一种新的超分辨率网络(EDSR),其图像超分辨率重建性能表现超越了很多先进的图像超分辨率重建方法。不同于 SRResNet 网络结构,EDSR 去掉了规范化处理(batch normalization, BN)操作,从而减少了内存资源。因此,在不增加计算资源的情况下,EDSR 可以添加更多的卷积层,从而扩大了感受野的范围。但是在增加特征图数量的同时,会导致网络模型训练过程中不稳定,作者使用了残差规模来解决该问题。受到稠密连接的启发, Tong 等^[19]提出了 SRDenseNet 网络模型,该网络第一次将稠密连接引入到了图像超分辨重建任务,可以在控制参数量的同时,增强特征的传播,提高特征复用,取得了不错的性能。

2018 年, Zhang 等^[20]提出了 RCAN 网络结构, RCAN 认为在网络的特征图中,各个通道上的特征图所捕捉到的高频特征信息也是会有所不同的,也就是由于有上述的特点,所以在超分辨重建任务中,不同的特征图对高频特征的恢复的贡献也是会不太相同的,因此可以利用通道注意力机制来对网络特征图中的各个通道分别给出一个不同程度的权重,来进一步提高网络通道权重间存在的相对差异性,这样就能够大大增强网络特征的定量表征的能力;受到 ResNet 中残差学习的启发, RCAN 网络模型同时使用了全局残差和局部残差学习,全局残差用于学习低分辨率图像到高分辨率图像的残差图,而局部残差是为了降低网络模型训练的难度。

之后,也有一些研究人员利用特殊的卷积操作来进行图像超分辨率的重建。例如, Xu 等^[21]基于动态卷积提出了 UDVD 网络模型,该模型在前面部分是采用了普通的卷积层和残差结构来提取特征信息,之后采用堆叠的动态卷积提取深层特征信息。该模型不管对于非盲超分辨率还是盲超分辨率问题,效果都得到了进一步的提升。

为了可以在移动端等终端设备上部署深度学习模型,轻量级深度学习模型的研究工作逐渐成为研究热点,研究人员开始研发轻量级模型设计思路。2020 年, Zhao 等^[22]受到自校准卷积的启发,提出了一种只有 272K 参数量的网络结构 PAN, PAN 网络的主要创新点是像素注意力机制,像素注意力生成 3D 注意力图而不是 1D 注意力矢量或 2D 图。像素注意力策略引入的附加参数很少,但产生了更好的超分辨率重建结果。

同年, Wang 等^[23]提出了 A²F-SR 网络模型,该模型的主要模块是 A²F 模块,该模块主要分为两条支路,一条支路由两个 3×3 的卷积层和两个 ReLU 激活函数构

成, 另外一条支路不仅将输入特征作为输入, 还将其他模块的特征作为输入特征; 将多个特征信息进行整合以后, 又采用了通道注意力机制, 来提取到更为重要的特征信息; 最后将两条路径的输出特征乘以不同的权重系数, 进行整合。该模块利用了多层特征信息, 更加充分利用了中间层丰富的特征信息, 使图像重建结果更优异。Who 等^[24]提出了 LatticeNet 网络, 该网络中设计了有利于轻量级模型设计的 LB 块, 可以根据组合系数有效的组合残差块, 并且通过注意机制学习组合系数, 提高了图像超分辨率的性能, 同时利用了反向特征融合策略整合上下文信息。

Hui 等^[25]提出了一种轻量级 IMDN 网络。它的主要组成部分是: 信息多重蒸馏模块(IMDB), 整体表现为残差结构, 是一种渐进式模块。该模块使用尺寸大小为 3×3 的卷积核来提取特征信息, 每次通过通道分离(Channel Split)提取一部分有用的特征, 然后剩下的特征信息继续使用 3×3 的卷积层逐步来提取特征信息。

Liu 等^[26]受到残差连接思想的思想, 进一步改良了 IMDB 模块, 提出了 RFDN 网络, 该网络的基本组成块是: 残差特征蒸馏模块 RFDB, 该模块同样也是通道分离的思想, 每次分离时, 将单路径分为两条路径进行特征信息的提取, 而 RFDB 设计了一个 SRB 模块, 该模块加入了残差连接以及 ReLU 激活函数, 不仅可以有效的利用恒等连接的优点, 又增加了网络模型的非线性。

陈一鸣等^[27]提出了一个基于自适用级联的注意力网络 ACAN, 该网络中的局部像素级注意力模块, 在局部图像像素级上可以定位到高频特征信息比较丰富集中的目标区域, 能够快速比较全面有效地利用特征信息。在上采样层模块中可以根据各种不同的层次特征而采用的不同尺寸大小的卷积核, 可以实现有一定尺度选择性地利用网络模型中生成的各种特征信息, 也就可以实现通过自动选择适应参数, 自动适应选择各种层次特征信息的最佳结合的方法, 以达到提高网络超分辨率模型的重建效率。随后, 李金新等^[28]提出了 MHFN 网络模型, 该网络 MHFN 设计了一个多路重建单元, 以较少的参数量和计算量, 进一步改善了上采样模块。

1.3 主要研究内容

近年来, 随着深度学习技术的迅速发展, 许多先进方法通过加深或者加宽网络模型, 虽然改进了单图像超分辨率的性能, 但是同时也增加了参数量和计算量, 并且训练网络模型往往需要更长的训练时间以及更强的计算能力, 导致在资源受限的移动设备上使用受到限制。本文提出了一种新的轻量级多路跨尺度信息融合的超分辨率网络, 在保持参数量和性能之间取得较好平衡的同时, 提升了图像超分辨率重建的质量。本文的研究内容如下:

- (1) 本文提出了多路特征渐进融合块(FPF), 使用多种尺寸不同的卷积核来提

取多路径不同深度的特征信息, FPF 充分利用浅层特征信息和深层特征信息, 为重建高质量图像提供丰富的细节信息。通过对 Wang 等提出的注意力辅助特征块 A^2F 进行分析, A^2F 通过浅层特征(辅助特征)去帮助当前层特征的学习, 是有效的。不同于 A^2F 的是, 我们将浅层特征通过 1×1 的卷积和 Sigmoid 函数去多路渐进地引导深层特征的提取, 实验也证明了这种用法是有效的。

(2) 本文提出了多路特征注意力机制(FAM), FAM 与 FPF 配对使用, 加权拼接多路通道特征, 可以增强特征表达能力。采用通道级联直接连接不同层次的特征, 忽略了自适应学习对模型的贡献, 加权层间连接虽然会阻碍有效的反向传播, 但这种自适应学习的方法与人脑神经元的行为方式相似。基于该思想, 我们设计了 FAM 模块, 可以最优地对特征通道进行加权, 并进行通道拼接, 从而可以关注到更丰富的特征信息。

(3) 本文提出了一个基于多路跨尺度信息融合的轻量级单图像超分辨率模型, 该模型以较少的参数量和计算量, 改进了网络模型的性能。与同参数量甚至于更大的参数量网络模型比较, 性能指标值都高于这些方法。

1.4 论文的内容结构安排

本文主要内容如下:

第一章, 绪论。在本章节内容中, 第一小节阐述了图像超分辨率技术的发展背景及研究意义; 第二小节介绍了国内外研究现状中涉及的三大类图像超分辨率技术; 第三小节着重阐述了本文所提出的轻量级方法的主要内容; 最后, 是本论文各个章节的内容结构安排。

第二章, 相关方法综述。在介绍本部分章节内容过程中, 第一小节中主要内容详细地介绍了卷积神经网络方面的相关内容; 第二小节重点是详细地介绍了单图像超分辨率算法; 第三小节则重点地阐述分析注意力机制。

第三章, 基于多路跨尺度信息融合的轻量级单图像超分辨率研究。本章节主要提出了本文的方法, 即一种多路跨尺度信息融合的轻量级图像超分辨率研究算法。该网络采用了一种多路径学习的方式, 在减少参数量的同时, 可以提取不同支路的特征信息, 为单图像超分辨率创建提供了更丰富的特征信息。

第四章, 实验与分析。在引言部分介绍了本章的主体安排, 在第二小节着重系统地讲述了网络模型所需用到的数据集。在第三小节部分重点利用多组对比实验, 来验证该模型中模块的有效性。最后, 与当前主流的轻量级单图像超分辨率方法做了对比, 通过大量的图表, 得出无论在主观视觉还是客观指标, 都表明了本文方法的有效性。

第五章, 结论与展望。本章节主要对所提出的轻量级算法思想进行做了归纳

总结，同时也分析了目前该算法方案的主要优缺点，为以后开展的图像超分辨率算法研究开发工作也指明出了一个具体可行的技术科研方向。

第 2 章 相关方法综述

2.1 卷积神经网络

神经网络的构成要素是：一组神经元，在这些神经元中存在着权重和偏差。在整个网络模型训练中，会不断调整这些参数，直到得到一个优秀的结果。实际上，这个过程也相当于，我们人类的大脑收到了一个信息，通过一系列的分析，得到分析的结果。当神经网络模型的层次更多时，那么分析处理的过程也会变得复杂，那么结果也会相应地变得更优。

卷积神经网络之所以能主导图像超分辨率重建技术，是因为存在两种最重要的特性：稀疏连接和权重共享。稀疏连接不同全连接，全连接是该层的每一个结点与其上一层的全部结点相连接，而稀疏连接的稀疏性在于并不是所有的结点之间都是全部连接，有助于提升在计算和内存资源受限的设备上训练网络模型的速度。权重通常理解为卷积核上的数值，采用共享的方法，同样也可以减少在网络模型训练过程中产生的权重参数量。

卷积神经网络基于上述特性，成为了深入机器学习研究的一种代表算法，具有表征学习能力，也就可以直接在输入的信号序列中直接获得一些高阶特性。详细地说，卷积神经网络模型中的卷积层与池化层既可以识别响应空间输入特性的空间平移不变性，也同样可以用来识别响应在同一空间 and 不同时间地点时的空间相近特性。一个成熟的卷积神经网络模型中，传输图像至全连接层的特征图会包括所有与机器学习的目标图像一致的图像特征，如图像分类中的所有类型图像的完整图像。

卷积神经网络一般是由五部分构成：输入层、隐含层、输出层、损失函数(Loss Function)和激活函数(Activation Function)。

(1) 输入层：卷积神经网络被通常认为是用于图像处理中的另一种人工智能算法，其输入图像一般由很多个像素点构成，图像中的数值代表输入图像的亮度，其中，0 是黑色，255 是白色。这样，一幅二维图像在一台计算机中的显示即可被简化为由若干个数字所构成的多维矩阵。

(2) 卷积层：由一组滤波器(filter)组成。我们通常把输入特征图当成数字矩阵，卷积核也视为数字矩阵，在卷积计算中，卷积核会先从输入特征图像信息的左上出发，完成一个由从左至从右，自上而下的连续扫描，在整个扫描的过程中，做一些乘法运算与一些相加的运算，以此方式来快速获得输入特征图像中的一些典型特征信息。在深度学习神经网络模型中，通常称为浅层卷积层提取出来的特

征信息为低频信息，即图像中的曲线等；深层卷积层提取到的特征信息是更加复杂的一些特征信息。当我们在使用卷积层的过程中，不进行填充，那么经过多次卷积操作，我们的图像会变得越来越小。但是用带有padding的方式去做卷积，对图像进行补0操作，恢复到原来的尺寸大小，这就使得中间的网络模型层的可变空间非常的大，模型使用非常的自由。 1×1 卷积、组卷积等这些特殊的卷积也在网络架构中得到了广泛的使用。

① 1×1 的卷积核可以很灵活方便的来调节特征图像的深度， 1×1 的卷积核因为尺寸大小也只是 1×1 ，所以也不必去考虑像素大小和图像周边的像素之间的线性关联，其功能主要是用来自动调整网络模型中的通道数量，对于在不同通道上对应的像素点可以进行线性的组合，再添加上激活函数，从而可以实现图像非线性化的运算，即可轻松实现图像升维和图像降维的功能。

②组卷积：当网络模型的规模增加时，性能会得到进一步的提升，但是由于设备的计算资源是有限的，这时可以采用分组卷积训练，最后再对特征图进行整合。通常我们将分组数设置为几，那么最终网络模型训练过程中参数量也会减少到几分之一。这种操作方式，不仅可以减少参数量，还可以帮助我们减少模型训练的时间，同时还可以使我们更加增大网络模型的深度，可以提取到更加丰富多样的特征信息，有助于我们从输入图像中得到更加有用的特征信息，帮助计算机视觉图像任务的进一步研究。

(3) 池化层：减少维数，参数量和计算量。这样就减少了网络模型的训练时间，并且防止训练过程中的过度拟合。池化的过程其实就是一种特殊的卷积操作，只不过没有涉及到对应元素的乘法操作。在最大池化过程中，我们取得的值是最大的像素值，从几个像素点中直接取一个值；而在平均池化中，得到的像素值是几个像素点的平均值。从两种方法可以看出，后者基本考虑到了所有的像素值的影响，而前者和最邻近插值原理相似，只不过取最大值。在池化过程中，由于只是对图像的尺寸进行了缩小，并不会对特征图中的主要信息造成影响，有一个不错的抗杂讯功能；而且在降维的过程中，也会把一些无用的特征信息筛选出去，防止这些信息让我们对图像进行错误的分析。

(4) 全连接层：它不同于卷积层，可以总结为两个方面：①形状方面：它的每一个叶结点与上一层中的每个结点都是彼此之间连通的；②功能方面：卷积层主要负责的是对输入图像进行特征信息提取的工作，而全连接层只是进行非线性整合，会把多维的特征图变为一维向量，会经常被用在图像分类任务当中，在图像超分辨率算法中应用的较小一些。而全连接层模型本身似乎也没有被期望为具备大规模图像数据的获取学习能力，只是在试图通过使用其现有模型的更高层次特性来实现其学习目标。

(5) 输出层：输出网络模型的结果。在不同的计算机视觉任务中，输出的结果是各不相同的。

(6) 激活函数：卷积的计算实际上也是一个纯线性关系的计算，在自然中有很多函数关系实际上都是非纯线性关系的。激活阈值函数机制是指参考到了生物学意义上的神经元激活的函数机制，在所有生物学意义上激活的神经元序列中，只有当前面激活的神经元树突所传递出的激活信息远远超过激活神经元序列的激活阈值时，下面的某一激活神经元序列才会真正被激活。




图 2-1 激活函数图像

① Sigmoid函数是常用的非线性激活函数，如图 2-1(a)所示，用于隐层神经元输出，取值范围为[0,1]，该函数用公式表示为：

$$f(x) = \frac{1}{1 + e^{-x}} \tag{2-1}$$

优点：Sigmoid函数求导相对比较简单，能够直观推理得到；同时由于其独特的取值范围，可以对一张图像中物体的进行分类，而且当特征相差比较复杂时或特征差异也没有特别的大变化时效果也相当好。缺点：反向传播时，Sigmoid导数的值始终小于1且一直在0周围变化，在深层的神经网络中极易造成梯度消失的问题，从而无法完成深层网络的训练。

② Tanh函数，将实数值压缩到[-1,1]之间。优点：收敛速度更快。缺点：并不能完全克服Sigmoid梯度消失的问题，该函数用公式表示为：

$$f(x) = \tanh\left(\frac{e^x - e^{-x}}{e^x + e^{-x}}\right) \quad (2-2)$$

③ReLU函数是一个分段函数，值域为 $[0, +\infty]$ 。该函数的优点：能加速反向传播时随机梯度的下降；该函数只有一种简单的判断和运算，不要求占用太多的内存资源。但是也存在缺点：由于该函数的最小值为零，所以在网络模型训练的过程中，容易出现梯度为零的情况，那么之后，无论经过多少层卷积层或者激活函数，它的值会一直都是零，就会使该神经元死亡，该函数用公式表示为：

$$f(x) = \max(0, x) \quad (2-3)$$

④PReLU 函数如图 2-1(d)所示，在 PReLU 中，小于零部分的斜率是根据数据自适应变化的，这样就基本上不会出现梯度为零的情况，解决了 ReLU 函数中出现的问题。除此之外，当该函数的斜率为 0.01 的时候，我们将该函数重新定义为 Leaky ReLU 激活函数，该函数用公式表示为：

$$f(x) = \max(\alpha x, x) \quad (2-4)$$

(7) 梯度下降法：损失函数越小，说明两张图像之间的差距最小，所以在模型训练的过程中，会使其最小化。那么梯度下降算法就是为了将损失函数降至最小而存在的。在使损失函数最小化的过程中，我们希望时间越快越好，也就可以使网络模型训练的时间越短。就比如我们为了找到最短最快的下山方法，希望每一步走的地方都是朝向最低点的方向。所以，会涉及到函数的求导过程，来实现目标函数的快速下降。

$$\theta := \theta - \eta \frac{\partial J(\theta)}{\partial \theta} \quad (2-5)$$

该公式就是关于参数 θ 的损失函数，其中， η 就是学习率。由上述公式可知，梯度下降的想法是使得参数 θ 向着负梯度方向做更新迭代。在网络模型的训练过程中，若是采用太大的学习率，就会出现损失函数无限大的情况；若是采用太小的学习率，就会导致模型训练的十分缓慢，很难收敛；所以需要我们设置一个合理的数值。

当在一个凸优化的问题上，例如开口向上的二次函数，都能找到它的全局最小值点，而且还是唯一的。但是在图像超分辨率重建的任务中，所采用神经网络模型都是一个复杂的非凸优化。所以就不会像开口向上的二次函数一样，它会存在着很多个鞍点，所以不一定在网络模型训练的过程中会找到这个函数的最小值。所以，我们希望一种优秀的梯度下降算法至少要同时符合以下两方面：一是收敛的速率一定要足够快；而是要得到的最优值一定不能是局部的。一般常用的几种

梯度下降算法如下:

①批量梯度下降法: 该算法从“批量”两个字, 可以得出该方法的优点, 顾名思义考虑到了整个数据集对网络模型训练的结果; 同时, 带来的缺点也是显而易见地, 因为采用了整个数据集, 如果数据集特别大, 就会在网络训练的过程中, 占用更多的存储资源。

②随机梯度下降法: 该算法中的“随机”指的是随机抽取一个样本, 来计算梯度值, 通过不断对随机样本进行计算, 从而来对参数进行参数, 直到得到最优值再停止, 该方法与①方法进行比较, 该方法明显会增加网络模型的训练速度。但是由于随机选取样本, 样本数据集得到的结果并不一定是最优的。

③小批量梯度下降: 方法②的收敛速度快, 但是波动较大, 在最优解处出现波动很难判断其是否收敛到一个合理的值。而批梯度下降稳定但是时空开销很大, 针对于这种情况, 引入小批量梯度下降对二者进行折中, 结合两者的优点, 在每轮迭代过程中使用 n 个样本来训练参数。

④动量梯度下降: 采用的是指数加权平均策略, 使用之前梯度信息修正当前梯度, 来加速参数学习。优点: 通过对过去梯度信息来优化下降速度, 如果当前梯度与之前梯度方向一致时候, 收敛速度得到加强, 反之则减弱。缺点: 可能在下坡过程中累计动量太大, 冲过极小值点。

⑤Nesterov 加速梯度法: 该方法是通过使用未来梯度来进行动量的更新。优点: 相对于动量梯度下降法, 因为 NAG 考虑到了未来预测梯度, 收敛速度更快; 当更新幅度很大时, NAG 可以抑制震荡。

⑥自适应梯度(AdaGrad/Adaptive Gradient): AdaGrad 在训练过程中动态调整学习率, 对不同参数根据累计梯度平方和更新不同学习率。梯度一直变化较大的参数, 学习率下降也较快, 即高频特征使用较小学习率; 梯度一直变化较小的参数, 学习率下降也较慢, 即低频特征使用较大学习率。因为累加性, 学习率的趋势是不断衰减的, 这也符合迭代后期靠近极值点时需设置较小的学习率的直观想法。该方法的缺点: 由于学习率的不断衰减, 在迭代过程早期衰减过快可能直接导致后期收敛动力不足, 使得 AdaGrad 无法获得满意的结果。

(8) 反向传播算法: 该算法的理论构建于梯度下降学习法理论的理论基础之上, 对于卷积神经网络模型的训练也是至关重要的一部分。反向传播的算法过程主要是通过两个循环过程(激励传播、权重更新)的不断循环和迭代, 直至反馈网络中的输出对输入信息的正向反馈超过了预期的反馈目标范围为止。

2.2 经典的单图像超分辨率算法

2.2.1 SRCNN 方法

Dong 等^[9]所提出的 SRCNN，成为了使用卷积神经网络进行重建超分辨率图像工作的先驱，也在之后图像超分辨率重建这一方面的研究中产生了深远的影响。该网络将低分辨率图像通过双三次插值算法后，再进行卷积操作，仅使用了 3 个卷积层，获得了不错的性能。网络结构如图 2-2 所示。




图 2-2 SRCNN 网络结构

SRCNN 首先将低分辨率图像的尺寸大小通过双三次插值技术放大调整到重建后的超分辨率图像的尺寸大小，然后再利用只有 3 个卷积层的网络模型来拟合非线性映射的过程，最后再输出超分辨率图像。在该文章中，作者把 3 层卷积的构造过程分解为 3 种过程：（1）图像块的特征提取过程与特征表示；（2）非映射过程；（3）最终的重构。

2.2.2 FSRCNN 方法

FSRCNN^[10]是对 SRCNN^[9]网络模型的进一步改良，有以下 3 点：①SRCNN 首先将 LR 图像通过双三次插值放大到重建后的 SR 图像的尺寸大小；输入图像尺寸较大，会使来网络模型训练的过程中占用更多的内存资源，从而也会产生更多的参数量和计算量。FSRCNN 解决了该问题，直接输入 LR 图像，在网络模型的最后，才做了放大处理。②改变了特征的维数，采用了更小的卷积核，可以减少网络模型的参数量。③共享其中的卷积层，通常在训练网络模型时，会需要恢复多种倍数的图像，这时如果去调整网络模型的主体部分，就会让网络模型变得笨重，在该方法中，只需要对反卷积层进行简单的调整。网络结构如图 2-3 所示。




图 2-3 FSRCNN 网络结构

FSRCNN 由五部分构成。①特征提取：SRCNN 首先将低分辨率图像的尺寸大小通过双三次插值技术放大调整到重建后的超分辨率图像的尺寸大小，所以采用 9×9 卷积层，但是该算法采用了 5×5 的卷积层；②收缩层：网络模型中采用了 1×1 的卷积层，从而以较少的参数量实现了降维操作，同时还增加了网络模型的深度，增加了非线性；③非线性映射层：在卷积操作中，感受野的增大，让网络模型可以根据图像中更多的像素点去推测目标像素值，这样考虑到了多个像素点之间的相互联系，可以提高图像超分辨率算法的效率。所以采用了多个 3×3 卷积层，增大了感受野；④扩张层：和收缩层相似，同样采用 1×1 的卷积层来进行卷积操作，只不过是为了增加维度；⑤反卷积层：相当于是卷积层的逆操作，将网络模型产生的特征矩阵转换为超分辨率图像。

2.2.3 VDSR 方法

SRCNN 和 FSRCNN 模型的层数都是非常少。网络模型的深度会影响到图像超分辨率的性能，但是深度不能无限增加，会带来梯度消失或爆炸的问题，为了解决这一问题，可以采用 ResNet^[11]中的残差连接。受到残差学习的影响，VDSR^[12]第一次采用残差学习的方式加深了神经网络的层数，同 SRCNN 的做法一样，VDSR 也将输入的低分辨率图像首先通过双三次插值算法放大。VDSR 的主要贡献如下：①采用残差学习，加深了网络模型，使得网络模型的参数量和计算量增加，单图像超分辨率性能会得到了一定的提升；②VDSR 采用了不同于传统的卷积层-带 padding 的 3×3 卷积核大小都是且步长为 1×1 的卷积层，解决了图像在连续的卷积操作会变得越来越小的问题。网络模型如图 2-4 所示。




图 2-4 VDSR 网络结构

2.3 注意力机制

从注意力模型的命名方法上来看，和人类大脑的注意力机制类似，人类视觉注意力机制大大地提高了人类对视觉信息的处理工作的整体效率水平和准确度。深度机器学习过程中的视觉注意力机理从其本质上来说也与一般人理解的选择性视觉注意力机理极为相似，主要的任务都是要从特别多的信息中选取更重要一些的信息。

2.3.1 通道注意力机制

SENet^[29]第一次将注意力机制引入卷积神经网络，它获得了 ImageNet 2017^[30]竞赛分类任务的第一名。它的创新模块是 SE，该模块由压缩和提取两部分构成：前者通过全局平均池化层获得特征向量，后者通过激活函数来获得每个通道的权重系数。

2018 年，Zhang 等^[20]提出了 RCAN 网络结构，该网络第一次将注意力机制应用到了图像超分辨率重建任务中，RCAN 认为在网络的特征图中，各个通道上的特征图所捕捉到的高频特征信息也是会有所不同的，也就是由于有上述的特点，所以在超分辨/重建任务中，不同的特征图对高频特征的恢复的贡献也是会不太相同的，因此可以利用通道注意力机制来对网络特征图中的各个通道分别给出一个不同程度的权重，来进一步提高网络通道权重间存在的相对差异性，这样就能够大大增强网络特征的定量表征的能力。在 CA 模块中，三维特征图经过平均池化层，得到一维输出；然后通过一个卷积核尺寸大小为 1×1 的下采样层，将通道数量缩小了 r 倍，之后经过一个 ReLU 激活函数，再经过一个卷积核尺寸大小为 1×1 的上采样层，将通道数量扩大 r 倍，再经过一个 Sigmoid 激活函数，此时就会得到每一个特征通道上的权重系数。将这个权重系数再与通道原有的特征进行相乘就可以获得经过缩放处理后得到的通道新的特征。整个缩放流程其实也是在对原来各个通道上的特征信息进行重新计算并且进行优化了的权重分配。

2.3.2 空间注意力机制

Spatial Transformer Networks(STN)^[31]网络结构使用注意力机制，使其具有空间不变性。2018 年，Li 等^[32]提出了 CBAM，在空间注意力机制中，输入特征的尺寸大小为 $H \times W \times C$ ，再依次地通过进行每一个通道维度的平均池化和最大池化来得到对应两个通道 $H \times W \times 1$ 的通道描述，并最后把这两种通道描述都按照通道拼接组合到一起。

2.3.3 混合注意力机制

空间域的注意力相当于利用池化操作，将图像的尺寸大小进行缩小，再提取特征。而通道注意力对网络特征图中的各个通道分别给出一个不同程度的权重，来进一步提高网络通道权重间存在的相对差异性。所以 Li 等^[32]提出了 CBAM，设计出了一个基于混合域的注意力机制模型，该模型不仅仅可以节省参数空间和计算力，而且还确保可以将它作为一个即插即用系统的模型来整合到一个现有的网络结构模型中。

2.4 本章小结

在本章节内容中，主要阐述了卷积神经网络的内容，重点详细阐述了 SRCNN 方法、FSRCNN 方法、VDSR 方法以及与本文方法相关的注意力机制。

第3章 基于多路跨尺度信息融合的轻量级超分辨率算法研究

3.1 引言

单图像超分辨率重建目的在于从给定的一张低分辨率图像得到一张高分辨率图像^[2]。但是在学习从 LR 到 HR 图像的映射的过程中,可以得到无限个 HR 图像^[3]。而且,在自然图像中,它们退化的方式多种多样,我们无法确定单一的形式。

Dong 等^[9]所提出 SRCNN,成为了使用 CNN 技术进行重建超分辨率图像工作的先驱,也在之后图像超分辨率重建这一方面的研究中产生了深远的影响。该网络将低分辨率图像通过双三次插值算法后,再进行卷积操作,仅使用了 3 个卷积层,获得了不错的性能。之后出现了大量基于卷积神经网络的单图像超分辨率方法,主要是改进:加深或加宽网络架构。Kim 等^[12]提出的 VDSR,基于残差技术加深了神经网络,将卷积层扩展为 20 层,进一步提升了网络的性能。Lim 等^[18]在 SRResNet^[17]的基础上,提出了一种新的超分辨率网络(EDSR),其图像超分辨率重建性能表现超越了很多先进的图像超分辨率重建方法。在不增加计算资源的情况下,EDSR 可以添加更多的卷积层,从而扩大了感受野的范围,同时使用了残差规模来解决该问题。RDN^[33]借鉴了残差和稠密两种网络结构的思想,将稠密连接嵌入到残差块中,在参数量比 EDSR 参数量减少一半的情况下,还超越了其性能。RCAN^[20]网络结构利用通道注意力机制来对网络特征图中的各个通道分别给出一个不同程度的权重,来进一步提高网络通道权重间存在的相对差异性,这样大大增强了网络特征的定量表征的能力,参数量为 16MB。Liu 等^[34]提出了一种新的网络结构 RFANet,将各层残差信息经过跳跃连接直接传到后层,基本构件是残差特征聚集框架 RFA,每个 RFA 通过堆积多个残差块,可以更充分地利用残差分支上的分层特征。Qiu 等^[35]提出了一种新的嵌入式块残差网络 EBRN,是一种增量式的纹理超分辨率恢复方法。尽管这些深层网络模型都能取得显著的性能,但它们在内存存储和计算复杂性方面的成本很高,难以在资源受限的移动设备上应用。由此可见,设计轻量级的网络结构是实际应用中所需要的。但是轻量级网络也面临着极大的挑战:在深度卷积神经网络模型复杂度和图像超分辨率性能之间建立更好的平衡。

为了在降低网络模型参数量的情况下,又能使网络模型的深度足够深,递归结构变得十分流行^[36-40]。例如, Kim 等^[14]提出了 DRCN 方法。Tai^[15]等借鉴 VDSR

的调整梯度裁剪和 DRCN 的递归学习，提出了 DRRN 方法，进一步提升了 SISR 的性能。Tai 等^[41]同样使用递归的技术，提出了 MemNet 方法。周等^[42]提出的递归残差网络结构 RRSR 和李文斌^[43]提出的 NRSR 都采用了递归技术在增加网络深度的情况下，不增加参数量，但是却增加了计算量。

除了采用递归技术的方法外，用多路径学习^[44-48]的方式设计轻量级架构也是一种流行的方法。残差连接和稠密连接，可能是单图像超分辨率算法网络架构中最常见的多路径学习。残差连接和稠密连接虽然能够增强特征信息的传播，但是也会造成大量的特征信息冗余。如何改进多路径学习，提高特征信息的利用率和表达能力，持续受到研究人员的重视。

3.2 多路径特征提取块

3.2.1 Inception 模块

网络模型的规模会影响到图像超分辨率的性能，所以在 SRCNN 出现以后，许多研究工作人员都会网络模型加深层数和宽度，从而提升图像超分辨率的性能，但是也会使得网络模型占用的资源增多，计算量增多，参数量增多，计算速度变低。2014 年，Google 公司受到了网络中的网络(Network in Network)和稀疏网络的启发，提出了一个深度卷积神经网络-GoogLeNet 网络来解决这些问题，该网络模型赢得了 ILSVRC2014 的第一名。GoogLeNet 网络有时又称为 Inception-v1 网络，即 GoogLeNet 网络中使用的是 Inception-v1 模块。Inception 模块设计的一个核心思想是要把不同的卷积层采用并联的方法组合到了一起，把先前的特征信息通过这些不同的卷积层，然后将卷积后的结果，在深度维度上拼接成一个新的特征矩阵，这个特征矩阵的深度会更深。该模块结构如图 3-1 所示。




图 3-1 Inception 结构

该结构共采用了 4 种不同的卷积层。将输入特征信息分别经过了不同的卷积核，

最后再进行通道上的拼接。

3.2.2 多路径信息融合块

Li^[49]等提出的 MSRN 方法也是采用了多路径的学习方式，它的主要创新点是多尺度特征提取模块 MSRB，MSRB 主要分为两条支路，一条支路由两个 3×3 的卷积层和两个 ReLU 激活函数构成，另外一条支路由两个 5×5 的卷积层和两个 ReLU 激活函数构成，同时在两条支路对特征信息进行提取的过程中，将中间产生的特征信息进行了通道拼接。由于 MSRB 模块采用了两种不同尺寸的卷积核，因此它能够用于从不同的尺度图像上观察得到图像上的特征信息。文章还认为这是人类首次尝试在残差结构模型上采用多尺度的模型。其结构如图 3-2 所示。




图 3-2 MSRB 模块

IDN^[50]，IMDN^[25]，RFDN^[26]都采用了多路径学习的方式，它们通过采用通道分离的方法，将分离后的通道通过不同的卷积层进行特征提取。IDN 是由信息蒸馏网络实现的快速准确的超分辨率方法，该网络将先前提取的特征明确划分为两部分：一部分通过支路保留原特征信息，另一部分通过支路做进一步处理。通过这种方式，IDN 在实现了良好的性能。IDN 的重要创新点是信息蒸馏块(DBlocks)，其结构如图 3-3 所示。




图 3-3 DBlocks 模块

DBlocks 主要由增强单元和压缩单元两部分组成。其中，增强模块由两部分构成：第一部分将输入特征先通过了 3 个 3×3 的卷积层，之后又经过了 LeakyReLU 非线性函数。接着，将输出在通道维度进行切片，其中前 $1/s$ 通道用于和输出拼接 (concat) 在一起，剩下的 $1-1/s$ 通道继续送往下面的 3 个卷积层加 LeakyReLU 非线性激活函数。最后，将两者的输出做元素位相加。压缩单元其实就是 1×1 的卷积层，从而降低通道数起到压缩的效果。

Hui 等^[25]受到 IDN 的启发，提出了一种轻量级 IMDN 网络。它的主要组成部分是：信息多重蒸馏模块(IMDB)，该模块如图 2-8 所示。模块整体表现为残差结构，是一种渐进式模块。该模块使用尺寸大小为 3×3 的卷积核来提取特征信息，每次通过通道分离(Channel Split)提取一部分有用的特征，然后剩下的特征信息继续使用 3×3 的卷积层逐步来提取特征信息。进行三次重复的操作，将 4 条路径提取到的特征进行通道拼接，最后利用通道注意力来筛选出重要的特征信息，然后用 1×1 的卷积层进行压缩，最后在进行残差连接，该方法进一步提高了重建图像质量。其结构如图 3-4 所示。




图 3-4 IMDN 模块

Liu 等^[26]受到残差连接思想的思想，进一步改良了 IMDN 模块，提出了 RFDN 网络，RFDN 同样采用通道分裂操作来提取特征信息，提升了重建图像性能，获得了 AIM 2020 高效 SR 挑战赛的冠军。该网络的基本组成块是：残差特征蒸馏模块 RFDB，该模块同样也是通道分离的思想，从网络结构可以看出，每次分离时，将单路径分为两条路径进行特征信息的提取。结构如图 3-5 所示。




图 3-5 RFDB 模块

RFDB 有 3 点不同于 IMDB 模块：①在通道分离后，IMDB 直接保留一部分特征信息，而 RFDB 又采用了 1×1 的卷积层通过卷积操作降维；②IMDB 直接采用 3×3 卷积层进一步提取特征，而 RFDB 设计了一个 SRB 模块，该模块加入了残差连接以及 ReLU 激活函数，不仅可以有效的利用恒等连接的优点，又增加了网络模型的非线性；③在该模块进行完通道拼接以后，IMDB 直接利用通道注意力机制，而 RFDB 先用 1×1 的卷积层通过卷积操作降维，在采用通道注意力机制，进一步降低了网络模型的参数量。

Zhao 等^[22]受到自校准卷积的启发，提出了一种只有 272K 参数量的网络结构 PAN，PAN 网络的主要创新点是在多路径结构中引入了像素注意力机制，像素注意力生成 3D 注意力图而不是 1D 注意力矢量或 2D 图。像素注意力策略引入的附加参数很少，但产生了更好的超分辨率重建结果。结构如图 3-6 所示。




图 3-6 SC-PA 网络结构

它将输入特征通过两条不同的支路进行特征提取，一条支路使用像素注意力 (PA) 来提取更重要的特征信息，另外一条支路使用简单堆叠的卷积层来对特征进行提取，最后将两条支路的输出特征进行通道级联，由于其双分支架构和注意力方案，该模块比常规的残差/密集块效率更高。最终模型 PAN 可以达到与轻量级网络

SRResNet 相似的性能，但是参数只有 272K。

Huang^[51]等提出了 DPAN，DPAN 也采用了多路径学习的方式，DPAN 的重要组成部分有双路径块(DPB)。在 DPB 中，双路径还共享卷积层的权重，以减少参数的数量和计算复杂性，这意味着稠密信息和残差信息由相同的卷积层处理。结构如图 3-7 所示。




图 3-7 DPB 模块

Wang 等^[23]提出了 A²F 方法，A²F 同样采用了多路径学习的方式，该方法中的每个注意力辅助特征学习模块拥有两条支路，一条支路接收之前所有模块的输出，通过通道压缩后进入通道注意力模块，消除冗余的特征信息，另一支路仅对上一层的输出进行残差学习。该工作研究表明：前面层的特征(即辅助特征)有助于当前层特征的学习。结构如图 3-8 所示。




图 3-8 A²F 模块

3.3 算法总体框架

深层网络模型能取得显著的性能，但它们在内存存储和计算复杂性方面的成本很高，难以在资源受限的移动设备上应用。为了能减少参数数量的同时又减小计算量，采用多路径学习的方法，是设计轻量级单图像超分辨率网络模型的一种有效的方式。Zhao 等^[52]的研究表明：加权的通道拼接，更符合人脑神经元的行为，可以提高特征的表达能力。主要受 Zhao 等^[22]、Wang 等^[23]和 Zhao 等^[52]的工作启发，我们提出了一个基于多路跨尺度信息融合的轻量级 SISR 网络 MPFN。MPFN 网络主干的核心构件是多路特征提取块(Multi-Path Feature Extraction, MPFE)，MPFE 包括两个子块：多路特征渐进融合块(Multi-Path Feature Progressive Fusion, FPF)和多

路特征注意力机制(Multi-Path Feature Attention Mechanism, FAM)。FPF 的每条支路使用不同的卷积核和不同数目的卷积层, 来提取不同支路的特征信息, 同时可以通过前面的特征, 多路渐进地引导后面多路径特征的学习。FAM 则通过通道注意力, 加权各路特征通道后, 进行拼接。我们的MPFN的参数量大约是PAN的2倍, 计算量大约比 PAN 高出 60%, 但是, MPFN 显著改进了 PAN 的性能, 无论是主观度量, 还是客观度量, 也优于当前其它类似的轻量级方法, 把模型复杂度和性能之间的平衡提升到了一个新的水平。MPFN 网络结构如图 3-9(a)所示, 该网络架构主要包括四个部分: 一个 3×3 的卷积层、一个深层特征提取块(Deep Feature Extraction Block, DFEB)、一个分层特征融合注意力块(Hierarchical Feature Fusion Attention Block, HFFAB)和一个上采样块(Upsampler)。其中, 3×3 的卷积层主要用于提取浅层特征, DFEB 包括 3 个特征提取组(Feature Extraction Group, FEG), FEG 的结构如图 3-9(b)所示, 每个 FEG 包含 6 个多路特征提取块(MPFE), MPFE 的结构如图 3-10 所示, 每个 MPFE 包括一个多路特征渐进融合块(FPF)和一个多路特征注意力机制(FAM)。HFFAB 主要使用了 TSAN^[53]中的多上下文注意力块(Multi-context Attentive Block, MCAB)。HFFAB 在本文中为了减小计算量, 对输入到 MCAB 块的特征通道, 用 1×1 的卷积进行了 4 倍的压缩和融合, 对 MCAB 块的输出特征通道, 用 1×1 的卷积进行了 4 倍的扩张。HFFAB 的结构如图 3-11 所示。Upsampler 使用了 PAN^[22]的上采样块, Upsampler 的结构如图 3-12 所示。MPFN 架构也包含一个全局残差连接, LR 图像通过双三次插值, 放大到目标 SR 图像的大小。

3.3.1 MPFN 网络结构




图 3-9 MPFN 结构图

首先, 假设 I_{LR} 是低分辨率输入图像, I_{SR} 是输出图像。 I_{LR} 先经过了一个 3×3 的卷积层, 我们将提取到的特征信息称为 F_0 :

$$F_0 = \text{Conv}_{3 \times 3}(I_{LR}) \quad (3-1)$$

其中, $\text{Conv}_{3 \times 3}(\cdot)$ 是 3×3 的卷积层, F_0 是输出特征信息。 F_0 再输入到 DFEB, 进行特征提取。 DFEB 包含 3 个 FEG, 每个 FEG 又包含 6 个 MPFE。 所以, F_0 共经过 18 个 MPFE, 每个 MPFE 的输出可以表示为:

$$F_n = H_n(F_{n-1}), n = 1, 2, \dots, 18 \quad (3-2)$$

其中, $H_n(\cdot)$ 是第 n 个 MPFE 函数, F_n 是其输出特征信息。 将 3 个 FEG 模块的输出标记为: F_6 、 F_{12} 和 F_{18} , 之后将 3 张特征图进行拼接后再压缩融合:

$$F_{M0} = \text{Conv}_{1 \times 1}([F_6, F_{12}, F_{18}]) \quad (3-3)$$

其中, $\text{Conv}_{1 \times 1}(\cdot)$ 是 1×1 的卷积层, $[\cdot]$ 是特征通道拼接, F_{M0} 是拼接压缩融合后的特征, 也是 DFEB 块的输出特征, 再输入到 HFFAB:

$$F_M = H_{\text{HFFAB}}(F_{M0}) \quad (3-4)$$

其中, $H_{\text{HFFAB}}(\cdot)$ 是 HFFAB 函数, F_M 是该函数的输出特征。 F_M 输入 Upsampler:

$$I_{SR} = H_{\text{Up}}(F_M) + H_{\text{Bic}}(I_{LR}) \quad (3-5)$$

其中, $H_{\text{Up}}(\cdot)$ 是上采样块 Upsampler 函数, $H_{\text{Bic}}(\cdot)$ 是传统的双三次插值函数, 叠加到残差 $H_{\text{Up}}(\cdot)$ 的输出, 得到最终输出的目标 SR 图像 I_{SR} 。 当前单图像超分辨率方法的上采样块, 大多数都采用亚像素的卷积或转置的卷积, 与之不同的是, 我们使用了 PAN 的上采样块。

3.3.2 多路特征提取块(MPFE)

多路特征提取块(MPFE)的结构图如图 3-10 所示, 主要由多路特征渐进融合块(FPF)和多路特征注意力机制(FAM)组成。 多路特征渐进融合块(FPF)进行多路(本文使用 3 路)渐进地对特征提取和融合, 并用前面的特征引导和校准后面的特征学习; 多路特征注意力机制(FAM) 使用通道注意机制来优化 FPF 每个分支的特征通道权重, 然后将 3 个分支的特征拼接起来; 之后采用一个 1×1 的卷积层进行通道压缩和融合; MPFE 也包含一个残差连接, 可以更好地传递和融合特征信息。




图 3-10 MPFE 结构图

3.3.3 多路特征渐进融合块 (FPF)

多路特征渐进融合块(FPF)，主要是受 Zhao 等^[22]和 Wang 等^[23]工作的激发，进行多路(本文使用 3 路)渐进特征提取和融合，并用前面的特征引导和校准后面的特征学习。与 Wang 等^[23]工作不同的是，我们使用当前块中前一层特征来指导和校准当前层特征的学习，而不是将所有前面基本组成块的特征进行投影来计算通道注意力。如图 3-10 所示，我们的 FPF 包含三条支路，第一条支路只包含一个 1×1 的卷积层，我们将提取到的特征称为浅层特征；第二条支路包含了一个 1×1 的卷积层和一个 3×3 的卷积层，两个卷积层之间包含一个 LReLU 非线性激活函数，我们将提取到的特征称为较深层特征，第一条支路提取的浅层特征通过 1×1 卷积和 Sigmoid 函数，引导和校准该支路的特征；第三条支路由一个 1×1 的卷积层和两个 3×3 的卷积层组成，每两个卷积层之间包含一个 LReLU 非线性激活函数，我们将提取到的特征称为深层特征。第二条支路提取的特征再通过 1×1 卷积和 Sigmoid 函数引导和校准该支路特征。考虑到 F_{n-1} 和 F_n 分别是第 n 个 MPFE 的输入和输出，参见公式(3-2)。三条支路校准前的特征输出分别为(忽略了 LReLU 非线性激活函数)：

$$X_1 = \text{Conv}_{1 \times 1}(F_{n-1}) \quad (3-6)$$

$$X_2 = \text{Conv}_{3 \times 3}(\text{Conv}_{1 \times 1}(F_{n-1})) \quad (3-7)$$

$$X_3 = \text{Conv}_{3 \times 3}(\text{Conv}_{3 \times 3}(\text{Conv}_{1 \times 1}(F_{n-1}))) \quad (3-8)$$

其中， $\text{Conv}_{1 \times 1}(\cdot)$ 是 1×1 的卷积， $\text{Conv}_{3 \times 3}(\cdot)$ 表示 3×3 的卷积，三条支路校准后的特

征输出分别为:

$$X'_1 = X_1 \quad (3-9)$$

$$X'_2 = X_2 \odot (\sigma(\text{Conv}_{1 \times 1}(X_1))) \quad (3-10)$$

$$X'_3 = X_3 \odot (\sigma(\text{Conv}_{1 \times 1}(X_2))) \quad (3-11)$$

其中, $\sigma(\cdot)$ 指的是 Sigmoid 函数, $\odot$ 指的是两张特征图中对应元素相乘。然后, 三条支路校准后的输出特征通道进行拼接, 并用 1×1 的卷积进行通道压缩和融合:

$$X' = \text{Conv}_{1 \times 1}([X'_1, X'_2, X'_3]) \quad (3-12)$$

其中, $\text{Conv}_{1 \times 1}(\cdot)$ 是 1×1 的卷积层, $[\cdot]$ 是特征通道拼接, X' 是多路特征渐进融合块(FPF)的输出特征。

3.3.4 多路特征注意力机制(FAM)

在图像超分辨率重建中, 图像的浅层纹理信息和深层语义信息都应该值得我们更感兴趣。我们提出的多路特征注意力机制(FAM), 如图 3-10 所示, 主要受 Wang 等^[23]工作的启发, Wang 等^[23]工作表明特征通道的加权拼接可以提高特征的表达能力。与 Wang 等^[23]工作不同的是, FAM 没有使用标量权重, 而是使用通道注意机制来优化 FPF 每个分支的特征通道权重, 然后将它们拼接起来。FAM 包含三条支路, 每条支路与多路渐进融合模块(FPF)的三条支路进行注意力融合, 这样我们的注意机制既关注了浅层的纹理信息, 又关注了深层的语义信息, 同时对不同层次的特征信息进行了更进一步的融合, 能更快更准确地关注到对恢复高分辨率图像有用的特征信息, 有助于恢复出质量更高的超分辨率图像。我们采用多路注意力机制, 可以实现最优加权特征通道, 并进行通道拼接后再采用 1×1 的卷积压缩。第 n 个 FPF 块的输出特征为 X' , 经过一个全局平均池化(GAP), 就会得到一个初始权重向量。然后, 各个支路通过两个 1×1 的卷积(两个 1×1 的卷积之间包含一个 ReLU 非线性激活函数), 进行通道的压缩和扩张, 再通过一个 Sigmoid 函数, 生成各个支路特征通道的权重向量。

假定 FPF 块的特征拼接输出 $X' = [x_1, \dots, x_c, \dots, x_C] \in \mathbb{R}^{H \times W \times C'}$, GAP 运算可表示为:

$$z_c = H_{\text{GAP}}(x_c) = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W x_c(i, j) \quad (3-13)$$

其中, $H_{\text{GAP}}(\cdot)$ 是 GAP 函数, $Z = [z_1, \dots, z_c, \dots, z_C] \in \mathbb{R}^C$, 三个支路特征各个通道的

权重可表示为(为了简便, 公式中忽略了 ReLU 非线性激活函数):

$$A_k = \sigma \left(\text{Conv}_{1 \times 1} \left(\text{Conv}_{1 \times 1} (Z) \right) \right), k = 1, 2, 3 \tag{3-14}$$

其中, $\text{Conv}_{1 \times 1}(\cdot)$ 是 1×1 的卷积层, $\sigma(\cdot)$ 是 Sigmoid 函数。第 n 个 FAM 的残差输出 Y , 可表示为:

$$Y = \text{Conv}_{1 \times 1} \left(\left[A_1 \odot X'_1, A_2 \odot X'_2, A_3 \odot X'_3 \right] \right) \tag{3-15}$$

其中, $\text{Conv}_{1 \times 1}(\cdot)$ 是 1×1 的卷积, $X'_k (k = 1, 2, 3)$ 是第 n 个 FPF 块的三条支路输出的特征, $[\]$ 是特征通道拼接, $\odot$ 表示权重向量元素与对应特征通道相乘。由于使用了残差连接, 第 n 个 FAM 的输出特征 F_n 需要再加上第 n 个 FPF 块的输入 F_{n-1} , 即:

$$F_n = Y + F_{n-1} \tag{3-16}$$

3.3.5 分层特征融合注意力块(HFFAB)

分层特征融合注意力块(HFFAB)主要由多上下文注意力块(MCAB)和两个 1×1 的卷积层组成, HFFAB 的结构如图 3-11 所示。MACB 可聚焦信息丰富的上下文特征, 多上下文注意力块包括三个部分: 切割拼接模块(CSB)、第一阶三元组、第二阶三元组。对于 CSB 而言, 用于同时获取局部块与全局的空间依赖。首先, 将输出特征进行切块, 然后切割单元再进行拼接以及卷积操作, 获得局部与非局部信息, 最后, 再将这些切割单元进行拼接; 对于第一阶三元组, 用于建模不同维度的内在依赖, 使其能够获得上下文特征。对于第二阶三元组而言, 关注的是跨维度的交互关系。




图 3-11 HFFAB 结构图

首先, 为了减少参数量和计算量, 分层特征融合注意力块(HFFAB)在 CSB 前增加一个 1×1 的卷积层进行 4 倍的通道压缩, 该过程可进一步表示为:

$$F_{M1} = \text{Conv}_{1 \times 1}(F_{M0}) \quad (3-17)$$

其中, $\text{Conv}_{1 \times 1}(\cdot)$ 是 1×1 的卷积, F_{M1} 是进行 4 倍压缩通道后得到的特征, 然后 F_{M1} 输入到 CSB, CSB 首先对 F_{M1} 进行切割, 将 $C \times H \times W$ 大小的特征图切割成 $n \times n$ 大小的特征图, 然后将这些特征图在进行拼接以后输入到一个 3×3 的卷积层, 进行特征的提取, 同时聚合局部和非局部特征信息, 之后再 $n \times n$ 大小的特征图拼接成大小为 $C \times H \times W$ 的特征图, 该运算可以进一步表示为:

$$F_{M2} = O_s(\text{Conv}_{3 \times 3}(O_c(F_{M1}))) \quad (3-18)$$

其中, $O_s(\cdot)$ 代表拼接操作, $\text{Conv}_{3 \times 3}(\cdot)$ 是 3×3 的卷积层, $O_c(\cdot)$ 代表切割操作, F_{M2} 是该过程的输出特征。然后 F_{M2} 输入到第一阶三元组, 该过程主要是在 3 种维度上分别做一维注意力, 然后对 3 个进行注意力后的特征进行相加操作, 之后在与输入特征 F_{M2} 相加。

首先在通道维上做一维注意力的运算过程可以用公式表示为:

$$F_{M21} = \sigma(H_{\text{GAP}}(F_{M2})) \otimes F_{M2} \quad (3-19)$$

其中, $\sigma(\cdot)$ 是 Sigmoid 函数, $\otimes$ 表示逐元素相乘, $H_{\text{GAP}}(\cdot)$ 是 GAP 函数, 在此 GAP 函数得到的是通道维上的描述符。 F_{M21} 是进行通道维注意力后的输出特征。然后, 在高度维上一维做注意力的运算过程可以用公式表示为:

$$F_{M22} = T_{21}(\sigma(H_{\text{GAP}}(T_{21}(F_{M2}))) \otimes F_{M2}) \quad (3-20)$$

其中, $T_{21}(\cdot)$ 是维度转换函数, 将特征图的通道维和高度维进行交换, $\sigma(\cdot)$ 是 Sigmoid 函数, $\otimes$ 表示逐元素相乘, $H_{\text{GAP}}(\cdot)$ 是 GAP 函数, 在此 GAP 函数得到的是高度维上的描述符。 F_{M22} 是进行高度维上注意力后的输出特征。然后, 在宽度维上做一维注意力的运算过程可以用公式表示为:

$$F_{M23} = T_{31}(\sigma(H_{\text{GAP}}(T_{31}(F_{M2}))) \otimes F_{M2}) \quad (3-21)$$

其中, $T_{31}(\cdot)$ 是维度转换函数, 将特征图的通道维和宽度维进行交换, $\sigma(\cdot)$ 是 Sigmoid 函数, $\otimes$ 表示逐元素相乘, $H_{\text{GAP}}(\cdot)$ 是 GAP 函数, 在此 GAP 函数得到的是宽度维上的描述符。 F_{M23} 是进行宽度维上注意力后的输出特征。最后, 将 3 个经过注意力后的特征进行相加, 再与输入特征 F_{M2} 相加, 该过程可以表示为:

$$F_{M3} = F_{M21} + F_{M22} + F_{M23} + F_{M2} \quad (3-22)$$

其中, F_{M3} 是经过第一阶三元组后的输出特征。然后, F_{M3} 输入到第二阶三元组。该过程中主要是在 3 种维度上分别做二维注意力, 然后对 3 个进行注意力后的特征进行相加操作, 之后在与输入特征 F_{M3} 相加。

首先在(H,W)维上做二维注意力的运算过程可以用公式表示为:

$$F_{M31} = \sigma(M(F_{M3})) \otimes F_{M3} \quad (3-23)$$

其中, $\sigma(\cdot)$ 是 Sigmoid 函数, $\otimes$ 表示逐元素相乘, $M(\cdot)$ 是平均池化函数。 F_{M31} 是在(H,W)上进行注意力后的输出特征。然后, 在(C,W)维上做注意力的运算过程可以用公式表示为:

$$F_{M32} = T_{21}(\sigma(M(T_{21}(F_{M3}))) \otimes F_{M3}) \quad (3-24)$$

其中, $\sigma(\cdot)$ 是 Sigmoid 函数, $\otimes$ 表示逐元素相乘, $M(\cdot)$ 是平均池化函数, F_{M32} 是在(C,W)维上进行二维注意力后的输出特征。然后, 在(C,H)维上做二维注意力的运算过程可以用公式表示为:

$$F_{M33} = T_{31}(\sigma(M(T_{31}(F_{M3}))) \otimes F_{M3}) \quad (3-25)$$

其中, $\sigma(\cdot)$ 是 Sigmoid 函数, $\otimes$ 表示逐元素相乘, $M(\cdot)$ 是平均池化函数, F_{M33} 是在(C,H)维上进行二维注意力后的输出特征。最后, 将 3 个经过注意力后的特征进行相加, 再与输入特征 F_{M3} 相加, 该过程可以进一步表示为:

$$F_{M4} = F_{M31} + F_{M32} + F_{M33} + F_{M3} \quad (3-26)$$

其中, F_{M4} 是经过第二阶三元组后的输出特征。之后, 该特征经过一个 1×1 的卷积层, 1×1 的卷积层将通道扩张 4 倍, 该运算可进一步表示为:

$$F_{M5} = \text{Conv}_{1 \times 1}(F_{M4}) \quad (3-27)$$

其中, $\text{Conv}_{1 \times 1}(\cdot)$ 是 1×1 的卷积层, F_{M5} 是输出特征。之后该特征经过 Sigmoid 函数之后, 与 F_{M0} 相乘, 该运算可进一步表示为:

$$F_M = \sigma(F_{M5}) \otimes F_{M0} \quad (3-28)$$

其中, $\sigma(\cdot)$ 是 Sigmoid 函数, $\otimes$ 表示逐元素相乘, F_M 是 F_{M0} 经过 HFFAB 块后的输出。

3.3.6 上采样(Upsampler)

当前单图像超分辨率方法的上采样块，大多数都采用亚像素的卷积或转置的卷积，与之不同的是，我们使用了 PAN 的上采样块(U-PA) Upsampler 块的结构如图 3-12 所示，Upsampler 块中包含了 U-PA 块以及一个 3×3 的卷积层，U-PA 主要由最近邻上采样层和两个 3×3 卷积层之间的像素注意力组成，该块与采用亚像素卷积有两点不同：①引入了像素注意力，不仅可以显著提高图像重建的最终性能，而且参数开销很小；②使用了最近邻插值层作为上采样层，进一步减少了参数量。而 U-PA 块后面的 3×3 的卷积层是对通道降维到 3 通道。




图 3-12 Upsampler 结构图

对于 HEFAB 的输出特征 F_U ，首先经过一个最近邻插值层，然后再输入到一个 3×3 的卷积层，该卷积层将通道数 48 降维到 24，该运算可以表示为：

$$F_{S1} = Conv_{3,3}(H_{nearest}(F_U)) \quad (3-29)$$

其中， $H_{nearest}(\cdot)$ 代表最近邻插值函数， $Conv_{3,3}(\cdot)$ 是 3×3 的卷积层， F_{S1} 是该过程的输出特征。然后， F_{S1} 输入到 PA 注意力机制，该过程可进一步表示为：

$$F_{S2} = F_{S1} \otimes \sigma(Conv_{1,1}(F_{S1})) \quad (3-30)$$

其中， $\sigma(\cdot)$ 是 Sigmoid 函数， $Conv_{1,1}(\cdot)$ 是 1×1 的卷积， $\otimes$ 表示逐元素相乘， F_{S2} 是该过程的输出特征。然后， F_{S2} 输入到两个相连的 3×3 的卷积层，第一个 3×3 的卷积层是标准的卷积操作，第二个 3×3 的卷积层是对通道进行降维到 3 通道，该过程可表示为：

$$F_S = Conv_{3,3}(Conv_{3,3}(F_{S2})) \quad (3-31)$$

其中, $Conv_{3\times3}(\cdot)$ 是 3×3 的卷积层, F_s 是经过上采样后的输出特征, 该特征与将 LR 图像进行双三次插值后的特征进行相加, 得到最后的超分辨率图像 I_{SR} 。

3.4 本章小结

本章节在引言部分解释了由于为了减少网络模型训练过程中产生的参数量和计算量, 所以多路径学习的方式十分受研究人员的欢迎。之后, 介绍了目前优秀的轻量级多路径信息融合模块。然后提出了一种新的多路跨尺度信息融合的轻量级单图像超分辨率网络, 介绍了 MPFN 的整体网络结构, 主要包括多路特征渐进融合模块(FPF), 多路特征注意力机制(FAM)和分层特征融合注意力块(HFFAB)等, 同时详细地介绍了本文方法设计的动机。多路特征渐进融合块(FPF)作为本文方法最主要的创新点, 使用不同尺寸大小的卷积核, 通过多路径的学习方式采取不同深度的特征信息, 同时将浅层的特征信息渐进地引导和校准深层特征的学习, 该模块由于使用了不同尺寸大小的卷积核去提取多样的特征信息, 为后续重建高质量的超分辨率图像提供了丰富的特征信息。多路特征注意力机制(FAM)作为本文方法主要的创新点之一, 与多路渐进融合模块配对使用, 使用通道注意机制来优化 FPF 每个分支的特征通道权重, 这样注意机制既关注了浅层的纹理信息, 又关注了深层的语义信息, 同时对不同层次的特征信息进行了更进一步的融合, 能更快更准确地关注到对恢复高分辨率图像有用的特征信息, 有助于恢复出质量更高的超分辨率图像。此外, 本文采用的多路特征注意力机制, 可以实现最优加权特征通道, 并进行通道拼接。为了进一步充分利用残差块间的层次特征信息, 本文应用了分层特征融合注意力块, 该注意力块不仅可以同时获取局部块与全局的空间依赖, 又可以关注到不同维度的内在依赖以及跨维度的交互关系。本文以一种全新的多路径学习方式, 在深度卷积神经网络模型复杂度和单图像超分辨率性能之间, 建立了更好的平衡。

第 4 章 实验与分析

4.1 引言

本章节着重系统地讲述了实验中用到的数据集、图像质量评价(PSNR、SSIM、LPIPS、主观质量)、损失函数以及实验参数设置细节。此外，为了验证本文方法中多路特征渐进融合块(FPF)、多路特征注意力机制(FAM)和分层特征融合注意力块(HFFAB)的有效性，设置了各种实验。同时，与一些其它同类型的轻量级方法在主观效果和客观指标上做了比较。

4.2 数据集

4.2.1 训练集

本文的训练和验证图像都是采用的 DIV2K 数据集，DIV2K 是 NTIRE 2017 竞赛数据，它包含 1000 张 2K 分辨率图像^[54]。我们采用前 800 张图像用于模型的训练，第 821-830 张图像用于模型的验证，标记为 DIV2K_val10 数据集。DIV2K 数据集部分图像示例如下：




图 4-1 DIV2K 图像示例

4.2.2 测试集

为了保证比较的客观性，本文使用同其他方法一样的 5 个基准测试集，即：Set5^[54]、Set14^[55]、B100^[56]、Urban100^[57]和 Manga109^[58]。Set5 图像部分示例如下：




图 4-2 Set5 图像示例

4.3 图像质量评价

在当前的图像超分辨率重建中，常用的客观评价指标主要是峰值信噪比(Peak Signal to Noise Ratio, PSNR)^[59]和结构相似性(Structure Similarity Index Measurement, SSIM)^[60]，常用的主观视觉评价指标主要是学习的感知图像块相似性(Learned Perceptual Image Patch Similarity, LPIPS)^[61]。

4.3.1 PSNR

PSNR 是使用最为广泛的一种图像质量客观的评价方法指标，它主要是基于对应像素点之间存在的偏差，即根据对偏差敏感的图像质量评估。PSNR 一般都是指用于最大幅值信号输出与背景噪声输出之间转换的一种工程。一般来说在进行影像压缩以后，通常所输出来的影片内容都会在某种特定程度上和原来的影片内容有所不同。PSNR 一般是应用于峰值数据信息和背景信噪比之间的一种工程。为准确评估影像经处理过程后产生的实际影像质量，人们也往往都会通过参考 PSNR 指标的值来评估对某一个影像处理的程序效果是否满意。它也就是原始图像和最终被加工处理的图像间的均方误差系数(MSE)是相对于 $(2^n - 1)^2$ 的一个对数值，其系数的最小单位为 dB。PSNR 的值越大，效果越好。计算公式如下所示：

$$MSE = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W (X(i, j) - Y(i, j))^2 \quad (4-1)$$

$$PSNR = 10 \log_{10} \left(\frac{(2^n - 1)^2}{MSE} \right) \quad (4-2)$$

在图像超分辨率任务中，MSE 指的是超分辨率图像与高分辨率图像的均方误差，H 代表图像的高度，W 代表图像的宽度，n 是像素比特数。

4.3.2 SSIM

SSIM 也是一种全参考的客观评价指标，它主要通过从亮度值(luminance)、对比度值(contrast)、结构值(structure)这三方面来分别对这两张图像之间的相似性程度做出评价。亮度、对比度、结构系数的计算基本公式如下所示：

$$\begin{cases} l(X,Y) = \frac{2\mu_X\mu_Y + C_1}{\mu_X^2 + \mu_Y^2 + C_1} \\ c(X,Y) = \frac{2\sigma_X\sigma_Y + C_2}{\sigma_X^2 + \sigma_Y^2 + C_2} \\ s(X,Y) = \frac{\sigma_{XY} + C_3}{\sigma_X\sigma_Y + C_3} \end{cases} \quad (4-3)$$

其中， μ_X 、 μ_Y 分别表示图像X和Y的均值，即：

$$\begin{cases} \mu_X = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W X(i,j) \\ \mu_Y = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W Y(i,j) \end{cases} \quad (4-4)$$

σ_X 、 σ_Y 分别表示图像X和Y的方差， σ_X^2 、 σ_Y^2 计算如下：

$$\begin{cases} \sigma_X^2 = \frac{1}{H \times W - 1} \sum_{i=1}^H \sum_{j=1}^W (X(i,j) - \mu_X)^2 \\ \sigma_Y^2 = \frac{1}{H \times W - 1} \sum_{i=1}^H \sum_{j=1}^W (Y(i,j) - \mu_Y)^2 \end{cases} \quad (4-5)$$

σ_{XY} 表示超分辨率X和高分辨率图像Y的协方差， C_1 、 C_2 、 C_3 为常数，可由如下公式所得：

$$\sigma_X\sigma_Y = \frac{1}{H \times W - 1} \sum_{i=1}^H \sum_{j=1}^W (X(i,j) - \mu_X)(Y(i,j) - \mu_Y) \quad (4-6)$$

SSIM 的计算公式如下，SSIM 取值范围为[0,1]，SSIM 值越大，重建效果越好。

$$SSIM(X,Y) = [l(X,Y)]^\alpha \cdot [c(X,Y)]^\beta \cdot [s(X,Y)]^\gamma \quad (4-7)$$

其中，三个参数 α ， β ， γ 用来表示这三个模块的重要性。

4.3.3 LPIPS

LPIPS 称为“感知损失”，是一种常用的视觉指标，用来比较超分辨率图像与高分辨率图像之间的差异性。假设 x_0 为超分辨率图像， x 为高分辨率图像，差异性为 d ：

$$d(x, x_0) = \sum_i \frac{1}{H_i W_i} \sum_{h,w} \|w_i \odot (\hat{y}_{hw}^i - \hat{y}_{0,hw}^i)\|_2^2 \quad (4-8)$$

4.4 损失函数

损失函数：在图像超分辨率重建的任务中，它是至关重要的，通常采用它去计算输出图像与原始 HR 图像的差异，损失函数越好，那么恢复出来的超分辨率图像效果就会越好，从而神经网络模型的性能越好。常用的损失函数有 L_1 和 L_2 。

(1) L_1 损失函数即最小化绝对误差。在图像超分辨率重建的任务中，经常把图像当作一个多维的数字矩阵，我们可以假设 y_i 是真实图像数字矩阵中的一个值， $f(x_i)$ 是输出图像数字矩阵中的一个值，然后对两个数字矩阵做差，可能有正值和负值，所以对差值取平均值，最后在对所有像素点的差值进行相加，得到 D_{L1} 。那么最后得到的数值最小，说明两张图像之间的差距最小，所以在模型训练的过程中，会使其 D_{L1} 最小化。

$$D_{L1} = \sum_{i=1}^n |y_i - f(x_i)| \quad (4-9)$$

(2) L_2 损失函数即最小化平方误差。在图像超分辨率重建的任务中，经常把图像当作一个多维的数字矩阵，我们可以假设 y_i 是真实图像数字矩阵中的一个值， $f(x_i)$ 是输出图像数字矩阵中的一个值，然后对两个数字矩阵做差，再对所有的差求平方之后，在进行加操作，最后得到 D_{L2} 。

$$D_{L2} = \sum_{i=1}^n (y_i - f(x_i))^2 \quad (4-10)$$

其中， D_{L2} 是均方误差损失(MSE)，使用 L_2 损失函数也就是最小化 D_{L2} 。

4.5 实验细节

4.5.1 实验参数设置

在模型训练中，每批次随机选取 32 个的图像块。使用参数设置为 $\beta_1 = 0.9$ 、 $\beta_2 = 0.999$ 和 $\varepsilon = 10^{-8}$ 的 Adam 优化器^[62]，本文模型训练了 1200 个迭代周期，初始学习率设置为 2×10^{-4} ，每 200 个迭代周期衰减一半，采用了 L_1 损失函数。通过 PyTorch 框架^[63]，一个 NVIDIA 2080Ti GPU 实现模型，并进行模型的训练和测试。

4.5.2 各种对比实验

4.5.2.1 消融实验

为了验证多路特征渐进融合块(FPF)、多路特征注意力机制(FAM)，以及分层特征融合注意力模块(HFFAB)的有效性，进行了四组对比实验，我们给出了各个模型的参数量和计算量，以及在 DIV2K_val10 验证集上的 PSNR 值，如表 4-1 所示。我们将不包含 FAM 和 HFFAB，仅包含 FPF 中 3 个主支路(即不包含两个支路间的 1×1 卷积和 Sigmoid 函数)的网络称为基准网络，即为 MPFN_0，该网络在 DIV2K_val10 验证集上的 PSNR 值只有 29.49dB。

在基准网络上增加包含前面的特征对后面的特征的校准，即完整的 FPF，该模型标记为 MPFN_1。该模型的 PSNR 值比 MPFN_0 高了 0.11dB，说明我们的多路特征渐进融合模块中，前面特征辅助后面特征的学习，是很有效的。

接下来，在模型 MPFN_1 的基础上，增加 HFFAB 模块，该模型标记为 MPFN_2。相较于模型 MPFN_1，模型 MPFN_2 仅增加了 15K 的参数量，同时 PSNR 值增加了 0.03dB，表明我们的 HFFAB 模块是有效的。

最后，在模型 MPFN_2 的基础上，增加 FAM 模型，该模块标记为 MPFN。相较于模型 MPFN_2，该模型仅增加了 43K 的参数量，但 PSNR 值增加了 0.06dB。表明对各个支路特征通道进行加权拼接的 FAM 块，是有效的。

表4-1 网络架构不同变种在验证集DIV2K_val10上的3倍SR的客观指标

模型	FPF 三个 分支	FPF 校准 部分	HFFAB	FAM	PSNR (dB)	参数量	计算量
MPFN_0	√	×	×	×	29.49	443K	59.4G
MPFN_1	√	√	×	×	29.60	465K	61.6G
MPFN_2	√	√	√	×	29.63	480K	63.0G
MPFN	√	√	√	√	29.69	523K	66.2G

为了排除参数量对多路特征渐进融合块(FPF)、多路特征注意力机制(FAM)，以及分层特征融合注意力模块(HFFAB)有效性的影响，我们进行了三组对比实验，该 3 个模型在 DIV2K_val10 验证集上，3 倍 SR 的 PSNR，如表 4-2 所示。

第一组实验，在模型 MPFN_0 的基础上，通过对 FPF 块(仅包含 3 个支路)的简单堆叠保持与 MPFN_1 模型的参数量相当，得到模型 MPFN_3 模型，模型 MPFN_3 与 MPFN_1 相比较，MPFN_3 的 PSNR 值在比 MPFN_1 低 0.10dB，说明本文提出的多路特征渐进融合块(FPF)中，前面特征辅助后面特征的学习，是很有效的。

第二组实验，在模型 MPFN_0 的基础上，通过对 FPF 块(仅包含 3 个支路)的简

单堆叠保持与 MPFN_2 模型的参数量相当，得到模型 MPFN_4 模型，模型 MPFN_4 与 MPFN_2 相比较，MPFN_4 的 PSNR 值在比 MPFN_2 低 0.09dB，说明本文的 HFFAB 模块是有效的。

第三组实验，在模型 MPFN_0 的基础上，通过对 FPF 块(仅包含 3 个支路)的简单堆叠保持与 MPFN 模型的参数量相当，得到模型 MPFN_5 模型，模型 MPFN_5 与 MPFN 相比较，MPFN_5 的 PSNR 值在比 MPFN 低 0.11dB，说明对各个支路特征通道进行加权拼接的 FAM 块，是有效的。

表 4-2 MPFN 不同变种在验证集 DIV2K_val10 上的 3 倍 SR 的客观指标

模型	FPF 三个 分支	FPF 校准 部分	HFFAB	FAM	PSNR (dB)	参数量	计算量
MPFN_3	√	×	×	×	29.50	466K	61.7G
MPFN_4	√	×	×	×	29.54	488K	64.0G
MPFN_5	√	×	×	×	29.58	533K	68.7G

4.5.2.2 FEG 中 MPFE 的影响

本文模型包含三个特征提取组(FEG)，每组内包含相同个数多路特征提取块(MPFE)。MPFE 的个数选择，要综合考虑参数量、计算量，以及每个 FEG 输出的不同深度特征拼接后，对性能的影响。我们在 DIV2K_val10 验证集上进行了 5 组对比实验，我们将 MPFE 中的个数分别设置 4、5、6、7 和 8。该模型在 3 倍上的 SR 的 PSNR 结果，如表 4-3 所示。当 MPFE 的个数为 5 时，比为 4 时，PSNR 值增了 0.09dB；当 MPFE 的个数为 6 时，比为 5 时，PSNR 值增了 0.14dB；当 MPFE 的个数为 7 时，比为 6 时，PSNR 值增了 0.05dB；当 MPFE 的个数为 8 时，比为 7 时，PSNR 值降了 0.02dB。模型中 MPFE 的个数选择，应该综合考虑参数量，计算量以及对模型性能的影响。随着参数量的增加，7 个 MPFE 的 PSNR 增幅显著减缓，为了保持我们的模型在参数量和性能上取得一个良好的平衡，我们在本文中将 MPFE 的个数设置为 6，可能是一个合理的折中。

表 4-3 在 DIV2K_val10 上的不同 MPFE 个数对模型客观指标的影响

MPFE 个数	PSNR(dB)	参数量
4	29.46	367K
5	29.55	445K
6	29.69	523K
7	29.74	601K
8	29.72	679K

4.5.2.3 FAM 的影响

为了进一步洞察 FAM 的影响，我们在 DIV2K_val10 验证集上进行了两组实验。第一个实验，我们把 FAM 块的三条支路改为了一条支路，该模型在 3 倍的 SR 的 PSNR 结果为 29.56dB，这比我们的 MPFN 模型的 PSNR 低了 0.13dB。此外，更有趣的是，FAM 中仅包含一条支路比 MPFN_2 模型的 PSNR 值还低了 0.07dB。第二个实验，我们把 FAM 中各支路的参数进行共享，在验证集 DIV2K_val10 上，3 倍 SR 的 PSNR 结果为 29.65dB，比 MPFN 模型中各支路参数不共享的情形，PSNR 低 0.04dB，实验结果如表 4-4 所示。

表 4-4 在 DIV2K_val10 上的 FAM 的影响

FAM 三支路权重参数	PSNR(dB)
共享	29.65
不共享	29.69

4.6 结果与分析

4.6.1 客观评价指标对比

为了验证本文提出模型的有效性，同其他先进方法进行了定量客观。其它代表性的方法包括：SRCNN^[9]、FSRCNN^[10]、VDSR^[12]、AWSRN-M^[69]、DRRN^[15]、PAN^[22]、A²F-M^[23]、LatticeNet^[24]、IMDN^[25]、DRCN^[14]、RFDN^[26]、ACAN^[27]、MemNet^[41]、LapSRN^[64]、SRMDNF^[65]、CARN^[66]、MAFFSRN-L^[67]和 LAPAR-A^[68]，这些方法在 5 个标准测试数据集上，2、3 和 4 倍 SR 的 PSNR/SSIM、参数量和计算量(即 GFLOPs)^[70]结果，如表 4-6、4-7、4-8、4-9、4-10 和 4-11 所示，在上述方法中，除 LatticeNet 和 PAN 方法以外，其它方法的 PSNR/SSIM 结果均来自作者的原论文。LatticeNet 原论文的结果由于使用了自集成(self_ensemble)策略，所以本论文中的结果，并没有采用该策略，而是直接运行作者提供的训练模型。由于 PAN 同时使用了 DIV2K 和 Flickr2K 两个训练数据集进行训练，为了公平比较，我们使用了作者提供的代码，在 DIV2K 训练集上，重新进行了训练，所以，测试结果与原论文上的结果略有不同。

除此之外，本文还给出了在 4 倍超分辨率图像在 Set5、Urban100 和 Manga109 三个标准测试数据集上的 LPIPS 的结果，本文方法与其它 5 个代表方法：PAN^[22]、LatticeNet^[24]、IMDN^[25]、CARN^[66]和 LAPAR-A^[68]进行了对比。

(1) LPIPS 的值越小，代表超分辨率图像与高分辨率图像之间的差异性越小。

从表 4-5 可以看出，我们的 LPIPS 结果值最小，均优于其它比较的方法，表示本文方法重建的超分辨率图像与高分辨率图像越相似。

表 4-5 不同 SISR 方法 4 倍 SR 的 LPIPS 值

模型	参数量	计算量	Set5	Urban100	Manga109
CARN	1592K	90.9G	0.1761	0.2363	-
IMDN	715K	40.9G	0.1743	0.2350	0.1330
LatticeNet	777K	43.6G	0.1769	0.2423	0.1113
LAPAR-A	659K	94.0G	0.1759	<u>0.2317</u>	<u>0.1101</u>
PAN	272K	28.2G	<u>0.1741</u>	0.2348	0.1107
MPFN	534K	43.0G	0.1727	0.2265	0.1071

注：表中加粗的值为每列的最优值，下划线为每列的次优值。

表 4-6 各种 SISR 方法×2 放大倍数下的 PSNR 值

模型	参数量 (K)	计算量 (G)	Set5	Set14	B100	Urban100	Manga109
SRCNN	57	52.7	36.66	32.42	31.36	29.50	35.74
FSRCNN	12	6	37.00	32.63	31.53	29.88	36.67
VDSR	665	612.6	37.53	33.03	31.90	30.76	37.22
DRCN	1774	17974	37.63	33.04	31.85	30.75	37.63
LapSRN	813	29.9	37.52	33.08	31.80	30.41	37.27
DRRN	297	6796.9	37.74	33.23	32.05	31.23	37.92
MemNet	677	2662.4	37.78	33.28	32.08	31.31	37.72
SRMDNF	1513	347.7	37.79	33.32	32.05	31.33	38.07
CARN	1592	222.8	37.76	33.52	32.09	31.92	38.36
IMDN	694	158.8	38.00	33.63	32.19	32.17	38.88
LAPAR-A	548	171	38.01	33.62	32.19	32.10	38.67
RFDN	534	123.0	38.05	<u>33.68</u>	32.16	32.12	38.88
A ² F-M	999	224.2	38.04	33.67	32.18	32.27	38.87
ACAN	800	2108	38.10	33.60	<u>32.21</u>	32.29	38.81
LatticeNet	756	169.5	38.06	33.70	32.20	32.25	<u>38.94</u>
AWSRN-M	1063	244.1	38.04	33.66	<u>32.21</u>	32.23	38.66
PAN	261	70.5	37.99	33.53	32.14	31.93	38.37
MAFFSRN-L	790	154.4	38.07	33.59	32.23	32.38	-
MPFN	523	129.4	<u>38.09</u>	33.70	<u>32.21</u>	<u>32.34</u>	38.98

注：表中加粗的值为每列的最优值，下划线为每列的次优值。

(2) 表 4-6 和表 4-7 展示出了在 $\times 2$ 的放大倍数下, 多种先进方法在 5 种测试数据集下的 PSNR 与 SSIM 的结果。首先, 与本文方法参数量相差无几的 LAPAR-A 方法进行比较, 在本文方法计算量较小的情况下, 在 Urban100 数据集上, 我们的 PSNR 值超过了 LAPAR-A 方法 0.24dB; 在 Manga109 数据集上, 我们的 PSNR 值超过了其 0.31dB。然后, 与比本文方法参数量大一倍的 AWSRN-M 方法进行比较, 在 Urban100 数据集上, 我们的 PSNR 值超过了 AWSRN-M 方法 0.11dB; 在 Manga109 数据集上, 我们的 PSNR 值超过了 AWSRN-M 方法 0.32dB。其次, 与 ACAN 方法进行比较, 虽然在 Set5 数据集上, 我们的方法比 ACAN 的 PSNR 值低了 0.01dB, 但是在计算量上, 我们的方法只有 ACAN 的 6.3%, 同时在 Manga109 数据集上, 我们的 PSNR 值超过了其 0.17dB。从表 4-7 可以看出, 综合参数量和计算量考虑, 本文方法的 SSIM 值也十分具有优势。

表 4-7 各种 SISR 方法 $\times 2$ 放大倍数下的 SSIM 值

模型	参数量(K)	计算量(G)	Set5	Set14	B100	Urban100	Manga109
SRCNN	57	52.7	0.9524	0.9063	0.8879	0.8946	0.9661
FSRCNN	12	6	0.9558	0.9088	0.8920	0.9020	0.9694
VDSR	665	612.6	0.9587	0.9124	0.8960	0.9140	0.9729
DRCN	1774	17974	0.9588	0.9118	0.8942	0.9133	0.9723
LapSRN	813	29.9	0.9590	0.9130	0.8950	0.9100	0.9740
DRRN	297	6796.9	0.9591	0.9136	0.8973	0.9188	0.9760
MemNet	677	2662.4	0.9597	0.9142	0.8978	0.9195	0.9740
SRMDNF	1513	347.7	0.9600	0.9150	0.8980	0.9200	0.9761
CARN	1592	222.8	0.9590	0.9166	0.8978	0.9256	0.9765
IMDN	694	158.8	0.9605	0.9177	0.8996	0.9283	0.9774
LAPAR-A	548	171	0.9605	0.9183	0.8999	0.9283	0.9772
RFDN	534	123.0	0.9606	0.9184	0.8994	0.9278	<u>0.9773</u>
A ² F-M	999	224.2	<u>0.9607</u>	0.9184	0.8996	0.9294	0.9774
ACAN	800	2108	0.9608	0.9177	<u>0.9001</u>	<u>0.9297</u>	<u>0.9773</u>
LatticeNet	756	169.5	<u>0.9607</u>	<u>0.9187</u>	0.8999	0.9288	0.9774
AWSRN-M	1063	244.1	0.9605	0.9181	0.9000	0.9294	0.9772
PAN	261	70.5	0.9603	0.9174	0.8992	0.9263	0.9766
MAFFSRN-L	790	154.4	<u>0.9607</u>	0.9177	0.9005	0.9308	-
MPFN	523	129.4	<u>0.9607</u>	0.9190	0.9000	0.9296	0.9767

注: 表中加粗的值为每列的最优值, 下划线为每列的次优值。

表 4-8 各种 SISR 方法×3 放大倍数下的 PSNR 值

模型	参数量 (K)	计算量 (G)	Set5	Set14	B100	Urban100	Manga109
SRCNN	57	52.7	32.75	29.28	28.41	26.24	30.59
FSRCNN	12	4.6	33.16	29.43	28.53	26.43	30.98
VDSR	665	612.6	33.66	29.77	28.82	27.14	32.01
DRCN	1774	17974	33.82	29.76	28.80	27.15	32.31
DRRN	297	67969	34.03	29.96	28.95	27.53	32.74
MemNet	677	2662.4	34.09	30.00	28.96	27.56	32.51
SRMDNF	1530	156.3	34.12	30.04	28.97	27.57	33.00
CARN	1592	118.8	34.29	30.29	29.06	27.38	33.50
IMDN	703	71.5	34.36	30.32	29.09	28.17	33.61
LAPAR-A	594	114	34.36	30.34	<u>29.11</u>	28.15	33.51
RFDN	541	55.4	34.41	30.34	29.09	28.21	<u>33.67</u>
A ² F-M	1003	100	<u>34.50</u>	<u>30.39</u>	<u>29.11</u>	<u>28.28</u>	33.66
ACAN	1115	1051.7	34.46	<u>30.39</u>	<u>29.11</u>	<u>28.28</u>	33.61
LatticeNet	765	76.3	34.40	30.32	29.10	28.19	33.63
AWSRN-M	1143	116.6	34.42	30.32	29.13	28.26	33.64
PAN	261	39.0	34.30	30.30	29.06	28.02	33.34
MAFFSRN-L	807	68.5	34.45	30.40	29.13	28.26	-
MPFN	523	66.2	34.51	30.37	29.13	28.35	33.85

注：表中加粗的值为每列的最优值，下划线为每列的次优值。

表 4-9 各种 SISR 方法×3 放大倍数下的 SSIM 值

模型	参数量 (K)	计算量 (G)	Set5	Set14	B100	Urban100	Manga109
SRCNN	57	52.7	0.9090	0.8209	0.7863	0.7989	0.9107
FSRCNN	12	4.6	0.9104	0.8242	0.7910	0.8080	0.9212
VDSR	665	612.6	0.9213	0.8314	0.7976	0.8279	0.9310
DRCN	1774	17974	0.9226	0.8311	0.7963	0.8276	0.9328
DRRN	297	67969.0	0.9244	0.8349	0.8004	0.8378	0.9390
MemNet	677	2662.4	0.9248	0.8350	0.8001	0.8376	0.9369
SRMDNF	1530	156.3	0.9250	0.8370	0.8030	0.8400	0.9403
CARN	1592	118.8	0.9255	0.8407	0.8034	0.8404	0.9440
IMDN	703	71.5	0.9270	0.8417	0.8046	0.8519	0.9445
LAPAR-A	594	114	0.9267	0.8421	0.8054	0.8523	0.9441
RFDN	541	55.4	0.9273	0.8420	0.8050	0.8525	0.9449
A ² F-M	1003	100	<u>0.9278</u>	0.8427	0.8054	0.8546	<u>0.9453</u>
ACAN	1115	1051.7	0.9277	0.8435	0.8055	<u>0.8550</u>	0.9447
LatticeNet	765	76.3	0.9272	0.8416	0.8049	0.8513	0.9442
AWSRN-M	1143	116.6	0.9275	0.8419	<u>0.8059</u>	0.8545	0.9450
PAN	261	39.0	0.9266	0.8416	0.8042	0.8493	0.9435
MAFFSRN-L	807	68.5	0.9277	<u>0.8432</u>	0.8061	0.8552	-
MPFN	523	66.2	0.9283	0.8424	0.8058	<u>0.8550</u>	0.9461

注：表中加粗的值为每列的最优值，下划线为每列的次优值。

(3) 表 4-8 和表 4-9 展示出了在×3 的放大倍数下，多种先进方法 5 种数据集下的 PSNR 与 SSIM 的结果。首先，与比本文方法参数量大一倍的 A²F-M 方法进行比较，在 Manga109 数据集上，我们的 PSNR 值超过了其 0.19dB。然后，与 ACAN 方法进行比较，在 Manga109 数据集上，我们的 PSNR 值超过了其 0.24dB。其次，与 LatticeNet 方法进行比较，在 Urban100 数据集上，我们的 PSNR 值超过了它 0.16dB，在 Set5 数据集上，我们的 PSNR 值超过了其 0.11dB。从表 4-8 可以看出，综合参数量和计算量考虑，本文方法的 SSIM 值也十分具有优势。

表 4-10 各种 SISR 方法×4 的 PSNR 值

模型	参数量 (K)	计算量 (G)	Set5	Set14	B100	Urban100	Manga109
SRCNN	57	52.7	30.48	27.49	26.90	24.52	27.66
FSRCNN	12	4.6	30.71	27.59	26.98	24.62	27.90
VDSR	665	612.6	31.35	28.01	27.29	25.18	28.83
DRCN	1774	17974	31.53	28.02	27.23	25.14	28.98
LapSRN	813	149.4	31.54	28.19	27.32	25.21	29.09
DRRN	1774	17974.3	31.53	28.02	27.23	25.14	28.98
MemNet	677	2662.4	31.74	28.26	27.40	25.50	29.42
SRMDNF	1555	89.3	31.96	28.35	27.49	25.68	30.09
CARN	1592	90.9	32.13	28.60	27.58	26.07	30.47
IMDN	715	40.9	32.21	28.58	27.56	26.04	30.45
LAPAR-A	659	94	32.15	28.61	27.61	26.14	30.42
RFDN	550	31.6	32.24	28.61	27.57	26.11	<u>30.58</u>
A ² F-M	1010	56.7	<u>32.28</u>	28.62	27.58	<u>26.17</u>	30.57
ACAN	1556	616.5	32.24	28.62	27.59	<u>26.17</u>	30.53
LatticeNet	777	43.6	32.18	28.61	27.57	26.14	30.54
AWSRN-M	1254	72	32.21	<u>28.65</u>	<u>27.60</u>	26.15	30.56
PAN	272	28.2	32.06	28.56	27.55	26.01	30.33
MAFFSRN-L	830	38.6	32.20	28.62	27.59	26.16	-
MPFN	534	43.0	32.36	28.69	27.61	26.29	30.71

注：表中加粗的值为每列的最优值，下划线为每列的次优值。

(4) 表 4-10 和表 4-11 展示出了在×4 的放大倍数下，多种先进方法在 5 种数据集下的 PSNR 与 SSIM 的结果。与 LatticeNet 方法进行比较，在 Manga109 数据集上，我们的 PSNR 值超过了它 0.17dB，在 Set5 数据集上，我们的 PSNR 值超过了其 0.18dB。与 ACAN 方法进行比较，在 Manga109 数据集上，我们的 PSNR 值超过了其 0.18dB。

(5) 从图 4-3 展示出了在×4 的放大倍数下，多种先进方法在 Urban100 数据集下的 PSNR 以及模型的参数量，可以看出我们的网络模型性能均比其他方法效果更

好。




图 4-3 各种先进的 SISR 方法在 Urban100 数据集下>2 的参数量和 PSNR 结果

表 4-11 各种 SISR 方法×4 的 SSIM 值

模型	参数量 (K)	计算量(G)	Set5	Set14	B100	Urban100	Manga109
SRCNN	57	52.7	0.8628	0.7503	0.7101	0.7221	0.8505
FSRCNN	12	4.6	0.8657	0.7535	0.7150	0.7280	0.8517
VDSR	665	612.6	0.8838	0.7674	0.7251	0.7524	0.8809
DRCN	1774	17974	0.8854	0.7670	0.7233	0.7510	0.8816
LapSRN	813	149.4	0.8850	0.7720	0.7280	0.7560	0.8845
DRRN	1774	17974.3	0.8854	0.7670	0.7233	0.7510	0.8816
MemNet	677	2662.4	0.8893	0.7723	0.7281	0.7630	0.8942
SRMDNF	1555	89.3	0.8930	0.7770	0.7340	0.7730	0.9024
CARN	1592	90.9	0.8937	0.7806	0.7349	0.7837	0.9084
IMDN	715	40.9	0.8948	0.7811	0.7353	0.7838	0.9075
LAPAR-A	659	94	0.8944	0.7818	0.7366	0.7871	0.9074
RFDN	550	31.6	0.8952	0.7819	0.7360	0.7858	0.9089
A ³ F-M	1010	56.7	<u>0.8955</u>	0.7828	0.7364	<u>0.7892</u>	<u>0.9100</u>
ACAN	1556	616.5	0.8955	0.7824	0.7366	0.7891	0.9086
LatticeNet	777	43.6	0.8943	0.7812	0.7355	0.7844	0.9075
AWSRN-M	1254	72	0.8954	<u>0.7832</u>	0.7368	0.7884	0.9093
PAN	272	28.2	0.8939	0.7813	0.7352	0.7830	0.9069
MAFFSRN-L	830	38.6	0.8953	0.7822	<u>0.7370</u>	0.7887	-
MPFN	534	43.0	0.8968	0.7835	0.7372	0.7902	0.9115

注：表中加粗的值为每列的最优值，下划线为每列的次优值。

4.6.2 主观效果对比

主观效果比较：图 4-4 展示了本文方法与其它先进方法，在×4 时 Urban100 数据集上重建的超分辨率图像结果。以 Urban100 数据集中图像 067 为例，Bicubic、FSRCNN、CARN、LatticeNet 和 A²F-M 等方法恢复的条纹，均有不同程度的模糊和失真，我们的结果很接近于原高分辨率图像。Urban100 数据集中图像 089，除 LAPAR-A 方法和本文网络模型之外，其它方法恢复的条纹，或过度模糊，或条纹方向错误。虽然 LAPAR-A 方法正确地恢复了条纹的方向，但是，仍然有明显的模糊，我们的结果条纹方向正确，也更清晰。




图 4-4 在 Urban100 数据集×4 放大倍数下的主观效果图

图 4-5 展示了本文方法与其它先进方法，在×4 时 Set14 数据集上重建的超分辨率图像结果。以图像 barbara 为例，除本文方法以外，Bicubic、SRCNN、VDSR 和 LapSRN 方法中书的线条畸变现象严重，其它方法均有不同程度的模糊和失真，我们的结果也最接近原高分辨率图像。




图 4-5 在 Set14 数据集×4 放大倍数下的主观效果图

图 4-6 展示了本文方法与其它先进方法，在×3 时重建的 SR 图像结果。以 Urban100 数据集中图像 img011 为例，Bicubic、FSRCNN、CARN、LatticeNet 和 A²F-M 等方法恢复的纹理，均有不同程度的模糊和失真，本文方法的重建效果很接近于原 HR 图像。Urban100 数据集中图像 img024 也类似，相较于其它几种方法，本文方法的重建效果比它们更接近于 HR 图像。




图 4-6 在 Urban100 数据集×3 放大倍数下的主观效果图

4.7 本章小结

本章介绍了实验所用的数据集，设计了多组实验，验证多路特征渐进融合块 (FPF)、多路特征注意力机制(FAM)以及分层特征融合注意力模块(HFFAB)的有效

性，最后，通过大量的图表给出了客观指标值和主观效果。从客观指标上来看，本文方法 PSNR 和 SSIM 值几乎超过了其他轻量级的图像超分辨率方法；从主观指标来看，本文方法的 LPIPS 值最小，LPIPS 的值越低表示两张图像越相似，反之，则差异越大，说明本文方法重建的超分辨率图像与原高分辨率图像越相似；从主观效果来看，本文方法恢复的图像纹理清晰、细节丰富，更加接近真实图像。此外，在模型的复杂度方面，本文方法参数量小，计算量小，但是 PSNR 值却比较高，把模型复杂度和性能之间的平衡，提升到了一个新的水平。

第 5 章 结论与展望

5.1 论文工作总结

近年来,随着深度学习技术的迅速发展,许多先进方法通过加深或者加宽网络模型,虽然改进了单图像超分辨率的性能,但是同时也增加了参数量和计算量,并且训练网络模型往往需要更长的训练时间以及更强的计算能力,导致在资源受限的移动设备上使用受到限制。因此,设计轻量级的网络是十分必要的,但是网络深度和参数量是影响单图像超分辨率性能的重要因素。本文提出了一种新的轻量级多路跨尺度信息融合的超分辨率网络,在保持参数量和性能之间取得较好平衡的同时,提升了图像超分辨率重建的质量。本文的研究内容如下:

本文提出了多路特征渐进融合块(FPF),使用多种尺寸不同的卷积核来提取多路径不同深度的特征信息。FPF 充分利用浅层特征信息和深层特征信息,为重建高质量图像提供丰富的细节信息。通过对 Wang 等提出的注意力辅助特征块 A^2F 进行分析, A^2F 通过浅层特征(辅助特征)去帮助当前层特征的学习,是有效的。不同于 A^2F 的是,我们将浅层特征通过 1×1 的卷积和 Sigmoid 函数去多路渐进地引导深层特征的提取,实验也证明了这种用法是有效的。

本文提出了多路特征注意力机制(FAM),FAM 与 FPF 配对使用,加权拼接多路通道特征,可以增强特征表达能力。通过对 FC^2N 分析, FC^2N 中提到采用通道级联直接连接不同层次的特征,忽略了自适应学习对模型的贡献,其认为加权层间连接虽然会阻碍有效的反向传播,但这种自适应学习的方法更符合人脑神经元的行为方式。不同于 FC^2N 的是,我们采用了注意力机制,可以最优地对特征通道进行加权,并进行通道拼接。实验也证明了这种用法是有效的。

本文提出了一个多路跨尺度信息融合的轻量级图像超分辨率模型,该模型无论是在主观视觉还是主观、客观性能指标,都优于其它类似的轻量级超分辨率方法,在深度卷积神经网络模型复杂度和单图像超分辨率性能之间,取得了一个更好的平衡。

大量的实验证明:本文提出的方法与当前其他先进的轻量级图像超分辨率方法相比,我们的性能指标 PSNR、LPIPS 都优于其它方法,同时,我们重建的 SR 图像很接近于原 HR 图像。此外,本文的方法参数量和计算量都较小,在深度卷积神经网络模型复杂度和单图像超分辨率性能之间,建立了更好的平衡。

5.2 未来工作展望

本文提出了一种多路径的轻量级单图像超分辨率网络，虽然在性能指标和主观视觉方面都具有良好的结果，但是本文方法仍然有一定的缺陷，主要有以下方面：

(1) 本文方法在训练时都是基于单尺度，该方法的三种放大倍数都是基于不同的模型，对未来的应用具有一定的局限性。因此，可以通过进一步改进网络模型，使一个模型可以重建多种放大倍数的图像，以便未来的应用。

(2) 本文方法虽然在 534K 量级的参数量上，在深度卷积神经网络模型复杂度和单图像超分辨率性能之间，取得了一个更好的平衡。但是当增大参数量时，却发现 PSNR 值增加的不明显，所以可以对网络架构做进一步的改进，使其在小参数量和较大参数量上，都有更好的结果。

单图像超分辨率技术是目前提升计算机视觉领域图像清晰度效率的最主要的图像视觉处理技术方式之一，有着十分广阔深远的技术现实和应用价值。以上内容是本人在攻读硕士阶段的研究内容，希望我的研究成果可以为单图像超分辨率重建技术研究带来一些价值。

参考文献

- [1] 阮秋琦. 数字图像处理[M]. 北京: 电子工业出版社, 2021.1
- [2] Freeman W T, Pasztor E C, Carmichael O T. Learning low-level vision[J]. International Journal of Computer Vision, 2000, 40(1): 25-47
- [3] Peyré G, Bougleux S, Cohen L. Non-local regularization of inverse problems[C]. Proceedings of the 2008 European Conference on Computer Vision, 2008: 57-68
- [4] Li X, Orchard M T. New edge-directed interpolation[J]. IEEE Transactions on Image Processing, 2001, 10(10): 1521-1527
- [5] Battiato S, Gallo G, Stanco F. A locally adaptive zooming algorithm for digital images[J]. Image and Vision Computing, 2002, 20(11): 805-812
- [6] Sun J, Xu Z, Shum H Y. Image super-resolution using gradient profile prior[C]. Proceedings of the 2008 IEEE Conference on Computer Vision and Pattern Recognition, 2008: 1-8
- [7] Tsai R. Multiframe image restoration and registration[J]. Advance Computer Visual and Image Processing, 1984, 1: 317-339
- [8] Irani M, Peleg S. Improving resolution by image registration[J]. Graphical Models and Image Processing, 1991, 53(3): 231-239
- [9] Dong C, Loy C C, He K, et al. Learning a deep convolutional network for image super-resolution[C]. Proceedings of the 2016 European Conference on Computer Vision, 2014: 184-199
- [10] Dong C, Chen C L, Tang X. Accelerating the super-resolution convolutional neural network[C]. Proceedings of the 2016 European Conference on Computer Vision, 2016: 391-407
- [11] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]. Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition, 2016: 770-778
- [12] Kim J, Lee J K, Lee K M. Accurate image super-resolution using very deep convolutional networks[C]. Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition, 2016: 1646-1654
- [13] Shi W, Caballero J, Huszár F, et al. Real-time single image and video super-resolution using an efficient sub-pixel convolutional neural network[C]. Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition, 2016: 1874-1883
- [14] Kim J, Lee J K, Lee K M. Deeply-recursive convolutional network for image super-

- resolution[C]. Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition, 2016: 1637-1645
- [15] Tai Y, Yang J, Liu X. Image super-resolution via deep recursive residual network[C]. Proceedings of the 2017 IEEE Conference on Computer Vision and Pattern Recognition, 2017: 3147-3155
- [16] Lai W S, Huang J B, Ahuja N, et al. Deep laplacian pyramid networks for fast and accurate super-resolution[C]. Proceedings of the 2017 IEEE Conference on Computer Vision and Pattern Recognition, 2017: 624-632
- [17] Ledig C, Theis L, Huszár F, et al. Photo-realistic single image super-resolution using a generative adversarial network[C]. Proceedings of the 2017 IEEE Conference on Computer Vision and Pattern Recognition, 2017: 4681-4690
- [18] Lim B, Son S, Kim H, et al. Enhanced deep residual networks for single image super-resolution[C]. Proceedings of the 2017 IEEE Conference on Computer Vision and Pattern Recognition Workshops, 2017: 1132-1140
- [19] Tong T, Li G, Liu X, et al. Image super-resolution using dense skip connections[C]. Proceedings of the 2017 IEEE International Conference on Computer Vision, 2017: 4809-4817
- [20] Zhang Y, Li K, Li K, et al. Image super-resolution using very deep residual channel attention networks[C]. Proceedings of the 2018 European Conference on Computer Vision, 2018: 286-301
- [21] Xu Y S, Tseng S Y R, Tseng Y, et al. Unified dynamic convolutional network for super-resolution with variational degradations[C]. Proceedings of the 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020: 12496-12505
- [22] Zhao H, Kong X, He J, et al. Efficient image super-resolution using pixel attention[C]. Proceedings of the 2020 European Conference on Computer Vision, 2020: 56-72
- [23] Wang X, Wang Q, Zhao Y, et al. Lightweight single-image super-resolution network with attentive auxiliary feature learning[C]. Proceedings of the 2020 Asian Conference on Computer Vision, 2020: 268-285
- [24] Luo X, Xie Y, Zhang Y, et al. Latticenet: towards lightweight image super-resolution with lattice block[C]. Proceedings of the 2020 European Conference on Computer Vision, 2020: 272-289
- [25] Hui Z, Gao X, Yang Y, et al. Lightweight image super-resolution with information multi-distillation network[C]. Proceedings of the 27th ACM International Conference on Multimedia, 2019: 2024-2032

- [26] Liu J, Tang J, Wu G. Residual feature distillation network for lightweight image super-resolution[C]. Proceedings of the 2020 European Conference on Computer Vision, 2020: 41-55
- [27] 陈一鸣, 周登文. 基于自适应级联的注意力网络的超分辨率重建[J]. 自动化学报, 2020, 46: 1-11
- [28] 李金新, 黄志勇, 李文斌, 等. 基于多层次特征融合的图像超分辨率重建[J]. 自动化学报, 2021: 1-11
- [29] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]. Proceedings of the 2018 IEEE Conference on Computer Vision and Pattern Recognition, 2018: 7132-7141
- [30] Timofte R, Agustsson E, Van Gool L, et al. Ntire 2017 challenge on single image super-resolution: methods and results[C]. Proceedings of the 2017 IEEE Conference on Computer Vision and Pattern Recognition Workshops, 2017: 114-125
- [31] Jaderberg M, Simonyan K, Zisserman A. Spatial transformer networks[J]. Advances in Neural Information Processing Systems, 2015: 28
- [32] Woo S, Park J, Lee J Y, et al. Cbam: Convolutional block attention module[C]. Proceedings of the 2018 European Conference on Computer Vision, 2018: 3-19
- [33] Zhang Y, Tian Y, Kong Y, et al. Residual dense network for image super-resolution[C]. Proceedings of the 2018 IEEE Conference on Computer Vision and Pattern Recognition, 2018: 2472-2481
- [34] Liu J, Zhang W, Tang Y, et al. Residual feature aggregation network for image super-resolution[C]. Proceedings of the 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020: 2359-2368
- [35] Qiu Y, Wang R, Tao D, et al. Embedded block residual network: a recursive restoration model for single-image super-resolution[C]. Proceedings of the 2019 IEEE/CVF International Conference on Computer Vision, 2019: 4180-4189
- [36] 沈明玉, 俞鹏飞, 汪荣贵, 等. 多路径递归网络结构的单帧图像超分辨率重建[J]. 光电工程, 2019, 46(11): 9
- [37] 郭琳, 李晨, 陈晨, 等. 基于通道注意递归残差网络的图像超分辨率重建[J]. 计算机科学, 2021, 48(8): 6
- [38] 张雷, 胡博文, 张宁, 等. 图像超分辨率全局残差递归网络[J]. 计算机科学, 2019, 46(B06): 4
- [39] 吴磊, 吕国强, 薛治天, 等. 基于多尺度递归网络的图像超分辨率重建[J]. 光学学报, 2019, 39(6): 8
- [40] 高青青, 赵建伟, 周正华. 基于递归多尺度卷积网络的图像超分辨率重建[J]. 模式识别与人工智能, 2020, 33(11): 9

- [41] Tai Y, Yang J, Liu X, et al. Memnet: a persistent memory network for image restoration[C]. Proceedings of the 2017 IEEE International Conference on Computer Vision, 2017: 4539-4547
- [42] 周登文, 赵丽娟, 段然, 等. 基于递归残差网络的图像超分辨率重建[J]. 自动化学报, 2019, 45(6): 1157-1165
- [43] 李文斌. 基于嵌套残差图像超分辨率算法研究[D]. 北京: 华北电力大学, 2021
- [44] 郭锋锋, 马璐. 基于多路径残差网络交叉学习的图像超分辨率重建[J]. 攀枝花学院学报: 综合版, 2020, 37(2): 7
- [45] 王永金, 左羽, 吴恋, 等. 基于注意力机制的图像超分辨率重建[J]. 计算机应用, 2021, 41(3): 6
- [46] 俞鹏飞. 基于多路前馈深度网络的图像超分辨重建方法研究[D]. 合肥: 合肥工业大学, 2019
- [47] 王超. 基于多特征融合学习的图像超分辨率算法[D]. 济南: 山东师范大学, 2020
- [48] 胡锐, 赵佰亭, 贾晓芬. 双路多尺度残差网络的图像超分辨率重建[J]. 青岛科技大学学报(自然科学版), 2021, 42(03): 107-112+118
- [49] Li J, Fang F, Mei K, et al. Multi-scale residual network for image super-resolution[C]. Proceedings of the 2018 European Conference on Computer Vision, 2018: 517-532
- [50] Hui Z, Wang X, Gao X. Fast and accurate single image super-resolution via information distillation network[C]. Proceedings of the 2018 IEEE Conference on Computer Vision and Pattern Recognition, 2018: 723-731
- [51] Huang Z, Li W, Li J, et al. Dual-path attention network for single image super-resolution[J]. Expert Systems with Applications, 2021, 169: 114450
- [52] Zhao X, Liao Y, He T, et al. Fc2n: fully channel-concatenated network for single image super-resolution. arXiv preprint arXiv: 1907.03221v4, 2021
- [53] Zhang J, Long C, Wang Y, et al. A two-stage attentive network for single image super-resolution[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2021, 32(3): 1020-1033
- [54] Bevilacqua M, Roumy A, Guillemot C, et al. Low-complexity single-image super-resolution based on nonnegative neighbor embedding[J]. Proceedings of the 2012 British Machine Vision Conference, 2012
- [55] Zeyde R, Elad M, Protter M. On single image scale-up using sparse-representations[C]. Proceedings of the 2010 International Conference on Curves and Surfaces, 2010: 711-730
- [56] Martin D, Fowlkes C, Tal D, et al. A database of human segmented natural images and its application to evaluating segmentation algorithms and measuring ecological

- statistics[C]. Proceedings of the 2001 IEEE International Conference on Computer Vision, 2001, 2: 416-423
- [57] Huang J B, Singh A, Ahuja N. Single image super-resolution from transformed self-exemplars[C]. Proceedings of the 2015 IEEE Conference on Computer Vision and Pattern Recognition, 2015: 5197-5206
- [58] Matsui Y, Ito K, Aramaki Y, et al. Sketch-based manga retrieval using manga109 dataset[J]. Multimedia Tools and Applications, 2017, 76(20): 21811-21838
- [59] Huynh-Thu Q, Ghanbari M. Scope of validity of psnr in image/video quality assessment[J]. Electronics Letters, 2008, 44(13): 800-801
- [60] Wang Z, Bovik A C, Sheikh H R, et al. Image quality assessment: from error visibility to structural similarity[J]. IEEE Transactions on Image Processing, 2004, 13(4): 600-612
- [61] Zhang R, Isola P, Efros A A, et al. The unreasonable effectiveness of deep features as a perceptual metric[C]. Proceedings of the 2018 IEEE Conference on Computer Vision and Pattern Recognition, 2018: 586-595
- [62] Kingma D P, Ba J. Adam: a method for stochastic optimization[C]. Proceedings of the 3rd International Conference on Learning Representations, 2015
- [63] Pytorch. <http://pytorch.org>
- [64] Lai W S, Huang J B, Ahuja N, et al. Deep laplacian pyramid networks for fast and accurate super-resolution[C]. Proceedings of the 2017 IEEE Conference on Computer Vision and Pattern Recognition, 2017: 624-632
- [65] Zhang K, Zuo W, Zhang L. Learning a single convolutional super-resolution network for multiple degradations[C]. Proceedings of the 2018 IEEE Conference on Computer Vision and Pattern Recognition, 2018: 3262-3271
- [66] Ahn N, Kang B, Sohn K A. Fast, accurate, and lightweight super-resolution with cascading residual network[C]. Proceedings of the 2018 European Conference on Computer Vision, 2018: 252-268
- [67] Muqet A, Hwang J, Yang S, et al. Multi-attention based ultra lightweight image super-resolution[C]. Proceedings of the 2020 European Conference on Computer Vision, 2020: 103-118
- [68] Li W, Zhou K, Qi L, et al. Lapar: linearly-assembled pixel-adaptive regression network for single image super-resolution and beyond[J]. Advances in Neural Information Processing Systems, 2020, 33: 20343-20355
- [69] Wang C, Li Z, Shi J. Lightweight image super-resolution with adaptive weighted learning network. arXiv preprint arXiv: 1904.02358, 2019

- [70] Zhang X, Zhou X, Lin M, et al. Shufflenet: an extremely efficient convolutional neural network for mobile devices[C]. Proceedings of the 2018 IEEE Conference on Computer Vision and Pattern Recognition, 2018: 6848-685

攻读硕士学位期间发表的论文及其它成果

- [1] 第一作者. 基于多路跨尺度信息融合的轻量级超分辨率算法研究. (在审稿中)
- [2] 第一作者. Lightweight single image super-resolution based on multi-path progressive feature fusion and attention mechanism. (在审稿中)

致谢

三年的硕士生涯即将结束，在这难忘的三年里，每天过的充实而又快乐。值此之际，谨向那些帮助过我的老师和同学们，表达由衷的感谢。

首先，我要感谢我的导师周登文教授。周老师治学严谨、为人正直。对待科研一丝不苟，还经常在深夜帮我指导论文，在我整个研究生期间给予了莫大的帮助。周老师的言传身教、以身作则，不断鼓舞着我们不断努力向前，唯有脚踏实地才能有所成果。

其次，我要感谢 721 的小伙伴们，李艺攀、王天生同学，他们总是在我困难的时候及时给予帮助，在科研的道路上相互鼓励。也感谢他们创造了一个良好的学术氛围，让我不再那么浮躁、不再那么急功近利。每一次的思想碰撞，总是有新的灵感爆发，让我的实验顺利搞下去；同时也在我错误的时候，能够及时止损。我要感谢他们的陪伴，无数个日日夜夜的努力，没有他们，科研的道路注定索然无味。

然后，感谢师兄师姐们的指导，他们是我科研的领路人。优秀的田金月师姐、马路遥师兄、李文斌师兄、李金新师兄、黄志勇师兄。无论在科研上还是生活中，对我悉心的指导，让我少走了许多弯路，传授了我们经验，感谢他们无私的帮助。感谢高丹丹师妹、王婉君师妹、邱连明师妹、乌恩师妹，马钰师弟、王凯皞师弟、刘玉铠师弟、刘子涵师弟的陪伴。

最后，感谢各位评阅专家的辛苦审阅，感谢你们提出了宝贵的修改意见，使我的工作更加完善。

感恩研究生期间遇到的一切！在三年期间，每一年都经历了新冠疫情，学校为了保障我们的安全，也采取了很多种措施，希望新冠疫情能够早日结束，打赢这场无声的战争。