

华北电力大学

专业硕士学位论文

基于非局部信息融合的轻量级超分辨率算法
研究

**Research on Lightweight Super-resolution Algorithm
Based on Non-local Information Fusion**

王天生

2022 年 6 月

国内图书分类号：TP751.1
国际图书分类号：004.8

学校代码：10079
密级：公开

专业硕士学位论文

基于非局部信息融合的轻量级超分辨率算法 研究

硕士研究生：王天生

导师：周登文教授

企业导师：陈光

申请学位：工程硕士

专业领域：计算机技术

培养方式：全日制

所在学院：控制与计算机工程学院

答辩日期：2022年5月15日

授予学位单位：华北电力大学

Classified Index: TP751.1

U.D.C: 004.8

Dissertation for the Professional Master's Degree

**Research on Lightweight Super-Resolution Algorithm
Based on Non-local Information Fusion**

Candidate:	Wang Tiansheng
Supervisor:	Prof.Zhou Dengwen
Enterprise mentor:	Chen Guang
Academic Degree Applied for:	Master of Engineering
Speciality:	Computer Technology
Cultivation ways:	Full-time
School:	School of Control and Computer Engineering
Date of Defence:	May, 2022
Degree-Confering-Institution:	North China Electric Power University

摘 要

为了在条件受限的情况下获得主观效果更好的高分辨率图像,往往采用超分辨率算法处理图像,来恢复图像细节,提升图像质量。深度学习方法的广泛的运用与发展,卷积神经网络尤其适合于图像任务,在超分辨率算法中出现较多的相关研究。然而一些性能优异的基于深度学习的超分辨率算法参数量和计算量都较大,难以在实际场景中应用,因此一些轻量级的模型提出,来解决这个问题。本文针对目前超分辨率算法中所存在的一些问题进行研究:

为了降低参数量和计算量,许多轻量级网络会减小模型主通道大小,在网络内压缩通道数,使得特征维度降低,非线性映射能力变差,影响模型性能。本文设计了一种基于 3D 卷积的轻量级卷积层,在参数量较小的情况下,保证了较大的特征维度,并根据提出的卷积层特性对网络的特征提取、特征映射和图像重建三个部分加以改进,在小参数量的情况下获得了较好的性能。最终对比实验得出,所提出的模型在参数量相近的模型中表现最优,参数量和计算量很均衡,补充的消融实验中探讨了不同网络超参数的设置对模型性能的影响。

自然图像中存在许多的跨尺度相似的图像块,可以利用相似图像块补充下采样丢失的信息;同时卷积层自身的计算方法限制,往往不能获得足够的感受野,利用较远位置的信息。为了充分利用图像中较远的、跨尺度的相似信息,文中设计了一个跨尺度非局部信息融合块。由于非局部算法往往计算量较大,不适合直接在轻量级网络,文中采用了局部敏感哈希的方式来降低在跨尺度相似特征搜索时的计算量,同时模块中利用了跨尺度的相似特征信息,可以更有效的帮助网络进行图像重建,更好的补充图像在降质过程中丢失的信息,获取更好的性能。最终的对比实验可以看出,与参数相近模型的比较获得优势,后续的消融实验也可以看出,在相对基线模型参数没有明显变化的情况下,性能得到了一定的提升。

关键词: 超分辨率; 3D 卷积; 非局部注意力; 局部敏感哈希

Abstract

In order to obtain high-resolution images with better subjective effect under limited conditions, super-resolution algorithms are often used to process images to restore image details and improve image quality. With the wide application and development of deep learning methods, convolution neural network is especially suitable for image tasks, and there are many related studies in super-resolution algorithms. However, some super-resolution algorithms with excellent performance based on deep learning have a large number of parameters and a large amount of computation, so it is difficult to apply in the actual scene, so some lightweight models are proposed to solve this problem. This paper studies some problems existing in the current super-resolution algorithms.

In order to reduce the number of parameters and the amount of computation, many lightweight networks will reduce the size of the main channel of the model, compress the number of channels in the network, reduce the feature dimension, worsen the nonlinear mapping ability, and affect the performance of the model. In this paper, a lightweight convolution layer based on 3D convolution is designed, which ensures a large feature dimension when the number of parameters is small. According to the proposed convolution layer characteristics, the network feature extraction, feature mapping and image reconstruction are improved, and a better performance is obtained in the case of the number of small parameters. Finally, the comparative experiment shows that the performance of the proposed model is the best in the model with similar number of parameters, and the number of parameters and the amount of calculation are very balanced. In the supplementary ablation experiment, the influence of different network hyper-parameters on the performance of the model is discussed.

There are many cross-scale similar image blocks in the natural image, which can be used to supplement the lost information of down-sampling; at the same time, due to the limitation of the calculation method of the convolution layer itself, it is often unable to obtain enough receptive field and make use of the information of the distant position. In order to make full use of the distant and cross-scale similar information in the image, a cross-scale non-local information fusion block is designed in this paper. Because non-local algorithms often have a large amount of computation and are not suitable for lightweight networks directly, this paper uses local sensitive hashing to reduce the amount of computation in cross-scale similar feature search. at the same time, cross-scale similar feature information is used in the module, which can more effectively help the network to carry out image reconstruction, better supplement the information lost in the process of image degradation, and obtain better performance. The final

comparative experiment shows that the comparison with the model with similar parameters has an advantage, and the subsequent ablation experiments can also see that the performance has been improved to a certain extent when there is no obvious change in the parameters of the relative baseline model.

Keywords: Super resolution, 3D convolution, Non-local attention, Locally sensitive hash

目 录

摘要	I
Abstract	II
第 1 章 绪论	1
1.1 课题背景及研究的目的和意义	1
1.2 图像超分辨率研究现状	2
1.2.1 基于插值的方法	2
1.2.2 基于重建的方法	3
1.2.3 基于学习的方法	4
1.3 本文研究的主要内容与章节安排	7
1.3.1 主要内容	7
1.3.2 章节安排	7
第 2 章 基于深度学习的图像超分辨率相关工作	9
2.1 相关深度学习理论	9
2.1.1 深度学习	9
2.1.1 神经元模型	9
2.1.2 激活函数	10
2.1.3 卷积神经网络	13
2.1.4 卷积层	14
2.1.5 池化层	14
2.1.6 反向传播与梯度更新优化方法	15
2.1.7 注意力机制	16
2.1.8 非局部信息融合算法	16
2.1.9 轻量级网络设计	17
2.2 基于深度学习的图像超分辨率	21
2.2.1 降质模型	21
2.2.2 深度学习图像超分辨率算法的网络结构	21
2.2.3 损失函数	23
2.3 图像超分辨率研究常用数据集	23
2.4 图像超分辨率算法评价指标	24

2.4.1 主观评价指标.....	24
2.4.2 客观评价指标.....	24
2.5 本章小结.....	25
第 3 章 基于 3D 卷积的轻量级卷积层设计	26
3.1 引言.....	26
3.2 基于 3D 卷积的轻量级卷积层及网络设计	27
3.2.1 整体网络设计.....	27
3.2.2 多路信息融合残差块.....	28
3.2.3 基于 3D 卷积的轻量级卷积层.....	29
3.2.4 渐进特征提取模块.....	30
3.2.5 轻量级上采样模块.....	30
3.3 实验内容与实验结果.....	31
3.3.1 实验数据集及训练参数设置.....	31
3.3.2 实验结果分析.....	31
3.3.3 消融实验分析.....	35
3.4 本章小结.....	36
第 4 章 跨尺度轻量级非局部注意力设计	38
4.1 引言.....	38
4.2 基于跨尺度信息融合的轻量级非局部注意力设计	40
4.2.1 整体网络设计.....	40
4.2.2 跨尺度非局部信息融合模块.....	40
4.3 实验内容与实验结果.....	43
4.3.1 实验数据集及参数设置.....	43
4.3.2 实验结果分析.....	43
4.3.3 消融实验分析.....	46
4.4 本章小结.....	46
第 5 章 结论与展望	47
5.1 本文总结	47
5.2 本文未来研究展望	48
参考文献	49
致 谢	56

第1章 绪论

1.1 课题背景及研究的目的和意义

二十一世纪,人类步入数字信息化时代,而近些年的 4G 和 5G 技术的推出,又进一步掀起移动通信的浪潮。如今,电脑、手机等智能终端设备已经成为众多家庭中不可或缺的成员,庞大的用户基础也推动着互联网的发展,在 IDC《数据时代 2025》研究调查里可以看到,全球互联网在 2025 年产生的数据体量可能会达到 175ZB。而带宽的增加,网速的提升,影像在互联网的影响也越来越大,据统计,2019 年互联网上每天会发出 30 亿张图片。图像作为一种高效率的信息传递形式,是一种比较直观的表达方式,也最符合人的感知习惯,用户发表图片也是当今社交媒体平台的主流分享方式。而图像分辨率的大小,往往决定这图像本身的质量,图像能包含多少的信息是由图像的分辨率决定的^[1]。图像的分辨率更高,往往会拥有更多的、更加真实的细节与纹理信息,图片的主观感受效果更好,而较低分辨率的图片往往丢失了大量的语义信息,有比较严重的失真,人的主观感受较差,获取更清晰的图像会带给用户更好的体验。但是在每日上传图像规模巨大的情况下,传输高分辨率图片会对网络带来较大负担。同样,目前多数借助深度学习^[2]解决的计算机视觉问题^[3,4],例如语义分割^[5,6]、人脸识别^[7,8]、图像分类^[9,10]、目标检测^[11,12]、图像语义理解^[3,13]等问题,都需要大量的高清晰度图片构建数据集。但是为了获取高质量的图像,需要各式各样的场景用以拍摄,摄影设备的要求较高,要耗费许多资源,且限制比较多。为了降低图像在网络传输的压力、提升用户对图像的视觉体验和更容易获取高分辨率图像,通过算法提升图像的分辨率也是近些年热门的研究课题。

图像的超分辨率重建^[14]是指采用低分辨率的单图像或一组图像来获取对应图像的高分辨率图像,从而提升图像质量。在网络中,可以通过发送低分辨率图像,在用户需要时再进行超分辨率来减少网络所需流量,或者在用户对当前分辨率图像不满意时提升用户体验;超分辨率技术的成本比较低,而低分辨率图像的获取难度要远低于高分辨率图像,可以采用超分辨率技术获取高分辨率图像,减小了硬件成本,更好的构建一个高质量的数据集,具有很广的应用前景。

超分辨率技术在多个领域都凭借其速度快而成本低的优势大放异彩,例如遥感监测^[15,16]、医疗卫生图像^[17]、计算摄影^[18]等。在遥感监测领域,由于卫星获取了多光谱遥感图像和丰富的空间信息,通过融合多光谱图像与空间信息,图像间相互补充,可以获得更高分辨率的遥感图像,更好的完成监测任务;在医疗卫生

图像中,超分辨率技术在常见的 X 射线图像^[19]、核磁共振图像^[20]和计算机断层扫描图像^[21]都能应用,并使图像质量获得一定提升,可以帮助医生更快的发现确定病灶,辅助医师提高诊断效率;而在移动终端时代大受追捧的计算摄影中,超分辨率技术更是常客,多视角图像合成超分辨率图像、多图像合成超分辨率图像、多焦距图像合成超分辨率图像,都是改善成像质量的热门算法,可以使用户获得更好的视觉享受,在拍摄设备受限的情况下得到高质量的图片。而在一些需要更高精度的场景,像是自动驾驶、监控摄像头追踪识别等方向,超分辨率可以帮助更好的完成这些视觉任务。所以图像的超分辨率技术具有较大的研究价值和探索空间。

传统的超分辨率采用插值的方式,例如最邻近插值^[22]、双三次插值^[23]等,以及迭代反投影^[24]、最大后验概率^[25-27]等基于重建的方法提升恢复效果。自新一波的人工智能浪潮开始,深度学习理论的蓬勃发展,计算机视觉相关领域和深度学习的结合,获得了相较于传统方法很大的性能提升,超分辨率领域也由此掀开了新的篇章^[28]。但是目前基于深度学习的多数超分辨率方法都对硬件有着较大的要求,计算量巨大,参数量庞大,而实际的使用场景往往存储与计算能力较小,尤其是手机、无人机等智能设备,所以轻量级的算法能够更好的在更多更丰富的场景中应用^[29],具有更贴合实际的应用价值。

1.2 图像超分辨率研究现状

图像的超分辨率问题的研究也有较长时间了,作为一个病态问题^[30],每一张低分辨率图像对应的高分辨率图像并不唯一,如何引入额外的约束和先验知识去保证超分辨率图像尽可能接近真实高分辨率图像一直是研究的重点。传统的超分辨率方法采用插值和重建的方式来获得高分辨率图像,随后基于学习的方法出现,而近些年深度学习方法在传统方法上获得了较大的提升。下文将对这三种方法进行简要的分析。

1.2.1 基于插值的方法

基于插值的方法是假设在图像中,相邻像素间语义具有一定的相关性,像素的变化具有连续性,假设高分辨率图像未知的像素点与其邻域的已知像素点有联系。通过计算得出已知像素点之间可能的像素值,插入已知像素点间,得到更高分辨率的图像所以叫插值。单张图像通过插值获得的高分辨率图像并没有引入额外信息,所以并非是超分辨率。多张图像的插值生成高分辨率图像中引入了额外信息,其假设为存在亚像素,即存在一个未被采样的中间像素点,通过图像配准

后,通过非冗余的图像内容计算像素点间的亚像素值,生成超分辨率图像。这里介绍单图像常用的三种插值方法,分别是最近邻插值^[22]、双线性插值^[31]和双三次插值^[23]。最近邻插值,像素间插入的像素为距离它距离最近的像素点的像素值,是最简单的插值方法,计算速度快,实现简单,但是插值后的图像边缘处会有锯齿效应,边缘过度不自然最终图像视觉效果差;双线性插值同时考虑了两个方向上的像素值,通过水平和竖直方向上的邻近的四个像素值计算插值,相较于最近邻,边缘过度平滑,不会产生锯齿,但是会导致图像过度模糊,缺少高频信息和纹理细节;双三次插值,扩充了插值邻域的大小,在 4×4 的邻域中采用两个三次多项式作为插值函数计算邻近16个像素值进行内插。相较于前两种方法可以产生更加平滑的边缘过度,但是计算复杂度要大很多。后来也有一些在这些方法上改进的一些算法,例如考虑纹理边缘方向的插值算法,在边缘处可以得到更好的效果;计算邻近像素变化的导数,来修正双线性插值的系数,获取更准确的内插值等。

总体上,基于插值的方法大多数比较简单,快速,而且泛用性强。但是其假设图像处处连续相关的假设并不完全成立,图像具有一些突变的边缘特征,不符合假设,而且在计算中没有利用图像中的先验信息,重建出来的图像往往过度平滑,边缘魔化,没有纹理细节,主观视觉效果较差。

1.2.2 基于重建的方法

基于重建的方法相较于插值,利用了图像中存在的先验知识,来估计高分辨率图像。通过对高分辨率到低分辨率的降质过程建模,反向推到如何由低分辨率图像得到高分辨率图像,对丢失的高频细节进行重建。下面介绍三种比较常见的方法:凸集投影法^[32]、迭代反投影法^[24]和最大后验概率法^[25]。迭代反投影提出了残差图的思想,将通过插值或别的方式产生的高分辨率图采用与获得低分辨率图在同样的方式下采样得到新的低分辨率图,即为投影,计算原始低分辨率图与新低分辨率图的差值,获得的差值图即为残差图,将低分辨率残差图同样计算得到高分辨率残差图,用以修正高分辨率图,得到新的高分辨率图,反复迭代,知道残差图小于一定的阈值停止迭代。该算法采用低分辨率图像作为约束,来提升重建效果,但是往往高分辨率到地分辨的降质过程是未知的,投影过程可能产生较大误差。凸集投影法假设从低分辨率图像得到的高分辨率图像的解空间具有一组凸形约束集合,约束后的空间相较于原空间会有更少的解。高分辨率图像中一个点的估计值为这些约束集合的交集内的一点,采用迭代的方法把任意一个的初始估计值向这些凸约束进行投影求得一个近似解,就可以获得高分辨率图像的一个估计。该方法利用了较多的先验知识,可以获得较好的重建效果,拥有较多细

节,但是计算比较复杂,收敛速度较慢,而且选取的初始值不同会影响最终的重建图像,解是不唯一的。最大后验概率法采用贝叶斯理论,假设高分辨率图像可以看作是一个统计估计问题。假设超分辨率模型为:

$$y = Dx + v \quad (1-1)$$

式中 y ——低分辨率图像;

D ——降质矩阵与下采样操作;

x ——高分辨率图像;

v ——噪声,那么超分辨率过程就是这个模型的逆问题。

对于高分辨率图像的最大后验概率估计为最大化后验概率 $P\{x|y\}$, 假设 $\hat{x}_{MAP}$ 为 x 的最大后验方法, 则:

$$\hat{x}_{MAP} = \arg \max_x P\{x|y\} = \arg \max_x [\log P\{y|x\} + \log P\{x\}] \quad (1-2)$$

式中 $\log P\{x\}$ ——对数先验模型。通过获取有效的图像先验信息再对高分辨率图像进行估计,重建的高分辨率图像拥有较好的边缘,但是需要保证先验信息的选取是有效的,而且图像矩阵往往较大,整体计算量偏大,收敛速度慢。

总体而言,基于重建的方法在插值的思想下,结合了图像的先验信息,用已知的像是边缘、纹理等先验信息帮助高分辨率图像的重建,可以获得真实的纹理细节和图像边缘,但是由于单张图像上能获取的先验知识有限,低分辨率图像本身就缺乏高频细节,得到的高分辨率图像仍然存在边缘平滑,细节模糊的情况,且本身依赖于初始值的选取。

1.2.3 基于学习的方法

从没有先验,到利用图像先验,虽然提升了图像的质量,但是仅仅利用一张图像的先验知识是不够的,其一是单一图像包含的特征较少,其二是低分辨率图像本身就缺少高频特征,对于高分辨率图像的重建帮助较少,如果能够构建一个库,里面为低分辨率特征所对应的高分辨率特征,通过查找的方式利用高分辨率图像来重建高分辨率图像,可以获得更好的效果,基于学习的方法由此出现,也成为热门研究邻域。建立一个拥有低分辨率和配对高分辨率的数据集,整体或局部的对低分辨率特征进行学习,并探寻与对应高分辨率图像的映射关系,通过引入先验知识与约束条件来获得接近真实高分辨率图像。基于学习的方式在训练的过程中获取了高分辨率特征,对于补充高频信息具有很好的效果,边缘更加锐利,清晰。虽然搭建模型复杂,需要一个大型数据集,而且训练时间长,但是一旦完成训练,对于单图像的超分辨率的计算较快。

早期的一些基于学习的方法有基于样例学习的方法^[33],基于邻域嵌入的方

法^[34]和基于稀疏表示的方法^[35]等。基于样例学习的方法最直观，制作对应的低分辨率和高分辨率图像块，作为构建的样例库，划分的块越大，计算复杂度越高，但是越不容易受噪声影响，训练的时候从中找寻与目标低分辨率图像的图像块最接近的在样例库中的低分辨率块，并将对应的高分辨率块提取出用以补充目标图像高分辨率图像的高频信息，完成重建。这种方法由于直接引入了高频细节来补充重建图像，会比只从低分辨率图像获得信息取得更好的效果，但是自然图像中存在的特征的数量是十分庞大的，构建的样例配对图像不会往往不会和目标图像完全一致，如果没有丰富的数据，很有可能匹配出相差较远的高频特征，且在特征融入的时候，在不同块之间会出现比较明显的边界效应，还需要对图像块根据周围信息再处理；基于邻域嵌入的方法在处理上相较于样例学习考虑了更多样本，每个低分辨率图像块都会找出 K 个近邻图像块，并且引入了几何流形的概念，假设高分辨率块和低分辨率块的包含的几何流形结构应该是相似的，计算出 K 个近邻图像块与目标图像块的相似系数，作为加权系数，最终对应的高分辨率图像块加权融合获得目标的高分辨率图像块。类似于将一个特征用了不同的特征来表示，然后在线性组合起来得到目标特征，可以减小数据集的规模，也更加灵活，更加符合图像本身的内容，但是由于是多个特征的平均，生成效果上会更模糊一点；基于稀疏表示的方法需要构建一个通过稀疏表示检索的字典，首先制作一些高分辨率块，由于图像中存在一些冗余信息，可以进行压缩，对这些高分辨率块进行稀疏表示，对于想要重建的低分辨率图像块对应高分辨率块也进行稀疏表示，计算与其他特征的相似程度，计算出不同高分辨率特征的稀疏系数，在字典中通过不同特征对应的系数进行加权组合获得合成目标高分辨率图像块。稀疏表示对于完备字典的构建要求比较高，很难广泛用以多数多种类的图像进行超分辨率。

随着深度学习的快速发展，深度神经网络在多个邻域都开始崭露头角，卷积神经网络^[36]和 Transformer 结构^[37]对特征的提取都很有成效，并且可以在隐空间中学习从低分辨率到高分辨率的映射关系，而网络的发展，算力的提升，很容易构建一个容量巨大的数据集进行高效的学习。Dong 等最早提出采用三个卷积层组建的超分辨率网络 SRCNN^[38]，将特征提取，低分辨率到高分辨率特征映射和图像重建分别用一层卷积实现，输入图像为已经通过插值放大的图像，是一个完整的基于卷积神经网络构建的模型，也奠定了后续相关网络设计的框架；SRCNN 只有三层，非线性映射能力较弱，为了提升性能，Dong 等改进提出了 FSRCNN^[39]，增加了网络深度的同时改变了输入低分辨率图像，最后在图像重建的部分引入了上采样层，采用反卷积的形式对特征图进行放大。输入低分辨率图像减小了模型的计算压力，后续的模型也基本延续了这个方式，但是采用的反卷积会导致高分

分辨率图像出现棋盘效应,会出现大片的色块;为了改善棋盘效应,提升计算速度,ESPCN^[40]采用亚像素混淆的方式替换掉反卷积上采样,采用了空间存在亚像素的假设,将通道上邻近的特征图看作亚像素图,排序后依次将特征图填充到高分辨率图中,得到高分辨率图的过程是没有参数和计算量的,但是生成亚像素图需要对通道数按放大倍数的平方数进行倍增,参数量还是比较大的。

早期的网络层数都不多,深度小,计算快,效果相较于传统的插值和重建的方法已经有了较大改进,后续的网络为了提升性能,逐渐加深网络,而随着ResNet^[41]的出现,超分辨率领域也借鉴了残差学习的方法。VDSR^[42]类似于VGG16^[43]的设计,并且引入了残差学习的思想,类似于迭代反投影使用残差图,其实插值的图像相差于真实图像多数是符合的,只有边界纹理恢复的不好,网络一条支路插值获得高分辨率图像,加入了全局残差,让含参数的网络主体学习插值图像的补充,相当于计算目标高分辨率图像与插值高分辨率图像的残差,这样的方式大大减小了需要学习的特征,并使中间的特征图变得稀疏,只保留更有用的特征,排除了无关特征的一些,加快了网络的收敛速度,提升了性能;DRCN^[44]在全局残差的基础上,采用了递归的形式,在参数量不改变的情况下加深网络,提升了网络的感受野和非线性映射能力;DRRN^[45]在全局残差的基础上加入了局部残差,使用跳跃连接在内部构建残差块,并实现对残差块的递归,获得了比DRCN更好的效果;LapSRN^[46]采用了图像金字塔的结构,逐级对图像放大,但是每次计算的参数可以复用,并对损失函数进行了改进,一个网络可以得到多个尺度的图像,但是放大倍数受到限制,只能在特定倍数输出;SRResNet^[47]引入了密集连接块,在块的内部采用密集连接,减缓了随着网络加深信息丢失的问题,最后将所有块的输出作为最终输出,压缩通道数后进入上采样层,大大加深了深度;SRGAN^[47]首次在超分辨率领域采用了生成对抗网络,并采用感知损失作为优化,获得了较好的主观效果;EDSR^[48]在SRResNet的基础上取消掉了批归一化层,论文通过实验发现批归一化操作会拉平像素间的差异性,对于超分辨率这种像素大小敏感的问题并不适用;DBPN^[49]借鉴了迭代反投影的思想,在网络内部多次的进行上下采样,并在不同尺度间采用跳跃连接,来纠正错误的信息。

加深网络带来的性能提升随着深度加大逐渐减小,受SENet^[50]的启发,逐渐开始引入注意力机制。RCAN^[51]构建了三种不同跨度的残差块,并在残差块的最后加入注意力层,多个残差块进行短的跳跃连接,模型头尾进行长的跳跃连接,提升了模型性能;SAN^[52]受非局部神经网络的启发,引入了非局部注意力,添加在模型的头部和尾部,并提出了二阶注意力,进一步提升了重建效果。

还有一些别的工作也取得了不错的效果。DRN^[53]采用了UNet^[54]的结构,并对获得的超分辨率图像下采样获得低分辨率图,在计算损失函数时也考虑低分辨

率图的偏差程度,作为一种额外的约束,为了估计降质过程,下采样采用的是卷积层而非传统插值方法; IGNN^[55]利用了跨尺度非局部相似图块,在图像自身寻找跨尺度的匹配的低分辨率到高分辨率图像对,用来模型的信息补充; SwinIR^[56]将 Transformer 引入超分辨率,同时结合了卷积层运算快,提取特征能力强的优势,降低了参数量的同时,在超分领域又获得较大提升,缺点在于全局计算的时间复杂度比较高,计算量大,计算速度慢,且由于 Transformer 的特殊计算方式,对于图像尺寸的敏感性比较大,通用性降低。

1.3 本文研究的主要内容与章节安排

1.3.1 主要内容

许多表现优异的超分辨率算法在实际应用中都存在困难,算法模型参数大、计算量大,在面向实际资源受限的设备时往往很难直接加以应用,轻量级算法更加具有优势。多数轻量级算法会选择减少网络通道数来减少参数量,但是这样会较大损失性能,本文提出一种基于 3D 卷积设计的轻量级神经网络,参数更少,特征维度更大,性能更好。

基于卷积神经网络设计的超分辨率算法,由于卷积操作只能计算图像一部分临近的特征,对较远位置的特征难以利用,不能很充分的覆盖图像所有区域。自然图像往往内部具有很强的规律性,甚至在同图像上存在跨尺度的相似特征,这些相似信息可以很好的弥补在高分辨率图像下采样时丢失的信息,也就是采用非局部的算法进行计算。非局部的方法计算量较大,本文提出一种跨尺度的非局部信息融合算法,并进行了轻量化改进,以适合轻量级网络使用,提升了网络性能,获得更好的图像质量。

1.3.2 章节安排

本文含有五个章节,以下为全文组成情况:

第 1 章为绪论,介绍了课题的背景以及研究现状,分析了该课题的实际意义,应用价值,并对目前本领域的研究现状做了综合的回顾和分析,对本篇文章的主体工作安排简要介绍。

第 2 章为本文相关工作的基础知识,会介绍深度学习的相关知识,并对深度学习的超分辨率领域的研究方法做了简要说明;对较为经典的深度学习超分辨率工作做了一个回顾;介绍了常用的损失函数,并对其优劣做了分析;随后介绍了在超分辨率领域常用的数据集;最后对常用来评价模型性能优劣的主观和客观指标做了简短介绍。

第3章主要介绍采用3D卷积设计的轻量级卷积层，本章开始分析了目前轻量级模型常常压缩通道大小以降低参数量，往往会引起的性能下降的问题，介绍了基于3D卷积设计的轻量级卷积层，在拥有较大特征维度的同时没有带来显著的参数量提升；本章对网络的三个部分做了详细介绍，并介绍了如何采用3D卷积在模型的不同阶段降低模型的参数量和计算量；最后对比了同参数量下模型的性能，本章方法取得了较好的结果，并对网络中不同超参数的设置开展了消融实验

第4章主要介绍非局部注意力机制的设计，首先对近年经典的超分辨率领域的非局部注意力的方法做了总结；为了解决卷积操作感受野受限，信息利用不足的问题，同时为了避免非局部操作带来的大量计算量的提升，本章提出了采用局部敏感哈希设计的跨尺度非局部信息融合模块；最后实验部分对比了同参数模型的性能，本章方法性能优异，并对模块对于网络的提升开展了消融实验。

第5章为总结与展望，对全文的提出的方法和工作做总结，同时展望本文方法可能的未来的研究方向，对研究中还有亟待解决问题和不足做简短的分析。

第2章 基于深度学习的图像超分辨率相关工作

深度学习的方法已经在超分辨率获得了超过传统方法较多的效果。通过构建大规模数据集和反向传播的学习方法,让模型自己学习到低分辨率到高分辨率的映射方式。本章会对深度学习相关理论做介绍,随后介绍在超分辨率领域深度学习如何解决问题,并对有代表性的相关工作做简单描述,最后给出在超分辨率任务中所需数据集和评价指标。

2.1 相关深度学习理论

人工智能浪潮始于1956年,在后来的几十年时间里经历了三起三落。早期的逻辑主义,但是通过推理与证明定理建立的模型只能解决一些简单的问题。随后伴随人工神经网络的提出,开始出现联结主义,反向传播人工神经网络更是取得了较大的成果,机器学习的概念开始盛行,在多个模式识别领域开始应用,但是由于早期模型都比较简单,面对复杂的问题还是力不从心,而且模型训练学习所需要的数据量庞大,计算量巨大,而且很多结果很快收敛不再提升。2006年,Hinton提出了深度信念网络,多隐含层的人工神经网络网络有很强的特征学习能力,深度学习拉开帷幕。随着高性能计算机和图形处理器的飞速发展,模型的训练速度大大加快,互联网浪潮的到来,每天都在产生庞大的数据量,数据的收集变得唾手可得,越来越多的深度学习框架提出,提升了解决问题的效率,让深度学习在多个领域发光发热。

本小节将对深度学习相关知识做简要介绍,尤其是计算机视觉领域应用比较广泛的卷积神经网络和一些常用的层。

2.1.0 深度学习

在人工神经网络中,通过对特征进行非线性运算后,可以将特征映射到更高维的空间,变成更抽象的特征,反复操作,理论上神经网络可以拟合任意复杂的表征函数。深度学习是相对早期的浅层神经网络而言的,整体结构也是类似的,由输入层、隐含层和输出层组成。每个隐含层都包括一组神经元和激活函数。

2.1.1 神经元模型

人工神经元模型^[57]的建立借鉴了生物学上神经元的结构,每个神经元接收多个其他神经元的输入,计算后通过激活函数引入非线性操作,再将输出通向下一

个神经元。示意如图 2-1。




图 2-1 神经元模型

2.1.2 激活函数

为了获得更强的非线性拟合能力，往往会在神经元的输出加一个激活函数，根据神经网络万能近似定理：如果一个前馈神经网络具有线性部分和至少一层非线性部分，且该网络具有充分的隐藏单元，网络可以以任意精度来近似任意一个从一个有限维空间到另一个有线维空间的 Borel 可测函数。常见的激活函数有 Sigmoid 激活函数^[58]，Tanh 激活函数，ReLU 激活函数^[59]及它的变种等。

Sigmoid 如图示 2-2 所示，表达式如式(2-1)所示。




图 2-2 Sigmoid 激活函数

$$f(x) = \frac{1}{1 + e^{-x}} \tag{2-1}$$

Sigmoid 函数的输出固定在 0 到以 1 之间，函数左侧趋近于 0，右侧趋近于 1。输入值趋近于负无穷与正无穷时，函数的导数都趋近于 0，在输入值为 0 时

函数的导数值最大，导致在梯度更新时，过大过小的激活值使都只能参数获得较小的更新，很难收敛趋近全局最优值。

Tanh 如图 2-3 所示，表达式如式(2-2)所示。




图 2-3 Tanh 激活函数

$$f(x) = \frac{\sinh x}{\cosh x} \quad (2-2)$$

Tanh 函数的变化区间更宽一些，比 Sigmoid 的收敛速度快一些，但是两端的导数同样趋近于 0，较大较小的激活值产生的梯度变化也较小。

下面介绍 ReLU 激活函数及改进的激活函数：

ReLU 函数也叫线性整流单元，是目前既简单应用又广泛的激活函数，是一个简单的分段函数构成，输入值小于等于 0 时恒输出 0，也就是负值抑制，大于 0 的输入保持不变输出，大于 0 的激活值都可以给参数带来较大的梯度更新，但是一旦激活值为 0，则完全没有梯度更新，容易导致神经元死亡，再也不更新，模型没有提升，神经元利用率低，表达式如(2-3)所示，函数如图 2-4 所示。

$$f(x) = \max(0, x) = \begin{cases} 0 & x \leq 0 \\ x & x > 0 \end{cases} \quad (2-3)$$

为了改进 ReLU 的性能，后来有很多的相关工作提出，ReLU 的效果比较好是其使部分激活值为 0，使得特征分布变得较为稀疏，类似于一些增加对于参数正则化的训练操作，使得每个神经元能够更好的独自参与计算，减少了网络的过拟合情况。后续对于 ReLU 激活函数的改进在保持较快的计算速度的情况下，缓解了较多神经元死亡的问题。

LeakyReLU 并没有向 ReLU 将负值部分完全抑制，而是人工给定了一个很小的系数乘以负值，允许在输出为负值时获得一个较小的激活值，保证在负值的情况下也有一定的信息量通过，获得梯度更新，表达式如(2-4)所示，函数如图 2-5 所示。




图 2-4 ReLU 激活函数




图 2-5 LeakyReLU

$$f(x) = \begin{cases} vx & x \leq 0 \\ x & x > 0 \end{cases} \quad (2-4)$$

PReLU^[60]在 LeakyReLU 上加以改进，LeakyReLU 是人工选择的负值系数，PReLU 将其改进为可以学习的参数，这样每个神经元都可以用不同的系数控制

负值的通过程度，表达式如(2-5)所示。

$$f(x_i) = \begin{cases} a_i x_i & x \leq 0 \\ x_i & x > 0 \end{cases} \quad (2-5)$$

为了获得较好的收敛速度，激活函数的输出分布最好均值为 0，且激活函数单侧饱和。ELU 不同于上述的线性变换，无法同时满足以上两个条件，它在负值引入了一个非线性变换部分，保证负值部分允许通过的同时使输入逐渐减小时梯度趋近于 0，保证单侧饱和，表达式如(2-6)所示，函数如图 2-6 所示。




图 2-4 ELU 激活函数

$$f(x) = \begin{cases} v(e^x - 1) & x \leq 0 \\ x & x > 0 \end{cases} \quad (2-6)$$

2.1.3 卷积神经网络

1980 年 Fukushima 提出了第一个卷积神经网络^[61]。其借鉴了人类的视觉系统，人类视觉对图像的响应是从简单的线条纹理一步步到抽象的更高层复杂细节，并引入了传统图像处理中卷积核的概念，用卷积核提取特征，结合神经网络逐级非线性映射的形式，每层堆叠若干组卷积核作为神经元，并通过池化逐步减小特征图尺寸模拟人类视觉抽象的过程，但是由于当时硬件水平较差，也没有参数共享，最终效果也不佳，此类方法沉寂多年。直到 1990 年，LeCun^[62]将反向传播梯度学习方法引入卷积神经网络来解决手写数字识别问题，大大提升了效果，并采用了同层参数共享，减小了参数量。相较于早期的全连接神经网络，卷积神经网络参数更少，计算更快，对图像尺寸不敏感，却能有效的提取图像中的特征，

自此卷积神经网络广泛应用于图像处理的任务。但是早期的网络较浅，只能解决较简单的识别问题，更复杂的图像分类的问题效果一般，而后随着网络的加深，取得了更好的效果。

2.1.4 卷积层

与全连接网络采用全连接层不同，卷积神经网络采用卷积核设计了卷积层，用卷积核和卷积操作在图像上提取特征。特定尺寸的卷积核在图像上按照规律进行滑动。卷积核参数和图像上特定区域的特征值进行计算。从传统图像处理的操作上讲，卷积层的计算方式实际上为相关，但是由于卷积核参数是可学习，随机给定的，并没有明确的计算顺序，将参数顺序颠倒，所以可以也看作是卷积。具体操作位卷积核参数与特征图对应位置特征值相乘之后再求和，得到计算的输出特征图对应值。

卷积操作会导致图像变小，所以需要在特征图参与计算前加入补丁，在图像的周围填充一些值，填充 0 则为零填充，也是最常用的填充方式，其他还有反射填充和镜像填充等。

卷积层能够减小参数量和计算量，是因为卷积核在同一层特征图的不同位置是共享的，无论图像尺寸多少，参数量也不会发生改变。相较于将图像拉伸成一维全连接计算，卷积操作只能在计算邻近若干特征值，不能充分利用图像的信息，也就是当前层的感受野大小是与卷积核尺寸一致的，但是特征周围的值会随着卷积操作与当前特征融合，下一次计算时理论上已经获取了距离更远的特征，随着网络层数的加深，感受野会逐渐变大，一定程度上减少了每一层计算利用信息少的问题，获得了较好的效果。




图 2-5 卷积层操作示意图

2.1.5 池化层

池化层主要是为了减小特征图尺寸，让网络获取了不同尺度的特征图信息，

变相的增加了下一层的感受野，并方便后续的操作。一般常用的池化操作有两种，均值池化和最大值池化。




图 2-6 池化层操作示意图

均值池化是求一个窗口内特征值的均值，作为池化后的值，对于背景和大面积的平滑区域有较好的保留作用；最大值池化是取一个窗口内的最大值，保留激活值较大，影响较大的特征。池化减小了图像维度，可以提取更值得关注更有效地信息，更好的抑制了过拟合。

2.1.6 反向传播与梯度更新优化方法

神经网络的训练过程分为前向传播和反向传播，前向传播即为模型推理，将输入值经过各个隐含层的神经元逐步计算得到最终输出。反向传播也就是梯度更新，模型学习的过程，定义好合适的损失函数，计算输出值与标签的值的差值，将差值回传，根据链式求导法则，获取每一层参数的更新值，是差值下降，模型趋于收敛，往往会得到很接近全局最优的局部最优值。

参数的更新策略，则是采用梯度下降法。反向传播中每层根据链式法则求解出参数变化的梯度，给定一个学习率 η ，作为参数更新变化的步长，参数每次在计算的梯度的方向上更新一个步长，直到模型收敛。

早期的梯度更新采用的是批量梯度下降和随机梯度下降。批量梯度下降是将数据集所有样本计算完后再更新，所以每一次更新所有样本都有贡献，会获得比较大的更新幅度，同样容易在全局上达到较优，但是更新速度太慢；随机梯度下降每次只训练一个样本更新，为了防止数据选取顺序对网络形成干扰，导致过拟合，所以随机采样，每一次更新的梯度比较小，但是每次的更新是朝着局部最优走的，模型收敛会减慢，还容易陷入局部最优值。用的最多的形式是小批量梯度下降，每次训练若干个样本进行更新，获得比随机梯度下降更快的收敛速度，比批量梯度下降更快的学习效率，虽然每次更新仍然是局部最优，但是不容易陷入局部最优，训练次数足够大整体是朝着全局最优更新的。

在训练中可能会遇到梯度为 0 但并非最优的点，也就是马鞍点，此时模型无法更新，陷入局部最优，为了改善这个问题，提出了牛顿法，通过海塞矩阵计算二阶导数，但是计算量太大，实际应用较难。后续提出了累积梯度的概念，也就

是动量法，每次梯度还要加上之前更新时累积的梯度，作为动量，但是更新越近的梯度权重越大，越久以前的梯度权重越小，这样遭遇鞍点梯度也不会为 0，可以继续更新。目前采用最广的是 Adam 算法，在计算动量的同时还计算了每个参数自适应学习率，可以很快的收敛而不陷入局部最优。

2.1.7 注意力机制

2016 年 SENet^[63]提出，注意力机制逐渐被多数模型使用。SENet 更加关注通道间的关系，类似于人看待一副图像，有更关注的地方和不怎么关注的区域，SENet 希望模型能学习不同特征的不同重要程度，来得到不同通道的权重，激活后与对应特征图相乘，让模型更加关注重要的特征，对不重要的特征镜像抑制。而且 SE 模块即插即用，可以嵌入到大多数目前的网络中。

受到自然语言处理领域自注意力和传统图像领域中非局部均值思想的启发，2018 年非局部神经网络^[64]提出，设计了适合图像自注意力方法。非局部神经网络设计了一个具有全局感受野的非局部模块，计算了空间上不同像素值之间的相关关系，归一化作为权重进行空间上的信息融合。卷积层的堆叠虽然会扩大感受野，但是随着激活函数的抑制作用，以及卷积不停的稀释较远特征的占比，加深网络对感受野的提升是有限的，非局部模块则实现了全局信息的利用，但是整体计算量及其巨大，很难直接使用。

2.1.8 非局部信息融合算法

2.1.8.1 基于自注意力方式的非局部信息融合方法

传统图像处理方法中已经有了非局部的思想，最近有一些工作把非局部均值的操作进行改进，加入了神经网络当中，来提升模型的性能。

NLNN 结合了传统图像处理的非局部均值的思想与自然语言处理领域的自注意力操作，加入用以图像处理的深度学习算法中，提出了一种即插即用的非局部计算模块，来对图像空间上的特征，甚至是不同图像间的特征建立起长距离的依赖关系，可以很方便的应用在已有算法上。但是对于每一个位置的特征都需要计算剩余所有位置特征的相关性，且并没有将特征间的距离作为一个影响因素来进行考虑，计算量较大。

DANet^[65]提出了采用自注意力机制的通道与空间注意力。通过对特征的维度变换，可以对通道与空间分别计算自注意力，通道自注意力机制用来计算不同通道间的相关性，空间自注意力来捕获长距离特征依赖，获得了较好的效果。

CCNet^[66]提出了一个 criss-cross 的自注意力模块，该模块没有对每个位置的

特征都计算与所有的特征的相关性，仅考虑同行同列的所有特征，将计算复杂度从 $O(H \times W \times H \times W)$ 降低到了 $O(H \times W \times (H + W))$ ，同时为了保证能计算到所有位置特征的相关关系，文中提出连续经过两次该模块计算，获取更好的性能。

2.1.8.2 基于相似特征搜索与融合的非局部信息融合方法

自注意力在计算时涉及全图范围的所有特征，计算一个相关矩阵，往往是图像尺寸的平方大小，占用大量的算力和内存，后续的改进也是着重于降低中间变量的大小；其次虽然计算了全图的特征，但是对于空间上的特征仅仅考虑了彼此之间的相关性，但是没有考虑特征的空间距离，较远的特征可能和当前特征语义上相差较远，尽管相似，但是并没有太大的相关性，相当于噪声，不能对图像恢复起到较好的作用。

针对上面的几个问题，近年来提出了若干方法。传统图像处理中的非局部均值，仅仅计算目标特征一个固定窗口大小内的特征相关性，假定较远的位置特征可利用信息较少，借鉴这样的思想可以改进非局部的计算范围，减小计算量；查找算法上可以优化来提升计算速度，采用 K 临近(KNN)匹配来选取可能最接近的 K 个特征，可以大大的提升计算速度，最邻近神经网络提出了连续的确定性松弛的 KNN 算法，使算法可微。

IGNN 将相似特征用图数据结构进行表示，图的边长即为相似特征间的距离，结合了可微的 KNN 算法；文中提出自然图像具有丰富的跨尺度相似特征，之前的非局部方法单纯在单尺度进行计算，同尺度中的有效信息有限，无法获得更好的效果，扩展搜索维度可以获得更有效的消息。IGNN 对图像进行跨尺度相似图像块采用 KNN 算法进行搜索匹配，减小了计算量，随后对不同距离和相似度的图像块计算相似权和距离权，并对寻找出的图像块进行图像配准，对纹理信息有更好的恢复作用。

2.1.9 轻量级网络设计

现实场景中应用超分辨率算法的往往是一些移动端或物联网设备，它们自身拥有的算力有限，目前的深度学习算法较难直接在这些设备上应用，轻量级网络的参数量更小，计算量更少，推理时间更快，更适合实际应用。

2.1.9.1 轻量级网络结构设计

超分辨率的轻量级网络结构设计，可以分为架构的设计，轻量级卷积层的设计，轻量级注意力的设计和轻量级上采样层的设计。

(1)递归网络 递归网络的设计是采用同样的模块对于一个低分辨率图像迭代的、多次的超分，已达到目标图像大小。通过递归的形式学习图像中的高级特

征, 同时在训练时递归的更新网络中的参数。

深度递归卷积网络 DRCN 采用递归网络在没有增加额外参数的情况下, 仅仅使用了一个卷积层, 使感受野达到了 41×41 , 与超分辨率卷积神经网络 SRCNN 相比(13×13)获得了较大的提升。深度递归残差网络 DRRN 使用了 ResBlock 作为递归模块的一部分, 总共用了 25 次递归, 获得了比原模型更好的性能。基于记忆块的网络 MemNet^[67]包含了 6 个递归的 ResBlock。级联残差网络 CARN^[29]也使用 ResBlock 作为递归单元。最近的一种双态递归网络 DSRN^[68]中, 除了采用了端到端的递归, 内部中采用了高低分辨率特征图的分支, 在分支之间也采用递归。

总体而言, 递归学习网络减少了网络参数量, 以更高的计算量为代价, 来学习丰富的图像特征。此外, 由于计算量的增加可能会导致梯度的爆炸或者消失, 所以递归学习通常与多监督学习和残差学习相结合, 减小梯度爆炸和梯度消失的风险。

(2) 残差网络 自残差网络 ResNet 提出以来, 残差学习广泛的应用于超分辨率领域。总体而言, 残差学习有两种, 一是局部残差学习, 一是全局残差学习。由于可以将低频信息便捷的通过, 使网络更容易的学习复杂的高频信息, 可以有效减小参数量。

局部残差学习有效的缓解由于网络加深而导致的退化问题, 及梯度弥散。此外, 局部残差学习还提高了学习速度, 降低了训练难度, 在超分辨率领域有着很高的使用频率。

全局残差学习是一种输入与最终输出相关的方法, 尤其是在超分辨率领域, 输出图像与输入图像是高度相关的, 因此学习低分辨率图像与高分辨率图像之间的全局残差在超分辨率中具有重要的意义。在全局残差学习中, 模型通过在低分辨率图像中生成缺失的高频细节, 将低分辨率图像转换为高分辨率图像的残差映射。此外, 残差往往是比较小的, 大大的降低了全局残差学习的训练难度和模型复杂度。

总体而言, 局部残差和全局残差都使用残差连接输入和输出。全局残差将模型输入与输出直接连接, 局部残差学习将不同深度的各个层的输入与输出相连。

(3) 密集连接网络 密集连接也是超分辨率中经常使用的方法, 如 DenseNet^[69]。密集块将先前层生成的缩影特征图连同当前特征图作为输入, 也就是说第 k 层要连接 $k(k-1)/2$ 层。使用密集连接提高了特征的重用性, 同时解决了梯度消失的问题。此外, 密集连接可以压缩通道数来减小模型大小。超分辨率中采用密集连接来连接低层和高层的特征图, 以重建更高质量, 更加精细的高分辨率图像。SRDesnseNet^[70]提出了一个 69 层的网络, 包含了若干的密集块, 密集

块之间采用密集连接,同时密集块内部含有数个密集连接的层。RDN^[71],CARN,MemNet 和 ESRGAN^[72]都使用了密集连接,DBPN 仅仅在上下采样单元里使用了密集连接。

(4) **多路径网络** 多路径学习中,对于不同的特征表示,使用多条路径传递特征,这些路径或者交叉融合,或者在后续组合以获得更好的性能。主要有尺度相关的,局部的,全局的多路径学习这几种形式。

对于不同的尺度,超分辨率模型使用不同的特征提取。多路径学习的多尺度信息提取充分的利用了图像信息,同参数量下可以获得更好的效果。

在 EDSR 中作者提出了一种基于单一网路的多尺度多路径学习方法。模型的中间层共享,作为特征提取层,而针对于特定尺度的路径(包含了预处理和上采样过程)位于模型的开头和末尾,即网络的开始和结束。在训练过程中,尺度的相对路径相应的被启用和更新,并提出了 MDSR 方法。因为各个尺度的特征提取部分参数共享,从而减小了整体模型的参数量。与 MDSR 类似,CARN 中也采用了类似的多路径方法。

局部多路径学习的灵感来自于 MSRN^[73]中采用的多尺度特征提取模块。模块中分为两个分支,分别采用 3×3 和 5×5 的卷积层进行不同尺度的特征提取。在合并两个卷积层的输出后,最终通过一个 1×1 卷积进行融合。使用这种局部的多路径学习可以更有效地提取特征。

多路径学习的另一种变体是全局多路径学习,使用相互交叉融合的多路径信息来提取特征。在 DSRN 中,有两条提取低层和高层信息的路径,在 PRSR 中,条件路径负责提取全局结构。则采用了不对称结构来提取特征。

(5) **神经网络架构搜索** 神经网络的超参数设置一直是个亟待解决的问题,超参数主要分为两类,一是训练网络定义的参数,一是网络本身的参数,其维度高,离散且相互依赖。前一种调参属于超参数优化,而后一种网络结构调整则一般称为网络架构搜索。一般步骤为:确定结构参数空间,然后列出可能的结构参数调整,评价其带来的变化,由得到的变化确定下一步方向。由于对整体网络的优化很好,所以在较少的参数和较为精简的模型时也能很好的发挥模型性能。

2.1.9.2 轻量级卷积层设计

轻量级的卷积层设计也是今年来比较热门的方向,通过巧妙的设计卷积运算,在减少参数的情况下保证网络性能。或者是采用一些等价的操作来简化计算。深度可分离卷积先执行一个在空间上的卷积,保持通道独立,然后在进行深度上的卷积操作,融合通道信息,将普通的卷积操作拆解为两个独立的操作,较大的减小的计算量。小尺寸的卷积核参数量较小,但是其感受野也减小了,对于计算机

视觉任务,更大的感受野往往能获得更好的性能,所以提出来就大卷积拆分为小卷积,通过加深网络的形式提升感受野。组卷积的最早提出是受限于硬件资源和计算能力,不能将所有操作在一个 GPU 上处理,所有将特征图分给多个 GPU 运算,之后再融合。也能很大的减小参数。如果网络中涉及了大通道变化,可以采用瓶颈层降低参数,瓶颈层中间采用小卷积核压缩通道数,采用大卷积核进行卷积操作,随后再通过小卷积核恢复通道,既保证了性能,又减小了参数量。蒸馏层类似于瓶颈层,会有通道压缩的过程,希望能获得更稠密的中间特征图,提升卷积层对特征的表达能力,但是蒸馏层会同时将剩余的通道信息往下传递,而不像瓶颈层仅仅传递压缩后的信息。

2.1.9.3 轻量级注意力机制

在超分辨率中,采用注意力机制可以帮助网络更好的学习,提升模型的性能。通道注意力通过全局均值池化来压缩特征图大小;空间注意力在通道上做全局均值池化来压缩通道数。RCAN 中引入了注意力机制,性能提升明显。SAN 采用了二阶通道注意力。采用了局部和非局部的注意力模块,同样,在 SAN 中,网络使用非局部注意力来提取较远的上下文信息。

2.1.9.4 轻量级上采样层

近年来针对深度卷积神经网络提出了若干种可学习的上采样层,亚像素卷积一种可学习的端到端的上采样方法,是近年超分辨率算法中采用最较多的方式之一;反卷积层也称为转置卷积层,会进行卷积的逆运算,基于来自的低分辨率图像的特征映射来预测可能的真实高分辨率图像,反卷积在超分辨率也有较为广泛的利用;元上采样模块的提出,可以使网络以任意放大比例来生成高分辨率图像。

2.1.9.5 其余一些轻量级改进

小波变换是一种利用高频子带来表示纹理细节信息、低频子带来表示全局结构的技术。利用小波变换分解低分辨率来提取高频子带,在超分辨率网络中来重建高分辨率的高频子带,在通过逆小波变换重建图像,将小波变换与其他方法结合起来提升网络性能,还有逆亚像素卷积学习,金字塔池化学习等。CycleGAN^[74]提出的循环超分辨率框架,总共使用了四个生成器和两个鉴别器来分别完成不同阶段的超分辨率任务。类似于循环弱监督学习,不过网络的低分辨率和高分辨率间的相互映射是分开学习,使网络能学到真实图像的降质过程。ZSSR^[75]在没有高分辨率图像的情况下,用图像自身通过不同的处理方式生成数据集。

这些方法都可以做到小参数量,不需要复杂的网络设计都可以获得较好的性能,是可以参考选取的比较新颖的一些方向。

2.2 基于深度学习的图像超分辨率

采用深度学习的方式解决超分辨率问题已经获得了相较于传统方法较大的提升，主要使用卷积神经网络为主，而更新的一些方法已经开始将自然语言处理领域的 Transformer 的形式也引入了超分辨率任务中，更有方法结合了卷积层与 Transformer 进一步提升计算效率。本节首先描述了在深度学习超分辨率问题的理论模型，介绍一些在深度学习超分辨率中比较关键的一些相关知识，包括上采样层，全局残差等。

2.2.1 降质模型

为了更好的解决超分辨率问题，首先我们要知道低分辨率特征图是如何得到的，所以要建立一个高分辨率图像到低分辨率图像的降质模型。类似于前面章节提到的观测模型，超分辨率问题的退化模型额外需要一步降采样的操作。场景经过传感器采样和模数转换后得到高分辨率图像，但是由于拍摄者抖动会产生模糊，采样分辨率不足产生混叠，空气的气流扰动会产生变形。最终得到的图像经过模糊和下采样生成低分辨率图像，如图 2-7 所示。

建立的观测模型如下：




图 2-7 图像的降质模型

场景的图像受到气候、镜头形变和拍摄者运动形变影响，经过光学传感器采样得到数字信号后，进入数模转换器，由于采样精度的限制，转换后的图像会出现信号的混叠，得到的图像经过模糊后下采样得到低分辨率图像。

由于超分辨率问题是个病态问题，低分辨率对应的高分辨率图像不唯一。深度学习的方法就是构建大规模数据集，通过训练的方式让网络学习从低分辨率图像到高分辨率图像的映射关系，从而获得较为理想的重建模型。

2.2.2 深度学习图像超分辨率算法的网络结构

自 SRCNN 提出以来，后续的深度学习的超分辨率方法基本保持了三段式的网络结构，即特征提取，特征映射和图像重建部分。

2.2.2.1 特征提取

特征提取部分往往比较简单，多数模型只采用一层卷积层对维度进行放大。部分网络在特征提取时会采用较大尺寸的卷积核，具有更大的感受野，可以更有效地提取特征。

2.2.2.2 特征映射

特征映射是整个超分辨率网络的主体部分，也是决定性能和大小的主要因素。SRCNN 和 FSRCNN 都是直接采用了卷积层作为映射部分，VDSR 借鉴了残差的思想，插值获得的图像和真实图像其实比较接近，只是在细节纹理上有所欠缺，那么如果让神经网络去学习这个差异，也就是缺失的高频部分，而低频部分直接采用快速便捷的插值得到，可以提升网络的收敛速度。VDSR 在网络中添加了一个长的跳跃连接，将插值后的图像与网络的输出图像相加作为最后输出，即让网络学习插值图像与真实图像的插值，实现了残差学习。与残差网络 ResNet 相似的地方是形式上两者都采用了跳跃连接，不同是残差学习的目的是让网络学习图像的残差，而且跳跃连接是全局的，残差网络中引入残差是为了减缓随网络加深产生的梯度爆炸或梯度弥散，将上一层的输出直接向下一层输入，帮助网络更好的收敛，同时跳跃连接的中间的层数较少，属于局部跳跃连接。

2.2.2.3 图像重建

早期的网络由于输入的图像是插值后放大的图像，所以重建部分基本就是若干层的卷积层，然后直接输出即可。FSRCNN 改进为输入低分辨率图像，在重建部分采用反卷积进行上采样，减小了特征映射部分的计算量，提升了运算速度，




图 2-8 亚像素卷积

但是反卷积的操作会产生棋盘效应，重建的图像会出现块状的纹理。为了改进上采样，ESPCN 采用了亚像素卷积的方式来实现。如图 2-8 所示：

亚像素卷积是亚像素思想的延伸,其假设点与点间有可能存在,但是未被采样到的像素,就是亚像素,采用通道扩张的方式,假设邻近特征图上的点为亚像素点,通过将通道特征图在空间上重排实现亚像素的插入。重排的操作没有参数,但是放大通道数为放大尺度的平方倍,会产生较大的参数量。

为了减小上采样的参数量,PAN^[76]采用了插值放大特征图后再卷积的操作来避免通道维倍增的情况。

上述的重建方法都只能产生特定整数倍率放大的超分辨率图像,不能放大非整数倍率的图像。Meta-SR^[77]采用了动态卷积的思想,根据缩放因子大小去得到所需的滤波器尺寸,可以去生成任意大小的超分辨率图像。

2.2.3 损失函数

基于深度学习的超分辨率任务既可以采用有监督的形式,也可以采用无监督的形式,相较而言,有监督的效果更好,也是更主流的情形。有监督学习往往需要成对的输入和标签,需要超分辨率的低分辨率图像则为输入,对应的高分辨率真实图像则为标签。而无监督学习的形式会将重建好的图片再进行降采样,同原始低分辨率图像对比,此时不需要高分辨率图像作为标签。但是无论有监督还是无监督,都需要一种方式计算图像之间的误差,也就是需要设计一个损失函数。

在早期超分辨率任务中,往往采用的是均方误差损失,也叫 L_2 损失,与图像的客观评价指标是一致的,但是由于平方的计算方式会放大异常值的影响,从而使网络加重对异常值的惩罚,导致图像比较平滑,虽然均方误差损失训练得到的模型生成的图像的 PSNR 值会更高,但是后来还是逐渐变成了对异常值容忍度更高的 L_1 损失。目前主流的超分辨率模型训练基本都是采用 L_1 损失。

2.3 图像超分辨率研究常用数据集

深度学习的兴起也离不开互联网的发展,数据集的规模与质量也影响这最终的结果,数据集一般划为训练集和测试集,有些时候还会在训练集中划分一部分作为验证集,验证集作为平时训练修改模型的验证数据,等模型确定后再使用测试集测试,可以避免由于操作中产生数据泄露,使模型在数据集上过拟合。超分辨率任务的特殊在于需要对一张图上所有的点做预测,相对而言较难过拟合,所以一般只分为训练集与测试集。

目前主流采用的训练数据集为 DIV2K 和 Flickr2k 数据集等。DIV2K 数据集是 2017 年的 NTIRE 超分辨率竞赛采用的数据集,包含 1000 张的 2K 分辨率的图像,800 张训练,100 张验证,还有 100 张作为比赛方评判的测试图,没有对

应的高分辨率图。官方提供了采用不同下采样方式的低分辨率图，包括已知下采样和未知下采样两种，是一个专门针对超分辨率的包含大量丰富特征的数据集。Flickr2K 提供了 2650 张高分辨率的图片，类似 DIV2K 数据集，规模相较于 DIV2K 数据集更大，同样对各种场景的图像都有收录，特征丰富，场景很广。

测试集也是一个对衡量模型效果比较关键的因素，常用的五个测试集为 Set5、Set14、BSD100、Urban100 和 Manga109。单词后面的编号即为测试集规模，在之前的图像任务中作为训练集集，后来更大规模的训练集出现，逐渐变成了测试集。其中 Urban100 只包含城市场景，Manga109 只有杂志封面图片，而剩下的测试集都包含比较多样的场景，整体能比较好的验证算法在多种图像上的通用性能。

2.4 图像超分辨率算法评价指标

有了数据集，还需要有评价模型性能好坏的标准，并且这个标准能对大多数的算法进行公平的评估。算法评价指标一般分为主观评价指标和客观评价指标。主观评价指标一般是指接近人眼视觉感知的评测；客观评价指标主要是计算重建图像与真实图像某些属性的差别。

2.4.1 主观评价指标

主观评价指标可以由观察者直接查看，由主观视觉效果评估，可以通过问卷调查的形式获得评价，向多人展示不同方法得到的图片，来进行打分；同样也可以去近似人的主观感受，例如采用神经网络的方式去判断哪张图像更真实，能获得类似于人对图像质量好坏的评价，近年有一些相关工作，例如 PI 和 LPIPS^[78]等。

2.4.2 客观评价指标

客观评价指标更加考虑重建图像与真实图像的差别，通过不同的计算方式获得两张图片在不同属性上的差值。常用的客观评价指标有：均方误差(MSE)、峰值信噪比(PSNR)和结构相似度(SSIM)。

均方误差的计算方式如下：

$$MSE = \frac{1}{mn} \sum_{i=0}^{m-1} \sum_{j=0}^{n-1} (I(i,j) - K(i,j))^2 \quad (2-7)$$

式中 m, n —— 图像的高和宽；

I, K —— 计算误差的两张图像。

均方误差直接计算了对应像素值的差值的均方值，越大效果越差，是比较直

观的一种计算方式，也相对简单快速，

峰值信噪比计算方式如下：

$$PSNR = 10 \times \log \left(\frac{MAX_I^2}{MSE} \right) \quad (2-8)$$

峰值信噪比是在均方误差的基础上求解的，值越高，与真实图像的差别越小，重建质量越高。

为了更加符合对图像内容的判断，提出了结构相似度指标 SSIM。自然图像中的结构性很强，图中像素点之间有着较高的关联性，跟据图像的内部结构的相似程度判断图像的接近程度，会更加接近于人眼对图片的判断。重建图像与真实图像越接近，SSIM 越大。PSNR 和 SSIM 为超分辨率算法中比较常用的客观指标。

2.5 本章小结

本章主要介绍了与深度学习的相关背景知识；简要描述了观测图像的降质模型，介绍了目前深度学习图像超分辨率模型的主要组成结构，并分析了每个结构的作用和实现，对几种常用的损失函数做了分析；列举了超分辨率任务中常见的训练集和测试集；最后介绍了超分辨率任务中的两大类算法评价指标，主观评价指标和客观评价指标。

第3章 基于3D卷积的轻量级卷积层设计

3.1 引言

自2006年始,深度学习逐渐在诸多任务上获得相较于传统方法较大的提升,吸引越来越多的关注。基于学习的方式摆脱了特征工程的限制,而且由于互联网时代产生的大量数据以及硬件的快速提升,建立深度网络,将数据喂给网络让其自行学习数据间的非线性关系使深度网络在许多任务上都取得了较好的成绩。同时越来越成熟的深度学习框架、优化器的提出与改进、训练方法的改进都使网络结构越来越深。但是与此同时,早期的神经网络,例如全连接网络在面临维度极高的数据时,其计算量往往难以承受,卷积神经网络应运而生。

卷积神经网络的原理是模仿人类大脑皮层对简单线条纹理响应的机理。网络往往具有丰富的层级,低层来响应基础的纹理特征,不同的低层特征的响应会传递到下一层,每个层级会学习到不同的特征,逐步学得语义更丰富的特征,提升模型性能,提高训练速度的同时,大大的减小了参数量。

轻量级网络在现实中具有较大的实际意义。轻量级网络,参数量少,计算量小,推理时间短,通常部署在移动和边缘设备上。同时物联网时代对于人工智能的需求使大而复杂的网络很难与现有的设备能力相匹配,轻量级网络的设计则更显得有意义。

FSRCNN改进了SRCNN,大大减小了SRCNN并且提升了训练和推理速度,网络将大的卷积核替换为多层的小卷积核,并且将上采样放在了最后,减小计算量;LapSRN采用了级联结构,也叫金字塔结构,网络采取逐步学习,得到每级相应尺寸的重建结果,并采用了改进的损失函数,训练时不同尺度的输出有不同的标签,由于每级的参数都是共享的,内部层也共享,所以网络的参数量很小;IDN^[79]提出了信息蒸馏网络,达到轻量级的参数量,增强单元采用一个压缩单元提升对有效信息的提取,提升特征表达能力;CARN是一个轻量级残差级联网络,设计了全局和局部的级联连接,三个级联块密集连接,同时级联块中的残差结构也跳跃连接,同时每个级联块参数共享,每个级联块内部残差结构参数共享,网络采用了组卷积进一步降低参数;FALS^[80]采用了模型搜索的方法,设计了一个平衡参数和性能的轻量级模型;AWSRN^[81]简化了注意力的部分,采用两个自适应参数作为独立的权重对特征图加权求和;MCAN^[82]采用了矩阵排列的方式搭建网络,将特征图在递归中反复使用,s-LWSR^[83]采用了对称结构和将多块的信息池化后补充进网络中;IMDN^[84]改进了IDN,在蒸馏模块加入了注意力模块,

同时在全局平均池化的基础上加上了特征图的方差，增加对结构的感知能力；PAN 将注意力改进为像素注意力，在减少参数量的同时完成通道和空间的注意力加权。

本章提出了一种新的轻量级卷积层来替换网络中的传统卷积层，在更小的参数量的情况下可以获得更好的效果，并提出了基于 3D 卷积的高效超分辨率网络 E3DCSRNet (Efficient 3D Convolution Super-Resolution Network, E3DCSRNet)。本章的工作如下：

(1) 提出了采用 3D 卷积设计的轻量级卷积层，有效的减小了模型的参数量，并获得较好的性能；

(2) 设计了多路信息融合残差块 (Multi-Path Information Fusion Residual Block, MPIFRB)，能够充分利用不同尺度，不同深度的特征，获取更好的重建效果；

(3) 设计了渐进特征提取块 (Progressive Feature Extraction Block, PFEB)，逐步的提取特征，并扩大特征维度；

(4) 设计了轻量级上采样模块 (Lightweight Upsampling Block, LWUB)，将维度扩展的操作放置在深度维，减小了通道维扩展带来的巨大参数增加。

3.2 基于 3D 卷积的轻量级卷积层及网络设计

本节将介绍本文 E3DCSRNet 算法，首先主要介绍网络的整体结构设计，然后对各个模块做分析。

3.2.1 整体网络设计




图 3-1 整体网络设计

图 3-1 展示了本章的基于 3D 卷积的高效超分辨率网络 E3DCSRNet 的整体框架，分为特征提取、特征映射和图像重建三个部分。

(1) 特征提取：网络设计了渐进特征提取块，用了多个 3D 反卷积进行提取，同时对特征的深度维进行放大，最后通过一个 3D 卷积进行通道维的放大。

(2) 特征映射：设计了一个多路信息融合残差模块，通过堆叠多个多路信息融合残差模块来获得较大的感受野和非线性拟合能力。

(3) 图像重建：提出了轻量级上采样模块，并把通过插值获得的图像同上采样的输出相加作为最后输出，让整个网络主体学习残差图像，提升训练拟合速度和重建效果。

3.2.2 多路信息融合残差块




图 3-2 多路信息融合残差块

模块的设计如上图 3-2 所示。支路的差异性越大，学习到的特征越不同，所以两条支路包含不同数目的卷积层，加大差异性，提升特征丰富度。首先将输入通过两个卷积层进行维度压缩，变为原维度的一半，是一个类似于瓶颈层的设计，这样可以降低后续的计算量，并使整个网络的参数减小；同时压缩的过程可以更有效的过滤冗余的特征，保留更有效的特征。特征上面的支路加入了注意力机制，可以学习不同重要程度的特征，最后经过一个 3D 卷积得到上支路的输出。下面的支路则直接通过一个 3D 卷积和激活后输出。

上下的支路包含十分不同的信息，上方的支路感受野更大，深度更深，同时经过注意力机制后获取的特征更加有效，具有更多的语义信息；下方的支路是浅层特征，拥有较多的纹理信息，所以设计了一个上下支路相融合的设计，将上方注意力计算后的特征图与下方特征图相加，让浅层特征获取高层语义，得到更好的效果，输出的特征与上方特征相加，再卷积，让深层的特征可以获得浅层特征的，更加精确。

为了更好的利用不同支路上的信息，对两条支路的输出进行合并，最后再通过一个 3D 卷积进行两条支路的信息融合，输出的特征加上整个模块前的输入，使模块学习残差信息，提高网络学习效率。

3.2.3 基于 3D 卷积的轻量级卷积层

网络的宽度，即特征维度，也就是 2D 卷积的通道数，与网络的深度，在很大程度上决定了模型的性能。随着 ResNet 大大加深了网络，堆叠网络深度一直是提升网络效果的最直接的手段。超分辨率网络中 SRCNN 作为较早提出的算法，只有 3 层，在 VDSR，EDSR 堆叠到几十层后，通过加大超分辨率网络的深度已经很难在获取性能的提升了。同样，网络的通道维度也在增加，层数的堆叠对计算量的提升是线性的，但是由于普通 2D 卷积的计算方式，通道维度的增加会带来计算量平方数的增加，所以常规卷积很难获得较大的通道数。扩大网络的宽度往往可以让网络学习到更加丰富的特征。同样，由于网络宽度提升所需要的参数量过大，轻量级模型往往会将网络中的通道数设置的较小，或引入瓶颈层，减小通道数，以此减小参数量。但是减小通道数的影响也很大，首先是过小的通道数会导致网络无法学习到丰富的特征，大大降低模型性能；其次较小的通道有可能会使模型无法收敛，因为通道数太少，如果产生一些异常值，比如一些特征图出现较多的零值，网络将无法训练。

为了在轻量级网络中也能保持较大的特征维度，本章提出了基于 3D 卷积设计的卷积层，将 2D 卷积的通道维度拆分为 3D 卷积中通道维与深度维的乘积，同时 3D 卷积中深度维的计算类似于空间上的带步长的扫描卷积，无论的缩放维度还是计算，都只需要较少的参数就可以完成，从而在小参数量的情况下获取较大的宽度，取得更好的效果。接下来分析一下与普通的 2D 卷积相比，参数量和计算量的不同，对比如表 3-1 所示。

表 3-1 2D 卷积与 3D 卷积计算量对比

	2D 卷积	3D 卷积
参数量	$C_{in} \times C_{out} \times k_1 \times k_2$	$C_{in} \times C_{out} \times k_1 \times k_2 \times k_3$
计算量	$C_{in} \times C_{out} \times k_1 \times k_2 \times H \times W$	$C_{in} \times C_{out} \times k_1 \times k_2 \times k_3 \times H \times W \times D$

其中 C_{in} 表示输入特征的通道数； C_{out} 表示输出特征的通道数， k_1, k_2 为空间上卷积核的尺寸； k_3 为深度维卷积核的尺寸，3D 卷积比 2D 卷积多了一个深度维度，但是计算方式与空间卷积类似，所以参数量和计算量受深度维大小影响较小； H, W 为图像的高和宽； D 为 3D 卷积的深度维大小。假设空间上的卷积核尺寸相当，当 3D 卷积中通道维与深度维的乘积与 2D 卷积通道维大小一致时，可以计算出 3D 卷积和 2D 卷积的计算量和参数量的比值，此时参与计算的特征维度大小是相同的。比值如表 3-2 所示。

表 3-2 3D 卷积与 2D 卷积参数量和计算量比值

3D 卷积与 2D 卷积的比值	
参数量	$\frac{k_3}{D^2}$
计算量	$\frac{k_3}{D}$

当越多的特征维度转换到深度维，则 3D 卷积相较于 2D 卷积获得越少的参数量和计算量。以此为基础，设计了基于 3D 卷积的轻量级的卷积层，采用较小通道数与较大深度维度的组合，在采用较少参数的同时取得较大网络宽度。

3.2.4 渐进特征提取模块




图 3-3 渐进特征提取模块

图 3-3 为渐进特征提取模块的描述。由于 3D 卷积在深度维度的操作是类似于一维的卷积，所以通道扩展所需要的参数较少，只需要步长为 2 的 3D 反卷积操作即可对深度维的大小进行倍增，同时逐步的提取浅层特征。最后通过一个 3D 卷积完成对通道维度的变化，进入特征映射部分。本文方法只进行了一次反卷积，将深度维数变为 6，具体的参数是由实验结果，综合计算量和参数量确定的。

3.2.5 轻量级上采样模块




图 3-4 轻量级上采样模块

早期的模型，如 SRCNN，输入的是插值后的图像，图像重建部分无需上采样；后来的模型采用低分辨率图输入，在最后用反卷积完成高分辨率图像重建，但是会出现棋盘效应；目前采用较多的上采样方法是 ESPCN 提出的亚像素卷积

的方法,但是其中的通道维度变为原通道乘以放大尺度的平方数,会引入巨大的参数量,放大尺寸越大,增加的越明显,所以在放大4倍时通常采用将特征图分两次放大两倍来减小参数量。

本章采用的轻量上采样将通道倍增的操作转为在深度维倍增。由于深度维是类似于卷积的形式,采用不同步长的反卷积即可获得不同的倍数的放大,参数量较小。同样是利用了3D卷积深度维度扩展参数量计算量小的优势,设计了轻量级的上采样形式。如图3-4所示。

3.3 实验内容与实验结果

3.3.1 实验数据集及训练参数设置

本章模型训练时采用的是DIV2K数据集,测试时采用Set5, Set14, B100, Urban100及Manga109数据集。客观指标采用峰值信噪比PSNR和结构相似性SSIM,计算时将RGB图像转换到YCbCr空间,只计算超分辨率图像和真实图像的Y通道的PSNR和SSIM。

输入图像块大小为 64×64 ,批次大小设为32,网络内通道数为20,渐进特征提取块PFEB采用一次3D反卷积,空间卷积核大小为 1×1 ,深度卷积核大小为4,步长为2,计算后深度维为6,相当于特征维度为120,变化通道维的3D卷积层的空间维卷积核大小为 3×3 ,深度维卷积核为3。多路信息融合残差块MPIFRB内部两条支路的第一次卷积将通道维变为一半,最后一次卷积将两条通道合并融合输出,维度不变,其中所有涉及通道维数变化和信息融合的卷积层,空间维卷积核大小为 1×1 ,深度维卷积核为1,其他卷积层的空间维卷积核大小为 3×3 ,深度维卷积核为3,总共设置16个MPIFRB线性堆叠。

本章采用了Adam优化器和 L_1 损失,由于轻量级模型训练较慢,通常学习率设置要大于普通模型,初始学习率设置为 10^{-3} ,采用余弦退火衰减策略,最小学习率为 10^{-7} ,变换周期为250个批次,学习率变化速度为1,总共训练650个批次,因为余弦退火学习率变换有周期性的跃升,会导致在每个周期的早期出现损失加大,不稳定的情况,所以在训练要在每次周期的末端结束。采用Pytorch框架和1块GeForce RTX 2080Ti GPU进行训练与测试。

3.3.2 实验结果分析

3.3.2.1 客观指标对比

本节将对比其他几种基于深度学习方法的超分辨率算法,部分方法中选用参

数量与本章模型参数量接近的模型，如 VDSR, LapSRN, DRRN, CARN-M, SRFBN-S^[85], AWSRN-SD, A2F-SD^[86], ESRN-V^[87]和 LAPAR-B^[88]。对比了多个模型在 Set5, Set14, B100, Urban100 和 Manga109 数据集的 PSNR 和 SSIM, 实验总共包含三个倍数, 2 倍, 3 倍和 4 倍, 对比结果如表 3-3 所示。

表 3-3 PSNR 和 SSIM 对比

模型	倍数	Set5	Set14	B100	Urban100	Manga109
		PSNR(dB)/SSIM				
VDSR	2	37.53/0.9587	33.03/0.9124	31.90/0.8960	30.76/0.9140	37.22/0.9729
LapSRN		37.52/0.9590	33.08/0.9130	31.80/0.8950	30.41/0.9100	37.27/0.9740
CARN-M		37.53/0.9583	33.26/0.9141	31.92/0.8960	31.23/0.9193	-/-
DRRN		37.74/0.9591	33.23/0.9136	32.05/0.8973	31.23/0.9188	37.92/0.9760
SRFBN-S		37.78/0.9597	33.35/0.9156	32.00/0.8970	31.41/0.9207	38.06/0.9757
AWSRN-SD		37.86/0.9600	33.41/0.9161	32.07/0.8984	31.67/0.9237	38.20/0.9762
A2F-SD		37.91/0.9602	33.45/0.9164	32.08/0.8986	<u>31.79/0.9246</u>	38.52/0.9767
ESRN-V		37.85/0.9600	33.42/0.9161	<u>32.10/0.8987</u>	<u>31.79/0.9248</u>	-/-
LAPAR-B		<u>37.87/0.9600</u>	33.39/0.9162	<u>32.10/0.8987</u>	31.62/0.9235	38.27/0.9764
E3DCSRNet		37.91/0.9603	33.52/0.9167	32.12/0.8989	31.85/0.9258	38.45/0.9768
VDSR	3	33.66/0.9213	29.77/0.8314	28.82/0.7976	27.14/0.8279	32.01/0.9310
LapSRN		33.81/0.9220	29.79/0.8325	28.82/0.7980	27.07/0.8275	32.21/0.9350
CARN-M		33.99/0.9236	30.08/0.8367	28.91/0.8000	27.55/0.8385	-/-
DRRN		34.03/0.9244	29.96/0.8349	28.95/0.8004	27.53/0.8378	32.74/0.9390
SRFBN-S		34.20/0.9255	30.10/0.8372	28.96/0.8010	27.66/0.8415	33.02/0.9404
AWSRN-SD		34.18/0.9273	30.21/0.8398	28.99/0.8027	27.80/0.8444	33.13/0.9416
A2F-SD		<u>34.23/0.9259</u>	30.22/0.8395	29.01/0.8028	27.91/0.8465	<u>33.29/0.9424</u>
ESRN-V		<u>34.23/0.9262</u>	<u>30.27/0.8400</u>	<u>29.03/0.8039</u>	<u>27.95/0.8481</u>	-/-
LAPAR-B		34.20/0.9256	30.17/0.8387	<u>29.03/0.8032</u>	27.85/0.8459	33.15/0.9417
E3DCSRNet		34.32/0.9267	30.30/0.8416	29.06/0.8045	28.00/0.8499	33.43/0.9444
VDSR	4	31.35/0.8838	28.01/0.7674	27.29/0.7251	25.18/0.7524	28.83/0.8809
LapSRN		31.54/0.8850	28.19/0.7720	27.32/0.7280	25.21/0.7560	29.09/0.8845
CARN-M		31.92/0.8903	28.42/0.7762	27.44/0.7304	25.62/0.7694	-/-
DRRN		31.68/0.8888	28.21/0.7720	27.38/0.7284	25.44/0.7638	29.46/0.8960
SRFBN-S		31.98/0.8923	28.45/0.7779	27.44/0.7313	25.71/0.7719	29.91/0.9008
AWSRN-SD		31.98/0.8921	28.46/0.7786	27.48/ <u>0.7368</u>	25.74/0.7746	30.09/0.9024
A2F-SD		<u>32.06/0.8928</u>	<u>28.47/0.7790</u>	27.48/0.7373	25.80/0.7767	<u>30.16/0.9038</u>
ESRN-V		31.99/0.8919	<u>28.49/0.7779</u>	<u>27.50/0.7331</u>	<u>25.87/0.7782</u>	-/-
LAPAR-B		31.94/0.8917	28.46/0.7784	27.52/0.7335	25.85/0.7772	30.03/0.9025
E3DCSRNet		32.10/0.8934	28.53/0.7807	27.52/0.7347	25.90/0.7813	30.35/0.9082

表中标粗的数据代表是在该数据集的最优值, 表中下划线标记的数据代表在

该数据集上获得了次优值。可以看到本章提出的 E3DCSRNet 在三个倍数和五个测试集上基本都获得了最高的 PSNR 和 SSIM，充分体现了本文方法的有效性，尤其是在高倍数上，本章模型的优势更加明显。

作为一个轻量级模型，不仅要性能优异，还要尽可能保持较小的参数量和计算量，参数量和计算量只对比 4 倍的模型的相关参数和 PSNR。为了保证公平对比，所有模型的计算量为其 4 倍模型在将一张 320×180 的图像放大到 1280×720 所需要的乘加操作操作，并列出该模型在 Set5 的 PSNR 值。在下表 3-4 列出了参数量和计算量的对比：

表 3-4 模型参数量、计算量和 PSNR 对比

模型	Params(K)	MultiAdds(G)	PSNR(dB)
VDSR	665	612.6	31.35
LapSRN	813	149	31.54
CARN-M	412	32.5	31.92
DRRN	<u>297</u>	6797	31.68
SRFBN-S	483	1037	31.98
AWSRN-SD	444	25.4	31.98
A2F-SD	320	18.2	<u>32.06</u>
ESRN-V	324	<u>20.7</u>	31.99
LAPAR-B	313	53	31.94
E3DCSRNet	178	80	32.10

从表 3-4 中可以看出，本章方法 E3DCSRNet 的参数量是最小的，因为采用的 3D 卷积本身在较大特征维度时可以保持较小的参数量，本章模型的参数是多数模型的一半甚至四分之一；计算量虽然不是最低的，但是相较于一些计算量巨大的模型也在一个比较低的水平，但是整体的性能是最优的，PSNR 最高，达 32.10dB，实现了参数量和计算量降低，性能反而更优。

3.3.2.2 主观指标对比

为了更加直观的评价模型对图像恢复的效果，本节从多个数据集中对不同倍数的图像进行了恢复，为了更好的看出在恢复细节上的差异，仅截取了在图像上纹理较为丰富的部分进行对比。选取了 VDSR、LapSRN 和 CARN-M 三个模型作为主观效果的对比模型，同时截取了真实图像和低分辨率图像进过插值获得的图像作为参照和对比。从主观图可以看出，相较于其他模型，本章模型纹理细节恢复更加真实合理，生成的边缘更加锐利，模糊的部分更少。主观图的对比效果如图 3-5 所示：




图 3-5 模型主观效果图对比

3.3.3 消融实验分析

3.3.3.1 通道维数消融实验

为了探究通道数大小对模型性能的影响以及参数量的变化关系,本实验对不同的通道数的模型进行了消融实验。如图所示,根据一些预实验和实验前计算,过大的通道数目需要的巨大的参数量与计算量,过小的通道数会导致模型性能大幅下降,所以在较小的通道数和较大的通道数时实验设置步长较大,适中的通道数则设置更多更密集的实验。实验设置通道数分别为 8、12、16、18、20、22、24、28,其他的例如残差块数、特征提取层数和上采样层数均不变,保持一致,在 4 倍超分辨率模型上训练,采用 DIV2K 的 801-810 共 10 张图像作为测试图像,绘制了随通道数 PSNR 和参数量的变化折线图,图中横坐标为通道数,纵坐标为 4 倍模型不同通道数下的 PSNR,右纵坐标为不同通道数下的参数量。实验结果如图 3-6 所示。




图 3-6 通道数对模型性能影响

观察可得,参数量随着通道数增加而增加,而且增加幅度随通道数变大而变大,增加速度是通道的平方数。同时可以看到随着通道数增加,网络性能也在增加,在 12 和 16 之间增幅较大,说明较小的通道数会较大的损伤模型性能,通道数不宜设置的过小,当通道数为 20 时模型获得最优性能,随着通道数继续增加,反而会出现性能下降。由于通道数代表着隐空间的维数,过大的维数可能会产生过强的拟合能力,导致模型过拟合,泛化性能下降,反而在测试集上获得更差的效果。因此,本章算法中设置网络的主通道数为 20,参数量的增加相对而言不大,但是又可以获得较好的性能。

3.3.3.2 深度维数消融实验

控制网络的特征维数还可以通过改变深度维的数目，本实验针对不同的深度维数做了消融实验。如图可以看到，实验设置了 3、4、5、6、7、8、9 七种深度维数目。由图可以看出，深度维的变化在参数量的波动是很小的，几乎不变，而随着深度维的加大，同样出现了性能先提升后下降的情况，与通道数目变化规律类似，由此得出最合适的深度维参数为 6，实验如图 3-7 所示。




图 3-7 深度维数对模型性能影响

3.3.3.3 卷积核尺寸消融实验

对于深度维度的卷积核大小同样进行了实验，发现随着深度维卷积核的尺寸的增加，性能会得到提升，但是同时参数量也会有较大的增加，所以本章实验采用深度维卷积核尺寸为 3，实验如图 3-8 所示。

3.4 本章小结

本章提出了一种基于 3D 卷积的轻量级卷积层以及相应的高效超分辨率网络 E3DCSRNet。首先对近几年的轻量级网络及方法做了回顾，当前轻量级网络往往为了更小的参数量和计算量，将通道数目设置的很小，会较大影响模型性能，基于此，本章提出了采用 3D 卷积的方式获得较大的特征维度，同时保持较小的参数量。首先本章对于 E3DCSRNet 的整体结构做了描述，网络在特征提取、特征映射和图像重建部分都充分结合了 3D 卷积的特点进行了轻量化的改进。设计了

多路信息融合残差块 MPIFRB，将两条支路的信息进行融合，充分的利用了高层语义信息和低层的纹理信息；渐进特征提取块 PFEB 在逐步完成特征提取的同时完成了对特征维度的放大；轻量级上采样模块 LWUB，利用 3D 卷积在深度维上进行维度放缩参数量较小的优点，减小了上采样所需参数量。在实验部分，介绍了训练时的参数，以及所需要的数据集。对参数量接近的模型进行对比，展示了 E3DCSRNet 的性能优异，消融实验探究了最合适的超参数设置。




图 3-8 深度维卷积核尺寸对模型性能影响

虽然 E3DCSRNet 在较小参数量的情况下已经取得了较好的性能，但是网络中只采用了卷积这种局部运算的形式来对信息进行处理，不能很好的对图像全局的信息加以利用。自然图像存在大量有规律的，相似的一些特征，但是分散距离较远，卷积运算很难用到这些信息，为了改进这一问题，进一步提升网络的性能，网络需要引入基于非局部的方法来改善信息利用不足的问题，也是论文下一步的研究方向。

第4章 跨尺度轻量级非局部注意力设计

4.1 引言

卷积神经网络的提出，大大的提升了图像任务深度学习方法的训练效率；相较于全连接层无法对图像尺寸自适应的调整，卷积层计算时并不关注图像大小，这两个优点都使得在图像任务中卷积神经网络具有优越性，尤其是超分辨率任务。超分辨率任务中图像往往尺寸较大，且图像尺寸跨度较大，依赖于图像尺寸大小的网络在超分辨率任务上泛化性较差。但是卷积神经网络也有它的不足，最主要的就是卷积层局部操作虽然减小了计算量，也减小了对全局信息的利用。为了解决感受野受限的问题，许多模型加大网络深度，由于卷积的计算方式，虽然较远的特征也可以利用，不过多次计算后基本很难建立起较长的连接；扩大卷积核则会面临参数量和计算量的增大。

同样，自然图像中的纹理信息往往具有丰富的规律，相同的图像会出现相同的图案，甚至在不同的尺度信息上具有相关性，利用这些相似信息，可以帮助得到更有利于图像恢复的信息。但是这些相似信息可能距离较近，也可以距离较远，卷积神经网络的局限性很难加以利用，而跨尺度的相似信息采用单一卷积核尺寸的卷积神经网络则无法计算，虽然有些网络通过采用支路具有大小不同的卷积核，但是很难将较远区域的跨尺度信息进行联系。非局部的方法应运而生。

非局部均值 (NL-means) 基于一个假设，也就是图像中的每个图像块存在着一些相似图像块，由于图像本身的结构性比较强，而噪声往往是随机的，如果对于所有相似的图像块计算其均值，就会削弱噪声的影响。同时图像块虽然相似，但是并不相同，单纯的点对点对应计算平均值效果一般，更加相似的图像应该具有更高的权重。图像中内容具有一定的联系与相关性，距离较远的图像块联系性更弱，所以对于不同位置的图像块也会具有不同的权重。由于是以图像块为单位来计算相似度，就会涉及两个参数，也就是图像块的大小，和图像块搜索的范围。图像块越大，越难找到相似的图像块，同时会加大计算量；图像块越小，越容易受到噪声影响。搜索范围越大，利用的图像信息越多，计算量越大；搜索范围越小，越不易受到不相似的图像块影响。

NLNN 将传统图像领域的非局部均值的思想迁移到了深度神经网络中，提出了一种高效，简单，通用的非局部操作，用来捕捉深度神经网络中的远程依赖关系，non-local 操作对于远程依赖关系的获取，是通过任意两个位置的计算，直接获取的，与他们的位置信息无关。该非局部操作保证了输入与输出维度上保持一

直，能作为即插即用的模块应用于较多模型上。

NLRN 将 non-local 操作引入模型，端到端的训练网络捕捉临近的相似信息，non-local 操作会在整个图像的范围内计算每个局部特征的相关性，然后进行特征重组，NLRN 改进了计算整个图像相似性的部分，选择计算局部相似性，减小了计算量；RNAN^[89]在网络的始末加入了非局部注意力模块，而且为了保证网络深度，在特征图输入注意力模块前加入了跳跃到输出；SAN 采用了二阶注意力，在网络的头部与尾部加入了改进的非局部信息融合模块，将图像划分为的小块，在每个小块上分别进行 non-local 操作；DNLN^[90]将非局部信息融合与视频超分辨率结合，不仅利用了自身的相似块，还将相邻视频帧的信息也通过非局部模块进项融合，提升了网络性能；PFNL^[91]采用了非局部信息融合模块来进行隐性的相邻帧图像对齐，并且在模块内扩张通道数，压缩了图像尺寸，从而降低了中间变量的大小；CSNLN^[92]扩展了传统的 self-attention 形式，将相似权重矩阵与特征矩阵相乘，再 softmax 激活计算相似权的方式改进为采用卷积核反卷积的操作，将相似度计算从像素点扩展到相思块计算，同时网络还利用了多尺度的相似信息，两条分支分别融合不同尺度的特征图，缺点是计算量和中间变量极其巨大；PANet^[93]采用了类似 CSNLN 的设计，不过将多尺度的相似信息融合放入了一个模块中，同时采用金字塔放大，逐级计算的形式将不同尺度的信息进行融合；IGNN 没有采用自注意力的形式来进行相似信息融合，而是采用了最邻近算法寻找相似块，采用图像网络将相似块视为节点，其边长为到目标块的距离，作为权重，在图像对齐之后进行加权融合；NLSN^[94]为了解决对于每个位置的特征都要计算与空间上其他所有特征的相关性权重导致的计算量过大的问题，采用了局部敏感哈希（Locality-Sensitive Hashing, LSH）的方法，将相似图像搜索匹配的操作大大减小，不仅获取相关性更强的特征进行融合，排除了噪声的干扰，同时计算量更小。

为了提升模型提升的效果，同时解决卷积层感受野有限导致信息利用不足的问题，加强对自然图像跨尺度相似特征的利用，本章设计了一个非局部信息融合模块，可以获取更远位置的信息。同样，图像中存在较多相似的不同尺度的图像块，这些图像块同样可以用来作为一种信息补偿，但是 NLNN 中提出的计算方式需要计算每个位置与其他所有位置的相似权重，计算量十分巨大，不适合在轻量级模型上采用。为了减小搜索相似图像块的计算量，本章采用了局部敏感哈希的方法，将特征进行哈希编码，相同编码的特征即为接近特征，降低了计算量，并设计了跨尺度非局部信息融合模块（Cross-Scale Non-Local Information Fusion Block, CSNLIFB）。本章网络主体框架为第 3 章的 E3DCSRNet，在特征提取阶段后插入跨尺度非局部信息融合模块 CSNLIFB，提出了非局部高效 3D 网络

NLE3DNet (Non-Local Efficient 3D Convolution Network, NLE3DNet)。

4.2 基于跨尺度信息融合的轻量级非局部注意力设计

本节将介绍非局部高效 3D 网络 NLE3DNet 的整体结构，跨尺度非局部信息融合模块 CSNLIFB 的具体设计与实验结果。

4.2.1 整体网络设计




图 4-1 整体网络结构

本章的网络采用第 3 章的基于 3D 卷积的高效超分辨率网络 E3DCSRNet 作为基线模型，在模型的特征提取块 PFEB 后加入一个跨尺度非局部信息融合模块 CSNLIFB，来提升对全局信息的利用，随后输入后续的残差块中，其余结构均不改变，超参数设置也一致。

4.2.2 跨尺度非局部信息融合模块

自然图像中存在较多的相似部分。甚至在同一张图片上存在不同尺度的相似信息。如下图 4-2 所示，低分辨率图像所对应的高分辨率图的部分图像块与低分辨率图像中的部分图像块相似，如果利用这样跨尺度的相似图像块信息，就可以来补充在降采样中丢失的信息。




图 4-2 自然图像中的跨尺度相似

但是图像的空间尺寸是很大的，如果在图像空间上全局搜索，且对于每一个位置的特征都要进行一次与所有特征的相似度计算，计算量是十分庞大的，并不适合轻量的模型。为了解决搜索计算量大的问题，本章采用了局部敏感哈希的方法。

图为局部敏感哈希的算法原理。假设空间中两个向量，它们的投影会落在空间里两个位置，我们旋转投影空间，这两个向量就会在新空间上产生新的投影，将空间划分为若干区域，由于旋转了空间，那么两次向量投影在空间的位置是不同的，每次记录投影所在的区域编号，进行多次后，便得到了该向量的哈希编码。两个向量采用同样的操作，如果两个向量本身很接近，那么它们产生的哈希编码理论上也是相似或一致的，而相似度较低的两个向量往往会得到差别较大的哈希编码，这样只需要对所有的图像特征进行一次编码，即可将相似的特征通过哈希编码的形式进行分类，后续的计算更加方便

如图 4-3 所示，为局部敏感哈希算法的简单示例。假设空间中存在两个相近的特征向量，距离较近的特征往往也较为相似，旋转坐标系，计算其投影位置，两个特征编码均为 2,4,1；但是如果是两个较远的特征向量，也就是差异较大的特征，得到的编码为 2,4,1 和 3,1,2，差别较大。

为了获取跨尺度的信息，可以将跨尺度信息经过下采样后得到的特征向量与目标特征向量一同进入局部敏感哈希算法编码，这样就可以来比较不同尺度上不同区域的相关性，同时减小了在全局进行搜索匹配的计算量。




图 4-3 局部敏感哈希算法示意图

图 4-4 为跨尺度非局部信息融合模块 CSNLIFB 的算法流程。输入的特征图经过一次映射，并对特征进行降维，降低后续的计算量。查询特征为下采样的输入特征图，设置一个较大的滑动窗口，对窗口内的特征值进行下采样。将两组特征图在同一组随机向量空间中进行投影，随机向量的维度与特征向量的维度相同。通过旋转向量，得到两组哈希编码。对哈希编码进行排序，随后对输入特征图所有的特征向量进行遍历，并与查询特征图中同样哈希值的特征向量采用及自身特




图 4-4 跨尺度非局部信息融合模块

征向量计算相似度权重，最后对所有相似特征进行加权融合，得到融合后的特征图并输出到网络后续的部分。

相较于传统的非局部算法，本章算法的计算复杂度具有优势，下图为一些常见非局部算法的计算复杂度对比，如表 4-1 所示。

表 4-1 非局部算法复杂度对比

非局部算法	计算复杂度
NLNN	$O(H \times W \times H \times W)$
NLRN	$O(H \times W \times k \times k)$
CCNet	$O(H \times W \times (H + W))$
NLSN	$O(H \times W)$
NLE3DNet (Ours)	$O(H \times W)$

4.3 实验内容与实验结果

4.3.1 实验数据集及参数设置

本章采用 DIV2K 作为训练数据集，Set5, Set14, B100, Urban100 及 Manga109 作为测试数据集。客观指标对比了峰值信噪比 PSNR 和结构相似性 SSIM，计算时将 RGB 图像转换到 YCbCr 空间，只计算超分辨率图像和真实图像的 Y 通道的 PSNR 和 SSIM。

采用第三章的网络作为基线模型，对训练超参数不做更改，只在多路信息融合残差块与渐进特征提取块间添加一个跨尺度非局部信息融合模块 CSNLIFB，模型残差块数量、每层通道数和卷积核尺寸设置均不变。

本章采用了 Adam 优化器和 L_1 损失，初始学习率设置为 10^{-3} ，采用余弦退火衰减策略，最小学习率为 10^{-7} ，变换周期为 250 个批次，学习率变化速度为 1，总共训练 650 个批次。采用 Pytorch 框架和 1 块 GeForce RTX 2080Ti GPU 进行训练与测试。

4.3.2 实验结果分析

4.3.2.1 客观指标对比

本节选择了 VDSR, LapSRN, DRRN, CARN-M, SRFBN-S^[85], AWSRN-SD, A2F-SD^[86], ESRN-V^[87] 和 LAPAR-B^[88]。对比了多个模型在 Set5, Set14, B100, Urban100 和 Manga109 数据集在 2,3,4 倍多个倍数上的 PSNR 和 SSIM，实验对比结果如表 4-2 所示。

表 4-2 PSNR 和 SSIM 对比

模型	倍数	Set5	Set14	B100	Urban100	Manga109
		PSNR(dB)/SSIM				
VDSR	2	37.53/0.9587	33.03/0.9124	31.90/0.8960	30.76/0.9140	37.22/0.9729
LapSRN		37.52/0.9590	33.08/0.9130	31.80/0.8950	30.41/0.9100	37.27/0.9740
CARN-M		37.53/0.9583	33.26/0.9141	31.92/0.8960	31.23/0.9193	-/-
DRRN		37.74/0.9591	33.23/0.9136	32.05/0.8973	31.23/0.9188	37.92/0.9760
SRFBN-S		37.78/0.9597	33.35/0.9156	32.00/0.8970	31.41/0.9207	38.06/0.9757
AWSRN-SD		37.86/0.9600	33.41/0.9161	32.07/0.8984	31.67/0.9237	38.20/0.9762
A2F-SD		<u>37.91/0.9602</u>	<u>33.45/0.9164</u>	32.08/0.8986	<u>31.79/0.9246</u>	38.52/0.9767
ESRN-V		37.85/0.9600	33.42/0.9161	<u>32.10/0.8987</u>	<u>31.79/0.9248</u>	-/-
LAPAR-B		37.87/0.9600	33.39/0.9162	<u>32.10/0.8987</u>	31.62/0.9235	38.27/0.9764
NLE3DNet		37.94/0.9604	33.57/0.9172	32.15/0.8993	31.91/0.9266	<u>38.47/0.9768</u>
VDSR	3	33.66/0.9213	29.77/0.8314	28.82/0.7976	27.14/0.8279	32.01/0.9310
LapSRN		33.81/0.9220	29.79/0.8325	28.82/0.7980	27.07/0.8275	32.21/0.9350
CARN-M		33.99/0.9236	30.08/0.8367	28.91/0.8000	27.55/0.8385	-/-
DRRN		34.03/0.9244	29.96/0.8349	28.95/0.8004	27.53/0.8378	32.74/0.9390
SRFBN-S		34.20/0.9255	30.10/0.8372	28.96/0.8010	27.66/0.8415	33.02/0.9404
AWSRN-SD		34.18/ 0.9273	30.21/0.8398	28.99/0.8027	27.80/0.8444	33.13/0.9416
A2F-SD		<u>34.23/0.9259</u>	30.22/0.8395	29.01/0.8028	27.91/0.8465	<u>33.29/0.9424</u>
ESRN-V		<u>34.23/0.9262</u>	<u>30.27/0.8400</u>	<u>29.03/0.8039</u>	<u>27.95/0.8481</u>	-/-
LAPAR-B		34.20/0.9256	30.17/0.8387	<u>29.03/0.8032</u>	27.85/0.8459	33.15/0.9417
NLE3DNet		<u>34.35/0.9268</u>	30.33/0.8420	29.08/0.8046	28.06/0.8502	33.47/0.9445
VDSR	4	31.35/0.8838	28.01/0.7674	27.29/0.7251	25.18/0.7524	28.83/0.8809
LapSRN		31.54/0.8850	28.19/0.7720	27.32/0.7280	25.21/0.7560	29.09/0.8845
CARN-M		31.92/0.8903	28.42/0.7762	27.44/0.7304	25.62/0.7694	-/-
DRRN		31.68/0.8888	28.21/0.7720	27.38/0.7284	25.44/0.7638	29.46/0.8960
SRFBN-S		31.98/0.8923	28.45/0.7779	27.44/0.7313	25.71/0.7719	29.91/0.9008
AWSRN-SD		31.98/0.8921	28.46/0.7786	27.48/ <u>0.7368</u>	25.74/0.7746	30.09/0.9024
A2F-SD		<u>32.06/0.8928</u>	<u>28.47/0.7790</u>	27.48/0.7373	25.80/0.7767	<u>30.16/0.9038</u>
ESRN-V		31.99/0.8919	<u>28.49/0.7779</u>	27.50/0.7331	<u>25.87/0.7782</u>	-/-
LAPAR-B		31.94/0.8917	28.46/0.7784	<u>27.52/0.7335</u>	25.85/0.7772	30.03/0.9025
NLE3DNet		32.14/0.8941	28.59/0.7815	27.56/0.7352	25.99/0.7819	30.43/0.9081

表 4-2 中加粗数值为最优值，下划线为次优值，本章模型综合表现最优。

4.3.2.2 主观指标对比




图 4-5 主观效果图对比

可以看出本章模型对于图像纹理的恢复更好，更清晰，更真实。

4.3.3 消融实验分析

针对本章提出残差块对于模型的具体提升，开展了消融实验，实验在 4 倍模型上进行，对比了有无非局部信息融合模块情况下参数量和不同数据集的 PSNR 结果变化，对比的结果如下，括号为变化情况。

表 4-3 非局部模块对性能的影响

模型	参数量 (K)	PSNR(dB)/SSIM					平均
		Set5	Set14	B100	Urban100	Manga109	
E3DCSRNet (baseline)	178	32.10	28.53	27.52	25.90	30.35	28.88
NLE3DNet	178(+0)	32.14	28.59	27.56	25.99	30.43	28.94(+0.06)

由表 4-3 可见，加入跨尺度非局部信息融合模块的网络在参数量没有显著增加的情况，五个数据集的平均 PSNR 增加了 0.06，证明了本章方法的有效性。

4.4 本章小结

本章设计了一种基于跨尺度信息融合的轻量级非局部注意力 CSNLIFB，并在第三章模型 E3DCSRNet 的基础上设计了非局部高效 3D 网络 NLE3DNet。本章开始介绍了有关图像中非局部信息利用的最新相关工作，非局部的方法往往需要对整个图像所有信息计算相关性，计算量较大；同时，自然图像中往往存在较多的相似结构，可以用来补充下采样时缺失的信息，弥补卷积操作感受野受限的不足，由此设计了跨尺度非局部信息融合模块 CSNLIFB。首先本章简要介绍了 NLE3DNet，网络在第三章模型的基础上，在特征提取阶段后添加了一个 CSNLIFB 来融合跨尺度信息。CSNLIFB 采用了局部敏感哈希的方法，只需要对输入特征和查询特征分别做一次遍历，计算其在随机向量空间投影所得到的哈希编码，即可对不同的特征进行分类，只需要计算相似的特征之间的相似度即可，大大的减小了计算量。在实验部分，同参数量接近的模型进行对比，NLE3Dnet 在参数量接近的模型中确实获得了较好的效果，消融实验探究了非局部注意力模块对于模型性能的影响，相较于原网络，添加了非局部注意力模块的网络性能得到了提升。

第 5 章 结论与展望

5.1 本文总结

当今互联网快速的发展也让图像在日常生活中扮演越来越重要的角色, 社交媒体和新闻平台每天都会产生大量的图片, 但是高分辨率的图像传输对网络带宽和稳定性更高, 在通信中传输低分辨率图像, 需要查看图像细节时再进行超分辨率操作无疑可以节省大量资源。同时在高光谱遥感图像、医疗卫生图像和监控图像领域, 都需要获得更高分辨率的图像, 图像超分辨率技术有着广泛的应用场景。传统的基于插值和基于重建的方法取得了一定的成果, 而基于学习的方法则将超分辨率问题的解决向前推进了一大步, 尤其是近十年和机器学习、深度学习的结合, 该领域取得较大的进展。神经元模型的建立, 深度学习策略的提出, 逐渐可以解决现实中十分复杂的问题, 但是图像由于尺寸较大, 导致特征维度较大, 处理较为困难, 而卷积神经网络通过参数空间共享的方式解决了这个问题, 随后也在超分辨率领域发光发热。根据高分辨率图像到低分辨率图像的降质过程, 建立了深度学习超分辨率算法的基本网络结构, 一般由特征提取、特征映射和图像重建三部分组成。但是如今多数效果较好的模型都拥有较大的计算量和参数量, 在日常中往往很难具有充足的计算资源, 基于此, 轻量级模型具有更强的实际使用价值, 但是很多轻量级网络会采用通道压缩的方式降低参数量和计算量, 导致模型性能下降, 为了改进此问题, 本文将重点放在了设计一个性能更好的轻量级的神经网络模型上。为了解决通道压缩带来信息损失的问题, 本文提出了一种基于 3D 卷积设计的轻量级卷积层; 为了进一步提升网络性能, 解决卷积操作感受野受限的问题, 本文提出了跨尺度非局部信息融合模块。以下为本文具体工作:

很多现有的轻量级超分辨率网络为了减少参数量和计算量, 选择减小网络主通道数或者压缩特征维度, 但是会导致网络性能下降, 甚至出现模型训练不稳定、无法收敛等问题。针对以上问题, 本文提出了一种基于 3D 卷积设计的轻量级卷积层, 并以此为基础设计了一个高效的超分辨率网络, 在保持较小参数量的情况下获得较大的特征维度, 取得了较好的性能。

卷积是局部的操作, 尽管可以通过加大网络深度, 提高网络层数来提升感受野, 但是随着层数的加深, 距离当前特征较远的特征影响会越来越小, 无法根本上解决问题。为了解决这个问题, 本文采用了非局部注意力来提升网络性能。自然图像中往往存在一些跨尺度的相似图像, 可以用来补充缺失的信息。基于此, 本文设计了一个跨尺度非局部信息融合模块, 在基本不增加参数量的前提下获得

了一定的性能提升。

5.2 本文未来研究展望

为了获得更好的轻量级网络性能，本文设计了基于 3D 卷积的轻量级卷积层以及相应的超分辨率网络；为了进一步提升网络性能，加强对图像信息的利用，本文提出了一个跨尺度轻量级非局部注意力设计，这些方法都取得了一定的效果，但是还有值得改进和提升的方面，还需要继续的探究和实验，未来的研究可能方向如下：

基于 3D 卷积设计的轻量级卷积层确实具有较小的参数，但是很依赖通道维度大小和深度维度大小的平衡，两者共同决定了图像的特征维度，通道维对参数量影响较大，深度维对计算速度影响较大，需要更多的实验来设计调整才能获得性能与计算速度较为平衡的网络；在图像的特征提取部分，无法很便捷的调整输出的深度维大小，未来可以改进为基于动态卷积核的形式，自适应生成合适大小的卷积核来获得目标维度大小；残差块的设计考虑了上下支路不同尺度的信息，但是上下支路的感受野差距较小，可以跟换为更大尺度的卷积核获得更丰富的尺度信息。

跨尺度非局部信息融合模块利用了自然图像中存在跨尺度相似图像块，补充了下采样损失的信息，但是其实同样的图像存在多个不同尺度的相似图像块，而文中方法只考虑了一个尺度；同样，图像中也存在不同角度上彼此相似的图像块，需要通过旋转等操作后在进行搜索，同样是可以用来进一步提升网络性能的方向；下采样的图像块可能会与原图像块在分布上存在差异，融合时会有较多噪声影响，未来考虑在融合前对相似图像块进行配准对齐，获得更好的融合效果。

参考文献

- [1] Gu K, Liu M, Zhai G, et al. Quality Assessment Considering Viewing Distance and Image Resolution[J]. IEEE Transactions on Broadcasting, 2015, 61(3): 520–531.
- [2] LeCun Y, Bengio Y, Hinton G. Deep learning[J]. Nature, Nature Publishing Group, 2015, 521(7553): 436–444.
- [3] Yanming, Guo, Yu, et al. Deep learning for visual understanding: A review[J]. Neurocomputing, Elsevier, 2016, 187: 27–48.
- [4] A Voulodimos, N Doulamis, A Doulamis, et al. Deep Learning for Computer Vision: A Brief Review[EB/OL]. [2022-03-16]. <https://www.hindawi.com/journals/cin/2018/7068349/>.
- [5] Garcia-Garcia A, Orts-Escolano S, Oprea S, et al. A Review on Deep Learning Techniques Applied to Semantic Segmentation[J]. 2017.
- [6] A Garcia-Garcia, S Orts-Escolano, S Oprea, et al. A survey on deep learning techniques for image and video semantic segmentation[J]. Applied Soft Computing, Elsevier, 2018, 70: 41–65.
- [7] Hu G, Yang Y, Yi D, et al. When Face Recognition Meets With Deep Learning: An Evaluation of Convolutional Neural Networks for Face Recognition[C]//2015: 142–150.
- [8] Mei Wang, Weihong Deng. Deep face recognition: A survey[J]. Neurocomputing, Elsevier, 2021, 429: 215–244.
- [9] S Li, W Song, L Fang, Y Chen, et al. Deep Learning for Hyperspectral Image Classification: An Overview | IEEE Journals & Magazine | IEEE Xplore[EB/OL]. [2022-03-16]. <https://ieeexplore.ieee.org/abstract/document/8697135>.
- [10] Cai L, Gao J, Zhao D. A review of the application of deep learning in medical image classification and segmentation[J]. Annals of Translational Medicine, AME Publications, 2020, 8(11).
- [11] Zhao, Zhong-Qiu, P Zheng, Xu, Shou-Tao, et al. Object Detection With Deep Learning: A Review | IEEE Journals & Magazine | IEEE Xplore[EB/OL]. [2022-03-16]. <https://ieeexplore.ieee.org/abstract/document/8627998>.
- [12] L Liu, W Ouyang, X Wang, et al. Deep Learning for Generic Object Detection: A Survey | SpringerLink[EB/OL]. [2022-03-16]. <https://link.springer.53yu.com/>.
- [13] Malinowski M, Rohrbach M, Fritz M. Ask Your Neurons: A Deep Learning Approach to Visual Question Answering[J]. International Journal of Computer Vision, 2017, 125(1): 110–135.
- [14] JDV Ouwerkerk. Image super-resolution survey[J]. Image and Vision Computing,

- Elsevier, 2006, 24(10): 1039–1052.
- [15] Yang D, Li Z, Xia Y, et al. Remote sensing image super-resolution: Challenges and approaches[C]//2015 IEEE International Conference on Digital Signal Processing (DSP). 2015: 196–200.
- [16] Dong W, Fu F, Shi G, et al. Hyperspectral Image Super-Resolution via Non-Negative Structured Sparse Representation[J]. IEEE Transactions on Image Processing, 2016, 25(5): 2337–2352.
- [17] JS Isaac, R Kulkarni. Super resolution techniques for medical image processing | IEEE Conference Publication | IEEE Xplore[EB/OL]. [2022-03-16]. <https://ieeexplore.ieee.org/abstract/document/7095900>.
- [18] Farrugia R A, Galea C, Guillemot C. Super Resolution of Light Field Images Using Linear Subspace Projection of Patch-Volumes[J]. IEEE Journal of Selected Topics in Signal Processing, 2017, 11(7): 1058–1071.
- [19] RP Rambo, JA Tainer. Super-Resolution in Solution X-Ray Scattering and Its Applications to Structural Systems Biology | Annual Review of Biophysics[EB/OL]. [2022-03-16]. <https://www.annualreviews.org/doi/abs/10.1146/annurev-biophys-083012-130301>.
- [20] H Greenspan, G Oz, N Kiryati, et al. MRI inter-slice reconstruction using super-resolution[J]. Magnetic Resonance Imaging, Elsevier, 2002, 20(5): 437–446.
- [21] Z Yan, J Li, L Yao, et al. Super resolution in CT - Yan - 2015 - International Journal of Imaging Systems and Technology - Wiley Online Library[EB/OL]. [2022-03-16]. <https://onlinelibrary.wiley.com/doi/full/10.1002/ima.22125>.
- [22] Rukundo O, Cao H. Nearest Neighbor Value Interpolation[J]. 2012.
- [23] Arondiga, F. Monotone Piecewise Bicubic Interpolation | SIAM Journal on Numerical Analysis[EB/OL]. [2022-03-16]. <https://epubs.siam.org/doi/abs/10.1137/0722023>.
- [24] Nitta K, Shogenji R, Miyatake S, et al. Image reconstruction for thin observation module by bound optics by using the iterative backprojection method[J]. Applied Optics, Optica Publishing Group, 2006, 45(13): 2893–2900.
- [25] Sønderby C K, Caballero J, Theis L, et al. Amortised MAP Inference for Image Super-resolution[J]. 2016.
- [26] Elad M, Hel-Or Y. A fast super-resolution reconstruction algorithm for pure translational motion and common space-invariant blur | IEEE Journals & Magazine | IEEE Xplore[EB/OL]. [2022-03-16]. <https://ieeexplore.ieee.org/abstract/document/935034>.
- [27] Tipping M, Bishop C. Bayesian Image Super-Resolution[C]//Advances in Neural Information Processing Systems. MIT Press, 2002, 15.
- [28] Dong C, Loy C C, He K, et al. Learning a Deep Convolutional Network for Image

- Super-Resolution[C]//Computer Vision – ECCV 2014. Springer, Cham, 2014: 184–199.
- [29]Ahn N, Kang B, Sohn K-A. Fast, Accurate, and Lightweight Super-Resolution with Cascading Residual Network[C]//2018: 252–268.
- [30]Agrawal A, Gupta M, Veeraraghavan A, et al. Optimal coded sampling for temporal super-resolution[C]//2010 IEEE Computer Society Conference on Computer Vision and Pattern Recognition. 2010: 599–606.
- [31]Gibbon K T, Bailey D G. A novel approach to real-time bilinear interpolation[C]//Proceedings. DELTA 2004. Second IEEE International Workshop on Electronic Design, Test and Applications. 2004: 126–131.
- [32]Elad M, Feuer A. Super-resolution reconstruction of an image[C]//Proceedings of 19th Convention of Electrical and Electronics Engineers in Israel. 1996: 391–394.
- [33]T Yi, P Yan, Y Yuan, et al. Single-image super-resolution via local learning | SpringerLink[EB/OL]. [2022-03-16]. <https://link.springer.53yu.com/>.
- [34]Shuyuan, Yang, Zhiyi, et al. Dual-Geometric Neighbor Embedding for Image Super Resolution With Sparse Tensor | IEEE Journals & Magazine | IEEE Xplore[EB/OL]. [2022-03-16]. <https://ieeexplore.ieee.org/abstract/document/6805627>.
- [35]LY Zhou, SU Cai-Xia, YF Cao, et al. Image Super-Resolution Via Sparse Representation | IEEE Journals & Magazine | IEEE Xplore[EB/OL]. [2022-03-16]. <https://ieeexplore.ieee.org/abstract/document/5466111>.
- [36]Albawi S, Mohammed T A, Al-Zawi S. Understanding of a convolutional neural network[C]//2017 International Conference on Engineering and Technology (ICET). 2017: 1–6.
- [37]Jaderberg M, Simonyan K, Zisserman A, et al. Spatial Transformer Networks[C]//Advances in Neural Information Processing Systems. Curran Associates, Inc., 2015, 28.
- [38]Dong C, Loy C C, He K, et al. Image Super-Resolution Using Deep Convolutional Networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2016, 38(2): 295–307.
- [39]D Chao, CL Chen, X Tang. Accelerating the Super-Resolution Convolutional Neural Network | SpringerLink[EB/OL]. [2022-03-16]. <https://link.springer.53yu.com/>.
- [40]Shi W, Caballero J, Huszár F, et al. Real-Time Single Image and Video Super-Resolution Using an Efficient Sub-Pixel Convolutional Neural Network[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 1874–1883.
- [41]He K, Zhang X, Ren S, et al. Deep Residual Learning for Image

- Recognition[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 770–778.
- [42]Kim J, Lee J K, Lee K M. Accurate Image Super-Resolution Using Very Deep Convolutional Networks[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 1646–1654.
- [43]Simonyan K, Zisserman A. Very Deep Convolutional Networks for Large-Scale Image Recognition[J]. Computer Science, 2014.
- [44]Kim J, Lee J K, Lee K M. Deeply-Recursive Convolutional Network for Image Super-Resolution[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 1637–1645.
- [45]Tai Y, Yang J, Liu X. Image Super-Resolution via Deep Recursive Residual Network[C]//2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2017: 2790–2798.
- [46]Lai W-S, Huang J-B, Ahuja N, et al. Fast and Accurate Image Super-Resolution with Deep Laplacian Pyramid Networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2019, 41(11): 2599–2613.
- [47]Ledig C, Theis L, Huszár F, et al. Photo-Realistic Single Image Super-Resolution Using a Generative Adversarial Network[C]//2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2017: 105–114.
- [48]Lim B, Son S, Kim H, et al. Enhanced Deep Residual Networks for Single Image Super-Resolution[C]//2017 IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW). 2017: 1132–1140.
- [49]Haris M, Shakhnarovich G, Ukita N. Deep Back-Projection Networks for Super-Resolution[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2018: 1664–1673.
- [50]Hu J, Shen L, Albanie S, et al. Squeeze-and-Excitation Networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020, 42(8): 2011–2023.
- [51]Zhang Y, Li K, Li K, et al. Image Super-Resolution Using Very Deep Residual Channel Attention Networks[C]//Computer Vision – ECCV 2018. Springer, Cham, 2018: 294–310.
- [52]Dai T, Cai J, Zhang Y, et al. Second-Order Attention Network for Single Image Super-Resolution[C]//2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 11057–11066.
- [53]Guo Y, Chen J, Wang J, et al. Closed-Loop Matters: Dual Regression Networks for Single Image Super-Resolution[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 5406–5415.
- [54]Ronneberger O, Fischer P, Brox T. U-Net: Convolutional Networks for Biomedical

- Image Segmentation[C]//Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015. Springer, Cham, 2015: 234–241.
- [55]Zhou S, Zhang J, Zuo W, et al. Cross-Scale Internal Graph Neural Network for Image Super-Resolution[C]//LAROCHELLE H, RANZATO M, HADSELL R, et al. Advances in Neural Information Processing Systems. Curran Associates, Inc., 2020, 33: 3499–3509.
- [56]Liang J, Cao J, Sun G, et al. SwinIR: Image Restoration Using Swin Transformer[C]//IEEE Computer Society, 2021: 1833–1844.
- [57] Warren S, Mcculloch, Walter Pitts. A logical calculus of the ideas immanent in nervous activity | SpringerLink[EB/OL]. [2022-03-16]. <https://link.springer.53yu.com/article/10.1007/BF02478259>.
- [58]Han J, Moraga C. The influence of the sigmoid function parameters on the speed of backpropagation learning[C]//From Natural to Artificial Neural Computation. Springer, Berlin, Heidelberg, 1995: 195–201.
- [59]Glorot X, Bordes A, Bengio Y. Deep Sparse Rectifier Neural Networks[C]//Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics. JMLR Workshop and Conference Proceedings, 2011: 315–323.
- [60]He K, Zhang X, Ren S, et al. Delving Deep into Rectifiers: Surpassing Human-Level Performance on ImageNet Classification[C]//2015 IEEE International Conference on Computer Vision (ICCV). 2015: 1026–1034.
- [61]Fukushima K, Miyake S. Neocognitron: A Self-Organizing Neural Network Model for a Mechanism of Visual Pattern Recognition[J]. Competition and Cooperation in Neural Nets, Springer, Berlin, Heidelberg, 1982: 267–285.
- [62]LeCun Y, Boser B, Denker J S, et al. Backpropagation Applied to Handwritten Zip Code Recognition[J]. Neural Computation, 1989, 1(4): 541–551.
- [63]Iandola F N, Han S, Moskewicz M W, et al. SqueezeNet: AlexNet-level accuracy with 50x fewer parameters and <0.5MB model size[J]. arXiv:1602.07360 [cs], 2016.
- [64]Wang X, Girshick R, Gupta A, et al. Non-local neural networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 7794–7803.
- [65]Fu J, Liu J, Tian H, et al. Dual attention network for scene segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2019: 3146–3154.
- [66]Z Huang, X Wang, L Huang, et al. CCNet: Criss-Cross Attention for Semantic Segmentation | IEEE Journals & Magazine | IEEE Xplore[EB/OL]. [2022-03-16]. <https://ieeexplore.ieee.org/abstract/document/9133304>.

-
- [67]Tai Y, Yang J, Liu X, et al. MemNet: A Persistent Memory Network for Image Restoration[C]//2017 IEEE International Conference on Computer Vision (ICCV). 2017: 4549–4557.
 - [68]Han W, Chang S, Liu D, et al. Image Super-Resolution via Dual-State Recurrent Networks[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2018: 1654–1663.
 - [69]Huang G, Liu Z, van der Maaten L, et al. Densely Connected Convolutional Networks[J]. 2016.
 - [70]Tong T, Li G, Liu X, et al. Image Super-Resolution Using Dense Skip Connections[C]//2017 IEEE International Conference on Computer Vision (ICCV). 2017: 4809–4817.
 - [71]Zhang Y, Tian Y, Kong Y, et al. Residual Dense Network for Image Super-Resolution[C]//2018.
 - [72]Wang X, Yu K, Wu S, et al. ESRGAN: Enhanced Super-Resolution Generative Adversarial Networks[C]//2018.
 - [73]Li J, Fang F, Mei K, et al. Multi-scale Residual Network for Image Super-Resolution[C]//Computer Vision – ECCV 2018. Springer, Cham, 2018: 527–542.
 - [74]JY Zhu, T Park, P Isola, et al. Unpaired Image-to-Image Translation Using Cycle-Consistent Adversarial Networks | IEEE Conference Publication | IEEE Xplore[EB/OL]. [2022-03-16].
<https://ieeexplore.ieee.org/abstract/document/8237506>.
 - [75]Shocher A, Cohen N, Irani M. Zero-Shot Super-Resolution Using Deep Internal Learning[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2018: 3118–3126.
 - [76]Zhao H, Kong X, He J, et al. Efficient Image Super-Resolution Using Pixel Attention[G]//BARTOLI A, FUSIELLO A. Computer Vision – ECCV 2020 Workshops. Cham: Springer International Publishing, 2020, 12537: 56–72.
 - [77]Hu X, Mu H, Zhang X, et al. Meta-SR: A Magnification-Arbitrary Network for Super-Resolution[C]//2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 1575–1584.
 - [78]R Zhang, P Isola, AA Efros, et al. The Unreasonable Effectiveness of Deep Features as a Perceptual Metric | IEEE Conference Publication | IEEE Xplore[EB/OL]. [2022-03-16].
<https://ieeexplore.ieee.org/abstract/document/8578166>.
 - [79]Hui Z, Wang X, Gao X. Fast and Accurate Single Image Super-Resolution via Information Distillation Network[C]//2018: 723–731.
 - [80]X Chu, B Zhang, H Ma. Fast, Accurate and Lightweight Super-Resolution with Neural Architecture Search | IEEE Conference Publication | IEEE Xplore[EB/OL].

-
- [2022-03-16]. <https://ieeexplore.ieee.org/abstract/document/9413080>.
- [81]Wang C, Li Z, Shi J. Lightweight Image Super-Resolution with Adaptive Weighted Learning Network[J]. arXiv:1904.02358 [cs], 2019.
- [82]H Ma, X Chu, B Zhang. A Matrix-in-matrix Neural Network for Image Super Resolution[EB/OL]. [2022-03-16]. <https://arxiv.53yu.com/abs/1903.07949>.
- [83]Li B, Wang B, Liu J, et al. s-LWSR: Super Lightweight Super-Resolution Network[J]. IEEE Transactions on Image Processing, 2020, 29: 8368–8380.
- [84]Hui Z, Gao X, Yang Y, et al. Lightweight Image Super-Resolution with Information Multi-distillation Network[C]//Proceedings of the 27th ACM International Conference on Multimedia. Nice France: ACM, 2019: 2024–2032.
- [85]Li Z, Yang J, Liu Z, et al. Feedback Network for Image Super-Resolution[C]//2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 3862–3871.
- [86]Wang X, Wang Q, Zhao Y, et al. Lightweight Single-Image Super-Resolution Network with Attentive Auxiliary Feature Learning[J]. 2020.
- [87]Song D, Xu C, Jia X, et al. Efficient Residual Dense Block Search for Image Super-Resolution[J]. 2019.
- [88]Li W, Zhou K, Qi L, et al. LAPAR: Linearly-Assembled Pixel-Adaptive Regression Network for Single Image Super-resolution and Beyond[C]//LAROCHELLE H, RANZATO M, HADSELL R, et al. Advances in Neural Information Processing Systems. Curran Associates, Inc., 2020, 33: 20343–20355.
- [89]Ai W, Tu X, Cheng S, et al. Single Image Super-Resolution Via Residual Neuron Attention Networks[C]//2020 IEEE International Conference on Image Processing (ICIP). 2020: 1586–1590.
- [90]Wang H, Su D, Liu C, et al. Deformable Non-Local Network for Video Super-Resolution[J]. IEEE Access, 2019, 7: 177734–177744.
- [91]Yi P, Wang Z, Jiang K, et al. Progressive Fusion Video Super-Resolution Network via Exploiting Non-Local Spatio-Temporal Correlations[C]//2019 IEEE/CVF International Conference on Computer Vision (ICCV). 2019: 3106–3115.
- [92]Mei Y, Fan Y, Zhou Y, et al. Image Super-Resolution With Cross-Scale Non-Local Attention and Exhaustive Self-Exemplars Mining[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 5689–5698.
- [93]Mei Y, Fan Y, Zhang Y, et al. Pyramid Attention Networks for Image Restoration[J]. 2020.
- [94]Mei Y, Fan Y, Zhou Y. Image Super-Resolution with Non-Local Sparse Attention[C]//2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2021: 3516–3525.

致 谢

写下致谢时，我的心情十分的不平静，研究生的三年中疫情肆虐两年有余，回顾往往心怀不安。疫情期间经历过隔离，担心过家人，更忧心自己的学业和学习任务。三年时光消弭的无声无息，更是错过了许多，但也是这三年，让我记住了更多。虽然疫情物理上隔断了时空，但是阻断不了人与人间的羁绊。

三年里，我最感谢我的导师——周登文教授。在我初入实验室之时，对于个人所要面对的一切都是迷茫的，正是导师此时指导了我，为了我们这一届研究生适时安排了充分的学习任务，在不断讨论和学习中我们都得到了飞速的成长；导师又十分的有耐心，悉心指导我们不懂不会的地方，加快了我们课题的研究速度。但是不久后的研一的寒假，新冠疫情爆发，正值新年，全国迅速调整，进入全体抗疫状态。在我们最不安的时候周老师在安慰我们，为了防止我们课题进度受影响，重新制定了科研的计划与方案，在疫情和未开学的日子都未曾耽搁，给我们吃了一颗定心丸。三年来我的个人成长，离不开导师的敦敦教诲和悉心教导。

在艰难的时刻，实验室中的同学团结一致，共克时艰，我们经常一同交流，相互帮助。大家来自不同的地域，来自不同专业，一起面对科研的任务，在谈论诞生思维的火花。感谢师兄指导的事无巨细，不耐其烦；感谢同级同学的相互扶持，共同阅读论文，交流前沿观点，互相进步；感谢学弟学妹，虽然晚一年进入实验室，但是学习速度令我们这些学长学姐感叹，我从他们中看到的不仅是新颖的想法，更是热爱科研的拼搏。

最后对疫情中抗疫的基层工作者、医护人员和各种伸出自己援手投身疫情防控中的人表示感谢，没有你们，我不可能安安全全进入校园，恢复科研工作进度，辛苦的付出，让多数人得到安稳的环境，我心存感激。

研究生生活结束，但是生活的“研究”还会继续。但行好事，莫问前程。