

您的稿件编号：（新投稿无编号时暂不作填写）

本稿件需要修改时请联系：

作者： 刘子涵

手机号： 16601251217

邮箱：120212227102@ncepu.edu.cn

请务必确认好作者、单位、基金等相关信息，投稿成功后不得随意修改

<http://www.joca.cn>

doi:10.11772/j.issn.1001-9081.yyyymmnnnn

基于全局依赖 Transformer 的图像超分辨率网络

刘子涵^{1*}, 周登文¹, 刘玉铠¹

(1.华北电力大学 控制与计算机工程学院, 北京市 102206)

(*120212227102@ncepu.edu.cn)

摘要: 目前, 大多数基于 Transformer 的图像超分辨率模型, 在参数量小、网络层数少的情况下无法建立全局依赖, 限制了模型的性能。为了进一步发挥 Transformer 在超分辨率模型中的潜力, 提出了基于全局依赖 Transformer 的图像超分辨率网络, 其主要组成部分为残差方形轴向窗口块, 其内部的轴向窗口 Transformer 残差层利用轴向窗口和自注意力, 可以使每个像素与整个特征图建立起全局依赖。此外, 目前大多数图像超分辨率模型的超分辨率图像重建模块都由卷积组成, 为了发挥 Transformer 在其中的作用, 把 Transformer 与卷积进行结合, 共同重建超分辨率图像。通过实验表明, 基于全局依赖 Transformer 的图像超分辨率网络在各个倍数的超分辨率任务, 与其他先进的模型相比, 在大尺寸数据集上的峰值信噪比指标上有超过 0.3dB 的提升。

关键词: 图像超分辨率; Transformer; 自注意力; 全局依赖; 轴向窗口

中图分类号: TP391.4; TP183

文献标志码: A

Image Super-Resolution Network Based on Global Dependency Transformer

LIU Zihan^{1*}, ZHOU Dengwen¹, LIU Yukai¹


(1. School of Control and Computer Engineering, North China Electric Power University, Beijing 102206, China)

Abstract: At present, most Transformer-based image super-resolution models cannot establish global dependencies when the number of parameters is small and the number of network layers is small, which limits the performance of the model. In order to further exploit the potential of the Transformer in the super-resolution model, an image super-resolution network based on the global dependence Transformer is proposed. Its main component is the residual square axial window block, and the internal axial window Transformer residual layer uses axial window and self-attention, which can make each pixel globally dependent on the entire feature map. In addition, the super-resolution image reconstruction module of most current image super-resolution models is composed of convolutions. In order to play the role of Transformer in it, Transformer and convolution are combined to jointly reconstruct super-resolution images. Experiments show that the image super-resolution network based on the global Transformer has an improvement of more than 0.3dB in the peak signal to noise ratio index on large-scale datasets compared with other advanced models in various super-resolution tasks.

Keywords: Image Super-resolution; Transformer; Self-Attention; Global Dependency; Axial Window

0 引言

单图像超分辨率(Single Image Super-Resolution, SISR)是计算机视觉和图像处理中的一个经典问题, 目标由低分辨率(Low Resolution, LR)图像生成对应的高分辨率图像(High Resolution, HR)。近年来, 基于卷积神经网络(Convolutional Neural Network, CNN)的图像超分辨率模型^[1-6]因其恢复图像高频信息的能力而备受欢迎, 并在图像超分辨率领域占据主导地位。



划分的窗口 A像素建立依赖的区域

图1 移动窗口策略

Fig.1 Strategy of shift window

近几年, 由于 Transformer^[7]在自然语言处理(natural language processing, NLP)领域的广泛应用, Transformer 逐渐

收稿日期: 20yy-mm-dd; 修回日期: 20yy-mm-dd; 录用日期: yyyy-mm-dd。

作者简介: 刘子涵(1997—), 男, 河北石家庄人, 硕士研究生, 主要研究方向: 深度学习、计算机视觉; 周登文(1965—), 男, 湖北省黄梅县人, 教授, 硕士, 主要研究方向: 图像去噪、图像超分辨率; 刘玉铠(1996—), 男, 河北衡水人, 硕士研究生, 主要研究方向: 深度学习、计算机视觉。

在计算机视觉领域被研究和使用的,取得了非常显著的效果。**Transformer** 的自注意力的计算量与参与计算的像素点数量成 2 次方关系。为了减少计算量, **SwinIR**^[8] 基于 **Swin Transformer**^[9] 把特征图划分为不重叠的方形窗口, 在方形窗口内部进行自注意力计算, 并使用移动窗口策略建立窗口间的联系, 取得了超越基于 CNN 的模型性能。

尽管 **SwinIR**^[8] 在图像超分辨率领域取得了很大的成功, 但其存在一个固有的缺陷: 在方形窗口内部进行自注意力仅仅会让模型有良好的局部信息处理能力。使用移动窗口策略, 如图 1 所示, 与使用卷积类似, 随着网络层的堆叠, 像素 A 建立依赖的区域会逐渐扩大, 在网络层数少、参数量小的网络中无法建立全局依赖, 这会限制网络的性能。

针对上述问题, 本文提出了基于全局依赖 **Transformer** 的图像超分辨率网络(Image Super-Resolution Network Based on Global Dependency Transformer, **GDTSR**)。根据 Ho 等^[10] 提出的轴向窗口, 本文提出了轴向窗口 **Transformer** 残差层(Axial Window Transformer Residual Layer, **AWTRL**), 经过 2 个方向的轴向窗口内部的自注意力后, 每个像素可以与整个特征图的所有像素点进行直接或间接地交互, 与整个特征图建立起全局依赖。如图 2 所示, 对于任意像素点 B, 像素 A 可以通过两方向的轴向窗口内部自注意力(图中黑色窗口)与其建立依赖, 像素 A 可以用类似的方式与整个特征图的所有像素建立依赖, 即全局依赖。同时本文注意到, 仅使用轴向窗口会使每个像素无法与临近像素直接进行自注意力, 导致模型局部信息处理能力变差, 因此本文兼顾使用与 **SwinIR**^[8] 类似的方形窗口 **Transformer** 层(Square Window Transformer Layer, **SWTL**)。由 **AWTRL** 和 **SWTL** 共同组成的残差方形轴向窗口块(Residual Square-Axial Window Block, **RSAWB**)作为 **GDTSR** 的主要组成部分。

此外, 目前单图像超分辨率模型的超分辨率重建模块大多由亚像素卷积^[11]或类似的结构组成, 鉴于 **Transformer** 在图像特征提取部分有很好的效果, 本文尝试把 **Transformer** 应用到超分辨率重建模块并设计了 **Transformer** 卷积上采样(**Transformer and Convolution Upsample**, **TACUpSample**)块。如图 3 所示, 本文提出的 **GDTSR** 与其他先进的模型相比, 性能达到了最优。

综上所述, 本文的主要贡献有:

1) 本文提出了一个基于全局依赖 **Transformer** 的图像超分辨率网络(**GDTSR**)。该网络把轴向窗口与方形窗口相结合, 让每个像素与整个特征图建立依赖, 获得整个特征图信息的




图 2 轴向窗口
Fig.2 Axial window




图 3 在 Urban100^[12]数据集上, 各种超分辨率模型 4 倍 SR 的参数数量和 PSNR 比较

Fig.3 PSNR and parameter comparison of different methods for $\times 4$ SR on dataset Urban100^[12]

补充。

2) 本文提出了一种通用的 **Transformer** 卷积上采样块(**TACUpSample**), 把 **Transformer** 引入到超分辨率重建模块与卷积一起重建高分辨率图像。

3) 实验表明, 本文提出的 **GDTSR** 结合 **TACUpSample** 后, 与其他先进的模型相比, 在 3 个倍数的超分辨率实验上, 模型性能在各个指标上都有很大提升。

1 相关工作

1.1 基于卷积神经网络的图像超分辨率模型

与传统的图像超分辨率方法^[13-14]相比, 基于学习的方法, 由于其优秀的性能而越来越受欢迎。这些方法大多从大规模的配对数据集中学习低分辨率图像到高分辨率图像之间的映射, 自开创性工作 **SRCNN**^[11]出现后, 一系列通过使用更复杂基于卷积神经网络架构的模型被提出, 如残差块^[4]和稠密块^[6]等。部分研究使用了卷积神经网络内的注意力机制, 如通道注意力^[5]和非局部注意力^[15]等。一些工作也把不同的框架应用在超分辨率领域上, 如递归神经网络^[16]等。为了生成更符合人眼视觉的图片, **Ledig** 等^[17]和 **Wang** 等^[18]使用生成对抗网络(**Generative Adversarial Network**, **GAN**)^[19]来生成超分辨率图片。

1.2 视觉 Transformer

近年来, **Transformer**^[7]在高级视觉任务领域取得了很大的成功, 包括图像分类^[9-10, 20-22]、目标检测^[20-23]等。由于 **Transformer** 的自注意力计算量与参与计算的像素数量成 2 次方关系, 这么庞大的计算量无法使整张图片的所有像素点参与运算。为了降低计算量, **Swin Transformer**^[9]提出把图像划




图4 GDTSR、RSAWB、AWTRL 和 SWTL 的结构图
Fig.4 Architecture of GDTSR, RSAWB, AWTRL and SWTL

分为多个方形窗口，在窗口内部进行自注意力计算并使用移动窗口策略建立窗口间的联系。Ho 等^[10]把特征图按照两个轴的方向进行划分,得到轴向窗口。由于 Transformer 在高级视觉领域的成功应用,Transformer 在图像超分辨率领域上的研究得到关注。Liang 等^[8]基于 Swin Transformer^[9]提出了 SwinIR, 并取得了超越基于 CNN 模型的效果。EDT^[24]把 SwinIR 中的方形窗口变为矩形窗口,并使用预训练进一步改进网络性能。ACT^[26]在 Transformer 的基础上添加卷积,使二者关注图像的不同细节,使模型获得了超越 SwinIR 的性能,但需要更大的参数量作为代价。ESRT^[25]提出了卷积与 Transformer 的串行架构,使模型更加轻量化。此外还有使用图像多尺度特征的 NGswin^[27]和用于人脸超分辨率的 MSwinSR^[28]等相继被提出。

2 方法

如图 4(a)所示,基于全局依赖 Transformer 的超分辨率网络(GDTSR)由浅层特征提取模块、深层特征提取模块和超分辨率重建模块组成。

浅层特征提取模块: 低分辨率图像 $I_{LR} \in \mathbb{R}^{H \times W \times 3}$ (H 和 W 为低分辨率图像高和宽包含的像素数量)作为输入。本文使用 3×3 的卷积 $\text{Conv}(\cdot)$ 来提取浅层特征,过程为:

$$F_0 = \text{Conv}(I_{LR}) \quad (1)$$

其中 $F_0 \in \mathbb{R}^{H \times W \times C}$ 为图像的浅层特征, C 为特征图的通道数,卷积操作具有良好的局部信息提取能力,可以有效地提取图像的浅层特征。

深层特征提取模块: 图像经过浅层特征提取后,从得到的浅层特征 F_0 中提取深层特征,深层特征提取模块包含 K 个 RSAWB 和一个 3×3 的卷积。中间特征 $F_1, F_2, \dots, F_K$ 和最终输出的深层特征 F_D 都是逐块提取的,过程为:

$$\begin{aligned} F_k &= f_{\text{RSAWB}}^k(F_{k-1}) \quad k=1,2,\dots,K \\ F_D &= \text{Conv}(F_K) \end{aligned} \quad (2)$$

其中 $f_{\text{RSAWB}}^k(\cdot)$ 是第 k 个 RSAWB 函数。

超分辨率重建模块: 鉴于 Transformer 在深层特征提取中有很好的性能,本文尝试在超分辨率重建模块中引入 Transformer,并设计了 Transformer 卷积上采样(Transformer and Convolution Upsample, TACUpSample)块作为超分辨率

重建模块。TACUpSample 通过融合浅层特征 F_0 和深层特征 F_D 来重建超分辨率图像 I_{SR} ，过程为：

$$I_{SR} = f_{TAC}(F_D + F_0) \quad (3)$$

其中 $f_{TAC}(\cdot)$ 是 TACUpSample 函数， $I_{SR} \in \mathbb{R}^{sH \times sW \times 3}$ ， s 是图像超分辨率倍数。

2.1 残差方形轴向窗口块(RSAWB)

为了解决移动窗口策略不能达到全局感受野的问题，同时兼顾局部信息处理能力，本文设计的 RSAWB 由使用方形窗口的方形窗口 Transformer 层(Square Window Transformer Layer, SWTL)和使用轴向窗口的轴向窗口 Transformer 残差层(Axial Window Transformer Residual Layer, AWTRL)以及一个卷积组成，如图 4(b)所示。中间特征是被逐层提取的，过程为：

$$\begin{aligned} F_{k,1} &= f_{S,1}^k(F_{k-1}) \\ F_{k,2} &= f_{A,H}^k(F_{k,1}) \\ F_{k,3} &= f_{S,2}^k(F_{k,2}) \\ F_{k,4} &= f_{A,W}^k(F_{k,3}) \\ F_{k,5} &= f_{S,3}^k(F_{k,4}) \\ F_k &= \text{Conv}(F_{k,5}) + F_{k-1} \end{aligned} \quad (4)$$

其中 $f_{S,j}^k(\cdot)$ 是第 k 个 RSAWB 中的第 j ($j=1,2,3$) 个 SWTL 函数， $f_{A,H}^k(\cdot)$ 和 $f_{A,W}^k(\cdot)$ 是第 k 个 RSAWB 中 H 轴向和 W 轴向的 AWTRL 函数。RSAWB 中网络层划分窗口方式如图 4(c) 所示，RSAWB 主要使用了 AWTRL 和 SWTL 去提取深层特征，其中 AWTRL 把特征图划分为轴向窗口，相比于移动窗口策略，经过两个方向的 AWTRL 后可以使每个像素与整个特征图建立依赖。SWTL 把特征图划分为方形窗口，在方形窗口内部进行自注意力可以很好地提取特征的局部信息。同时使用 AWTRL 和 SWTL，可以使模型保持良好的局部信息处理能力，同时最大程度对每个像素进行全局信息的补充，有利于提取到更有效的深层特征。

2.2 轴向窗口 Transformer 残差层(AWTRL)

如图 4(d)所示，为了使每个像素充分利用全局信息，与整个特征图建立依赖，根据^[10]，在 AWTRL 中按照 H 或 W 轴方向，把特征图划分为轴向窗口。如图 3 所示，在两个方向的窗口内部进行自注意力计算，可以使每个像素获得整个特征图所有像素信息的补充。以 H 轴窗口为例，把输入的特征图 $H \times W \times C$ 划分为 $H \times (1 \times W) \times C$ ，其中 H 为划分的窗口数量，每个窗口包含 $1 \times W$ 个像素，每个像素在其所在的 H 轴窗口内部进行自注意力。对于每个输入窗口 $X \in \mathbb{R}^{1 \times W \times C}$ ，query、key、value 矩阵 $Q, K, V \in \mathbb{R}^{1 \times W \times C}$ 的计算方式分别为：

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V \quad (5)$$

其中 $W_Q, W_K, W_V \in \mathbb{R}^{C \times C}$ 为可学习参数。自注意力过程 $SA(\cdot)$ 为：

$$SA(Q, K, V) = \text{Softmax}(QK^T)V \quad (6)$$

其中， $\text{Softmax}(\cdot)$ 是 Softmax 函数。

此外，根据 ACT^[26]，Transformer 和卷积共同使用可以使二者关注特征图的不同细节。本文在 AWTRL 中添加了由卷积，激活函数(GELU)和通道注意力(Channel Attention, CA)^[5]共同组成的残差块(Residual Block, RB)。多头自注意力(multi-head self-attention, MHSA)与残差块得到的共同特征经过多层感知机(Multi-Layer Perceptron, MLP)^[8]进一步整合。每个阶段都使用层归一化和残差。假设 AWTRL 的输入特征为 X_{in} ，整个过程可以表示为：

$$\begin{aligned} X_m &= \text{MHSA}(\text{LN}(X_{in})) + \text{RB}(\text{LN}(X_{in})) + X_{in} \\ X_{out} &= \text{MLP}(\text{LN}(X_m)) + X_m \end{aligned} \quad (7)$$

其中， $\text{RB}(\cdot)$ 是 RB 函数， $\text{LN}(\cdot)$ 是层归一化函数， $\text{MLP}(\cdot)$ 是 MLP 函数。MHSA $(\cdot)$ 是 MHSA 函数，其计算过程是：把输入特征的通道平分为 d 份，即头数为 d ，并行执行 d 次 $SA(\cdot)$ 后，拼接得到的 d 个特征作为输出特征 X_{out} 。

把特征图划分为 H 轴窗口或 W 轴窗口，并在窗口内部进行自注意力计算，其自注意力计算的计算量为 $6C^2HW + 4CH^2W$ (以 H 轴窗口为例)，在输入图像的 H 与 W 近似相等的情况下，其计算量是图像像素数量的近似 1.5 次方。相比于只使用方形窗口划分的 SwinIR^[8]等，尽管计算量有所上升，但是可以使每个像素与整个特征图建立全局依赖。经过实验可以得到，本文的方法比 SwinIR^[8]等基于移动窗口策略的模型相比，在性能上有的较大的提升。

2.3 方形窗口 Transformer 层(SWTL)

使用两个方向的轴向窗口可以使每个像素与整个特征图建立起全局依赖，但是每个像素与大部分的邻近像素没有直接进行自注意力，这会导致模型的局部信息处理能力下降。为此，本文设计了 SWTL，如图 4(e)所示。与 SwinIR^[8]的窗口划分方式相同，SWTL 把每个特征图划分为方形的局部窗口，在窗口内部进行自注意力计算。整个过程与 AWTRL 类似。并且为了轻量化，在 SWTL 中不使用 RB，以减少参数量。

2.4 Transformer 卷积上采样(TACUpSample)

目前大多数超分辨率模型的超分辨率重建模块都是使用卷积实现^[4,8,18,25]，如亚像素卷积^[11]等。由于 Transformer 在低级视觉任务中进行深层特征提取有很好的效果^[8,24]，本文尝试把 Transformer 引入到超分辨率重建模块，与卷积共同一起进行超分辨率图像的重建，如图 5 所示。整个 TACUpSample 作为超分辨率重建模块，过程为：

$$\begin{aligned} F_M &= \text{Conv}(F_0 + F_D) + \text{MHSA}(\text{LN}(F_0 + F_D)) \\ I_{SR} &= \text{Conv}(\text{PixelShuffle}(F_M)) \end{aligned} \quad (8)$$




图5 Transformer 卷积上采样块
Fig.5 Transformer and Convolution Upsample(TACUpSample)

其中 PixelShuffle(·) 是 PixelShuffle 函数, 多头自注意力计算过程与 AWTRL 中一致。

2.5 损失函数

本文通过优化参数使生成的超分辨率图像与配对的高分辨率图像逐像素 L_1 距离最小, 为:

$$L_1 = \|I_{SR} - I_{HR}\|_1 \quad (9)$$

其中 I_{HR} 为配对的高分辨率图像。

3 实验

3.1 实验设置

本文使用 DIV2K^[29] 数据集的 800 张训练图片作为训练集, 并对其进行多次 90° 的旋转和水平翻转以实现数据增强。选取 DIV2K 的 851-860 图像作为验证集记为 DIV_val10。模型中 RSAWB 的数量设置为 4, 中间特征图的通道数设置为 60。为了与其他先进的超分辨率模型进行公平的比较, 本文设计了参数量为 600K(GDTSR-T)和 1M(GDTSR)的两个轻量级模型, 两个模型仅卷积的参数量不同。此外本文额外增加 DF2K(DIV2K+Flickr2K^[29])作为训练集的实验, 记为 (GDTSR-DF), 进一步提升模型的性能。使用 $\beta_1 = 0.9$ 、 $\beta_2 = 0.999$ 、 $\varepsilon = 10^{-8}$ 的 ADAM^[30] 优化器, 训练时每个批次处理 8 张 64×64 的训练图片, 初始学习率为 2×10^{-4} , 共训练 500000 次迭代, 在 250000、400000、450000、475000 次迭代后学习率降为之前的一半。在 Set5^[31]、Set14^[32]、B100^[33]、Urban100^[12] 和 Manga109^[34] 共 5 个标准数据集上测试模型性能。在 YCbCr 空间的亮度(Y)通道上, 使用峰值信噪比(Peak Signal to Noise Ratio, PSNR)^[35] 和结构相似性 (Structural Similarity Index, SSIM)^[35] 来评估模型的性能。整个模型在 NVIDIA RTX A5000 上进行训练。

表 1 各种 SISR 网络 2 倍 SR 的平均 PSNR(dB)与 SSIM, 最好结果与次好结果分别用下划线和加粗标出

Tab. 1 Average PSNR(dB) and SSIM of $\times 2$ SR for various SISR networks, Best and second best results are in underline and highlighted

训练集	模型	参数量	Set5	Set14	B100	Urban100	Manga109
			PSNR/SSIM	PSNR/SSIM	PSNR/SSIM	PSNR/SSIM	PSNR/SSIM
DIV2K	IDN ^[36]	533K	37.83/0.9600	33.30/0.9148	32.08/0.8985	31.27/0.9196	--/--
DIV2K	IMDN ^[37]	694K	38.00/0.9605	33.63/0.9177	32.19/0.8996	32.17/0.9283	38.88/0.9774
DIV2K	LAPAR ^[38]	548K	38.01/0.9605	33.62/0.9183	32.19/0.8999	32.10/0.9283	38.67/0.9772
DIV2K	LatticeNet ^[39]	756K	38.15/0.9610	33.78/0.9193	32.25/0.9005	32.43/0.9302	--/--
DIV2K	ESRT ^[25]	677K	38.03/0.9600	33.75/0.9184	32.25/0.9005	32.58/0.9318	39.12/0.9774
DIV2K	SwinIR-light ^[8]	878K	38.14/0.9611	33.86/0.9206	32.31/0.9012	32.76/0.9340	39.12/0.9783
DIV2K	ELAN-light ^[40]	582K	38.17/0.9611	33.94/0.9207	32.30/0.9012	32.76/0.9340	39.11/0.9782
DIV2K	GDTSR-T (ours)	600K	38.17/0.9612	33.99/0.9203	32.31/0.9013	32.78/0.9342	39.27/0.9784
DIV2K	EDSR-baseline ^[4]	1370K	37.99/0.9604	33.57/0.9175	32.16/0.8994	31.98/0.9272	38.54/0.9769
DIV2K	CARN ^[41]	1592K	37.76/0.9590	33.52/0.9166	32.09/0.8978	31.92/0.9256	38.36/0.9765
DIV2K	SMSR ^[42]	985K	38.00/0.9601	33.64/0.9179	32.17/0.8990	32.19/0.9284	38.76/0.9771
DIV2K	HGSRNN ^[43]	2178K	37.80/0.9591	33.56/0.9175	32.12/0.8984	32.21/0.9292	--/--
DIV2K	SwinIR-NG ^[27]	1181K	38.17/0.9612	33.94/0.9205	32.31/0.9013	32.78/0.9340	39.20/0.9781
DIV2K	Swin2SR-s ^[44]	1000K	38.17/0.9613	33.95/0.9216	32.35/0.9024	32.85/0.9349	39.32/0.9784
DIV2K	GDTSR (ours)	1003K	<u>38.26/0.9615</u>	<u>34.13/0.9217</u>	32.35/0.9018	<u>33.15/0.9368</u>	<u>39.45/0.9787</u>
DF2K	EDT-T ^[24]	917K	<u>38.23/0.9615</u>	33.99/0.9209	<u>32.37/0.9021</u>	32.98/0.9362	<u>39.45/0.9789</u>
DF2K	GDTSR-DF (ours)	1003K	38.31/0.9616	34.28/0.9239	32.39/0.9023	33.34/0.9384	39.66/0.9788

表 2 各种 SISR 网络 3 倍 SR 的平均 PSNR(dB)值与 SSIM 值, 最好结果与次好结果分别用下划线和加粗标出
Tab. 2 Average PSNR(dB) and SSIM of $\times 3$ SR for various SISR networks, Best and second best results are in underline and highlighted

训练集	模型	参数量	Set5	Set14	B100	Urban100	Manga109
			PSNR/SSIM	PSNR/SSIM	PSNR/SSIM	PSNR/SSIM	PSNR/SSIM
DIV2K	IDN ^[36]	533K	34.11/0.9253	29.99/0.8354	28.95/0.8013	27.42/0.8359	--/--
DIV2K	IMDN ^[37]	703K	34.36/0.9270	30.32/0.8417	29.09/0.8046	28.17/0.8519	33.61/0.9445
DIV2K	LAPAR ^[38]	544K	34.36/0.9267	30.34/0.8421	29.11/0.8054	28.15/0.8523	33.51/0.9441
DIV2K	LatticeNet ^[39]	765K	34.53/0.9281	30.39/0.8424	29.15/0.8059	28.33/0.8538	--/--
DIV2K	ESRT ^[25]	770K	34.42/0.9268	30.43/0.8433	29.15/0.8063	28.46/0.8574	33.95/0.9455
DIV2K	SwinIR-light ^[8]	886K	34.62/0.9289	30.54/0.8463	29.20/0.8082	28.66/0.8624	33.98/0.9478
DIV2K	ELAN-light ^[40]	590K	34.61/0.9288	30.55/0.8463	29.21/0.8081	28.69/0.8624	34.00/0.9478
DIV2K	GDTSR-T(ours)	611K	34.62/0.9289	30.58/0.8463	29.23/0.8086	28.71/0.8629	34.35/0.9488
DIV2K	EDSR-baseline ^[4]	1555K	34.37/0.9270	30.28/0.8417	29.09/0.8052	28.15/0.8527	33.45/0.9439
DIV2K	CARN ^[41]	1592K	34.29/0.9255	30.29/0.8407	29.06/0.8034	28.06/0.8493	33.43/0.9427
DIV2K	SMSR ^[42]	993K	34.40/0.9270	30.33/0.8412	29.10/0.8050	28.25/0.8536	33.68/0.9445
DIV2K	HGSRNN ^[43]	2363K	34.35/0.9260	33.32/0.8413	29.09/0.8042	28.29/0.8546	--/--
DIV2K	SwinIR-NG ^[27]	1190K	34.64/0.9293	30.58/0.8471	29.24/0.8090	28.75/0.8639	34.22/0.9488
DIV2K	GDTSR (Ours)	1014K	<u>34.78/0.9300</u>	<u>30.67/0.8477</u>	<u>29.29/0.8102</u>	<u>29.07/0.8691</u>	<u>34.58/0.9504</u>
DF2K	EDT-T ^[24]	919K	34.73/0.9299	<u>30.66/0.8481</u>	<u>29.29/0.8103</u>	28.89/0.8674	34.44/0.9498
DF2K	GDTSR(Ours)	1014K	34.83/0.9304	30.72/0.8487	29.33/0.8109	29.22/0.8717	34.80/0.9513

表 3 各种 SISR 网络 4 倍 SR 的平均 PSNR(dB)值与 SSIM 值, 最好结果与次好结果分别用下划线和加粗标出
Tab. 3 Average PSNR(dB) and SSIM of $\times 4$ SR for various SISR networks, Best and second best results are in underline and highlighted

训练集	模型	参数量	Set5	Set14	B100	Urban10	Manga109
			PSNR/SSIM	PSNR/SSIM	PSNR/SSIM	PSNR/SSIM	PSNR/SSIM
DIV2K	IDN ^[36]	533K	31.82/0.8903	28.25/0.7730	27.41/0.7297	25.41/0.7632	--/--
DIV2K	IMDN ^[37]	715K	32.21/0.8948	28.58/0.7811	27.56/0.7353	26.04/0.7838	30.45/0.9075
DIV2K	LAPAR ^[38]	659K	32.15/0.8944	28.61/0.7818	27.61/0.7366	26.14/0.7871	30.42/0.9074
DIV2K	LatticeNet ^[39]	777K	32.30/0.8962	28.68/0.7830	27.62/0.7367	26.25/0.7873	--/--
DIV2K	ESRT ^[25]	751K	32.19/0.8947	28.69/0.7833	27.69/0.7379	36.39/0.7962	30.75/0.9100
DIV2K	SwinIR-light ^[8]	897K	32.44/0.8976	28.77/0.7858	27.69/0.7406	26.47/0.7980	30.92/0.9151
DIV2K	ELAN-light ^[40]	601K	32.43/0.8975	28.78/0.7858	27.69/0.7406	26.54/0.7982	30.92/0.9150
DIV2K	GDTSR-T(ours)	627K	32.40/0.8978	28.84/0.7869	27.72/0.7414	26.64/0.8012	31.21/0.9163
DIV2K	EDSR-baseline ^[4]	1518K	32.09/0.8938	28.58/0.7813	27.57/0.7357	26.04/0.7849	30.35/0.9067
DIV2K	CARN ^[41]	1592K	32.13/0.8937	28.60/0.7806	27.58/0.7349	26.07/0.7837	30.42/0.9070
DIV2K	SMSR ^[42]	1006K	32.12/0.8932	28.55/0.7808	27.55/0.7351	26.11/0.7868	30.54/0.9085
DIV2K	HGSRNN ^[43]	2321K	32.13/0.8940	28.62/0.7820	27.60/0.7363	26.27/0.7908	--/--
DIV2K	SwinIR-NG ^[27]	1201K	32.44/0.8980	28.83/0.7870	27.73/0.7418	26.61/0.8010	31.09/0.9161
DIV2K	GDTSR (Ours)	1030K	<u>32.65/0.9001</u>	<u>28.91/0.7885</u>	<u>27.78/0.7435</u>	<u>26.89/0.8084</u>	<u>31.47/0.9191</u>
DF2K	EDT-T ^[24]	922K	32.53/0.8991	28.88/0.7882	27.76/0.7433	26.71/0.8051	31.35/0.9180
DF2K	GDTSR (Ours)	1030K	32.71/0.9007	28.97/0.7898	27.82/0.7444	27.04/0.8120	31.64/0.9202

测试结果中, 三个倍数的 PSNR 和 SSIM 结果, 与参数量相当的其他先进的超分辨率模型相比都达到了最优, 特别是在大尺寸图像的 Urban100 和 Manga109 数据集上模型性能的提升尤为明显。与 ELAN-light^[40]相比, 本文的 GDTSR-T 使用几乎相同的参数量, 在 Manga109 数据集上 PSNR 结果平均提升了 0.26dB。与参数量更大的 SwinIR-light^[8]相比, 本文的 GDTSR-T 在 Manga109 数据集上 PSNR 结果平均提升了

3.2 实验结果

3.2.1 客观指标

不同倍数($\times 2$, $\times 3$, $\times 4$)的超分辨率实验结果如表 1、表 2、表 3 所示。本文提出的 GDTSR 在 5 个标准测试集的

0.27dB。本文的 GDTSR-DF 与 EDT-T^[24]相比,在 Urban100 数据集上的 PSNR 结果平均提升了 0.34dB,在 Manga109 数据集上的 PSNR 结果平均提升了 0.29dB。在仅使用 DIV2K 作为训练集的情况下,本文的 GDTSR 与 EDT-T^[24]相比仍有优势,在 Manga109 数据集上的 PSNR 结果平均提升了 0.09dB,与参数量相当的先进模型(如 SMSR^[42]、SwinIR-NG^[27]、Swin2SR-s^[44])相比,各个数据集的 PSNR 结果均有明显提升。

3.2.2 主观效果

各种超分辨率模型结果的主观效果如图 6 所示。以 Set14 数据集的 ppt3 为例,其他模型的结果都有不同程度的模糊或失真,本文模型恢复出的图像更加清晰,很接近于原 HR 图像。Manga109 数据集的 Shimattelkouze_vol01 也是类似。再以 Urban100 数据集的 img078 和 img059 为例,其他方法恢复出的图像,或过度模糊和失真,或条纹方向错误。本文的 GDTSR 可以恢复出更加清晰准确的纹理细节。

3.2.3 模型复杂度的比较

模型复杂度的比较如表 4 所示,模型的计算量用 FLOPs 来表示,FLOPs 指模型在推理时乘法和加法运算的次数。由表 4 可以得到,本文的模型与 SwinIR-light^[8]和 EDT-T^[24]相比,计算量有所增加。这是因为本文的 AWTSR 中使用计算量更大的轴向窗口。本文弃用了移动窗口策略,不需要在图像上进行移位操作,同时也弃用了移动窗口策略使用的掩码矩阵。此外 GDTSR 使用了更少的网络层数,这就导致虽然本文模型的计算量有所增加,但是推理速度相当,甚至推理时间有所减少。

表 4 在 4 倍 SR 的 Urban100 数据集上,3 种模型在推理时间、FLOPs 和 PSNR 的比较

Tab. 4 On dataset Urban100 of $\times 4$ SR, inference time, FLOPs and PSNR comparison in 3 models

模型	推理时间(s)	FLOPs	PSNR (dB)
SwinIR-light ^[8]	118.25	49.6G	26.47
EDT-T ^[24]	128.48	54.9G	26.71
GDTSR(ours)	110.75	71.9G	26.89




图 6 2 倍、3 倍和 4 倍 SR 的视觉效果比较
Fig.6 Visual qualitative comparison of $\times 2$, $\times 3$ and $\times 4$ SR

3.3 消融实验

3.3.1 TACUpSample 的有效性

为证明本文提出的 TACUpSample 比单独使用卷积可以取得更好的超分辨率重建效果, 本文对于超分辨率重建模块进行了消融实验, 实验设置了仅 TACUpSample 中的卷积和仅 TACUpSample 的 Transformer 作为超分辨率重建模块, 与与本文模型进行比较, 两个模型分别记为 GDTSR_0 和 GDTSR_1, 相比较的三个模型参数量几乎相同, 实验结果如表 5 所示。从实验结果可以看到, 在仅使用 Transformer 时相比于其他模型, 性能有较明显的下降, 说明在超分辨率重建模块中使用卷积是必不可少的。用本文提出的 TACUpSample, 比单独使用卷积, 参数量只增加了 0.3%, PSNR 结果有 0.04dB 的提升, 说明 Transformer 可以与卷积一起整合浅层和深层特征, 相比于与只使用卷积可以更好地重建超分辨率图像。

表 5 在验证集 DIV_val10 上, GDTSR 中不同的超分辨率重建模块, 4 倍 SR 的 PSNR 结果

Tab. 5 On validation dataset DIV_val10, PSNR results of $\times 4$ SR with different super-resolution reconstruction in GDTSR

模型	PSNR (dB)	参数量(K)
GDTSR_0	29.85	1030
GDTSR_1	29.66	1024
GDTSR	29.89	1027

此外, 为了验证 TACUpSample 的通用性, 本文把 EDSR-baseline^[4]和 SwinIR-light^[8]的超分辨率重建模块替换为 TACUpSample, 实验结果如表 6 所示。可以看到, 其他经典的轻量级超分辨率模型在使用 TACUpSample 后, 可以提升模型性能。

表 6 不同的模型中使用 TACUpSample, 在验证集 DIV_val10 上, 4 倍 SR 的 PSNR 结果

Tab. 6 On validation dataset DIV_val10, PSNR results of $\times 4$ SR with different model using TACUpSample

模型	TACUpSample	PSNR (dB)
EDSR-baseline	-	29.61
	√	29.67(↑0.06)
SwinIR-light	-	29.80
	√	29.83(↑0.03)

3.3.2 轴向窗口的有效性

本文的 AWTRL 包含 H 或 W 轴的条形窗口, 为验证两个方向的轴向窗口提供的全局信息有利于超分辨率性能的提高。本文设计把 AWTRL 中的条形窗口替换为与 SWTL 中相同的方形局部窗口, 与本文模型进行比较, 结果如表 7 所示。可以看到在整个模型中仅仅使用方形局部窗口, 虽然有更好的局部信息处理能力, 但是每个像素点无法取得较远位置信息的补充, 缺少全局依赖, 模型的性能也有较明显的下降。

表 7 AWTRL 中不同的窗口, 在验证集 DIV_val10 上, 4 倍 SR 的 PSNR 结果

Tab. 7 On validation dataset DIV_val10, PSNR results of $\times 4$ SR with different window in AWTRL

AWTRL 的窗口类型	PSNR (dB)
方形窗口	29.72
轴向窗口	29.89

3.3.3 残差块的有效性

本文的 AWTRL 额外添加了由卷积、激活函数和通道注意力^[9]组成的残差块。为验证其有效性, 设计了在 AWTRL 中不使用残差块的模型, 记为 GDTSR_w/o_RB, 与本文模型进行对比, 实验结果见表 8。可以看到使用了残差块虽然参数量会有所增加, 但是模型的性能会有显著提高。根据 ACT^[26], 说明在超分辨率超分辨率网络中, 共同使用卷积与 Transformer, 同样可以使二者关注图片的不同细节, 有利于提取到更准确有效的高频信息。

表 8 在验证集 DIV_val10 上, ATRL 包含 RB 与不包含 RB, 4 倍 SR 的参数量和 PSNR 结果

Tab. 8 On validation dataset DIV_val10, parameter quantification and PSNR results of $\times 4$ SR with or without RB in AWTRL

模型	参数量(K)	PSNR (dB)
GDTSR w/o RB	773	29.79
GDTSR	1030	29.89

3.3.4 轴向窗口宽度的讨论

本文使用的轴向窗口为或, 窗口的宽度为 1。为了讨论轴向窗口宽度对于模型的影响, 本文在 AWTRL 中分别设置了宽度分别为 2、4 和 8 的轴向窗口, 在性能、推理时间和占用显存上与本文模型进行比较, 结果如表 9 所示。通过对比可以发现, 轴向窗口宽度的增加, 模型的推理时间和占用显存会有明显的提高, 但模型的性能只有很小的提升。相比于使用宽度为 1 的轴向窗口, 宽度设置为 8, 其推理时间增加了近 60%, 同时占用显存增加了近 2 倍。但 PSNR 仅仅增长了 0.02dB。很显然轴向窗口越大, 其推理速度越慢, 占用显存也会随之越大。本文认为使用任意宽度的轴向窗口都能起到建立全局依赖的效果。使用更大宽度的轴向窗口, 会在窗口内部包含更多的局部信息, 但 SWTL 中已经使用了方形的局部窗口, 有较强的局部信息处理能力, 在 AWTRL 中添加更多的局部信息不能使模型性能有较为明显的增加。本文把轴向窗口宽度设置为 1, 可以在性能、推理速度和占用显存上有很好的权衡。

4 结束语

本文提出了基于全局依赖 Transformer 的图像超分辨率网络 GDTSR, GDTSR 使用两个方向的轴向窗口建立全局依赖, 比目前基于移动窗口策略的模型^[8,24], 能更好地利用整

表9 在验证集 DIV_val10 上, ATWSR 中使用不同宽度的轴向窗口, 4 倍 SR 的占用显存、推理时间和 PSNR 结果
Tab. 9 On validation dataset DIV_val10, memory, inference time and PSNR results of $\times 4$ SR with different width of axial window in ATWSR

窗口宽度	占用显存(M)	推理时间(s)	PSNR (dB)
1	3898	50.46	29.89
2	5427	56.73	29.89
4	7982	62.94	29.90
8	9864	81.87	29.91

个特征图的所有信息。GDTSR 兼顾使用方形窗口来保持良好的局部信息处理能力, 两者结合可以提取更有效的高频信息。此外本文提出了通用的卷积与 Transformer 结合的超分辨率图像重建模块, 比起单独使用卷积可以更好地整合提取到的特征, 提升模型的超分辨率重建能力。实验表明, 与其他先进的超分辨率模型相比, GDTSR 在各个尺度的测试集上的性能达到了最优, 特别是在大尺寸纹理细节丰富的数据集上展示出了较大的优势, 有推广价值和发展前景。

参考文献

- [1] DONG C, LOY C C, HE K, et al. Learning a Deep Convolutional Network for Image Super-Resolution[C]//Computer Vision-ECCV 2014: 13th European Conference, Zurich, Switzerland, September 6-12, 2014, Proceedings, Part IV 13. Springer International Publishing, 2014: 184-199.
- [2] DONG C, LOY C C, TANG X. Accelerating the Super-Resolution Convolutional Neural Network[C]//Computer Vision-ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11-14, 2016, Proceedings, Part II 14. Springer International Publishing, 2016: 391-407.
- [3] KIM J, LEE J K, LEE K M. Accurate Image Super-Resolution Using Very Deep Convolutional Networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 1646-1654.
- [4] LIM B, SON S, KIM H, et al. Enhanced Deep Residual Networks for Single Image Super-Resolution[C]//Proceedings of the IEEE conference on computer vision and pattern recognition work-shops. 2017: 136-144.
- [5] ZHANG Y, LI K, LI K, et al. Image Super-Resolution Using Very Deep Residual Channel Attention Networks[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 286-301.
- [6] TONG T, LI G, LIU X, et al. Image Super-Resolution Using Dense Skip Connections[C]//Proceedings of the IEEE international conference on computer vision. 2017: 4799-4807.
- [7] VASWANI A, SHAZEER N, Parmar N, et al. Attention Is All You Need[J]. Advances in neural information processing systems, 2017, 30.
- [8] LIANG J, CAO J, SUN G, et al. SwinIR: Image Restoration Using Swin Transformer[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 1833-1844.
- [9] LIU Z, LIN Y, CAO Y, et al. Swin Transformer: Hierarchical Vision Transformer using Shifted Windows[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 10012-10022.
- [10] HO J, KALCHBRENNER N, WEISSENBORN D, et al. Axial Attention in Multidimensional Transformers[J]. arXiv preprint arXiv:1912.12180, 2019.
- [11] SHI W, CABALLERO J, HUSZAR F, et al. Real-Time Single Image and Video Super-Resolution Using an Efficient Sub-Pixel Convolutional neural network[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 1874-1883.
- [12] HUANG J B, SINGH A, AHUJA N. Single Image Super-Resolution from Transformed Self-Exemplars[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 5197-5206.
- [13] TIMOFTE R, DE SMET V, VAN GOOL L. A+: Adjusted Anchored Neighborhood Regression for Fast Super-Resolution[C]//Computer Vision-ACCV 2014: 12th Asian Conference on Computer Vision, Singapore, Singapore, November 1-5, 2014, Revised Selected Papers, Part IV 12. Springer International Publishing, 2015: 111-126.
- [14] ZHANG L, WU X. An Edge-Guided Image Interpolation Algorithm via Directional Filtering and Data Fusion[J]. IEEE transactions on Image Processing, 2006, 15(8): 2226-2238.
- [15] MEI Y, FAN Y, ZHOU Y. Image Super-Resolution with Non-Local Sparse Attention[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 3517-3526.
- [16] KIM J, LEE J K, LEE K M. Deeply-Recursive Convolutional Network for Image Super-Resolution[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 1637-1645.
- [17] LEDIG C, THEIS L, HUSZAR F, et al. Photo-Realistic Single Image Super-Resolution Using a Generative Adversarial Network[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 4681-4690.
- [18] WANG X, YU K, WU S, et al. ESRGAN: Enhanced Super-Resolution Generative Adversarial Networks[C]//Proceedings of the European conference on computer vision (ECCV) work-shops. 2018: 0-0.
- [19] GOODFELLOW I, POUGET-ABADIE J, MIRZA M, et al. Generative Adversarial Nets[C]//Neural Information Processing Systems. MIT Press, 2014.
- [20] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An Image Is Worth 16×16 Words: Transformers for Image Recognition at Scale[J]. ICLR, 2021.
- [21] YANG J, LI C, ZHANG P, et al. Focal Self-Attention for Local-Global Interactions in Vision Transformers[J]. arXiv preprint arXiv:2107.00641, 2021.
- [22] DONG X, BAO J, CHEN D, et al. CSWin Transformer: A General Vision Transformer Backbone with Cross-Shaped Windows[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 12124-12134.
- [23] CARION N, MASSA F, SYNNAEVE G, et al. End-to-End Object Detection with Transformers[C]//Computer Vision-ECCV 2020: 16th European Conference, Glasgow, UK, August 23-28, 2020, Proceedings, Part I 16. Springer International Publishing, 2020: 213-229.
- [24] LI W, LU X, LU J, et al. On Efficient Transformer Image Pre-training for Low-Level Vision[J]. arXiv preprint arXiv:2112.10175, 2021.
- [25] LU Z, LI J, LIU H, et al. Transformer for Single Image Super-Resolution[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 457-466.
- [26] YOO J, KIM T, LEE S, et al. Rich CNN-Transformer Feature Aggregation Networks for Super-Resolution[J]. Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV), 2023.
- [27] CHOI H, LEE J, YANG J. N-Gram in Swin Transformers for Efficient Lightweight Image Super-Resolution[J]. arXiv preprint arXiv:2211.11436, 2022.
- [28] ZHANG B, CHEN J, WEN Q. Single Image Super-Resolution Using Lightweight Networks Based on Swin Transformer[J]. arXiv preprint arXiv:2210.11019, 2022.
- [29] TIMOFTE R, AGUSTSSON E, VAN GOOL L, et al. NTIRE 2017 Challenge on Single Image Super-Resolution: Methods and

- Results[C]//Proceedings of the IEEE conference on computer vision and pattern recognition workshops. 2017: 114-125.
- [30] KINGMA D P, BA J. ADAM: A Method for Stochastic Optimization[J]. arXiv preprint arXiv:1412.6980, 2014.
- [31] BEVILACQUA M, ROUMY A, GUILLEMOT C, ALBERI MO-REL M L. Low-Complexity Single-Image Super-Resolution based on Nonnegative Neighbor Embedding[J]. 2012.
- [32] ZEYDE R, ELAD M, PROTTER M. On Single Image Scale-Up using Sparse-Representations[C]//Curves and Surfaces: 7th International Conference, Avignon, France, June 24-30, 2010, Re-vised Selected Papers 7. Springer Berlin Heidelberg, 2012: 711-730.
- [33] MARTIN D, FOWLKES C, TAL D, et al. A Database of Human Segmented Natural Images and its Application to Evaluating Segmentation Algorithms and Measuring Ecological Statistics[C]//Proceedings Eighth IEEE International Conference on Computer Vision. ICCV 2001. IEEE, 2001, 2: 416-423.
- [34] MATSUI Y, ITO K, ARAMAKI Y, et al. Sketch-based manga retrieval using manga109 dataset[J]. Multimedia Tools and Applications, 2017, 76: 21811-21838.
- [35] WANG Z, BOVIK A C, SHEIKH H R, et al. Image Quality Assessment: From Error Visibility to Structural Similarity[J]. IEEE transactions on image processing, 2004, 13(4): 600-612.
- [36] HUI Z, WANG X, GAO X. Fast and Accurate Single Image Super-Resolution via Information Distillation Net-work[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 723-731.
- [37] HUI Z, GAO X, YANG Y, et al. Lightweight Image Super-Resolution with Information Multi-distillation Net-work[C]//Proceedings of the 27th acm international conference on multimedia. 2019: 2024-2032.
- [38] LI W, ZHOU K, QI L, et al. Lapar: Linearly-Assembled Pixel-Adaptive Regression Network for Single Image Super-Resolution and Beyond[J]. Advances in Neural Information Processing Systems, 2020, 33: 20343-20355.
- [39] LUO X, XIE Y, ZHANG Y, et al. LatticeNet: Towards Lightweight Image Super-resolution with Lattice Block[C]//Computer Vision—ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XXII 16. Springer International Publishing, 2020: 272-289.
- [40] ZHANG X, ZENG H, GUO S, et al. Efficient Long-Range Attention Network for Image Super-resolution[C]//Computer Vision—ECCV 2022: 17th European Conference, Tel Aviv, Israel, October 23–27, 2022, Proceedings, Part XVII. Cham: Springer Nature Switzerland, 2022: 649-667.
- [41] AHN N, KANG B, SOHN K A. Fast, Accurate, and Lightweight Super-Resolution with Cascading Residual Net-work[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 252-268.
- [42] WANG L, DONG X, WANG Y, et al. Exploring Sparsity in Image Super-Resolution for Efficient Inference[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 4917-4926.
- [44] TIAN C, ZHANG Y, ZUO W, et al. A heterogeneous group CNN for image super-resolution[J]. IEEE Transactions on Neural Networks and Learning Systems, 2022.
- [45] CONDE M V, CHOI U J, BURCHI M, et al. Swin2SR: SwinV2 Transformer for Compressed Image Super-Resolution and Restoration[C]//Computer Vision—ECCV 2022 Workshops: Tel Aviv, Israel, October 23–27, 2022, Proceedings, Part II. Cham: Springer Nature Switzerland, 2023: 669-687.

刘子涵(1997-), 男, 河北石家庄人, 硕士研究生, 主要研究方向: 深度学习、计算机视觉。周登文(1965-), 男, 湖北省黄梅县人, 教授, 硕士, 主要研究方向: 图像去噪、图像超分辨率。刘玉铠(1996-), 男, 河北衡水人, 硕士研究生, 主要研究方向: 深度学习、计算机视觉。

LIU Zihan, born in 1997, master. His research interests include deep learning, computer vision.

ZHOU Dengwen, born in 1965, master, professor. His research interests include image denoising, image super-resolution.

LIU Yukai, born in 1996, master. His research interests include deep learning, computer vision.

本文有任何疑问请联系作者: 刘子涵, 手机号是: 16601251217, 邮箱是 120212227102@ncepu.edu.cn

本文矩阵、矢量/向量等变量符号说明:

变量符号	含义	备注
I_{LR}	低分辨率图像	矩阵
H	输入图像 H 轴包含的像素数量	数量
W	输入图像 W 轴包含的像素数量	数量
F_0	浅层特征	矩阵
K	RSAWB 的数量	数量
$F_1, F_2, \dots, F_K$	每个 RSAWB 的输出特征	矩阵
F_D	深层特征	矩阵
I_{SR}	超分辨率图像	矩阵
s	超分辨率倍数	数量
X	特征图的窗口	矩阵

Q, K, V	query、key、value 矩阵	矩阵
W_Q, W_K, W_V	生成 Q, K, V 的可学习参数	矩阵
X_{in}	AWTRL 的输入特征	矩阵
X_t	AWTRL 中 MLP 的输入特征	矩阵
X_{out}	AWTRL 的输出特征	矩阵
F_M	TACUpSample 中上采样前的输出特征	矩阵
L_1	1 范式距离	矩阵

工作背景及成果

单图像超分辨率是计算机视觉和图像处理中的一个经典问题, 目标由低分辨率图像生成对应的高分辨率图像. 近几年, 由于 Transformer 在自然语言处理领域的广泛应用, Transformer 逐渐在计算机视觉领域被研究和使

目前,大多数先进的基于 Transformer 的超分辨率网络,在参数量少、网络层数少的情况下无法建立全局依赖.基于此问题,本文提出了基于全局依赖 Transformer 的图像超分辨率网络,其把特征图划分为 2 个方向的轴向窗口,并在内部进行自注意力,可以使每个像素获得整个特征图信息的补充,有利于提取到更有效的图像特征,提高超分辨率模型的性能.此外,鉴于目前大多数超分辨率重建模块都由卷积组成,本文把 Transformer 引入到超分辨率重建模块与卷积一起重建超分辨率图像.

实验表明,与其他先进的图像超分辨率模型相比,本文提出的网络在各个尺度的测试集上的性能达到了最优,特别是在大尺寸纹理细节丰富的数据集上展示出了显著的优势,有推广价值和发展前景.