



计算机应用  
*Journal of Computer Applications*  
ISSN 1001-9081, CN 51-1307/TP

## 《计算机应用》网络首发论文

题目：基于全局依赖 Transformer 的图像超分辨率网络  
作者：刘子涵，周登文，刘玉铠  
收稿日期：2023-05-23  
网络首发日期：2023-09-21  
引用格式：刘子涵，周登文，刘玉铠. 基于全局依赖 Transformer 的图像超分辨率网络 [J/OL]. 计算机应用. <https://link.cnki.net/urlid/51.1307.tp.20230920.1111.008>



**网络首发：**在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

**出版确认：**纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

# 基于全局依赖 Transformer 的图像超分辨率网络

刘子涵\*, 周登文, 刘玉铠

(华北电力大学 控制与计算机工程学院, 北京 102206)

(\*120212227102@ncepu.edu.cn)

**摘要:** 目前, 基于深度学习的图像超分辨率网络主要由卷积实现。相较于传统的卷积神经网络, Transformer 在图像超分辨率任务中的主要优势是它的长距离依赖建模能力。然而大多数基于 Transformer 的图像超分辨率模型在参数量小、网络层数少的情况下无法建立全局依赖, 限制了模型的性能。为了在超分辨率网络中建立全局依赖, 提出了基于全局依赖 Transformer 的图像超分辨率网络, 其主要组成部分为残差方形轴向窗口块, 其内部的轴向窗口 Transformer 残差层利用轴向窗口和自注意力, 可以使每个像素与整个特征图建立起全局依赖。此外, 目前大多数图像超分辨率模型的超分辨率图像重建模块都由卷积组成, 为了可以动态整合提取到的特征信息, 把 Transformer 与卷积进行结合, 共同重建超分辨率图像。通过实验表明, 基于全局依赖 Transformer 的图像超分辨率网络在各个倍数的超分辨率任务中, 与其他先进的模型相比, 在大尺寸数据集上的峰值信噪比指标上有超过 0.3dB 的提升。

**关键词:** 图像超分辨率; Transformer; 自注意力; 全局依赖; 轴向窗口

**中图分类号:** TP391.4; TP183

**文献标志码:** A

## Image super-resolution network based on global dependency Transformer

LIU Zihan\*, ZHOU Dengwen, LIU Yukai

(School of Control and Computer Engineering, North China Electric Power University, Beijing 102206, China)

**Abstract:** At present, the image super-resolution network, based on deep learning, is mainly implemented by convolution. Compared with the traditional convolutional neural network, the main advantage of the Transformer in the image super-resolution task is its long-distance dependency modeling ability. However, most Transformer-based image super-resolution models cannot establish global dependencies when the number of parameters is small and the number of network layers is small, which limits the performance of the model. In order to establish global dependency in super-resolution network, an image super-resolution network based on the global dependency Transformer is proposed. Its main component is the residual square axial window block, and the internal axial window Transformer residual layer uses axial window and self-attention, which can make each pixel globally dependent on the entire feature map. In addition, the super-resolution image reconstruction module of most current image super-resolution models is composed of convolutions. In order to dynamically integrate the extracted feature information, Transformer and convolution are combined to jointly reconstruct super-resolution images. Experiments show that the image super-resolution network based on the global Transformer has an improvement of more than 0.3dB in the peak signal to noise ratio index on large-scale datasets compared with other advanced models in various super-resolution tasks.

**Keywords:** image super-resolution; Transformer; self-attention; global dependency; axial window

### 0 引言

单图像超分辨率(Single Image Super-Resolution, SISR)是计算机视觉和图像处理中的一个经典问题, 目标由低分辨率(Low Resolution, LR)图像生成对应的高分辨率图像(High Resolution, HR)。近年来, 基于卷积神经网络(Convolutional Neural Network, CNN)的图像超分辨率模型<sup>[1-6]</sup>因其恢复图像

高频信息的能力而备受欢迎, 并在图像超分辨率领域占据主导地位。

近几年, 由于 Transformer<sup>[7]</sup>在自然语言处理(Natural Language Processing, NLP)领域的广泛应用, Transformer 逐渐在计算机视觉领域被研究和使用的, 取得了非常显著的效果。相对于传统的卷积神经网络(CNN), Transformer 具有长距离依赖建模的优势, 在低级视觉任务, 尤其图像超分辨率领域具有非常广泛的应用前景。Transformer 的自注意力的计算量

收稿日期: 2023-05-23; 修回日期: 2023-08-31; 录用日期: 2023-09-13。

**作者简介:** 刘子涵(1997—), 男, 河北石家庄人, 硕士研究生, 主要研究方向: 深度学习、计算机视觉; 周登文(1965—), 男, 湖北省黄梅县人, 教授, 硕士, 主要研究方向: 图像去噪、图像超分辨率; 刘玉铠(1996—), 男, 河北衡水人, 硕士研究生, 主要研究方向: 深度学习、计算机视觉。

与参与计算的像素点数量成 2 次方关系。为了减少计算量, SwinIR<sup>[8]</sup>基于 Swin Transformer<sup>[9]</sup>把特征图划分为不重叠的方形窗口, 在方形窗口内部进行自注意力计算, 并使用移动窗口策略建立窗口间的联系, 取得了超越基于 CNN 的模型性能。

尽管 SwinIR<sup>[8]</sup>在图像超分辨率领域取得了很大的成功, 但其存在一个固有的缺陷: 在方形窗口内部进行自注意力仅仅会让模型有良好的局部信息处理能力。使用移动窗口策略, 如图 1 所示, 与使用卷积类似, 随着网络层的堆叠, 像素 A 建立依赖的区域会逐层扩大, 在网络层数少、参数量小的网络中无法建立全局依赖, 这会限制网络的性能。

针对上述问题, 本文提出了基于全局依赖 Transformer 的图像超分辨率网络(Image Super-Resolution Network Based on Global Dependency Transformer, GDTSR)。根据 Ho 等<sup>[10]</sup>提出的轴向窗口, 本文提出了轴向窗口 Transformer 残差层(Axial Window Transformer Residual Layer, AWTRL), 经过 2 个方向的轴向窗口内部的自注意力后, 每个像素可以与整个特征图的所有像素点进行直接或间接地交互, 与整个特征图建立起全局依赖。如图 2 所示, 对于任意像素点 B, 像素 A 可以通过两方向的轴向窗口内部自注意力(图中黑色窗口)与其建立依赖, 像素 A 可以用类似的方式与整个特征图的所有像素建立依赖, 即全局依赖。同时本文注意到, 仅使用轴向窗口会使每个像素无法与临近像素直接进行自注意力, 导致模型局部信息处理能力变差, 因此本文兼顾使用与 SwinIR<sup>[8]</sup>类似的方形窗口 Transformer 层(Square Window Transformer Layer, SWTL)。由 AWTRL 和 SWTL 共同组成的残差方形轴向窗口块(Residual Square-Axial Window Block, RSAWB)作为 GDTSR 的主要组成部分。

此外, 目前单图像超分辨率网络的超分辨率重建模块大多由亚像素卷积<sup>[11]</sup>或类似的结构组成。相比于与特征信息无关的卷积, Transformer 可以给不同的特征信息自适应地添加权重, 使更有效的纹理信息发挥更大的作用, 有利于重建清晰的超分辨率图像。因此本文把 Transformer 应用到超分辨率重建模块并设计了 Transformer 卷积上采样(Transformer and Convolution Upsample, TACUpSample)块。

如图 3 所示, 本文提出的 GDTSR 与其他先进的参数量相近的模型相比, 性能达到了最优。

本文的主要工作有:

1)提出了一个基于全局依赖 Transformer 的图像超分辨率网络(GDTSR)。该网络把轴向窗口与方形窗口相结合, 让每个像素与整个特征图建立依赖, 获得整个特征图信息的补充。

2)本文提出了一种通用的 Transformer 卷积上采样块(TACUpSample), 把 Transformer 引入到超分辨率重建模块与卷积一起重建高分辨率图像。

3)实验表明, 本文提出的 GDTSR 结合 TACUpSample 后, 与其他先进的模型相比, 在 3 个倍数的超分辨率实验上, 模型性能在各个指标上都有很大提升。




图 1 移动窗口策略

Fig.1 Strategy of shift window




图 2 轴向窗口

Fig.2 Axial window




图 3 在 Urban100<sup>[12]</sup>数据集上, 各种超分辨率模型 4 倍 SR 的参数量和 PSNR 比较

Fig.3 PSNR and parameter comparison of different methods for  $\times 4$  SR on dataset Urban100<sup>[12]</sup>

## 1 相关工作

### 1.1 单图像超分辨率

单图像超分辨率是计算机视觉和图像处理中的一个经典问题。与传统的图像超分辨率方法<sup>[13-14]</sup>相比, 基于学习的方法, 由于其优秀的性能而越来越受欢迎。这些方法大多从大规模的配对数据集中学习低分辨率图像到高分辨率图像之间的映射, 自开创性工作 SRCNN<sup>[1]</sup>出现后, 一系列通过使用更复杂基于卷积神经网络架构的模型被提出, 如残差块<sup>[4]</sup>和稠密块<sup>[6]</sup>等。部分研究使用了卷积神经网络内的注意力机制, 如通道注意力<sup>[5]</sup>和非局部注意力<sup>[15]</sup>等。一些工作也把不同的框架应用在超分辨率领域上, 如递归神经网络<sup>[16]</sup>等。为了生成更符合人眼视觉的图片, Ledig 等<sup>[17]</sup>和 Wang 等<sup>[18]</sup>把生成

对抗网络(Generative Adversarial Network, GAN)<sup>[19]</sup>应用到图像超分辨率领域。目前, 鉴于 Transformer 在高级视觉领域的成功应用, 越来越多的研究把 Transformer 应用在图像超分辨率网络中, 如 SwinIR<sup>[8]</sup>, EDT<sup>[20]</sup>等, 取得了超过卷积神经网络的性能。

## 1.2 视觉 Transformer

近年来, Transformer<sup>[7]</sup>在高级视觉任务领域取得了很大的成功, 包括图像分类<sup>[9-10,21-23]</sup>、目标检测<sup>[21-24]</sup>等。由于 Transformer 的自注意力计算量与参与计算的像素数量成 2 次方关系, 这么庞大的计算量无法使整张图片的所有像素点参与运算。为了降低计算量, DOSOVITSKIY 等<sup>[21]</sup>提出 ViT, 把图像划分为 16×16 的窗口, 在窗口内部进行自注意力, 通过这种方式可以明显地减少其计算量。Chen 等<sup>[25]</sup>把 ViT 用于图像超分辨率任务, 提出 IPT 模型, 通过超过 100M 的参数量, 取得了超越 CNN 的性能。虽然 IPT 在性能上取得了突破, 但是基于局部窗口划分, 只能取得很好的局部信息处理能力, 无法建立起窗口之间的依赖。Liu 等<sup>[9]</sup>提出的 Swin Transformer 改善了上述问题, 在局部窗口的基础上使用了移动窗口策略, 通过这种方式可以在不增加计算量的基础上建立窗口间的交互。Ho 等<sup>[10]</sup>把特征图按照两个轴的方向进行划分, 得到轴向窗口, 这种方式虽然可以建立全局依赖, 但是局部信息处理能力又会明显不足。Liang 等<sup>[8]</sup>基于 Swin Transformer<sup>[9]</sup>提出了 SwinIR, 在参数量明显小于 IPT 的情况下, 取得了超越 IPT 的性能。EDT<sup>[20]</sup>把 SwinIR 中的方形窗口改进为矩形窗口, 并使用预训练进一步改进网络性能。ACT<sup>[26]</sup>在 Transformer 的基础上添加卷积, 使二者关注图像的不同细节, 使模型获得了超越 SwinIR 的性能, 但需要更大的参数量作为代价。ESRT<sup>[27]</sup>提出了卷积与 Transformer 的串行架构, 并使模型更加轻量化。此外还有使用图像多尺度特征的 NGswin<sup>[28]</sup>和用于人脸超分辨率的 MSwinSR<sup>[29]</sup>等相继被提出。虽然目前 Transformer 在图像超分辨率领域有广泛的应用, 但是如图 1 所示, 使用移动窗口策略只能使感受野逐层增加, 在参数量小, 层数少的网络中无法建立起全局依赖, 这会限制网络的性能。

## 2 网络设计

### 2.1 基于全局依赖 Transformer 的图像超分辨率网络

如图 4(a)所示, 基于全局依赖 Transformer 的超分辨率网络(GDTSR)由浅层特征提取模块、深层特征提取模块和超分辨率重建模块组成。

**浅层特征提取模块:** 把低分辨率图像  $I_{LR} \in \mathbb{R}^{H \times W \times 3}$  ( $H$  和  $W$  为低分辨率图像高和宽包含的像素数量)作为输入。本文使用 3×3 的卷积 Conv(·) 来提取浅层特征, 过程为:

$$F_0 = \text{Conv}(I_{LR}) \quad (1)$$

其中  $F_0 \in \mathbb{R}^{H \times W \times C}$  为图像的浅层特征,  $C$  为特征图的通道数, 卷积操作具有良好的局部信息提取能力, 可以有效地提取图像的浅层特征。

**深层特征提取模块:** 图像经过浅层特征提取后, 从得到的浅层特征  $F_0$  中提取深层特征, 深层特征提取模块包含  $K$  个残差方形轴向窗口块(Residual Square-Axial Window Block, RSAWB)和一个 3×3 的卷积 Conv(·)。中间特征  $F_1, F_2, \dots, F_K$  和最终输出的深层特征  $F_D$  都是逐块提取的, 过程为:

$$\begin{aligned} F_k &= f_{RSAWB}^k(F_{k-1}) \quad k=1, 2, \dots, K \\ F_D &= \text{Conv}(F_K) \end{aligned} \quad (2)$$

其中  $f_{RSAWB}^k(\cdot)$  是第  $k$  个 RSAWB 函数。

**超分辨率重建模块:** 由于卷积核与作用的特征图无关, 这就导致卷积会平等地对待提取到的特征图中的不同信息, 根据 SwinIR<sup>[8]</sup>, Transformer 可以给不同的特征信息自适应地添加权重, 动态地使用特征图中的信息, 给更有效的纹理信息赋予更大的权重, 有利于提升重建超分辨率图像的能力。因此把 Transformer 引入到超分辨率图像重建模块, 设计了 Transformer 卷积上采样(Transformer and Convolution Upsample, TACUpSample)块作为超分辨率重建模块。TACUpSample 通过融合浅层特征  $F_0$  和深层特征  $F_D$  来重建超分辨率图像  $I_{SR}$ , 过程为:

$$I_{SR} = f_{TAC}(F_D + F_0) \quad (3)$$

其中  $f_{TAC}(\cdot)$  是 TACUpSample 函数,  $I_{SR} \in \mathbb{R}^{sH \times sW \times 3}$ ,  $s$  是图像超分辨率倍数。

### 2.2 轴向窗口 Transformer 残差层

SwinIR<sup>[8]</sup>等目前大多数基于 Transformer 的图像超分辨率网络, 把特征图划分为局部窗口, 并且使用移动窗口策略建立窗口间的联系。如图 1 所示, 这种方式只能逐层扩大感受野, 在参数量小的模型中无法建立起全局依赖。针对这个问题, 本文设计了轴向窗口 Transformer 残差层(Axial Window Transformer Residual Layer, AWTRL)。

如图 4(d)所示, 为了使每个像素充分利用全局信息, 与整个特征图建立依赖, 根据[10], 在 AWTRL 中按照  $H$  或  $W$  轴方向, 把特征图划分为轴向窗口。如图 2 所示, 在两个方向的窗口内部进行自注意力计算, 可以使每个像素与整个特征图的所有像素点建立依赖, 获得整个特征图所有像素信息的补充, 建立全局依赖。以  $H$  轴窗口为例, 把输入的特征图  $H \times W \times C$  划分为  $N \times (1 \times W) \times C$ , 其中  $N$  为划分的窗口数量(同时也是特征图  $H$  轴的像素数量,  $N = H$ ), 每个窗口包含  $1 \times W$  个像素, 每个像素在其所在的  $H$  轴窗口内部进行自注意力。对于每个输入窗口  $X \in \mathbb{R}^{1 \times W \times C}$ , query、key、value 矩阵  $Q, K, V \in \mathbb{R}^{1 \times W \times C}$  的计算方式分别为:



$$\mathbf{Q} = \mathbf{X}\mathbf{W}_Q, \quad \mathbf{K} = \mathbf{X}\mathbf{W}_K, \quad \mathbf{V} = \mathbf{X}\mathbf{W}_V \quad (4)$$

其中  $\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V \in \mathbb{R}^{C \times C}$  为可学习参数。自注意力过程  $\text{SA}(\cdot)$  为:

$$\text{SA}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{Softmax}(\mathbf{Q}\mathbf{K}^T)\mathbf{V} \quad (5)$$

其中,  $\text{Softmax}(\cdot)$  是 Softmax 函数。

此外, 根据 ACT<sup>[26]</sup>, Transformer 和卷积共同使用可以使二者关注特征图的不同细节。本文在 AWTRL 中添加了由卷积, 激活函数(GELU)和通道注意力(Channel Attention, CA)<sup>[5]</sup>共同组成的残差块(Residual Block, RB)。多头自注意力(multi-head self-attention, MHSA)与残差块得到的共同特征经过多层感知机(Multi-Layer Perceptron, MLP)<sup>[8]</sup>进一步整合。每个阶段都使用层归一化和残差。假设 AWTRL 的输入特征为  $\mathbf{X}_{in}$ , 整个过程可以表示为:

$$\begin{aligned} \mathbf{X}_m &= \text{MHSA}(\text{LN}(\mathbf{X}_{in})) + \text{RB}(\text{LN}(\mathbf{X}_{in})) + \mathbf{X}_{in} \\ \mathbf{X}_{out} &= \text{MLP}(\text{LN}(\mathbf{X}_m)) + \mathbf{X}_m \end{aligned} \quad (6)$$

其中,  $\text{RB}(\cdot)$  是残差块函数,  $\text{LN}(\cdot)$  是层归一化函数,  $\text{MLP}(\cdot)$  是多层感知机函数。MHSA $(\cdot)$  是多头自注意力函数, 其计算

过程是: 把输入特征的通道平分为  $d$  份, 即头数为  $d$ , 并行执行  $d$  次  $\text{SA}(\cdot)$  后, 拼接得到的  $d$  个特征作为输出特征  $\mathbf{X}_{out}$ 。

如图 2 所示, 对于特征图内任意像素点 A, 假设坐标为  $(a, b)$ , 首先与所有坐标为  $(h, b)$  ( $h = 1, 2, \dots, H$ ) 的像素点进行自注意力, 然后所有坐标为  $(h, b)$  的像素点与对应的  $(h, w)$  ( $w = 1, 2, \dots, W$ ) 的所有像素点进行自注意力。此时已经与整张特征图的所有像素点建立了依赖, 则说明任意像素点都可以与整个特征图建立依赖关系, 即全局依赖。

把特征图划分为 H 轴窗口或 W 轴窗口, 并在窗口内部进行自注意力, 其自注意力的计算量为  $6C^2HW + 4CH^2W$  (以 H 轴窗口为例), 在输入图像的  $H$  与  $W$  近似相等的情况下, 其计算量是图像像素数量的近似 1.5 次方。相比于只使用方形窗口划分的 SwinIR<sup>[8]</sup>等, 尽管计算量有所上升, 但是可以使每个像素与整个特征图建立全局依赖。经过实验可以得到, 本文的方法比 SwinIR<sup>[8]</sup>等基于移动窗口策略的模型相比, 在性能上有的较大的提升(见表 1, 表 2 和表 3)。




图 4 GDTSR、RSAWB、AWTRL 和 SWTL 的结构图  
Fig.4 Architecture of GDTSR, RSAWB, AWTRL and SWTL

### 2.3 方形窗口 Transformer 层

在 AWTRL 中使用两个方向的轴向窗口可以使每个像素与整个特征图建立起全局依赖, 但是每个像素与大部分的邻

近像素没有直接进行自注意力, 这会导致模型的局部信息处理能力下降。为此, 本文设计了方形窗口 Transformer 层 (Square Window Transformer Layer, SWTL), 如图 4(e)所示。与 SwinIR<sup>[8]</sup>的窗口划分方式相同, SWTL 把每个特征图划分为方形的局部窗口, 在窗口内部进行自注意力计算。整个过

程与 AWTRL 类似。并且为了轻量化,在 SWTL 中不使用残差块,以减少参数量。

## 2.4 残差方形轴向窗口块

由 AWTRL 和 SWTL 共同组成的残差方形轴向窗口块 (Residual Square-Axial Window Block, RSAWB), RSAWB 是本文提出模型的主要组成部分,如图 4(b)所示。RSAWB 中的中间特征是被逐层提取的,过程为:

$$\begin{aligned} F_{k,1} &= f_{S,1}^k(F_{k-1}) \\ F_{k,2} &= f_{A,H}^k(F_{k,1}) \\ F_{k,3} &= f_{S,2}^k(F_{k,2}) \\ F_{k,4} &= f_{A,W}^k(F_{k,3}) \\ F_{k,5} &= f_{S,3}^k(F_{k,4}) \\ F_k &= \text{Conv}(F_{k,5}) + F_{k-1} \end{aligned} \quad (7)$$

其中  $f_{S,j}^k(\cdot)$  是第  $k$  个 RSAWB 中的第  $j$  ( $j=1,2,3$ ) 个 SWTL 函数,  $f_{A,H}^k(\cdot)$  和  $f_{A,W}^k(\cdot)$  是第  $k$  个 RSAWB 中 H 轴向和 W 轴向的 AWTRL 函数。RSAWB 中网络层划分窗口方式如图 4(c) 所示, RSAWB 使用了 AWTRL 和 SWTL 去提取深层特征,其中 AWTRL 把特征图划分为轴向窗口,相比于移动窗口策略,经过两个方向的 AWTRL 后可以使每个像素与整个特征图建立依赖。SWTL 把特征图划分为方形窗口,在方形窗口内部进行自注意力可以很好地提取特征的局部信息。同时使用 AWTRL 和 SWTL,可以使模型保持良好的局部信息处理能力,同时最大程度对每个像素进行全局信息的补充,有利于提取到更有效的深层特征。

## 2.5 Transformer 卷积上采样块

目前大多数超分辨率模型的超分辨率重建模块都是使用卷积实现<sup>[4,8,18,26]</sup>,如亚像素卷积<sup>[11]</sup>等。由于卷积核与作用的特征图无关,这就导致卷积会平等地对待提取到的特征图中的不同信息,根据 SwinIR<sup>[8]</sup>,Transformer 在进行特征提取时,可以给不同的特征信息自适应地添加权重,相当于动态卷积。因此本文把 Transformer 引入到超分辨率重建模块,与卷积共同一起进行超分辨率图像的重建,如图 5 所示。整个 TACUpSample 作为超分辨率重建模块,过程为:

$$\begin{aligned} F_M &= \text{Conv}(F_0 + F_D) + \text{MHSA}(\text{LN}(F_0 + F_D)) \\ I_{SR} &= \text{Conv}(\text{PixelShuffle}(F_M)) \end{aligned} \quad (8)$$

其中 PixelShuffle( $\cdot$ ) 是 PixelShuffle 函数,多头自注意力 MHSA( $\cdot$ ) 计算过程与 AWTRL 中一致。




图 5 Transformer 卷积上采样块  
Fig.5 Transformer and Convolution Upsample(TACUpSample)

## 2.6 损失函数

在单图像超分辨率任务中,常用的损失函数为平均绝对误差<sup>[4,5,8,20]</sup> ( $L_1$  损失)和均方误差<sup>[1]</sup> ( $L_2$  损失)。相比于  $L_2$  损失,  $L_1$  损失可以使生成的图像更加锐化,有利于使超分辨率图像获得更清晰的纹理细节。与目前大多数超分辨率网络相同,本文通过优化参数使生成的超分辨率图像与配对的高分辨率图像逐像素  $L_1$  距离最小,为:

$$L_1 = \|I_{SR} - I_{HR}\|_1 \quad (9)$$

其中  $I_{HR}$  为配对的高分辨率图像。

## 3 实验与结果分析

### 3.1 实验设置

本文使用 DIV2K<sup>[30]</sup>数据集中的 800 张训练图片作为训练集,并对其随机进行多次 90° 旋转和水平翻转以实现数据增强。选取 DIV2K 的 851-860 图像作为验证集记为 DIV\_val10。参考 SwinIR-light<sup>[8]</sup>中 RSTB 的数量和 EDT-T<sup>[20]</sup>中 Transformer Block 的数量均为 4,本模型中 RSAWB 的数量同样设置为 4,中间特征图的通道数  $C$  设置为 60,多头自注意力的头数  $d$  设置为 6。为了与其他先进的超分辨率模型进行公平的比较,本文设计了参数量为 600K(GDTSR-T)和 1M(GDTSR)的两个轻量级模型,两个模型仅卷积的参数量不同。此外本文额外增加 DF2K(DIV2K+Flickr2K<sup>[30]</sup>)作为训练集的实验,记为(GDTSR-DF),进一步提升模型的性能。使用  $\beta_1=0.9$ 、 $\beta_2=0.999$ 、 $\varepsilon=10^{-8}$  的 ADAM<sup>[31]</sup>优化器,训练时每个批次处理 8 张  $64 \times 64$  的训练图片,初始学习率为  $2 \times 10^{-4}$ ,共训练 500000 次迭代,在 250000、400000、450000、475000 次迭代后学习率降为之前的一半。在 Set5<sup>[32]</sup>、Set14<sup>[33]</sup>、B100<sup>[34]</sup>、Urban100<sup>[12]</sup>和 Manga109<sup>[35]</sup>共 5 个标准数据集上测试模型性能。在 YCbCr 空间的亮度(Y)通道上,使用峰值信噪比(Peak Signal to Noise Ratio, PSNR)<sup>[36]</sup>和结构相似性(Structural Similarity Index, SSIM)<sup>[36]</sup>来评估模型的性能。整个模型在 NVIDIA RTX A5000 上进行训练。

### 3.2 实验结果

#### 3.2.1 客观指标

不同倍数( $\times 2$ ,  $\times 3$ ,  $\times 4$ )的超分辨率实验结果如表 1、表 2、表 3 所示, 最好和次好的结果分别用加粗和下划线表示。本文提出的 GDTSR 在 5 个标准测试集的测试结果中, 三个倍数的 PSNR 和 SSIM 结果, 与参数量相当的其他先进的超分辨率模型相比都达到了最优, 特别是在大尺寸图像的 Urban100 和 Manga109 数据集上模型性能的提升尤为明显。与 ELAN-light<sup>[41]</sup>相比, 本文的 GDTSR-T 使用几乎相同的参数量, 在 Manga109 数据集上 PSNR 结果平均提升了 0.26dB。与参数量更大的 SwinIR-light<sup>[8]</sup>相比, 本文的 GDTSR-T 在 Manga109 数据集上 PSNR 结果平均提升了 0.27dB。本文的 GDTSR-DF 与 EDT-T<sup>[20]</sup>相比, 在 Urban100 数据集上的 PSNR 结果平均提升了 0.34dB, 在 Manga109 数据集上的 PSNR 结果平均提升了 0.29dB。在仅使用 DIV2K 作为训练集的情况下, 本文的 GDTSR 与 EDT-T<sup>[20]</sup>相比仍有优势, 在 Manga109 数据集上的 PSNR 结果平均提升了 0.09dB, 与参数量相当的先进模型(如 SMSR<sup>[43]</sup>、SwinIR-NG<sup>[28]</sup>、Swin2SR-s<sup>[45]</sup>)相比, 各个数据集的 PSNR 结果均有较大提升。

表 1 各种 SISR 网络 2 倍 SR 的平均 PSNR 与 SSIM

Tab. 1 Average PSNR(dB) and SSIM of  $\times 2$  SR for various SISR networks

| 训练集   | 模型                           | 参数量   | Set5         |               | Set14        |               | B100         |               | Urban100     |               | Manga109     |               |
|-------|------------------------------|-------|--------------|---------------|--------------|---------------|--------------|---------------|--------------|---------------|--------------|---------------|
|       |                              |       | PSNR/dB      | SSIM          | PSNR/dB      | SSIM          | PSNR/dB      | SSIM          | PSNR/dB      | SSIM          | PSNR/dB      | SSIM          |
| DIV2K | IMDN <sup>[38]</sup>         | 694K  | 38.00        | 0.9605        | 33.63        | 0.9177        | 32.19        | 0.8996        | 32.17        | 0.9283        | 38.88        | 0.9774        |
| DIV2K | LAPAR <sup>[39]</sup>        | 548K  | 38.01        | 0.9605        | 33.62        | 0.9183        | 32.19        | 0.8999        | 32.10        | 0.9283        | 38.67        | 0.9772        |
| DIV2K | LatticeNet <sup>[40]</sup>   | 756K  | 38.15        | 0.9610        | 33.78        | 0.9193        | 32.25        | 0.9005        | 32.43        | 0.9302        | --           | --            |
| DIV2K | ESRT <sup>[27]</sup>         | 677K  | 38.03        | 0.9600        | 33.75        | 0.9184        | 32.25        | 0.9005        | 32.58        | 0.9318        | 39.12        | 0.9774        |
| DIV2K | SwinIR-light <sup>[8]</sup>  | 878K  | 38.14        | 0.9611        | 33.86        | 0.9206        | 32.31        | 0.9012        | 32.76        | 0.9340        | 39.12        | 0.9783        |
| DIV2K | ELAN-light <sup>[41]</sup>   | 582K  | 38.17        | 0.9611        | 33.94        | 0.9207        | 32.30        | 0.9012        | 32.76        | 0.9340        | 39.11        | 0.9782        |
| DIV2K | GDTSR-T                      | 600K  | 38.17        | 0.9612        | 33.99        | 0.9203        | 32.31        | 0.9013        | 32.78        | 0.9342        | 39.27        | 0.9784        |
| DIV2K | EDSR-baseline <sup>[4]</sup> | 1370K | 37.99        | 0.9604        | 33.57        | 0.9175        | 32.16        | 0.8994        | 31.98        | 0.9272        | 38.54        | 0.9769        |
| DIV2K | CARN <sup>[42]</sup>         | 1592K | 37.76        | 0.9590        | 33.52        | 0.9166        | 32.09        | 0.8978        | 31.92        | 0.9256        | 38.36        | 0.9765        |
| DIV2K | SMSR <sup>[43]</sup>         | 985K  | 38.00        | 0.9601        | 33.64        | 0.9179        | 32.17        | 0.8990        | 32.19        | 0.9284        | 38.76        | 0.9771        |
| DIV2K | HGSRNN <sup>[44]</sup>       | 2178K | 37.80        | 0.9591        | 33.56        | 0.9175        | 32.12        | 0.8984        | 32.21        | 0.9292        | --           | --            |
| DIV2K | SwinIR-NG <sup>[28]</sup>    | 1181K | 38.17        | 0.9612        | 33.94        | 0.9205        | 32.31        | 0.9013        | 32.78        | 0.9340        | 39.20        | 0.9781        |
| DIV2K | Swin2SR-s <sup>[45]</sup>    | 1000K | 38.17        | 0.9613        | 33.95        | 0.9216        | 32.35        | 0.9024        | 32.85        | 0.9349        | 39.32        | 0.9784        |
| DIV2K | GDTSR                        | 1003K | <u>38.26</u> | <u>0.9615</u> | <u>34.13</u> | <u>0.9217</u> | 32.35        | 0.9018        | <u>33.15</u> | <u>0.9368</u> | <u>39.45</u> | 0.9787        |
| DF2K  | EDT-T <sup>[24]</sup>        | 917K  | 38.23        | <u>0.9615</u> | 33.99        | 0.9209        | <u>32.37</u> | <u>0.9021</u> | 32.98        | 0.9362        | <u>39.45</u> | <b>0.9789</b> |
| DF2K  | GDTSR-DF                     | 1003K | <b>38.31</b> | <b>0.9616</b> | <b>34.28</b> | <b>0.9239</b> | <b>32.39</b> | <b>0.9023</b> | <b>33.34</b> | <b>0.9384</b> | <b>39.66</b> | <u>0.9788</u> |

表 2 各种 SISR 网络 3 倍 SR 的平均 PSNR 与 SSIM

Tab. 2 Average PSNR(dB) and SSIM of  $\times 3$  SR for various SISR networks

| 训练集   | 模型                         | 参数量  | Set5    |        | Set14   |        | B100    |        | Urban100 |        | Manga109 |        |
|-------|----------------------------|------|---------|--------|---------|--------|---------|--------|----------|--------|----------|--------|
|       |                            |      | PSNR/dB | SSIM   | PSNR/dB | SSIM   | PSNR/dB | SSIM   | PSNR/dB  | SSIM   | PSNR/dB  | SSIM   |
| DIV2K | IMDN <sup>[38]</sup>       | 703K | 34.36   | 0.9270 | 30.32   | 0.8417 | 29.09   | 0.8046 | 28.17    | 0.8519 | 33.61    | 0.9445 |
| DIV2K | LAPAR <sup>[39]</sup>      | 544K | 34.36   | 0.9267 | 30.34   | 0.8421 | 29.11   | 0.8054 | 28.15    | 0.8523 | 33.51    | 0.9441 |
| DIV2K | LatticeNet <sup>[40]</sup> | 765K | 34.53   | 0.9281 | 30.39   | 0.8424 | 29.15   | 0.8059 | 28.33    | 0.8538 | --       | --     |

#### 3.2.2 主观效果

2 倍和 4 倍的超分辨率结果的主观效果如图 6 所示。以 Set14 数据集的 barbara 为例, 其他模型的结果都有模糊和纹理方向错误的问题, 本文模型恢复出的图像更加清晰, 纹理方向正确, 很接近于原 HR 图像。Urban100 数据集的 img092 也是类似。再以 Urban100 数据集的 img024 和 img059 为例, 其他模型恢复出的图像, 或过度模糊, 或严重失真, 本文的 GDTSR 可以恢复出更加清晰准确的纹理细节。

#### 3.2.3 模型复杂度的比较

模型复杂度的比较如表 4 所示, 模型的计算量用 FLOPs 来表示, FLOPs 指模型在推理时乘法和加法运算的次数。由表 4 可以得到, 本文的模型与 SwinIR-light<sup>[8]</sup>和 EDT-T<sup>[20]</sup>相比, 计算量有所增加。这是因为本文的 AWTSR 中使用计算量更大的轴向窗口。本文弃用了移动窗口策略, 不需要在图像上进行移位操作, 同时也弃用了移动窗口策略使用的掩码矩阵。此外 GDTSR 使用了更少的网络层数, 这就导致虽然本文模型的计算量有所增加, 但是推理速度相当, 甚至推理时间有所减少。

|       |                              |       |              |               |              |               |              |               |              |               |              |               |
|-------|------------------------------|-------|--------------|---------------|--------------|---------------|--------------|---------------|--------------|---------------|--------------|---------------|
| DIV2K | ESRT <sup>[27]</sup>         | 770K  | 34.42        | 0.9268        | 30.43        | 0.8433        | 29.15        | 0.8063        | 28.46        | 0.8574        | 33.95        | 0.9455        |
| DIV2K | SwinIR-light <sup>[8]</sup>  | 886K  | 34.62        | 0.9289        | 30.54        | 0.8463        | 29.20        | 0.8082        | 28.66        | 0.8624        | 33.98        | 0.9478        |
| DIV2K | ELAN-light <sup>[41]</sup>   | 590K  | 34.61        | 0.9288        | 30.55        | 0.8463        | 29.21        | 0.8081        | 28.69        | 0.8624        | 34.00        | 0.9478        |
| DIV2K | GDTSR-T                      | 611K  | 34.62        | 0.9289        | 30.58        | 0.8463        | 29.23        | 0.8086        | 28.71        | 0.8629        | 34.35        | 0.9488        |
| DIV2K | EDSR-baseline <sup>[4]</sup> | 1555K | 34.37        | 0.9270        | 30.28        | 0.8417        | 29.09        | 0.8052        | 28.15        | 0.8527        | 33.45        | 0.9439        |
| DIV2K | CARN <sup>[42]</sup>         | 1592K | 34.29        | 0.9255        | 30.29        | 0.8407        | 29.06        | 0.8034        | 28.06        | 0.8493        | 33.43        | 0.9427        |
| DIV2K | SMSR <sup>[46]</sup>         | 993K  | 34.40        | 0.9270        | 30.33        | 0.8412        | 29.10        | 0.8050        | 28.25        | 0.8536        | 33.68        | 0.9445        |
| DIV2K | HGSRNN <sup>[44]</sup>       | 2363K | 34.35        | 0.9260        | 33.32        | 0.8413        | 29.09        | 0.8042        | 28.29        | 0.8546        | --           | --            |
| DIV2K | SwinIR-NG <sup>[28]</sup>    | 1190K | 34.64        | 0.9293        | 30.58        | 0.8471        | 29.24        | 0.8090        | 28.75        | 0.8639        | 34.22        | 0.9488        |
| DIV2K | GDTSR                        | 1014K | <u>34.78</u> | <u>0.9300</u> | <u>30.67</u> | <u>0.8477</u> | <u>29.29</u> | <u>0.8102</u> | <u>29.07</u> | <u>0.8691</u> | <u>34.58</u> | <u>0.9504</u> |
| DF2K  | EDT-T <sup>[24]</sup>        | 919K  | 34.73        | 0.9299        | 30.66        | <u>0.8481</u> | <u>29.29</u> | <u>0.8103</u> | 28.89        | 0.8674        | 34.44        | 0.9498        |
| DF2K  | GDTSR                        | 1014K | <b>34.83</b> | <b>0.9304</b> | <b>30.72</b> | <b>0.8487</b> | <b>29.33</b> | <b>0.8109</b> | <b>29.22</b> | <b>0.8717</b> | <b>34.80</b> | <b>0.9513</b> |

表 3 各种 SISR 网络 4 倍 SR 的平均 PSNR 与 SSIM  
Tab. 3 Average PSNR(dB) and SSIM of  $\times 4$  SR for various SISR networks

| 训练集   | 模型                           | 参数量   | Set5         |               | Set14        |               | B100         |               | Urban10      |               | Manga109     |               |
|-------|------------------------------|-------|--------------|---------------|--------------|---------------|--------------|---------------|--------------|---------------|--------------|---------------|
|       |                              |       | PSNR/dB      | SSIM          | PSNR/dB      | SSIM          | PSNR/dB      | SSIM          | PSNR/dB      | SSIM          | PSNR/dB      | SSIM          |
| DIV2K | IMDN <sup>[38]</sup>         | 715K  | 32.21        | 0.8948        | 28.58        | 0.7811        | 27.56        | 0.7353        | 26.04/       | 0.7838        | 30.45        | 0.9075        |
| DIV2K | LAPAR <sup>[39]</sup>        | 659K  | 32.15        | 0.8944        | 28.61        | 0.7818        | 27.61        | 0.7366        | 26.14        | 0.7871        | 30.42/       | 0.9074        |
| DIV2K | LatticeNet <sup>[40]</sup>   | 777K  | 32.30        | 0.8962        | 28.68        | 0.7830        | 27.62        | 0.7367        | 26.25        | 0.7873        | --           | --            |
| DIV2K | ESRT <sup>[27]</sup>         | 751K  | 32.19        | 0.8947        | 28.69        | 0.7833        | 27.69        | 0.7379        | 36.39        | 0.7962        | 30.75        | 0.9100        |
| DIV2K | SwinIR-light <sup>[8]</sup>  | 897K  | 32.44        | 0.8976        | 28.77        | 0.7858        | 27.69        | 0.7406        | 26.47        | 0.7980        | 30.92        | 0.9151        |
| DIV2K | ELAN-light <sup>[41]</sup>   | 601K  | 32.43        | 0.8975        | 28.78        | 0.7858        | 27.69        | 0.7406        | 26.54        | 0.7982        | 30.92        | 0.9150        |
| DIV2K | GDTSR-T                      | 627K  | 32.40        | 0.8978        | 28.84        | 0.7869        | 27.72        | 0.7414        | 26.64        | 0.8012        | 31.21        | 0.9163        |
| DIV2K | EDSR-baseline <sup>[4]</sup> | 1518K | 32.09        | 0.8938        | 28.58        | 0.7813        | 27.57        | 0.7357        | 26.04        | 0.7849        | 30.35        | 0.9067        |
| DIV2K | CARN <sup>[42]</sup>         | 1592K | 32.13        | 0.8937        | 28.60        | 0.7806        | 27.58        | 0.7349        | 26.07        | 0.7837        | 30.42        | 0.9070        |
| DIV2K | SMSR <sup>[46]</sup>         | 1006K | 32.12        | 0.8932        | 28.55        | 0.7808        | 27.55        | 0.7351        | 26.11        | 0.7868        | 30.54        | 0.9085        |
| DIV2K | HGSRNN <sup>[44]</sup>       | 2321K | 32.13        | 0.8940        | 28.62        | 0.7820        | 27.60        | 0.7363        | 26.27        | 0.7908        | --           | --            |
| DIV2K | SwinIR-NG <sup>[28]</sup>    | 1201K | 32.44        | 0.8980        | 28.83        | 0.7870        | 27.73        | 0.7418        | 26.61        | 0.8010        | 31.09        | 0.9161        |
| DIV2K | GDTSR                        | 1030K | <u>32.65</u> | <u>0.9001</u> | <u>28.91</u> | <u>0.7885</u> | <u>27.78</u> | <u>0.7435</u> | <u>26.89</u> | <u>0.8084</u> | <u>31.47</u> | <u>0.9191</u> |
| DF2K  | EDT-T <sup>[24]</sup>        | 922K  | 32.53        | 0.8991        | 28.88        | 0.7882        | 27.76        | 0.7433        | 26.71        | 0.8051        | 31.35        | 0.9180        |
| DF2K  | GDTSR                        | 1030K | <b>32.71</b> | <b>0.9007</b> | <b>28.97</b> | <b>0.7898</b> | <b>27.82</b> | <b>0.7444</b> | <b>27.04</b> | <b>0.8120</b> | <b>31.64</b> | <b>0.9202</b> |






图 6 2 倍和 4 倍 SR 的视觉效果比较  
Fig.6 Visual qualitative comparison of  $\times 2$  and  $\times 4$  SR

表 4 在 4 倍 SR 的 Urban100 数据集上, 3 种模型在推理时间、FLOPs 和 PSNR 的比较  
Tab. 4 On dataset Urban100 of  $\times 4$  SR, inference time, FLOPs and PSNR comparison in 3 models

| 模型                          | 推理时间/s | GFLOPs | PSNR/dB |
|-----------------------------|--------|--------|---------|
| SwinIR-light <sup>[8]</sup> | 118.25 | 49.6   | 26.47   |
| EDT-T <sup>[20]</sup>       | 128.48 | 54.9   | 26.71   |
| GDTSR                       | 110.75 | 71.9   | 26.89   |

3.3 消融实验

3.3.1 轴向窗口的有效性

本文的 AWTRL 包含 H 或 W 轴的条形窗口, 为验证两个方向的轴向窗口提供的全局信息有利于超分辨率性能的提高。本文设计把 AWTRL 中的条形窗口替换为与 SWTL 中相同的方形局部窗口, 与本文模型进行比较, 结果如表 5 示。可以看到在整个模型中仅仅使用方形局部窗口, 虽然有更好的局部信息处理能力, 但是每个像素点无法取得较远位置信息的补充, 缺少全局依赖, 模型的性能也有较明显的下降。

表 5 AWTRL 中不同的窗口, 在验证集 DIV\_val10 上, 4 倍 SR 的 PSNR 结果

Tab. 5 On validation dataset DIV\_val10, PSNR results of  $\times 4$  SR

| with different window in AWTRL |         |
|--------------------------------|---------|
| AWTRL 的窗口类型                    | PSNR/dB |
| 方形窗口                           | 29.72   |
| 轴向窗口                           | 29.89   |

3.3.2 残差块的有效性

本文的 AWTRL 额外添加了由卷积、激活函数和通道注意力<sup>[5]</sup>组成的残差块。为验证其有效性, 设计了在 AWTRL 中不使用残差块的模型, 记为 GDTSR\_w/o\_RB, 与本文模型进行对比, 实验结果见表 6。可以看到使用了残差块虽然参数量会有所增加, 但是模型的性能会有显著提高。根据 ACT<sup>[26]</sup>, 说明在参数量小的超分辨率网络中, 共同使用卷积与 Transformer, 同样可以使二者关注图片的不同细节, 有利于提取到更准确有效的高频信息。

表 6 在验证集 DIV\_val10 上, ATRL 包含 RB 与不包含 RB, 4 倍 SR 的参数量和 PSNR 结果

Tab. 6 On validation dataset DIV\_val10, parameter quantification and PSNR results of  $\times 4$  SR with or without RB in AWTRL

| 模型           | 参数量/ $10^3$ | PSNR/dB |
|--------------|-------------|---------|
| GDTSR_w/o_RB | 773         | 29.79   |
| GDTSR        | 1030        | 29.89   |

3.3.3 轴向窗口宽度的讨论

本文使用的轴向窗口为或，窗口的宽度为 1。为了讨论轴向窗口宽度对于模型的影响，本文在 AWTRL 中分别设置了宽度分别为 2、4 和 8 的轴向窗口，在性能、推理时间和占用显存上与本文模型进行比较，结果如表 7 所示。通过对比可以发现，轴向窗口宽度的增加，模型的推理时间和占用显存会有明显的提高，但模型的性能只有很小的提升。相比于使用宽度为 1 的轴向窗口，宽度设置为 8，其推理时间增加了近 60%，同时占用显存增加了近 2 倍。但 PSNR 仅仅增长了 0.02dB。很显然轴向窗口越大，其推理速度越慢，占用显存也会随之越大。本文认为使用任意宽度的轴向窗口都能起到建立全局依赖的效果。使用更大宽度的轴向窗口，会在窗口内部包含更多的局部信息，但 SWTL 中已经使用了方形的局部窗口，有较强的局部信息处理能力，在 AWTRL 中添加更多的局部信息不能使模型性能有较为明显的增加。本文把轴向窗口宽度设置为 1，可以在性能、推理速度和占用显存上有很好地权衡。

表 7 在验证集 DIV\_val10 上，ATWSR 中使用不同宽度的轴向窗口，4 倍 SR 的占用显存、推理时间和 PSNR 结果  
Tab. 7 On validation dataset DIV\_val10, memory, inference time and PSNR results of  $\times 4$  SR with different width of axial window in ATWSR

| 窗口宽度 | 占用显存/MB | 推理时间/s | PSNR/dB |
|------|---------|--------|---------|
| 1    | 3898    | 50.46  | 29.89   |
| 2    | 5427    | 56.73  | 29.89   |
| 4    | 7982    | 62.94  | 29.90   |
| 8    | 9864    | 81.87  | 29.91   |

### 3.3.4 Transmre 卷积上采样块的有效性

为证明本文提出的 TACUpSample 比单独使用卷积可以取得更好的超分辨率重建效果，本文对于超分辨率重建模块进行了消融实验，实验设置了仅 TACUpSample 中的卷积和仅 TACUpSample 的 Transformer 作为超分辨率重建模块，与与本文模型进行比较，两个模型分别记为 GDTSR\_0 和 GDTSR\_1，相比较的三个模型参数量几乎相同，实验结果如表 8 所示。从实验结果可以看到，在仅使用 Transformer 时相比于其他模型，性能有较明显的下降，说明在超分辨率重建模块中使用卷积是必不可少的。用本文提出的 TACUpSample，比单独使用卷积，参数量只增加了 0.3%，PSNR 结果有 0.04dB 的提升，说明 Transformer 可以与卷积一起整合浅层和深层特征，相比于与只使用卷积可以更好地重建超分辨率图像。

此外，为了验证 TACUpSample 的通用性，本文把 EDSR-baseline<sup>[4]</sup>和 SwinIR-light<sup>[8]</sup>的超分辨率重建模块替换为 TACUpSample，实验结果如表 9 所示。可以看到，其他经典的轻量级超分辨率模型在使用 TACUpSample 后，可以提升模型性能。

表 8 在验证集 DIV\_val10 上，GDTSR 中不同的超分辨率重建模块，4 倍 SR 的 PSNR 结果  
Tab. 8 On validation dataset DIV\_val10, PSNR results of  $\times 4$  SR

with different super-resolution reconstruction in GDTSR

| 模型      | PSNR/dB | 参数量/ $10^3$ |
|---------|---------|-------------|
| GDTSR_0 | 29.85   | 1030        |
| GDTSR_1 | 29.66   | 1024        |
| GDTSR   | 29.89   | 1027        |

表 9 不同的模型中使用 TACUpSample，在验证集 DIV\_val10 上，4 倍 SR 的 PSNR 结果  
Tab. 9 On validation dataset DIV\_val10, PSNR results of  $\times 4$  SR with different model using TACUpSample

| 模型            | TACUpSample | PSNR/dB                  |
|---------------|-------------|--------------------------|
| EDSR-baseline | -           | 29.61                    |
|               | $\sqrt{}$   | 29.67( $\uparrow 0.06$ ) |
| SwinIR-light  | -           | 29.80                    |
|               | $\sqrt{}$   | 29.83( $\uparrow 0.03$ ) |

### 3.3.5 训练数据集对网络性能的影响

为了说明在训练集中添加 Flickr2K 数据集，对于网络性能的影响，本文把仅使用 DIV2K 作为训练集的 GDTSR 和使用 DF2K(DIV2K+Flickr2K)的 GDTSR-DF 分别在验证集 DIV\_val10 上进行了实验，结果如表 10 所示。可以看到，在训练集中添加了 Flickr2K 数据集后，对网络的性能会有很大提升，在验证集上有 0.29dB 的提升。在 5 个通用测试集上，如表 1、表 2、表 3 所示，网络性能均有很大程度的提高。

表 10 GDTSR 和 GDTSR-DF，在验证集 DIV\_val10 上，4 倍 SR 的 PSNR 结果  
Tab. 10 On validation dataset DIV\_val10, PSNR results of  $\times 4$  SR with GDTSR and GDTSR-DF

| 模型       | PSNR/dB |
|----------|---------|
| GDTSR    | 29.89   |
| GDTSR-DF | 30.18   |

## 4 结语

本文提出了基于全局依赖 Transformer 的图像超分辨率网络 GDTSR，GDTSR 使用两个方向的轴向窗口建立全局依赖，比目前基于移动窗口策略的模型<sup>[8,20]</sup>，能更好地利用整个特征图的所有信息。GDTSR 兼顾使用方形窗口来保持良好的局部信息处理能力，两者结合可以提取更有效的高频信息。此外本文提出了通用的卷积与 Transformer 结合的超分辨率图像重建模块，比起单独使用卷积可以更好地整合提取到的特征，提升模型的超分辨率重建能力。实验表明，与其他先进的超分辨率模型相比，GDTSR 在各个尺度的测试集上的性能达到了最优，特别是在大尺寸纹理细节丰富的数据集上展示出了较大的优势。

### 参考文献

- [1] DONG C, LOY C C, HE K, et al. Learning a Deep convolutional network for image super-resolution[C]//Computer Vision-ECCV 2014: 13th European Conference, Zurich, Switzerland, September 6-12, 2014, Proceedings, Part IV 13. Springer International Publishing, 2014: 184-199.
- [2] DONG C, LOY C C, TANG X. Accelerating the Super-Resolution Convolutional Neural Network[C]//Computer Vision-ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October

- 11-14, 2016, Proceedings, Part II 14. Springer International Publishing, 2016: 391-407.
- [3] KIM J, LEE J K, LEE K M. Accurate Image Super-Resolution Using Very Deep Convolutional Networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 1646-1654.
- [4] LIM B, SON S, KIM H, et al. Enhanced Deep Residual Networks for Single Image Super-Resolution[C]//Proceedings of the IEEE conference on computer vision and pattern recognition work-shops. 2017: 136-144.
- [5] ZHANG Y, LI K, LI K, et al. Image Super-Resolution Using Very Deep Residual Channel Attention Networks[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 286-301.
- [6] TONG T, LI G, LIU X, et al. Image Super-Resolution Using Dense Skip Connections[C]//Proceedings of the IEEE international conference on computer vision. 2017: 4799-4807.
- [7] VASWANI A, SHAZEER N, Parmar N, et al. Attention Is All You Need[J]. *Advances in neural information processing systems*, 2017, 30.
- [8] LIANG J, CAO J, SUN G, et al. SwinIR: Image Restoration Using Swin Transformer[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 1833-1844.
- [9] LIU Z, LIN Y, CAO Y, et al. Swin Transformer: Hierarchical Vision Transformer using Shifted Windows[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 10012-10022.
- [10] HO J, KALCHBRENNER N, WEISSENBORN D, et al. Axial Attention in Multidimensional Transformers[J]. *arXiv preprint arXiv:1912.12180*, 2019.
- [11] SHI W, CABALLERO J, HUSZAR F, et al. Real-Time Single Image and Video Super-Resolution Using an Efficient Sub-Pixel Convolutional neural network[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 1874-1883.
- [12] HUANG J B, SINGH A, AHUJA N. Single Image Super-Resolution from Transformed Self-Exemplars[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 5197-5206.
- [13] TIMOFTE R, DE SMET V, VAN GOOL L. A+: Adjusted Anchored Neighborhood Regression for Fast Super-Resolution[C]//Computer Vision--ACCV 2014: 12th Asian Conference on Computer Vision, Singapore, Singapore, November 1-5, 2014, Revised Selected Papers, Part IV 12. Springer International Publishing, 2015: 111-126.
- [14] ZHANG L, WU X. An Edge-Guided Image Interpolation Algorithm via Directional Filtering and Data Fusion[J]. *IEEE transactions on Image Processing*, 2006, 15(8): 2226-2238.
- [15] MEI Y, FAN Y, ZHOU Y. Image Super-Resolution with Non-Local Sparse Attention[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 3517-3526.
- [16] KIM J, LEE J K, LEE K M. Deeply-Recursive Convolutional Network for Image Super-Resolution[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 1637-1645.
- [17] LEDIG C, THEIS L, HUSZAR F, et al. Photo-Realistic Single Image Super-Resolution Using a Generative Adversarial Network[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 4681-4690.
- [18] WANG X, YU K, WU S, et al. ESRGAN: Enhanced Super-Resolution Generative Adversarial Networks[C]//Proceedings of the European conference on computer vision (ECCV) work-shops. 2018: 0-0.
- [19] GOODFELLOW I, POUGET-ABADIE J, MIRZA M, et al. Generative Adversarial Nets[C]// *Neural Information Processing Systems*. Cambridge, MA: MIT Press, 2014.
- [20] LI W, LU X, LU J, et al. On Efficient Transformer Image Pre-training for Low-Level Vision[J]. *arXiv preprint arXiv:2112.10175*, 2021.
- [21] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An Image Is Worth 16x16 Words: Transformers for Image Recognition at Scale[J]. *ICLR*, 2021.
- [22] YANG J, LI C, ZHANG P, et al. Focal Self-Attention for Local-Global Interactions in Vision Transformers[J]. *arXiv preprint arXiv:2107.00641*, 2021.
- [23] DONG X, BAO J, CHEN D, et al. CSWin Transformer: A General Vision Transformer Backbone with Cross-Shaped Windows[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 12124-12134.
- [24] CARION N, MASSA F, SYNNAEVE G, et al. End-to-End Object Detection with Transformers[C]//Computer Vision--ECCV 2020: 16th European Conference, Glasgow, UK, August 23-28, 2020, Proceedings, Part I 16. Springer International Publishing, 2020: 213-229.
- [25] Chen H, Wang Y, Guo T, et al. Pre-trained image processing transformer[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 12299-12310.
- [26] YOO J, KIM T, LEE S, et al. Rich CNN-Transformer Feature Aggregation Networks for Super-Resolution[J]. *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, 2023.
- [27] LU Z, LI J, LIU H, et al. Transformer for Single Image Super-Resolution[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 457-466.
- [28] Choi H, Lee J, Yang J. N-gram in swin transformers for efficient lightweight image super-resolution[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 2071-2081.
- [29] ZHANG B, CHEN J, WEN Q. Single Image Super-Resolution Using Lightweight Networks Based on Swin Transformer[J]. *arXiv preprint arXiv:2210.11019*, 2022.
- [30] TIMOFTE R, AGUSTSSON E, VAN GOOL L, et al. NTIRE 2017 Challenge on Single Image Super-Resolution: Methods and Results[C]//Proceedings of the IEEE conference on computer vision and pattern recognition workshops. 2017: 114-125.
- [31] KINGMA D P, BA J. ADAM: A Method for Stochastic Optimization[J]. *arXiv preprint arXiv:1412.6980*, 2014.
- [32] BEVILACQUA M, ROUMY A, GUILLEMOT C, ALBERI M O. Low-Complexity Single-Image Super-Resolution based on Nonnegative Neighbor Embedding[J]. 2012.
- [33] ZEYDE R, ELAD M, PROTTER M. On Single Image Scale-Up using Sparse-Representations[C]//Curves and Surfaces: 7th International Conference, Avignon, France, June 24-30, 2010, Revised Selected Papers 7. Springer Berlin Heidelberg, 2012: 711-730.
- [34] MARTIN D, FOWLKES C, TAL D, et al. A Database of Human Segmented Natural Images and its Application to Evaluating Segmentation Algorithms and Measuring Ecological Statistics[C]//Proceedings Eighth IEEE International Conference on Computer Vision. ICCV 2001. IEEE, 2001, 2: 416-423.
- [35] MATSUI Y, ITO K, ARAMAKI Y, et al. Sketch-based manga retrieval using manga109 dataset[J]. *Multimedia Tools and Applications*, 2017, 76: 21811-21838.
- [36] WANG Z, BOVIK A C, SHEIKH H R, et al. Image Quality Assessment: From Error Visibility to Structural Similarity[J]. *IEEE transactions on image processing*, 2004, 13(4): 600-612.
- [37] HUI Z, WANG X, GAO X. Fast and Accurate Single Image Super-Resolution via Information Distillation Network[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 723-731.



- [38] HUI Z, GAO X, YANG Y, et al. Lightweight Image Super-Resolution with Information Multi-distillation Net-work[C]//Proceedings of the 27th acm international conference on multimedia. 2019: 2024-2032.
- [39] LI W, ZHOU K, QI L, et al. Lapar: Linearly-Assembled Pixel-Adaptive Regression Network for Single Image Super-Resolution and Beyond[J]. Advances in Neural Information Processing Systems, 2020, 33: 20343-20355.
- [40] LUO X, XIE Y, ZHANG Y, et al. LatticeNet: Towards Lightweight Image Super-resolution with Lattice Block[C]//Computer Vision—ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XXII 16. Springer International Publishing, 2020: 272-289.
- [41] ZHANG X, ZENG H, GUO S, et al. Efficient Long-Range Attention Network for Image Super-resolution[C]//Computer Vision—ECCV 2022: 17th European Conference, Tel Aviv, Israel, October 23–27, 2022, Proceedings, Part XVII. Cham: Springer Nature Switzerland, 2022: 649-667.
- [42] AHN N, KANG B, SOHN K A. Fast, Accurate, and Lightweight Super-Resolution with Cascading Residual Net-work[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 252-268.
- [43] WANG L, DONG X, WANG Y, et al. Exploring Sparsity in Image Super-Resolution for Efficient Inference[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 4917-4926.
- [44] TIAN C, ZHANG Y, ZUO W, et al. A heterogeneous group CNN for image super-resolution[J]. IEEE Transactions on Neural Networks and Learning Systems, 2022. HCNN
- [45] CONDE M V, CHOI U J, BURCHI M, et al. Swin2SR: SwinV2 Transformer for Compressed Image Super-Resolution and Res-toration[C]//Computer Vision—ECCV 2022 Workshops: Tel Aviv, Israel, October 23–27, 2022, Proceedings, Part II. Cham: Springer Nature Switzerland, 2023: 669-687. Swin2SR

**LIU Zihan**, born in 1997, master. His research interests include deep learning, computer vision.

**ZHOU Dengwen**, born in 1965, master, professor. His research interests include image denoising, image super-resolution.

**LIU Yukai**, born in 1996, master. His research interests include deep learning, computer vision.