

华北电力大学

专业硕士学位论文

基于轴向自注意力的图像超分辨率算法研
究

Research on Image Super-Resolution Algorithm

Based on Axial Self-Attention

刘玉铠

2024 年 6 月

国内图书分类号：TP39
国际图书分类号：004.9

学校代码：10079
密 级：公开

专业硕士学位论文

基于轴向自注意力的图像超分辨率算法研究

硕 士 研 究 生：刘玉铠

导 师：周登文教授

企 业 导 师：张海鹏高级工程师

申 请 学 位：电子信息硕士

专 业 领 域：计算机技术

学 习 方 式：全日制

所 在 学 院：控制与计算机工程学院

答 辩 日 期：2024 年 6 月

授予学位单位：华北电力大学

Classified Index: TP39

U.D.C: 004.9

Thesis for the Professional Master's Degree

**Research on Image Super-Resolution Algorithm
Based on Axial Self-Attention**

Candidate:	Liu Yukai
Supervisor:	Prof.Zhou Dengwen
Enterprise mentor:	Senior Engineer Zhang Haipeng
Professional Degree Applied for:	Electronic and Information Engineering
Speciality:	Computer Technology
Cultivation ways:	Full-time
School:	School of Control and Computer Engineering
Date of Defence:	June, 2024
Degree-Conferring-Institution:	North China Electric Power University

华北电力大学学位论文原创性声明

本人郑重声明：此处所提交的学位论文《基于轴向自注意力的图像超分辨率算法研究》，是本人在导师指导下，在华北电力大学攻读学位期间独立进行研究工作所取得的成果。论文中除已注明部分外不包含他人已发表或完成的研究成果。对本文的研究工作做出重要贡献的个人和集体，均已在文中以明确方式注明。论文由本人撰写，未使用人工智能代写。本声明的法律结果将完全由本人承担。

作者签名：日期：年 月 日

华北电力大学学位论文使用授权书

学位论文系研究生在华北电力大学攻读学位期间在导师指导下完成的成果，知识产权归属华北电力大学所有，学位论文的研究内容不得以其它单位的名义发表。研究生完全了解华北电力大学关于保存、使用学位论文的规定，同意学校保留并向有关部门送交论文的复印件和电子版本，同意学校将学位论文的全部或部分内容编入有关数据库进行检索，允许论文被查阅和借阅，学校可以为存在馆际合作关系的兄弟高校用户提供文献传递服务和交换服务。本人授权华北电力大学，可以采用影印、缩印或其他复制手段保存论文，可以公布论文的全部或部分内容。

保密论文在保密期内遵守有关保密规定，解密后适用于此使用权限规定。
本人知悉学位论文的使用权限，并将遵守有关规定。

作者签名：日期：年 月 日

导师签名：日期：年 月 日

摘 要

单图像超分辨率是一项基本的图像处理任务，旨在从低分辨率图像重建出对应的高分辨率图像。早期的单图像超分辨率网络大多是基于卷积网络实现的。然而卷积层因为在长距离像素的建模上仍有一定的限制，这一问题造成了卷积网络在超分辨率的应用上存在一定的限制。最近，基于视觉 Transformer 的模型因其自注意力机制在长距离建模方面的优势而在超分辨率领域获得了广泛关注，显示出巨大的潜力。

为了进一步提升图像超分辨率性能，本文提出了一种基于轴向自注意力的单图像超分辨率网络。该网络使用轴向自注意力来扩大感受野，并且在有限的计算量和参数量下充分发挥网络的性能。此外本方法还改进了传统 Transformer 网络中激活像素不足的问题，通过改进 Transformer 块中多层感知机(Multilayer Perceptron, MLP)的结构来激活更多的像素进而提升网络的性能。

本文还提出一种结合卷积和 Transformer 的双路超分辨率网络架构。通过引入轴向自注意力优化 Transformer 部分，并设计为双路架构，其中一个分支负责提取局部特征，另一个分支负责提取粗粒度全局特征，实现两种特征的互补融合。这种设计有效地克服了 Transformer 缺乏全局信息的问题。为了能有效融合两路分支的特征，本文设计了一种双路特征融合模块，该模块采用卷积网络架构，通过设计多路的特征并且在不同支路上应用渐进融合策略，来有效提升两路分支融合的性能。本文还设计了一种特征后处理块，在特征后处理块中，将特征分成不同的支路，最后使用通道注意力和增强空间注意力机制来进行最后的信息融合，从而解决深度模型中信息丢失的问题。

实验结果表明，无论是客观指标还是主观视觉效果，本文方法与其他同类方法相比，在参数量和模型性能之间取得更好的平衡，并且具有更好的客观指标和主观视觉效果。

关键词：图像超分辨率；Transformer 网络；卷积神经网络；轴向自注意力；双路特征融合

Abstract

Single image super-resolution is a fundamental image processing task aimed at reconstructing a high-resolution image from its corresponding low-resolution counterpart. Early single image super-resolution networks were mostly based on convolutional networks. However, convolutional layers have certain limitations in modeling long-distance pixels, which has led to some restrictions in the application of convolutional networks to super-resolution. Recently, models based on Vision Transformers have attracted widespread attention in the field of super-resolution due to their advantage in long-distance modeling through self-attention mechanisms, demonstrating great potential.

To further enhance image super-resolution performance, this paper proposes a single image super-resolution network based on axial self-attention. This network uses axial self-attention to expand the receptive field and fully exploit the network's performance with limited computational and parameter resources. Additionally, this method improves the issue of insufficient activation of pixels in traditional Transformer networks by enhancing the structure of the multi-layer perceptron in Transformer blocks to activate more pixels and thus improve network performance.

This article also introduces a dual-path super-resolution network architecture that combines convolution and Transformer. By incorporating axial self-attention to optimize the Transformer part and designing a dual-path architecture, where one path is responsible for extracting local features and the other for coarse-grained global features, it achieves a complementary fusion of the two types of features. This design effectively overcomes the problem of Transformers lacking global information. To effectively merge features from both paths, a dual-path feature fusion module is designed using a convolutional network architecture. It employs multiple feature paths and applies a progressive fusion strategy on different branches to enhance the performance of the fusion of the two branches. Additionally, a feature post-processing block is designed. In this block, features are divided into different branches, and finally, a channel attention mechanism is used for the final information fusion, thereby addressing the issue of information loss in deep models.

Experimental results show that, in terms of both objective metrics and subjective visual effects, our method achieves a better balance between parameter quantity and model performance compared to other similar methods, and it exhibits better objective metrics and subjective visual effects.

Keywords: image super-resolution, Transformer networks; convolutional neural

networks; axial attention; dual-path feature fusion

目 录

摘 要	I
ABSTRACT.....	II
第 1 章 绪 论	1
1.1 课题背景及研究意义	1
1.2 国内外研究现状	2
1.2.1 基于插值的方法.....	2
1.2.2 基于重建的方法.....	3
1.2.3 基于学习的方法.....	4
1.3 主要研究内容	6
1.4 本文章节安排	7
第 2 章 相关方法综述	9
2.1 卷积神经网络	9
2.1.1 卷积核.....	9
2.1.2 池化层.....	10
2.1.3 激活函数.....	10
2.2 Transformer 网络.....	12
2.3 基于 Transformer 网络架构的超分辨率网络	13
2.3.1 基本的 Transformer 架构的超分辨率网络算法.....	13
2.3.2 常用的数据集.....	18
2.3.3 常用的损失函数.....	18
2.3.4 常用的评价指标.....	19
2.3.5 LAM 分析	21
2.4 本章小结	22
第 3 章 基于轴向自注意力的单图像超分辨网络算法的研究	23
3.1 引言	23
3.2 算法总体设计	26
3.2.1 AASR 网络架构	26
3.2.2 残差的轴向自注意力块(RASAB).....	27
3.2.3 轴向自注意力计算块(ASAB)	27

3.2.4 轴向自注意力计算层(ASAL).....	28
3.2.5 基于卷积的 Gated-Dconv 前馈结构层(GDFN).....	29
3.3 实验与分析	30
3.3.1 实验设置.....	30
3.3.2 消融实验.....	30
3.3.3 实验结果分析.....	32
3.4 本章小结	39
第 4 章 基于双路的卷积轴向自注意力单图像超分辨率算法的研究	40
4.1 引言	40
4.2 算法总体设计	41
4.2.1 DCASRN 网络架构	41
4.2.2 增强的卷积特征提取块(ECFEB)模块设计.....	42
4.2.3 Transformer 特征提取块(TFEB)模块设计	46
4.2.4 双路特征融合块(DFFB)模块设计	48
4.2.5 特征后处理块(FPB)模块设计	50
4.3 实验与分析	51
4.3.1 实验设置.....	51
4.3.2 消融实验.....	52
4.3.3 实验结果分析.....	53
4.4 本章小结	60
第 5 章 结论与展望	61
5.1 论文工作总结	61
5.2 未来工作展望	62
参考文献	63
攻读硕士学位期间发表的论文及其它成果	70
致 谢	71

第1章 绪论

1.1 课题背景及研究意义

在数字化和信息技术飞速发展的今天，人们对于图像清晰度和细节表现的追求从未停止。随着高清视觉内容成为新的标准，图像的分辨率及其重要性日益突显。分辨率，即图像中所包含的像素密度，直接影响到图像的质量和细节丰富度。高分辨率图像以其细腻的纹理和锐利的边缘，提供了更加生动和真实的视觉体验，成为了数字图像处理、计算机视觉等领域研究的重点。然而，由于设备限制、成本考虑或现实环境中的种种不可控因素，获取高分辨率图像并非总是可行的。在这种背景下，图像超分辨率技术应运而生，它通过软件算法来改善和增强图像的分辨率，而非依赖昂贵的硬件升级。这种技术尝试从现有的低分辨率图像中重构出高分辨率的细节，弥补了直接获取高质量图像的不足。通过对图像的深度学习和智能分析，超分辨率技术能够揭示并增强图像中原本不明显的细节和纹理，从而在不增加成本的同时，显著提升图像质量。这一进展不仅推动了视觉技术的发展，也为多媒体应用、远程感应、医疗成像等多个领域带来了革命性的改变。

在当前的科技发展趋势中，图像处理技术的进步已经成为不可或缺的一部分，尤其是图像超分辨率重建技术，它已经成为了图像处理领域的一个热点研究方向。该技术主要通过先进的计算方法，从一个或多个低分辨率图像中重建出高质量的高分辨率图像^[1]。这种技术的应用范围非常广泛，包括但不限于卫星图像处理^[2,3]、医疗影像提升^[4]、安防监控^[5]优化等多个领域。

在卫星图像处理领域，由于自然条件和技术限制，获取的图像往往分辨率不高，这限制了其在地理信息系统、环境监测等领域的应用。通过应用图像超分辨率重建技术，可以在不更换昂贵设备的情况下，提高图像的分辨率和质量，从而更好地进行地形分析和环境监测。

在医疗影像领域，高分辨率的医学图像对于疾病的诊断和治疗至关重要。利用图像超分辨率重建技术，可以从低分辨率的医学扫描图像中重建出更清晰的图像，帮助医生更准确地诊断疾病，提高治疗效果。

安防监控领域，超分辨率技术的应用对于提升监控画面的质量发挥着重要作用。尤其在一些对安防有着高度要求的区域，应用超分辨率技术可以显著增强监控画面的质量和细节，保障区域安全，为社会治安贡献力量。

总之，随着计算机视觉技术的不断进步，图像超分辨率技术将在更多领域发挥越来越多的作用。不仅能够提升图像和视频等相关应用的恢复细节和质量，还

能够推动相关领域的研究和技术的发展。

1.2 国内外研究现状

在当前的科技领域，单图像超分辨率重建(Single Image Super-Resolution, SISR)技术正迅速发展，成为图像处理研究中的热点。这项技术旨在通过分析低分辨率(Low-Resolution, LR)图像，恢复出其高分辨率(High-Resolution, HR)版本，以此提升图像的质量和细节。早期的 SISR 方法主要依赖于传统的插值技术，如双线性插值^[6]和双三次插值^[7]等，这些方法虽然操作简便、计算成本低，但在恢复高频细节方面表现不佳。随着时间的推移，基于重建的方法开始流行^[8-10]，这类方法通过引入图像的先验知识，尝试更准确地预测 HR 图像。最近，深度学习特别是卷积神经网络(Convolutional Neural Network, CNN)的引入，使得 SISR 技术得到了质的飞跃^[11-13]。通过深度学习模型直接从 LR 到 HR 图像之间学习非线性映射关系，大大提高了超分辨率重建的准确性和效率。当前研究的焦点包括进一步提升重建图像的质量，减少重建过程中的失真和模糊，以及降低计算复杂度以适应实时处理需求^[14]。随着技术的不断进步和优化，SISR 技术未来在多个应用场景中的潜力仍然巨大，包括但不限于医疗成像、卫星图像处理、以及视频流媒体增强等领域。

1.2.1 基于插值的方法

基于插值的图像超分辨率算法因其计算的高效性应用广泛，特别在一些对图像恢复质量不高的场景，如简单的图片放大等场景。这些技术的实现通常依赖于高效的插值方法。基于插值的超分辨率算法主要是利用已有的像素信息，通过特定的数学模型预测并填充图像中未知的像素点，从而达到图像超分辨率的效果。目前常用的插值技术主要包括三种：最近邻插值法^[15]、双线性插值法^[6]和双三次插值法^[7]。最近邻插值法的主要优点是简单性和高效性。这种算法计算简便，可以快速完成图像尺寸的调整。然而，它的缺点也非常明显，由于仅仅采用最近的像素值进行填充，没有进行任何形式的平滑或过渡处理，因此很容易在放大图像的过程中产生锯齿效应，降低图像质量。

双线性插值法相较于最近邻插值法，在图像质量上有一定的提升。它通过对四个最近邻像素值进行加权平均，从而预测未知的像素点。这种算法能够在一定程度上模拟出更加平滑的过渡效果，减少锯齿现象。但是由于缺乏全局信息，双线性插值法在处理高频细节时仍然可能出现模糊，对于生成图像要求质量较高的场景来说，这可能是一个缺点。

双三次插值法提供了更高级的插值算法，通过考虑更多的邻近像素并使用三

次多项式函数进行插值,从而能够更好地保留图像的高频信息。这种方法在图像质量上相比前两者有显著提升,特别是在保持边缘锐度和纹理细节方面表现更佳。然而,双三次插值法的计算复杂度也相应增加,处理速度相较于最近邻插值法和双线性插值法来说会更慢。

Li 等人^[16]开发了一种新型的基于边缘指导的图像插值算法,这种算法显著优于传统的线性插值方法,因为它能够在提高图像分辨率的同时,保持图像的边缘清晰度,从而改善了图像的整体视觉效果。同时,Battiatto 等人^[17]发展了一种考虑图像局部特征的自适应缩放算法,通过分析图像的纹理和结构信息来优化插值结果,进一步提升了图像质量。尽管这些方法在提高图像分辨率方面取得了一定的进展,但仍存在计算复杂度高、处理时间长等挑战。

虽然基于插值的图像超分辨率算法速度快,占用资源小,但这类方法往往需要依赖局部个别的像素信息。这种依赖局部像素信息的特性会导致生成的图像缺乏图像全局的信息,进而导致生成的图像会过度平滑和模糊,甚至会产生锯齿效应。对于需要产生高质量超分辨图像的领域,如专业的图像编辑、医学图像处理等领域,这种图像质量的损失往往是不可接受的。因此,为了追求更高的图像质量,需要探索其他的高级图像处理技术,在保证计算资源的前提下,利用图像全局信息来恢复更高质量的图像。

1.2.2 基于重建的方法

基于重建的方法通过利用图像内部已有的先验知识来预测高分辨率图像,它通过模拟从高分辨率(HR)图像到低分辨率(LR)图像的退化过程,逆向推导出将 LR 图像转换为相应的 HR 图像的建模方法,以此来补充丢失的高频细节。典型的基于重建的超分辨率技术包括迭代反投影法^[8]、多帧超分辨率法^[18]和最大后验概率法^[10]。

迭代反投影法是一种图像重建技术,它通过引入残差图的概念来逐步提高图像的分辨率。具体过程包括:首先使用插值等方法生成高分辨率图像,然后将这个高分辨率图像进行下采样,这里的下采样需要和获得低分辨率图像的下采样方法保持一致,以模拟获取低分辨率图像的过程,从而得到一个新的低分辨率图像。通过计算新旧低分辨率图像之间的差异,可以得到一个残差图。这个残差图随后被用来修正高分辨率图像,通过不断迭代这个过程,直到残差图的变化小于某个预设的阈值,从而得到最终的高分辨率图像。尽管这种方法能够在一定程度上约束高分辨率图像的生成过程,使其更加接近真实情况,但它也存在明显的缺陷。由于从高分辨率到低分辨率的具体过程是未知的,投影过程可能会引入较大的误差。此外,算法对初始估计的要求较高,对噪声也比较敏感,同时多次迭代会导

致图像生成速度相对较慢，所以这些问题限制了其在图像恢复领域中的应用。

Tsai 等人^[18]通过将低分辨率图像划分成不同的时序，并将其转换至频率域，利用傅里叶变换作为桥梁，实现了从低分辨率图像到频率域的转换。通过对这些频率域内的图像进行重建和恢复，他们成功地获得了更高质量的图像效果。在此过程中，傅里叶变换扮演了关键的中介角色，为高分辨率图像的重建提供了所需的频率信息。

最大后验概率估计方法^[10]是一种基于贝叶斯统计理论的非线性超分辨率方法。它通过考虑图像的先验信息，将图像重建问题转化为最大化后验概率的问题，以此来估计图像的最可能状态。在处理无噪声情况时，该方法将问题转化为优化凸函数，以求解高分辨率图像；而在有噪声的情况下，通过引入正则项，将问题转化为二次规划问题，这样不仅能够较好地解决噪声问题，还能避免过拟合，从而生成高质量且清晰度较高的图像。然而，该方法的一个主要缺陷在于其计算过程相对较慢，特别是当图像矩阵很大时，收敛速度会更慢，这限制了其在需要快速处理大量数据时的应用效率。

1.2.3 基于学习的方法

早期基于学习的方法主要包括基于邻域嵌入的方法^[19]和基于稀疏编码的方法^[20]。基于邻域嵌入的算法通过考虑图像块之间的局部结构相似性，实现了从低分辨率 LR 到高分辨率 HR 图像的转换。该方法通过识别输入的 LR 图像块与训练集中最相近的几个块之间的关系，并将这种关系映射到对应的 HR 图像块上，从而合成最终的 HR 图像。虽然该方法速度较快且存储需求灵活，但在处理大数据集时速度下降，且可能导致重建的 HR 图像质量不足，同时维护庞大样本库需要占用大量存储空间。基于稀疏编码的算法是一种通过学习 LR 图像块与 HR 图像块之间的映射关系来进行图像超分辨率重建的方法。该方法利用超完备字典对 LR 图像块进行稀疏表示，然后通过相同的稀疏系数结合 HR 超完备字典来重建 HR 图像块。由于能够捕捉到图像的纹理和结构信息，因此在提高图像分辨率方面表现出了优异的效果。然而，该方法对字典构建的要求较高，需要大量训练数据来学习字典，使得训练过程相对困难，并且计算复杂度较高，当处理大规模数据时，算法的效率可能会受到影响。

随着深度学习领域发展，基于学习的超分辨率方法通常使用深度学习方法，涉及到使用卷积神经网络^[11]、生成对抗网络^[21]、深度扩散模型^[22]和 Transformer 模型^[23,24]等方法。

基于卷积神经网络的典型算法是由 Dong^[11]等人提出的 SRCNN 网络，该模型通过端到端的方式学习低分辨率到高分辨率图像之间的非线性映射关系，实现

图像的超分辨率重建。SRCNN 网络结构包括特征提取、特征映射和重建三个主要部分。首先，它通过卷积层提取输入的低分辨率图像的特征；然后，这些特征进一步通过卷积层进行映射和转换；最后，通过卷积层重建出高分辨率图像。这个过程允许网络自动学习图像的超分辨率映射，从而生成更加清晰、细节丰富的高分辨率图像。SRCNN 的创新之处在于将深度学习技术首次成功应用于图像超分辨率领域，展现了卷积神经网络在图像处理方面的强大潜力。尽管如此，随着深度学习技术的发展，后续研究中提出了更多高效、复杂的模型来进一步提升超分辨率重建的性能。在 2015 年，ResNet^[25]首次将深度残差网络引入到图像识别任务中，并对后续的图像超分辨率研究产生了深远的影响。ResNet 通过引入残差连接来解决深度网络训练过程中可能出现的梯度消失或爆炸问题，在构建更深的网络的同时能够学习到更加复杂和深层的特征表示。在 ResNet 的基础上，VDSR^[26]模型通过采用残差学习的方式，显著增加了网络层数，不仅提高了单图像超分辨率的性能，而且通过全局残差学习和带填充(padding)的卷积层设计，解决了图像在连续卷积操作中逐渐缩小的问题，并使得网络模型能够更快地收敛。然而，这些方法的缺陷在于随着网络深度的增加，模型的参数量和计算量也随之增大，这对计算资源提出了更高的要求，同时也增加了训练的难度。

生成对抗网络(Generative Adversarial Network, GAN)自 2014 年由 Goodfellow 等人^[27]提出以来，在图像超分辨率(SR)领域得到了广泛的应用。GANs 由生成器(Generator)和判别器(Discriminator)两部分组成。生成器用于生成需要的图像，判别器用于按照预设的条件对生成的图片进行判别以帮助生成器更好的学习图像的特征。在图像超分辨率领域，使用 GAN 可以帮助模型学习到更加复杂和细致的图像纹理细节，从而生成看起来更加真实、细腻的高分辨率图像。著名的应用实例是 SRGAN^[28]，它是专门为了提升低分辨率图像到高分辨率图像转换的质量而设计的。SRGAN 通过训练生成器生成高分辨率图像，并通过判别器来评估生成图像的真实性，从而在训练过程中逐渐提升生成图像的质量。虽然 GAN 在图像超分辨率领域取得了显著成效，但也面临着一些挑战和缺陷，例如训练过程的稳定性问题、模型收敛速度慢以及可能产生不真实的纹理或伪影等问题。

深度扩散模型在图像超分辨率领域的应用确实取得了令人瞩目的成就。SR3^[22]模型作为该技术的一个代表，通过其迭代细化策略，可以将低分辨率图像转换为高质量的高分辨率图像。这一过程涉及到将低分辨率图像视作含有噪声的高分辨率图像，然后逐步消除这些噪声，以此来恢复图像的清晰度和细节。尽管如此，深度扩散模型在实际应用中面临诸多挑战。首先是推理速度的问题，由于模型复杂度较高，其生成高分辨率图像的速度往往不能满足实时处理的需求。其次，模型的参数量大，计算成本高，这意味着需要较为强大的硬件支持才能有效

运行这些模型，这对于资源有限的环境是一个不小的挑战。

SwinIR^[24]作为一种基于 Transformer 的低级视觉重建模型，在图像超分辨率领域中展现出了显著的优势。它通过将传统的卷积神经网络与 Transformer 结构相结合，克服了卷积神经网络在感受野大小上的限制以及 GAN 网络训练稳定性方面的不足，同时也避免了深度扩散模型在计算成本上的高昂开销。SwinIR 模型主要由三大部分构成：浅层特征提取、深层特征提取和图像重建模块三部分构成。首先浅层特征提取用于提取图像浅层特征，之后深层特征提取通过多个 Swin Transformer^[29]块来实现，这些块能够利用 Transformer 的长距离依赖建模能力，显著扩大模型的感受野，最后的图像重建部分则将提取到的特征转化为高质量的超分辨率图像。SwinIR 的这一创新设计不仅提高了超分辨率算法的性能，而且为未来的研究工作指明了方向，是图像处理领域中的一大进步。

1.3 主要研究内容

近年来，随着深度学习技术的不断进步，基于 Transformer 架构的网络在单图像超分辨率领域得到了广泛的研究和应用。与传统的卷积神经网络相比，Transformer 网络引入的自注意力机制^[30]在特征提取和信息融合方面展现出了独特的优势。自注意力机制能够有效地捕捉图像中不同区域之间的长距离依赖关系，这对于改善图像的超分辨率重建质量至关重要。它通过计算序列内部各元素之间的注意力分数来实现这一特性，使得模型能够关注到更加全面的上下文信息。这种机制在处理长距离依赖的问题上比卷积神经网络更加高效，因为卷积操作通常只关注局部邻域像素之间的联系，而忽略了远距离像素间的联系。基于 Transformer 架构的特点，本文主要研究基于 Transformer 架构的轴向自注意力^[31]的单图像超分辨率网络，具体研究内容如下：

本文提出了一种基于 Transformer 架构的单图像超分辨率(SISR)网络，核心是基于轴向自注意力的 SISR 网络(Axial self Attention single image Super-Resolution, AASR)，结合了基于门控卷积(Gated-Dconv)的前馈结构层(Gated-Dconv Feedforward Network, GDFN)。AASR 网络利用轴向自注意力机制，通过水平和垂直方向的自注意力计算，有效捕捉图像的全局依赖性，相对于局部的窗口自注意力机制能够扩大模型的感受野，这有效提高了超分辨模型的性能。此外本文提出的 GDFN 是 AASR 网络中的另一个关键创新，它通过引入深度可分离卷积^[32]和门控机制^[33]，取代了传统 Transformer 块中的多层感知机^[34]，从而增强了网络处理图像细节的能力。GDFN 具有两个分支，一个是通过深度可分离卷积处理输入特征的分支，另一个是在此基础上加入非线性激活函数 GELU 的分支。这两个分支的输出经过逐元素求积，再与原始输入特征相加，形成最终的输出。

这种结构显著提升了模型的性能,尤其是在处理高频细节和纹理方面的能力。通过一系列的实验表明本文提出的网络在多个标准数据集上的有效性。与现有的先进方法相比,所提出的方法无论在主观效果还是客观指标上都取得了显著的提升,同时在视觉质量上也表现出了优越性。这些实验结果展现了 AASR 网络中轴向自注意力机制的强大性能。尤其是在细节恢复和纹理增强方面, AASR 网络能够在不同尺度的超分辨率任务中表现出色,这归功于其能够捕捉到图像中的长距离依赖信息。轴向自注意力机制通过分别在水平和垂直方向上应用自注意力,使得网络能够更加灵活地处理图像的全局信息,提高超分辨率图像的质量。

本文还提出了一种结合了卷积神经网络和 Transformer 的双路架构的超分辨率网络。该网络通过 Transformer 分支提取图像局部特征,通过卷积神经网络分支提取全局特征。该架构通过在 Transformer 分支中采用轴向自注意力机制来增强图像局部细节恢复,而在卷积分支中利用卷积计算的高效性提取图像的全局特征。为了能够更好的提取图像的全局信息,增强图像细节的恢复,本文设计了一款特殊的卷积网络模块,能够有效的提取图像的全局信息。具体来说,本方法在卷积分支中引入多分支的渐进融合策略来使各个分支的信息相互融合,避免因为各个分支的信息缺少交互而导致全局信息的缺失。此外我们使用通道注意力机制^[12](Channel Attention, CA)来将各个分支的信息进一步融合,增强各个分支信息融合的能力。我们还使用增强空间注意力^[35](Enhanced Spatial Attention, ESA)来进一步提高卷积分支的感受野,增强卷积分支全局信息的获取能力从而提取图像粗粒度的全局信息。实验证明,我们的方法能够有效融合全局和局部信息,在平衡计算量和参数量的情况下提高超分辨率图像的质量。

1.4 本章章节安排

本文的主要内容如下:

第 1 章为绪论,阐述了选定课题的研究背景,介绍了国内外在该课题领域的研究现状以及本文主要的研究内容,最后介绍本文的章节安排。

第 2 章为相关方法综述,首先介绍深度学习中卷积神经网络和 Transformer 网络的基本概念和一些理论基础,之后介绍各种基于 Transformer 架构的超分辨率网络结构。最后介绍单图像超分辨率领域中常用的数据集、损失函数以及各种评价指标。

第 3 章主要介绍基于轴向自注意力网络的基本结构以及改进提升方案并详述了网络中各模块的构造。通过多项消融实验检验网络的有效性。本章节中所提出的方法在客观指标和主观效果评价上均表现出较大优势,这为轴向自注意力的研究提供了启发性的设计方案。

第 4 章中主要介绍了一种双路径网络，该网络融合了轴向自注意力的 Transformer 和卷积神经网络的优势提升超分辨率网络的性能。本章节先介绍了网络的整体架构，包括各个模块的内部结构和工作原理。通过一系列的实验验证，本章所提出的方法在主观视觉效果评价和客观性能指标测评上均展现出了竞争力。

第 5 章是结论与展望，旨在综合前述章节的研究成果，对提出的方法和理论进行归纳总结。本章不仅回顾了研究过程中取得的关键发现，而且对其中存在的不足之处进行了简单分析。

第 2 章 相关方法综述

2.1 卷积神经网络

卷积神经网络是由卷积核构成的一种前馈神经网络，主要应用于图像和视频识别、图像分类、图像分割以及机器人技术等领域。这种网络通过卷积层的卷积核对输入的数据进行特征提取，每个卷积核负责捕捉输入数据的不同特征。随后，池化层(也称为下采样层)会减少数据的维度，同时保留最重要的信息。激活函数如 ReLU^[36]则负责引入非线性，使得网络能够学习和模拟复杂的函数映射。由于卷积具有平移不变性的特点，即当图像中的物体发生位移时，通过卷积提取的特征不会受到影响，这一特点保证了模型对于物体位置的泛化能力。此外，卷积还能够通过局部感受野捕捉图像局部区域的特征，从而降低模型的复杂度并减少参数数量。权重共享是卷积神经网络中的一个核心概念，它指的是网络中每个卷积核的参数在整个输入图像上使用是相同的。这不仅大幅度减少了模型的参数数量，也使得模型更易于训练和泛化。此外通过设计多尺度卷积，即在同一层中使用不同大小的卷积核进行特征融合，网络可以同时捕获图像的粗粒度和细粒度信息，这样就能够提取到更加丰富和层次化的特征，并且可以有效减少过多较大的卷积核的使用，减少计算量和参数数量。总之，卷积在图像超分辨率领域中的应用极为广泛，并且通过创新性的网络架构设计，如重参数化^[37]和多尺度卷积^[38]等方法，可以极大地提升模型对图像超分辨率的性能。

2.1.1 卷积核


在卷积神经网络中，卷积核扮演着至关重要的角色，它通过在图像上滑动来提取重要的特征信息。卷积核的大小，即宽度和高度，决定了它能够覆盖图像的区域范围。填充(Padding)是一种常用的技术，通过在图像边缘添加额外的像素来保持图像尺寸的一致性，这样可以使得边缘信息得到更好的处理。步幅(Stride)是卷积核在图像上移动时的距离，它决定了特征图的大小，较大的步幅会减少特征图的维度。空洞率系数(Dilation)是另一个参数，它允许卷积核中的元素间隔更宽，从而在不增加参数数量的情况下增加感受野。这些参数共同作用，使得卷积神经网络能够高效地学习图像数据中的层次性结构和复杂特征，从而在视觉任务中取得优异的性能。

2.1.2 池化层


在卷积神经网络的架构中，池化层扮演着至关重要的角色。作为一种标准的降采样技术，池化层的主要目的是通过减少数据维度和复杂性来提升计算效率，同时保持关键特征信息的完整性。在大多数情况下，池化层紧随卷积层之后，对其输出进行空间上的下采样处理。这种处理不仅有助于显著降低网络模型中的参数数量和计算负担，还可以有效减轻过拟合问题，增强模型对新数据的泛化能力。池化操作主要分为两种类型：最大池化(Max Pooling)和平均池化(Average Pooling)。最大池化操作通过提取特定窗口内的最大值来代表整个窗口区域，这种方式极好地保留了窗口中最显著的特征信号。相对地，平均池化则通过计算窗口内所有元素的平均值来反映该窗口区域的一般特征强度。这两种池化策略都使得网络结构对于输入数据中的微小变动具有一定的不变性，如图像中物体的轻微移动，从而增强了模型对实际应用场景的适应性和鲁棒性。总体而言，池化层是卷积神经网络中不可或缺的一环，对于优化模型性能和效率起到了关键作用。

2.1.3 激活函数

激活函数是深度学习领域中一个重要的概念，通过激活函数可以为网络引入非线性变化，增加模型的复杂度。激活函数的主要作用是让网络能够处理输入数据中的非线性模式，因为现实世界中的映射变换往往是非线性的，所以需要引入非线性变化来为模型提供复杂的映射。如果模型没有激活函数，则深度模型的表达能力会受到限制。常用的激活函数如下：



a) Sigmoid 激活函数



b) ELU 激活函数




图 2-1 常见的激活函数

1) Sigmoid 激活函数^[39]:

如图 2-1 a)所示, Sigmoid 函数是一个 S 形曲线, 它将任何输入值压缩到 0 和 1 之间。这使得它特别适用于将输出解释为概率或用于二分类问题中。由于其平滑的梯度特性, 它在早期的神经网络模型中非常受欢迎。其数学表达式如公式(2-1)所示:

$$f(x) = \frac{1}{1 + e^{-x}} \quad (2-1)$$

2) ELU 激活函数^[40]:

如图 2-1 b)所示, ELU 函数是为了改善 ReLU 激活函数在负值区域内的硬饱和问题而提出的。它旨在将神经网络中隐藏层的单元输出调整到一个更加自然的数值范围, 从而帮助减少梯度消失问题, 加速学习过程。ELU 激活函数在输入大于 0 时, 直接输出该值; 而在输入小于等于 0 时, 输出一个关于该值的指数函数减 1, 这样可以确保激活函数的输出均值接近于零, 从而提高神经网络的训练速度和性能。其数学表达式如公式(2-2)所示:

$$f(x) = \begin{cases} x & \text{if } x > 0 \\ \alpha(e^x - 1) & \text{if } x \leq 0 \end{cases} \quad (2-2)$$

3) ReLU 激活函数:

如图 2-1 c)所示, ReLU 函数提供了一个简单的阈值操作, 所有负输入值都被置为 0, 而所有正输入值保持不变。这种非线性特性使得 ReLU 在隐藏层中应用广泛, 因为它既简单又有效, 能够加速神经网络的训练。其在正区间内的线性特性有助于缓解梯度消失问题, 使得网络能够学习更快并更深入。其数学表达式如公式(2-3)所示:

$$f(x) = \max(0, x) \quad (2-3)$$

4) Leaky ReLU 激活函数^[41]:

Leaky ReLU 是 ReLU 的一个变种,如图 2-1 d)所示,它允许负输入值有一个非零的输出(即“leak”),这个小斜率确保即使在输入值为负时梯度也不会完全消失。这有助于解决 ReLU 激活函数中的死神经元问题,即某些情况下神经元只输出 0 的问题。通过这种方式,Leaky ReLU 保持了 ReLU 的一些优点,同时试图提供更好的性能。其数学表达式如公式(2-4)所示:

$$f(x) = \begin{cases} x & \text{if } x > 0 \\ \alpha x & \text{if } x \leq 0 \end{cases} \quad (2-4)$$

在上述公式中, α 通常设置为一个正数,保证函数在小于 0 的区间内不再输出 0 而是一个小的数据输出,进而保证即使在输入值为负时梯度也不会完全消失从而保证训练的稳定性。

2.2 Transformer 网络

Transformer 架构^[23]的核心组件是 Transformer 块,其整体的结构如图 2-2 所示:




图 2-2 Transformer 块内部结构

首先将输入的图像向量化为 X , 在进入多头自注意力机制(MHSA)之前, 向量 X 首先通过层归一化(LN)^[42]进行预处理。层归一化的目的是减少内部协变量偏移, 通过对特征进行标准化来稳定训练过程。其数学表达式如公式(2-5)所示:

$$LN(X) = \gamma \left(\frac{X - \mu}{\sqrt{\sigma^2 + \epsilon}} \right) + \beta \quad (2-5)$$

其中 X 是输入图像, μ 、 σ 、 γ 、 ϵ 和 β 是层归一化的参数。

接下来的 MHSA 是多头自注意力, 其计算过程如公式(2-6)所示:

$$\begin{aligned} MultiHead(Q, K, V) &= Concat(head_1, \dots, head_h) W^O \\ head_i &= Attention(QW_i^Q, KW_i^K, VW_i^V) \end{aligned} \quad (2-6)$$

上述公式中的 $MultiHead(\cdot)$ 表示多头自注意力的计算, 每个 $head_i$ 代表一个通道分组内的自注意力计算。自注意力 $Attention(\cdot)$ 的计算过程如下:

首先, 将输入图像转换成一系列向量, 即查询(Query, Q)、键(Key, K)和值(Value,

V)。这些向量是通过将输入向量与权重矩阵相乘得到的，如公式(2-7)所示：

$$Q = XW^Q, K = XW^K, V = XW^V \quad (2-7)$$

其中 x 是输入向量， W^Q 、 W^K 和 W^V 是权重矩阵。权重矩阵允许模型将输入向量转换为新的特征空间。通过与权重矩阵相乘，输入数据可以被映射到一个可能更有利于模型理解和处理的表示形式。这种变换可以帮助模型更好地捕捉和理解数据中的复杂关系和模式，从而学到特定任务中的知识。待输入序列转换后，执行自注意力计算，过程如公式(2-8)所示：

$$Attention(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (2-8)$$

在上述公式中， $\text{softmax}(\cdot)$ 表示 softmax 函数。自注意力机制在处理图像任务时，可以被视为一种允许模型在处理每个像素点时考虑到图像中所有其他像素点信息的机制。在这里， QK^T 表示查询和键的点积，用于衡量它们之间的相似度。然后，将计算得到的相似度积除以 $\sqrt{d_k}$ ，其中 d_k 是键向量的维度，这样做是为了控制点积得分的量级，避免过大的得分导致 softmax 函数进入梯度很小的区域，从而影响梯度下降的效率。接下来，应用 softmax 函数对这些得分进行归一化处理，使得所有得分之和为 1。 softmax 函数确保了每个值的权重是正的且总和为 1，这样就可以将它们解释为概率。这一步骤使得模型能够决定在生成每个输出元素时应该“关注”输入序列的哪些部分更多。通过这种方式， softmax 函数在 MHSA 中起到了关键作用，它使得模型能够基于输入之间的相互作用动态地调整注意力焦点。在实际应用中，这允许 Transformer 模型捕捉到输入数据中复杂的、长距离的依赖关系。

在 MHSA 之后，有另一个层归一化步骤，随后是多层感知机(MLP)。MLP 可以看作是对 MHSA 输出的进一步处理，它包含两个线性层和一个非线性激活函数，通常是 ReLU。MLP 的存在使得模型能够学习复杂的特征表示。MLP 的计算过程如公式(2-9)所示：


$$MLP(X) = \text{ReLU}(XW_1 + b_1)W_2 + b_2 \quad (2-9)$$

其中 W_1 和 W_2 为 MLP 的权重矩阵， b_1 和 b_2 是偏置参数。

2.3 基于 Transformer 网络架构的超分辨率网络


2.3.1 基本的 Transformer 架构的超分辨率网络算法

2.3.1.1 IPT


 图 2-3 IPT 网络结构图^[23]

Chen 等人提出的 IPT 网络^[23]是一种利用 Transformer 架构针对多种低层次视觉任务(如超分辨率、噪声去除和去雨)的预训练模型。通过在大规模数据集上预训练, IPT 在多个基准测试中实现了单一模型针对特定任务的微调, 达到了最先进的性能。模型架构包括多个针对不同任务的头部和尾部, 共享一个通用的 Transformer 主体。该研究展示了使用基于 Transformer 架构的预训练模型进行图像处理任务的有效性, 相较于现有方法显示出显著的改进。但是这个模型的缺点是基于全局感受野的自注意力计算, 所以该模型的计算量很大, 速度很慢, 不利于推广应用。其网络结构如图 2-3 所示。

2.3.1.2 SwinIR


 图 2-4 SwinIR 网络结构图^[24]

Liang 等人提出的 SwinIR^[24]是基于 Swin Transformer 的图像恢复模型。该模型由浅层特征提取、深层特征提取和高质量图像重建三个模块组成。该模型在多个图像恢复任务上, 包括图像超分辨率、去噪、以及 JPEG 压缩去伪影等任务展现出优于此前最先进方法的性能, 同时显著减少了参数数量。SwinIR 的核心是

利用滑动窗口(Shifted Windows)机制解决了 IPT 中全局计算注意力造成计算量过大的问题。其深层特征提取模块,由多个残差 Swin Transformer 块(RSTB)组成,每个 RSTB 包含多层 Swin Transformer 层,用于局部注意力和窗口间交互,加上卷积层以增强特征并通过残差连接实现特征聚合。实验结果证明 SwinIR 相对于其他传统方法在不同任务上均达到了显著的性能提升。其网络结构如图 2-4 所示。

2.3.1.3 HAT





图 2-5 HAT 网络结构图^[43]


Chen 等人提出了一种新型的图像超分辨率方法,名为 HAT 网络^[43],通过结合通道注意力和自注意力机制,激活更多的输入像素以重建高分辨率图像。此外,引入了一个重叠交叉注意力模块(overlapping cross-attention block, OCAB)来更好地聚合跨窗口信息,并提出了一种先在大规模数据集(作者使用的是 ImageNet 数据集)上做预训练然后再在特定数据集训练(作者使用的是 DF2K 数据集)的策略以进一步激发模型潜能。此外,作者使用了一种结合 Transformer 和通道注意力网络的混合注意力模块,通过在 Transformer 分支中提取的特征加入通道注意力的特征,可以激活更多的像素,从而增加图像超分辨率的性能。通过广泛的实验,验证了所提出模块的有效性, HAT 在多个基准测试中显著优于此前现有的最先进方法。其网络结构如图 2-5 所示。

2.3.1.4 ACT


 图 2-6 ACT 网络结构图^[44]

Yoo 等人提出的 ACT^[44]方法采用了 CNNs 和 Vision Transformer (ViTs)^[45]相结合的混合架构, 实现了此前最先进的超分辨率结果。这种架构有效地利用了 CNNs 的局部特征和 ViTs 捕获的长距离依赖的特征。引入的跨尺度令牌注意力 (cross-scale token attention, CSTA) 模块, 允许有效地利用不同尺度间令牌(tokens) 之间的信息关系, 增强了模型重构高质量图像的能力。ACT 框架在基准数据集上展示了显著的改进, 超越了此前现有方法, 并展示了整合 CNN 和 Transformer 特征对于图像超分辨率任务的好处。其网络结构如图 2-6 所示。

2.3.1.5 Restormer


 图 2-7 Restormer 网络结构图^[33]

Zamir 等人提出的 Restormer^[33]是一种高效的 Transformer 模型, 专为图像恢复任务设计。通过引入多尺度的层次架构和多 Dconv 头反向注意力 (multi-dconv head ‘transposed’ attention, MDTA) 使得 Restormer 能够处理大图像的同时保持计算效率。这些技术改进使 Restormer 在包括去雨、去模糊及去噪等多个图像恢复任务上取得了此前最先进的结果。此外, 文章还展示了 Restormer 在不同基准数据集上的卓越性能, 并通过广泛的消融实验验证了其架构设计的有效性。其网络结构如图 2-7 所示。

2.3.1.5 EDT




图 2-8 EDT 网络结构图^[46]

Li 等人提出的 EDT^[46]是一种基于编解码器的低级视觉网络，该论文研究了多种低级视觉任务(超分辨率，去噪声和图像去雨)在该模型使用预训练技术的效果。本文发现预训练在低级任务中起到的作用截然不同。例如，在超分辨率(SR)任务中，预训练将更多的局部信息引入到更高的层中，从而显著提升性能，而在去噪任务中，预训练几乎不影响内部特征表示，导致改进有限。。此外，本文的 EDT 架构结合了编码器—解码器架构和 Transformer 模型的优势，在多个低级视觉任务中取得了显著的性能改进。

2.3.1.6 Uformer




图 2-9 Uformer 网络结构图^[47]

Wang^[47]等人提出的 Uformer 是一个基于 Transformer 的高效图像恢复网络，该网络具有分层的编解码器架构和创新的局部增强窗口 Transformer 块，通过非重叠的窗口自注意力显著降低计算复杂度，并引入了一个可学习的多尺度修复调制器来调整解码器的多层特征，从而在各种图像修复任务中实现了优越的细节恢复能力，刷新了多个图像恢复数据集上的最先进性能。

2.3.2 常用的数据集

在超分辨率图像重建的研究领域中，为了训练高效且准确的模型，研究者们通常会采用一些标准的数据集。其中，DIV2K^[48]和 Flickr2K^[49]是两个被广泛使用的训练集。DIV2K 数据集含有 1000 张高质量的图像，这些图像的分辨率非常高，通常取前 800 张用来作为训练集数据。Flickr2K 则包含 2650 张图像，这些图像包含的细节和内容比 DIV2K 更加丰富，有助于进一步提升模型的泛化能力。

在评估超分辨率模型的性能时，研究者们通常会使用特定的测试集来进行验证。Set5^[50]、Set14^[51]、BSD100^[52]、Urban100^[53]和 Manga109^[54]是当前最为常见的测试集。Set5 包含了 5 张不同场景的图像，而 Set14 则包含了 14 张图像，这两个测试集虽然相对较小，但被广泛用于快速评估模型性能。BSD100 是从 Berkeley Segmentation Dataset 中精选出来的 100 张图像，这些图像在自然场景中具有代表性。Urban100 包含了 100 张城市建筑物的高分辨率图像，这些图像往往包含大量的细节和直线结构，对超分辨率算法是一个挑战。Manga109 则是一个包含了 109 本不同风格漫画书中的图像的数据集，其特点是线条清晰、对比度高，非常适合用来测试模型在处理线条和纹理上的能力。

2.3.3 常用的损失函数

在超分辨率领域，损失函数是评估模型输出与真实图像差异的关键指标。三种常用的损失函数包括 L1 损失、L2 损失和感知损失。本小结分别介绍这三个损失函数：

L1 损失函数：也称为平均绝对误差(Mean Absolute Error, MAE)，是预测值与真实值之差的绝对值的平均。在超分辨率重建中，L1 损失有助于减少重建图像与真实图像之间的平均像素误差，通常能够得到较为平滑的重建结果。L1 损失的计算公式如式(2-8)所示：

$$f(x) = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i| \quad (2-10)$$

上式中， N 表示输入图像像素点的数量， y_i 表示输入图像， $\hat{y}_i$ 表示生成图像。

L2 损失函数：也称为均方误差(Mean Squared Error, MSE)，是预测值与真实值之差的平方的平均。在超分辨率领域，L2 损失有助于惩罚较大的误差，使模型更加关注于减少大的预测误差，常常能够获得较高的峰值信噪比(PSNR)性能。L2 损失的计算公式如式(2-9)所示：

$$f(x) = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \quad (2-11)$$

感知损失^[28]：与 L1 和 L2 损失不同，感知损失是基于图像的高级特征而非像素级差异来计算的。它通过预训练的深度神经网络(如 VGG 网络)来提取图像的特征表示，然后计算重建图像与真实图像在这些特征表示上的差异。感知损失有助于重建图像在视觉上更加逼真，保留更多的纹理和细节信息。感知损失的计算公式如式(2-10)所示：

$$f(x) = \frac{1}{N} \sum_{i=1}^N \|\phi(y_i) - \phi(\hat{y}_i)\| \quad (2-12)$$

其中， $\phi(\cdot)$ 表示通过某个预训练的深度神经网络(例如 VGG 网络)提取的特征表示函数。

2.3.4 常用的评价指标

常用的评估超分辨率图像生成质量的客观指标包括峰值信噪比(Peak Signal-to-Noise Ratio, PSNR)^[55]、结构相似性指数(Structural Similarity Index Measure, SSIM)^[55]、学习感知图像块相似度(Learned Perceptual Image Patch Similarity, LPIPS)^[56]和无参考图像质量评估指标(Natural Image Quality Evaluator, NIQE)^[57]。这些指标各自从不同的角度评估图像恢复的质量。本小结分别介绍这四个指标：

PSNR 是最常用的评价指标之一，用于衡量重建图像和原始高分辨率图像之间的相似度。它基于整体像素的误差计算，通过比较两幅图像的均方误差(MSE)来计算。PSNR 值越高，表示图像质量越好。尽管 PSNR 是一个流行的度量，但它并不总能很好地反映人眼对图像质量的感知，因为它主要关注像素级的差异，而忽略了图像的视觉结构和内容。PSNR 的计算公式如式(2-11)：

$$PSNR = 10 \cdot \log_{10} \left(\frac{MAX_I^2}{MSE} \right) \quad (2-13)$$

其中： MAX_I 表示图像可能的最大像素值(例如，对于 8 位图像 $MAX_I = 255$)。

MSE 表示均方误差，其计算公式如式(2-12)所示：

$$MSE = \frac{1}{mn} \sum_{i=1}^m \sum_{j=1}^n (I(i, j) - K(i, j))^2 \quad (2-14)$$

其中 $I(i, j)$ 是原始图像在位置 (i, j) 的像素值， $K(i, j)$ 是重建图像在位置 (i, j) 的像素值， m 和 n 分别是图像的行数和列数。

SSIM 是一种更加先进的评价指标，用于衡量两幅图像在视觉结构、亮度和对比度方面的相似性。与 PSNR 不同，SSIM 考虑了图像的视觉感知特性，更能准确反映人类对图像质量的评价。SSIM 的值范围从 -1 到 1，1 表示两幅图像完全相同。SSIM 通常被认为比 PSNR 更能准确地评估图像质量，尤其是在视觉相

似性方面。其计算公式如式(2-13)：

$$\text{SSIM}(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (2-15)$$

其中 μ_x 和 μ_y 分别是图像 x 和 y 的平均宽度； σ_x^2 和 σ_y^2 分别是图像 x 和 y 的方差； σ_{xy} 是图像 x 和 y 的协方差； C_1 和 C_2 是为了避免分母为零而加入的小常数。

LPIPS 是一个相对较新的评价指标，用于衡量图像之间的感知相似性。它使用深度学习模型来评估图像质量，通过比较图像在特征层面上的差异来计算分数。LPIPS 尤其关注图像的感知质量，而不仅仅是像素级的差异。因此，它通常能更准确地反映出图像质量的感知差异，尤其是在超分辨率等复杂图像处理任务中。

LPIPS 计算的具体形式依赖于所使用的深度学习模型，因此没有一个固定的公式。不过，其基本思想是比较图像在深度网络的某些层的特征表示之间的差异如式(2-14)所示：

$$\text{LPIPS}(x, y) = \sum_l \frac{1}{H_l W_l} \sum_{h=1}^{H_l} \sum_{w=1}^{W_l} \|\phi_l(x)_{hw} - \phi_l(y)_{hw}\|^2 \quad (2-16)$$

其中： $\phi_l(x)$ 和 $\phi_l(y)$ 分别表示图像 x 和 y 的在深度网络中第 l 层的特征表示。 H_l 和 W_l 分别表示第 l 层特征表示的高度和宽度。 h 和 w 是特征表示中的位置索引。 $\|\cdot\|^2$ 表示欧几里得距离的平方。

NIQE 是一种无参考图像质量评估指标，用于评估图像的视觉质量，而不需要任何参考图像。它是基于从自然无失真图像中提取的统计特性来预测图像质量的。NIQE 的核心思想是，自然图像的统计特性可以被特定的模型捕获，而失真的图像会在这些统计特性上表现出显著的偏差。NIQE 的计算可以分为以下几个步骤：

- (1) 特征提取：首先，从图像中提取一组特征，这些特征反映了图像的自然性。这通常涉及到从图像的局部区域中提取特定的统计量。
- (2) 模型构建：基于从一组无失真自然图像中提取的特征，构建一个模型来捕获这些图像的统计特性。这个模型通常以高斯混合模型(Gaussian Mixture Model, GMM)的形式出现。
- (3) 质量评估：对于待评估的图像，同样提取特征，并计算这些特征与模型之间的距离。这个距离用于表示图像质量，距离越小，则表示图像的质量越高。

NIQE 的具体公式如下：

$$\text{NIQE}(X) = \sqrt{(\bar{x} - \bar{\mu})^T \Sigma^{-1} (\bar{x} - \bar{\mu})} \quad (2-17)$$

其中， X 是待评估的图像， $\bar{x}$ 是从图像 X 中提取的特征向量， $\bar{\mu}$ 是从一组训练图

像中提取的特征向量的均值， Σ 是协方差矩阵。NIQE 分数越低则表示图像质量越好。

NIQE 作为一种无参考质量评估方法，在实际应用中有着广泛的应用，尤其是在没有理想参考图像可用的情况下。NIQE 广泛应用于图像处理、视频处理等领域，用于在无参照的情况下评估图像或视频的视觉质量。

2.3.5 LAM 分析




图 2-10 LAM 图示例^[58]

局部属性图(Local Attribution Map, LAM)是 Gu 等人^[58]提出的一种寻找对超分辨率结果产生强烈影响的输入像素的方法，最初用于对超分辨率模型进行解释。后来在 HAT^[43]中用于解释提出的模型能够有效激活更多的像素，从而增强了超分辨率模型的性能。在 LAM 中使用模糊图像作为基准输入和采用逐渐模糊的函数作为路径函数，LAM 方法能够对超分辨率网络进行归因分析。通过 LAM 方法，研究人员观察到：(1)参与超分辨率过程的像素范围对最终的超分辨率性能具有显著影响，具有更广泛像素范围的超分辨率网络可以实现更好的性能；(2)自注意力和非局部机制，尤其是能够进行长距离建模的模型，可以帮助超分辨率网络从更广泛的输入像素中提取特征；(3)对于大多数深度学习的网络来说，感受野大多已经足够大(4)对于现有的超分辨率网络，具有规则条纹或网格纹理的图像更容易被提取，但复杂的语义难以被提取和利用。该研究为超分辨率网络的设计和解释低级视觉深度学习模型开辟了新的方向，并对超分辨率的研究具有实践上的

益处。

2.4 本章小结

本章介绍了图像超分辨率技术中卷积神经网络(CNN)和 Transformer 网络的关键原理与应用,展示了它们在图像恢复领域的强大能力。本章深入分析了 CNN 的基础组件和 Transformer 网络的自注意力机制,展示了它们如何有效地提取图像特征以及通过网络架构创新显著提高图像超分辨率的性能。此外,还介绍了相关的数据集、损失函数和评价指标,为深入理解和进一步研究图像超分辨率领域提供了全面的视角。

第3章 基于轴向自注意力的单图像超分辨率网络算法的研究

3.1 引言

单图像超分辨率是一项基本的视觉任务,该任务旨在从已知的低分辨率图像中恢复其对应的高分辨率的图像。超分辨率任务目前被广泛应用于视频监控^[5],遥感医学^[4]成像等多个领域。然而单图像超分辨率是一个逆病态问题(Ill-Posed Problem),因为一个低分辨率图像可以对应多种高分辨率图像,所以需要假设图像的退化过程等先验知识。

早期图像的超分辨率的研究大多是基于卷积网络的架构,如 SRCNN^[11],EDSR^[38],VDSR^[26],RCAN^[12]等模型在超分辨率领域都达到了相对不错的性能。卷积神经网络在学习局部信息时具有很强的泛化性能,但是由于卷积层本身的性质,卷积神经网络在处理图像中长距离的像素信息时会相对较弱。针对这一问题,基于视觉 Transformer^[46]的有关模型出现并在一定程度上解决长距离信息丢失的问题。Transformer 通过自注意力机制在图像上获取全局信息并在许多视觉问题上达到了不错的效果。但 Transformer 在计算注意力时会出现计算量过大的问题,如 ViT^[45]和 IPT^[23]等网络采用的是全局自注意力(Global Attention)的方案,即计算自注意力的区域是整个输入图像,其自注意力的计算量与输入的图像尺寸成二次方关系,计算量过大,进而限制了模型应用的推广。为了克服上述提到的全局 Transformer 模型计算量过大的问题,基于局部的自注意力计算(Local Attention)的网络如 Swin Transformer^[29]、SwinIR^[24]以及 Uformer^[47]等网络通过将图像划分为若干个窗口,然后在每个窗口中计算自注意力。然而,这些方法虽然采用局部的自注意力计算方案来降低网络的计算量,但这些网络由于切分窗口导致图像的特征被破坏,导致网络因为丢失了这些特征进而影响其性能。为了缓解上述问题, Swin Transformer 在计算自注意力时通过滑动窗口(Shifted Windows)操作,使得输入的不同窗口之间能够建立联系,进而补充由于被划分窗口丢失的部分特征信息从而提升网络的性能。Focal Self-attention^[59]和 Swin Transformer 一样也是局部自注意力计算,但与 Swin Transformer 不同的是, Focal Self-attention 根据池化层下采样的系数将输入的特征划分成不同的等级,下采样系数越大则对应的划分粒度也越粗。Focal Self-attention 在计算的时候对这些不同粒度的输入特征进行融合然后通过自注意力对输入的特征进行计算。虽然这些方法在一定程度上缓解了局部自注意力由于窗口划分导致的信息丢失的问题,但窗口划分这一




图 3-1 IPT、SwinIR 和 AASR 感受野比较

操作本身破坏了自注意力的长距离建模的特性，从而限制了 Transformer 网络在超分辨率上的应用。

所以综上所述，全局自注意力网络相对局部自注意力网络会产生大量的计算量，而局部自注意力网络相对于全局自注意力网络表达能力较弱，为了能够在网络的性能和表达能力之间寻求平衡，本文受 CSwin Transformer^[31]的启发，采用基于轴向自注意力方案^[60]，如图 1 所示。AASR 将输入的特征按水平和垂直两个方向切割成等宽的条纹，然后在等宽的条纹中计算自注意力，最后再将两个方向计算的注意力特征进行融合，从而得到经过自注意力计算之后的特征。从图 3-1 我们可以看出，AASR，具备以下两个优势：1)与全局自注意力相比，我们的网络并不是将整个输入图像作为特征计算自注意力的，它会将输入的特征切割成若干个等宽的矩形条纹，然后在这个矩形条纹中计算自注意力，这样做的好处在于，它避免了进行全局自注意力计算，从而减少了大量的计算量。2)与局部自注意力相比，轴向自注意力提供了比局部自注意力更大的感受野，局部自注意力通常采用的是将输入切割成等大小的矩形区域的方法。无论在水平方向还是垂直方向上都对图像的特征进行了切割，并且在计算自注意力时，每个矩形条纹保留了图像水平方向或垂直方向的图像特征，这样能够缓解由于切割造成图像特征丢失的问题，相对于局部的自注意力计算，AASR 拥有更强的表达能力。

受最近的工作 Restormer^[33]的启发，我们改进了 Transformer 块的结构。将 Transformer 块中的多层感知机网络改进成一种基于卷积的 Gated-Dconv 前馈结构，采用这种结构能够进一步增强网络的表达能力，该结构能够激活输入图像更多的像素，进而增加网络的表达能力。我们通过最近的 LAM 分析法^[58]分析可知。SwinIR 激活得到的像素点有限，从图 3-2 中我们可以看到，使用 SwinIR 生成的 SR 图像得到的 DI 值仅有 12.55。而应用我们的轴向自注意力计算得到的图像可以激活更多的像素，可以使 DI 值增长至 29.64。但仅仅使用轴向自注意力的模型表达能力有限，从图 3-2 的 AASR w/o 中的结果可以看出，MLP 的表达能力有限，所以能够激活的像素点也是有限的，最终导致图像的恢复受到了限制。因此，为了进一步提升图像的恢复效果，我们引入的 GDFN 前馈层能够激活更多的像




图 3-2 在 Urban100 img_012 上的 LAM 分析结果

素点。如图 3-2 中所示，在 AASR 中的结果表明，通过使用 GDFN，模型的 DI 值能显著提升至 30.33，这表明我们的 GDFN 层可以激活更多的像素，进而增强模型的表达能力，从而得到更好的恢复效果。此外，我们的网络与 Restormer 不同的是 Restormer 采用的是一种线性的自注意力的计算，这种线性的自注意力与前文提到的自注意力不同的是：前文提到的自注意力都是在空间维度进行自注意力的计算，而 Restormer 是在通道维度上进行自注意力的计算。这种计算的好处是能够使网络的计算量与输入的特征的尺寸成线性的复杂度，但这种基于通道维度的自注意力的计算的表达能力相对于空间维度的自注意力计算来说会更弱，所以这类模型往往需要比基于空间维度的自注意力更多的参数量，如 Uformer 采用的是基于空间维度的自注意力计算，而与 Uformer 采用同样架构的 Restormer(两个网络都是基于 U-Net^[61]架构)的参数量比 Uformer 高约 22.7 % (真实场景下图像去噪实验中 Uformer-S 参数量为 20.63M 而 Restormer 的参数量为 25.31M)。此外，Restormer 对通道空间的建模依赖可能会牺牲一些有用的纹理和结构的空信息，这对恢复高分辨率图像是不利的^[62]。基于以上原因，我们的 AASR 不像 Restormer 采用基于通道的自注意力计算而是采用基于空间的自注意力计算以保证模型的表达能力。

我们工作的主要贡献包括：(1)采用基于轴向自注意力模型来设计并构建




图 3-3 AASR 网络架构图

超分辨率模型。(2)我们提出了一种残差的轴向自注意力块(Residual Axial Self-Attention Block, RASAB), 并采用 Gated-Dconv 前馈结构来进一步增强模型的表达能力。(3)使用上述提到的 RASAB 构建我们的超分辨率模型—AASR, 我们在超分辨率的多个数据集上进行测试, 均表现出优于同类网络的水平。

3.2 算法总体设计

3.2.1 AASR 网络架构

AASR 的架构如图 3-3 a)所示, 本模型先经过浅层特征提取层提取图像的浅层特征, 再经过若干个 RASAB 块进一步提取图像的深层特征, 然后将提取到的浅层特征和深层特征进行加和再经过一个上采样层进行特征融合和上采样, 最后得到复原的超分辨图像。整体的流程如下:

假定输入的低分辨率图像为 I_{LR} , I_{LR} 首先通过一个 3×3 的卷积层提取浅层特征, 如公式(3-1)所示:

$$F_0 = \text{Conv}_{3 \times 3}(I_{LR}) \quad (3-1)$$

$\text{Conv}_{3 \times 3}(\cdot)$ 是卷积核大小为 3×3 的卷积层, F_0 是其输出的特征信息。 F_0 再经过若干个 RASAB 块进行深层特征提取, 其过程如公式(3-2)所示:

$$F_n = \text{RASAB}_n(F_{n-1}), n = 1, 2, \dots \quad (3-2)$$

RASAB_n 是第 n 个 RASAB 块函数, F_{n-1} 是输入至 RASAB 块的特征, F_n 是 RASAB 块输出的特征。经过多个 RASAB 块处理之后, 将与浅层特征提取的特征求和并进行特征融合和上采样处理。这里特征融合使用的是一个卷积核大小为 3×3 的卷

积层，上采样是通过亚像素卷积^[63]实现的，其过程如公式(3-3)和公式(3-4)所示：

$$F = F_0 + F_n \quad (3-3)$$

$$I_{SR} = \text{Conv}_{3 \times 3}(\text{PixelShuffle}(F)) \quad (3-4)$$

F 是浅层特征与深层特征的残差连接之和， $\text{PixelShuffle}(\cdot)$ 是亚像素卷积层， I_{SR} 是最终输出的超分辨率图像。

3.2.2 残差的轴向自注意力块(RASAB)

如图 3-3 b)所示，RASAB 是本文的一个重要的模块，该模块通过多个轴向自注意力计算块(Axial Self-Attention Block, ASAB)来进行深层的特征提取，然后将提取的深层特征通过卷积进行融合，最后与输入到 RASAB 的特征进行直接求和，其过程如公式(3-5)和公式(3-6)所示：

$$H_m = \text{ASAB}_m(H_{m-1}), m = 1, 2, \dots \quad (3-5)$$

$$H = \text{Conv}_{3 \times 3}(H_m) + H_0 \quad (3-6)$$

ASAB_m 是第 m 个 ASAB 块， H_{m-1} 是输入至 ASAB 块的特征，经过多个 ASAB 块处理之后将输出的特征 H_m 输入到 3×3 的卷积层中，然后再与输入至 RASAB 的原始特征 H_0 求和得到 RASAB 块最终的输出。

3.2.3 轴向自注意力计算块(ASAB)

ASAB 的基本结构如图 3-3 c)所示，整个 ASAB 的工作流程如公式(3-7)和公式(3-8)所示：

$$X' = X + \text{ASAL}(\text{LN}(X)) \quad (3-7)$$

$$X = X' + \text{GDFN}(\text{LN}(X')) \quad (3-8)$$

假设输入到 ASAB 块的特征为 X ， $\text{LN}(\cdot)$ 是层归一化； $\text{ASAL}(\cdot)$ 是轴向自注意力计算层(Axial Self-Attention Layer, ASAL)； $\text{GDFN}(\cdot)$ 是基于卷积的 Gated-Dconv 前馈结构层(GDFN)。首先该特征 X 先经过层归一化 $\text{LN}(\cdot)$ 处理，之后将处理得到的特征再经过 $\text{ASAL}(\cdot)$ 进行计算，将计算输出的结果与输入特征 X 求和得到新的特征 X' 。之后再将该特征 X' 进行层归一化，然后经由 $\text{GDFN}(\cdot)$ 处理，再把处理得到的特征与 X' 相加求和得到 ASAB 最终的输出。

3.2.4 轴向自注意力计算层(ASAL)




图 3-4 轴向自注意力计算层(ASAL)计算过程

ASAL 的计算过程大致如图 3-4 所示。假设输入特征的尺寸为 $H \times W \times C$ ，即 $X \in \mathbb{R}^{(H \times W) \times C}$ ，根据多头自注意力的机制，我们首先将输入特征映射至 K 个头上，然后将这 K 个头分成两组，一组执行水平方向的自注意力，另一组执行垂直方向的自注意力。

对于前 K 组在水平方向上的自注意力的计算过程如公式(3-9)、公式(3-10)和公式(3-11)所示：

$$X_H = [X_H^1, X_H^2, \dots, X_H^M], X_H^i \in \mathbb{R}^{(S_w \times W) \times C/2}, M = H / S_w \quad (3-9)$$

$$Y_k^i = \text{Attention}(X_H^i W_k^Q, X_H^i W_k^K, X_H^i W_k^V), i = 1, \dots, M \quad (3-10)$$

$$H - \text{Attn}_k(X) = [Y_k^1, Y_k^2, \dots, Y_k^M] \quad (3-11)$$

其中 X_H^i 表示切割的水平条纹(切割的条纹互不重叠，如若不能均匀切割则在特征图周围进行零填充以保证可以均匀切割)，其大小为 $S_w \times W$ ， $[\cdot]$ 表示通道拼接的操作， $\text{Attention}(\cdot)$ 表示自注意力的计算， $H - \text{Attn}(\cdot)$ 表示第 K 个头的输入特征在水平方向的自注意力计算函数。 $W_k^Q, W_k^K, W_k^V \in \mathbb{R}^{(C/2) \times C/(2 \cdot k)}$ 分别表示 Q, K, V 在第 k 个头上的参数矩阵。后续的 K 组在执行垂直方向上的自注意力计算时，其过程与前 K 组类似。不同之处在于，其垂直切割的条纹大小为 $H \times S_w$ 。我们用 $V - \text{Attn}_k(\cdot)$ 表示第 K 个头的输入特征在垂直方向的自注意力计算函数。综上所述，整个 ASAL 的输出如公式(3-12)所示：

$$\text{ASAL}(X) = [\text{head}_1, \text{head}_2, \dots, \text{head}_k] \cdot W^O \quad (3-12)$$

其中 $head_i$ 为:

$$head_i = \begin{cases} H - Attn_k(X) & k = 1, \dots, K/2 \\ V - Attn_k(X) & k = K+1, \dots, K \end{cases} \quad (3-13)$$

最后,为了能够在自注意力的计算中引入位置信息,我们和 CSwin Transformer 一样采用局部增强位置编码(Locally-Enhanced Positional Encoding, LePE)。整个 ASAL 的输出如公式(3-14)所示:

$$Attention(Q, K, V) = softmax\left(\frac{Q \cdot K^T}{\sqrt{d}}\right) \cdot V + LePE(V) \quad (3-14)$$

其中局部增强位置编码如公式(3-15)所示:

$$LePE(V) = D - Conv_{3 \times 3}(V) \quad (3-15)$$

上述公式中, Q, K, V 为输入的查询, 键和值, d 与 Q, K, V 通道维度相同, $LePE(\cdot)$ 是位置编码函数, $D - Conv_{3 \times 3}(\cdot)$ 使用的是卷积核大小为 3×3 通道可分离卷积, 我们使用通道可分离卷积提取的特征作为自注意力的位置信息, 这样可以提升网络的表达能力。

3.2.5 基于卷积的 Gated-Dconv 前馈结构层(GDFN)




图 3-5 GDFN 结构图

为了能够增强 AASR 的表达能力,我们把传统 Transformer 块中的多层感知机(MLP)改为了基于卷积的 Gated-Dconv 前馈结构层(GDFN), GDFN 的计算过程如公式(3-16)所示:

$$X_1 = D - Conv_{3 \times 3}(X) \quad (3-16)$$

$$X_2 = \sigma(D - Conv_{3 \times 3}(X)) \quad (3-17)$$

$$X = \text{Conv}_{1 \times 1}(X_1 \odot X_2) \quad (3-18)$$

其中 X 是输入特征, $\text{Conv}_{1 \times 1}(\cdot)$ 是卷积核大小为 1×1 的卷积层, $\sigma(\cdot)$ 是非线性激活函数, 这里用的是 GELU 函数^[64]。该模块分成两个分支: 第一个分支首先将输入的特征 X 经过一个卷积核大小为 3×3 的深度可分离卷积层, 再经过一个卷积核大小为 1×1 的普通卷积层, 最后得到输出特征 X_1 ; 而第二个分支相对第一个分支, 在最后 1×1 卷积层的基础上又多了个非线性激活函数操作, 第二个输出的特征为 X_2 。然后将输出的两个特征 X_1 和 X_2 进行逐元素求积操作(对应公式(3-18)的 $\odot$ 符号), 得到最终 GDFN 的输出结果。

3.3 实验与分析

3.3.1 实验设置

我们采用 DIV2K 数据集中的 001-800 作为我们的训练集, 801-805 作为我们的测试集(后面简称为 DIV2K_5)。此外, 我们还采用了五个广泛使用的超分辨率测试集 Set5^[50]、Set14^[51]、BSD100^[52]、Urban100^[53]和 Manga109^[54]来评估我们模型的性能。为了公平的比较, 我们测试 PSNR 和 SSIM 在图像 YCbCr 空间^[11]中 Y 通道上结果的作为评估的指标。训练时的 batchsize 大小为 32, 最终输出的 HR 图形尺寸固定为 128×128 。我们使用 Adam 优化器^[65]进行参数优化, 其中初始学习率为 2×10^{-4} , betas 参数范围是 0.9 到 0.999。总共训练 1000000 次迭代, 按 50000, 800000, 900000, 1000000 进行一次学习率折半。本实验在单块 NVIDIA 3080Ti 上进行。

在超参数选择上, 我们将基础模型中的 RASAB 块数量设为 4, ASAB 块数设为 6, ASAL 中的切割宽度 S_w 参数设为 3, 模型的中间特征通道数 C 设为 60, 多头自注意力的头数设为 6。其余参数配置与 SwinIR 一样。后续的消融实验均在 $\times 4$ 超分辨率条件下进行。

3.3.2 消融实验

3.3.2.1 切割宽度 S_w 对网络的影响

为了验证切割宽度 S_w 对网络的影响, 我们通过不断调整切割宽度 S_w 的大小来观察网络在不同数据集上 PSNR 的性能、时间和参数量的影响。从表 3-1 的实

表 3-1 不同 S_w 设置下网络在各数据集上的 PSNR、运行时间和参数量比较

S_w	Set5	Set14	B100	Urban100	Manga109	DIV2K_5	Time(s)	Params(M)
$S_w=1$	32.48	28.76	27.67	26.47	31.00	33.98	0.30	1.14
$S_w=2$	32.58	28.78	27.68	26.54	31.06	34.01	0.33	1.14
$S_w=3$	32.65	28.87	27.73	26.67	31.22	34.06	0.37	1.14
$S_w=4$	32.67	28.89	27.74	26.72	31.30	34.08	0.41	1.14

验结果可以看出,随着 S_w 的增大,网络的 PSNR 不断提高,这意味网络的表达能力会随着切割宽度 S_w 的提高而增强,但其推理时间也会随之加长。为了平衡模型的表达能力与推理时间,我们将模型的默认切割宽度 S_w 设为 3。

3.3.2.2 RASAB 块对网络的影响

表 3-2 不同 RASAB 块数对各数据集上 PSNR、运行时间和参数量的影响

RASAB 块数	Set5	Set14	B100	Urban100	Manga109	DIV2K_5	Time(s)	Params(M)
1	32.20	28.56	27.55	26.01	30.38	33.77	0.24s	0.33
2	32.40	28.72	27.64	26.35	30.82	33.92	0.29s	0.60
3	32.45	28.75	27.65	26.45	30.90	33.96	0.33s	0.87
4	32.65	28.87	27.73	26.67	31.22	34.06	0.37s	1.14

在本节的实验中,我们验证 RASAB 块对网络的影响。从表 3-2 的结果可以看出随着 RASAB 块数量的增加,网络的表达能力也随之变强。但与此相对应的代价就是网络的推理时间和参数量也会随之增大。这说明我们模型中的 RASAB 块能够有效的提取图像的深层特征,并且随州块数的增多,模型的表达能力也会增强,说明 RASAB 块对模型的表达能力起到重要的作用。为了平衡模型的表达能力与计算量和参数量,我们将模型默认的 RASAB 块数设为 4。

3.3.2.3 每个 RASAB 块中的 ASAB 层对网络的影响

表 3-3 不同 AAB 层在不同数据集上 PSNR、时间和参数数量的结果

ASAB 块数	Set5	Set14	B100	Urban100	Manga109	DIV2K_5	Time(s)	Params(M)
2	32.38	28.66	27.62	26.29	30.72	33.86	0.26	0.51
4	32.49	28.77	27.67	26.52	31.00	33.95	0.31	0.82
6	32.65	28.87	27.73	26.67	31.22	34.06	0.37	1.14
8	32.65	28.88	27.73	26.70	31.28	34.09	0.43	1.46

为了进一步探究 RASAB 块内 ASAB 数量对网络的影响,我们不断调整每个 RASAB 块内 ASAB 的数量来进一步验证网络的表达能力。从表 3-3 的实验结果可以看出,随着每个 RASAB 块内的 ASAB 数量的增加,网络的表达能力也越来越强,但模型的推理时间与参数量也随之变大。这进一步说明 ASAL 的计算是有效的,能够有效的利用轴向自注意力机制来对超分辨率任务的建模产生积极的影响。为了平衡模型的表达能力与推理时间和参数量,我们默认将 RASAB 块内 ASAB 的数量设为 6。

3.3.2.4 GDFN 对网络的影响

表 3-4 MLP 和 GDFN 在不同数据集上 PSNR、时间和参数数量的结果

	Set5	Set14	B100	Urban100	Manga109	DIV2K_5	Time(s)	Params(M)
MLP	32.55	28.78	27.68	26.54	30.93	33.93	0.35	0.91
GDFN	32.65	28.87	27.73	26.67	31.22	34.06	0.37	1.14

在前文中,我们提到了一项关键改进:将 ASAL 计算中的多层感知机(MLP)替换为基于卷积的 Gated-Dconv 前馈结构层(GDFN),这一改进的动机在于,传统的 MLP 因其有限的表达能力而制约了网络整体的性能表现。从表 3-4 的实验结果可以看出,与使用 MLP 相比,使用 GDFN 作为 Transformer 块的前馈层,能够有效增强网络的表达能力,其中在 Manga109 数据集上有 0.29dB 的 PSNR 的提升。这说明 GDFN 能够有效提升 ASAL 的表达能力。

3.3.3 实验结果分析

3.3.3.1 客观评价指标

表 3-5 各种先进 SISR 方法在 $\times 2$ 放大倍数下的平均 PSNR 和参数量结果

放大倍数	模型	参数量	Set5	Set14	B100	Urban100	Manga109
$\times 2$	SRCNN	57K	36.66	32.42	31.36	29.50	35.74
	FSRCNN	12K	37.00	32.63	31.53	29.88	36.67
	VDSR	665K	37.53	33.03	31.90	30.76	37.22
	DRCN	1774K	37.63	33.04	31.85	30.75	37.63
	LapSRN	813K	37.52	33.08	31.80	30.41	37.27
	DRRN	297K	37.74	33.23	32.05	31.23	37.92
	MemNet	677K	37.78	33.28	32.08	31.31	37.72
	SRMDNF	1513K	37.79	33.32	32.05	31.33	38.07
	CARN	1592K	37.76	33.52	32.09	31.92	38.36
	IMDN	694K	38.00	33.63	32.19	32.17	38.88
	LAPAR-A	548K	38.01	33.62	32.19	32.10	38.67
	RFDN	534K	38.05	33.68	32.16	32.12	38.88
	A ² F-M	999K	38.04	33.67	32.18	32.27	38.87
	ACAN	800K	38.10	33.60	32.21	32.29	38.81
	LatticeNet	756K	38.06	33.70	32.20	32.25	38.94
	AWSRN-M	1063K	38.04	33.66	32.21	32.23	38.66
	MAFFSRN-L	790K	38.07	33.59	32.23	32.38	-/-
	SwinIR	878K	<u>38.14</u>	<u>33.86</u>	32.31	<u>32.76</u>	<u>39.12</u>
	AASR(ours)	1119K	38.22	34.04	<u>32.28</u>	32.96	39.36

表 3-6 各种先进 SISR 方法在 $\times 3$ 放大倍数下的平均 PSNR 和参数量结果

放大倍数	模型	参数量	Set5	Set14	B100	Urban100	Manga109
$\times 3$	SRCNN	57K	32.75	29.28	28.41	26.24	30.59
	FSRCNN	12K	33.16	29.43	28.53	26.43	30.98
	VDSR	665K	33.66	29.77	28.82	27.14	32.01
	DRCN	1774K	33.82	29.76	28.80	27.15	32.31
	DRRN	297K	34.03	29.96	28.95	27.53	32.74
	MemNet	677K	34.09	30.00	28.96	27.56	32.51
	SRMDNF	1530K	34.12	30.04	28.97	27.57	33.00
	CARN	1592K	34.29	30.29	29.06	27.38	33.50
	IMDN	703K	34.36	30.32	29.09	28.17	33.61

表 3-6(续表)

放大倍数	模型	参数量	Set5	Set14	B100	Urban100	Manga109
×3	LAPAR-A	594K	34.36	30.34	29.11	28.15	33.51
	RFDN	541K	34.41	30.34	29.09	28.21	33.67
	A ² F-M	1003K	34.50	30.39	29.11	28.28	33.66
	ACAN	1115K	34.46	30.39	29.11	28.28	33.61
	LatticeNet	765K	34.40	30.32	29.10	28.19	33.63
	AWSRN-M	1143K	34.42	30.32	29.13	28.26	33.64
	MAFFSRN-L	807K	34.45	30.40	29.13	28.26	-/-
	EMASRN	437K	34.36	30.30	29.05	28.04	33.43
	SwinIR	886K	<u>34.62</u>	<u>30.54</u>	<u>29.20</u>	<u>28.66</u>	<u>33.98</u>
	AASR(ours)	1128K	34.78	30.62	29.29	28.99	34.43

表 3-7 各种先进 SISR 方法在×4 放大倍数下的平均 PSNR 和参数量结果

放大倍数	模型	参数量	Set5	Set14	B100	Urban100	Manga109
×4	SRCNN	57K	30.48	27.49	26.90	24.52	27.66
	FSRCNN	12K	30.71	27.59	26.98	24.62	27.90
	VDSR	665K	31.35	28.01	27.29	25.18	28.83
	DRCN	1774K	31.53	28.02	27.23	25.14	28.98
	LapSRN	813K	31.54	28.19	27.32	25.21	29.09
	DRRN	1774K	31.53	28.02	27.23	25.14	28.98
	MemNet	677K	31.74	28.26	27.40	25.50	29.42
	SRMDNF	1555K	31.96	28.35	27.49	25.68	30.09
	CARN	1592K	32.13	28.60	27.58	26.07	30.47
	IMDN	715K	32.21	28.58	27.56	26.04	30.45
	LAPAR-A	659K	32.15	28.61	27.61	26.14	30.42
	RFDN	550K	32.24	28.61	27.57	26.11	30.58
	A ² F-M	1010K	32.28	28.62	27.58	26.17	30.57
	ACAN	1556K	32.24	28.62	27.59	26.17	30.53
	LatticeNet	777K	32.18	28.61	27.57	26.14	30.54
	AWSRN-M	1254K	32.21	28.65	27.60	26.15	30.56
	MAFFSRN-L	830K	32.20	28.62	27.59	26.16	30.33

表 3-7(续表)

放大倍数	模型	参数量	Set5	Set14	B100	Urban100	Manga109
×4	EMASRN	558K	32.17	28.57	27.55	26.01	30.41
	SwinIR	897K	<u>32.44</u>	<u>28.77</u>	<u>27.69</u>	<u>26.47</u>	<u>30.92</u>
	AASR (ours)	1139K	32.65	28.87	27.73	26.67	31.22

表 3-8 各种先进 SISR 方法在×2 放大倍数下的平均 SSIM 和参数量结果

放大倍数	模型	参数量	Set5	Set14	B100	Urban100	Manga109
×2	SRCNN	57K	0.9524	0.9063	0.8879	0.8946	0.9661
	FSRCNN	12K	0.9558	0.9088	0.8920	0.9020	0.9694
	VDSR	665K	0.9587	0.9124	0.8960	0.9140	0.9729
	DRCN	1774K	0.9588	0.9118	0.8942	0.9133	0.9723
	LapSRN	813K	0.9590	0.9130	0.8950	0.9100	0.9740
	DRRN	297K	0.9591	0.9136	0.8973	0.9188	0.9760
	MemNet	677K	0.9597	0.9142	0.8978	0.9195	0.9740
	SRMDNF	1513K	0.9600	0.9150	0.8980	0.9200	0.9761
	CARN	1592K	0.9590	0.9166	0.8978	0.9256	0.9765
	IMDN	694K	0.9605	0.9177	0.8996	0.9283	0.9774
	LAPAR-A	548K	0.9605	0.9183	0.8999	0.9283	0.9772
	RFDN	534K	0.9606	0.9184	0.8994	0.9278	0.9773
	A ² F-M	999K	0.9607	0.9184	0.8996	0.9294	0.9774
	ACAN	800K	0.9608	0.9177	0.9001	0.9297	0.9773
	LatticeNet	756K	0.9607	0.9187	0.8999	0.9288	0.9774
	AWSRN-M	1063K	0.9605	0.9181	0.9000	0.9294	0.9772
	MAFFSRN-L	790K	0.9607	0.9177	0.9005	0.9308	-/-
	SwinIR	878K	<u>0.9611</u>	<u>0.9206</u>	0.9012	<u>0.9340</u>	0.9783
	AASR(ours)	1119K	0.9615	0.9214	<u>0.9007</u>	0.9345	<u>0.9781</u>

表 3-9 各种先进 SISR 方法在×3 放大倍数下的平均 SSIM 和参数量结果

放大倍数	模型	参数量	Set5	Set14	B100	Urban100	Manga109
×3	SRCNN	57K	0.9090	0.8209	0.7863	0.7989	0.9107
	FSRCNN	12K	0.9104	0.8242	0.7910	0.8080	0.9212
	VDSR	665K	0.9213	0.8314	0.7976	0.8279	0.9310

表 3-9(续表)

放大倍数	模型	参数量	Set5	Set14	B100	Urban100	Manga109
×3	DRCN	1774K	0.9226	0.8311	0.7963	0.8276	0.9328
	DRRN	297K	0.9244	0.8349	0.8004	0.8378	0.9390
	MemNet	677K	0.9248	0.8350	0.8001	0.8376	0.9369
	SRMDNF	1530K	0.9250	0.8370	0.8030	0.8400	0.9403
	CARN	1592K	0.9255	0.8407	0.8034	0.8404	0.9440
	IMDN	703K	0.9270	0.8417	0.8046	0.8519	0.9445
	LAPAR-A	594K	0.9267	0.8421	0.8054	0.8523	0.9441
	RFDN	541K	0.9273	0.8420	0.8050	0.8525	0.9449
	A ² F-M	1003K	0.9278	0.8427	0.8054	0.8546	0.9453
	ACAN	1115K	0.9277	0.8435	0.8055	0.8550	0.9447
	LatticeNet	765K	0.9272	0.8416	0.8049	0.8513	0.9442
	AWSRN-M	1143K	0.9275	0.8419	0.8059	0.8545	0.9450
	MAFFSRN-L	807K	0.9277	0.8432	0.8061	0.8552	-/-
	EMASRN	437K	0.9264	0.8411	0.8035	0.8493	0.9433
	SwinIR	886K	<u>0.9289</u>	<u>0.8463</u>	<u>0.8082</u>	<u>0.8624</u>	<u>0.9478</u>
	AASR (ours)	1128K	0.9299	0.8471	0.8096	0.8659	0.9495

表 3-10 各种先进 SISR 方法在×4 放大倍数下的平均 SSIM 和参数量结果

放大倍数	模型	参数量	Set5	Set14	B100	Urban100	Manga109
×4	SRCNN	57K	0.8628	0.7503	0.7101	0.7221	0.8505
	FSRCNN	12K	0.8657	0.7535	0.7150	0.7280	0.8517
	VDSR	665K	0.8838	0.7674	0.7251	0.7524	0.8809
	DRCN	1774K	0.8854	0.7670	0.7233	0.7510	0.8816
	LapSRN	813K	0.8850	0.7720	0.7280	0.7560	0.8845
	DRRN	1774K	0.8854	0.7670	0.7233	0.7510	0.8816
	MemNet	677K	0.8893	0.7723	0.7281	0.7630	0.8942
	SRMDNF	1555K	0.8930	0.7770	0.7340	0.7730	0.9024
	CARN	1592K	0.8937	0.7806	0.7349	0.7837	0.9084
	IMDN	715K	0.8948	0.7811	0.7353	0.7838	0.9075
	LAPAR-A	659K	0.8944	0.7818	0.7366	0.7871	0.9074
	RFDN	550K	0.8952	0.7819	0.7360	0.7858	0.9089

表 3-10(续表)

放大倍数	模型	参数量	Set5	Set14	B100	Urban100	Manga109
×4	A ² F-M	1010K	0.8955	0.7828	0.7364	0.7892	0.9100
	ACAN	1556K	0.8955	0.7824	0.7366	0.7891	0.9086
	LatticeNet	777K	0.8943	0.7812	0.7355	0.7844	0.9075
	AWSRN-M	1254K	0.8954	0.7832	0.7368	0.7884	0.9093
	MAFFSRN-L	830K	0.8953	0.7822	0.7370	0.7887	0.9069
	EMASRN	558K	0.8948	0.7809	0.7351	0.7838	0.9076
	SwinIR	897K	<u>0.8976</u>	<u>0.7858</u>	<u>0.7406</u>	<u>0.7980</u>	<u>0.9151</u>
	AASR (ours)	1139K	0.8997	0.7860	0.7406	0.7994	0.9172

表 3-5、表 3-6、表 3-7、表 3-8、表 3-9 和表 3-10 展示了 AASR 与其他方法在不同尺度下的性能比较。本文选取 SRCNN^[11]、FSRCNN^[66]、VDSR^[26]、DRCN^[67]、LapSRN^[68]、DRRN^[69]、MemNet^[70]、SRMDNF^[71]、CARN^[72]、IMDN^[73]、LAPAR-A^[74]、RFDN^[75]、A²F-M^[76]、ACAN^[77]、LatticeNet^[78]、AWSRN-M^[79]、MAFFSRN-L^[80]、EMASRN^[81]和 SwinIR^[24]作为客观指标的比较模型。我们将表格中相同尺度最好的模型的数值用粗体展示，次优的模型的数值用下划线表示。从×2 到×4 的放大倍数，AASR 在各种测试集上均展现出了显著的优势，尤其是在客观评价指标 PSNR 和 SSIM 上。这些结果展现了 AASR 在图像超分辨率重建方面的卓越性能与处理不同类型图像内容时的广泛适应性和高效性。

对比其他先进的超分辨率方法，如 SwinIR、MAFFSRN-L、A²F-M 等，AASR 在参数量略有增加的情况下，实现了更高的性能提升。例如，在×4 的放大倍数下，AASR 在 Set14 数据集上的 PSNR 和 SSIM 值分别为 28.87 和 0.7860，相比 SwinIR 的 28.77 和 0.7858 有着显著的提升。在 Urban100 和 Manga109 这两个数据集上，相较于次优的模型 SwinIR，AASR 的性能提升更为突出。在 Urban100 中 AASR 相较于 SwinIR 有 0.2dB 的 PSNR 的性能提升，而在 Manga109 数据集上 AASR 相较于 SwinIR 的提升则更为显著，在 PSNR 这个指标上 AASR 比 SwinIR 高出 0.3dB。

3.3.3.2 主观效果比较




图 3-6 AASR 与其他方法主观视觉效果

图 3-6 为 AASR 与其他模型的主观视觉效果比较图，本文选取 CARN^[72]、

IMDN^[73]、LAPAR-A^[74]、A²F-M^[76]、EMASRN^[81]和 SwinIR^[24]作为主观视觉效果比较模型。此外为了更直观展示 AASR 的恢复效果，我们还选取了原图像的高分辨率图像(HR)作为参照图像。从图 3-6 中可以看出，在 Urban100 的 img004 图片中，其他模型的背景均出现了扭曲变形，而我们模型产生的图片基本没有扭曲变形。在 img024 的栏杆上，其他模型产生的图像的栏杆均出现了畸变，而我们的结果明显优于其他模型。其他模型在 img038 产生的墙面均出现了扭曲的条纹，而我们模型产生的墙面几乎没有变形。在 Set14 的 barbara 图像可以明显看出，我们模型产生的图片条纹恢复正常，而其他模型产生的条纹都是扭曲的。这说明我们模型在主观视觉恢复上有着不错的效果。

3.4 本章小结

本章详细讨论了基于 Transformer 超分辨率模型的相关方法及其特点，特别是在自注意力计算上的特点，介绍了设计 AASR 网络的动机与思想。

本章的核心内容是提出了 AASR 模型，该模型采用轴向自注意力机制，通过在水平和垂直两个方向上对图像特征进行切割和处理，显著提升了模型对长距离信息的捕获能力。除此之外，AASR 模型还引入了基于卷积的 Gated-Dconv 前馈网络(GDFN)，进一步增强了模型的表达能力，使其在多个超分辨率基准测试集上取得了优异的性能。

经过一系列实验验证，AASR 模型不仅在客观评价指标 PSNR 和 SSIM 上取得了显著提升，而且在视觉效果上也展现出了更好的恢复质量，尤其是在处理具有复杂纹理和结构的图像时。消融实验进一步证明了 AASR 模型中各个组件的有效性和对模型性能的贡献。

总之，本章所提出的 AASR 模型在超分辨率图像重建领域具有重要意义，为相关研究尤其是 Transformer 与超分辨率领域的研究提供了新的思路和方法。

第 4 章 基于双路的卷积轴向自注意力单图像超分辨率算法的研究

4.1 引言

在前面的章节中，本文介绍了基于 Transformer 架构的单图像超分辨率网络的基本设计思路以及提出了一种基于轴向自注意力网络的设计方案。从前面的章节可以看出，Transformer 架构凭借其强大的特征提取能力和长距离依赖建模的能力，在单图像超分辨率任务中展现出了显著的性能提升。

然而，尽管基于 Transformer 的单图像超分辨率方法取得了重大进展，现有的方法仍面临着一些挑战。其中，最主要的挑战之一是感受野的局限性。例如，Liang 等人提出的 SwinIR^[24]采用局部自注意力机制的方法，虽然通过滑动窗口(Shifted Windows)策略^[29]尝试扩大模型的感受野，但这种方法仍然难以充分捕捉图像的全局特征，从而限制了单图像超分辨率任务。此外，轴向自注意力机制虽然在扩大感受野方面相比基于局部自注意力的方法有所改进，但其感受野仍局限于条状区域内，未能彻底解决全局特征提取的问题。

针对这些挑战，本文提出了一种创新的基于卷积和 Transformer 双路架构的单图像超分辨率网络。该网络旨在通过结合卷积计算的高效性和 Transformer 的长距离建模能力，有效融合输入图像的局部和全局特征信息，从而显著提升超分辨率重建的性能。我们的设计思想主要基于四个方面的考虑：首先，本文受 ACT^[44]的启发构建卷积与 Transformer 双路架构的超分辨率网络，与 ACT 不同的是本文通过引入卷积分支来有效提取图像的全局粗粒度信息，利用均值池化和基于卷积的像素注意力网络进行特征提取，从而捕捉到更广泛的图像粗粒度的全局信息；其次，采用双路架构对 Transformer 分支中提取的局部信息进行补偿，以实现更细致的局部特征重建；此外，设计了一种创新的双路融合块，该融合块能够有效整合卷积分支和 Transformer 分支提取的不同尺度的图像特征信息，从而实现更准确的超分辨率重建效果。最后我们还在上采样之前引入了图像后处理模块，该模块对特征进行重新校准和增强，有效地补偿了上述处理过程中可能损失的高频细节，使得最终的超分辨率图像更加逼真和高质量。

本文的主要贡献可以进一步概括为：(1) 提出了一种双路的卷积轴向自注意力单图像超分辨率网络(Dual-path Convolutional Axial self-attention image Super-Resolution Network, DCASRN)，有效克服了现有方法在全局特征提取方面的限制，显著提升了超分辨率重建的性能；(2) 设计了一种高效的卷积网络分支，专

注于提取图像的全局粗粒度信息，通过均值池化和像素注意力机制，该分支能够捕捉更广泛的图像上下文信息；(3) 提出了一种创新的图像融合块，能够有效整合来自不同架构分支的图像特征信息，实现了更细致和准确的超分辨率重建效果。(4)引入图像后处理块，进一步补偿了上述处理过程中可能损失的高频细节，从而增强图像恢复质量。通过这些设计和创新，我们的网络不仅能够处理复杂的图像场景，还能在保持高效计算的同时，提供优异的超分辨率图像重建质量。

4.2 算法总体设计

4.2.1 DCASRN 网络架构




图 4-1 DCASRN 模型整体结构

如图所示，整个模型的架构如图 4-1 所示，本模型先经过浅层特征提取块 (Shallow Feature extraction Block, SFB) 提取图像的浅层特征，再经过若干个双路特征提取块 (Dual-path Feature Extraction Block, DFEB) 进一步提取图像的深层特征，然后将提取到的浅层特征和前面各个 DFEB 块提取的深层特征进行加和再经过一个特征后处理块 (Feature Post-processing Block, FPB) 进行进一步的特征提取，最后经过 Upsample 块进行特征融合和上采样，最后得到复原的超分辨图像。整个网络的框架流程如下：

假定输入的低分辨率图像为 I_{LR} ， I_{LR} 首先通过一个 SFB 进行浅层特征提取，这里使用的 SFB 块由一个 3×3 卷积组成，如公式(4-1)所示：

$$F_0 = \text{Conv}_{3 \times 3}(I_{LR}) \quad (4-1)$$

之后通过若干个 DFEB 块进行浅层特征提取，如公式(4-2)所示：

$$H_m = \text{DFEB}_m(H_{m-1}), m = 1, 2, \dots \quad (4-2)$$

这里的 $\text{DFEB}_m(\cdot)$ 表示第 m 个双路特征提取块，之后将提取到的浅层特征与多个 DFEB 块提取到的深层特征进行求和，其过程如公式(4-3)所示：

$$H = F_0 + \sum_i^n H_i, n = 1, 2, 3, \dots \quad (4-3)$$

之后将提取到的深层特征进行特征后处理，这一步主要是为了进一步提取图像的

特征，增加图像的细节，其过程如公式(4-4)所示：

$$F = FPB(H) + F_0 \quad (4-4)$$

这里的 $FPB(\cdot)$ 表示特征后处理块，这里的特征后处理块可以对网络提取的深层特征进行有效的融合以进一步增强特征的细节，有利于图像的恢复。之后将提取到的特征进行特征融合和上采样，其过程如公式(4-5)所示：

$$I_{SR} = PixelShuffle(F) \quad (4-5)$$

这里的 $PixelShuffle(\cdot)$ 与前面第 3 章介绍的方法一样都采用亚像素卷积进行上采样。

以上是整个 DCASRN 网络工作过程，其网络中核心的是深层特征提取部分，DCASRN 网络的深层特征提取主要是通过 DFEB 模块构成的，整个 DFEB 模块的结构如图 4-2 所示：




图 4-2 DFEB 模块结构

DFEB 模块主要通过卷积和 Transformer 双路架构提取图像的深层信息，其工作过程如公式(4-6)所示：

$$F_{DFEB}(X) = F_{DFFB}([F_{TFEB}(X), F_{ECFEB}(X)]) \quad (4-6)$$

其中 X 表示输入的特征， $F_{DFEB}(\cdot)$ 表示 DFEB 块提取的特征， $F_{TFEB}(\cdot)$ 表示 Transformer 特征提取块(Transformer Feature Extraction Block, TFEB)提取的特征， $F_{ECFEB}(\cdot)$ 表示增强的卷积特征提取块(Enhanced Convolutional Feature Extraction Block, ECFEB)提取的特征， $F_{DFFB}(\cdot)$ 表示双路特征融合块(Dual-path Feature Fusion Block, DFFB)提取的特征 $[\cdot]$ 表示特征拼接操作。

4.4.2 增强的卷积特征提取块(ECFEB)模块设计

如图 4-3 所示，ECFEB 模块构成了我们模型主要的卷积分支。ECFEB 主要由多个增强型卷积网络模块(Enhanced Convolutional Network Block, ECNB)组成。




图 4-3 ECFEB 模块及其子模块的结构图

本文提出的 ECFEB 模块主要用于对图像全局粗粒度的信息进行提取，从而对 Transformer 提取的局部信息进行补偿。在设计 ECFEB 模块时我们采用了如下的关键设计方案：首先，我们采用了与 EISR^[37]相同的重参数化方案，因为使用重参数化可以保证在训练过程中使用多分支结构帮助模型更好进行训练，而在推理的时候采用单分支结构帮助模型在不改变训练结果的前提下，减少模型的计算量。其次，我们使用通道注意力和增强空间注意力相结合的方案来帮助模型更好的进行特征提取。通道注意力可以帮助模型自适应的生成通道的权重向量，强化关键的通道信息，弱化非关键信息。而空间注意力可以帮助模型自适应的提取图像空间中的关键信息。最后两种注意力相结合可以帮助模型学习图像中关键的全局信息，进而对 Transformer 分支中提取的信息进行补偿。ECFEB 模块主要工作过程如下：

首先经过一个 1×1 的卷积和 ELU 激活函数进行特征提取，其过程如公式(4-7)所示：

$$F_0 = ELU(Conv_{1 \times 1}(X)) \quad (4-7)$$

其中 $Conv_{1 \times 1}(\cdot)$ 表示卷积核大小为 1×1 的卷积层， $ELU(\cdot)$ 表示 ELU 激活函数。

接下来经过多个 ECNB 块进行特征提取，如公式(4-8)所示：

$$H_n = ECNB_n(H_{n-1}) \quad (4-8)$$

其中上述公式中 $ECNB_n(\cdot)$ 表示第 n 个 ECNB 块， H_0 等于 F_0 。最后将提取得到的

深层特征与使用卷积得到的特征进行求和，如公式(4-9)所示：

$$F_{ECFEB}(X) = F_0 + H_n \quad (4-9)$$

在设计 ECNB 模块时我们参考了 EISR^[37]的重参数化方案，在训练的时候采用如图 4-3 b)的多分支的结构，在推理时采用如图 4-3 c)的单分支结构。两种结构在逻辑上是等价的，但因为训练时采用了多分支结构可以帮助模型更好的训练以增强模型的性能，而在推理的时候采用单分支结构可以有效减少模型的计算量。我们参考了这种设计以更好的训练 ECNB 模块。如图 4-3 b)所示，ECNB 模块在训练时的主要计算过程如下：

首先将输入特征 X ，经过一个三支的多路卷积网络结构，如公式(4-10)所示：

$$\begin{aligned} F_1 &= ELU(GConv(DwConv(ChannelShuffle(GConv(X))))) \\ F_2 &= Conv_{1 \times 1}(X) \\ F &= F_1 + F_2 + X \end{aligned} \quad (4-10)$$

其中 $GConv(\cdot)$ 表示分组卷积^[82]， $DwConv(\cdot)$ 表示逐深度卷积^[32]， $ChannelShuffle(\cdot)$ 表示通道重组^[83]， $ELU(\cdot)$ 表示 ELU 激活函数。之后输出的特征 F 经过一个 ELU 激活函数后，再次经过一个三支的多路卷积网络结构，如公式(4-11)所示：

$$\begin{aligned} F'_1 &= ELU(GConv(DwConv(ChannelShuffle(GConv(F))))) \\ F'_2 &= Conv_{1 \times 1}(F) \\ F' &= F'_1 + F'_2 + F \end{aligned} \quad (4-11)$$

最后输出的特征 F' 经过一个通道注意力^[12](CA)和增强的空间注意力^[35](ESA)两个网络模块以进一步增强网络特征提取的能力，其主要计算过程如公式(4-12)所示：

$$F_{training} = ESA(CA(F')) \quad (4-12)$$

其中 $CA(\cdot)$ 和 $ESA(\cdot)$ 分别表示通道注意力模块和空间注意力模块， $F_{training}$ 表示训练时 ECNB 输出的特征。

在网络推理阶段，我们采用如图 4-3 c)所示的单分支结构，其主要的计算过程如公式(4-13)所示：

$$\begin{aligned} F_1 &= ELU(GConv(DwConv(ChannelShuffle(GConv(X))))) \\ F_2 &= ELU(F_1) \\ F_3 &= ELU(GConv(DwConv(ChannelShuffle(GConv(F_2))))) \\ F_{inference} &= ESA(CA(F_3)) \end{aligned} \quad (4-13)$$

其中 $F_{inference}$ 表示 ECNB 模块推理过程输出的特征，其过程与训练过程类似，只不过在推理时去掉了残差分支和 1×1 的卷积分支，以达到减少计算量但不影响最终的输出的目的。

在上述过程中使用了通道注意力和增强的空间注意力，使用通道注意力的目的是为了输入特征中的每个通道自适应的生成一个特征权重，强化重要的特征，弱化无效特征。使用增强的空间注意力的主要目的是提取输入图像中粗粒度的全局信息，以补偿 Transformer 分支中提取的局部信息。其中，通道注意力如图 4-4 所示：




图 4-4 通道注意力^[12]

通道注意力的主要工作过程如下：

假定输入的特征图为 X ，首先经过一个均值池化，变成一个 $1 \times 1 \times C$ 的向量，其过程如公式(4-14)所示：

$$F_{GP} = GAP(X) \quad (4-14)$$

其中 $GAP(\cdot)$ 为自适应均值池化操作，之后经过一个输入通道为 C ，输出通道数为 C/r 的 1×1 卷积，其过程如(4-15)所示：

$$F_D = Conv_{1 \times 1}(F_{GP}) \quad (4-15)$$

上述过程中的 r 表示压缩系数，主要用于对中间过程产生的通道数进行压缩，以减少参数量和计算量。之后对输出的 F_D 再经过一个 1×1 的卷积进行特征提取，其过程如公式(4-16)所示：

$$F_U = Conv_{1 \times 1}(F_D) \quad (4-16)$$

这里的 1×1 卷积与前面公式(4-15)中 1×1 卷积不同的是：(4-15)中 1×1 卷积的输出通道数为 C/r ，而(4-16)中 1×1 的卷积输出通道为 C ，之后对输出的向量进行非线性化映射，其过程如公式(4-17)所示：

$$f = \sigma(F_U) \quad (4-17)$$

其中 $\sigma(\cdot)$ 表示 Sigmoid 函数，这样可以将计算过程引入非线性操作，最后对原输入特征 X 进行特征重要性调整，其过程如公式(4-18)所示：

$$F_{CA} = f \otimes X \quad (4-18)$$

最后输出的特征 F_{CA} 即为经过通道注意力的特征。

在对输入的特征经过通道注意力进行通道重要性调整后，使用增强的空间注意力进一步提取图像粗粒的全局特征，如图 4-5 所示为 ESA 的结构，其主要工作过程如下：

首先，假设输入特征为 X ，首先 X 经过一个 1×1 的卷积进行特征提取，其过程如公式(4-19)所示：

$$F = \text{Conv}_{1 \times 1}(X) \quad (4-19)$$

然后将输出的特征 F 经过带步长为 2 的 3×3 卷积，如公式(4-20)所示：

$$F_1 = \text{Conv}_{3 \times 3}(X) \quad (4-20)$$




图 4-5 增强空间注意力模块结构

再经过池化和卷积组的特征提取操作，其过程如公式(4-21)所示：

$$F_2 = \text{ConvGroup}(\text{MAP}(F_1)) \quad (4-21)$$

其中 $\text{ConvGroup}(\cdot)$ 表示卷积组，主要是由一组卷积块组成。 $\text{MAP}(\cdot)$ 表示最大池化操作。这一步的操作主要是对图像进行降维，提取图像中有用的粗粒度信息。之后对特征图像进行上采样，将其恢复到与输入特征 X 同样大小的尺寸。然后将 F_1 与提取到的特征 F_2 求和，如公式(4-22)所示：


$$F_3 = F_1 + F_2 \quad (4-22)$$

之后将特征进行权重相乘，如公式(4-23)所示：

$$F_{\text{ESA}} = \text{Conv}_{1 \times 1}(\sigma(X)) \otimes F_3 \quad (4-23)$$

特到的特征 F_{ESA} 即为经过 ESA 模块输出后的特征。

4.4.3 Transformer 特征提取块(TFEB)模块设计



a) TFEB 总体结构图




图 4-6 TFEB 模块及其子模块的结构图

Transformer 网络分支我们采用如图 4-6 所示的结构, 我们采用轴向自注意力与局部自注意力交替的形式来设计 Transformer 分支。其主要计算过程如公式(4-24)所示:

$$F_n = AWTRL(SWTL(F_{n-1})) \quad (4-24)$$

其中 F_{n-1} 表示上一个层的输出, $AWTRL(\cdot)$ 和 $SWTL(\cdot)$ 分别表示基于轴向自注意力的 Transformer 层和基于窗口自注意力的 Transformer 层。最后整个 TFEB 块的输出如公式(4-25)所示:

$$F_{TFEB} = Conv(F_n) \quad (4-25)$$

其中 $Conv(\cdot)$ 表示卷积层, 本文该卷积层采用的是 3×3 卷积, F_{TFEB} 表示 TFEB 模块的输出。

Transformer 分支主要依靠自注意力计算, 其主要结构如图 4-6 b) 的轴向自注意力的 Transformer 层(AWTRL)和 4-6 c) 局部自注意力 Transformer 层(SWTL), 其中 AWTRL 层的计算过程如公式(4-26)所示:

$$\begin{aligned} F_1 &= RB(LN(X)) + ASAL(LN(X)) \\ F_{AWTRL} &= F_1 + MLP(LN(F_1)) \end{aligned} \quad (4-26)$$

其中 X 为输入特征, 与第 3 章介绍的轴向自注意力的 ASAL 层不同的是, 我们

在该层中引入了一个基于残差卷积块的旁路分支,用于为自注意力的计算补充更为丰富的特征。 $ASAL(\cdot)$ 表示前面第3章介绍的轴向自注意力计算层。

该残差卷积块的计算过程如公式(4-27)所示:

$$RB(X) = \text{Conv}_{3 \times 3}(\text{ELU}(\text{Conv}_{3 \times 3}(X))) \quad (4-27)$$

SWTL层与SwinIR^[24]中的基于局部自注意力的Transformer层相同,其计算过程如公式(4-28)所示:

$$\begin{aligned} F_1 &= \text{MHSA}(\text{LN}(X)) \\ F_{\text{SWTL}} &= F_1 + \text{MLP}(\text{LN}(F_1)) \end{aligned} \quad (4-28)$$

其中 $\text{MHSA}(\cdot)$ 表示多自注意力的计算,其过程与SwinIR相同都是在局部窗口内进行自注意力计算。

4.2.4 双路特征融合块(DFFB)模块设计




图 4-7 DFFB 模块的结构图

DFFB模块的结构如图4-7所示,该模块为一个全卷积模块,用于卷积分支的ECFEB模块和Transformer分支的TFEB模块的特征进行融合从而对Transformer分支的局部信息进行补偿。首先对TFEB和ECFEB两个模块的输出进行拼接,其计算过程如公式(4-29)所示:

$$F = [F_{\text{TFEB}}, F_{\text{ECFEB}}] \quad (4-29)$$

其中 F_{TFEB} 和 F_{ECFEB} 分别表示TFEB模块和ECFEB模块提取的特征。 $[\cdot]$ 表示通道拼接操作,其输出的特征为 F 。之后经过两个 1×1 卷积的层进行特征提取,其过程如公式(4-30)所示:

$$F_0 = \text{Conv}_{1 \times 1}(\text{ELU}(\text{Conv}_{1 \times 1}(F))) \quad (4-30)$$

其中 F_0 为经过两个卷积层输出的特征。接下来输出的特征 F_0 经过一个三支路的卷积网络进行特征提取,其过程如公式(4-31)所示:

$$\begin{aligned}
 F_1 &= \text{Conv}_{1 \times 1}(F_0) \\
 F_2 &= \text{ELU}(\text{Conv}_{3 \times 3}(F_0)) \\
 F_3 &= \text{Conv}_{3 \times 3}(\text{ELU}(\text{Conv}_{3 \times 3}(F_0)))
 \end{aligned} \tag{4-31}$$

然后对提取的特征进行多路渐进融合操作，其过程如公式(4-32)所示：

$$\begin{aligned}
 H_1 &= F_1 \\
 H_2 &= \text{Conv}_{1 \times 1}(\sigma(F_1)) \odot F_2 \\
 H_3 &= \text{Conv}_{1 \times 1}(\sigma(F_2)) \odot F_3
 \end{aligned} \tag{4-32}$$

这里的 $\sigma(\cdot)$ 表示 Sigmoid 激活函数，经过多路渐进融合输出的特征分别是 H_1 、 H_2 和 H_3 ，之后对这三个特征进行特征拼接，如公式(4-33)所示：

$$Y = [H_1, H_2, H_3] \tag{4-33}$$

其中 Y 表示拼接后输出的特征，之后经过一个 1×1 的卷积和通道注意力，其过程如公式(4-34)所示：

$$Y' = \text{CA}(\text{Conv}_{1 \times 1}(Y)) \tag{4-34}$$

这里 Y' 表示经过一个 1×1 的卷积和通道注意力输出的特征，之后进行如公式(4-35)的计算：

$$\begin{aligned}
 F_1' &= H_1 \odot Y' \\
 F_2' &= H_2 \odot Y' \\
 F_3' &= H_3 \odot Y'
 \end{aligned} \tag{4-35}$$

其中 $\odot$ 表示逐个元素相乘函数，最后将上述输出的特征进一步拼接和进行特征融合，如公式(4-36)所示：

$$F_{DFEB} = \text{Conv}_{1 \times 1}([F_1', F_2', F_3']) \tag{4-36}$$

其中 F_{DFEB} 为 DFEB 块最终的输出。

4.2.5 特征后处理块(FPB)模块设计




图 4-8 FPB 模块的结构图

FPB 的结构如图 4-8 所示，该模块用于对所有输出的浅层特征和深度特征求和后的特征图进行后处理，以进一步增强图像恢复的质量，我们同样采用多路渐进融合的策略来设计这个模块，首先对输入的特征 X 进行卷积处理，如公式(4-37)所示：

$$F_0 = \text{Conv}_{1 \times 1}(\text{ELU}(\text{Conv}_{1 \times 1}(X))) \quad (4-37)$$

接下来输出的特征 F_0 经过一个四支路的卷积网络进行特征提取，其过程如公式(4-38)所示：

$$\begin{aligned} F_1 &= \text{Conv}_{1 \times 1}(F_0) \\ F_2 &= \text{ELU}(\text{Conv}_{3 \times 3}(F_0)) \\ F_3 &= \text{Conv}_{3 \times 3}(\text{ELU}(\text{Conv}_{3 \times 3}(F_0))) \\ F_4 &= \text{Conv}_{3 \times 3}(\text{ELU}(\text{Conv}_{3 \times 3}(\text{ELU}(\text{Conv}_{3 \times 3}(F_0))))) \end{aligned} \quad (4-38)$$

与 DFEB 一样，接下来对提取的特征做多路渐进融合，其过程如公式(4-39)所示：

$$\begin{aligned} H_1 &= F_1 \\ H_2 &= \text{Conv}_{1 \times 1}(\sigma(F_1)) \odot F_2 \\ H_3 &= \text{Conv}_{1 \times 1}(\sigma(F_2)) \odot F_3 \\ H_4 &= \text{Conv}_{1 \times 1}(\sigma(F_3)) \odot F_4 \end{aligned} \quad (4-39)$$

这里的 $\sigma(\cdot)$ 表示激活函数，这里我们和 DFEB 同样使用 Sigmoid 激活函数，经过多路渐进融合输出的特征分别是 H_1 、 H_2 、 H_3 和 H_4 ，之后对这四个特征进行特征

拼接，如公式(4-40)所示：

$$Y = [H_1, H_2, H_3, H_4] \quad (4-40)$$

其中 Y 表示拼接后输出的特征，之后经过一个 1×1 的卷积和通道注意力，其过程如公式(4-41)所示：

$$Y' = CA(Conv_{1 \times 1}(Y)) \quad (4-41)$$

这里 Y' 表示经过一个 1×1 的卷积和通道注意力输出的特征，之后进行如公式(4-42)的计算：

$$\begin{aligned} F_1' &= H_1 \odot Y' \\ F_2' &= H_2 \odot Y' \\ F_3' &= H_3 \odot Y' \\ F_4' &= H_4 \odot Y' \end{aligned} \quad (4-42)$$

其中 $\odot$ 表示逐个元素相乘函数，最后将上述输出的特征进行拼接和使用 1×1 的卷积进行特征融合，如公式(4-43)所示：

$$F_{FPB} = Conv_{1 \times 1}([F_1', F_2', F_3', F_4']) \quad (4-43)$$

其中 F_{FPB} 为 FPB 块最终的输出。

4.3 实验与分析

4.3.1 实验设置

本章采用的训练配置与第 3 章介绍的方法大致相同。训练时采用 DIV2K 数据集中的 001-800 作为我们的训练集，使用 Manga109 作为验证集进行验证，采用 Set5^[50]、Set14^[51]、BSD100^[52]、Urban100^[53]和 Manga109^[54]作为我们结果评估的依据。本实验中，我们依然计算 PSNR 和 SSIM 在图像 YCbCr 空间^[11]中 Y 通道上的结果作为评估的指标。训练时的 batchsize 大小为 48，训练时输入的图形尺寸固定为 64×64 。与第 3 章一样，我们仍然使用 Adam 优化器^[65]进行参数优化，其中初始学习率为 2×10^{-4} ，betas 参数范围是 0.9 到 0.999。总共训练 1000000 次迭代，按 500000, 800000, 900000, 950000 进行一次学习率折半。与第 3 章不同的是，本章节模型的切割宽度 S_w 设为 1，网络中 DFEB 模块的数量设为 4，每个 ECFEB 块中 ECNB 块的数量设为 7，这样做是出于平衡模型的性能和计算量

而设置的。本实验在四块 NVIDIA 2080Ti 上进行训练与测试。

4.3.2 消融实验

4.3.2.1 双路结构对网络的影响

表 4-1 双路结构对网络的影响

CNN	Transformer	PSNR	SSIM
√	√	31.24	0.9170
√	×	30.37	0.9068
×	√	30.55	0.9083

如表 4-1 所示,同时使用卷积分支和 Transformer 分支的网络在 PSNR 和 SSIM 两个指标上都取得了最好的结果。其中使用双路结构的网络 PSNR 达到 31.24dB, SSIM 达到 0.9170,这表明双路结构能够有效提升超分辨率的图像质量。只使用卷积分支而不使用 Transformer 分支的网络 PSNR 为 30.37dB, SSIM 为 0.9068,两项指标均低于同时使用双路结构的网络。这说明单独使用卷积分支虽然能达到一定的超分效果,但加入 Transformer 可以进一步提升性能。相比之下,只使用 Transformer 分支而不使用卷积分支的网络 PSNR 为 30.55dB, SSIM 为 0.9083,略高于只用 CNN 的网络,但仍然低于双路结构。这表明单独使用 Transformer 虽然也有不错的效果,但仍有进一步提升的空间。从上述实验的结果可以看出,卷积分支和 Transformer 的互补性较强,将二者结合能够取长补短,更好地提取图像特征,从而达到更优的超分效果。总的来说,实验结果证实了双路结构在超分辨率任务中的有效性。

4.3.2.2 双路特征融合块(DFEB)对网络的影响

表 4-2 双路特征融合块(DFEB)

有无 DFEB 块	PSNR	SSIM
√	31.24	0.9170
×	31.15	0.9164

如表 4-2 的实验结果可以看出,双路特征融合块(DFEB)对超分辨率网络性能的影响。使用 DFEB 块的网络在 PSNR 和 SSIM 两个指标上均优于不使用 DFEB 块的网络,其中 PSNR 提升了 0.09dB, SSIM 提升了 0.0006。这表明 DFEB 块通过融合来自 CNN 和 Transformer 两个分支的特征,能够在一定程度上提升超分辨率的图像质量。

4.3.2.3 特征后处理块(FPB)对网络的影响

表 4-3 特征后处理块(FPB)

有无 FPB 块	PSNR	SSIM
√	31.24	0.9170
×	31.03	0.9141

如表 4-3 的实验结果可以看出特征后处理块(FPB)在超分辨率网络中展现出了非凡的优势和重要性。通过对融合后的特征进行精细化处理和优化,FPB 块能够有效地提取和增强图像的关键细节,生成更加清晰、锐利的超分辨率结果。实验数据充分证实了 FPB 块的显著效果:使用 FPB 块的网络在 PSNR 和 SSIM 两个评价指标上都大幅领先于未使用 FPB 块的网络,其 PSNR 和 SSIM 分别达到了 31.24dB 和 0.9170 的优异水平,较无 FPB 块的网络分别提升了 0.21 和 0.0029。这一显著的性能提升充分体现了 FPB 块在超分辨率任务中的关键作用。FPB 块巧妙地利用了后处理策略,通过对特征进行重新校准和增强,有效地补偿了上述处理过程中可能损失的高频细节,使得最终的超分辨率图像更加逼真和高质量。

4.3.3 实验结果分析

4.3.3.1 客观评价指标

表 4-4 各种先进 SISR 方法在×2 放大倍数下的平均 PSNR 和参数量结果

放大倍数	模型	参数量	Set5	Set14	B100	Urban100	Manga109
×2	SRCNN	57K	36.66	32.42	31.36	29.50	35.74
	FSRCNN	12K	37.00	32.63	31.53	29.88	36.67
	VDSR	665K	37.53	33.03	31.90	30.76	37.22
	EDSR	1370K	37.99	33.57	32.16	31.98	38.54
	DRCN	1774K	37.63	33.04	31.85	30.75	37.63
	LapSRN	813K	37.52	33.08	31.80	30.41	37.27
	DRRN	297K	37.74	33.23	32.05	31.23	37.92
	MemNet	677K	37.78	33.28	32.08	31.31	37.72
	SRMDNF	1513K	37.79	33.32	32.05	31.33	38.07
	CARN	1592K	37.76	33.52	32.09	31.92	38.36
	IMDN	694K	38.00	33.63	32.19	32.17	38.88
	LAPAR-A	548K	38.01	33.62	32.19	32.10	38.67
	RFDN	534K	38.05	33.68	32.16	32.12	38.88
	A ² F-M	999K	38.04	33.67	32.18	32.27	38.87

表 4-4(续表)

放大倍数	模型	参数量	Set5	Set14	B100	Urban100	Manga109
×2	ACAN	800K	38.10	33.60	32.21	32.29	38.81
	LatticeNet	756K	38.06	33.70	32.20	32.25	38.94
	AWSRN-M	1063K	38.04	33.66	32.21	32.23	38.66
	MAFFSRN-L	790K	38.07	33.59	32.23	32.38	-/-
	SwinIR	878K	38.14	33.86	32.31	<u>32.76</u>	39.12
	ELAN	582K	<u>38.17</u>	33.94	<u>32.30</u>	<u>32.76</u>	39.11
	DLGSANet-tiny	566K	38.16	<u>33.92</u>	32.26	32.82	<u>39.14</u>
	DCASRN (ours)	669K	38.20	33.87	32.29	<u>32.76</u>	39.21

表 4-5 各种先进 SISR 方法在×3 放大倍数下的平均 PSNR 和参数量结果

放大倍数	模型	参数量	Set5	Set14	B100	Urban100	Manga109
×3	SRCNN	57K	32.75	29.28	28.41	26.24	30.59
	FSRCNN	12K	33.16	29.43	28.53	26.43	30.98
	VDSR	665K	33.66	29.77	28.82	27.14	32.01
	EDSR	1370K	37.99	33.57	32.16	31.98	38.54
	DRCN	1774K	33.82	29.76	28.80	27.15	32.31
	DRRN	297K	34.03	29.96	28.95	27.53	32.74
	MemNet	677K	34.09	30.00	28.96	27.56	32.51
	SRMDNF	1530K	34.12	30.04	28.97	27.57	33.00
	CARN	1592K	34.29	30.29	29.06	27.38	33.50
	IMDN	703K	34.36	30.32	29.09	28.17	33.61
	LAPAR-A	594K	34.36	30.34	29.11	28.15	33.51
	RFDN	541K	34.41	30.34	29.09	28.21	33.67
	A ² F-M	1003K	34.50	30.39	29.11	28.28	33.66
	ACAN	1115K	34.46	30.39	29.11	28.28	33.61
	LatticeNet	765K	34.40	30.32	29.10	28.19	33.63
	AWSRN-M	1143K	34.42	30.32	29.13	28.26	33.64
	MAFFSRN-L	807K	34.45	30.40	29.13	28.26	-/-
	EMASRN	437K	34.36	30.30	29.05	28.04	33.43
	SwinIR	886K	<u>34.62</u>	30.54	29.20	<u>28.66</u>	33.98
	ELAN	590K	34.61	<u>30.55</u>	<u>29.21</u>	<u>28.69</u>	34.00

表 4-5(续表)

放大倍数	模型	参数量	Set5	Set14	B100	Urban100	Manga109
×3	DLGSANet-tiny	572K	34.63	30.57	<u>29.21</u>	<u>28.69</u>	<u>34.10</u>
	DCASRN (ours)	708K	<u>34.62</u>	30.48	29.26	28.78	34.31

表 4-6 各种先进 SISR 方法在×4 放大倍数下的平均 PSNR 和参数量结果

放大倍数	模型	参数量	Set5	Set14	B100	Urban100	Manga109
×4	SRCNN	57K	30.48	27.49	26.90	24.52	27.66
	FSRCNN	12K	30.71	27.59	26.98	24.62	27.90
	VDSR	665K	31.35	28.01	27.29	25.18	28.83
	EDSR	1518K	32.09	28.58	27.57	26.04	30.35
	DRCN	1774K	31.53	28.02	27.23	25.14	28.98
	LapSRN	813K	31.54	28.19	27.32	25.21	29.09
	DRRN	1774K	31.53	28.02	27.23	25.14	28.98
	MemNet	677K	31.74	28.26	27.40	25.50	29.42
	SRMDNF	1555K	31.96	28.35	27.49	25.68	30.09
	CARN	1592K	32.13	28.60	27.58	26.07	30.47
	IMDN	715K	32.21	28.58	27.56	26.04	30.45
	LAPAR-A	659K	32.15	28.61	27.61	26.14	30.42
	RFDN	550K	32.24	28.61	27.57	26.11	30.58
	A ² F-M	1010K	32.28	28.62	27.58	26.17	30.57
	ACAN	1556K	32.24	28.62	27.59	26.17	30.53
	LatticeNet	777K	32.18	28.61	27.57	26.14	30.54
	AWSRN-M	1254K	32.21	28.65	27.60	26.15	30.56
	MAFFSRN-L	830K	32.20	28.62	27.59	26.16	30.33
	EMASRN	558K	32.17	28.57	27.55	26.01	30.41
	SwinIR	897K	<u>32.44</u>	28.77	27.69	26.47	30.92
	ELAN	601K	32.43	<u>28.78</u>	27.69	26.54	30.92
	DLGSANet-tiny	581K	32.46	28.79	<u>27.70</u>	<u>26.55</u>	<u>30.98</u>
	DCASRN (ours)	765K	32.41	28.74	27.74	26.67	31.24

表 4-7 各种先进 SISR 方法在 $\times 2$ 放大倍数下的平均 SSIM 和参数量结果

放大倍数	模型	参数量	Set5	Set14	B100	Urban100	Manga109
$\times 2$	SRCNN	57K	0.9524	0.9063	0.8879	0.8946	0.9661
	FSRCNN	12K	0.9558	0.9088	0.8920	0.9020	0.9694
	VDSR	665K	0.9587	0.9124	0.8960	0.9140	0.9729
	EDSR	1370K	0.9604	0.9175	0.8994	0.9272	0.9769
	DRCN	1774K	0.9588	0.9118	0.8942	0.9133	0.9723
	LapSRN	813K	0.9590	0.9130	0.8950	0.9100	0.9740
	DRRN	297K	0.9591	0.9136	0.8973	0.9188	0.9760
	MemNet	677K	0.9597	0.9142	0.8978	0.9195	0.9740
	SRMDNF	1513K	0.9600	0.9150	0.8980	0.9200	0.9761
	CARN	1592K	0.9590	0.9166	0.8978	0.9256	0.9765
	IMDN	694K	0.9605	0.9177	0.8996	0.9283	0.9774
	LAPAR-A	548K	0.9605	0.9183	0.8999	0.9283	0.9772
	RFDN	534K	0.9606	0.9184	0.8994	0.9278	0.9773
	A ² F-M	999K	0.9607	0.9184	0.8996	0.9294	0.9774
	ACAN	800K	0.9608	0.9177	0.9001	0.9297	0.9773
	LatticeNet	756K	0.9607	0.9187	0.8999	0.9288	0.9774
	AWSRN-M	1063K	0.9605	0.9181	0.9000	0.9294	0.9772
	MAFFSRN-L	790K	0.9607	0.9177	0.9005	0.9308	-/-
	SwinIR	878K	<u>0.9611</u>	<u>0.9206</u>	0.9012	<u>0.9340</u>	0.9783
	ELAN	582K	<u>0.9611</u>	0.9207	0.9012	<u>0.9340</u>	<u>0.9782</u>
	DLGSANet-tiny	566K	<u>0.9611</u>	0.9202	0.9007	0.9343	0.9777
	DCASRN (ours)	669K	0.9613	0.9199	<u>0.9011</u>	0.9336	<u>0.9782</u>

表 4-8 各种先进 SISR 方法在 $\times 3$ 放大倍数下的平均 SSIM 和参数量结果

放大倍数	模型	参数量	Set5	Set14	B100	Urban100	Manga109
$\times 3$	SRCNN	57K	0.9090	0.8209	0.7863	0.7989	0.9107
	FSRCNN	12K	0.9104	0.8242	0.7910	0.8080	0.9212
	VDSR	665K	0.9213	0.8314	0.7976	0.8279	0.9310
	EDSR	1555K	0.9270	0.8417	0.8052	0.8527	0.9439
	DRCN	1774K	0.9226	0.8311	0.7963	0.8276	0.9328
	DRRN	297K	0.9244	0.8349	0.8004	0.8378	0.9390

表 4-8(续表)

放大倍数	模型	参数量	Set5	Set14	B100	Urban100	Manga109
×3	MemNet	677K	0.9248	0.8350	0.8001	0.8376	0.9369
	SRMDNF	1530K	0.9250	0.8370	0.8030	0.8400	0.9403
	CARN	1592K	0.9255	0.8407	0.8034	0.8404	0.9440
	IMDN	703K	0.9270	0.8417	0.8046	0.8519	0.9445
	LAPAR-A	594K	0.9267	0.8421	0.8054	0.8523	0.9441
	RFDN	541K	0.9273	0.8420	0.8050	0.8525	0.9449
	A ² F-M	1003K	0.9278	0.8427	0.8054	0.8546	0.9453
	ACAN	1115K	0.9277	0.8435	0.8055	0.8550	0.9447
	LatticeNet	765K	0.9272	0.8416	0.8049	0.8513	0.9442
	AWSRN-M	1143K	0.9275	0.8419	0.8059	0.8545	0.9450
	MAFFSRN-L	807K	0.9277	0.8432	0.8061	0.8552	-/-
	EMASRN	437K	0.9264	0.8411	0.8035	0.8493	0.9433
	SwinIR	886K	<u>0.9289</u>	<u>0.8463</u>	0.8082	0.8624	0.9478
	ELAN	590K	0.9288	<u>0.8463</u>	0.8081	0.8624	0.9478
	DLGSANet-tiny	677K	0.9288	0.8459	<u>0.8083</u>	<u>0.8630</u>	<u>0.9480</u>
	DCASRN (ours)	708K	0.9293	0.8467	0.8094	0.8645	0.9490

表 4-9 各种先进 SISR 方法在×4 放大倍数下的平均 SSIM 和参数量结果

放大倍数	模型	参数量	Set5	Set14	B100	Urban100	Manga109
×4	SRCNN	57K	0.8628	0.7503	0.7101	0.7221	0.8505
	FSRCNN	12K	0.8657	0.7535	0.7150	0.7280	0.8517
	VDSR	665K	0.8838	0.7674	0.7251	0.7524	0.8809
	EDSR	1518K	0.8938	0.7813	0.7357	0.7849	0.9067
	DRCN	1774K	0.8854	0.7670	0.7233	0.7510	0.8816
	LapSRN	813K	0.8850	0.7720	0.7280	0.7560	0.8845
	DRRN	1774K	0.8854	0.7670	0.7233	0.7510	0.8816
	MemNet	677K	0.8893	0.7723	0.7281	0.7630	0.8942
	SRMDNF	1555K	0.8930	0.7770	0.7340	0.7730	0.9024
	CARN	1592K	0.8937	0.7806	0.7349	0.7837	0.9084
	IMDN	715K	0.8948	0.7811	0.7353	0.7838	0.9075
	LAPAR-A	659K	0.8944	0.7818	0.7366	0.7871	0.9074

表 4-9(续表)

放大倍数	模型	参数量	Set5	Set14	B100	Urban100	Manga109
×4	RFDN	550K	0.8952	0.7819	0.7360	0.7858	0.9089
	A ² F-M	1010K	0.8955	0.7828	0.7364	0.7892	0.9100
	ACAN	1556K	0.8955	0.7824	0.7366	0.7891	0.9086
	LatticeNet	777K	0.8943	0.7812	0.7355	0.7844	0.9075
	AWSRN-M	1254K	0.8954	0.7832	0.7368	0.7884	0.9093
	MAFFSRN-L	830K	0.8953	0.7822	0.7370	0.7887	0.9069
	EMASRN	558K	0.8948	0.7809	0.7351	0.7838	0.9076
	SwinIR	897K	0.8976	0.7858	0.7406	0.7980	0.9151
	ELAN	601K	0.8975	0.7858	0.7406	0.7982	0.9150
	DLGSANet-tiny	558K	0.8993	<u>0.7871</u>	<u>0.7415</u>	0.8033	<u>0.9161</u>
	DCASRN (ours)	765K	<u>0.8981</u>	0.7874	0.7421	<u>0.8029</u>	0.9170

DCASRN 与其他方法的 PSNR 和 SSIM 指标测试的结果如表 4-4、表 4-5、表 4-6、表 4-7、表 4-8 和表 4-9 所示。本文选取 SRCNN^[11]、FSRCNN^[66]、VDSR^[26]、EDSR^[38]、DRCN^[67]、LapSRN^[68]、DRRN^[69]、MemNet^[70]、SRMDNF^[71]、CARN^[72]、IMDN^[73]、LAPAR-A^[74]、RFDN^[75]、A²F-M^[76]、ACAN^[77]、LatticeNet^[78]、AWSRN-M^[79]、MAFFSRN-L^[80]、EMASRN^[81]、SwinIR^[24]、ELAN^[62]和 DLGSANet-tiny^[84]作为客观指标的比较模型。在×2 放大倍数下,我们的 DCASRN 模型在 Set5, Set14, B100, Urban100 和 Manga109 数据集上均表现出了优异的性能,尤其是在 Manga109 数据集上达到了 39.21dB 的 PSNR 值,相比其他模型显示出了明显的优势。同时,在参数量方面,DCASRN 模型仅为 669K,相比 EDSR 的 1370K,我们的模型在保持高性能的同时大幅减小了模型大小,这对于资源受限的场景具有极大的应用价值。

在×3 和×4 放大倍数下,DCASRN 模型同样展现出了有竞争力的性能,在大多数数据集上均能达到或超越其他模型。值得注意的是,在×4 放大倍数下,尽管参数量仅为 765K,DCASRN 模型在 Manga109 数据集上达到了 31.24dB 的 PSNR 值,优于其他所有模型。这一结果证明了我们模型在处理高放大倍数时依旧能够保持高效和有效。从 SSIM 角度来看,DCASRN 模型在所有放大倍数下均展现出了优秀的表现。尤其是在×3 放大倍数下,DCASRN 模型在 Manga109 数据集上达到了 0.9490 的 SSIM 值,这一结果突显了我们模型在保持图像结构和纹理方面的能力。

4.3.3.2 主观效果比较




图 4-9 DCASRN 与其他方法主观视觉效果

图 4-9 为 DCASRN 与其他模型的主观视觉比较图。本文选取 CARN^[72]、IMDN^[73]、AWSRN-S^[79]、LAPAR-A^[74]、EDSR^[38]和 SwinIR^[24]作为主观视觉效果

的比较模型。此外为了更直观展示 DCASRN 的恢复效果，我们还选取了原图像的高分辨率图像(HR)作为比较图像。对比分析可以观察到 DCASRN 在细节重建和图像清晰度方面相较于其他模型有着明显的优势。在 Urban100(img027)中可以看出，其他模型生成的房子墙壁的图案是模糊的，但我们模型生成的房子的墙壁图案明显比其他模型要更清晰。在 Urban100(img085)中，我们模型生成的桥旁边船上的人物的图案是正常的，但其他模型生成的船上的人物图案明显存在缺失的问题。在 Urban100(img086)中，我们模型生成的大楼的图案是正常的，而其他模型生成的楼的图案明显扭曲。在 Set14(barbara)中，其他模型生成的书本的图案明显是扭曲的，而 DCASRN 生成的书本的图案是正常的。从主观视觉效果可以看出，DCASRN 在提升图像的视觉效果和保持图像细节方面具有明显的优势。

4.4 本章小结

本章介绍了一种基于卷积和 Transformer 双路架构的单图像超分辨率网络 DCASRN，旨在解决现有基于 Transformer 架构的单图像超分辨率网络在全局特征提取方面的局限性。本文提出的网络能够有效融合 Transformer 提取的局部特征和卷积提取的全局粗粒度特征，从而显著提升超分辨率重建的性能。此外，本章还介绍了双路融合块、增强的卷积特征提取块和图像后处理块等设计，进一步实现更准确的超分辨率重建效果。

实验结果表明，DCASRN 在多个数据集上达到了优异的性能，尤其是在 Manga109 数据集上，其 PSNR 和 SSIM 指标均超过了其他先进方法。这一结果证明了 DCASRN 模型在处理高放大倍数时依旧能够保持高性能的特性，同时也突显了模型在保持图像结构和纹理方面的强大能力。通过这些设计和创新，本文提出的网络不仅能够处理复杂的图像场景，还能在保持高效计算的同时，提供优异的超分辨率图像重建质量，为单图像超分辨率任务提供了一种有效的解决方案。

第 5 章 结论与展望

5.1 论文工作总结

随着深度学习领域的发展,图像恢复领域尤其单图像超分辨率领域在基于 Transformer 方法下显著提高了其性能。但传统的基于 Transformer 的方法面临感受野限制的挑战,导致难以提取多尺度的特征。为了解决以上问题,我们提出了两个基于 Transformer 的网络。本文的研究内容如下:

本文简要分析了当前超分辨率领域的进展,简单介绍了基于深度学习方法的超分辨率网络的设计,尤其分析了 Transformer 架构在超分辨率领域中的主要设计方法和目前应用中的不足。

本文在第 3 章提出了一种基于轴向自注意力的网络 AASR,该网络将输入的特征按水平和垂直两个方向切割成等宽的条纹,然后在等宽的条纹中计算自注意力,最后再将两个方向计算的注意力特征进行融合,从而得到整个经过轴向自注意力计算的特征。使用轴向自注意力能有效改善局部自注意力感受野不足的问题,同时相对于全局自注意力有着更少的计算量。此外,本文引入了基于卷积的 Gated-Dconv 前馈结构层来激活图像更多的像素,用于改善传统 Transformer 块中 MLP 性能不足的问题。

通过大量的消融实验证明,本文提出的 AASR 模型中各种改进的有效性,无论在客观指标还是主观视觉效果上都表现出了有竞争力的结果。

本文在第 4 章提出了一种卷积和 Transformer 双路架构的单图像超分辨率网络——DCASRN。本文分析了传统 Transformer 架构中由于自注意力计算感受野的局限性,提出利用 Transformer 架构和卷积运算相结合的方法。在本方法中,利用卷积网络运算的高效性,通过使用卷积分支提取图像粗粒度的全局信息来弥补自注意力计算中有限的图像特征,进而提升图像恢复的质量。此外,本文设计的双路特征融合块(DFEB)可以有效融合两个分支中的信息,从而实现卷积分支和 Transformer 分支信息的互补。最后本文设计的特征后处理块(FPB)能够对所有输出的浅层特征和深度特征进行后处理,减少多层网络中信息丢失的问题,以进一步增强图像恢复的质量。

通过各种消融实验可以看出,DCASRN 中 DFEB 块能够有效利用双路分支的特征进行信息的融合,从而提升网络性能。此外,通过 FPB 块的设计,能够有效减少深度模型中信息丢失的问题,从而进一步提升网络的性能。从客观指标和主观视觉效果可以看出,DCASRN 网络在参数量极小的情况下表现出了有竞争

力的结果。

5.2 未来工作展望

本文提出了两种单图像超分辨率网络并都取得了不错的结果,但仍有一些不足和需要改进优化的地方,主要包括以下几个方面:

(1)本文使用的是基于 Transformer 的网络,针对大尺度图像,如遥感图像,仍然需要将图像切割至合适大小再进行超分辨率,由于图像的切割会带来一定图像信息的丢失,所以这不利于大尺度图像的恢复。

(2)本文使用的单图像超分辨率网络是针对双三次下采样退化而设计的,如果要适用其他的退化,需要对应退化的数据集进行端到端的训练。这一点不利于模型应用的扩展,所以需要考虑更多更复杂的场景,针对这些场景来进一步优化模型,扩大模型的应用范围。

(3)本文提出的模型主要是应用于图像领域,未来需要扩展到其他领域,如视频超分辨率领域或其他低级视觉领域。

虽然单图像超分辨率技术的应用广泛,但仍然存在一些不足。随着未来计算能力的提升、深度学习算法的优化以及其他创新技术的出现,相信单图像超分辨率技术将会得到进一步的发展,满足人们对高质量图像的需求。

参考文献

- [1] Freeman W T, Pasztor E C, Carmichael O T. Learning low-level vision[J]. International journal of computer vision, 2000, 40: 25-47.
- [2] Lu T, Wang J, Zhang Y, et al. Satellite image super-resolution via multi-scale residual deep neural network[J]. Remote Sensing, 2019, 11(13): 1588.
- [3] 许晓阳, 张梦飞. 融合 LR 编码网络和扩散模型的遥感图像超分辨率算法[J]. 计算机工程与应用, 2024: 1-12.
- [4] Isaac J S, Kulkarni R. Super resolution techniques for medical image processing[C]. 2015 International Conference on Technologies for Sustainable Development (ICTSD). IEEE, 2015: 1-6.
- [5] 卢峰, 周琳, 蔡小辉. 面向安防监控场景的低分辨率人脸识别算法研究[Z]. 计算机应用研究: Vol. 38. 2021: 1230-1234.
- [6] Gribbon K T, Bailey D G. A novel approach to real-time bilinear interpolation[C]. Proceedings. DELTA 2004. Second IEEE international workshop on electronic design, test and applications. IEEE, 2004: 126-131.
- [7] Keys R. Cubic convolution interpolation for digital image processing[J]. IEEE transactions on acoustics, speech, and signal processing, 1981, 29(6): 1153-1160.
- [8] Nitta K, Shogenji R, Miyatake S, et al. Image reconstruction for thin observation module by bound optics by using the iterative backprojection method[J]. Applied Optics, 2006, 45(13): 2893-2900.
- [9] Elad M, Feuer A. Super-resolution reconstruction of an image[C]. Proceedings of 19th convention of electrical and electronics engineers in Israel. IEEE, 1996: 391-394.
- [10] Sønderby C K, Caballero J, Theis L, et al. Amortised map inference for image super-resolution[J]. arXiv preprint arXiv:1610.04490, 2016.
- [11] Dong C, Loy C C, He K, et al. Learning a Deep Convolutional Network for Image Super-Resolution[M]. FLEET D, PAJDLA T, SCHIELE B, et al. Computer Vision – ECCV 2014: Vol. 8692. Cham: Springer International Publishing, 2014: 184-199.
- [12] Zhang Y, Li K, Li K, et al. Image super-resolution using very deep residual channel attention networks[C]. Proceedings of the European conference on computer vision (ECCV). 2018: 286-301.

-
- [13] Zhao H, Kong X, He J, et al. Efficient Image Super-Resolution Using Pixel Attention[J]. arXiv:2010.01073 [cs, eess], 2020.
 - [14] Kong F, Li M, Liu S, et al. Residual local feature network for efficient super-resolution[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 766-776.
 - [15] Rukundo O, Cao H. Nearest neighbor value interpolation[J]. arXiv preprint arXiv:1211.1768, 2012.
 - [16] Li X, Orchard M T. New edge-directed interpolation[J]. IEEE transactions on image processing, 2001, 10(10): 1521-1527.
 - [17] Battiato S, Gallo G, Stanco F. A locally adaptive zooming algorithm for digital images[J]. Image and vision computing, 2002, 20(11): 805-812.
 - [18] Tsai R Y, Huang T S. Multiframe image restoration and registration[J]. Multiframe image restoration and registration, 1984, 1: 317-339.
 - [19] Chang H, Yeung D Y, Xiong Y. Super-resolution through neighbor embedding[C]. Proceedings of the 2004 IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2004. CVPR 2004.: Vol. 1. IEEE, 2004: I-I.
 - [20] Yang J, Wright J, Huang T S, et al. Image super-resolution via sparse representation[J]. IEEE transactions on image processing, 2010, 19(11): 2861-2873.
 - [21] Wang X, Yu K, Wu S, et al. Esrgan: Enhanced super-resolution generative adversarial networks[C]. Proceedings of the European conference on computer vision (ECCV) workshops. 2018: 0-0.
 - [22] Saharia C, Ho J, Chan W, et al. Image super-resolution via iterative refinement[J]. IEEE transactions on pattern analysis and machine intelligence, 2022, 45(4): 4713-4726.
 - [23] Chen H, Wang Y, Guo T, et al. Pre-Trained Image Processing Transformer[C]. 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Nashville, TN, USA: IEEE, 2021: 12294-12305.
 - [24] Liang J, Cao J, Sun G, et al. Swinir: Image restoration using swin transformer[C]. Proceedings of the IEEE/CVF international conference on computer vision. 2021: 1833-1844.
 - [25] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]. Proceedings of the IEEE conference on computer vision and pattern recognition.

2016: 770-778.

- [26] Kim J, Lee J K, Lee K M. Accurate image super-resolution using very deep convolutional networks[C]. Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 1646-1654.
- [27] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial networks[J]. Communications of the ACM, 2020, 63(11): 139-144.
- [28] Ledig C, Theis L, Huszár F, et al. Photo-realistic single image super-resolution using a generative adversarial network[C]. Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 4681-4690.
- [29] Liu Z, Lin Y, Cao Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]. Proceedings of the IEEE/CVF international conference on computer vision. 2021: 10012-10022.
- [30] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [31] Dong X, Bao J, Chen D, et al. Cswin transformer: A general vision transformer backbone with cross-shaped windows[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 12124-12134.
- [32] Chollet F. Xception: Deep learning with depthwise separable convolutions[C]. Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1251-1258.
- [33] Zamir S W, Arora A, Khan S, et al. Restormer: Efficient transformer for high-resolution image restoration[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 5728-5739.
- [34] Morris R G M. Parallel distributed processing[J]. Implications for, 1989.
- [35] Liu J, Zhang W, Tang Y, et al. Residual feature aggregation network for image super-resolution[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 2359-2368.
- [36] Glorot X, Bordes A, Bengio Y. Deep sparse rectifier neural networks[C]. Proceedings of the fourteenth international conference on artificial intelligence and statistics. JMLR Workshop and Conference Proceedings, 2011: 315-323.
- [37] Du Z, Liu D, Liu J, et al. Fast and memory-efficient network towards efficient image super-resolution[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 853-862.
- [38] Lim B, Son S, Kim H, et al. Enhanced deep residual networks for single image

-
- super-resolution[C]. Proceedings of the IEEE conference on computer vision and pattern recognition workshops. 2017: 136-144.
- [39] Han J, Moraga C. The influence of the sigmoid function parameters on the speed of backpropagation learning[C]. International workshop on artificial neural networks. Springer, 1995: 195-201.
- [40] Clevert D A, Unterthiner T, Hochreiter S. Fast and accurate deep network learning by exponential linear units (elus). arXiv 2015[J]. arXiv preprint arXiv:1511.07289, 2020.
- [41] Maas A L, Hannun A Y, Ng A Y. Rectifier nonlinearities improve neural network acoustic models[C]. Proc. icml: Vol. 30. Atlanta, GA, 2013: 3.
- [42] Ba J L, Kiros J R, Hinton G E. Layer normalization[J]. arXiv preprint arXiv:1607.06450, 2016.
- [43] Chen X, Wang X, Zhou J, et al. Activating more pixels in image super-resolution transformer[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 22367-22377.
- [44] Yoo J, Kim T, Lee S, et al. Enriched cnn-transformer feature aggregation networks for super-resolution[C]. Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision. 2023: 4956-4965.
- [45] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale[J]. ICLR, 2021.
- [46] Li W, Lu X, Qian S, et al. On efficient transformer-based image pre-training for low-level vision[J]. arXiv preprint arXiv:2112.10175, 2021.
- [47] Wang Z, Cun X, Bao J, et al. Uformer: A general u-shaped transformer for image restoration[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 17683-17693.
- [48] He K, Zhang X, Ren S, et al. Delving deep into rectifiers: Surpassing human-level performance on imagenet classification[C]. Proceedings of the IEEE international conference on computer vision. 2015: 1026-1034.
- [49] Timofte R, Agustsson E, Van Gool L, et al. Ntire 2017 challenge on single image super-resolution: Methods and results[C]. Proceedings of the IEEE conference on computer vision and pattern recognition workshops. 2017: 114-125.
- [50] Bevilacqua M, Roumy A, Guillemot C, et al. Low-complexity single-image super-resolution based on nonnegative neighbor embedding[J]. 2012.
- [51] Zeyde R, Elad M, Protter M. On single image scale-up using sparse-

- hr/>
- representations[C]. Curves and Surfaces: 7th International Conference, Avignon, France, June 24-30, 2010, Revised Selected Papers 7. Springer, 2012: 711-730.
- [52] Martin D, Fowlkes C, Tal D, et al. A database of human segmented natural images and its application to evaluating segmentation algorithms and measuring ecological statistics[C]. Proceedings Eighth IEEE International Conference on Computer Vision. ICCV 2001: Vol. 2. IEEE, 2001: 416-423.
- [53] Huang J B, Singh A, Ahuja N. Single image super-resolution from transformed self-exemplars[C]. Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 5197-5206.
- [54] Matsui Y, Ito K, Aramaki Y, et al. Sketch-based manga retrieval using manga109 dataset[J]. Multimedia tools and applications, 2017, 76: 21811-21838.
- [55] Wang Z, Bovik A C, Sheikh H R, et al. Image quality assessment: from error visibility to structural similarity[J]. IEEE transactions on image processing, 2004, 13(4): 600-612.
- [56] Zhang R, Isola P, Efros A A, et al. The unreasonable effectiveness of deep features as a perceptual metric[C]. Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 586-595.
- [57] Mittal A, Soundararajan R, Bovik A C. Making a “completely blind” image quality analyzer[J]. IEEE Signal processing letters, 2012, 20(3): 209-212.
- [58] Gu J, Dong C. Interpreting Super-Resolution Networks with Local Attribution Maps[C]. 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Nashville, TN, USA: IEEE, 2021: 9195-9204.
- [59] Yang J, Li C, Zhang P, et al. Focal Self-attention for Local-Global Interactions in Vision Transformers[Z]. 2021.
- [60] Zuo S, Xiao Y, Chang X, et al. Vision transformers for dense prediction: A survey[J]. Knowledge-Based Systems, 2022, 253: 109552.
- [61] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]. Medical image computing and computer-assisted intervention–MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III 18. Springer, 2015: 234-241.
- [62] Zhang X, Zeng H, Guo S, et al. Efficient Long-Range Attention Network for Image Super-Resolution[M]. AVIDAN S, BROSTOW G, CISSÉ M, et al. Computer Vision – ECCV 2022: Vol. 13677. Cham: Springer Nature Switzerland, 2022: 649-667.

-
- [63] Thornton M W, Atkinson P M, Holland D A. Sub-pixel mapping of rural land cover objects from fine spatial resolution satellite sensor imagery using super-resolution pixel-swapping[J]. *International Journal of Remote Sensing*, 2006, 27(3): 473-491.
 - [64] Hendrycks D, Gimpel K. Gaussian error linear units (gelus)[J]. *arXiv preprint arXiv:1606.08415*, 2016.
 - [65] Diederik P K. Adam: A method for stochastic optimization[J]. (No Title), 2014.
 - [66] Dong C, Loy C C, Tang X. Accelerating the super-resolution convolutional neural network[C]. *Computer Vision—ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11-14, 2016, Proceedings, Part II 14*. Springer, 2016: 391-407.
 - [67] Kim J, Lee J K, Lee K M. Deeply-recursive convolutional network for image super-resolution[C]. *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2016: 1637-1645.
 - [68] Lai W S, Huang J B, Ahuja N, et al. Deep laplacian pyramid networks for fast and accurate super-resolution[C]. *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2017: 624-632.
 - [69] Tai Y, Yang J, Liu X. Image super-resolution via deep recursive residual network[C]. *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2017: 3147-3155.
 - [70] Tai Y, Yang J, Liu X, et al. Memnet: A persistent memory network for image restoration[C]. *Proceedings of the IEEE international conference on computer vision*. 2017: 4539-4547.
 - [71] Zhang K, Zuo W, Zhang L. Learning a Single Convolutional Super-Resolution Network for Multiple Degradations[J]. *arXiv:1712.06116 [cs]*, 2018.
 - [72] Ahn N, Kang B, Sohn K A. Fast, accurate, and lightweight super-resolution with cascading residual network[C]. *Proceedings of the European conference on computer vision (ECCV)*. 2018: 252-268.
 - [73] Hui Z, Gao X, Yang Y, et al. Lightweight Image Super-Resolution with Information Multi-distillation Network[C]. *Proceedings of the 27th ACM International Conference on Multimedia*. 2019: 2024-2032.
 - [74] Li W, Zhou K, Qi L, et al. Lapar: Linearly-assembled pixel-adaptive regression network for single image super-resolution and beyond[J]. *Advances in Neural Information Processing Systems*, 2020, 33: 20343-20355.

-
- [75] Liu J, Tang J, Wu G. Residual feature distillation network for lightweight image super-resolution[C]. Computer Vision–ECCV 2020 Workshops: Glasgow, UK, August 23–28, 2020, Proceedings, Part III 16. Springer, 2020: 41-55.
 - [76] Wang X, Wang Q, Zhao Y, et al. Lightweight Single-Image Super-Resolution Network with Attentive Auxiliary Feature Learning[M]. ISHIKAWA H, LIU C L, PAJDLA T, et al. Computer Vision – ACCV 2020: Vol. 12623. Cham: Springer International Publishing, 2021: 268-285.
 - [77] Zhou D, Chen Y, Li W, et al. Image super-resolution based on adaptive cascading attention network[J]. Expert Systems with Applications, 2021, 186: 115815.
 - [78] Luo X, Xie Y, Zhang Y, et al. LatticeNet: Towards Lightweight Image Super-Resolution with Lattice Block[M]. VEDALDI A, BISCHOF H, BROX T, et al. Computer Vision – ECCV 2020: Vol. 12367. Cham: Springer International Publishing, 2020: 272-289.
 - [79] Wang C, Li Z, Shi J. Lightweight image super-resolution with adaptive weighted learning network[J]. arXiv preprint arXiv:1904.02358, 2019.
 - [80] Muqet A, Hwang J, Yang S, et al. Multi-attention Based Ultra Lightweight Image Super-Resolution[M]. BARTOLI A, FUSIELLO A. Computer Vision – ECCV 2020 Workshops: Vol. 12537. Cham: Springer International Publishing, 2020: 103-118.
 - [81] Zhu X, Guo K, Ren S, et al. Lightweight image super-resolution with expectation-maximization attention mechanism[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2021, 32(3): 1273-1284.
 - [82] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25.
 - [83] Zhang X, Zhou X, Lin M, et al. Shufflenet: An extremely efficient convolutional neural network for mobile devices[C]. Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 6848-6856.
 - [84] Li X, Dong J, Tang J, et al. DLGSANet: lightweight dynamic local and global self-attention networks for image super-resolution[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 12792-12801.

攻读硕士学位期间发表的论文及其它成果

(一)发表的学术论文

- [1] 刘玉铠, 周登文. 基于多路特征渐进融合和注意力机制的轻量级图像超分辨率重建[J].智能系统学报 (已接收但尚未发表)
- [2] Li, Shanshan, Dengwen Zhou, Yukai Liu, et al. "Lightweight single image super-resolution based on multi-path progressive feature fusion and attention mechanism." International Journal of Machine Learning and Cybernetics 14, no. 10 (2023): 3517-3528. (SCI 收录号: WOS:000990616000001, IF=5.6)
- [3] 周登文,刘子涵,刘玉铠. 基于像素对比学习的图像超分辨率算法 [J]. 自动化学报, 2024, 50 (01): 181-193.
- [4] 刘子涵, 周登文, 刘玉铠. 基于全局依赖 Transformer 的图像超分辨率网络 [J]. 计算机应用, 1-11.

致 谢

在完成毕业论文之际，我要向所有在这个过程中给予我帮助和支持的人表示衷心的感谢。这段旅程不仅是我学术探索的挑战，更是我个人成长的关键时期。正是有了你们的帮助，我才能取得今天的成就。

首先，我要特别感谢我的导师周登文教授。您丰富的专业知识和悉心指导对我的论文至关重要。感谢您的耐心、无私支持以及深刻洞察力，使我能在研究的道路上保持正确的方向和专注度。

我还要感谢我的同门刘子涵、乌恩和邱连明。在漫长的学术研究和日常生活中，有你们的陪伴和帮助，使我感受到了无比的温暖和力量。我们之间的讨论和合作极大地充实了我的学习体验，并为我的论文增添了宝贵的视角。

同时，我也要感谢我的学弟李可、马冀、袁江、林家乐和张豪，感谢他们在实验设计、数据收集和论文初稿审阅等方面给予的帮助。他们的辛勤工作和热情对我完成论文起到了重要作用。

此外，我必须向我的家人表达最深厚的感激之情。感谢他们无条件的理解、鼓励和支持，为我提供了坚实的后盾，使我得以全心投入到学习和研究中。每当面临困难和挑战时，家人的爱是支撑我前行的最大动力。

我还要感谢参与论文评审和答辩的所有专家和老师。感谢你们提出的专业意见和建议，极大地提升了我的论文质量，并为我指明了未来学术道路上更高远的方向。

最后，对所有参考文献的作者和出版机构表示由衷的感激。正是你们辛勤的工作为我的研究提供了宝贵的知识资源和灵感。

感谢所有给予我帮助和支持的人。都是我成功完成论文不可或缺的一部分。我将这份成就献给你们，感谢你们的付出和关怀，我将永远铭记在心。谢谢你们！