

基于双路的卷积和 Transformer 的轻量化多尺度特征融合超分辨率网络

李可¹ 刘钰恺¹ 刘子涵²

摘要 基于深度学习的单图像超分辨率 (SISR) 算法已经成为主流, 然而, 传统卷积神经网络 (CNN) 和 Transformer 网络在性能方面存在问题。本文提出了一种双路互补的 SISR 网络, 一路使用 Transformer 提取局部和区域特征, 一路使用基于卷积神经网络 (CNN) 提取全局特征, 结合通道和空间增强注意力实现全局和局部特征融合。此外我们增加了多尺度结合通道注意力融合模块和多阶段中间特征的加法融合块, 进一步提高了性能。实验结果表明, 本文提出的模型在同参数量的模型对比下, 性能达到了最优。

关键词 Latex, 模板

引用格式 李可. 这是一个模板. xxx 期刊, 2021, XX(X): X-X

DOI xxxxxxxxxxxxxxxxxxxxxxxxx

This Is a Template

Li Ke¹ Liu Yukai¹ Liu Zihan¹

Abstract Deep learning-based single-image super-resolution (SISR) algorithms have become mainstream, however, traditional convolutional neural network (CNN) and Transformer networks have problems in performance. In this paper, we propose a two-way complementary SISR network, one way using a Transformer to extract local and regional features, and one way using a convolutional neural network (CNN) to extract global features, which combines channel and spatially augmented attention to achieve global and local feature fusion. In addition, we add a multi-scale combined channel attention fusion block and an additive fusion block for multi-stage intermediate features to improve the performance further. The experimental results show that the performance of the model proposed in this paper is optimal under the comparison of models with the same amount of parameters.

Key words latex, template

Citation Li Ke. This Is a Template. xxx Journal, 2021, XX(X): X-X

1 引言

单图像超分辨率 (SISR: Single Image Super Resolution) 问题是图像超分辨率 (SR: Super-Resolution) 领域的经典问题。目标是从给定的低分辨率 (LR: Low Resolution) 图像进行图像重建和恢复, 从而得到对应的高分辨率 (HR: High Resolution) 图像。目前该技术在医疗成像, 遥感, 视频监控等图像领域得到了广泛的应用。有关于图像超分辨率的研究已经取得了深厚的发展, 而目前基于深度学习的图像超分辨率算法已经广泛的应用于单图像超分辨率任务中。基于深度学习的超分辨率算法主要的优点是它不再需要人为的去在前期阶段进行数据特征的处理, 而是使用端到端的方式去学习 LR 和 HR 之间的映射函数, 并且大幅的提升了 SISR 相关模型的性能。




图 2 参数量对比图

在深度学习应用于图像超分辨率问题的早期, 主要自 Dong 等人的工作开始, 主要使用的是卷积神经网络 (CNN: Convolutional Neural Network) 来进行图像超分辨率任务。但是使用卷积神经网络的

国家自然科学基金 (xxxxxx) 资助
Supported by National Natural Science Foundation of China (xxxx)
1. 华清大学雷系 北京 100084
1. Department of Thunder, Huatsing University, Beijing 100084




图 1 DMFFN 网络框架.

主要的问题在于卷积神经网络的性能眼中依赖其本身网络规模，也就是参数量和计算量的大小。要想增强和改进卷积神经网络的性能，只能增加网络规模和网络深度。参数量过于大的模型对硬件的设备要求比较高，需要对应设备有较强的计算能力和储存能力，因此参数量过大的模型难以在非专业级的设备上部署训练，这对计算资源缺乏的个人，企业或者研究机构来说是一个挑战，因此研究一种轻量化的处理图像超分辨率的网络，并且处理好降低模型参数和计算量与模型性能之间的平衡是有必要的。

除此之外，由于 Transformer 在自然语言处理 (NLP: Natural Language Processing) 获得了巨大的成功，Transformer 也被迁移到了计算机视觉领域。并取得了广泛的成功。基于 Liu 等人提出的 Swin Transformer 被广泛的应用在了计算机视觉任务上，通过对图片切分窗口，并且在窗口与窗口之间使用相对位置编码或者绝对位置编码，从而使 Transformer 在图片上也具有长距离建模的能力，取得超

越原先卷积网络的性能。

虽然 Transformer 在计算机视觉领域已经取得了很大的成功，但是其任然存在一些缺陷：Transformer 在方形窗口内部进行的自注意力计算仅仅是局部注意力，而像素点之间全局依赖的建立取决于窗口的移动距离，也就是 Transformer 的网络层数。因此，对于参数量小，网络层数少的基于 Transformer 的超分辨率网络无法有效建立全局依赖，会严重影响网络的性能。

所以，在轻量化超分辨率网络的设计中，使用单一的卷积神经网络或者是 Transformer 网络都很难达到较高的图像恢复的性能，基于此，本文设计了一种双路互补的超分辨率网络，一条支路使用 Transformer 对图像进行局部和区域特征的提取，一条支路使用深度可分离处理后的卷积块组成的卷积神经网络，并结合通道注意力和空间增强注意力对图像进行全局的粗粒度特征的提取，最后对双支路所提取到的特征进行结合，从而使结合后的特征拥有充

足的全局和局部的特征信息,从而达到提高模型图像恢复和图像重建的能力的目的。

此外,为了提高模型在训练阶段时对图像特征的学习能力并降低模型在推理阶段的计算量,本文在卷积分支上采用了 repVGG 的设计思路,在卷积块的残差链接之外再加一个 1×1 的卷积,从而使得卷积分支在每一阶段都有三条支路,从而增加了模型的复杂度,提高了对于图像特征的学习效果。在模型推理阶段,本文将多余的 1×1 的卷积分支去除,从而可以使得模型在推理时的计算量大幅度降低,并维持一个相对不变的性能。

在双路特征的融合上,本文提出了一种多尺度结合通道注意力融合模块,通过对输入特征进行多次拆分到多支路进行卷积或者通道注意力计算并融合,我们可以使得双支路的特征在融合块处理后不会再有明显的分界,从而使得局部信息和全局信息能够进行充分地融合。此外,本文在图像重建模块之前将所有中间阶段的特征都进行了加法结合,本文认为,在深度图像超分辨率网络中,随着深度的加深,网络会逐渐舍弃低频特征而保留高频特征,但是实际上在图像恢复中,无论是低频特征还是高频特征,有应包含一定的有效信息,所以为了充分地利用低频和高频的信息,本文选择将各个阶段的特征进行结合,从而最大限度地保留对回复图像有效的信息。

在图像重建阶段,本文采用了该领域广泛采用的亚像素卷积对特征进行上采样。

如图所示,本文提出的模型在同参数量的模型对比下,性能达到了最优。

本文的主要工作有:

1) 提出了一种全新的双路 Transformer 和卷积神经网络的混合结构。该结构将卷积神经网络和 Transformer 所提取的特征进行结合,从而能够充分提取图像的全局和局部特征,获得整个特征图信息的补充。

2) 在卷积分支使用空间增强注意力模块,从而使得卷积神经网络能够提取图像粗粒度的全局特征,进而对 Transformer 分支进行信息的补充并使用 repVGG 的设计思路,在增加卷积分支模型复杂度的同时,在推理阶段大幅度的降低了模型的计算量。

3) 设计了一种多尺度多路特征融合块,通过对输入特征进行多次拆分到多支路进行卷积或者通道注意力计算并融合,使得双支路特征能够进行信息的互补。

4) 设计了多阶段的中间特征的加法融合,保留了有利于图像恢复的低频和高频信息,提升了图像的恢复性能。

2 相关工作

2.1 轻量级 SISR 方法

Dong 等人第一次提出了通过卷积神经网络(CNN)来处理单图像超分辨率,称作 SRCNN (super-resolution using convolutional neural network)。在此之后,国内外出现了大量的使用深度学习和卷积神经网络处理单图像超分辨率的方法。一般来说,随着卷积神经网络模型层数和参数量的增加,模型的表达能力和性能就会越好。但是,随着网络规模的增加,过大的参数量和计算量将会限制模型在硬件设备上的部署和训练,所以为了解决这一问题,出现了很多基于卷积神经网络的轻量化处理办法,包括但不限于使用递归结构,深度可分离卷积等方式去降低模型的参数量和计算量。本文中也用到了上述的一些方法,使用深度可分离卷积去降低卷积分支的参数量和计算量,从而提高了模型的性能和计算效率。

2.2 Transformer 和卷积神经网络双路径融合结构

单一的 Transformer 结构或者是卷积神经网络结构在单图像超分辨率问题上有较大的局限性,具体表现为在处理 LR 图象时无法很好的提取图像的全局特征,缺少充足的全局信息来恢复图像。即使是在 Swin Transformer 提出之后,对于图像的划分窗口也使得 Transformer 只能提取窗口内的特征,而不是真正意义上全局的图像特征。

Yoo 等人的论文提出了使用 Transformer 和卷积神经网络的双路结构,利用卷积神经网络分支所提取到的特征与 Transformer 所提取到的特征进行融合,从而对 Transformer 所提取到的信息进行补充,以达到提高模型恢复图像的性能的效果。

本文主要的工作也基于 Yoo 等人的思想,本文认为在卷积分支加入空间注意增强块(ESA)可以帮助卷积分支去提取全局图片的粗粒度的特征,从而对 Transformer 分支进行缺失信息的补充。

3 本文方法

本文提出了一种全新的基于双路的 Transformer 和卷积神经网络融合的轻量化图像超分辨率网络,主要结构如图所示()。该网络主要包括如下结构:浅层特征提取块,卷积神经网络块,Transformer 块,双支路融合块,和上采样块。浅层特征提取块的主要结构是一个 3×3 的卷积和一个 ELU 激活函数。卷积神经网络块主要由分组卷积,逐深度卷积,通道混洗三个部分组合的模块堆叠而成,并与空间增强注意力块结合,第一部分主要目的是尽可能的对模型进行轻量化处理,降低整体卷积分支

表 1 Add caption

缩放倍率	模型	参数量 (/K)	训练集	Set5		Set14		B100		Manga109		Urban100	
				PSNR	SSIM	PSNR	SSIM	PSNR	SSIM	PSNR	SSIM	PSNR	SSIM
X2	EDSR-baseline	1370	DIV2K	37.99	0.9604	33.57	0.9175	32.16	0.8994	38.54	0.9769	31.98	0.9272
	IMDN	694	DIV2K	38.00	0.9605	33.63	0.9177	32.19	0.8996	38.88	0.9774	32.17	0.9283
	LatticeNet	756	DIV2K	38.06	0.9607	33.7	0.9187	32.20	0.8999			32.25	0.9288
	SwinIR-light	878	DIV2K	38.14	0.9611	33.86	0.9206	32.31	0.9012	39.12	0.9783	32.76	0.9340
	ELAN-light	582	DIV2K	38.17	0.9611	33.94	0.9207	32.30	0.9012	39.11	0.9782	32.76	0.9340
	DLGSANet-tiny	566	DIV2K	38.16	0.9611	33.92	0.9202	32.26	0.9007	39.14	0.9777	32.82	0.9343
	DLGSANet-light	745	DIV2K	38.20	0.9612	33.89	0.9203	32.30	0.9012	39.29	0.9780	32.94	0.9355
	DMFFN (ours)	748	DIV2K	38.20	0.9613	33.87	0.9199	32.29	0.9011	39.21	0.9782	32.76	0.9336
X3	EDSR-baseline	1370	DIV2K	34.37	0.9270	30.28	0.8417	29.09	0.8052	33.45	0.9439	28.15	0.8527
	IMDN	694	DIV2K	34.36	0.9270	30.32	0.8417	29.09	0.8046	33.61	0.9445	28.17	0.8519
	LatticeNet	756	DIV2K	34.40	0.9272	30.32	0.8416	29.10	0.8049			28.19	0.8513
	SwinIR-light	878	DIV2K	34.62	0.9289	30.54	0.8463	29.20	0.8082	33.98	0.9478	28.66	0.8624
	ELAN-light	582	DIV2K	34.61	0.9288	30.55	0.8463	29.21	0.8081	34.00	0.9478	28.69	0.8624
	DLGSANet-tiny	566	DIV2K	34.63	0.9288	30.57	0.8459	29.21	0.8083	34.10	0.9480	28.69	0.8630
	DLGSANet-light	745	DIV2K	34.70	0.9295	30.58	0.8465	29.24	0.8089	34.16	0.9483	28.83	0.8653
	DMFFN (ours)	748	DIV2K	34.62	0.9293	30.48	0.8467	29.26	0.8094	34.31	0.9490	28.78	0.8645
X4	EDSR-baseline	1370	DIV2K	32.09	0.8938	28.58	0.7813	27.57	0.7357	30.35	0.9067	26.04	0.7849
	IMDN	694	DIV2K	32.21	0.8948	28.58	0.7811	27.56	0.7353	30.45	0.9075	26.04	0.7838
	LatticeNet	756	DIV2K	32.18	0.8943	28.61	0.7812	27.57	0.7355			26.14	0.7844
	SwinIR-light	878	DIV2K	32.44	0.8976	28.77	0.7858	27.69	0.7406	30.92	0.9151	26.47	0.7980
	ELAN-light	582	DIV2K	32.43	0.8975	28.78	0.7858	27.69	0.7406	30.92	0.9150	26.54	0.7982
	DLGSANet-tiny	566	DIV2K	32.46	0.8984	28.79	0.7861	27.70	0.7408	30.98	0.9137	26.55	0.8002
	DLGSANet-light	745	DIV2K	32.54	0.8993	28.84	0.7871	27.73	0.7415	31.13	0.9161	26.66	0.8033
	DMFFN (ours)	748	DIV2K	32.41	0.8981	28.74	0.7874	27.74	0.7421	31.24	0.9170	26.67	0.8029

的参数量和计算量。而空间增强注意力块的加入使得卷积分支拥有了能够提取全局图片粗粒度的信息的能力。Transformer 块使用了双支路融合块的主要功能是将卷积分支和 Transformer 分支分别提取到的特征充分地通过融合块进行融合。双支路融合块先是将两条支路提取到的不同的特征按通道拼接在一起，然后对拼接到一起的特征进行多尺度的处理，并在之后再次按通道均分成三到四组向量，分别对其使用通道注意力进行处理，最后将得到的特征再进行融合。这样操作的主要目的是为了输入进融合块的特征能够充分地互相结合到一起，而不是特征与特征之间出现明显的界限。

Transformer 分支本文使用了条形的注意力窗口办法去进行注意力的计算。通过竖向和横向的条形窗口进行注意力计算，本文可以增大注意力的感受野，从而提取到图片中更多的特征。实验结果也证明，当本文使用条形窗口法进行注意力计算时和仅仅使用 Swin Transformer 这种方形窗口进行注意力计算时，在 Manga109 测试集上，前者要比后者在 PSNR 上要高接近 0.2dB 到 0.3dB，说明这种方法是有一定效果的。

下面详细介绍该结构的各个部分：假设输入的图像本文记作 I_{LR} ， I_{LR} 首先通过 3X3 的卷积层进行浅层特征提取，

$$F_0 = Conv_{3 \times 3}(I_{LR}) \quad (1)$$

之后 F_0 被输入到提取融合快中进行特征提取的处理，特征提取块总共有四块：

$$F_n = H(F_{n-1}), n = 1..4 \quad (2)$$

然后，对各个阶段的提取到的特征进行拼接，并输入到多路特征融合块中：

$$\begin{aligned} F_{M0} &= Concat(F_1, F_2, F_3, F_4) \\ F_M &= AbstractBlock(F_{M0}) \end{aligned} \quad (3)$$

最后，对充分融合过后的特征进行上采样图像重建，得到最终的超分辨率图像 I_{HR} ：

$$I_{HR} = UpSampling(F_M) \quad (4)$$

3.1 卷积特征提取块

如图所示，卷积特征提取块由 3X3 的卷积层，连续 6 个残差卷积块构成。对于每一个输入到卷积分支的特征 f ，先是让特征通过一个 3X3 的卷积：

$$f_0 = Conv_{3 \times 3}(f) \quad (5)$$

, 之后在连续通过 6 个残差卷积块:

$$f_n = \text{ResBlock}(f_{n-1}), n = 1 \dots 6 \quad (6)$$

, 最后输出特征

$$f = f_6 * \text{res_scale} + f_0 \quad (7)$$

res_scale 是人为定义的缩放系数.

残差块主要由深度可分离卷积块 (Shuffle_Block), 一个残差链接和一个 1X1 的卷积分支并列以及通道注意力和空间增强注意力组成, 首先是深度可分离卷积块, 对于输入的特征 f' , 先是通过一个 1X1 的卷积

$$f'_0 = \text{Conv1X1}(f') \quad (8)$$

, 之后依次通过按通道分成四组的分组卷积、通道混洗、逐深度卷积和通道分成四组的分组卷积:

$$\begin{aligned} f'_1 &= \text{GroupConv}_4(f'_0) \\ f'_2 &= \text{ChannelShuffle}(f'_1) \\ f'_3 &= \text{DWconv}(f'_2) \\ f'' &= \text{GroupConv}_4(f'_3) \end{aligned} \quad (9)$$

以上是深度可分离卷积块的组成, 所以对于输入进残差块的特征 f' , 本文有:

$$\begin{aligned} f'_{out1} &= \text{ELU}(f' + \text{Conv1X1}(f')) \\ &\quad + \text{Shuffle_Block}(f') \\ f'_{out2} &= \text{ELU}(f'_{out1} + \text{Conv1X1}(f'_{out1})) \\ &\quad + \text{Shuffle_Block}(f'_{out1})) \\ f_n &= \text{ESA}(\text{CA}(f'_{out2}) * \text{res_scale}) \\ &\quad , n = 1 \dots 6 \end{aligned} \quad (10)$$

其中两次 Shuffle Block 共享参数以降低参数量, res_scale 是人为定义的缩放系数

3.2 Transformer 特征提取快

在图像超分辨率领域中, Liang 等先提出了 SwinIR 作为 Transformer 应用到图像超分辨率领域的方案, 其主要思想是使用方形的移动窗口在固定长宽的窗口内进行注意力计算。但是实际上本文考虑到, 即便该方法宣称是提取图像的全局特征和可以进行高效的长距离建模, 进行注意力计算范围依旧是局限在给定窗口的大小内, 在参数量小, 模型层数少的网络中, Transformer 很难建立图像的全局依赖, 这会很大程度上限制网络的性能。

所以为了能尽可能地使得图中的任意两个点都能建立依赖, 并且不造成计算资源的浪费, 本文设

计使用长度为图像的长或宽, 宽度为一个像素的互相垂直的自注意力窗口, 来解决图像任意两个像素点进行依赖建模的能力。同时, 在相近的两个像素点之间使用互相垂直的注意力窗口进行计算同样会导致计算资源的浪费, 而使用方形注意力窗口计算量比较少, 所以本文在设计模型的时候交替使用互相垂直的自注意力窗口和方形的自注意力窗口来进行 Transformer, 从而使得整张图片的所有像素点都能直接或间接地进行交互, 从而提升模型的性能。

如图所示, 对于任意输入到该分支的特征 f , 先使其进入方形窗口模块进行处理:

$$f_1 = \text{SWTL}(f) \quad (11)$$

再使其进入横向或竖向的条形窗口进行注意力计算:

$$f_2 = \text{AWTRL}(f_1) \quad (12)$$

如此交替进行总共五次计算:

$$\begin{aligned} f_3 &= \text{SWTL}(f_2) \\ f_4 &= \text{AWTRL}(f_3) \\ f_5 &= \text{SWTL}(f_4) \end{aligned} \quad (13)$$

其中对于 SWTL, 结构如图所示, 对于输入的任何特征 f' :

$$\begin{aligned} f'_1 &= f' + \text{Layer_Norm}(\text{MHSA}(f')) \\ f'_2 &= f'_1 + \text{Layer_Norm}(\text{MLP}(f'_1)) \end{aligned} \quad (14)$$

对于 AWTRL, 结构如图所示, 对于输入的任何特征 f'' :

$$\begin{aligned} f''_1 &= f'' + \text{RB}(\text{Layer_Norm}(f'')) \\ &\quad + \text{MHSA}(\text{Layer_Norm}(f'')) \\ f''_2 &= f''_1 + \text{Layer_Norm}(\text{MLP}(f''_1)) \end{aligned} \quad (15)$$

3.3 双路融合块

本文设计的双路融合块的主要作用是通过该融合块将双支路提取到的特征充分地混合到一起, 并使其之间不会有明显的差别。这样的话本文可以实现将卷积提取到的全局粗粒度特征补充到 Transformer 所提取到的区域或者局部特征中, 实现信息量的增加以及图片细节的丰富。

如图所示, 对于输入到双路特征融合块的卷积分支特征 X_1 和 Transformer 特征 X_2 , 先按通道维进行 Concat:

$$X = \text{Concat}(X_1, X_2) \quad (16)$$

然后使用两个 1X1 的卷积保持通道不变进行卷积:

$$X_1 = \text{Conv}_{1 \times 1}(\text{relu}(\text{Conv}_{1 \times 1}(X))) \quad (17)$$

之后将初步处理得到的 X_1 输入到三条支路进行多尺度处理:

$$\begin{aligned} X_2 &= \text{Conv}_{1 \times 1}(X_1) \\ X_3 &= \text{Conv}_{3 \times 3}(X_1) \\ X_4 &= \text{Conv}_{3 \times 3}(\text{relu}(\text{Conv}_{3 \times 3}(X_1))) \end{aligned} \quad (18)$$

本文在多尺度处理的通道之间进行通道之间跨尺度的融合, 用以校准主干支路的特征:

$$\begin{aligned} X'_3 &= X_3 * \text{Sigmoid}(\text{Conv}_{1 \times 1}(X_2)) \\ X'_4 &= X_4 * \text{Sigmoid}(\text{Conv}_{1 \times 1}(X_3)) \end{aligned} \quad (19)$$

将处理后的主干支路的特征按通道进行融合, 最后进行通道自注意力, 得到本文融合后的特征:

$$\begin{aligned} X_5 &= \text{Conv}_{1 \times 1}(\text{Concat}(X_2, X'_3, X'_4)) \\ X_6 &= \text{Conv}_{1 \times 1}(\text{Concat}(CA(X_5) * X_2, CA(X_5) * X'_3, \\ &\quad , CA(X_5) * X'_4)) \\ F_n &= X_6 + X_1 \end{aligned} \quad (20)$$

3.4 多阶段特征融合快

特征进入多层的深度神经网络进行处理时, 随着层数的加深, 网络会逐渐保留高频的特征而舍弃低频的特征。但是在低级别视觉任务中, 在进行图像重建时特征中包含的信息量越多, 图像重建后生成的超分辨率图像效果就越好。基于此, 本文在图像重建模块之前加入了一个多特阶段的特征融合块, 目的是为了将之前四个阶段的中间特征在多阶段特征融合块中进行融合, 使得最后进行图像重建的特征同时包含高频信息和低频信息, 避免遗失掉一些有助于图像恢复的低频信息。

如图所示, 对于输入进多阶段特征融合块的特征 F_{M0} , 先使用两个 1X1 的卷积保持通道不变进行卷积:

$$f_{M1} = \text{Conv}_{1 \times 1}(\text{relu}(\text{Conv}_{1 \times 1}(F_{M0}))) \quad (21)$$

然后分别将 f_{M1} 输入到四个支路进行多尺度的

处理:

$$\begin{aligned} f_{M2} &= \text{Conv}_{1 \times 1}(f_{M1}) \\ f_{M3} &= \text{Conv}_{3 \times 3}(f_{M1}) \\ f_{M4} &= \text{Conv}_{3 \times 3}(\text{relu}(\text{Conv}_{3 \times 3}(f_{M1}))) \\ f_{M5} &= \text{Conv}_{3 \times 3}(\text{relu}(\text{Conv}_{3 \times 3}(\text{relu}(\text{Conv}_{3 \times 3}(f_{M1})))) \end{aligned} \quad (22)$$

之后本文进行跨支路之间的结合, 跨支路本文主要用一条包含 1X1 卷积和 Sigmoid 激活函数来对三条主干支路进行校准, 校准后的特征更新为:

$$\begin{aligned} f'_{M3} &= f_{M3} * \text{Sigmoid}(\text{Conv}_{1 \times 1}(f_{M2})) \\ f'_{M4} &= f_{M4} * \text{Sigmoid}(\text{Conv}_{1 \times 1}(f_{M3})) \\ f'_{M5} &= f_{M5} * \text{Sigmoid}(\text{Conv}_{1 \times 1}(f_{M4})) \end{aligned} \quad (23)$$

然后将校准后特征按通道维度 Concat 到一起, 并将其压缩至原来的通道维数:

$$f_{M6} = \text{Conv}_{1 \times 1}(\text{Concat}(f_{M2}, f'_{M3}, f'_{M4}, f'_{M5})) \quad (24)$$

之后将 f_{M6} 进行通道注意力后与先前未经过校准的特征分别进行按位乘法, 最后再按通道维数拼接到一起并最后进行残差链接:

$$\begin{aligned} f_{M7} &= \text{Conv}_{1 \times 1}(\text{Concat}(CA(f_{M6}) * f_{M2}, \\ &\quad CA(f_{M6}) * f'_{M3}, \\ &\quad , CA(f_{M6}) * f'_{M4}, CA(f_{M6}) * f'_{M5})) \\ F'M &= f_{M7} + f_{M1} \end{aligned} \quad (25)$$

最后对 $F'M$ 进行上采样图像恢复:



$$I_{HR} = \text{UpSample}(F'M) \quad (26)$$

4 实验细节

4.1 实验设置

本文在训练阶段使用了当前流行的 DIV2k 作为数据集, 并让其作为训练集。在预处理图片的过程中, 本文对数据集中的原 HR 图像进行双三次下采样, 以获得对应的 LR 图像, 并在训练之前对图像进行水平翻转和 90°, 180°, 270° 的随机旋转, 通过这些操作达到图像增强的效果。在训练时, 先训练 X2 的模型, 在 X2 模型训练完后将训练好的 X2 模型作为预训练模型加载到 X3 和 X4 的模型上进行后续的训练。

本文在测试阶段使用 Set5, Set14, Urban100, B100 和 Manga109 作为测试集。为与之前的模型进行公正的比较, 本文在 YCbCr 空间的亮度 (Y)

图 3 在 $\times 4$ 上主观效果图图 4 在 $\times 3$ 上主观效果图

通道上使用该领域广泛使用的峰值信噪比 (PSNR: peak signal to noise ratio) 和结构相似性 (SSIM: structural similarity index) 作为度量, 分别计算各个测试集的 PSNR 和 SSIM 值, 并进行对比。

在模型训练过程中, 每批次随机选取 48 个 64×64 的图像块。使用 Adam 作为优化器, 并设置 $\beta_1 = 0.9, \beta_2 = 0.99$ 。本文所有模型均设置为 1000000 个迭代周期, 学习率一开始设置为 $2e-4$, 并在第 50000, 80000, 90000, 95000 次迭代时学习率减半。损失函数设置为 L1 损失函数。

本文使用 Pytorch 框架, 2 个 Nvidia 2080Ti GPU 进行模型训练和测试。

4.2 消融实验

为了验证残差卷积块, Transformer 块, 双路多尺度特征融合块以及特征复用融合块的有效性, 本文总共设计了 4 组实验。第一个实验本文去除了特征复用融合块, 并沿通道维度进行拼接后使用卷积核为 1×1 延通道的卷积, 将最终的特征图像从 $4C$ 压缩到 C , 再进行后续的图像恢复。第二个实验去除了双路多尺度特征融合块, 并替换为沿通道维度进

行拼接后使用卷积核为 1×1 沿通道的卷积, 将特征图从 $2C$ 压缩到 C , 再进行后续图像的特征提取。第三组实验, 本文去掉了 Transformer 分支, 并使用与残差卷积分支相同的结构来替换 Transformer 分支, 使用残差卷积组合的两条通路来进行低分辨率图像特征的提取以及图像的恢复, 第四组实验, 本文去掉了残差卷积分支, 并且使用与 Transformer 分支相同的结构来替换残差卷积分支, 使用 Transformer 分支组合的两条通路来进行低分辨率图像特征的提取进行后续的图像的恢复。第五个实验, 本文使用未经修改的 DMFFN 作为对照组与其他四组实验形成对比。

五组实验均使用 $\times 3$ 的缩放倍率, 在 DIV2K 训练集上进行训练, 并使用 Manga109 作为验证集进行验证, 使用 PSNR 和 SSIM 来作为评估指标。由表 3 可知, 通过实验 5 和实验 1 对比, 实验 5 比实验 1 增加了 0.21dB, 说明特征复用融合块的添加充分地结合了之前每一个阶段的特征信息, 对最终的特征图进行了信息的补充, 从而可以利用充足的特征信息进行图像的恢复; 通过实验 5 和实验 2 对比, 实验 5 比实验 2 增加了 0.09dB, 说明双路多尺度融

表 2 消融实验结果

缩放倍率	CNN	Transformer	双路融合块	特征复用融合块	PSNR	SSIM
X4	√	√	√	√	31.24	0.9170
	√	√	√		31.03	0.9141
	√	√		√	31.15	0.9164
	√		√	√	30.37	0.9068
		√	√	√	30.55	0.9083

合块的添加增加了双支路特征的融合的复杂性，使得双支路分别提取到的特征能以一种相比于按通道直接拼接更为复杂的形式进行特征的混合，从而可以使得卷积分支能够高效地对 Transformer 分支进行信息的补充，从而增加后续的图像恢复能力；通过实验 5 和实验 3 对比，实验 5 比实验 2 增加 0.87dB，说明有 Transformer 所在的模型相比于只有残差卷积模块的模型，能够对图像特征信息进行充分地提取，从而增加图像的局部和区域地特征信息；通过实验 5 和实验 4 对比，实验 5 相比于实验 4 增加了 0.69dB，说明有残差卷积模块所在的模型相比于只有 Transformer 模块地模型，能够充分地提取图像粗粒度的全局信息，从而增加特征图像的在后续的

恢复效果.

5 结论

本文提出了一种基于十字窗口注意力和空间注意力增强的卷积神经网络的轻量化双路渐进特征多尺度融合网络。本文的主要工作是设计了双路渐进特征多尺度融合块和将空间增强注意力块结合到传统的单支路卷积网络，通过 Transformer 分支提取的图像的局部特征和卷积分支提取的粗粒度的全局特征相融合，从而高最终的信息利用率和模型的表达能力。实验结果表明：本文方法是有效的，不管从算法设计原理上还是具体客观实验上，都证明该模型明显优于现有的方法。